

概率论与数理统计工具箱

Gary Chen

目录

前言	7
概统课程知识脉络	8
知识树	8
概率论	8
I. 概率：如何描述不确定性	8
II. 随机变量：如何把随机现象数值化	8
III. 概率的“大样本规律”	9
数理统计：从样本反推未知总体	9
Ch8 数理统计基本概念	9
Ch9 参数估计	9
1 随机事件与概率	11
1.1 核心对象	11
1.2 σ -代数	11
1.3 概率公理及其推出的性质	11
2 条件概率与独立性	13
2.1 条件概率	13
2.2 乘法公式	13
2.3 全概率公式	13
2.4 Bayes 公式	13
2.5 独立性	14
3 离散型随机变量	15
3.1 PMF 概率质量函数	15
3.2 数学期望	15
3.3 方差	15
3.4 常见的离散分布及其性质	16
3.4.1 Bernoulli 分布	16
3.4.2 二项分布	16
3.4.3 Poisson 分布	17
3.4.4 几何分布	17
4 连续型随机变量	18
4.1 CDF 累积分布函数	18

4.2	PDF 概率密度函数	18
4.3	连续型期望	18
4.4	典型的连续分布	19
4.4.1	均匀分布	19
4.4.2	指数分布	19
4.4.3	正态分布	20
4.5	随机变量函数	20
5	多维随机向量	21
5.1	Joint: 联合分布	21
5.2	Marginal: 边缘化	21
5.3	Conditional: 条件分布	21
5.4	Independence: 独立性	21
5.5	和的分布与卷积	22
5.6	多维变量变换	22
6	多维随机向量的数学特征	23
6.1	Covariance: 协方差	23
6.1.1	协方差矩阵	23
6.2	Correlation: 相关系数	24
6.3	三个基础不等式	24
6.3.1	Jensen 不等式	24
6.3.2	Cauchy-Schwarz 不等式	25
6.3.3	Hölder 不等式	25
6.4	Conditional Expectation: 条件期望	26
6.4.1	条件期望首先是随机变量	26
6.4.2	计算期望的另一种方法	27
6.4.3	全期望公式	28
6.4.4	条件期望: 信息子空间上的正交投影	28
6.4.5	全方差公式: 概率空间中的勾股定理	29
6.5	多维正态分布	31
6.5.1	Mahalanobis 几何与白化	31
6.5.2	边缘分布与独立性	32
6.5.3	多元正态的条件分布	33
6.5.4	线性高斯观测的统一更新	33
7	集中不等式与集中定理	35
7.1	Markov Inequality	35
7.2	Chebyshev Inequality	35
7.3	Chernoff 方法	35
7.4	Hoeffding 型有界变量界	36
7.5	随机变量序列的收敛方式	36
7.5.1	四种常用收敛	36

7.5.2	强弱关系	37
7.5.3	连续映射、Slutsky 与 Delta method	37
7.6	大数定律 (LLN)	38
7.6.1	四个经典版本	39
7.6.2	有限方差下弱大数律的关键推导	41
7.7	中心极限定理 (CLT)	42
7.7.1	独立同分布的中心极限定理 (林德贝格-勒维)	42
7.7.2	特征函数证明的主线	42
7.8	集中不等式的集中推导	44
7.8.1	Markov 不等式	44
7.8.2	Chebyshev 不等式	45
7.8.3	Chernoff 方法 / 指数矩方法	47
7.8.4	Hoeffding 引理和 Hoeffding 不等式	48
7.8.5	理解集中不等式的“家族树”	53
7.9	Hoeffding 为什么不够, 以及“方差敏感”从何而来	53
7.9.1	Bernstein 不等式的标准设定	53
7.9.2	Bernstein 不等式的 MGF 推导	54
7.9.3	Bernstein 的经验均值形式	57
7.10	Sub-Gaussian 与 Sub-Exponential 的统一语言	57
7.10.1	Sub-Gaussian 的定义	57
7.10.2	Sub-Exponential 的定义	59
8	数理统计基本概念	61
8.1	视角转换	61
8.2	总体、样本、样本值、统计量	61
8.2.1	随机样本与样本值	61
8.2.2	统计量与抽样分布	62
8.3	Beta、Gamma、Dirichlet: 统一分布家族	62
8.3.1	Beta 分布: 随机概率	62
8.3.2	Gamma 分布: 正数上的时间 / 速率模型	63
8.3.3	Dirichlet 分布: 随机概率向量	63
8.3.4	三个分布为什么属于同一条线	64
8.4	χ^2 、 t 、 F : 来自正态分布的三个构件	64
8.4.1	卡方分布	65
8.4.2	Student- t 分布	65
8.4.3	F 分布	66
8.5	正态总体抽样定理	66
8.5.1	关键推导: 平方和的正交分解	67
8.5.2	为什么样本方差除以 $n - 1$	67
8.6	充分统计量与指数族	67
8.6.1	充分统计量	68
8.6.2	指数族提供统一结构	68

9	参数估计	69
9.1	点估计	69
9.2	矩估计	70
9.2.1	为什么矩估计通常是一致的	70
9.2.2	例: 正态分布的矩估计	71
9.3	MLE (最大似然估计)	72
9.3.1	Bernoulli 参数的 MLE	73
9.3.2	正态分布参数的 MLE	73
9.4	估计量评价	74
9.4.1	无偏性	74
9.4.2	有效性与 MSE	74
9.4.3	一致性	75
9.5	Score、Fisher 信息与 Cramér–Rao 下界	75
9.5.1	Score 与 Fisher 信息	75
9.5.2	Cramér–Rao 下界的关键推导	76
9.5.3	例: Bernoulli 参数	76
9.6	MLE 为什么近似正态	77
9.7	区间估计	77
9.7.1	置信区间	77
9.7.2	枢轴量法	78
9.7.3	四套核心置信区间	78
9.8	假设检验: 用反证思路衡量数据与模型的冲突	79
9.8.1	四个基本量	79
9.8.2	例: 正态总体均值的双侧 t 检验	79
9.9	贝叶斯更新与共轭先验	80
9.9.1	Beta–Bernoulli 的完整更新	80
9.9.2	最小共轭关系表	80
9.10	非正态总体的三条推断路线	81
	附录	82
A	鞅与自适应集中	82
A.1	为什么独立样本框架还不够	82
A.2	信息流、适应过程与鞅	82
A.2.1	Filtration: 逐步增长的信息	82
A.2.2	Martingale、submartingale 与 supermartingale	83
A.2.3	两个基本例子	83
A.3	Martingale difference: 在线学习中的噪声语言	84
A.4	停止时刻与可选停止	84
A.4.1	Stopping time	84
A.4.2	Optional stopping theorem	85
A.5	指数 supermartingale: 统一证明模板	85

A.6	Azuma–Hoeffding 不等式	86
A.6.1	证明主线	87
A.7	Freedman 不等式: 方差敏感的鞅界	87
A.7.1	证明主线	88
A.8	固定时刻、固定窗口与 anytime 保证	89
A.8.1	直接 Union Bound	89
A.8.2	Ville 不等式	89
A.8.3	Confidence sequence	89
A.9	自归一化集中与椭圆置信集	90
A.9.1	为什么叫自归一化	90
A.9.2	证明主线	91
A.9.3	线性回归与 Linear Bandit	91
A.10	集中工具如何选择	92
B	Markov 链与依赖序列	93
B.1	为什么需要 Markov 链	93
B.2	Markov 性与转移矩阵	93
B.2.1	路径概率	94
B.3	分布演化与多步转移	94
B.4	状态之间的连通结构	95
B.4.1	可达与互通	95
B.4.2	Irreducible: 不可约	95
B.4.3	Period: 周期	95
B.5	平稳分布	96
B.5.1	二状态例子	96
B.6	Detailed balance 与可逆性	97
B.7	长期收敛与 mixing time	97
B.7.1	Total variation distance	98
B.7.2	Mixing time	98
B.8	两个分析 mixing 的工具	98
B.8.1	Coupling	98
B.8.2	Spectral gap	99
B.9	Markov 链遍历定理	99
B.10	依赖如何降低有效样本量	100
B.10.1	Markov 链集中界的量级图景	100
B.11	与 MCMC 和强化学习的连接	101
B.11.1	MCMC	101
B.11.2	强化学习	101
B.12	Markov 链分析清单	101

前言

本套笔记是笔者在学习概率论与数理统计是梳理的学习笔记，旨在整理出可以长期复习使用的概统工具箱。

笔记首先梳理概率论中从随机事件、随机变量到大样本规律的主线，再进入数理统计中从样本反推未知总体的主线。同时为了进一步提高工具实用性，附录添加了鞅和马尔可夫链的相关章节。

笔记较为粗略，后续会持续校对、补充与完善，也希望能给读者带来一些帮助。

概统课程知识脉络

知识树

概率论与数理统计

概率论

I. 概率：如何描述不确定性

Ch1 随机事件与概率

样本空间 $\rightarrow$ 事件 $\rightarrow \sigma$ -代数 $\rightarrow$ 概率公理

Ch2 条件概率与独立性

条件概率 $\rightarrow$ 乘法公式 $\rightarrow$ 全概率 $\rightarrow$ Bayes $\rightarrow$ 独立性

II. 随机变量：如何把随机现象数值化

Ch3 离散型随机变量

PMF $\rightarrow E/\text{Var} \rightarrow$ Bernoulli / Binomial / Poisson / Geometric

Ch4 连续型随机变量

CDF $\rightarrow$ PDF $\rightarrow E/\text{Var} \rightarrow$ Uniform / Exponential / Normal $\rightarrow$ 随机变量函数

Ch5 多维随机向量

Joint $\rightarrow$ Marginal $\rightarrow$ Conditional $\rightarrow$ Independence $\rightarrow$ 变量变换

Ch6 多维随机向量的数学特征

Covariance $\rightarrow$ Correlation $\rightarrow$ Conditional Expectation $\rightarrow$ Multivariate Gaussian

III. 概率的“大样本规律”

Ch7 集中不等式与集中定理

Markov / Chebyshev $\rightarrow$ Chernoff / 有界变量指数界 $\rightarrow$ 大数定律 $\rightarrow$ 中心极限定理

数理统计：从样本反推未知总体

Ch8 数理统计基本概念

Population / Sample / Statistic

$\downarrow$

Beta / Gamma / Dirichlet

$\downarrow$

χ^2 / t / F

$\downarrow$

Normal Sampling Theorems

Ch9 参数估计

Point Estimation

- Method of Moments
- Maximum Likelihood

$\downarrow$

Estimator Evaluation

- Unbiasedness
- Efficiency
- Consistency

↓

Interval Estimation

1 随机事件与概率

1.1 核心对象

概率空间的核心对象为

$$(\Omega, \Sigma, P).$$

- Ω : 样本空间;
- Σ : 允许讨论概率的事件集合;
- P : 给事件赋以概率的函数。

1.2 σ -代数

规定在一个随机试验中, 哪些“事件”是我们允许讨论概率的。

σ -代数满足三个条件:

1. 全集 $\Omega \in \mathcal{F}$;
2. 补集封闭: 若 $A \in \mathcal{F}$, 则 $A^c \in \mathcal{F}$;
3. 可数并封闭: 若 $A_1, A_2, \dots \in \mathcal{F}$, 则 $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$ 。

$\mathcal{F}$ 也常写作 Σ 。

1.3 概率公理及其推出的性质

概率公理: 设概率空间 $(\Omega, \mathcal{F}, P)$, 概率 P 满足:

1. 非负性:

$$P(A) \geq 0, \quad \forall A \in \mathcal{F}.$$

2. 规范化:

$$P(\Omega) = 1.$$

3. 可列可加性: 若 $A_1, A_2, \dots$ 两两不交, 那么

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

推出性质:

1. $P(\emptyset) = 0$;
2. $P(A^c) = 1 - P(A)$;
3. $A \subseteq B \Rightarrow P(A) \leq P(B)$;
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$;
5. Union Bound:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i).$$

章节思路

概率空间 $(\Omega, \mathcal{F}, P)$: 从样本空间 Ω 讲到事件与 σ -代数 $\mathcal{F}$, 再讲到概率测度 P 。

顺带介绍了古典概率、组合计数与几何概率。

2 条件概率与独立性

2.1 条件概率

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

本质上是“知道 B 已发生后，把样本空间 Ω 限制到 B ，重新归一化概率”。

2.2 乘法公式

$$P(A \cap B) = P(A | B)P(B), \quad P(B) > 0.$$

2.3 全概率公式

若 $A_1, \dots, A_n$ 构成样本空间的一个划分，则

$$P(B) = \sum_{i=1}^n P(A_i)P(B | A_i).$$

2.4 Bayes 公式

设 $A_1, \dots, A_n$ 构成样本空间的一个划分，则

$$P(A_i | B) = \frac{P(A_i)P(B | A_i)}{\sum_{j=1}^n P(A_j)P(B | A_j)}.$$

区分三个词：

- $P(A_i)$: Prior, 先验;
- $P(B | A_i)$: Likelihood, 似然;
- $P(A_i | B)$: Posterior, 后验。

2.5 独立性

$$A \perp B \iff P(A \cap B) = P(A)P(B).$$

区分：两两独立不等于相互独立。

章节思路

条件概率 $\rightarrow$ 乘法公式 $\rightarrow$ 全概率公式 $\rightarrow$ Bayes 公式 $\rightarrow$ 独立性

3 离散型随机变量

3.1 PMF 概率质量函数

$$p_X(x) = P(X = x).$$

满足

$$p_X(x) \geq 0, \quad \sum_x p_X(x) = 1.$$

3.2 数学期望

$$E[X] = \sum_x x p_X(x).$$

更重要:

$$E[g(X)] = \sum_x g(x) p_X(x).$$

3.3 方差

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2.$$

3.4 常见的离散分布及其性质

3.4.1 Bernoulli 分布

$$X \sim \text{Ber}(p),$$

则

$$P(X = 1) = p, \quad P(X = 0) = 1 - p.$$

性质:

$$E[X] = p, \quad \text{Var}(X) = p(1 - p).$$

$$X = I_A \Rightarrow E[X] = P(A).$$

3.4.2 二项分布

$$X \sim B(n, p),$$

则

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, \dots, n.$$

性质:

$$E[X] = np, \quad \text{Var}(X) = np(1 - p).$$

3.4.3 Poisson 分布

$$X \sim P(\lambda),$$

则

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

性质:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

Poisson 极限定理: 若 $n \rightarrow \infty$, $p \rightarrow 0$, $np = \lambda$, 则

$$B(n, p_n) \Rightarrow P(\lambda).$$

直觉上, 即 “大量机会 + 每次事件概率小 + 总平均次数保持有限”

$\Rightarrow$ Poisson.

3.4.4 几何分布

$$X \sim G(p),$$

则

$$P(X = k) = p(1 - p)^{k-1}, \quad k = 1, 2, \dots$$

性质:

$$E[X] = \frac{1}{p}, \quad \text{Var}(X) = \frac{1 - p}{p^2}.$$

无记忆性:

$$P(X > m + n \mid X > m) = P(X > n).$$

章节思路

PMF $\rightarrow E/\text{Var} \rightarrow$ 典型的离散分布

4 连续型随机变量

4.1 CDF 累积分布函数

对所有随机变量统一定义：

$$F_X(x) = P(X \leq x).$$

4.2 PDF 概率密度函数

对于连续随机变量，

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

若可微，并且

$$P(a < X \leq b) = \int_a^b f_X(x) dx,$$

称 $f_X(x)$ 为 PDF。

4.3 连续型期望

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

尾概率公式：若 $X \geq 0$ ，则

$$E[X] = \int_0^{\infty} P(X > t) dt.$$

方差 $\text{Var}(X)$ 依旧等于

$$E[(X - E[X])^2].$$

4.4 典型的连续分布

4.4.1 均匀分布

$$X \sim U(a, b).$$

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{otherwise.} \end{cases}$$

$$F(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b. \end{cases}$$

$$E[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

4.4.2 指数分布

$$X \sim e(\lambda).$$

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

$$F(x) = 1 - e^{-\lambda x}.$$

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}.$$

具有无记忆性:

$$P(X > x) = e^{-\lambda x},$$

$$P(X > s + t \mid X > t) = P(X > s).$$

Geometric $\longleftrightarrow$ 离散等待时间

Exponential $\longleftrightarrow$ 连续等待时间

4.4.3 正态分布

$$X \sim N(\mu, \sigma^2).$$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2.$$

标准化:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

$\Phi(x)$ 为标准正态分布函数,

$$P(a \leq X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$

4.5 随机变量函数

设

$$Y = g(X).$$

求 Y 的 CDF 和 PDF, 一般思路都是化归到 X 上去求。

若 g 单调, $x = h(y) = g^{-1}(y)$, 则

$$f_Y(y) = f_X(h(y))|h'(y)|.$$

章节思路

CDF $\rightarrow$ PDF $\rightarrow$ 典型连续分布 $\rightarrow$ 随机变量函数

5 多维随机向量

5.1 Joint: 联合分布

连续型联合密度 $f_{X,Y}(x,y)$ 满足

$$f_{X,Y}(x,y) \geq 0,$$

$$\iint f_{X,Y}(x,y) dx dy = 1.$$

5.2 Marginal: 边缘化

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx.$$

直觉：把不关心的变量积分 / 求和掉。

5.3 Conditional: 条件分布

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

5.4 Independence: 独立性

$$X \perp Y \iff f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

5.5 和的分布与卷积

独立随机变量求和 $\Rightarrow$ 相应概率密度做卷积。

若 X, Y 独立, $Z = X + Y$, 则

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx.$$

5.6 多维变量变换

设

$$Y = g(X), \quad X \in \mathbb{R}^d.$$

若 g 可微、可逆且 Jacobian 行列式不为 0, 如同存在 $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) |\det J_{g^{-1}}(y)|.$$

6 多维随机向量的数学特征

6.1 Covariance: 协方差

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y].$$

推出

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

$$X \perp Y \quad \Rightarrow \quad \text{Cov}(X, Y) = 0.$$

6.1.1 协方差矩阵

对随机向量

$$X = (X_1, \dots, X_d)^T, \quad \mu = E[X],$$

定义协方差矩阵

$$\Sigma = \text{Cov}(X) = E[(X - \mu)(X - \mu)^T].$$

其中第 (i, j) 个元素为

$$\Sigma_{ij} = \text{Cov}(X_i, X_j).$$

Σ 一定是对称半正定矩阵。对任意 $a \in \mathbb{R}^d$,

$$a^T \Sigma a = \text{Var}(a^T X) \geq 0.$$

这条等式给出协方差矩阵最重要的解释：它同时记录了随机向量沿所有方向 a 的波动大小。

若 $Y = AX + b$, 则

$$E[Y] = A\mu + b, \quad \text{Cov}(Y) = A\Sigma A^T.$$

⚠ 不相关不等于独立

$\text{Cov}(X, Y) = 0$ 一般只能说明没有线性相关性，不能推出独立。联合正态变量是重要例外：若 (X, Y) 联合正态且协方差为 0，则 X 与 Y 独立。

6.2 Correlation: 相关系数

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

一种比较有趣的理解概率论内在几何结构的角度是内积。

倘若将中心化后的随机变量看作概率空间中的向量，不难验证协方差运算其实构成一种内积结构，而标准差其实对应了这种内积结构中的“范数”，相关系数则对应了这种概率空间中向量之间夹角的余弦值。

6.3 三个基础不等式

下面三个不等式反复出现在方差分析、条件期望、集中不等式和统计学习中。

6.3.1 Jensen 不等式

若 φ 是凸函数，并且相关期望存在，则

$$\varphi(E[X]) \leq E[\varphi(X)].$$

直觉是：先取平均再代入凸函数，不会大于先经过凸函数再平均。若 φ 可微，凸性给出支撑线不等式

$$\varphi(x) \geq \varphi(m) + \varphi'(m)(x - m).$$

取 $m = E[X]$ 并对两边取期望，线性项消失，就得到 Jensen 不等式。

条件版本同样重要：

$$\varphi(E[X | Y]) \leq E[\varphi(X) | Y].$$

例如取 $\varphi(x) = x^2$ ，得到

$$(E[X | Y])^2 \leq E[X^2 | Y].$$

6.3.2 Cauchy–Schwarz 不等式

若 $E[X^2], E[Y^2] < \infty$, 则

$$|E[XY]| \leq \sqrt{E[X^2]E[Y^2]}.$$

证明只需利用任意 $t \in \mathbb{R}$ 下

$$E[(X - tY)^2] \geq 0.$$

把它看成关于 t 的二次函数, 其判别式不能为正, 便得到上述结论。

Cauchy–Schwarz 直接推出

$$|\rho_{XY}| \leq 1.$$

6.3.3 Hölder 不等式

若 $p, q > 1$ 且

$$\frac{1}{p} + \frac{1}{q} = 1,$$

则

$$E[|XY|] \leq (E[|X|^p])^{1/p} (E[|Y|^q])^{1/q}.$$

它来自 Young 不等式

$$uv \leq \frac{u^p}{p} + \frac{v^q}{q}.$$

把 X, Y 分别除以自己的 L^p, L^q 范数后应用 Young 不等式, 再取期望即可。 $p = q = 2$ 时, Hölder 就退化为 Cauchy–Schwarz。

6.4 Conditional Expectation: 条件期望

一般的随机向量函数的期望:

若离散型随机向量 (X, Y) 的分布列为

$$p_{ij} = P(X = x_i, Y = y_j),$$

则随机向量函数 $g(X, Y)$ 的期望为

$$E[g(X, Y)] = \sum_{i,j} g(x_i, y_j) p_{ij}.$$

若连续型随机向量 (X, Y) 的密度函数为 $f(x, y)$, 则随机向量函数 $g(X, Y)$ 的期望为

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy.$$

类似地有, 对于离散型随机变量 (X, Y) , 有随机变量函数 $g(X)$ 的条件期望

$$E[g(X) | Y = y] = \sum_i g(x_i) P(X = x_i | Y = y).$$

对连续型随机变量 (X, Y) , 有随机变量函数 $g(X)$ 的条件期望是

$$E[g(X) | Y = y] = \int_{-\infty}^{\infty} g(x) f_{X|Y}(x | y) dx.$$

由上述产生三个有用的定理。

6.4.1 条件期望首先是随机变量

$E[X | Y]$ 不是把 Y 固定为某个值后的一个常数, 而是 Y 的函数:

$$E[X | Y] = g(Y).$$

当观察到 $Y = y$ 后, 它才取值为 $g(y) = E[X | Y = y]$ 。更一般地, $E[X | \mathcal{G}]$ 表示只使用信息集合 $\mathcal{G}$ 时对 X 的最佳预测。

常用性质包括:

$$E[aX + bZ \mid Y] = aE[X \mid Y] + bE[Z \mid Y],$$

若 $h(Y)$ 是由 Y 决定的, 则

$$E[h(Y)X \mid Y] = h(Y)E[X \mid Y],$$

以及塔式性质

$$E[E[X \mid Y]] = E[X].$$

若信息逐层增加, 则更一般地有

$$E[E[X \mid Y, Z] \mid Y] = E[X \mid Y].$$

若 $X \perp Y$, 则观察 Y 不会改变对 X 的预测:

$$E[X \mid Y] = E[X].$$

6.4.2 计算期望的另一种方法

$$E[X] = E_Y[E[X \mid Y]].$$

离散型:

$$E[X] = \sum_{y_j} E[X \mid Y = y_j] P(Y = y_j).$$

连续型:

$$E[X] = \int_{-\infty}^{\infty} E[X \mid Y = y] f_Y(y) dy.$$

6.4.3 全期望公式

若 $A_1, A_2, \dots, A_n$ 是样本空间 Ω 的一个分割, 即

$$A_i \cap A_j = \emptyset, \quad \Omega = \bigcup_{i=1}^n A_i,$$

则有

$$E[X] = E[X | A_1]P(A_1) + E[X | A_2]P(A_2) + \dots + E[X | A_n]P(A_n).$$

6.4.4 条件期望：信息子空间上的正交投影

对平方可积随机变量, 可以定义 L^2 内积与范数

$$\langle U, V \rangle = E[UV], \quad \|U\|_2^2 = E[U^2].$$

于是随机变量可以看成 L^2 空间中的向量。所有仅依赖于 X 的平方可积随机变量构成一个子空间

$$\mathcal{H}_X = \{g(X) : E[g(X)^2] < \infty\}.$$

它表示“只使用 X 所包含的信息能够构造出的全部预测量”。

令

$$m(X) = E[Y | X].$$

条件期望的几何意义是：

$$m(X) = \text{Proj}_{\mathcal{H}_X} Y,$$

即 $E[Y | X]$ 是 Y 在信息子空间 $\mathcal{H}_X$ 上的正交投影。对应的残差

$$Y - E[Y | X]$$

与子空间中的任意方向 $h(X)$ 都正交：

$$E[(Y - E[Y | X])h(X)] = 0.$$

事实上，由塔式性质，

$$\begin{aligned} E[(Y - E[Y | X])h(X)] &= E[E[(Y - E[Y | X])h(X) | X]] \\ &= E[h(X)E[Y - E[Y | X] | X]] \\ &= 0. \end{aligned}$$

因此对任意平方可积函数 $g(X)$ ，都有正交分解

$$Y - g(X) = (Y - m(X)) + (m(X) - g(X)).$$

其中第一项与第二项正交，所以由勾股定理，

$$E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2].$$

第二项恒非负，因此

$$E[Y | X] = \arg \min_{g(X)} E[(Y - g(X))^2].$$

这说明条件期望是只利用 X 的全部信息时，对 Y 的最佳均方预测。

⚠ 不是最佳线性预测

这里优化的是所有平方可积函数 $g(X)$ ，而不只是 $aX + b$ 。只有把预测器限制为线性形式时，问题才变成线性回归。例如若

$$Y = X^2 + \varepsilon, \quad E[\varepsilon | X] = 0,$$

则

$$E[Y | X] = X^2,$$

它通常不是 X 的线性函数。

6.4.5 全方差公式：概率空间中的勾股定理

首先定义给定 X 后， Y 的条件方差：

$$\text{Var}(Y | X) = E[(Y - E[Y | X])^2 | X].$$

它本身是 X 的函数，表示已经知道 X 以后， Y 仍然保留多少不确定性。再对 X 取平均，有

$$E[\text{Var}(Y | X)] = E[(Y - E[Y | X])^2].$$

为了解释总体波动，在 $Y - E[Y]$ 中加上并减去 $E[Y | X]$ ：

$$Y - E[Y] = \underbrace{Y - E[Y | X]}_{\text{无法由 } X \text{ 解释的残差}} + \underbrace{E[Y | X] - E[Y]}_{\text{由 } X \text{ 解释的变化}}.$$

第一项与第二项正交。因为 $E[Y | X] - E[Y]$ 是 X 的函数，所以

$$E[(Y - E[Y | X])(E[Y | X] - E[Y])] = 0.$$

因此平方后取期望，交叉项消失：

$$\begin{aligned} \text{Var}(Y) &= E[(Y - E[Y])^2] \\ &= E[(Y - E[Y | X])^2] + E[(E[Y | X] - E[Y])^2] \\ &= E[\text{Var}(Y | X)] + \text{Var}(E[Y | X]). \end{aligned}$$

从几何上看，这是 L^2 空间中的勾股定理：

$$\|Y - E[Y]\|_2^2 = \|Y - E[Y | X]\|_2^2 + \|E[Y | X] - E[Y]\|_2^2.$$

i Noise-Signal 分解

全方差公式把总体波动分成两部分：

- $E[\text{Var}(Y | X)]$ ：知道 X 后仍无法解释的平均残差波动；
- $\text{Var}(E[Y | X])$ ：条件均值随 X 变化而产生的可解释波动。

因此可以记成

$$\text{总波动} = \text{平均组内波动} + \text{组间波动}.$$

若 X 几乎不能解释 Y ，则第二项较小；若 X 含有很强的预测信息，则第二项通常较大。

6.5 多维正态分布

$$X \sim N(\mu, \Sigma).$$

$$f(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right].$$

其中

$$E[X] = \mu, \quad \text{Cov}(X) = \Sigma.$$

6.5.1 Mahalanobis 几何与白化

多元正态密度不是由普通欧氏距离 $\|x - \mu\|_2$ 决定，而是由 Mahalanobis 距离

$$d_\Sigma(x, \mu)^2 = (x - \mu)^T \Sigma^{-1} (x - \mu)$$

决定。它会根据不同方向上的方差，对偏离程度进行不同尺度的衡量。

若 Σ 正定并作特征值分解

$$\Sigma = U \Lambda U^T, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d),$$

其中 u_j 是第 j 个特征向量，则

$$\begin{aligned} (x - \mu)^T \Sigma^{-1} (x - \mu) &= (x - \mu)^T U \Lambda^{-1} U^T (x - \mu) \\ &= \sum_{j=1}^d \frac{(u_j^T (x - \mu))^2}{\lambda_j}. \end{aligned}$$

因此，多元正态的等密度面

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = c$$

是以 μ 为中心的椭球：

- 特征向量 u_j 给出椭球的主轴方向；
- 第 j 个方向的轴长与 $\sqrt{\lambda_j}$ 成正比；
- λ_j 越大，分布在该方向越分散，同样大小的偏离受到的惩罚越小。

定义白化变换

$$Z = \Lambda^{-1/2} U^T (X - \mu),$$

则

$$Z \sim N(0, I),$$

并且

$$d_{\Sigma}(X, \mu)^2 = \|Z\|_2^2.$$

白化的作用是先旋转到协方差矩阵的特征方向，再按照各方向的标准差进行缩放，从而把原来的椭球几何变成标准球面几何。

i 这个几何视角为什么重要

Mahalanobis 距离、PCA、Gaussian anomaly detection 和许多高斯模型都依赖同一个思想：不同方向上的波动尺度不同，不能用未经归一化的欧氏距离衡量异常程度。

仿射变换：

$$AX + b \sim N(A\mu + b, A\Sigma A^T).$$

6.5.2 边缘分布与独立性

把随机向量分块：

$$X = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}.$$

则两个分块的边缘分布仍然是正态分布：

$$X_1 \sim N(\mu_1, \Sigma_{11}), \quad X_2 \sim N(\mu_2, \Sigma_{22}).$$

若 $\Sigma_{12} = 0$ ，则联合正态性进一步保证 $X_1 \perp X_2$ 。

6.5.3 多元正态的条件分布

若 Σ_{22} 可逆, 则

$$X_1 \mid X_2 = x_2 \sim N(\mu_{1|2}, \Sigma_{1|2}),$$

其中

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2),$$

$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

条件均值是在原均值 μ_1 上, 根据 X_2 的观测偏差作线性修正; 条件协方差则从原不确定性中减去由 X_2 所解释的部分。

其中

$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

称为 Σ_{22} 在联合协方差矩阵中的 Schur complement。它描述观察 X_2 后, X_1 仍然保留的不确定性。

值得注意的是, 在联合高斯模型中, 条件均值依赖具体观测值 x_2 , 但条件协方差只由原来的协方差结构决定, 不依赖 x_2 。

6.5.4 线性高斯观测的统一更新

设隐藏变量满足

$$X \sim N(\mu, \Sigma),$$

并通过带高斯噪声的线性模型观察到

$$Y = AX + b + \varepsilon, \quad \varepsilon \sim N(0, R),$$

其中 ε 与 X 独立。

由高斯分布在仿射变换下的封闭性,

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N\left(\begin{pmatrix} \mu \\ A\mu + b \end{pmatrix}, \begin{pmatrix} \Sigma & \Sigma A^T \\ A\Sigma & A\Sigma A^T + R \end{pmatrix}\right).$$

将这个联合分布代入分块高斯条件公式，可得

$$X | Y = y \sim N(\mu_{\text{post}}, \Sigma_{\text{post}}),$$

其中

$$\mu_{\text{post}} = \mu + \Sigma A^T (A \Sigma A^T + R)^{-1} (y - A\mu - b),$$

以及

$$\Sigma_{\text{post}} = \Sigma - \Sigma A^T (A \Sigma A^T + R)^{-1} A \Sigma.$$

条件均值可以理解为

$$\text{原有预测} + \text{修正系数} \times \text{观测残差}.$$

这里的观测残差

$$y - (A\mu + b)$$

表示实际观测与模型原先预测之间的差异；矩阵

$$\Sigma A^T (A \Sigma A^T + R)^{-1}$$

决定应该相信这次观测到什么程度。

! 一个反复出现的高斯更新模板

Bayesian linear regression、Kalman filter、高斯过程回归和线性高斯概率图模型，虽然具体符号不同，本质上都在使用

联合高斯 $\rightarrow$ 条件高斯 $\rightarrow$ 均值修正与协方差收缩.

i 本章抓住什么

本章的主线不是孤立公式，而是：协方差矩阵描述各方向波动，条件期望是平方损失下的投影，多元正态则让这种投影和条件更新得到闭式表达。

7 集中不等式与集中定理

7.1 Markov Inequality

若 $X \geq 0$, 则对任意 $a > 0$,

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

7.2 Chebyshev Inequality

设随机变量 X 有有限均值

$$\mu = E[X]$$

和有限方差

$$\sigma^2 = \text{Var}(X),$$

则对于任意 $\varepsilon > 0$,

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

7.3 Chernoff 方法

$$P(X \geq a) \leq \inf_{t>0} e^{-ta} M_X(t),$$

其中

$$M_X(t) = E[e^{tX}].$$

7.4 Hoeffding 型有界变量界

若 $X_i \in [a, b]$ 且独立, 则样本均值满足

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2 \exp\left(-\frac{2n\varepsilon^2}{(b-a)^2}\right).$$

7.5 随机变量序列的收敛方式

研究大数定律、中心极限定理和估计量的渐近性质之前, 必须先说明“收敛”究竟指什么。

7.5.1 四种常用收敛

设随机变量序列为 X_n , 极限为 X 。

几乎必然收敛:

$$X_n \xrightarrow{\text{a.s.}} X \iff P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1.$$

依概率收敛:

$$X_n \xrightarrow{P} X \iff \forall \varepsilon > 0, \quad P(|X_n - X| > \varepsilon) \rightarrow 0.$$

L^p 收敛:

$$X_n \xrightarrow{L^p} X \iff E[|X_n - X|^p] \rightarrow 0.$$

依分布收敛:

$$X_n \xrightarrow{d} X \iff F_{X_n}(x) \rightarrow F_X(x)$$

对 F_X 的每个连续点 x 成立。

7.5.2 强弱关系

常用的推出关系是

$$X_n \xrightarrow{\text{a.s.}} X \implies X_n \xrightarrow{P} X \implies X_n \xrightarrow{d} X,$$

以及

$$X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{P} X.$$

反方向一般不成立。一个重要例外是：若极限是常数 c ，则

$$X_n \xrightarrow{d} c \implies X_n \xrightarrow{P} c.$$

直觉上，依分布收敛只关心分布形状，最弱；依概率收敛要求单次偏差超过 ε 的概率消失；几乎必然收敛则要求几乎每条样本路径最终都收敛。

7.5.3 连续映射、Slutsky 与 Delta method

若 $X_n \xrightarrow{P} X$ ，且 g 连续，则

$$g(X_n) \xrightarrow{P} g(X).$$

依分布版本同样成立。Slutsky 定理说明：若

$$X_n \xrightarrow{d} X, \quad Y_n \xrightarrow{P} c,$$

则

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX,$$

并在 $c \neq 0$ 时有

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}.$$

它解释了为什么统计推断中可以把未知但一致估计的量代入渐近分布。

若进一步有

$$\sqrt{n}(X_n - \theta) \xrightarrow{d} N(0, \sigma^2),$$

且 g 在 θ 处可微, 则一阶 Taylor 展开给出 Delta method:

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2).$$

i 工具定位

大数定律通常给出依概率或几乎必然收敛, 回答“是否靠近真值”; 中心极限定理给出依分布收敛, 回答“以什么尺度、什么形状波动”。

7.6 大数定律 (LLN)

令

$$S_n = \sum_{i=1}^n X_i.$$

大数定律研究的是: 大量随机变量取平均后, 随机波动是否会被逐渐抵消。若

$$\frac{S_n - E[S_n]}{n} \xrightarrow{P} 0,$$

即

$$\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E[X_i] \xrightarrow{P} 0,$$

就称随机变量序列服从弱大数定律。

7.6.1 四个经典版本

1. Markov 大数定律：一个通用方差判据

若

$$\frac{\text{Var}(S_n)}{n^2} \rightarrow 0,$$

则

$$\frac{S_n - E[S_n]}{n} \xrightarrow{P} 0.$$

它不直接要求独立同分布，核心只在于累计方差相对于 n^2 可以忽略。由 Chebyshev 不等式，

$$P\left(\left|\frac{S_n - E[S_n]}{n}\right| \geq \varepsilon\right) \leq \frac{\text{Var}(S_n)}{n^2 \varepsilon^2} \rightarrow 0.$$

因此，面对非同分布或具有一定相关性的变量时，可以优先检查这个方差条件。

2. Chebyshev 大数定律：最常用的有限方差版本

若 $X_1, X_2, \dots$ 两两不相关，并且方差一致有界：

$$\text{Var}(X_i) \leq C < \infty,$$

则

$$\frac{1}{n} \sum_{i=1}^n (X_i - E[X_i]) \xrightarrow{P} 0.$$

因为两两不相关，所以

$$\text{Var}(S_n) = \sum_{i=1}^n \text{Var}(X_i) \leq nC,$$

进而

$$\frac{\text{Var}(S_n)}{n^2} \leq \frac{C}{n} \rightarrow 0.$$

因此 Chebyshev 大数定律可以看作 Markov 方差判据的直接推论。独立性能推出不相关，所以独立变量也包含在这一情形中。

3. Khinchin 大数定律：有限均值已经足够

若 $X_1, X_2, \dots$ 独立同分布，并且

$$E[|X_1|] < \infty, \quad E[X_1] = \mu,$$

则

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu.$$

它的重要之处在于不要求

$$\text{Var}(X_1) < \infty.$$

因此，有限方差下的 Chebyshev 证明虽然最直观，但并不是 iid 弱大数律所能达到的最弱条件。Khinchin 定理的完整证明通常需要截断或特征函数工具，本笔记只保留结论。

4. Bernoulli 大数定律：频率趋近概率

设 $I_1, \dots, I_n$ 是独立的 Bernoulli 随机变量：

$$I_i \sim \text{Bernoulli}(p).$$

令

$$N_n = \sum_{i=1}^n I_i$$

表示前 n 次试验中事件发生的次数，则

$$\frac{N_n}{n} \xrightarrow{P} p.$$

它说明当重复试验次数足够多时，事件发生的频率趋近其概率，是大数定律最直观的特殊情形。

i 四个版本的关系与掌握重点

可以把它们理解为：

- Markov: 检查累计方差是否为 $o(n^2)$;
- Chebyshev: 用不相关和方差有界保证 Markov 条件;
- Khinchin: iid 情形下只要求有限一阶矩;
- Bernoulli: 把大数定律用于 0-1 指示变量。

实用上应当会证明有限方差下的 Chebyshev 版本, 记住 Khinchin 的条件改进, 并能够把 Markov 判据用于更一般的序列。Bernoulli 版本理解其频率解释即可。

⚠ 弱大数律与强大数律

上述四个版本讨论的都是依概率收敛。强大数律把结论加强为

$$\bar{X}_n \xrightarrow{\text{a.s.}} \mu,$$

即除去一个概率为零的异常集合后, 几乎每条无限样本路径上的平均值都收敛到 μ 。现阶段应掌握两种收敛的区别, 强大数律的完整证明可以暂缓。

7.6.2 有限方差下弱大数律的关键推导

设 $X_1, \dots, X_n$ 独立同分布, 且

$$E[X_i] = \mu, \quad \text{Var}(X_i) = \sigma^2 < \infty.$$

对样本均值

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

有

$$E[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

由 Chebyshev 不等式, 对任意 $\varepsilon > 0$,

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

因此

$$\bar{X}_n \xrightarrow{P} \mu.$$

这就是有限方差条件下弱大数律最直接的证明：独立平均使方差按 $1/n$ 缩小，再由 Chebyshev 把方差控制转成概率收敛。

7.7 中心极限定理 (CLT)

7.7.1 独立同分布的中心极限定理 (林德贝格-勒维)

若独立同分布的随机变量 $X_1, X_2, \dots, X_n, \dots$ 的期望为

$$E[X_i] = \mu$$

和方差为

$$\text{Var}(X_i) = \sigma^2,$$

则有

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1).$$

等价于

$$\lim_{n \rightarrow \infty} P(Y_n \leq y) = \Phi(y).$$

7.7.2 特征函数证明的主线

下面展示了 CLT 证明的骨架，略去了一些技术细节。

先标准化

$$Z_i = \frac{X_i - \mu}{\sigma},$$

则

$$E[Z_i] = 0, \quad \text{Var}(Z_i) = 1, \quad Y_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i.$$

定义特征函数

$$\varphi_Z(t) = E[e^{itZ}].$$

由 $E[Z] = 0$ 、 $E[Z^2] = 1$ ，在 $t = 0$ 附近有二阶展开

$$\varphi_Z(t) = 1 - \frac{t^2}{2} + o(t^2).$$

利用独立性，和的特征函数等于各特征函数之积：

$$\begin{aligned} \varphi_{Y_n}(t) &= E \left[\exp \left(\frac{it}{\sqrt{n}} \sum_{i=1}^n Z_i \right) \right] \\ &= \left[\varphi_Z \left(\frac{t}{\sqrt{n}} \right) \right]^n. \end{aligned}$$

代入局部展开，

$$\varphi_{Y_n}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow e^{-t^2/2}.$$

$e^{-t^2/2}$ 正是 $N(0, 1)$ 的特征函数。由特征函数连续性定理，

$$Y_n \xrightarrow{d} N(0, 1).$$

这条证明揭示了 CLT 的核心机制：中心化消去一阶项，方差保留二阶项，独立求和把高阶细节在 $\sqrt{n}$ 的尺度下逐渐冲淡。

当 n 足够大时，近似有

$$Y_n \sim N(0, 1),$$

即有

$$\frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

大数定律给出了随机变量

$$\frac{1}{n} \sum_{i=1}^n X_i$$

的趋势，而中心极限定理给出了

$$\frac{1}{n} \sum_{i=1}^n X_i$$

的近似分布。

推论：棣莫弗—拉普拉斯中心极限定理。设随机变量 $X_n \sim B(n, p)$ ，则

$$Y_n = \frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1).$$

又对独立不同分布的随机变量序列，有李雅普诺夫中心极限定理。（了解）

7.8 集中不等式的集中推导

从 Markov、Chebyshev 到 Chernoff–MGF，再完整推出 Hoeffding。

7.8.1 Markov 不等式

设 Y 是一个非负随机变量， $Y \geq 0$ ，则对任意 $a > 0$ ，都有

$$P(Y \geq a) \leq \frac{E[Y]}{a}.$$

证明：利用函数不等式

$$Y \geq aI_{\{Y \geq a\}},$$

其中

$$I_{\{Y \geq a\}} = \begin{cases} 1, & Y \geq a, \\ 0, & Y < a. \end{cases}$$

当 $Y \geq a$ 时, 右边等于 a , $Y \geq a$ 成立; 当 $Y < a$ 时, 右边等于 0, 由 Y 非负, $Y \geq 0$ 成立。
对

$$Y \geq aI_{\{Y \geq a\}}$$

两边取期望, 有

$$E[Y] \geq aP(Y \geq a).$$

两边除以 $a > 0$, 即得

$$P(Y \geq a) \leq \frac{E[Y]}{a}. \quad \square$$

评价

只利用 $Y \geq 0$ 和 $E[Y]$ 的信息, 给出 $P(Y \geq a) \leq 1/a$ 这种随阈值 a 衰减的、速度为多项式级别的界。

这里的 $1/a$ 是归一化情形 $E[Y] = 1$; 一般形式仍是 $E[Y]/a$ 。

7.8.2 Chebyshev 不等式

设随机变量 X 有有限均值

$$\mu = E[X]$$

和有限方差

$$\sigma^2 = \text{Var}(X),$$

则对于任意 $\varepsilon > 0$,

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

证明: 考虑随机变量

$$Y = (X - \mu)^2,$$

正数 a 取 ε^2 , 使用 Markov 不等式即得。□

通过 Chebyshev 不等式, 我们同时控制经验均值。设 $X_1, X_2, \dots, X_n$ 独立同分布, 并且

$$E[X_i] = \mu, \quad \text{Var}(X_i) = \sigma^2.$$

经验均值为

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

则

$$\text{Var}(\hat{\mu}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

于是 Chebyshev 给出

$$P(|\hat{\mu}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}.$$

进一步可以反解出置信半径。令

$$\frac{\sigma^2}{n\varepsilon^2} \leq \delta,$$

则

$$\varepsilon^2 \geq \frac{\sigma^2}{n\delta}, \quad \varepsilon = \frac{\sigma}{\sqrt{n\delta}}.$$

即得

$$P\left(|\hat{\mu}_n - \mu| \leq \frac{\sigma}{\sqrt{n\delta}}\right) \geq 1 - \delta.$$

Chebyshev 的置信半径为

$$r(n, \delta) = \frac{\sigma}{\sqrt{n\delta}}.$$

评价

进一步利用上了方差, 但依旧只是 Markov 的非负随机变量框架内的一小步。

7.8.3 Chernoff 方法 / 指数矩方法

利用

$$X \geq t \iff e^{\lambda X} \geq e^{\lambda t}, \quad \forall \lambda > 0.$$

转向对 $e^{\lambda X} \geq 0$ 使用 Markov 不等式:

$$P(X \geq t) = P(e^{\lambda X} \geq e^{\lambda t}) \leq \frac{E[e^{\lambda X}]}{e^{\lambda t}}.$$

即

$$P(X \geq t) \leq e^{-\lambda t} E[e^{\lambda X}], \quad \forall \lambda > 0.$$

故

$$P(X \geq t) \leq \inf_{\lambda > 0} \{e^{-\lambda t} E[e^{\lambda X}]\}.$$

MGF: 矩母函数。定义随机变量 X 的矩母函数为

$$M_X(\lambda) = E[e^{\lambda X}].$$

对数矩母函数为

$$\psi_X(\lambda) = \log E[e^{\lambda X}].$$

因此 Chernoff bound 可以写成

$$P(X \geq t) \leq \inf_{\lambda > 0} \exp(-\lambda t + \psi_X(\lambda)).$$

对变量中心化

$$Z = X - E[X],$$

则

$$P(Z \geq t) \leq \inf_{\lambda > 0} \exp(-\lambda t + \psi_Z(\lambda)).$$

对于相互独立的 $Z_1, Z_2, \dots, Z_n$, 考虑它们的和

$$S_n = \sum_{i=1}^n Z_i.$$

则

$$E[e^{\lambda S_n}] = E[e^{\lambda \sum_{i=1}^n Z_i}] = E\left[\prod_{i=1}^n e^{\lambda Z_i}\right] = \prod_{i=1}^n E[e^{\lambda Z_i}].$$

因此

$$\log E[e^{\lambda \sum_{i=1}^n Z_i}] = \sum_{i=1}^n \log E[e^{\lambda Z_i}].$$

综上, 可得到集中不等式的母公式。对于独立中心化随机变量 $Z_1, \dots, Z_n$,

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq e^{-\lambda t} \prod_{i=1}^n E[e^{\lambda Z_i}], \quad \lambda > 0.$$

写成对数矩母函数:

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq \inf_{\lambda > 0} \exp\left(-\lambda t + \sum_{i=1}^n \psi_i(\lambda)\right).$$

几乎所有经典集中不等式都从这里出发, 因为分析核心可以化为控制 $\psi_i(\lambda)$ 。

7.8.4 Hoeffding 引理和 Hoeffding 不等式

7.8.4.1 Hoeffding 引理

设随机变量 X 满足

$$a \leq X \leq b,$$

并且

$$\mu = E[X],$$

则对于任意 $\lambda \in \mathbb{R}$, 有

$$E[e^{\lambda(X-\mu)}] \leq \exp\left(\frac{\lambda^2(b-a)^2}{8}\right).$$

证明原理可以暂且后置, 先承认这个引理即可。这个引理本质上揭示了有界随机变量中心化后是 Sub-Gaussian, 用于给独立有界变量之和提供高斯型尾界。

作为 P0 扩写, 下面补上常数 $1/8$ 的关键来源。

由于指数函数是凸函数, 对任意 $x \in [a, b]$,

$$e^{\lambda x} \leq \frac{b-x}{b-a} e^{\lambda a} + \frac{x-a}{b-a} e^{\lambda b}.$$

令

$$p = \frac{\mu - a}{b - a}, \quad h = \lambda(b - a).$$

对上式取期望并中心化, 得到

$$E[e^{\lambda(X-\mu)}] \leq (1-p)e^{-ph} + pe^{(1-p)h}.$$

记右侧对数为

$$g(h) = \log((1-p)e^{-ph} + pe^{(1-p)h}).$$

可以验证

$$g(0) = g'(0) = 0.$$

$g''(h)$ 等于某个参数经过指数倾斜后的 Bernoulli 变量方差, 因此

$$g''(h) \leq \frac{1}{4}.$$

对这个二阶导数界积分两次, 便有

$$g(h) \leq \frac{h^2}{8}.$$

于是

$$E[e^{\lambda(X-\mu)}] \leq e^{h^2/8} = \exp\left(\frac{\lambda^2(b-a)^2}{8}\right).$$

Hoeffding 引理得证。证明只使用了有界性，因此它不依赖 X 的具体分布。

7.8.4.2 Hoeffding 不等式：右尾单侧形式

设 $X_1, \dots, X_n$ 相互独立，并且

$$a_i \leq X_i \leq b_i.$$

记

$$Z_i = X_i - E[X_i],$$

则有

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right), \quad t > 0.$$

证明：由 Chernoff 方法知

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq e^{-\lambda t} \prod_{i=1}^n E[e^{\lambda Z_i}], \quad \lambda > 0.$$

对每个 Z_i 使用 Hoeffding 引理：

$$E[e^{\lambda Z_i}] \leq \exp\left(\frac{\lambda^2(b_i - a_i)^2}{8}\right).$$

因此

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq \exp\left[-\lambda t + \frac{\lambda^2}{8} \sum_{i=1}^n (b_i - a_i)^2\right].$$

右侧指数里是开口朝上的二次函数。令导数为 0，取

$$\lambda^* = \frac{4t}{\sum_{i=1}^n (b_i - a_i)^2},$$

代入右边取到下界

$$-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}.$$

因此

$$P\left(\sum_{i=1}^n Z_i \geq t\right) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right).$$

7.8.4.3 经验均值版本

假设

$$X_i \in [0, 1], \quad E[X_i] = \mu,$$

那么 $b_i - a_i = 1$, 且

$$\sum_{i=1}^n (b_i - a_i)^2 = n.$$

由于

$$\hat{\mu}_n - \mu = \frac{1}{n} \sum_{i=1}^n (X_i - \mu),$$

故

$$\hat{\mu}_n - \mu \geq \varepsilon \iff \sum_{i=1}^n (X_i - \mu) \geq n\varepsilon.$$

在 Hoeffding 不等式中令 $t = n\varepsilon$, 得

$$P(\hat{\mu}_n - \mu \geq \varepsilon) \leq \exp(-2n\varepsilon^2).$$

同样, 对 $-X_i$ 使用 Hoeffding, 有

$$P(\mu - \hat{\mu}_n \geq \varepsilon) \leq e^{-2n\varepsilon^2}.$$

事实上, Hoeffding 不等式下经验均值估计有

$$P(|\hat{\mu}_n - \mu| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

把尾界反解成置信区间。令

$$2e^{-2n\varepsilon^2} \leq \delta,$$

可得

$$\varepsilon^2 \geq \frac{\log(2/\delta)}{2n}.$$

取

$$\varepsilon = \sqrt{\frac{\log(2/\delta)}{2n}},$$

即得

$$P\left(|\hat{\mu}_n - \mu| \leq \sqrt{\frac{\log(2/\delta)}{2n}}\right) \geq 1 - \delta.$$

评价

以上给出了指数型的集中不等式, 但 Hoeffding 不等式采用的 MGF 控制只使用了一个信息: $X_i \in [a_i, b_i]$ 。

7.8.5 理解集中不等式的“家族树”

Markov: 只使用 $E[Y]$ 。

↓

Chebyshev: 对 $Y = (X - E[X])^2$ 使用 Markov, 只使用方差。

↓

Chernoff 方法: 对 $Y = e^{\lambda(X - E[X])}$ 使用 Markov。

↓

Hoeffding: 当 X 有界时, 用区间长度控制 MGF,

$$\log E[e^{\lambda(X - E[X])}] \leq \frac{\lambda^2(b - a)^2}{8}.$$

另一条路径是:

Bernstein: 除了有界, 还利用方差, 得到更精细的 MGF 界。

↓

Sub-Gaussian: 直接假设 / 控制

$$\log E[e^{\lambda(X - E[X])}] \leq \frac{\sigma^2 \lambda^2}{2}.$$

↓

Sub-Exponential: 只在某个有限范围内得到二次型 MGF 控制。

7.9 Hoeffding 为什么不够, 以及“方差敏感”从何而来

7.9.1 Bernstein 不等式的标准设定

设 $X_1, \dots, X_n$ 相互独立, 并且已经中心化:

$$E[X_i] = 0.$$

同时假设它们有界:

$$|X_i| \leq b.$$

记总方差

$$V = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n E[X_i^2],$$

以及

$$S_n = \sum_{i=1}^n X_i.$$

则 Bernstein 不等式的一侧形式是

$$P(S_n \geq t) \leq \exp\left(-\frac{t^2}{2(V + bt/3)}\right), \quad t > 0.$$

双侧形式是

$$P(|S_n| \geq t) \leq 2 \exp\left(-\frac{t^2}{2(V + bt/3)}\right), \quad t > 0.$$

7.9.2 Bernstein 不等式的 MGF 推导

由 Chernoff 方法,

$$E[e^{\lambda S_n}] = \prod_{i=1}^n E[e^{\lambda X_i}].$$

为估计上界, 分析如下。

1. 展开指数函数。由于中心化, $E[X] = 0$,

$$E[e^{\lambda X}] = 1 + \sum_{k \geq 2} \frac{\lambda^k E[X^k]}{k!}.$$

2. 用有界性把所有高阶矩压到二阶矩上。对于 $k \geq 2$,

$$|X|^k = |X|^{k-2} X^2.$$

由于 $|X| \leq b$, 所以

$$|X|^{k-2} \leq b^{k-2}.$$

因此逐点有

$$|X|^k \leq b^{k-2} X^2.$$

取期望,

$$E[|X|^k] \leq b^{k-2} E[X^2] = b^{k-2} \sigma^2.$$

进一步

$$E[X^k] \leq |E[X^k]| \leq E[|X|^k] \leq b^{k-2} \sigma^2.$$

从而

$$E[e^{\lambda X}] \leq 1 + \lambda^2 \sigma^2 \sum_{k \geq 2} \frac{(\lambda b)^{k-2}}{k!}.$$

3. 利用不等式

$$k! \geq 2 \cdot 3^{k-2}, \quad k \geq 2,$$

控制右侧的幂级数。由不等式

$$\frac{1}{k!} \leq \frac{1}{2 \cdot 3^{k-2}},$$

知

$$\sum_{k \geq 2} \frac{(\lambda b)^{k-2}}{k!} \leq \frac{1}{2} \sum_{k \geq 2} \left(\frac{\lambda b}{3} \right)^{k-2}.$$

当

$$0 < \lambda < \frac{3}{b}$$

时,

$$\sum_{k \geq 2} \frac{(\lambda b)^{k-2}}{k!} \leq \frac{1}{2(1 - \lambda b/3)}.$$

因此

$$E[e^{\lambda X}] \leq 1 + \frac{\lambda^2 \sigma^2}{2(1 - \lambda b/3)}.$$

4. 利用

$$1 + u \leq e^u, \quad u \in \mathbb{R},$$

变成指数形式:

$$E[e^{\lambda X}] \leq \exp\left(\frac{\lambda^2 \sigma^2}{2(1 - \lambda b/3)}\right), \quad 0 < \lambda < \frac{3}{b}.$$

等价得

$$\log E[e^{\lambda X}] \leq \frac{\lambda^2 \sigma^2}{2(1 - \lambda b/3)}.$$

此为 Bernstein 证明的核心 MGF 界。

5. 推广到独立变量的和, 不难推出

$$E[e^{\lambda S_n}] \leq \exp\left(\frac{\lambda^2 V}{2(1 - \lambda b/3)}\right),$$

对于 $0 < \lambda < 3/b$ 成立。

6. 代回 Chernoff bound:

$$P(S_n \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2 V}{2(1 - \lambda b/3)}\right).$$

在 $0 < \lambda < 3/b$ 范围内选取一个能够算出结果的 λ :

$$\lambda = \frac{t}{V + bt/3}.$$

即得

$$P(S_n \geq t) \leq \exp\left(-\frac{t^2}{2(V + bt/3)}\right).$$

最初的右尾形式得证。左尾对 $-X_i$ 使用相同结论即可，再由 Union Bound 可推出双侧形式。

7.9.3 Bernstein 的经验均值形式

$$P(|\hat{\mu}_n - \mu| \geq \varepsilon) \leq 2 \exp\left(-\frac{n\varepsilon^2}{2(\sigma^2 + b\varepsilon/3)}\right).$$

也可反解出相应的置信半径，常用的是

$$\sqrt{\frac{\sigma^2 \log(1/\delta)}{n}} + \frac{\log(1/\delta)}{n}.$$

Bernstein 具有一种“双重性格”：中等偏差时像高斯型 e^{-ct^2} ，极端偏差时像指数型 e^{-ct} 。

7.10 Sub-Gaussian 与 Sub-Exponential 的统一语言

7.10.1 Sub-Gaussian 的定义

若对于任意 $\lambda \in \mathbb{R}$,

$$E[e^{\lambda(X - E[X])}] \leq \exp\left(\frac{\sigma^2 \lambda^2}{2}\right),$$

则称 X 是一个 σ^2 -Sub-Gaussian 随机变量。

令

$$Z = X - E[X].$$

Sub-Gaussian 的 Chernoff bound 为

$$P(Z \geq t) \leq \exp\left(-\lambda t + \frac{\sigma^2 \lambda^2}{2}\right).$$

对右侧求下界（二次函数问题），即得

$$P(X - E[X] \geq t) \leq \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

双侧形式为

$$P(|X - E[X]| \geq t) \leq 2 \exp\left(-\frac{t^2}{2\sigma^2}\right).$$

可反解出置信半径为

$$\sigma \sqrt{2 \log \frac{2}{\delta}}.$$

最重要的封闭性：独立 Sub-Gaussian 变量之和

$$\sum_{i=1}^n (X_i - E[X_i])$$

是

$$\left(\sum_{i=1}^n \sigma_i^2\right)\text{-Sub-Gaussian.}$$

上述结论的经验均值版本：

$$P(|\hat{\mu}_n - \mu| \geq \varepsilon) \leq 2 \exp\left(-\frac{n\varepsilon^2}{2\sigma^2}\right).$$

置信半径为

$$\sigma \sqrt{\frac{2 \log(2/\delta)}{n}}.$$

7.10.2 Sub-Exponential 的定义

设随机变量 X 已中心化, 即 $E[X] = 0$ 。若存在参数

$$\nu^2 > 0, \quad b > 0,$$

使得当

$$|\lambda| < \frac{1}{b}$$

时,

$$E[e^{\lambda X}] \leq \exp\left(\frac{\nu^2 \lambda^2}{2}\right),$$

则称 X 是参数为 (ν^2, b) 的 Sub-Exponential 随机变量。

从 Sub-Exponential 推尾界:

$$P(X \geq t) \leq \exp\left(-\lambda t + \frac{\nu^2 \lambda^2}{2}\right), \quad 0 < \lambda < \frac{1}{b}.$$

当最优点

$$\lambda^* = \frac{t}{\nu^2} \leq \frac{1}{b}$$

时, 依旧有高斯型尾部

$$P(X \geq t) \leq e^{-t^2/(2\nu^2)}.$$

当

$$t > \frac{\nu^2}{b}$$

时, 取 $\lambda \approx 1/b$, 有

$$P(X \geq t) \leq e^{-t/(2b)}.$$

综上,

$$P(X \geq t) \leq \exp\left[-\frac{1}{2} \min\left(\frac{t^2}{\nu^2}, \frac{t}{b}\right)\right].$$

双侧形式为

$$P(|X| \geq t) \leq 2 \exp\left[-\frac{1}{2} \min\left(\frac{t^2}{\nu^2}, \frac{t}{b}\right)\right].$$

这体现了 Sub-Exponential 是重要的尾部结构: 小偏差为高斯型 e^{-ct^2} , 大偏差为指数型 e^{-ct} 。

关于闭合性, 独立 Sub-Exponential 变量之和

$$\sum_{i=1}^n X_i$$

是参数为

$$\left(\sum_{i=1}^n \nu_i^2, \max_i b_i\right)$$

的 Sub-Exponential 随机变量。

常用结论:

$$X \text{ Sub-Gaussian} \quad \Rightarrow \quad X^2 - E[X^2] \text{ Sub-Exponential}.$$

$$X, Y \text{ Sub-Gaussian} \quad \Rightarrow \quad XY \text{ Sub-Exponential}.$$

8 数理统计基本概念

8.1 视角转换

从概率论中: F 已知 $\Rightarrow$ 计算 $P(X \in A)$ 、 $E[X]$ 、 $\text{Var}(X)$ 。

变为数理统计中: $X_1, \dots, X_n$ 已观测, F_θ 中的 θ 未知 $\Rightarrow$ 反推 θ 。

数理统计的主线可以压缩成:

总体模型 $\longrightarrow$ 随机样本 $\longrightarrow$ 统计量及其抽样分布 $\longrightarrow$ 推断未知参数.

8.2 总体、样本、样本值、统计量

8.2.1 随机样本与样本值

设总体为 F_θ ,

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F_\theta,$$

即独立同分布。

抽样前: $X_1, \dots, X_n$ 都是随机变量。

抽样后: $X_1 = x_1, \dots, X_n = x_n$ 成为随机样本, 其中 $x_1, \dots, x_n$ 是确定的观测值 (样本值)。

 随机变量与观测值不要混用

X_i 表示抽样前的随机变量, x_i 表示已经观测到的数值。估计量 $\hat{\theta}(X_1, \dots, X_n)$ 是随机变量; 把数据代入后得到的估计值 $\hat{\theta}(x_1, \dots, x_n)$ 才是一个确定的数。

8.2.2 统计量与抽样分布

统计量是不能含未知参数的样本的任意函数：

$$T = T(X_1, \dots, X_n).$$

统计量本身也是随机变量，也有自己的分布，称为抽样分布。

例如

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

都是统计量。后面的点估计、区间估计和假设检验，本质上都依赖统计量的抽样分布。

经验分布函数

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}$$

也可以看成用样本对总体分布 F 的直接估计。

8.3 Beta、Gamma、Dirichlet：统一分布家族

8.3.1 Beta 分布：随机概率

$$X \sim \text{Beta}(\alpha, \beta), \quad \alpha, \beta > 0.$$

密度是

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$

其中 Beta 函数

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx.$$

$$E[X] = \frac{\alpha}{\alpha + \beta},$$

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

参数可以拆成两个作用： $\alpha/(\alpha + \beta)$ 控制分布中心，而 $\alpha + \beta$ 控制集中程度。

8.3.2 Gamma 分布：正数上的时间 / 速率模型

$$X \sim \Gamma(\alpha, \lambda).$$

密度是

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0.$$

$$E[X] = \frac{\alpha}{\lambda}, \quad \text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

! 参数化约定

这里的 λ 是 rate, 因此均值为 α/λ 。有些资料使用 scale $\theta = 1/\lambda$, 写成均值 $\alpha\theta$; 使用公式前先确认参数化。

8.3.3 Dirichlet 分布：随机概率向量

设

$$(X_1, \dots, X_k) \sim \text{Diri}(\alpha_1, \dots, \alpha_k),$$

定义在单纯形

$$X_i > 0, \quad \sum_{i=1}^k X_i = 1.$$

密度为

$$f(x_1, \dots, x_k) = \frac{\Gamma(\alpha_0)}{\prod_{i=1}^k \Gamma(\alpha_i)} \prod_{i=1}^k x_i^{\alpha_i-1},$$

其中

$$\alpha_0 = \sum_{i=1}^k \alpha_i.$$

$$E[X_i] = \frac{\alpha_i}{\alpha_0},$$

$$\text{Var}(X_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)},$$

$$\text{Cov}(X_i, X_j) = -\frac{\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)}.$$

8.3.4 三个分布为什么属于同一条线

若 $G_1 \sim \Gamma(\alpha, 1)$ 、 $G_2 \sim \Gamma(\beta, 1)$ 且独立，则

$$\frac{G_1}{G_1 + G_2} \sim \text{Beta}(\alpha, \beta).$$

更一般地，若 $G_i \stackrel{\text{ind}}{\sim} \Gamma(\alpha_i, 1)$ ，则归一化后的概率向量

$$X_i = \frac{G_i}{\sum_{j=1}^k G_j}.$$

服从 $\text{Diri}(\alpha_1, \dots, \alpha_k)$ 。因此可以把 Beta 看作二维 Dirichlet；Gamma 变量提供正的“质量”，归一化后得到概率。

这一关系在贝叶斯模型中很常见：Beta 对应二分类概率，Dirichlet 对应多分类概率。

8.4 χ^2 、 t 、 F ：来自正态分布的三个构件

统一结构是：

$$\text{平方和} \rightarrow \chi^2, \quad \frac{\text{Normal}}{\sqrt{\chi^2/df}} \rightarrow t, \quad \frac{\chi^2/df}{\chi^2/df} \rightarrow F.$$

8.4.1 卡方分布

若

$$Z_1, \dots, Z_\nu \stackrel{\text{iid}}{\sim} N(0, 1),$$

则

$$Q = \sum_{i=1}^{\nu} Z_i^2 \sim \chi_\nu^2,$$

ν 称为自由度。

性质：

$$E[Q] = \nu, \quad \text{Var}(Q) = 2\nu.$$

若两个卡方变量独立，则

$$\chi_{\nu_1}^2 + \chi_{\nu_2}^2 \sim \chi_{\nu_1 + \nu_2}^2.$$

8.4.2 Student- t 分布

若

$$Z \sim N(0, 1), \quad V \sim \chi_\nu^2,$$

且二者独立，则

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu.$$

可记住：

$$t_\nu \Rightarrow N(0, 1),$$

$$T^2 \sim F_{1, \nu}.$$

t 分布比正态分布尾部更厚，反映了用随机量 S 替代未知 σ 所引入的额外不确定性；当自由度增大，这种额外不确定性逐渐消失。

8.4.3 F 分布

若

$$U \sim \chi_m^2, \quad V \sim \chi_n^2,$$

且独立, 则

$$F = \frac{U/m}{V/n} \sim F_{m,n}.$$

F 分布用于比较两个独立的标准化平方和, 因此自然出现在方差比、方差分析和回归整体显著性检验中。

8.5 正态总体抽样定理

设

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

定义

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

有以下结论:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2,$$

$$\bar{X} \perp S^2.$$

推论:

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

8.5.1 关键推导：平方和的正交分解

先把总波动分解为“样本内部波动”和“样本均值偏离总体均值”：

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

标准化后，左边是 n 个独立标准正态变量的平方和，所以服从 χ_n^2 。右边第二项满足

$$\frac{n(\bar{X} - \mu)^2}{\sigma^2} \sim \chi_1^2.$$

正态样本中，这两个正交方向对应的投影相互独立，因此剩余项满足

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

这里丢掉的一个自由度，正是因为残差满足约束 $\sum_i (X_i - \bar{X}) = 0$ 。

8.5.2 为什么样本方差除以 $n-1$

由上面的卡方结论和 $E[\chi_{n-1}^2] = n-1$,

$$E[S^2] = \frac{\sigma^2}{n-1} E\left[\frac{(n-1)S^2}{\sigma^2}\right] = \sigma^2.$$

因此 S^2 是 σ^2 的无偏估计。分母 $n-1$ 不是形式约定，而是校正了估计 μ 所消耗的一个自由度。

8.6 充分统计量与指数族

样本可能很长，但用于推断参数的信息有时可以压缩到一个低维统计量中。

8.6.1 充分统计量

若在给定 $T(X)$ 后, 样本的条件分布不再依赖参数 θ , 则称 T 是 θ 的充分统计量。常用的 Fisher–Neyman 因子分解准则为: 若联合密度可以写成

$$f_{\theta}(x_1, \dots, x_n) = g_{\theta}(T(x_1, \dots, x_n))h(x_1, \dots, x_n),$$

其中 h 不含 θ , 则 T 对 θ 充分。

例如 $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$ 时,

$$L(p) = p^{\sum_i x_i} (1-p)^{n-\sum_i x_i},$$

所以数据对 p 的信息只通过 $T = \sum_i X_i$ 进入似然; T 是 p 的充分统计量。

8.6.2 指数族提供统一结构

一参数指数族可写为

$$f(x; \theta) = h(x) \exp\{\eta(\theta)T(x) - A(\theta)\}.$$

独立样本的似然中, 数据通常只通过 $\sum_i T(X_i)$ 出现, 因此充分统计量、似然计算和共轭先验都能得到统一表达。Bernoulli、Poisson、正态、Gamma 等常用模型都属于指数族。

i 本章抓住什么

不要孤立背诵 Beta、Gamma、 χ^2 、 t 、 F 。本章真正的链条是: 样本经过统计量压缩, 统计量有抽样分布, 抽样分布再支撑下一章的估计与检验。

9 参数估计

9.1 点估计

假定总体属于参数族

$$X \sim F_{\theta}, \quad \theta \in \Theta,$$

其中真实参数 θ 未知。我们根据随机样本构造统计量

$$\hat{\theta} = T(X_1, \dots, X_n)$$

来估计 θ 。

在观察数据之前， $X_1, \dots, X_n$ 是随机变量，因此 $\hat{\theta}$ 也是随机变量；它会随着抽到的样本不同而变化。观察到具体样本值 $x_1, \dots, x_n$ 后，

$$T(x_1, \dots, x_n)$$

才是一个具体数值。

估计量与估计值

- $\hat{\theta} = T(X_1, \dots, X_n)$ 称为估计量，是具有抽样分布的随机变量；
- $T(x_1, \dots, x_n)$ 称为估计值，是当前这组数据给出的具体结果。

研究估计量的期望、方差、偏差和一致性，都是在研究它重复抽样时的表现。

参数估计至少包含三个层次：

1. **怎样构造估计量**：如矩估计、最大似然估计；
2. **怎样评价估计量**：如偏差、方差、MSE 和一致性；
3. **怎样量化不确定性**：如标准误和置信区间。

单独报告点估计 $\hat{\theta}$ 并不能说明估计有多精确。相同的估计值可能来自不同样本量，其不确定性可能完全不同，因此点估计通常应与标准误或置信区间配合使用。

9.2 矩估计

矩估计的基本思想是：用样本的经验矩匹配总体的理论矩。

假设参数为

$$\theta = (\theta_1, \dots, \theta_r),$$

并且总体前 r 个理论矩为

$$m_k(\theta) = E_\theta[X^k], \quad k = 1, \dots, r.$$

对应的样本矩为

$$\widehat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

矩估计令

$$\widehat{m}_k = m_k(\theta), \quad k = 1, \dots, r,$$

再解这组方程得到矩估计量 $\widehat{\theta}_{\text{MOM}}$ 。

9.2.1 为什么矩估计通常是一致的

若相应总体矩存在，由大数定律，

$$\widehat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} E_{\theta_0}[X^k] = m_k(\theta_0),$$

其中 θ_0 是真实参数。

若矩映射

$$m(\theta) = (m_1(\theta), \dots, m_r(\theta))$$

能够唯一确定参数，并且逆映射在 θ_0 附近连续，那么由连续映射定理，

$$\widehat{\theta}_{\text{MOM}} = m^{-1}(\widehat{m}) \xrightarrow{P} m^{-1}(m(\theta_0)) = \theta_0.$$

因此矩估计的基本逻辑是

样本矩收敛到总体矩 $\implies$ 由总体矩反推出真实参数.

这里隐含一个重要条件：不同参数必须产生不同的矩特征。若

$$m(\theta_1) = m(\theta_2)$$

却有 $\theta_1 \neq \theta_2$ ，那么仅凭所选矩就无法区分这两个参数，矩方程也不能唯一识别模型。

9.2.2 例：正态分布的矩估计

若

$$X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2),$$

利用

$$E[X] = \mu, \quad E[X^2] = \mu^2 + \sigma^2,$$

令理论矩等于样本矩：

$$\bar{X} = \mu,$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \mu^2 + \sigma^2.$$

解得

$$\hat{\mu}_{\text{MOM}} = \bar{X},$$

以及

$$\begin{aligned} \hat{\sigma}_{\text{MOM}}^2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \end{aligned}$$

这里分母为 n 不是计算错误。矩估计要求匹配总体矩，首先追求的是构造与一致性，并不自动保证有限样本无偏。后文会看到，采用 $n - 1$ 才能得到 σ^2 的无偏估计。

⚠ 矩估计什么时候需要谨慎

矩估计计算简单、解释直接，但存在几个限制：

- 所需总体矩可能不存在，例如 Cauchy 分布没有有限均值；
- 矩方程可能无解、多解，或者解落在参数空间之外；
- 不同矩的选择可能产生不同估计量；
- 高阶矩容易受异常值和重尾数据影响，数值上往往不稳定；
- 它只使用选定的矩，不一定充分利用整个分布模型的信息。

当矩条件多于未知参数时，可以通过加权方式综合这些条件，这会引出广义矩估计（GMM）；现阶段了解这一联系即可。

9.3 MLE（最大似然估计）

寻找最能解释观测数据的参数。

观察到 $x_1, \dots, x_n$ 后，似然函数为

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

此时数据 x_i 固定， θ 是变量， $L(\theta)$ 表示出了不同参数对当前数据的解释能力。

MLE 定义为

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta),$$

也常转为最大化对数似然：

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta).$$

讨论 Bernoulli 和正态分布的 MLE。

9.3.1 Bernoulli 参数的 MLE

若 $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, 则

$$\ell(p) = \sum_{i=1}^n [X_i \log p + (1 - X_i) \log(1 - p)].$$

在 $0 < \bar{X} < 1$ 时令导数为零:

$$\ell'(p) = \frac{\sum_i X_i}{p} - \frac{n - \sum_i X_i}{1 - p} = 0,$$

得到

$$\hat{p}_{\text{MLE}} = \bar{X}.$$

若样本全为 0 或全为 1, 最大值落在参数空间边界, 结论仍分别为 $\hat{p} = 0$ 或 1。

9.3.2 正态分布参数的 MLE

若 $X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, 则忽略与参数无关的常数后,

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2.$$

分别对 μ 和 σ^2 求极值, 得到

$$\hat{\mu}_{\text{MLE}} = \bar{X}, \quad \widehat{\sigma^2}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

注意 $\widehat{\sigma^2}_{\text{MLE}}$ 的分母是 n 。它最大化似然, 但在有限样本下不是无偏估计; 无偏版本 S^2 的分母是 $n - 1$ 。

 求导等于零还不够

MLE 还要检查参数空间、边界点和极值类型。混合模型等问题甚至可能存在多个局部极值, 数值优化的结果不必然是全局 MLE。

9.4 估计量评价

9.4.1 无偏性

偏差定义为

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta.$$

可解释样本方差分母采用 $n - 1$ 的原因。

利用恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2,$$

取期望后得到

$$E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2.$$

因此

$$E[S^2] = E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \sigma^2.$$

这个无偏性结论只要求样本独立同分布且二阶矩存在，不要求总体正态；正态性是进一步得到卡方抽样分布时才需要的。

9.4.2 有效性与 MSE

若两个估计量都无偏，那么方差更小者更有效：

$$\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2).$$

但若估计量有偏，只比较方差并不公平，更统一的评价是

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta})^2.$$

这就是偏差—方差分解：允许引入少量偏差，可能换来更大的方差下降，从而降低总体误差。

9.4.3 一致性

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

表示对于任意 $\varepsilon > 0$,

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \rightarrow 0.$$

例如 $E[X_i] = \mu$ 、 $\text{Var}(X_i) = \sigma^2 < \infty$ 时,

$$P(|\bar{X} - \mu| > \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0,$$

所以 $\bar{X}$ 是 μ 的一致估计。这也把参数估计与前一章的 Chebyshev 不等式连接起来。

9.5 Score、Fisher 信息与 Cramér–Rao 下界

9.5.1 Score 与 Fisher 信息

一维参数的 score 定义为

$$U(\theta) = \frac{\partial}{\partial \theta} \ell(\theta).$$

在允许微分与积分交换等正则条件下,

$$E_\theta[U(\theta)] = 0.$$

单个观测的 Fisher 信息为

$$I_1(\theta) = E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(X; \theta) \right)^2 \right] = -E_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta) \right].$$

独立样本的信息可加: $I_n(\theta) = nI_1(\theta)$ 。信息越大, 似然在真实参数附近通常越尖, 参数越容易被精确估计。

9.5.2 Cramér–Rao 下界的关键推导

若 T 是 $g(\theta)$ 的无偏估计, 则在正则条件下

$$\text{Cov}_\theta(T, U) = g'(\theta).$$

由 Cauchy–Schwarz 不等式,

$$\text{Cov}(T, U)^2 \leq \text{Var}(T) \text{Var}(U).$$

又因为 $\text{Var}(U) = I_n(\theta)$, 所以

$$\text{Var}_\theta(T) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}.$$

特别地, 无偏估计 $\hat{\theta}$ 满足

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}.$$

这是无偏估计方差能够达到的理论下界, 不代表每个模型中都存在达到下界的估计量。

9.5.3 例: Bernoulli 参数

对单个 $X \sim \text{Bernoulli}(p)$,

$$I_1(p) = \frac{1}{p(1-p)}, \quad I_n(p) = \frac{n}{p(1-p)}.$$

因此无偏估计的方差下界为 $p(1-p)/n$ 。而 $\bar{X}$ 的方差恰好等于这个下界, 所以它在该意义下是有效的。

9.6 MLE 为什么近似正态

MLE 满足 score 方程 $U_n(\hat{\theta}) = 0$ 。在真实参数 θ_0 附近作 Taylor 展开：

$$0 = U_n(\theta_0) + (\hat{\theta} - \theta_0)U'_n(\tilde{\theta}),$$

其中 $\tilde{\theta}$ 位于 $\hat{\theta}$ 与 θ_0 之间。整理得

$$\sqrt{n}(\hat{\theta} - \theta_0) = -\frac{U_n(\theta_0)/\sqrt{n}}{U'_n(\tilde{\theta})/n}.$$

在可识别、参数位于内部、似然足够光滑等正则条件下，分子由中心极限定理趋于 $N(0, I_1(\theta_0))$ ，分母依概率趋于 $-I_1(\theta_0)$ ，于是

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I_1(\theta_0)}\right).$$

等价地，大样本下

$$\hat{\theta} \approx N\left(\theta_0, \frac{1}{nI_1(\theta_0)}\right).$$

这条结论连接了 MLE、Fisher 信息、CLT 与大样本置信区间。它是渐近结论；小样本、边界参数、不可识别模型或重尾模型中不能机械套用。

9.7 区间估计

9.7.1 置信区间

区间估计给出精度

$$[L(X), U(X)],$$

定义置信区间：

$$P_\theta(L(X) \leq \theta \leq U(X)) = 1 - \alpha.$$

含义为：若反复抽样，反复按同一规则构造区间，那么其中约 $1 - \alpha$ 的区间会覆盖真实参数。

⚠ 置信区间的频率学派含义

参数 θ 在频率学派中是固定的。观察到数据后，区间已经确定，不能再说“ θ 以 $1 - \alpha$ 的概率位于这个已实现区间内”； $1 - \alpha$ 描述的是构造区间的方法在重复抽样中的覆盖率。

9.7.2 枢轴量法

枢轴量是

$$W = W(X_1, \dots, X_n; \theta),$$

它可以包含未知参数，但其分布不含未知参数。

统一流程：构造参数枢轴量 $\rightarrow$ 截取 $1 - \alpha$ 概率 $\rightarrow$ 反解参数。

例如正态总体方差未知时，

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

由

$$P(-t_{n-1, 1-\alpha/2} \leq T \leq t_{n-1, 1-\alpha/2}) = 1 - \alpha$$

反解 μ ，得到

$$\mu \in \left[\bar{X} - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}} \right].$$

9.7.3 四套核心置信区间

问题	枢轴量	分布
σ^2 已知, 估计 μ	$(\bar{X} - \mu)/(\sigma/\sqrt{n})$	$N(0, 1)$
σ^2 未知, 估计 μ	$(\bar{X} - \mu)/(S/\sqrt{n})$	t_{n-1}
估计正态总体 σ^2	$(n-1)S^2/\sigma^2$	χ_{n-1}^2
估计两个正态总体方差比	$(S_1^2/S_2^2)/(\sigma_1^2/\sigma_2^2)$	F_{ν_1, ν_2}

9.8 假设检验：用反证思路衡量数据与模型的冲突

设原假设为 H_0 ，备择假设为 H_1 。先暂时假定 H_0 成立，再选择一个在 H_0 下分布已知的检验统计量。若观测结果在该分布下过于极端，就拒绝 H_0 。

9.8.1 四个基本量

- 显著性水平 α ：允许第一类错误的最大概率；
- 第一类错误： H_0 为真却拒绝 H_0 ；
- 第二类错误： H_1 为真却没有拒绝 H_0 ；
- 功效 (power)：在某个备择参数下正确拒绝 H_0 的概率。

p 值是在 H_0 成立时，得到当前结果或更极端结果的概率。若 $p \leq \alpha$ ，就在预先约定的规则下拒绝 H_0 。

p 值不是什么

p 值不是“ H_0 为真的概率”，也不是效应大小。样本很大时，实际意义很小的偏差也可能产生很小的 p 值，因此应同时报告效应量和区间估计。

9.8.2 例：正态总体均值的双侧 t 检验

考虑

$$H_0: \mu = \mu_0, \quad H_1: \mu \neq \mu_0.$$

总体方差未知时使用

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}.$$

在 H_0 下， $T \sim t_{n-1}$ 。当

$$|T| > t_{n-1, 1-\alpha/2}$$

时拒绝 H_0 。这与检查 $1 - \alpha$ 置信区间是否包含 μ_0 完全等价，体现了检验与置信区间的对偶关系。

9.9 贝叶斯更新与共轭先验

频率学派把参数视为固定未知量；贝叶斯方法则给参数指定先验分布，并用 Bayes 公式更新：

$$p(\theta | x) \propto p(x | \theta)p(\theta).$$

若后验与先验属于同一分布家族，就称该先验为共轭先验。

9.9.1 Beta–Bernoulli 的完整更新

设

$$p \sim \text{Beta}(\alpha, \beta), \quad X_i | p \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p).$$

记成功次数 $s = \sum_i X_i$ ，则

$$p(p | x) \propto p^{\alpha-1}(1-p)^{\beta-1}p^s(1-p)^{n-s},$$

所以

$$p | x \sim \text{Beta}(\alpha + s, \beta + n - s).$$

先验参数可以理解为成功与失败的伪计数。后验均值为

$$E[p | x] = \frac{\alpha + s}{\alpha + \beta + n},$$

它在先验均值与样本比例之间进行加权。

9.9.2 最小共轭关系表

似然模型	共轭先验	后验更新所需统计量
Bernoulli / Binomial	Beta	成功数与失败数
Categorical / Multinomial	Dirichlet	各类别计数
Poisson (rate 未知)	Gamma	$\sum_i X_i$ 与样本量

共轭模型的意义不只是“算得快”：它揭示了数据通过充分统计量进入后验，也为更复杂模型中的近似推断提供基准。

9.10 非正态总体的三条推断路线

Route A: Concentration, 有限样本保证。

Route B: CLT, 大样本近似。

Route C: Bayesian update, 得到参数的后验分布。

目标	优先工具	主要代价
需要非渐近误差上界	集中不等式	假设与界可能较保守
样本较大、需要近似推断	CLT / MLE 渐近理论	有限样本误差未必可控
需要融合先验并量化后验不确定性	贝叶斯更新	结论依赖先验与模型设定

本章抓住什么

矩估计和 MLE 回答“如何构造”；无偏性、MSE、一致性和 Fisher 信息回答“如何评价”；置信区间与假设检验回答“如何量化不确定性并作决定”；贝叶斯更新提供另一种参数不确定性语言。

A 鞅与自适应集中

A.1 为什么独立样本框架还不够

Hoeffding、Bernstein 等经典不等式通常从独立随机变量出发。但在在线学习、Bandit 和强化学习中，第 t 轮采取的动作会依赖前 $t - 1$ 轮的观测，数据因而是自适应产生的。

这时真正需要的条件往往不是无条件独立，而是：

$$E[D_t \mid \mathcal{F}_{t-1}] = 0.$$

它表示在已经知道全部历史后，下一步噪声仍然没有可预测的系统偏差。鞅正是描述这种“允许依赖历史，但条件均值保持稳定”的工具。

A.2 信息流、适应过程与鞅

A.2.1 Filtration: 逐步增长的信息

一个 filtration 是递增的 σ -代数序列

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \dots.$$

$\mathcal{F}_t$ 表示截至时刻 t 已经知道的全部信息。若随机变量 X_t 在 $\mathcal{F}_t$ 下可测，就称过程 $\{X_t\}$ 适应于 $\{\mathcal{F}_t\}$ 。

在线决策中，动作 A_t 通常由过去历史决定，因此它应当是 $\mathcal{F}_{t-1}$ -可测的；奖励 R_t 在本轮观察后才进入 $\mathcal{F}_t$ 。

A.2.2 Martingale、submartingale 与 supermartingale

若 $\{M_t\}$ 适应于 $\{\mathcal{F}_t\}$ 、 $E[|M_t|] < \infty$ ，并满足

$$E[M_t | \mathcal{F}_{t-1}] = M_{t-1},$$

则称 $\{M_t\}$ 为 martingale。

若条件等号改为

$$E[M_t | \mathcal{F}_{t-1}] \geq M_{t-1},$$

则是 submartingale；若方向为 $\leq$ ，则是 supermartingale。

直觉上，martingale 表示“在现有信息下没有可预测漂移”；submartingale 有向上的条件漂移，supermartingale 有向下的条件漂移。

A.2.3 两个基本例子

若 $X_1, X_2, \dots$ 独立，且 $E[X_t] = \mu_t$ ，令

$$D_t = X_t - \mu_t, \quad M_t = \sum_{s=1}^t D_s.$$

取 $\mathcal{F}_t = \sigma(X_1, \dots, X_t)$ ，则

$$E[D_t | \mathcal{F}_{t-1}] = 0,$$

所以 $\{M_t\}$ 是 martingale。

更一般地，对任意可积随机变量 Z ，定义

$$M_t = E[Z | \mathcal{F}_t].$$

由塔式性质，

$$E[M_t | \mathcal{F}_{t-1}] = E[E[Z | \mathcal{F}_t] | \mathcal{F}_{t-1}] = E[Z | \mathcal{F}_{t-1}] = M_{t-1}.$$

这称为 Doob martingale：随着信息增加，对同一终点量 Z 的预测不断更新，但当前预测的条件期望仍等于上一时刻的预测。

A.3 Martingale difference: 在线学习中的噪声语言

定义增量

$$D_t = M_t - M_{t-1}.$$

若

$$E[D_t \mid \mathcal{F}_{t-1}] = 0,$$

则 $\{D_t\}$ 称为 martingale difference sequence。

在 Bandit 中, 令

$$D_t = R_t - E[R_t \mid \mathcal{F}_{t-1}],$$

即“实际奖励减去在当前历史和动作下的条件均值”。虽然动作 A_t 可以根据历史自适应选择, 但仍有

$$E[D_t \mid \mathcal{F}_{t-1}] = 0.$$

因此独立性被替换成了更适合在线数据的条件中心化。

 零条件均值比零均值更强

$E[D_t] = 0$ 只说明平均后没有偏差; $E[D_t \mid \mathcal{F}_{t-1}] = 0$ 还要求过去信息无法预测下一步偏差。自适应集中不等式依赖的是后者。

A.4 停止时刻与可选停止

A.4.1 Stopping time

随机时刻 τ 若满足

$$\{\tau \leq t\} \in \mathcal{F}_t, \quad \forall t,$$

就称为 stopping time。它表示仅根据当前及过去信息就能判断是否已经停止, 不能偷看未来。

例如首次越过阈值

$$\tau = \inf\{t \geq 0 : M_t \geq a\}$$

是 stopping time。

停止后的过程定义为

$$M_{t \wedge \tau}, \quad t \wedge \tau = \min(t, \tau).$$

若 M_t 是 martingale, 则在适当可积条件下, 停止过程仍是 martingale。

A.4.2 Optional stopping theorem

一个最安全的版本是: 若 τ 有确定上界, 即存在 $T < \infty$ 使得 $\tau \leq T$, 并且 M_t 可积, 则

$$E[M_\tau] = E[M_0].$$

它说明仅靠根据历史选择停止时间, 不能从公平过程里凭空制造正期望收益。



不能忽略定理条件

无界停止时间、不可积增量或缺少一致可积性时, 可选停止结论可能失败。“输到翻倍、赢一次就停”的策略并不能绕开这些条件。

A.5 指数 supermartingale: 统一证明模板

设 $\{D_t\}$ 是 martingale difference sequence, 并且对某个函数 $\psi_t(\lambda)$ 有条件 MGF 控制

$$E[e^{\lambda D_t} \mid \mathcal{F}_{t-1}] \leq e^{\psi_t(\lambda)}.$$

定义

$$L_t(\lambda) = \exp\left(\lambda \sum_{s=1}^t D_s - \sum_{s=1}^t \psi_s(\lambda)\right).$$

则

$$\begin{aligned} E[L_t(\lambda) \mid \mathcal{F}_{t-1}] &= L_{t-1}(\lambda) E[e^{\lambda D_t - \psi_t(\lambda)} \mid \mathcal{F}_{t-1}] \\ &\leq L_{t-1}(\lambda). \end{aligned}$$

因此 $\{L_t(\lambda)\}$ 是非负 supermartingale。固定时刻的集中不等式可以对 L_t 使用 Markov 不等式；同时控制所有时刻则使用后面的 Ville 不等式。

这一模板把 Ch7 的

Chernoff + 独立 MGF 乘积

升级为

条件 MGF + 指数 supermartingale.

A.6 Azuma–Hoeffding 不等式

设 $\{D_t\}_{t=1}^T$ 是 martingale difference sequence, 并且几乎必然有

$$|D_t| \leq c_t.$$

令

$$M_T = \sum_{t=1}^T D_t.$$

则对任意 $x > 0$,

$$P(M_T \geq x) \leq \exp\left(-\frac{x^2}{2 \sum_{t=1}^T c_t^2}\right).$$

双侧形式为

$$P(|M_T| \geq x) \leq 2 \exp\left(-\frac{x^2}{2 \sum_{t=1}^T c_t^2}\right).$$

A.6.1 证明主线

条件于 $\mathcal{F}_{t-1}$ 后, D_t 均值为 0 且落在 $[-c_t, c_t]$ 。条件 Hoeffding 引理给出

$$E[e^{\lambda D_t} \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\lambda^2 c_t^2}{2}\right).$$

因此

$$\exp\left(\lambda M_t - \frac{\lambda^2}{2} \sum_{s=1}^t c_s^2\right)$$

是非负 supermartingale。由 Markov 不等式,

$$P(M_T \geq x) \leq \exp\left(-\lambda x + \frac{\lambda^2}{2} \sum_{t=1}^T c_t^2\right).$$

取

$$\lambda^* = \frac{x}{\sum_{t=1}^T c_t^2}$$

即得到 Azuma–Hoeffding。

与 Hoeffding 的关系

Hoeffding 控制独立有界变量之和; Azuma–Hoeffding 允许变量依赖历史, 只要求每一步在给定历史后仍然中心化且有界。

A.7 Freedman 不等式: 方差敏感的鞅界

Azuma 只使用增量上界, 可能忽略实际条件方差很小这一信息。定义可预测二次变差

$$V_t = \sum_{s=1}^t E[D_s^2 \mid \mathcal{F}_{s-1}].$$

V_t 在每一步都由过去信息确定, 是自适应过程中的累计条件方差。

设 $\{D_t\}$ 是 martingale difference sequence, 并且

$$D_t \leq b$$

几乎必然成立。则对任意 $x, v > 0$,

$$P(M_t \geq x, V_t \leq v) \leq \exp\left(-\frac{x^2}{2(v + bx/3)}\right).$$

这就是 Freedman 不等式的常用固定时刻形式。

A.7.1 证明主线

条件 Bernstein MGF 界给出

$$E[e^{\lambda D_t} \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\lambda^2 E[D_t^2 \mid \mathcal{F}_{t-1}]}{2(1 - \lambda b/3)}\right), \quad 0 < \lambda < \frac{3}{b}.$$

把这些条件 MGF 逐步累积, 可以构造以 M_t 和 V_t 为核心的指数 supermartingale。再对事件

$$\{M_t \geq x, V_t \leq v\}$$

应用 Markov 不等式并选择

$$\lambda = \frac{x}{v + bx/3},$$

即可得到上述尾界。

Freedman 对鞅所起的作用, 正对应 Bernstein 对独立变量所起的作用:

$$\text{Azuma : Freedman} \quad \Longleftrightarrow \quad \text{Hoeffding : Bernstein}.$$

A.8 固定时刻、固定窗口与 anytime 保证

A.8.1 直接 Union Bound

若对每个固定时刻 t 都有

$$P(|M_t| \geq b_t(\delta_t)) \leq \delta_t,$$

选择

$$\delta_t = \frac{6\delta}{\pi^2 t^2}, \quad \sum_{t=1}^{\infty} \delta_t = \delta,$$

则由 Union Bound, 以至少 $1 - \delta$ 的概率, 对所有 $t \geq 1$ 同时成立

$$|M_t| < b_t(\delta_t).$$

这种做法简单可靠, 但通常多付出一个随 t 增长的对数因子。

A.8.2 Ville 不等式

若 $\{L_t\}$ 是非负 supermartingale, 且 $E[L_0] \leq 1$, 则

$$P\left(\sup_{t \geq 0} L_t \geq \frac{1}{\delta}\right) \leq \delta.$$

它可以看作适用于整个时间过程的 Markov 不等式。与“对每个时刻分别控制再做 Union Bound”相比, Ville 不等式直接利用同一个 supermartingale 同时控制全部时刻。

A.8.3 Confidence sequence

若随机区间序列 $\{C_t\}$ 满足

$$P(\forall t \geq 1 : \theta \in C_t) \geq 1 - \delta,$$

就称其为置信序列。它允许研究者根据已经观察到的数据自适应决定何时停止, 同时保持整体覆盖保证。

⚠ 固定时刻区间不能随意反复查看

普通 $1 - \delta$ 置信区间只保证预先固定时刻的覆盖率。若每轮都查看并在“显著”时停止，错误率会累积；anytime-valid 的置信序列才适合这种持续监控。

A.9 自归一化集中与椭球置信集

在线性模型中，每一步的特征向量也可能根据历史选择，因此误差不能只用固定的样本量 t 归一化。

设 $x_t \in \mathbb{R}^d$ 是 $\mathcal{F}_{t-1}$ -可测的特征向量，噪声 η_t 满足条件 Sub-Gaussian 假设

$$E[e^{\lambda \eta_t} \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\lambda^2 R^2}{2}\right).$$

定义

$$S_t = \sum_{s=1}^t \eta_s x_s,$$

$$V_t = \lambda_0 I + \sum_{s=1}^t x_s x_s^T, \quad \lambda_0 > 0.$$

则以至少 $1 - \delta$ 的概率，对所有 $t \geq 0$ 同时有

$$\|S_t\|_{V_t^{-1}} \leq R \sqrt{2 \log\left(\frac{\det(V_t)^{1/2}}{\det(\lambda_0 I)^{1/2} \delta}\right)}.$$

这里

$$\|z\|_A = \sqrt{z^T A z}.$$

A.9.1 为什么叫自归一化

归一化矩阵 V_t 本身由已经选择过的特征 $x_1, \dots, x_t$ 构成。在哪些方向收集的信息多， V_t 在那些方向就大， V_t^{-1} 对相应误差的惩罚就小；信息少的方向则保持较宽的不确定性。

A.9.2 证明主线

对任意固定向量 $u \in \mathbb{R}^d$, 条件 Sub-Gaussian 假设使得

$$\exp\left(u^T S_t - \frac{R^2}{2} u^T (V_t - \lambda_0 I) u\right)$$

构成非负 supermartingale。再对 u 使用高斯混合, 把所有方向同时整合起来, 积分中的二次型产生 $\det(V_t)$; 最后应用 Ville 不等式, 就得到对所有时刻同时成立的椭球界。

A.9.3 线性回归与 Linear Bandit

若

$$y_t = x_t^T \theta_* + \eta_t$$

并使用 ridge 估计

$$\hat{\theta}_t = V_t^{-1} \sum_{s=1}^t x_s y_s,$$

则

$$\hat{\theta}_t - \theta_* = V_t^{-1} (S_t - \lambda_0 \theta_*).$$

因此若 $\|\theta_*\|_2 \leq S$, 便有高概率置信椭球

$$\|\hat{\theta}_t - \theta_*\|_{V_t} \leq R \sqrt{2 \log \left(\frac{\det(V_t)^{1/2}}{\det(\lambda_0 I)^{1/2} \delta} \right)} + \sqrt{\lambda_0} S.$$

Linear UCB 与线性 Bandit 的 optimism bonus 正是从这个椭球置信集出发。

数据结构	主要工具	使用的信息
------	------	-------

A.10 集中工具如何选择

数据结构	主要工具	使用的信息
独立、有界	Hoeffding	区间长度
独立、方差敏感	Bernstein	方差与增量上界
条件中心化、有界	Azuma–Hoeffding	鞅差与增量上界
条件中心化、方差敏感	Freedman	可预测二次变差
持续监控、随机停止	Ville / confidence sequence	非负 supermartingale
自适应向量特征	自归一化界	数据依赖椭球几何

i 本章抓住什么

鞅没有消除历史依赖，而是把“独立”替换成“给定历史后的公平性”。条件 MGF 产生指数 supermartingale，随后可以得到固定时刻、全时刻和自归一化三类集中保证。

B Markov 链与依赖序列

B.1 为什么需要 Markov 链

独立样本假设忽略了时间依赖；鞅允许过程依赖历史，但要求条件增量没有漂移。Markov 链则采用另一种结构化依赖：

给定当前状态后，下一步与更早历史无关。

它是 MCMC、强化学习状态轨迹、排队系统和随机算法的基础模型。

B.2 Markov 性与转移矩阵

设随机过程为 $X_0, X_1, \dots$ 。若对任意状态 $x_0, \dots, x_{t+1}$,

$$P(X_{t+1} = x_{t+1} \mid X_0 = x_0, \dots, X_t = x_t) = P(X_{t+1} = x_{t+1} \mid X_t = x_t),$$

则称 $\{X_t\}$ 为 Markov chain。

对于有限状态空间 $\mathcal{S} = \{1, \dots, m\}$, 定义转移矩阵

$$P_{ij} = P(X_{t+1} = j \mid X_t = i).$$

每一行都是概率分布：

$$P_{ij} \geq 0, \quad \sum_{j=1}^m P_{ij} = 1.$$

若 P_{ij} 不随 t 改变，就称为时齐 Markov 链。本章默认讨论这种情形。

B.2.1 路径概率

给定初始分布 μ_0 ，一条路径的概率可以分解为

$$P(X_0 = x_0, \dots, X_T = x_T) = \mu_0(x_0) \prod_{t=0}^{T-1} P_{x_t x_{t+1}}.$$

这与 iid 样本的乘积分解不同：每一步只依赖前一个状态，而不是所有变量相互独立。

B.3 分布演化与多步转移

把时刻 t 的状态分布写成行向量

$$\mu_t(j) = P(X_t = j).$$

则

$$\mu_{t+1} = \mu_t P,$$

因此

$$\mu_t = \mu_0 P^t.$$

矩阵幂给出多步转移概率：

$$(P^t)_{ij} = P(X_t = j \mid X_0 = i).$$

Markov 链的长期行为，本质上就是研究 P^t 随 t 增大如何变化。

B.4 状态之间的连通结构

B.4.1 可达与互通

若存在某个 $t \geq 0$ 使

$$(P^t)_{ij} > 0,$$

就称状态 j 从状态 i 可达, 记为 $i \rightarrow j$ 。

若 $i \rightarrow j$ 且 $j \rightarrow i$, 则称 i, j 互通。互通把状态空间划分为若干 communicating classes。

B.4.2 Irreducible: 不可约

若任意两个状态都互通, 则称 Markov 链不可约。不可约意味着状态空间没有被分成彼此无法到达的封闭区域。

对有限不可约链, 所有状态都是正常返的, 并且存在唯一平稳分布。

B.4.3 Period: 周期

状态 i 的周期定义为

$$d(i) = \gcd\{t \geq 1 : (P^t)_{ii} > 0\}.$$

不可约链中所有状态周期相同。若周期为 1, 就称链是非周期的。

非周期性排除了“只能在某些固定奇偶时刻返回”的机械振荡。

不可约还不够

有限不可约链具有唯一平稳分布, 但若链有周期, $\mu_0 P^t$ 仍可能在几个分布之间来回振荡。要保证逐时刻分布收敛到平稳分布, 通常还需要非周期性。

B.5 平稳分布

概率向量 π 若满足

$$\pi = \pi P, \quad \sum_i \pi_i = 1,$$

就称为 stationary distribution。

如果 $X_0 \sim \pi$, 那么

$$X_t \sim \pi, \quad \forall t \geq 0.$$

平稳不代表相邻状态独立, 只表示每个时刻的边缘分布保持不变。

B.5.1 二状态例子

考虑

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \quad 0 < a, b < 1.$$

设 $\pi = (\pi_1, \pi_2)$ 。由 $\pi = \pi P$ 和 $\pi_1 + \pi_2 = 1$,

$$\pi_1 a = \pi_2 b.$$

因此

$$\pi_1 = \frac{b}{a+b}, \quad \pi_2 = \frac{a}{a+b}.$$

这条平衡式表示: 平稳状态下, 从状态 1 流向状态 2 的平均概率质量, 等于反方向流回的质量。

B.6 Detailed balance 与可逆性

若对所有状态 i, j ,

$$\pi_i P_{ij} = \pi_j P_{ji},$$

就称 P 关于 π 满足 detailed balance, 或称该链关于 π 可逆。

把等式对 i 求和:

$$\sum_i \pi_i P_{ij} = \sum_i \pi_j P_{ji} = \pi_j,$$

所以 detailed balance 自动推出 $\pi = \pi P$ 。

可逆性比平稳性更强。它表示在平稳状态下观察一段轨迹, 正向与反向的概率规律相同。

Metropolis–Hastings 的核心设计就是构造满足 detailed balance 的转移核, 从而让目标分布成为平稳分布。

B.7 长期收敛与 mixing time

对于有限状态 Markov 链:

- 不可约保证平稳分布存在且唯一;
- 不可约加非周期保证

$$\mu_0 P^t \rightarrow \pi$$

对任意初始分布 μ_0 成立。

B.7.1 Total variation distance

有限状态空间中，两个分布 μ, ν 的总变差距离为

$$\|\mu - \nu\|_{\text{TV}} = \frac{1}{2} \sum_{x \in \mathcal{S}} |\mu(x) - \nu(x)|.$$

它也等于

$$\sup_{A \subseteq \mathcal{S}} |\mu(A) - \nu(A)|,$$

即两个分布对同一事件给出的概率最大能相差多少。

B.7.2 Mixing time

定义

$$t_{\text{mix}}(\varepsilon) = \min \left\{ t : \max_{x \in \mathcal{S}} \|P^t(x, \cdot) - \pi\|_{\text{TV}} \leq \varepsilon \right\}.$$

它衡量从最不利初始状态出发，需要多少步才能接近平稳分布。

i 平稳分布与混合速度是两件事

知道唯一的 π 只回答长期目标在哪里；mixing time 才回答需要多久到达。两条链可以拥有相同平稳分布，却具有完全不同的混合速度。

B.8 两个分析 mixing 的工具

B.8.1 Coupling

构造两个边缘上都服从同一转移核的过程 X_t, Y_t ，使它们尽快相遇。一旦相遇，就让它们之后始终一起运动。

Coupling inequality 给出

$$\|\mathcal{L}(X_t) - \mathcal{L}(Y_t)\|_{\text{TV}} \leq P(X_t \neq Y_t).$$

因此，只要能控制耦合时间

$$\tau_{\text{couple}} = \inf\{t : X_t = Y_t\},$$

就能控制分布距离：

$$\|\mathcal{L}(X_t) - \mathcal{L}(Y_t)\|_{\text{TV}} \leq P(\tau_{\text{couple}} > t).$$

B.8.2 Spectral gap

对有限可逆链，转移矩阵可以在以 π 加权的内积下进行谱分析。记特征值为

$$1 = \lambda_1 > \lambda_2 \geq \dots \geq \lambda_m \geq -1.$$

常用的绝对谱隙为

$$\gamma_* = 1 - \max\{|\lambda_2|, |\lambda_m|\}.$$

谱隙越大，偏离平稳分布的方向衰减越快；mixing time 通常与 $1/\gamma_*$ 同阶，并额外依赖最小平稳概率和精度的对数项。

这里最值得保留的是关系：

$$\text{大谱隙} \implies \text{快混合} \implies \text{相关性更快衰减}.$$

B.9 Markov 链遍历定理

设有限 Markov 链不可约，平稳分布为 π 。对任意函数 $f : \mathcal{S} \rightarrow \mathbb{R}$ 和任意初始分布，

$$\frac{1}{T} \sum_{t=1}^T f(X_t) \xrightarrow{\text{a.s.}} E_{\pi}[f(X)] = \sum_x \pi(x) f(x).$$

这就是 Markov chain ergodic theorem。它把 iid 大数律推广到了具有 Markov 依赖的数据。

❗ 周期性对两种收敛的影响不同

逐时刻分布 $P^t(x, \cdot) \rightarrow \pi$ 通常需要非周期性；时间平均的遍历收敛在不可约正再生条件下仍可成立。因此“分布是否稳定”和“长期平均是否稳定”必须区分。

B.10 依赖如何降低有效样本量

假设链已经处于平稳状态，令

$$Y_t = f(X_t), \quad \gamma_k = \text{Cov}(Y_0, Y_k).$$

样本均值的方差为

$$\text{Var}\left(\frac{1}{n} \sum_{t=1}^n Y_t\right) = \frac{1}{n^2} \left[n\gamma_0 + 2 \sum_{k=1}^{n-1} (n-k)\gamma_k \right].$$

iid 情形下 $\gamma_k = 0$ ($k \geq 1$)，方差按 γ_0/n 缩小；若自相关为正，额外的协方差项会使样本均值更不稳定。

令

$$\rho_k = \frac{\gamma_k}{\gamma_0}, \quad \tau_{\text{int}} = 1 + 2 \sum_{k=1}^{\infty} \rho_k,$$

则大样本下常用近似为

$$\text{Var}(\bar{Y}_n) \approx \frac{\gamma_0 \tau_{\text{int}}}{n}.$$

因此可把

$$n_{\text{eff}} \approx \frac{n}{\tau_{\text{int}}}$$

理解为有效样本量：收集了 n 个相关样本，但其信息量可能只相当于更少的独立样本。

B.10.1 Markov 链集中界的量级图景

对混合良好的可逆链和有界函数，许多集中结果具有如下结构：

$$P\left(\left|\frac{1}{n} \sum_{t=1}^n f(X_t) - E_{\pi}[f]\right| \geq \varepsilon\right) \lesssim 2 \exp(-c n \gamma_* \varepsilon^2),$$

其中常数和尺度还依赖 f 的范围、初始分布及所采用的谱隙定义。这里应记住的是有效指数样本量约为 $n \gamma_*$ ；精确使用时必须核对具体定理条件和常数。

B.11 与 MCMC 和强化学习的连接

B.11.1 MCMC

MCMC 先设计一个以目标分布 π 为平稳分布的 Markov 链，再用遍历平均

$$\frac{1}{T} \sum_{t=1}^T f(X_t)$$

估计 $E_{\pi}[f]$ 。正确的平稳分布保证“目标对”，mixing time 和有效样本量决定“估计快不快”。

B.11.2 强化学习

在固定策略 $\pi(a | s)$ 下，状态序列形成转移核

$$P^{\pi}(s' | s) = \sum_a \pi(a | s) P(s' | s, a)$$

对应的 Markov 链。策略的长期状态访问频率、平均奖励和数据相关性，都与这条链的平稳分布和混合性质相关。

策略改变时，转移规律本身也会改变，因此在线强化学习通常同时面对：

Markov 依赖 + 自适应决策 + 可能的非平稳性。

这也是 Markov 链工具与上一章鞅工具需要结合使用的原因。

B.12 Markov 链分析清单

面对一条有限状态链，依次检查：

1. 写出状态空间和转移矩阵；
2. 判断 communicating classes 与不可约性；
3. 检查周期；
4. 解 $\pi = \pi P$ ；
5. 若可能，验证 detailed balance；
6. 用 coupling 或 spectral gap 判断 mixing；
7. 用遍历定理处理时间平均；
8. 估计自相关和有效样本量。

i 本章抓住什么

Markov 性把任意历史依赖压缩为当前状态依赖；平稳分布描述长期目标，mixing 描述到达速度，遍历定理说明单条相关轨迹仍能估计平稳期望。