

高级优化工具箱

在线学习、Bandit 与自适应方法

Gary Chen

2026-09-19

目录

前言	7
本书回答的四个问题	7
阅读路径	7
I 统一分析语言	8
1 迭代复杂度与一阶分析模板	9
1.1 先确定测量什么	9
1.2 函数结构决定可达到速率	10
1.3 一步势函数不等式	10
1.4 望远镜求和与平均化	11
1.5 步长平衡	11
1.5.1 Polyak 步长	12
1.6 光滑目标：下降转化为最后迭代点速率	12
1.7 速率速查	13
1.8 加速与复合优化接口	13
1.9 使用检查	14
II 全信息在线优化	15
2 在线凸优化：协议、反馈与遗憾	16
2.1 从固定目标到交互式决策	16
2.2 OCO 协议：先决策，后反馈	17
2.3 反馈决定问题难度	17
2.4 环境模型	17
2.5 静态遗憾：与事后最佳固定决策比较	18
2.6 凸性把函数差转成线性损失	19
2.7 有界性假设为什么出现	19
2.8 $\sqrt{T}$ 量级不是分析松弛	20
2.9 静态遗憾不能表达什么	20
2.10 使用前检查	20
3 OGD、强凸遗憾与 online-to-batch	22
3.1 Online Gradient Descent	22

3.2	母不等式：一步距离如何变化	23
3.3	一般凸损失： $O(\sqrt{T})$ 遗憾	23
3.4	强凸损失：曲率产生对数遗憾	25
3.5	上界与下界的量级	26
3.6	Online-to-batch：把遗憾变成离线误差	26
3.7	从 OGD 重新理解 SGD	27
3.8	强凸情形：均匀平均为什么多一个 $\log T$	28
3.9	加权转换：去掉多余的 $\log T$	28
3.10	期望界与高概率界的边界	30
3.11	方法选择	30
3.12	本章主线	30
4	专家建议、Hedge 与二阶曲率	31
4.1	专家建议协议	31
4.2	Hedge：指数权重更新	32
4.3	Log-sum-exp 势函数证明	32
4.4	维数依赖与下界	33
4.5	Exp-concavity：弱于强凸但强于普通凸	34
4.6	Online Newton Step	34
4.7	何时值得使用二阶几何	35
5	镜像下降与 FTRL	36
5.1	为什么 Euclidean 几何会失配	36
5.2	强凸正则与对偶范数	36
5.3	Bregman 散度	37
5.4	Online Mirror Descent	37
5.4.1	Bregman 近端不等式	38
5.5	OMD 主不等式	38
5.6	三种核心几何	39
5.6.1	负熵恢复 Hedge	39
5.7	Mirror map 与 primal-dual 视角	39
5.8	Follow-the-Regularized Leader	40
5.9	Dual averaging 与等价边界	40
5.10	使用检查	41
6	自适应与乐观在线优化	42
6.1	从 minimax 到 problem-dependent	42
6.2	专家问题中的 small-loss	42
6.3	Self-confident 学习率	43
6.4	一般 OCO 的 self-bounding	43
6.5	Optimistic Online Mirror Descent	44
6.6	预测误差主不等式	44

6.7	三种 optimism 设计	45
6.7.1	小损失	45
6.7.2	梯度方差	46
6.7.3	梯度变化	46
6.8	随机—对抗连续视角	47
6.9	与 AdaGrad 和 parameter-free 方法的接口	47
6.10	使用检查	47
7	从在线遗憾到离线加速	48
7.1	普通转换的上限	48
7.2	稳定加权平均	48
7.3	为什么要取 $\alpha_t = t$	49
7.4	Optimism 设计	50
7.5	负稳定项完成抵消	50
7.6	与 Nesterov 加速的关系	51
7.7	未知光滑性与 universality	51
7.8	适用边界	52
III	部分反馈与 Bandit	53
8	对抗 Bandit 与 Bandit 凸优化	54
8.1	对抗多臂 Bandit 协议	54
8.2	重要性加权损失估计	55
8.3	Exp3	55
8.4	Exp3 遗憾主证明	56
8.5	下界与探索边界	57
8.6	Bandit Convex Optimization	57
8.7	一点梯度估计	57
8.8	Bandit Gradient Descent	58
8.9	光滑 BCO 与障碍几何	59
8.10	使用检查	59
9	随机多臂 Bandit	60
9.1	随机 MAB 模型	60
9.2	伪遗憾与计数分解	61
9.3	两类难度刻画	61
9.4	Explore-Then-Commit	62
9.5	ϵ -greedy 的局限	62
9.6	UCB: 用乐观原则分配探索	63
9.7	UCB 的 gap-dependent 证明	63
9.8	从 gap-dependent 到 gap-independent	64
9.9	Thompson Sampling	64

9.10 ETC、UCB 与 TS 的边界	65
9.11 进阶接口	65
10 线性 Bandit 与置信椭圆	66
10.1 线性奖励模型	66
10.2 正则最小二乘	67
10.3 为什么是置信椭圆	67
10.4 自归一化集中	68
10.5 LinUCB / OFUL	68
10.6 遗憾主证明	69
10.7 复杂度从哪里产生	70
10.8 广义线性 Bandit 接口	70
10.9 重尾、one-pass 与强化学习接口	70
10.9.1 重尾反馈	70
10.9.2 线性 MDP	70
10.9.3 One-pass	71
10.10 使用检查	71
附录	72
A 概率、范数与集中工具	72
A.1 对偶范数与 Hölder 不等式	72
A.2 条件期望与 filtration	72
A.3 次 Gaussian 随机变量	73
A.4 Hoeffding、Azuma 与 Freedman	73
A.5 Union bound 与 anytime 置信事件	74
A.6 矩阵集中接口	74
A.7 自归一化集中	74
A.8 使用条件速查	75
B 遗憾与收敛证明模板	76
B.1 势函数下降	76
B.2 望远镜求和	76
B.3 凸性线性化	76
B.4 强凸负二次项	77
B.5 指数权重与 log-partition	77
B.6 重要性加权估计	77
B.7 椭圆势函数	77
B.8 步长优化	78
B.9 速率、假设与输出点对照	78

C	研究接口：通用性、one-pass 与鲁棒 Bandit	79
C.1	Universal gradient-variation online learning	79
C.1.1	未知曲率与多层 ensemble	79
C.1.2	Hölder 光滑与通用离线加速	79
C.2	One-pass generalized linear bandits	79
C.2.1	非线性度带来的统计困难	79
C.2.2	最大似然带来的计算与存储困难	80
C.2.3	联合统计—计算效率	80
C.3	Heavy-tailed linear bandits	80
C.3.1	重尾噪声与鲁棒估计	80
C.3.2	Huber 回归	80
C.3.3	OMD 作为 one-pass 估计器	80
C.4	四份研究材料的定位	80
C.5	待添加研究方向	81
D	统一记号与模型对照	82
D.1	决策、动作与损失	82
D.2	Regret	82
D.3	随机历史	82
D.4	几何	83
D.5	Bandit	83
D.6	常数角色	83
D.7	Loss 与 reward 的约定	84

前言

《高级优化工具箱》沿着

统一分析语言 → 全信息在线优化 → 自适应与乐观学习 → 部分反馈与 Bandit

这份笔记是笔者参考优秀的优化材料组织高级优化课程中的核心问题、证明工具与算法框架。

本书承接《凸优化工具箱》，但不再重复讲授完整的凸性、对偶、KKT、基础 SGD 和近端方法。必要定义会在首次使用时简要重述，使本书能够独立查阅；已有基础理论则通过明确的先修提示承接。

本书回答的四个问题

1. 如何用一步不等式、势函数与望远镜求和统一分析迭代算法？
2. 当目标函数按轮到达时，如何用遗憾评价在线决策？
3. 如何让算法匹配问题的几何、曲率与可预测性？
4. 当反馈退化为所选动作的奖励时，如何处理探索和估计方差？

阅读路径

- 第 1 章整理全书反复使用的一阶分析模板；
- 第 2–5 章建立 OCO、OGD、Hedge、ONS、OMD 与 FTRL；
- 第 6–7 章讨论自适应遗憾、optimism 与 online-to-offline；
- 第 8–10 章进入对抗、随机与线性 Bandit；
- 附录保存集中工具、证明模板、研究接口和统一记号。

公开来源与尚待补齐的材料身份见仓库的[参考资料](#)。

Part I

统一分析语言

1 迭代复杂度与一阶分析模板

高级优化中的算法很多，但证明经常重复同一套动作：选定性能量、写出一步势函数不等式、求和消去中间项，再平衡步长。本章只整理后续会反复调用的分析语言，不重新讲授完整凸优化课程。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 2–4。次梯度、光滑性和强凸性只保留与速率直接相关的形式；KKT、完整近端理论和 Nesterov 加速的长篇代数证明不在此重复。

1.1 先确定测量什么

考虑

$$\min_{x \in \mathcal{X}} f(x), \quad x^* \in \operatorname{argmin}_{x \in \mathcal{X}} f(x).$$

常见性能量并不等价于“最后一步是否看起来稳定”。

性能量	形式	适用重点
函数值误差	$f(x_t) - f(x^*)$	最常用，直接对应优化目标
距最优集距离	$\operatorname{dist}(x_t, \mathcal{X}^*)$	强凸或误差界条件下尤其有用
梯度映射/梯度范数	$\ \nabla f(x_t)\ $	光滑非凸、复合优化的驻点度量
累计遗憾	$\sum_{t=1}^T [f_t(x_t) - f_t(u)]$	在线优化

若要达到 $f(x_t) - f(x^*) \leq \varepsilon$ ，所需迭代数称为**迭代复杂度**。它只统计 oracle 调用或更新轮数；实际运行时间还要乘上每轮求梯度、投影或解子问题的代价。

⚠ 先分清输出点

结论可能针对最后迭代点 x_T 、最佳迭代点 $\operatorname{argmin}_{t \leq T} f(x_t)$ ，也可能针对平均点。三者不能静默互换；非光滑凸优化尤其常依赖平均化。

1.2 函数结构决定可达到速率

后续最常用的四类条件为：

1. 凸性：对 $g \in \partial f(x)$,

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

2. G -Lipschitz: $|f(x) - f(y)| \leq G\|x - y\|$; 在合适的凸域上可由 $\|g\|_* \leq G$ 表示。

3. L -光滑:

$$\|\nabla f(x) - \nabla f(y)\|_* \leq L\|x - y\|.$$

4. μ -强凸:

$$f(y) \geq f(x) + \langle g, y - x \rangle + \frac{\mu}{2}\|y - x\|^2.$$

Lipschitz 性控制一阶信息的幅度；光滑性控制梯度变化；强凸性提供全局二次曲率。不能因为函数可微就默认光滑，也不能把严格凸当作具有统一参数 $\mu > 0$ 的强凸。

对 Euclidean 范数，可微凸函数的 L -光滑性还给出下降引理

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|_2^2. \quad (1.1)$$

若同时凸且 L -光滑，则梯度具有共轭性：

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{1}{L}\|\nabla f(x) - \nabla f(y)\|_2^2. \quad (1.2)$$

1.3 一步势函数不等式

投影次梯度法更新为

$$x_{t+1} = \Pi_{\mathcal{X}}(x_t - \eta_t g_t), \quad g_t \in \partial f(x_t).$$

取任意 $u \in \mathcal{X}$ 。投影非扩张性与凸性给出

$$2\eta_t(f(x_t) - f(u)) \leq \|x_t - u\|_2^2 - \|x_{t+1} - u\|_2^2 + \eta_t^2 \|g_t\|_2^2. \quad (1.3)$$

这就是一阶方法最基本的母不等式。左侧是想控制的误差，右侧由“势函数下降”和“步长代价”组成。

若 f 是 μ -强凸的，凸性线性化会多出

$$-\mu\eta_t\|x_t - u\|_2^2,$$

它可以抵消后续距离项；在线强凸 OGD 的 $O(\log T)$ 证明正是这一结构。

1.4 望远镜求和与平均化

假设 $\|g_t\|_2 \leq G$, 令 $R = \|x_1 - x^*\|_2$ 。对式 1.3 求和, 得到

$$\sum_{t=1}^T \eta_t (f(x_t) - f(x^*)) \leq \frac{R^2}{2} + \frac{G^2}{2} \sum_{t=1}^T \eta_t^2. \quad (1.4)$$

定义加权平均点

$$\bar{x}_T = \frac{\sum_{t=1}^T \eta_t x_t}{\sum_{t=1}^T \eta_t}.$$

由 Jensen 不等式,

$$f(\bar{x}_T) - f(x^*) \leq \frac{R^2 + G^2 \sum_{t=1}^T \eta_t^2}{2 \sum_{t=1}^T \eta_t}. \quad (1.5)$$

这个式子直接暴露步长要求: 分母 $\sum_t \eta_t$ 要持续增长, 而平方和 $\sum_t \eta_t^2$ 不能增长过快。经典渐近收敛条件

$$\sum_{t=1}^{\infty} \eta_t = \infty, \quad \sum_{t=1}^{\infty} \eta_t^2 < \infty$$

保证步长“走得足够远, 但噪声累计有限”; 它不等于有限时域下的最优调参。

1.5 步长平衡

若预先知道 T , 取常数步长

$$\eta = \frac{R}{G\sqrt{T}},$$

代入式 1.5 可得

$$f(\bar{x}_T) - f(x^*) \leq \frac{RG}{\sqrt{T}}. \quad (1.6)$$

因此一般 Lipschitz 凸优化的一阶 oracle 复杂度为 $O(1/\varepsilon^2)$ 。当 R 未知时, 不能假装上述步长可直接使用; 需要 doubling、coin-betting、DoG 等自适应机制, 或改用可估计的尺度上界。

1.5.1 Polyak 步长

若最优值 $f^* = f(x^*)$ 已知, 可取

$$\eta_t = \frac{f(x_t) - f^*}{\|g_t\|_2^2}. \quad (1.7)$$

把它代入 式 1.3 得

$$\|x_{t+1} - x^*\|_2^2 \leq \|x_t - x^*\|_2^2 - \frac{(f(x_t) - f^*)^2}{\|g_t\|_2^2}.$$

几何上, 步长正好最小化一步距离上界; 分析上, 它把未知的最佳固定步长转成当前误差与梯度范数的比值。缺点同样明确: 精确的 f^* 往往未知, 错误下界还可能导致过大步长。

1.6 光滑目标: 下降转化为最后迭代点速率

在无约束情形, 取

$$x_{t+1} = x_t - \frac{1}{L} \nabla f(x_t).$$

由 式 1.1,

$$f(x_{t+1}) \leq f(x_t) - \frac{1}{2L} \|\nabla f(x_t)\|_2^2. \quad (1.8)$$

这一步不需要凸性; 凸性用于把梯度下降量进一步连接到最优性间隙。若 f 凸且 L -光滑, 则

$$f(x_T) - f(x^*) \leq \frac{L\|x_1 - x^*\|_2^2}{2(T-1)}, \quad T \geq 2. \quad (1.9)$$

与非光滑情形相比, 速率从 $O(T^{-1/2})$ 提升到 $O(T^{-1})$, 而且可以控制最后迭代点。

若再有 μ -强凸性, 取步长 $1/L$ 可得线性收敛

$$f(x_t) - f(x^*) \leq \left(1 - \frac{\mu}{L}\right)^{t-1} (f(x_1) - f(x^*)). \quad (1.10)$$

条件数 $\kappa = L/\mu$ 决定收缩速度。这里“线性”指误差按几何级数衰减, 对应迭代复杂度 $O(\kappa \log(1/\varepsilon))$ 。

1.7 速率速查

令 $R = \|x_1 - x^*\|_2$ 。忽略绝对常数后，典型一阶速率为：

结构	代表方法	函数值误差	达到 ε 的迭代数
凸、 G -Lipschitz	次梯度法 + 平均	$O(RG/\sqrt{T})$	$O(R^2G^2/\varepsilon^2)$
μ -强凸、 G -Lipschitz	递减步长 + 加权平均	$O(G^2/(\mu T))$	$O(G^2/(\mu\varepsilon))$
凸、 L -光滑	GD	$O(LR^2/T)$	$O(LR^2/\varepsilon)$
凸、 L -光滑	Nesterov AGD	$O(LR^2/T^2)$	$O(\sqrt{LR^2}/\varepsilon)$
μ -强凸、 L -光滑	GD	$O(e^{-T/\kappa})$	$O(\kappa \log(1/\varepsilon))$
μ -强凸、 L -光滑	加速方法	$O(e^{-T/\sqrt{\kappa}})$	$O(\sqrt{\kappa} \log(1/\varepsilon))$

这些是不同函数类下的结论，不能把更快一行的速率移植到更弱假设上。

1.8 加速与复合优化接口

Nesterov 加速把“计算梯度的位置”和“携带动量的状态”分开。其 $O(1/T^2)$ 不是单纯把 GD 更新加上惯性项就自动得到，而是通过特定系数使势函数望远镜求和。第 7 章会从 optimism 与稳定转换重新解释这一结构。

复合目标写成

$$F(x) = f(x) + h(x),$$

其中 f 凸且 L -光滑， h 凸但可非光滑，并且近端映射易算：

$$\text{prox}_{\eta h}(z) = \underset{x}{\operatorname{argmin}} \left\{ h(x) + \frac{1}{2\eta} \|x - z\|_2^2 \right\}.$$

近端梯度更新为

$$x_{t+1} = \text{prox}_{h/L} \left(x_t - \frac{1}{L} \nabla f(x_t) \right). \quad (1.11)$$

它不是“先做梯度下降再随意截断”，而是精确最小化光滑上界与非光滑项组成的局部代理目标。ISTA 达到 $O(1/T)$ ，FISTA 达到 $O(1/T^2)$ ；完整证明留在《凸优化工具箱》，本书只把近端更新作为后续 OMD、FTRL 与约束算法的接口。

1.9 使用检查

1. 结论控制的是最后点、最佳点还是平均点？
2. G 、 L 、 μ 和距离尺度是否确实已知或可上界？
3. 投影/近端子问题是否真的比原问题容易？
4. 证明中的期望来自随机 oracle，还是算法随机化？
5. 更快速率究竟用了光滑、强凸，还是额外的可预测结构？

后续章节会反复复用 式 1.3 的“势函数下降 + 稳定性代价”结构，只是把 Euclidean 距离替换为更合适的几何。

Part II

全信息在线优化

2 在线凸优化：协议、反馈与遗憾

离线优化面对一个固定目标；在线优化面对的是连续到来的决策轮次。学习器必须先作出决策，随后才看到当轮损失及其反馈。因此，本章首先固定“谁先行动、能看到什么、与谁比较”，再讨论算法。

材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章以 Lecture 5 为主线。Online Convex Optimization Warmup 博客只用于辅助动机表达，正式定义、条件和结论以课件中的 OCO 模型为准。动态遗憾、非平稳环境和 Bandit 反馈只标明接口，不在本章展开。

2.1 从固定目标到交互式决策

固定优化通常写成

$$\min_{x \in \mathcal{X}} F(x),$$

目标函数在算法运行期间保持不变。在线优化则把过程拆成 T 轮：第 t 轮使用一个新的损失函数 f_t ，学习器在尚不知道 f_t 的情况下选择 x_t 。

这种形式至少覆盖两类机器学习场景。

- **随机优化与大规模 ERM**：每轮使用新样本或 mini-batch，因而实际处理的经验损失 f_t 随迭代变化。若样本来自同一分布，这仍是随机环境。
- **数据流与序列预测**：样本依次到达，模型必须先预测，再根据新数据产生的损失更新。数据分布还可能随时间变化。

OCO 不预先假设 f_t 来自固定分布。它允许损失序列是确定的、随机的，甚至是对抗式选择的；算法结论必须明确自己对哪一类序列成立。

2.2 OCO 协议：先决策，后反馈

设可行域 $\mathcal{X} \subseteq \mathbb{R}^d$ 非空、闭且凸。在线凸优化的标准协议为：对 $t = 1, \dots, T$,

1. 学习器根据过去的历史选择 $x_t \in \mathcal{X}$;
2. 环境给出凸损失 $f_t : \mathcal{X} \rightarrow \mathbb{R}$;
3. 学习器付出损失 $f_t(x_t)$ ，并收到指定类型的反馈;
4. 学习器利用反馈构造下一轮决策 x_{t+1} 。

时间顺序不能省略。若环境在看到当轮已经实现的 x_t 后，可以无约束地专门构造 f_t 惩罚该点，那么一般无法获得次线性遗憾。

! 非预见性约束

本书默认环境选择 f_t 时不能利用学习器当轮尚未公开的随机性。环境可以预先固定整个损失序列，也可以依赖历史 $x_1, \dots, x_{t-1}$ 自适应选择 f_t ；但不能先观察当轮随机决策的实现值，再任意针对它设置损失。

2.3 反馈决定问题难度

学习器遭受 $f_t(x_t)$ 后，可能获得不同强度的信息。

反馈模型	第 t 轮可见信息	典型问题
全信息	整个函数 f_t	专家问题、某些显式在线损失
一阶反馈	$f_t(x_t)$ 及一个 $g_t \in \partial f_t(x_t)$	OGD、OMD、FTRL
Bandit 反馈	通常只有 $f_t(x_t)$ 或所选动作的奖励	对抗 Bandit、Bandit 凸优化

第 2–7 章默认至少能够获得一阶反馈。第 8 章以后再处理部分反馈，因为此时需要额外构造损失或梯度估计量，遗憾中还会出现探索代价与估计方差。

2.4 环境模型

“对抗式”并不等于环境可以违反协议。常见模型的差别在于 f_t 可以依赖多少信息。

环境	损失的生成方式	结论通常如何表述
随机环境	f_t 由固定分布独立或按给定随机机制产生	期望风险、期望遗憾或高概率界
oblivious adversary	在过程开始前固定 $f_1, \dots, f_T$	对任意固定损失序列的界

环境	损失的生成方式	结论通常如何表述
adaptive adversary	f_t 可依赖截至 $t-1$ 的历史, 但不预见当轮随机性	条件期望界或路径式确定性界

确定性的 OGD 遗憾证明只使用已经实现的凸损失序列, 因此对任意满足协议的序列逐路径成立。涉及随机化或概率陈述时, 则必须进一步区分 oblivious 与 adaptive 环境。

2.5 静态遗憾：与事后最佳固定决策比较

在线过程没有单一固定目标, 不能只问最后一个迭代点是否接近某个最优解。标准评价量是**静态遗憾**：

$$\text{Reg}_T = \sum_{t=1}^T f_t(x_t) - \min_{u \in \mathcal{X}} \sum_{t=1}^T f_t(u). \quad (2.1)$$

对任意固定比较点 $u \in \mathcal{X}$, 记

$$\text{Reg}_T(u) = \sum_{t=1}^T (f_t(x_t) - f_t(u)). \quad (2.2)$$

若事后最佳固定点存在, 记为

$$u_T^* \in \operatorname{argmin}_{u \in \mathcal{X}} \sum_{t=1}^T f_t(u),$$

则 $\text{Reg}_T = \text{Reg}_T(u_T^*)$ 。这里比较的是“从一开始就始终使用同一个 u ”的累计损失, 而不是每轮分别选择最优优点。

i 为什么比较器要在事后选

在线算法无法预知未来；静态遗憾把算法与看完整个序列后才能确定的最佳固定决策比较。若仍能做到 $\text{Reg}_T = o(T)$, 说明在线决策为“不知道未来”支付的平均代价趋于零。

若

$$\frac{\text{Reg}_T}{T} \rightarrow 0, \quad (2.3)$$

则称算法具有 **no-regret** 性质, 也称 Hannan consistent。由 式 2.1,

$$\frac{1}{T} \sum_{t=1}^T f_t(x_t) \leq \min_{u \in \mathcal{X}} \frac{1}{T} \sum_{t=1}^T f_t(u) + o(1).$$

因此，no-regret 控制的是平均累计表现；它不保证每一轮都接近当轮最优，也不直接保证最后迭代点收敛。

2.6 凸性把函数差转成线性损失

对凸函数 f_t 和任意 $g_t \in \partial f_t(x_t)$ ，次梯度不等式给出

$$f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle. \quad (2.4)$$

于是

$$\text{Reg}_T(u) \leq \sum_{t=1}^T \langle g_t, x_t - u \rangle. \quad (2.5)$$

这一步是全书最常用的降维动作：分析一般凸损失时，可以先控制由次梯度产生的线性损失。OGD、OMD 与 FTRL 的证明虽然几何不同，但都会反复使用 式 2.4。

2.7 有界性假设为什么出现

一般凸情形中，常用两项尺度假设：存在 $D, G > 0$ ，使得

$$\sup_{x, y \in \mathcal{X}} \|x - y\|_2 \leq D, \quad \|g_t\|_2 \leq G, \quad (2.6)$$

其中 $g_t \in \partial f_t(x_t)$ 。

- D 控制比较点与在线决策之间可能相隔多远；
- G 控制单轮损失在空间中变化得多快；
- 乘积 DG 是单轮尺度，遗憾界必须与它同量纲。

若 f_t 在 $\mathcal{X}$ 上关于 ℓ_2 范数是 G -Lipschitz，则其内部点次梯度通常满足 $\|g_t\|_2 \leq G$ ；反过来，在合适的凸定义域上，有界次梯度也给出 Lipschitz 性。具体使用时应说明约束的是所有次梯度，还是算法实际取得的 g_t 。

一般凸损失既没有强曲率把迭代点拉回，也没有有限直径限制比较距离时，无法仅靠 G 得到统一的有限遗憾界。强凸情形则可用曲率代替直径，见 小节 3.4。

2.8 $\sqrt{T}$ 量级不是分析松弛

在直径至多为 D 的凸域上，面对梯度范数至多为 G 的一般凸损失，即使采用全信息或一阶反馈，也存在绝对常数 $c > 0$ ，使任意在线算法在某些损失序列上满足

$$\text{Reg}_T \geq cDG\sqrt{T}. \quad (2.7)$$

其核心构造可以取随机符号控制的线性损失：每轮梯度方向不可预测，而事后最佳固定点可以利用所有符号的累计偏差。该偏差的典型尺度为 $\sqrt{T}$ ，于是产生 $DG\sqrt{T}$ 级别的差距。

因此，只依赖凸性、直径 D 与梯度界 G 时， $O(DG\sqrt{T})$ 已是最坏情形最优阶。若要获得 $O(\log T)$ 或更快的累计遗憾，必须加入强凸性、可预测性、随机结构等额外条件。

2.9 静态遗憾不能表达什么

若环境随时间漂移，最佳固定点可能不是合适基准。动态遗憾允许比较器随轮次变化：

$$\text{DReg}_T(u_{1:T}) = \sum_{t=1}^T (f_t(x_t) - f_t(u_t)).$$

但若 u_t 可以任意变化，它每轮都能选取当轮最优点，通常不可能保证次线性动态遗憾。可证明结论需要额外限制，例如比较路径长度

$$P_T = \sum_{t=2}^T \|u_t - u_{t-1}\|$$

或损失序列的变化预算。动态遗憾与非平稳优化将在后续研究接口中处理；本书 OCO 主线默认静态比较器。

2.10 使用前检查

应用一个在线遗憾结论前，至少确认以下五点：

1. **时间顺序**： x_t 是否确实在当轮损失信息到达前决定？
2. **反馈**：算法需要整个 f_t 、一个次梯度，还是只需要函数值？
3. **环境**：结论对任意序列成立，还是只在随机/oblivious 环境下成立？
4. **比较器**：使用固定 u 、分段固定比较器，还是动态路径？
5. **结论类型**：是逐路径界、期望界，还是高概率界？

 典型误区

- $\text{Reg}_T = o(T)$ 不等于每轮损失差都趋于零。
- 静态遗憾小，不代表能跟踪快速变化的逐轮最优点。
- 对抗式损失可以很难，但仍必须遵守信息时序。
- $O(\sqrt{T})$ 是累计遗憾；对应平均遗憾为 $O(T^{-1/2})$ 。

下一章将用 Euclidean 投影和平方距离势函数构造 OGD，并由同一条一步不等式推出一般凸、强凸以及随机离线优化中的速率。

3 OGD、强凸遗憾与 online-to-batch

Online Gradient Descent (OGD) 只做两件事：沿当轮次梯度下降，再投影回可行域。它的全部分析建立在一个平方距离势函数上。本章先把这条母不等式证明清楚，再分别代入一般凸性、强凸性和随机梯度条件。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章以 Lecture 5 为主，并用 Lecture 3 的下降法分析补足步长选择。只保留 OGD 与 online-to-batch 的主证明链；高概率转换需要鞅集中工具，不由期望分析自动推出，留到集中不等式附录处理。

3.1 Online Gradient Descent

设 $\mathcal{X} \subseteq \mathbb{R}^d$ 非空、闭且凸。Euclidean 投影定义为

$$\Pi_{\mathcal{X}}(z) = \operatorname{argmin}_{x \in \mathcal{X}} \|x - z\|_2.$$

闭凸性保证投影存在且唯一。对任意 $u \in \mathcal{X}$ ，投影满足

$$\|\Pi_{\mathcal{X}}(z) - u\|_2^2 \leq \|z - u\|_2^2 - \|z - \Pi_{\mathcal{X}}(z)\|_2^2 \leq \|z - u\|_2^2. \quad (3.1)$$

这说明投影不会增大到任意可行比较点的距离。

给定步长 $\eta_t > 0$ 和当轮次梯度 $g_t \in \partial f_t(x_t)$ ，OGD 更新为

$$x_{t+1} = \Pi_{\mathcal{X}}(x_t - \eta_t g_t). \quad (3.2)$$

i OGD 算法模板

初始化 $x_1 \in \mathcal{X}$ 。第 t 轮先输出 x_t ，收到 $g_t \in \partial f_t(x_t)$ 后，再按式 3.2 更新。若 $\mathcal{X} = \mathbb{R}^d$ ，投影为恒等映射，OGD 就退化为普通次梯度下降。

3.2 母不等式：一步距离如何变化

取任意固定比较点 $u \in \mathcal{X}$ 。由 式 3.1,

$$\begin{aligned}\|x_{t+1} - u\|_2^2 &\leq \|x_t - \eta_t g_t - u\|_2^2 \\ &= \|x_t - u\|_2^2 - 2\eta_t \langle g_t, x_t - u \rangle + \eta_t^2 \|g_t\|_2^2.\end{aligned}\tag{3.3}$$

整理得

$$\langle g_t, x_t - u \rangle \leq \frac{\|x_t - u\|_2^2 - \|x_{t+1} - u\|_2^2}{2\eta_t} + \frac{\eta_t}{2} \|g_t\|_2^2.\tag{3.4}$$

再用凸性 式 2.4, 得到 OGD 的核心一步不等式:

$$f_t(x_t) - f_t(u) \leq \frac{\|x_t - u\|_2^2 - \|x_{t+1} - u\|_2^2}{2\eta_t} + \frac{\eta_t}{2} \|g_t\|_2^2.\tag{3.5}$$

它把单轮损失差拆成两部分:

- **势函数下降**: 比较距离的差分, 求和时可以望远镜消去;
- **移动代价**: $\eta_t \|g_t\|_2^2 / 2$, 步长越大, 单轮代价越高。

后面的速率差异主要来自两件事: 凸性还能提供多少负项, 以及如何选择 η_t 让两部分平衡。

3.3 一般凸损失: $O(\sqrt{T})$ 遗憾

假设每个 f_t 凸, 且沿算法轨迹取得的次梯度满足 $\|g_t\|_2 \leq G$ 。再假设可行域直径至多为 D :

$$\sup_{x, y \in \mathcal{X}} \|x - y\|_2 \leq D.$$

若步长正且不增, 即 $\eta_{t+1} \leq \eta_t$, 对 式 3.5 求和得到

$$\begin{aligned}\text{Reg}_T(u) &\leq \frac{1}{2} \sum_{t=1}^T \frac{\|x_t - u\|_2^2 - \|x_{t+1} - u\|_2^2}{\eta_t} + \frac{G^2}{2} \sum_{t=1}^T \eta_t \\ &\leq \frac{D^2}{2\eta_T} + \frac{G^2}{2} \sum_{t=1}^T \eta_t.\end{aligned}\tag{3.6}$$

第二个不等式不是直接望远镜, 因为分母随 t 变化。令 $a_t = \|x_t - u\|_2^2$, 则

$$\begin{aligned}\sum_{t=1}^T \frac{a_t - a_{t+1}}{\eta_t} &= \frac{a_1}{\eta_1} + \sum_{t=2}^T a_t \left(\frac{1}{\eta_t} - \frac{1}{\eta_{t-1}} \right) - \frac{a_{T+1}}{\eta_T} \\ &\leq D^2 \left[\frac{1}{\eta_1} + \sum_{t=2}^T \left(\frac{1}{\eta_t} - \frac{1}{\eta_{t-1}} \right) \right] = \frac{D^2}{\eta_T}.\end{aligned}$$

这里同时用到了 $a_t \leq D^2$ 、 $a_{T+1} \geq 0$ 和 $1/\eta_t$ 单调不减。

i 定理：未知时域的 OGD 遗憾界

在上述凸性、有界梯度和有界直径条件下，取

$$\eta_t = \frac{D}{G\sqrt{t}},$$

则对任意 $u \in \mathcal{X}$,

$$\text{Reg}_T(u) \leq \frac{3}{2} DG\sqrt{T}. \quad (3.7)$$

证明只需把步长代入 式 3.6，并使用

$$\sum_{t=1}^T \frac{1}{\sqrt{t}} \leq 2\sqrt{T}.$$

于是

$$\frac{D^2}{2\eta_T} + \frac{G^2}{2} \sum_{t=1}^T \eta_t \leq \frac{1}{2} DG\sqrt{T} + DG\sqrt{T}.$$

若预先知道 T ，使用常数步长

$$\eta = \frac{D}{G\sqrt{T}}$$

可以由

$$\text{Reg}_T(u) \leq \frac{D^2}{2\eta} + \frac{\eta G^2 T}{2}$$

得到更整齐的 $DG\sqrt{T}$ 。两者阶数相同；递减步长不需要预先知道终止轮数。

3.4 强凸损失：曲率产生对数遗憾

若 f_t 关于 ℓ_2 范数是 σ -强凸的，则对任意 $x, y \in \mathcal{X}$ 和 $g \in \partial f_t(x)$,

$$f_t(y) \geq f_t(x) + \langle g, y - x \rangle + \frac{\sigma}{2} \|y - x\|_2^2. \quad (3.8)$$

取 $x = x_t$ 、 $y = u$ 并移项，得到比普通凸性更强的上界：

$$f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle - \frac{\sigma}{2} \|x_t - u\|_2^2. \quad (3.9)$$

将式 3.4 代入，

$$\begin{aligned} f_t(x_t) - f_t(u) &\leq \frac{\eta_t^{-1} - \sigma}{2} \|x_t - u\|_2^2 \\ &\quad - \frac{\eta_t^{-1}}{2} \|x_{t+1} - u\|_2^2 + \frac{\eta_t}{2} \|g_t\|_2^2. \end{aligned} \quad (3.10)$$

取

$$\eta_t = \frac{1}{\sigma t}. \quad (3.11)$$

此时 $\eta_t^{-1} - \sigma = \sigma(t - 1) = \eta_{t-1}^{-1}$ 。对式 3.10 求和后，所有中间距离项精确抵消，只剩一个非正的末项。因此，在 $\|g_t\|_2 \leq G$ 下，

$$\begin{aligned} \text{Reg}_T(u) &\leq \frac{G^2}{2} \sum_{t=1}^T \eta_t \\ &= \frac{G^2}{2\sigma} \sum_{t=1}^T \frac{1}{t} \\ &\leq \frac{G^2}{2\sigma} (1 + \log T). \end{aligned} \quad (3.12)$$

! 条件变化

一般凸 OGD 用有限直径 D 控制势函数；强凸 OGD 依靠每轮额外的负二次项完成抵消，因此式 3.12 不再需要把域直径 D 放入结论。但仍需 $\mathcal{X}$ 闭凸、每轮损失具有统一强凸参数 σ ，并控制算法取得的次梯度范数。

3.5 上界与下界的量级

在对应的标准有界条件下，最坏情形量级为：

损失结构	OGD 上界	一般不可改进的下界	平均遗憾
凸、 G -Lipschitz、 域直径 D	$O(DG\sqrt{T})$	$\Omega(DG\sqrt{T})$	$O(T^{-1/2})$
σ -强凸、梯度有界	$O((G^2/\sigma) \log T)$	$\Omega((G^2/\sigma) \log T)$	$O((\log T)/T)$

这张表比较的是对抗式在线问题。它不能直接当作随机离线优化的下界：随机结构允许在强凸情形通过更合适的输出平均达到 $O(1/T)$ 。

3.6 Online-to-batch：把遗憾变成离线误差

考虑随机凸优化问题

$$\min_{x \in \mathcal{X}} F(x), \quad F(x) = \mathbb{E}_{\xi}[f(x; \xi)]. \quad (3.13)$$

设 $x^* \in \operatorname{argmin}_{x \in \mathcal{X}} F(x)$ 。第 t 轮，算法根据历史选择 x_t ，随机一阶 oracle 返回 g_t 。记 $\mathcal{F}_{t-1}$ 为产生 x_t 之前的历史信息，并假设

$$\mathbb{E}[g_t \mid \mathcal{F}_{t-1}] \in \partial F(x_t), \quad \mathbb{E}[\|g_t\|_2^2 \mid \mathcal{F}_{t-1}] \leq G^2. \quad (3.14)$$

条件无偏性很关键：因为 x_t 依赖过去的随机梯度，不能把 g_t 与 x_t 当作彼此独立。

构造线性在线损失

$$\ell_t(x) = \langle g_t, x \rangle, \quad (3.15)$$

并让任意在线算法 $\mathcal{A}$ 依次处理 $\ell_1, \dots, \ell_T$ 。最终输出均匀平均

$$\bar{x}_T = \frac{1}{T} \sum_{t=1}^T x_t. \quad (3.16)$$

i 定理：基本 online-to-batch 转换

若 F 凸且 式 3.14 的条件无偏性成立，则

$$\mathbb{E}[F(\bar{x}_T)] - F(x^*) \leq \frac{1}{T} \mathbb{E}[\text{Reg}_T^{\mathcal{A}}(x^*)], \quad (3.17)$$

其中右侧遗憾针对随机生成的线性损失 式 3.15。

证明链只有四步：

$$\begin{aligned} \mathbb{E}[F(\bar{x}_T)] - F(x^*) &\leq \frac{1}{T} \sum_{t=1}^T \mathbb{E}[F(x_t) - F(x^*)] \\ &\leq \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\langle \mathbb{E}[g_t \mid \mathcal{F}_{t-1}], x_t - x^* \rangle] \\ &= \frac{1}{T} \sum_{t=1}^T \mathbb{E}[\langle g_t, x_t - x^* \rangle] \\ &= \frac{1}{T} \mathbb{E} \left[\sum_{t=1}^T (\ell_t(x_t) - \ell_t(x^*)) \right]. \end{aligned} \quad (3.18)$$

第一步用 Jensen 不等式，第二步用凸性，第三步用条件期望，最后一步识别出在线遗憾。

! 自适应损失为什么不破坏证明

ℓ_t 由在 x_t 处查询得到的 g_t 构造，因此它依赖在线历史。这里需要在线算法的遗憾界对实际生成的损失序列成立；OGD 的确定性母不等式逐路径成立，恰好满足这一要求。随机性只在从线性损失差转换回 $F(x_t) - F(x^*)$ 时使用。

3.7 从 OGD 重新理解 SGD

把 OGD 用于线性损失 式 3.15，其次梯度就是 g_t ，更新变为

$$x_{t+1} = \Pi_{\mathcal{X}}(x_t - \eta_t g_t),$$

这正是投影随机梯度下降。若 $\mathcal{X}$ 直径至多为 D ，结合 OGD 的一般界与 式 3.17，可得

$$\mathbb{E}[F(\bar{x}_T)] - F(x^*) \leq \frac{3DG}{2\sqrt{T}} \quad (3.19)$$

对应步长为 $\eta_t = D/(G\sqrt{t})$ 。若只假设条件二阶矩有界，而不是 $\|g_t\| \leq G$ 几乎处处成立，则可直接对 式 3.5 取条件期望，得到同阶的期望结论；此时不能把中间的在线遗憾界误称为逐路径界。

online-to-batch 的价值不只是重新证明 SGD：任何可控制线性遗憾的在线算法，都能通过合适平均转化为随机凸优化算法。更换在线几何，就会得到非 Euclidean 的随机方法。

3.8 强凸情形：均匀平均为什么多一个 $\log T$

若 F 是 σ -强凸的，则

$$F(x_t) - F(x^*) \leq \langle \mathbb{E}[g_t \mid \mathcal{F}_{t-1}], x_t - x^* \rangle - \frac{\sigma}{2} \|x_t - x^*\|_2^2.$$

因此可构造强凸在线代理损失

$$\ell_t(x) = \langle g_t, x \rangle + \frac{\sigma}{2} \|x - x_t\|_2^2. \quad (3.20)$$

它在 x_t 处的梯度仍为 g_t 。把强凸 OGD 的 $O((G^2/\sigma) \log T)$ 遗憾除以 T ，均匀平均只能得到

$$\mathbb{E}[F(\bar{x}_T)] - F(x^*) = O\left(\frac{G^2 \log T}{\sigma T}\right). \quad (3.21)$$

这不是强凸随机优化的最优阶。多出的 $\log T$ 来自等权累计强凸在线遗憾，而不是强凸随机问题本身的统计困难。

3.9 加权转换：去掉多余的 $\log T$

取权重 $\alpha_t > 0$ ，记

$$A_t = \sum_{s=1}^t \alpha_s, \quad \bar{x}_T^{(\alpha)} = \frac{1}{A_T} \sum_{t=1}^T \alpha_t x_t. \quad (3.22)$$

使用代理损失

$$\ell_t^{(\alpha)}(x) = \alpha_t \langle g_t, x \rangle + \frac{\alpha_t \sigma}{2} \|x - x_t\|_2^2. \quad (3.23)$$

加权 Jensen 不等式和强凸性给出

$$\mathbb{E}[F(\bar{x}_T^{(\alpha)})] - F(x^*) \leq \frac{1}{A_T} \mathbb{E}[\text{Reg}_T^{\mathcal{A}}(x^*)]. \quad (3.24)$$

对 式 3.23 运行 OGD。它的强凸参数为 $\alpha_t \sigma$ ，在当前点的梯度为 $\alpha_t g_t$ 。取

$$\eta_t = \frac{1}{\sigma A_t}, \quad (3.25)$$

则一步界中的距离系数满足

$$\eta_t^{-1} - \alpha_t \sigma = \sigma A_{t-1} = \eta_{t-1}^{-1},$$

从而再次望远镜消去。若条件二阶矩由 G^2 控制，取期望后得到

$$\mathbb{E}[\text{Reg}_T^{\mathcal{A}}(x^*)] \leq \frac{G^2}{2\sigma} \sum_{t=1}^T \frac{\alpha_t^2}{A_t}. \quad (3.26)$$

选择线性权重 $\alpha_t = t$ ，则 $A_t = t(t+1)/2$ ，且

$$\frac{\alpha_t^2}{A_t} = \frac{2t}{t+1} \leq 2.$$

代入 式 3.24 与 式 3.26，得到

$$\mathbb{E}[F(\bar{x}_T^{(\alpha)})] - F(x^*) \leq \frac{2G^2}{\sigma(T+1)}. \quad (3.27)$$

此时 OGD 的实际更新为

$$x_{t+1} = \Pi_{\mathcal{X}} \left(x_t - \frac{\alpha_t}{\sigma A_t} g_t \right) = \Pi_{\mathcal{X}} \left(x_t - \frac{2}{\sigma(t+1)} g_t \right).$$

因此， $O(1/T)$ 并不是换了一个完全不同的算法，而是让在线代理损失的权重、步长和最终输出平均彼此匹配。

3.10 期望界与高概率界的边界

式 3.17 与 式 3.27 都是期望界。要得到概率至少为 $1 - \delta$ 的结论，需要控制鞅差

$$\sum_{t=1}^T \langle g_t - \mathbb{E}[g_t \mid \mathcal{F}_{t-1}], x_t - x^* \rangle,$$

并补充几乎处处有界、条件方差或次高斯等尾部条件。仅有二阶矩有界不足以直接套用 Hoeffding 型界。相关集中工具见附录 附录 A；本章不提前展开 Freedman/Bernstein 证明。

3.11 方法选择

目标与信息	更新/输出	典型结论
对抗式一般凸 OCO	OGD, $\eta_t \asymp t^{-1/2}$	$\text{Reg}_T = O(\sqrt{T})$
对抗式 σ -强凸 OCO	OGD, $\eta_t = 1/(\sigma t)$	$\text{Reg}_T = O(\log T)$
随机一般凸优化	投影 SGD + 均匀平均	$\mathbb{E}[F(\bar{x}_T)] - F(x^*) = O(T^{-1/2})$
随机 σ -强凸优化	递减步长 + 线性加权平均	$\mathbb{E}[F(\bar{x}_T)] - F(x^*) = O(T^{-1})$

⚠ 典型误用

- 使用 $\eta_t = D/(G\sqrt{t})$ 前没有确认有限直径 D 与梯度界 G 。
- 把 $\mathbb{E}[g_t \mid \mathcal{F}_{t-1}]$ 简写成 $\mathbb{E}[g_t]$ ，忽略 x_t 对历史的依赖。
- 从 $O(\log T)$ 的强凸在线遗憾直接断言随机优化只能达到 $O((\log T)/T)$ 。
- 证明在线遗憾时对随机梯度先取期望，却把结果写成对每条样本路径成立。
- 只改变 SGD 步长，却忘记强凸 $O(1/T)$ 结论还依赖匹配的加权输出。
- 把期望界直接改写成高概率界，而没有控制相应鞅差。

3.12 本章主线

本章只需要反复记住三条结构：

1. 投影展开产生 式 3.5；
2. 额外曲率提供负距离项，使 $\eta_t \asymp 1/t$ 时精确抵消；
3. **online-to-batch** 用平均与条件无偏性，把在线遗憾除以累计权重，转成离线随机优化误差。

下一章将把平方 Euclidean 势函数替换为熵势函数，进入单纯形上的 Hedge 与乘法权重方法。

4 专家建议、Hedge 与二阶曲率

当决策是“如何组合 N 个专家”时，可行域是概率单纯形。直接使用 Euclidean OGD 会引入不理想的维数因子；指数权重则自然产生 $\sqrt{\log N}$ 。本章先完整分析 Hedge，再说明局部二阶曲率如何导出 Online Newton Step (ONS)。

材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 6。Hedge 的 log-sum-exp 势函数证明完整保留；ONS 只保留 exp-concavity 二次下界、矩阵更新和椭圆势函数主链，不展开行列式代数的每个中间步骤。

4.1 专家建议协议

有 N 个专家。第 t 轮：

1. 学习器选择权重 $p_t \in \Delta_N$ ；
2. 环境给出损失向量 $\ell_t \in [0, 1]^N$ ；
3. 学习器损失为 $\langle p_t, \ell_t \rangle$ 。

其中

$$\Delta_N = \left\{ p \in \mathbb{R}_+^N : \sum_{i=1}^N p_i = 1 \right\}.$$

相对于最佳单个专家的遗憾为

$$\text{Reg}_T = \sum_{t=1}^T \langle p_t, \ell_t \rangle - \min_{i \in [N]} \sum_{t=1}^T \ell_{t,i}. \quad (4.1)$$

选择“目前累计损失最小的专家”的 Follow the Leader 可能在交替损失下每轮追错方向，产生 $\Theta(T)$ 遗憾。Hedge 用 softmin 代替硬最小化，使历史领先程度平滑地转化为权重。

4.2 Hedge: 指数权重更新

记

$$L_{t,i} = \sum_{s=1}^t \ell_{s,i}, \quad L_{0,i} = 0.$$

固定学习率 $\eta > 0$ 时, Hedge 取

$$p_{t,i} = \frac{\exp(-\eta L_{t-1,i})}{\sum_{j=1}^N \exp(-\eta L_{t-1,j})}. \quad (4.2)$$

等价的乘法更新为

$$p_{t+1,i} \propto p_{t,i} \exp(-\eta \ell_{t,i}).$$

固定 η 时两式相同; 当学习率随时间变化时, “对累计损失重新计算”的 lazy update 与 “在旧权重上乘一次”的 greedy update 不再自动等价, 必须明确算法版本。

4.3 Log-sum-exp 势函数证明

令未归一化总权重

$$W_t = \sum_{i=1}^N \exp(-\eta L_{t,i}).$$

一方面, 对任意专家 i ,

$$\log W_T \geq -\eta L_{T,i}. \quad (4.3)$$

另一方面, 由 $e^{-\eta x} \leq 1 - \eta x + \eta^2 x^2$ ($x \in [0, 1]$, 取适当的小学习率) 以及 $\log(1 + z) \leq z$,

$$\begin{aligned} \log \frac{W_t}{W_{t-1}} &= \log \sum_{i=1}^N p_{t,i} e^{-\eta \ell_{t,i}} \\ &\leq -\eta \langle p_t, \ell_t \rangle + \eta^2 \sum_{i=1}^N p_{t,i} \ell_{t,i}^2. \end{aligned} \quad (4.4)$$

对 t 求和, 并用 $W_0 = N$ 与 式 4.3, 得到对任意 i ,

$$\sum_{t=1}^T \langle p_t, \ell_t \rangle - L_{T,i} \leq \frac{\log N}{\eta} + \eta \sum_{t=1}^T \sum_{j=1}^N p_{t,j} \ell_{t,j}^2. \quad (4.5)$$

由于 $0 \leq \ell_{t,i} \leq 1$, 二阶项至多为 T , 于是

$$\text{Reg}_T \leq \frac{\log N}{\eta} + \eta T. \quad (4.6)$$

取

$$\eta = \sqrt{\frac{\log N}{T}},$$

便有

$$\text{Reg}_T \leq 2\sqrt{T \log N}. \quad (4.7)$$

这里的 $\log N$ 来自初始总权重与最佳专家单个权重之间的势函数差, 而不是把 N 维坐标逐一求和得到。

4.4 维数依赖与下界

对任意专家算法, 都存在 $[0, 1]^N$ 中的损失序列使

$$\text{Reg}_T = \Omega(\sqrt{T \log N}).$$

因此 Hedge 在最坏情形下达到最优阶。若实际损失很小, 式 4.5 中的二阶项可能远小于 T ; 第 6 章会利用这一点得到 small-loss 界。

4.5 Exp-concavity: 弱于强凸但强于普通凸

若 $x \mapsto e^{-\alpha f(x)}$ 在 $\mathcal{X}$ 上凹, 则称 f 为 α -exp-concave。典型例子包括适当定义域上的对数损失和投资组合的负对数收益。

设 $\|\nabla f(x)\|_2 \leq G$, $\mathcal{X}$ 直径至多为 D 。对

$$\gamma \leq \frac{1}{2} \min \left\{ \frac{1}{GD}, \alpha \right\},$$

exp-concavity 蕴含局部二次下界

$$f(x) \geq f(y) + \langle \nabla f(y), x - y \rangle + \frac{\gamma}{2} \langle \nabla f(y), x - y \rangle^2. \quad (4.8)$$

与强凸性的 $\|x - y\|_2^2$ 不同, 这里的曲率只沿当前梯度方向出现:

$$\langle \nabla f(y), x - y \rangle^2 = (x - y)^\top \nabla f(y) \nabla f(y)^\top (x - y).$$

因此合适的几何应累计历史梯度外积, 而不是始终使用单位矩阵。

4.6 Online Newton Step

令

$$A_0 = \varepsilon I, \quad A_t = A_{t-1} + g_t g_t^\top, \quad g_t = \nabla f_t(x_t). \quad (4.9)$$

ONS 更新为

$$x_{t+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\| x - \left(x_t - \frac{1}{\gamma} A_t^{-1} g_t \right) \right\|_{A_t}^2, \quad (4.10)$$

其中 $\|z\|_A^2 = z^\top A z$ 。它可以理解为在累计二阶几何 A_t 下做一次预条件梯度步。

对 式 4.10 做加权投影展开, 再用 式 4.8, 可得

$$\operatorname{Reg}_T(u) \leq \frac{\gamma}{2} \|x_1 - u\|_{A_0}^2 + \frac{1}{2\gamma} \sum_{t=1}^T \|g_t\|_{A_t^{-1}}^2. \quad (4.11)$$

关键的椭圆势函数引理为

$$\sum_{t=1}^T \|g_t\|_{A_t^{-1}}^2 \leq \log \frac{\det A_T}{\det A_0} \leq d \log \left(1 + \frac{G^2 T}{\varepsilon d} \right). \quad (4.12)$$

适当选择 ε 后, 得到

$$\text{Reg}_T = O\left(d \left(\frac{1}{\alpha} + GD \right) \log T\right). \quad (4.13)$$

ONS 不要求损失强凸, 却借助 exp-concavity 达到对数遗憾; 代价是显式的维数 d 、矩阵存储与求逆/递推更新。

4.7 何时值得使用二阶几何

方法	利用的结构	遗憾阶	每轮主要代价
OGD	普通凸性	$O(\sqrt{T})$	向量更新与投影
强凸 OGD	全方向强曲率	$O(\log T)$	向量更新与投影
ONS	梯度方向的 exp-concave 曲率	$O(d \log T)$	维护 $d \times d$ 矩阵
Hedge	单纯形 + 负熵几何	$O(\sqrt{T \log N})$	N 个权重

⚠ 典型误区

- 把 exp-concavity 当成强凸性; 前者的二次项依赖梯度方向。
- 在可变学习率下混用 lazy 与 greedy Hedge 更新。
- 只看到 ONS 的 $\log T$, 忽略其 d 依赖和矩阵计算代价。
- 用 Euclidean 直径分析单纯形, 得到 $\sqrt{N}$ 后误以为这是专家问题的固有维数代价。

下一章将用 Bregman 散度统一解释: OGD、Hedge 与 ONS 其实是在不同几何下运行的同一类近端更新。

5 镜像下降与 FTRL

OGD 默认用 Euclidean 距离衡量移动代价，但“距离近”应由问题结构决定：概率分布适合 KL 散度，椭圆域适合 Mahalanobis 范数。Online Mirror Descent (OMD) 用一个强凸正则函数把几何写进更新和证明。

材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 7。只完整建立 Bregman 三点结构与 OMD 主不等式，再把 OGD、Hedge、ONS、FTRL 和 dual averaging 放入同一坐标系；不并列重复前两章已经完成的具体遗憾证明。

5.1 为什么 Euclidean 几何会失配

在专家问题中， $p \in \Delta_N$ 是概率分布。若用 ℓ_2 几何分析线性损失，梯度 $\ell_t \in [0, 1]^N$ 的范数可达 $\sqrt{N}$ ，从而得到 $O(\sqrt{NT})$ ；Hedge 却能达到 $O(\sqrt{T \log N})$ 。

差距不来自更精巧的常数，而来自几何：单纯形上自然的距离是 KL 散度，配套范数是 ℓ_1/ℓ_∞ ，此时 $\|\ell_t\|_\infty \leq 1$ 与维数无关。

5.2 强凸正则与对偶范数

给定范数 $\|\cdot\|$ ，其对偶范数为

$$\|g\|_* = \sup_{\|x\| \leq 1} \langle g, x \rangle.$$

Hölder 不等式写成

$$\langle g, x \rangle \leq \|g\|_* \|x\|.$$

若可微函数 ψ 满足

$$\psi(x) \geq \psi(y) + \langle \nabla \psi(y), x - y \rangle + \frac{\lambda}{2} \|x - y\|^2, \quad (5.1)$$

则称 ψ 关于 $\|\cdot\|$ 为 λ -强凸。这里的范数必须写出；同一 ψ 对不同范数的强凸参数可以完全不同。

5.3 Bregman 散度

ψ 诱导的 Bregman 散度定义为

$$D_\psi(x, y) = \psi(x) - \psi(y) - \langle \nabla \psi(y), x - y \rangle. \quad (5.2)$$

它衡量函数值与在 y 处线性近似之间的差。若 ψ 关于 $\|\cdot\|$ 是 λ -强凸的，则

$$D_\psi(x, y) \geq \frac{\lambda}{2} \|x - y\|^2.$$

Bregman 散度通常不对称，也不满足三角不等式，因此不是度量。真正用于证明的是三点恒等式

$$\langle \nabla \psi(x) - \nabla \psi(y), z - x \rangle = D_\psi(z, y) - D_\psi(z, x) - D_\psi(x, y). \quad (5.3)$$

5.4 Online Mirror Descent

第 t 轮取得 $g_t \in \partial f_t(x_t)$ 后，OMD 更新为

$$x_{t+1} = \operatorname{argmin}_{x \in \mathcal{X}} \{ \eta_t \langle g_t, x \rangle + D_\psi(x, x_t) \}. \quad (5.4)$$

第一项推动损失下降，第二项惩罚在 ψ 几何下移动过远。若 ψ 是 Legendre 型正则或对子问题施加合适条件，更新存在且位于可行域内。

5.4.1 Bregman 近端不等式

更一般地, 若

$$x^+ = \operatorname{argmin}_{x \in \mathcal{X}} \{\langle g, x \rangle + D_\psi(x, y)\},$$

则对任意 $u \in \mathcal{X}$, 一阶最优性与 式 5.3 给出

$$\langle g, x^+ - u \rangle \leq D_\psi(u, y) - D_\psi(u, x^+) - D_\psi(x^+, y). \quad (5.5)$$

这是 Euclidean 投影勾股不等式在一般几何中的替代品。

5.5 OMD 主不等式

由凸性,

$$f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle.$$

把右侧拆成

$$\langle g_t, x_t - x_{t+1} \rangle + \langle g_t, x_{t+1} - u \rangle,$$

第二项使用 式 5.5, 得到

$$\begin{aligned} f_t(x_t) - f_t(u) &\leq \frac{D_\psi(u, x_t) - D_\psi(u, x_{t+1})}{\eta_t} \\ &\quad + \langle g_t, x_t - x_{t+1} \rangle - \frac{1}{\eta_t} D_\psi(x_{t+1}, x_t). \end{aligned} \quad (5.6)$$

由强凸性和 Young 不等式, 后两项满足

$$\langle g_t, x_t - x_{t+1} \rangle - \frac{1}{\eta_t} D_\psi(x_{t+1}, x_t) \leq \frac{\eta_t}{2\lambda} \|g_t\|_*^2.$$

于是

$$f_t(x_t) - f_t(u) \leq \frac{D_\psi(u, x_t) - D_\psi(u, x_{t+1})}{\eta_t} + \frac{\eta_t}{2\lambda} \|g_t\|_*^2. \quad (5.7)$$

固定步长 η 时求和即得

$$\text{Reg}_T(u) \leq \frac{D_\psi(u, x_1)}{\eta} + \frac{\eta}{2\lambda} \sum_{t=1}^T \|g_t\|_*^2. \quad (5.8)$$

若 $D_\psi(u, x_1) \leq B$ 且 $\|g_t\|_* \leq G$, 平衡两项得到

$$\text{Reg}_T(u) \leq G \sqrt{\frac{2BT}{\lambda}}.$$

因此选择几何的目标很明确: 让 Bregman 半径 B 与对偶梯度界 G 的乘积尽可能小, 同时保证更新可计算。

5.6 三种核心几何

正则函数 $\psi(x)$	Bregman 散度	原/对偶范数	典型算法
$\frac{1}{2}\ x\ _2^2$	$\frac{1}{2}\ x - y\ _2^2$	ℓ_2/ℓ_2	OGD
$\sum_i x_i \log x_i$ (单纯形)	$\text{KL}(x\ y)$	ℓ_1/ℓ_∞	Hedge
$\frac{1}{2}\ x\ _A^2, A \succ 0$	$\frac{1}{2}\ x - y\ _A^2$	A/A^{-1}	ONS、预条件方法

5.6.1 负熵恢复 Hedge

取 $\psi(p) = \sum_i p_i \log p_i$, 它在单纯形上关于 ℓ_1 范数为 1-强凸。以均匀分布 p_1 初始化, 对任意顶点 e_i ,

$$D_\psi(e_i, p_1) = \log N.$$

同时 $\|e_t\|_\infty \leq 1$ 。代入 式 5.8 即恢复 $O(\sqrt{T \log N})$, 而 式 5.4 的闭式解正是指数权重更新。

5.7 Mirror map 与 primal-dual 视角

在无约束、内点更新下, 对 式 5.4 写一阶条件:

$$\nabla \psi(x_{t+1}) = \nabla \psi(x_t) - \eta_t g_t. \quad (5.9)$$

令对偶变量 $y_t = \nabla \psi(x_t)$, 则

$$y_{t+1} = y_t - \eta_t g_t, \quad x_{t+1} = \nabla \psi^*(y_{t+1}), \quad (5.10)$$

其中 ψ^* 是 Fenchel 共轭。梯度自然位于对偶空间：先在对偶空间做线性更新，再经 $\nabla\psi^*$ 映回原空间，这就是“镜像”的含义。

若有约束，可将过程理解为先得到未约束镜像点，再做 Bregman 投影。边界处梯度可能发散并不一定是缺陷；对负熵和障碍函数，它正好阻止迭代离开定义域。

5.8 Follow-the-Regularized Leader

线性化损失 $\ell_t(x) = \langle g_t, x \rangle$ 后，FTRL 更新为

$$x_{t+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \sum_{s=1}^t \langle g_s, x \rangle + \frac{1}{\eta} \psi(x) \right\}. \quad (5.11)$$

它在每轮重新优化“所有历史线性损失 + 正则项”。因为历史只通过累计梯度 $G_t = \sum_{s=1}^t g_s$ 出现，实现时不需要保存全部样本。

FTRL 的遗憾可分为

$$\operatorname{Reg}_T(u) \leq \underbrace{\frac{\psi(u) - \min_{x \in \mathcal{X}} \psi(x)}{\eta}}_{\text{正则范围}} + \underbrace{\sum_{t=1}^T \langle g_t, x_t - x_{t+1} \rangle}_{\text{稳定性}}. \quad (5.12)$$

若 ψ 关于 $\|\cdot\|$ 为 λ -强凸，则更新映射稳定，

$$\langle g_t, x_t - x_{t+1} \rangle \leq \frac{\eta}{2\lambda} \|g_t\|_*^2,$$

从而得到与式 5.8 同型的界。

5.9 Dual averaging 与等价边界

Dual averaging 维护累计对偶梯度，再通过正则映射输出：

$$x_{t+1} = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \left\langle \sum_{s=1}^t g_s, x \right\rangle + \frac{1}{\eta_t} \psi(x) \right\}.$$

它在形式上就是使用时间变化正则强度的 FTRL。

在线性损失、固定学习率、相同 Legendre 正则和匹配初始化下，OMD 与 FTRL 可以产生相同迭代：

$$x_t = \operatorname{argmin}_{x \in \mathcal{X}} \left\{ \eta \left\langle \sum_{s=1}^{t-1} g_s, x \right\rangle + \psi(x) \right\}.$$

但二者不是无条件等价：非线性损失、约束边界、时变学习率或时变正则都会让动力学分离。OMD 以当前点为中心做局部移动；FTRL 重新平衡全部累计线性损失。

5.10 使用检查

1. 正则函数相对于哪一个原范数强凸？
2. 梯度界应使用哪个对偶范数？
3. $D_\psi(u, x_1)$ 是否有限，初始化是否位于正确的内点？
4. 镜像/近端子问题是否有闭式解或可高效求解？
5. 讨论 OMD 与 FTRL 等价时，是否固定了损失线性化、学习率和初始化？

下一章保留 式 5.6 中常被丢掉的稳定性负项，并加入对下一轮梯度的预测，从而得到 small-loss、variance 和 variation 依赖的自适应遗憾。

6 自适应与乐观在线优化

最坏情形界回答“环境最难时会多差”，却不能区分一个平稳、低损失序列与真正对抗的序列。本章研究第二层目标：在不牺牲最坏情形保证的前提下，让遗憾自动缩放到数据实际呈现的小损失、低方差或低变化。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 8–9。small-loss、self-confident tuning、Optimistic OMD、gradient variance 与 gradient variation 均为主线；AdaGrad、coin-betting 和完整 parameter-free 理论只保留接口。

6.1 从 minimax 到 problem-dependent

普通 OMD 给出

$$\text{Reg}_T(u) \lesssim \frac{B}{\eta} + \eta \sum_{t=1}^T \|g_t\|_*^2.$$

若直接用 $\|g_t\|_* \leq G$ ，便得到 $O(G\sqrt{BT})$ 。这一步把实际序列压缩成最坏上界 G^2T ，丢掉了所有“容易性”。自适应分析的核心是保留更细的二阶量，并让学习率由已经观察到的量调节。

一个合格的 problem-dependent 界通常同时满足：

- **自适应性**：容易序列上明显小于 $\sqrt{T}$ ；
- **鲁棒性**：最坏情况下退化回 minimax 阶，而不是变成线性遗憾；
- **可实现性**：调参只依赖当前和过去信息，不能偷看 T 、最佳专家损失或未来变化量。

6.2 专家问题中的 small-loss

对 $\ell_{t,i} \in [0, 1]$ ，记最佳专家累计损失

$$L_T^* = \min_{i \in [N]} \sum_{t=1}^T \ell_{t,i}.$$

Hedge 的精细势函数界 式 4.5 保留了

$$\sum_{t=1}^T \sum_{i=1}^N p_{t,i} \ell_{t,i}^2.$$

由于 $\ell_{t,i}^2 \leq \ell_{t,i}$, 该项至多为学习器累计损失 $L_T = L_T^* + \text{Reg}_T$ 。代回并解这个自指不等式, 可得到

$$\text{Reg}_T = O\left(\sqrt{(L_T^* + 1) \log N} + \log N\right). \quad (6.1)$$

若最佳专家几乎不犯错, 遗憾只随 L_T^* 增长; 最坏情况下 $L_T^* \leq T$, 又恢复 $O(\sqrt{T \log N})$ 。

6.3 Self-confident 学习率

若直接把最优学习率写成 $\eta^* \asymp \sqrt{\log N / L_T^*}$, 算法会非法依赖未来。self-confident tuning 用学习器已经发生的累计损失估计尺度, 例如

$$\eta_t \asymp \min \left\{ 1, \sqrt{\frac{\log N}{1 + L_{t-1}}} \right\}, \quad L_{t-1} = \sum_{s=1}^{t-1} \langle p_s, \ell_s \rangle. \quad (6.2)$$

分析依赖一类自归一化求和: 对 $a_t \geq 0$,

$$\sum_{t=1}^T \frac{a_t}{\sqrt{1 + \sum_{s=1}^t a_s}} \leq 2 \sqrt{1 + \sum_{t=1}^T a_t}. \quad (6.3)$$

它把“事后最优固定学习率”改造成合法的逐轮学习率。实践中还要明确采用哪一种时变 Hedge 更新, 因为 lazy 与 greedy 形式此时不再等价。

6.4 一般 OCO 的 self-bounding

small-loss 不只属于专家问题。若 $f: \mathbb{R}^d \rightarrow \mathbb{R}_+$ 是非负且 L -光滑的, 则

$$\|\nabla f(x)\|_2^2 \leq 2L f(x). \quad (6.4)$$

证明只需在下降引理中取 $y = x - \nabla f(x)/L$, 再用 $f(y) \geq 0$ 。它把梯度二阶量转成函数值, 因此称为 self-bounding。

在有界凸域上, 令

$$G_t = \sum_{s=1}^t \|\nabla f_s(x_s)\|_2^2, \quad \eta_t \asymp \frac{1}{\sqrt{1+G_t}},$$

把式 6.4 代入 OGD 的二阶界并处理自指项, 可得

$$\text{Reg}_T(u) = O\left(\sqrt{1 + \sum_{t=1}^T f_t(u)}\right), \quad (6.5)$$

其中大 O 隐藏域直径、光滑常数和低阶常数项。非负性不能静默删掉; 若损失可平移, 需要把界写成相对某个已知下界的形式。

6.5 Optimistic Online Mirror Descent

small-loss 利用结果值小; optimism 利用下一轮梯度可以预测。设 M_t 是在观察 g_t 前构造的预测向量, Optimistic OMD 维护辅助点 $\hat{x}_t$:

$$x_t = \operatorname{argmin}_{x \in \mathcal{X}} \{\eta_t \langle M_t, x \rangle + D_\psi(x, \hat{x}_t)\}, \quad (6.6)$$

$$\hat{x}_{t+1} = \operatorname{argmin}_{x \in \mathcal{X}} \{\eta_t \langle g_t, x \rangle + D_\psi(x, \hat{x}_t)\}. \quad (6.7)$$

第一步用预测 M_t 产生真正提交的决策 x_t ; 第二步看到实际梯度后校正基准点。若 $M_t = 0$, 退化为普通 OMD; 若 $M_t = g_t$, 预测完全准确, 理想情况下每轮只付常数级稳定代价。

6.6 预测误差主不等式

若 ψ 关于 $\|\cdot\|$ 为 1-强凸, 则对任意 $u \in \mathcal{X}$, Optimistic OMD 满足

$$\begin{aligned} \text{Reg}_T(u) &\leq \sum_{t=1}^T \eta_t \|g_t - M_t\|_*^2 \\ &\quad + \sum_{t=1}^T \frac{1}{\eta_t} [D_\psi(u, \hat{x}_t) - D_\psi(u, \hat{x}_{t+1})] \\ &\quad - \sum_{t=1}^T \frac{1}{\eta_t} [D_\psi(\hat{x}_{t+1}, x_t) + D_\psi(x_t, \hat{x}_t)]. \end{aligned} \quad (6.8)$$

三部分分别是:

- 预测误差 $\|g_t - M_t\|_*^2$;
- 可望远镜求和的比较器势能;
- 由两次近端更新产生的非正稳定项。

最坏情形分析常丢掉第三项; problem-dependent 分析中, 它往往恰好抵消由光滑性带来的决策移动量。

在 Euclidean 几何、域直径 D 下, 取自适应学习率

$$\eta_t \asymp \frac{D}{\sqrt{1 + \sum_{s=1}^{t-1} \|g_s - M_s\|_2^2}},$$

可得到

$$\text{Reg}_T(u) = O\left(D\sqrt{1 + \sum_{t=1}^T \|g_t - M_t\|_2^2}\right), \quad (6.9)$$

同时保留 $O(DG\sqrt{T})$ 的最坏情形保证。

6.7 三种 optimism 设计

Optimistic OMD 本身只说明“预测准则越准, 遗憾越小”。真正的算法设计问题是如何选择合法的 M_t 。

6.7.1 小损失

取 $M_t = 0$ 。若损失非负且光滑, 式 6.4 将

$$\sum_t \|g_t - M_t\|^2 = \sum_t \|g_t\|^2$$

连接到累计损失, 恢复 式 6.5。

6.7.2 梯度方差

对一条决策序列，令梯度均值

$$\mu_T = \frac{1}{T} \sum_{t=1}^T \nabla f_t(x_t),$$

并定义梯度方差尺度

$$\text{Var}_T = \sup_{x_1, \dots, x_T \in \mathcal{X}} \sum_{t=1}^T \|\nabla f_t(x_t) - \mu_T\|_2^2. \quad (6.10)$$

使用过去梯度的运行均值作为 M_t ，配合 self-confident 学习率，可得

$$\text{Reg}_T = \tilde{O}(\sqrt{1 + \text{Var}_T}). \quad (6.11)$$

若梯度围绕稳定均值波动，方差远小于 $G^2 T$ ；对抗序列上它仍至多退化到最坏阶。

6.7.3 梯度变化

定义

$$V_T = \sum_{t=2}^T \sup_{x \in \mathcal{X}} \|\nabla f_t(x) - \nabla f_{t-1}(x)\|_2^2. \quad (6.12)$$

取上一轮梯度

$$M_t = \nabla f_{t-1}(x_{t-1}),$$

则预测误差同时包含函数随时间的漂移和决策点移动。若各 f_t 为 L -光滑函数，后者可由 式 6.8 的稳定负项抵消，最终得到

$$\text{Reg}_T = O(\sqrt{1 + V_T}), \quad (6.13)$$

其中常数依赖 D, L, G 。缓慢变化时 $V_T \ll G^2 T$ ；最坏情况下 $V_T = O(G^2 T)$ ，仍恢复 $O(\sqrt{T})$ 。

6.8 随机——对抗连续视角

随机环境与对抗环境不必视为完全分离的两端。若 f_t 来自随时间变化的分布 $\mathcal{D}_t$ ，可把梯度不可预测性分解为：

- 分布内部的随机方差；
- 均值梯度随 t 的漂移；
- 算法移动造成的梯度变化。

variance 型 optimism 适合均值稳定但样本有噪声的环境；variation 型 optimism 适合损失缓慢漂移的环境；最坏情形界负责兜底。这一视角是后续 SEA、自适应 Bandit 和非平稳学习的共同入口。

6.9 与 AdaGrad 和 parameter-free 方法的接口

AdaGrad 同样根据累计梯度二阶量调节步长，但它主要适应坐标/方向尺度；Optimistic OMD 适应的是预测误差。两者可以结合，但需重新检查正则变化产生的额外项。

parameter-free 方法进一步尝试去除 D 、 G 、 T 等先验。它们不是简单把学习率设为“自动”，而是通过多学习率聚合、coin-betting 势函数或动态尺度估计保证与事后最佳参数竞争。本书主线只保留这一接口。

6.10 使用检查

1. 容易性量 L_T^* 、 Var_T 或 V_T 是否由合法历史信息估计？
2. 自适应界是否仍保留 minimax 最坏情形保证？
3. small-loss 是否真的具备非负与光滑条件？
4. M_t 是否在观察 g_t 前产生？
5. 推导是否保留并正确使用了 OMD 的稳定负项？

下一章将把 variation 型在线遗憾与稳定 online-to-batch 组合起来，解释 optimism 如何重新导出光滑离线优化的 $O(1/T^2)$ 加速率。

7 从在线遗憾到离线加速

普通 online-to-batch 把 $O(\sqrt{T})$ 遗憾除以 T , 得到 $O(T^{-1/2})$ 。若在线算法能利用光滑目标产生的梯度可预测性, 并让累计权重增长到 $\Theta(T^2)$, 同一转换可以得到 $O(T^{-2})$ 。关键不是机械加权, 而是稳定转换、optimism 和负稳定项三者匹配。

材料来源与边界

Lecture 编号沿用原材料标记, 课程与作者待补; 映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 9, 并与 Lecture 4 的 Nesterov 加速结果对照。完整保留 stabilized online-to-batch 的恒等式和 optimism 设计; Hölder 光滑下的 universal 方法只留研究接口。

7.1 普通转换的上限

对凸函数 F , 第 3 章的基本转换给出

$$F\left(\frac{1}{T} \sum_{t=1}^T x_t\right) - F(x^*) \leq \frac{\text{Reg}_T(x^*)}{T}.$$

若在线算法只有 $O(\sqrt{T})$ 最坏情形遗憾, 离线速率就是 $O(T^{-1/2})$ 。即使 F 光滑, 重复使用同一个静态在线损失构造也不会自动产生 $O(T^{-2})$; 必须让在线损失序列显露“相邻梯度越来越接近”的结构。

variation 型遗憾提供了入口, 但普通均匀平均会让查询点变化不够稳定, 无法充分利用 OMD 中的负项。

7.2 稳定加权平均

取权重 $\alpha_t > 0$, 记

$$A_t = \sum_{s=1}^t \alpha_s, \quad \bar{x}_t = \frac{1}{A_t} \sum_{s=1}^t \alpha_s x_s. \quad (7.1)$$

它满足递推恒等式

$$A_t \bar{x}_t = A_{t-1} \bar{x}_{t-1} + \alpha_t x_t,$$

从而

$$\alpha_t (\bar{x}_t - x_t) = A_{t-1} (\bar{x}_{t-1} - \bar{x}_t). \quad (7.2)$$

这条恒等式把当前在线点与平均点的差，转成相邻平均点之间的移动；后者会在凸性求和中望远镜消去。

定义线性在线损失

$$\ell_t(x) = \alpha_t \langle \nabla F(\bar{x}_t), x \rangle. \quad (7.3)$$

i 定理: stabilized online-to-batch

若 F 凸, $x_t \in \mathcal{X}$, 并由 式 7.1 产生 $\bar{x}_t$, 则

$$F(\bar{x}_T) - F(x^*) \leq \frac{1}{A_T} \sum_{t=1}^T (\ell_t(x_t) - \ell_t(x^*)) = \frac{\text{Reg}_T(x^*)}{A_T}. \quad (7.4)$$

证明的关键不是只用一次 Jensen, 而是利用 式 7.2:

$$\begin{aligned} \alpha_t \langle \nabla F(\bar{x}_t), \bar{x}_t - x_t \rangle &= A_{t-1} \langle \nabla F(\bar{x}_t), \bar{x}_{t-1} - \bar{x}_t \rangle \\ &\leq A_{t-1} (F(\bar{x}_{t-1}) - F(\bar{x}_t)). \end{aligned}$$

与 $\alpha_t (F(\bar{x}_t) - F(x^*))$ 求和后, 函数值项精确望远镜, 留下 式 7.4。

7.3 为什么要取 $\alpha_t = t$

若 $\alpha_t = t$, 则

$$A_T = \frac{T(T+1)}{2} = \Theta(T^2).$$

因此只要能让加权在线遗憾保持 $O(1)$, 除以 A_T 后就得到 $O(T^{-2})$ 。但加权损失的梯度为

$$\nabla \ell_t(x) = \alpha_t \nabla F(\bar{x}_t),$$

其幅度随 t 增大。普通 OGD 会因此付出快速增长的二阶项；必须用 optimism 预测这个大梯度。

7.4 Optimism 设计

在选择 x_t 前, 真正的平均点 $\bar{x}_t$ 尚未确定, 因为它包含 x_t 。构造可预先计算的稳定预测点

$$\tilde{x}_t = \frac{1}{A_t} \left(\sum_{s=1}^{t-1} \alpha_s x_s + \alpha_t x_{t-1} \right). \quad (7.5)$$

由定义,

$$\bar{x}_t - \tilde{x}_t = \frac{\alpha_t}{A_t} (x_t - x_{t-1}). \quad (7.6)$$

对在线损失 式 7.3, 选择 optimism

$$M_t = \alpha_t \nabla F(\tilde{x}_t), \quad g_t = \alpha_t \nabla F(\bar{x}_t). \quad (7.7)$$

若 F 为 L -光滑, 则

$$\|g_t - M_t\|_2 \leq \frac{L\alpha_t^2}{A_t} \|x_t - x_{t-1}\|_2. \quad (7.8)$$

当 $\alpha_t = t$ 时, $\alpha_t^2/A_t = O(1)$ 。因此预测误差不再随 t 爆炸, 而是与相邻在线点移动成正比。

7.5 负稳定项完成抵消

Euclidean Optimistic OMD 的精细遗憾界具有形式

$$\text{Reg}_T(u) \leq \frac{D^2}{2\eta} + \eta \sum_{t=1}^T \|g_t - M_t\|_2^2 - \frac{1}{4\eta} \sum_{t=1}^T \|x_t - x_{t-1}\|_2^2, \quad (7.9)$$

其中 D 控制初始 Bregman 半径。将 式 7.8 代入:

$$\eta \|g_t - M_t\|_2^2 \leq \eta L^2 \frac{\alpha_t^4}{A_t^2} \|x_t - x_{t-1}\|_2^2.$$

对 $\alpha_t = t$, 系数 $\alpha_t^4/A_t^2 = O(1)$ 。取 $\eta = \Theta(1/L)$, 正的预测误差项被 式 7.9 中的负稳定项吸收, 于是

$$\text{Reg}_T(x^*) = O(LD^2). \quad (7.10)$$

再由 $A_T = \Theta(T^2)$ 和 式 7.4,

$$F(\bar{x}_T) - F(x^*) = O\left(\frac{LD^2}{T^2}\right). \quad (7.11)$$

这正是光滑凸优化的一阶最优加速阶。

7.6 与 Nesterov 加速的关系

两种视角的变量可以对应起来：

Nesterov 视角	Optimistic OMD 视角
梯度计算点	稳定平均点 $\bar{x}_t$
动量/预测点	$\tilde{x}_t$
特定动量系数	线性权重 $\alpha_t = t$
势函数抵消	OOMD 负稳定项吸收预测误差

这不是说所有加速法都等于同一个 OOMD 实现，而是揭示共同结构：构造一个比真实查询点提前一步的稳定预测，并让系数保证误差可以望远镜或被负项吸收。

7.7 未知光滑性与 universality

上述推导使用 $\eta = \Theta(1/L)$ 。若 L 未知，可以考虑：

- 回溯线搜索或 doubling;
- 多学习率专家聚合;
- 由观测到的预测误差自适应调节学习率;
- Hölder 光滑类上的 universal 方法。

这些方法要同时处理未知平滑阶、未知尺度与模型选择开销。AOPT_Holder 中的完整 universal 结果属于 P2 研究接口，本章不展开其多层 ensemble 证明。

7.8 适用边界

典型误用

- 只取 $\alpha_t = t$ ，却没有让加权在线遗憾保持常数；此时 $A_T = \Theta(T^2)$ 并不自动带来加速。
- 用 $\bar{x}_t$ 构造 M_t ；它包含尚未产生的 x_t ，违反在线时序。
- 在式 7.9 中丢掉负稳定项后，仍声称能得到 $O(T^{-2})$ 。
- 对非光滑目标沿用式 7.8；梯度 Lipschitz 性正是抵消成立的关键。
- 把 online-to-batch 的函数值输出保证误读为最后一个原始在线点 x_T 的保证。

本章的加速模板可以压缩成：**线性增长的权重制造 T^2 分母，稳定平均制造可预测梯度，Optimistic OMD 的负项支付预测误差。**

Part III

部分反馈与 Bandit

8 对抗 Bandit 与 Bandit 凸优化

全信息在线学习能看到整条损失向量；Bandit 只能看到自己所选动作的损失。此时算法必须同时完成两件事：选择当前看起来好的动作，并主动收集足以估计其他动作的信息。探索与估计方差由此成为主导项。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。
本章对应 Lecture 10。Exp3 的重要性加权估计和遗憾证明为主线；一点 Bandit Gradient Descent 保留完整估计器与误差分解；自协调障碍只解释几何作用，不展开全部高级 BCO 证明。

8.1 对抗多臂 Bandit 协议

本章 Exp3 定理与证明针对 **oblivious adversary**：环境在交互开始前固定整个损失序列 $\ell_1, \dots, \ell_T \in [0, 1]^K$ ，其中 $K \geq 2, T \geq 1$ 。损失不依赖学习器随后产生的随机动作。第 t 轮：

1. 学习器根据过去观测选择分布 $p_t \in \Delta_K$ ；
2. 在已经固定的 ℓ_t 下，用本轮新随机性采样 $a_t \sim p_t$ ；
3. 学习器只观察 ℓ_{t,a_t} ，再更新权重。

$\mathcal{F}_{t-1}$ 包含前 $t-1$ 轮历史， p_t 对它可测；采样动作 a_t 通常不对它可测。下文 $\mathbb{E}_t$ 表示给定 $\mathcal{F}_{t-1}$ 后对本轮采样取条件期望。

期望静态遗憾为

$$\mathbb{E}[\text{Reg}_T] = \mathbb{E} \left[\sum_{t=1}^T \ell_{t,a_t} - \min_{a \in [K]} \sum_{t=1}^T \ell_{t,a} \right]. \quad (8.1)$$

期望针对算法采样随机性。损失可以随轮次任意变化，但本节不允许其依赖已实现的随机历史。

Hedge 无法直接使用，因为它需要整个 ℓ_t 。Bandit 方法的基本套路是：先从单点反馈构造一条完整的随机估计向量，再把它交给全信息算法。

8.2 重要性加权损失估计

定义

$$\hat{\ell}_{t,a} = \frac{\ell_{t,a_t}}{p_{t,a_t}} \mathbf{1}\{a = a_t\}. \quad (8.2)$$

给定历史和 p_t , 对每个 a ,

$$\mathbb{E}_t[\hat{\ell}_{t,a}] = \sum_{j=1}^K p_{t,j} \frac{\ell_{t,j}}{p_{t,j}} \mathbf{1}\{a = j\} = \ell_{t,a}. \quad (8.3)$$

同时存在路径恒等式

$$\langle p_t, \hat{\ell}_t \rangle = \ell_{t,a_t}. \quad (8.4)$$

$1/p_{t,a_t}$ 正是纠正“动作以非均匀概率被观察”的重要性权重。去掉它虽然方差更小, 却不再无偏, 也无法把估计损失的 Hedge 遗憾转换为真实 Bandit 遗憾。

8.3 Exp3

Exp3 在估计损失上运行指数权重:

$$p_{t,a} = \frac{\exp(-\eta \hat{L}_{t-1,a})}{\sum_{j=1}^K \exp(-\eta \hat{L}_{t-1,j})}, \quad \hat{L}_{t,a} = \sum_{s=1}^t \hat{\ell}_{s,a}. \quad (8.5)$$

每轮采样 $a_t \sim p_t$, 观察 ℓ_{t,a_t} , 按式 8.2 构造 $\hat{\ell}_t$ 再更新累计估计损失。

估计器的单个非零坐标可能很大, 但 Hedge 二阶项在取条件期望后发生抵消:

$$\begin{aligned} \mathbb{E}_t \left[\sum_{a=1}^K p_{t,a} \hat{\ell}_{t,a}^2 \right] &= \sum_{a=1}^K p_{t,a} \frac{\ell_{t,a}^2}{p_{t,a}^2} p_{t,a} \\ &= \sum_{a=1}^K \ell_{t,a}^2 \leq K. \end{aligned} \quad (8.6)$$

因此估计误差付出的维数代价是 K , 而不是全信息专家问题的常数 1。

8.4 Exp3 遗憾主证明

对非负估计损失使用 Hedge 的二阶势函数界：对任意动作 a ,

$$\sum_{t=1}^T \langle p_t, \hat{\ell}_t \rangle - \sum_{t=1}^T \hat{\ell}_{t,a} \leq \frac{\log K}{\eta} + \eta \sum_{t=1}^T \sum_{j=1}^K p_{t,j} \hat{\ell}_{t,j}^2.$$

先选定 $a^* \in \arg \min_{a \in [K]} \sum_{t=1}^T \ell_{t,a}$ (并列时用固定规则)。由于整个损失序列预先固定, a^* 不依赖算法随机性, 虽然学习器事先不知道它, 分析时仍可把它作为固定比较臂。将上式中的 a 取为 a^* , 再取期望, 便能逐项使用式 8.3; 结合式 8.4 和式 8.6, 得到

$$\mathbb{E}[\text{Reg}_T] \leq \frac{\log K}{\eta} + \eta K T. \quad (8.7)$$

选择

$$\eta = \sqrt{\frac{\log K}{KT}},$$

便有

$$\mathbb{E}[\text{Reg}_T] \leq 2\sqrt{KT \log K}. \quad (8.8)$$

与 Hedge 的 $O(\sqrt{T \log K})$ 相比, 多出的 $\sqrt{K}$ 是部分反馈造成的估计方差代价。

⚠ 自适应对手的边界

若损失允许依赖过去历史, 但在本轮动作采样前确定, 同样的无偏性和二阶矩计算仍可控制相对于每个预先固定比较臂 a 的期望差

$$\mathbb{E} \left[\sum_{t=1}^T (\ell_{t,a_t} - \ell_{t,a}) \right] \leq \frac{\log K}{\eta} + \eta K T.$$

但此时事后最优臂本身依赖随机历史, 不能将这个固定比较臂界直接换成含随机最小值的期望遗憾界, 也不能交换最大值与期望。自适应对手下的事后最优臂保证需要额外分析, 本节证明未覆盖。参见 Lattimore 与 Szepesvári 的 [Bandit Algorithms](#), §28.5 Notes, 第 9 点。

8.5 下界与探索边界

当 $2 \leq K \leq T$ 时, 对任意 Bandit 算法, 都存在损失序列使

$$\mathbb{E}[\text{Reg}_T] = \Omega(\sqrt{KT}). \quad (8.9)$$

此处的 $K \leq T$ 不能省略: 有界损失下遗憾至多为 T , 所以 K 远大于 T 时不能声称同一 $\sqrt{KT}$ 下界。参见 [Bandit Algorithms, Exercise 15.4](#) 的 Bernoulli 构造。

下界甚至可以在随机 Bandit 子类中构造: 设置多个均值极其接近的环境, 使有限样本不足以可靠识别最优臂。因随机环境比对抗环境更容易, 该下界也适用于对抗 MAB。

Exp3 与下界只差 $\sqrt{\log K}$ 。更精细的正则和估计器可以去掉这一对数, 但重要性加权、探索概率与估计方差之间的三角关系不会消失。

8.6 Bandit Convex Optimization

BCO 把有限动作扩展到凸域 $\mathcal{X} \subseteq \mathbb{R}^d$ 。第 t 轮先选 $x_t \in \mathcal{X}$, 随后只观察 $f_t(x_t)$, 目标是控制

$$\mathbb{E} \left[\sum_{t=1}^T f_t(x_t) - \min_{u \in \mathcal{X}} \sum_{t=1}^T f_t(u) \right].$$

困难在于一个函数值不足以直接恢复 d 维梯度。标准方法通过随机扰动, 把函数值变成某个平滑版本梯度的无偏估计。

8.7 一点梯度估计

令 s_t 在单位球面上均匀采样, 取

$$x_t = y_t + \delta s_t.$$

定义球内平滑函数

$$\tilde{f}_t(y) = \mathbb{E}_{v \sim \text{Unif}(\mathbb{B})}[f_t(y + \delta v)].$$

一点估计器为

$$\tilde{g}_t = \frac{d}{\delta} f_t(y_t + \delta s_t) s_t. \quad (8.10)$$

Stokes 公式给出

$$\mathbb{E}_t[\tilde{g}_t] = \nabla \tilde{f}_t(y_t). \quad (8.11)$$

无偏性针对的是平滑函数 $\tilde{f}_t$ ，不是原始 f_t 。参数 δ 越小，平滑偏差越小，但估计器范数按 $1/\delta$ 增长。

8.8 Bandit Gradient Descent

假设

$$r\mathbb{B} \subseteq \mathcal{X} \subseteq R\mathbb{B},$$

并令 y_t 位于收缩域 $(1 - \alpha)\mathcal{X}$ ，其中 $\alpha = \delta/r$ ，保证扰动后的 $x_t = y_t + \delta s_t$ 仍可行。更新为

$$y_{t+1} = \Pi_{(1-\alpha)\mathcal{X}}(y_t - \eta \tilde{g}_t). \quad (8.12)$$

若每个 f_t 为 G -Lipschitz，且 $|f_t(x)| \leq C$ ，对 oblivious adversary，遗憾可以分解为：

$$\mathbb{E}[\text{Reg}_T] \leq \frac{R^2}{2\eta} + \frac{\eta d^2 C^2 T}{2\delta^2} + 3G\delta T + \alpha GRT. \quad (8.13)$$

四项依次来自 OGD 初始势能、估计方差、平滑偏差和域收缩。平衡 η 与 δ 得到经典一点 BGD 的

$$\mathbb{E}[\text{Reg}_T] = O(T^{3/4})$$

量级，常数包含 d, R, r, G, C 。它不是 BCO 的最终最优率，但清楚展示了“扰动尺度同时控制偏差与方差”的基本机制。

8.9 光滑 BCO 与障碍几何

全局球面扰动对狭长或靠近边界的可行域效率很低。自协调障碍 $\mathcal{R}$ 用局部 Hessian 定义 Dikin 椭球：

$$\mathcal{E}(x) = \{x + h : \|h\|_{\nabla^2 \mathcal{R}(x)} \leq 1\} \subseteq \mathcal{X}.$$

于是可以沿局部矩阵

$$B_t^2 = \nabla^{-2} \mathcal{R}(y_t)$$

做各向异性探索 $x_t = y_t + \delta B_t s_t$ ，并构造

$$\tilde{g}_t = \frac{d}{\delta} f_t(y_t + \delta B_t s_t) B_t^{-1} s_t.$$

FTRL 使用障碍正则保持点位于内部，局部范数又让估计方差与域几何匹配。分析的三块仍是：

- FTRL 稳定性与 Newton decrement；
- 平滑偏差和梯度估计方差；
- 将内部比较点移向真实比较器的 shifting cost。

完整自协调障碍定义和最优 BCO 速率需要较多额外凸几何背景，因此作为 P1 接口保留；本章不复刻 Lecture 10 的全部证明。

8.10 使用检查

⚠ 典型误用

- 用 ℓ_{t,a_t} 直接填入被选坐标，却忘记除以 p_{t,a_t} 。
- 只验证估计器无偏，不检查二阶矩是否可控。
- 在自适应对手下把固定比较臂的期望界直接当作事后最优臂的期望遗憾界；本章 Exp3 结论限定于 oblivious adversary。
- 把一点估计器称为 $\nabla f_t(y_t)$ 的无偏估计；它对应的是平滑函数。
- 随机扰动后没有收缩可行域，导致查询点离开 $\mathcal{X}$ 。
- 把 BGD 的 $T^{3/4}$ 当作所有 BCO 模型的最终下界。

下一章转向固定但未知的随机奖励分布。此时重复采样同一动作可以形成收缩置信区间，从而把探索集中到仍可能最优的动作上。

9 随机多臂 Bandit

随机 Bandit 假设每个动作背后有固定但未知的奖励分布。与对抗 Bandit 不同，重复拉取同一臂会产生可累积的统计证据，因此探索可以逐渐集中到仍有可能最优的臂。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 11。ETC 保留一次完整误判分析，UCB 保留置信事件上的计数证明，Thompson Sampling 保留后验更新和结论边界；best-of-both-worlds 与 Best Arm Identification 只作为进阶接口。

9.1 随机 MAB 模型

有 K 个臂。臂 a 的奖励独立同分布于未知分布 $\mathcal{D}_a$ ，均值为

$$\mu_a = \mathbb{E}_{r \sim \mathcal{D}_a}[r].$$

记最优均值与一个最优臂为

$$\mu^* = \max_{a \in [K]} \mu_a, \quad a^* \in \operatorname{argmax}_{a \in [K]} \mu_a.$$

第 t 轮选择 a_t ，只观察 $r_t \sim \mathcal{D}_{a_t}$ 。次优差定义为

$$\Delta_a = \mu^* - \mu_a \geq 0. \tag{9.1}$$

Δ_a 越小，臂 a 越难与最优臂区分，但误选一次的代价也越小。

9.2 伪遗憾与计数分解

记臂 a 在前 T 轮被选择的次数为

$$N_T(a) = \sum_{t=1}^T \mathbf{1}\{a_t = a\}.$$

伪遗憾为

$$\bar{R}_T = T\mu^* - \sum_{t=1}^T \mu_{a_t}.$$

代入 式 9.1, 得到随机 MAB 最重要的分解:

$$\bar{R}_T = \sum_{a=1}^K \Delta_a N_T(a), \quad \mathbb{E}[\bar{R}_T] = \sum_{a=1}^K \Delta_a \mathbb{E}[N_T(a)]. \quad (9.2)$$

因此证明遗憾界等价于控制每个次优臂被拉取多少次。真实累计奖励遗憾还包含样本噪声；在期望下通常与伪遗憾一致，但高概率陈述时不能混用。

9.3 两类难度刻画

随机 MAB 有两类互补结论:

- **gap-dependent**: 依赖具体 Δ_a , 描述固定实例的渐近难度;
- **gap-independent**: 消去未知 gap, 给出所有实例上的 minimax 保证。

在典型次高斯奖励下, 任何一致算法都受到 Lai–Robbins 型下界

$$\liminf_{T \rightarrow \infty} \frac{\mathbb{E}[\bar{R}_T]}{\log T} \geq \sum_{a: \Delta_a > 0} \frac{\Delta_a}{\text{KL}(\mathcal{D}_a \| \mathcal{D}_{a^*})}. \quad (9.3)$$

当 KL 散度与 Δ_a^2 同阶时, 右侧为 $\Omega(\sum_a (\log T)/\Delta_a)$ 。另一方面, 最坏实例的 minimax 下界为

$$\Omega(\sqrt{KT}).$$

小 gap 不会与两类下界矛盾: 若 $\Delta \asymp \sqrt{K/T}$, 实例依赖式本身就过渡到 $\sqrt{KT}$ 尺度。

9.4 Explore-Then-Commit

ETC 先均匀探索，再永久提交给经验均值最大的臂。设探索总长度为 T_0 ，每个臂被探索

$$m = \frac{T_0}{K}$$

次；之后选择

$$\hat{a} \in \operatorname{argmax}_{a \in [K]} \hat{\mu}_m(a)$$

并一直使用到第 T 轮。

若奖励位于 $[0, 1]$ ，Hoeffding 不等式给出对任意次优臂 a ，

$$\Pr(\hat{a} = a) \leq 2 \exp\left(-\frac{m\Delta_a^2}{2}\right).$$

于是

$$\mathbb{E}[\bar{R}_T] \leq \sum_{a=1}^K \left[\frac{T_0}{K} + 2T \exp\left(-\frac{T_0\Delta_a^2}{2K}\right) \right] \Delta_a. \quad (9.4)$$

第一项是主动探索代价，第二项是提交错误后的长期代价。若已知最小正 gap

$$\Delta_{\min} = \min_{a: \Delta_a > 0} \Delta_a,$$

可取 $m \asymp (\log T)/\Delta_{\min}^2$ 。但 gap 未知时调参困难；一次错误提交也无法被后续数据纠正。ETC 因而适合阶段明确、可接受先探索后部署的场景，却不是通用 minimax 最优策略。

9.5 ε -greedy 的局限

ε -greedy 每轮以 $1 - \varepsilon_t$ 选择经验最优臂，以 ε_t 均匀探索。固定 $\varepsilon > 0$ 会持续拉取明显次优臂，产生线性遗憾；递减 ε_t 可得到对数阶实例依赖界，但通常需要已知或估计 $\Delta_{\min}$ 。

它实现简单，却把探索平均分给所有臂，没有利用“某些臂已经明显不可能最优”的证据。

9.6 UCB：用乐观原则分配探索

UCB 为每个臂维护经验均值和置信半径。以 $[0, 1]$ 奖励为例，定义

$$\hat{\mu}_t(a) = \frac{1}{N_t(a)} \sum_{s \leq t: a_s = a} r_s,$$

以及

$$\text{UCB}_t(a) = \hat{\mu}_t(a) + \sqrt{\frac{\log T}{N_t(a)}}. \quad (9.5)$$

初始化时每个臂至少拉取一次；之后选择

$$a_{t+1} \in \operatorname{argmax}_{a \in [K]} \text{UCB}_t(a). \quad (9.6)$$

置信上界大可能有两种原因：经验均值高，或样本太少、仍不确定。取最大 UCB 因而自动统一 exploitation 与 exploration。

9.7 UCB 的 gap-dependent 证明

由 Hoeffding 不等式和 union bound，以至少 $1 - 2K/T$ 的概率，对所有 a, t 同时有

$$|\hat{\mu}_t(a) - \mu_a| \leq \sqrt{\frac{\log T}{N_t(a)}}. \quad (9.7)$$

在此好事件上，如果次优臂 a 在时刻 $t + 1$ 仍被选择，则

$$\mu^* \leq \text{UCB}_t(a) \leq \mu_a + 2\sqrt{\frac{\log T}{N_t(a)}}.$$

因此

$$N_T(a) \leq \frac{4 \log T}{\Delta_a^2} + 1. \quad (9.8)$$

代入 式 9.2:

$$\bar{R}_T \leq \sum_{a: \Delta_a > 0} \left(\frac{4 \log T}{\Delta_a} + \Delta_a \right) \quad (9.9)$$

在好事件上成立。它与 式 9.3 的典型 $\sum_a (\log T)/\Delta_a$ 量级匹配。

9.8 从 gap-dependent 到 gap-independent

取阈值 $\Delta > 0$, 把臂分成小 gap 与大 gap 两组:

$$\bar{R}_T \leq T\Delta + \sum_{a: \Delta_a > \Delta} \frac{4 \log T}{\Delta_a}.$$

第二项可用 $K(4 \log T)/\Delta$ 控制。平衡两项, 取

$$\Delta \asymp \sqrt{\frac{K \log T}{T}},$$

得到

$$\bar{R}_T = O(\sqrt{KT \log T}). \quad (9.10)$$

这比 minimax 下界多一个 $\sqrt{\log T}$; MOSS 等算法通过改变置信半径获得最优 $O(\sqrt{KT})$ 。

9.9 Thompson Sampling

Thompson Sampling 用后验抽样表达不确定性。对 Bernoulli 奖励, 取独立先验

$$\mu_a \sim \text{Beta}(\alpha_{a,1}, \beta_{a,1}).$$

每轮:

1. 对每个臂采样 $\tilde{\mu}_{t,a} \sim \text{Beta}(\alpha_{a,t}, \beta_{a,t})$;
2. 选择 $a_t \in \arg\max_a \tilde{\mu}_{t,a}$;
3. 观察 $r_t \in \{0, 1\}$ 后更新

$$\alpha_{a_t, t+1} = \alpha_{a_t, t} + r_t, \quad \beta_{a_t, t+1} = \beta_{a_t, t} + 1 - r_t.$$

后验均值大对应 exploitation, 后验方差大则增加该臂偶尔被抽为最大值的概率, 对应 exploration。

在合适的 Bernoulli/有界奖励条件下, TS 具有实例依赖对数遗憾; 精细结论以 KL 散度刻画:

$$\mathbb{E}[\bar{R}_T] = O\left(\sum_{a:\Delta_a>0} \frac{\Delta_a \log T}{\text{KL}(\mu_a, \mu^*)}\right)$$

并带有较低阶项。先验、似然与奖励模型必须匹配; Beta 更新不能直接用于任意实值高斯奖励。

9.10 ETC、UCB 与 TS 的边界

方法	探索方式	主要优点	主要限制
ETC	固定探索阶段	结构最清楚, 易部署	依赖 gap/时域, 提交后不能纠错
ϵ -greedy	均匀随机探索	实现简单	探索不区分臂, 调度依赖问题尺度
UCB	确定性乐观置信区间	频率学派保证清晰	置信半径需匹配噪声模型
TS	后验概率匹配	实践常有效, 探索自然	依赖概率模型与先验, 证明更细致

9.11 进阶接口

- **Best of Both Worlds:** 同一算法在随机环境达到 gap-dependent 对数遗憾, 在对抗环境仍保持 $O(\sqrt{KT})$ 。普通 UCB 在对抗环境可能近线性, 普通 Exp3 又不充分利用随机 gap。
- **Best Arm Identification:** 目标不是累计遗憾, 而是在固定预算下最小化误识别概率, 或以最少样本在置信度 $1 - \delta$ 下返回最优臂。它是纯探索问题, 不能直接用累计遗憾衡量。
- **在线强化学习:** 状态—动作对的访问计数、置信奖励和乐观动态规划把 UCB 原理推广到序贯决策。

⚠ 典型误用

- 把一次观测的最高奖励当作最优臂均值。
- 只写 $O(\log T)$, 不说明常数中含有 $1/\Delta_a$ 或 KL 散度。
- 在 UCB 证明中只对单个固定 t 使用集中不等式, 却直接宣称所有轮同时成立。
- 把伪遗憾的高概率界当成实现奖励遗憾的同一事件。
- 在奖励模型不匹配时机械套用 Beta-Bernoulli Thompson Sampling。

下一章将用共享线性参数连接不同动作, 使一次观测同时减少一整个方向上的不确定性。

10 线性 Bandit 与置信椭圆

多臂 Bandit 把每个动作当成独立对象；动作很多甚至连续时，逐臂探索不再可行。线性 Bandit 假设奖励通过共享参数生成：观察一个动作，能够同时减少与它方向相近的其他动作的不确定性。

i 材料来源与边界

Lecture 编号沿用原材料标记，课程与作者待补；映射及公开核验资料见[参考资料](#)。

本章对应 Lecture 12。正则最小二乘、条件次高斯噪声、自归一化置信椭圆、LinUCB 和椭圆势函数构成主线；GLB、重尾反馈、线性 MDP 与 one-pass 计算问题只建立研究接口。

10.1 线性奖励模型

动作由特征向量 $x \in \mathcal{X} \subseteq \mathbb{R}^d$ 表示，假设

$$\|x\|_2 \leq L, \quad \|\theta^*\|_2 \leq S.$$

第 t 轮选择 $X_t \in \mathcal{X}$ ，观察

$$r_t = X_t^\top \theta^* + \eta_t, \quad (10.1)$$

其中 θ^* 未知。记历史过滤为 $\mathcal{F}_{t-1}$ ，噪声满足条件 R -次高斯：

$$\mathbb{E}[e^{\lambda \eta_t} \mid \mathcal{F}_{t-1}] \leq \exp\left(\frac{\lambda^2 R^2}{2}\right), \quad \forall \lambda \in \mathbb{R}. \quad (10.2)$$

这一条件允许 X_t 依赖过去奖励；不能把自适应动作序列当作预先固定的独立设计矩阵。

若动作集固定，伪遗憾为

$$\bar{R}_T = T \max_{x \in \mathcal{X}} x^\top \theta^* - \sum_{t=1}^T X_t^\top \theta^*. \quad (10.3)$$

10.2 正则最小二乘

给定正则参数 $\lambda > 0$ ，在第 t 轮决策前定义

$$V_{t-1} = \lambda I + \sum_{s=1}^{t-1} X_s X_s^\top, \quad b_{t-1} = \sum_{s=1}^{t-1} r_s X_s. \quad (10.4)$$

ridge 估计量为

$$\hat{\theta}_{t-1} = \operatorname{argmin}_{\theta \in \mathbb{R}^d} \left\{ \lambda \|\theta\|_2^2 + \sum_{s=1}^{t-1} (X_s^\top \theta - r_s)^2 \right\} = V_{t-1}^{-1} b_{t-1}. \quad (10.5)$$

充分统计量可单遍更新：

$$V_t = V_{t-1} + X_t X_t^\top, \quad b_t = b_{t-1} + r_t X_t.$$

无需保存全部历史样本；但精确维护 V_t 仍需 $O(d^2)$ 内存。利用 Sherman–Morrison 公式可将逆矩阵从头计算的 $O(d^3)$ 降为每轮 $O(d^2)$ 的秩一更新。

10.3 为什么是置信椭球

由式 10.1 和式 10.5,

$$\hat{\theta}_{t-1} - \theta^* = V_{t-1}^{-1} \left(\sum_{s=1}^{t-1} \eta_s X_s - \lambda \theta^* \right).$$

对任意动作 x ，广义 Cauchy–Schwarz 不等式给出

$$|x^\top (\hat{\theta}_{t-1} - \theta^*)| \leq \|x\|_{V_{t-1}^{-1}} \|\hat{\theta}_{t-1} - \theta^*\|_{V_{t-1}}. \quad (10.6)$$

因此参数误差在 V_{t-1} 范数下的球，映射到 Euclidean 空间就是椭球。历史经常探索的方向使 V_{t-1} 特征值增大，对应置信半径缩小；未探索方向仍保持较大不确定性。

10.4 自归一化集中

设

$$S_t = \sum_{s=1}^t \eta_s X_s, \quad V_t = \lambda I + \sum_{s=1}^t X_s X_s^\top.$$

向量值鞅的自归一化不等式说明：以至少 $1 - \delta$ 的概率，对所有 t 同时成立

$$\|S_t\|_{V_t^{-1}} \leq R \sqrt{2 \log \frac{1}{\delta} + \log \frac{\det V_t}{\det(\lambda I)}}. \quad (10.7)$$

结合 $\|\theta^*\|_2 \leq S$ ，得到置信半径

$$\beta_{t-1}(\delta) = R \sqrt{2 \log \frac{1}{\delta} + d \log \left(1 + \frac{(t-1)L^2}{\lambda d} \right)} + \sqrt{\lambda} S, \quad (10.8)$$

以及同时对所有 $x \in \mathcal{X}$ 成立的界

$$|x^\top (\hat{\theta}_{t-1} - \theta^*)| \leq \beta_{t-1}(\delta) \|x\|_{V_{t-1}^{-1}}. \quad (10.9)$$

普通 Hoeffding 不等式不足以直接处理这里的自适应设计；自归一化范数正是为了让噪声累计与动作协方差同步缩放。

10.5 LinUCB / OFUL

乐观原则在参数空间中写成

$$X_t \in \operatorname{argmax}_{x \in \mathcal{X}} \left\{ x^\top \hat{\theta}_{t-1} + \beta_{t-1}(\delta) \|x\|_{V_{t-1}^{-1}} \right\}. \quad (10.10)$$

第一项是估计奖励，第二项是方向相关的探索奖励。它等价于在置信集

$$\mathcal{C}_{t-1} = \left\{ \theta : \|\theta - \hat{\theta}_{t-1}\|_{V_{t-1}} \leq \beta_{t-1}(\delta) \right\}$$

中选择最乐观的参数—动作对：

$$(X_t, \tilde{\theta}_t) \in \operatorname{argmax}_{x \in \mathcal{X}, \theta \in \mathcal{C}_{t-1}} x^\top \theta.$$

文献中 LinUCB 与 OFUL 的名称和动作集设定略有差别；本书统一指这种 “ridge 置信椭圆 + 乐观选臂” 的模板。

10.6 遗憾主证明

在置信事件上，令 $x^* \in \arg \max_x x^\top \theta^*$ 。乐观性给出

$$(x^*)^\top \theta^* \leq X_t^\top \hat{\theta}_{t-1} + \beta_{t-1} \|X_t\|_{V_{t-1}^{-1}}.$$

再用 式 10.9 控制 X_t 的估计误差，得到单轮伪遗憾

$$(x^*)^\top \theta^* - X_t^\top \theta^* \leq 2\beta_{t-1} \|X_t\|_{V_{t-1}^{-1}}. \quad (10.11)$$

对 t 求和并用 Cauchy–Schwarz:

$$\bar{R}_T \leq 2\beta_T \sqrt{T \sum_{t=1}^T \|X_t\|_{V_{t-1}^{-1}}^2}.$$

椭圆势函数引理给出

$$\sum_{t=1}^T \min\{1, \|X_t\|_{V_{t-1}^{-1}}^2\} \leq 2 \log \frac{\det V_T}{\det V_0} \leq 2d \log \left(1 + \frac{TL^2}{\lambda d}\right). \quad (10.12)$$

在常见归一化条件下，合并可得以至少 $1 - \delta$ 的概率，

$$\bar{R}_T = \tilde{O}(d\sqrt{T}), \quad (10.13)$$

其中 $\tilde{O}$ 隐藏 R, S, L, λ 和对数因子。

10.7 复杂度从哪里产生

LinUCB 的 $d\sqrt{T}$ 可以拆成两部分：

- $\beta_T = \tilde{O}(\sqrt{d})$: 估计一个 d 维参数的统计半径；
- 椭圆势函数 $\sum_t \|X_t\|_{V_{t-1}^{-1}}^2 = \tilde{O}(d)$: 整个过程中可被反复探索的有效方向总量。

计算代价还取决于动作优化

$$\max_{x \in \mathcal{X}} x^\top \hat{\theta} + \beta \|x\|_{V^{-1}}.$$

有限动作集可枚举；连续或组合动作集可能比统计估计本身更难。

10.8 广义线性 Bandit 接口

GLB 把均值模型改为

$$\mathbb{E}[r_t | X_t] = \mu(X_t^\top \theta^*),$$

其中 μ 是已知链接函数，例如 logistic link。此时平方损失 ridge 不再自然，通常使用正则极大似然估计；置信半径还会依赖链接函数斜率下界。

核心困难是：非二次损失不能只靠 (V_t, b_t) 两个充分统计量精确表示，朴素算法可能每轮重新处理全部历史，造成 $O(t)$ 存储和不断增长的计算。如何同时达到近最优遗憾、 $O(1)$ 轮均摊历史访问和可控内存，是 one-pass GLB 的研究问题。

10.9 重尾、one-pass 与强化学习接口

10.9.1 重尾反馈

若噪声只有有限 $(1 + \nu)$ 阶矩，次高斯自归一化失效。需要截断、Catoni/Huber 型鲁棒估计或分块机制。难点不只是替换集中不等式，还要让鲁棒估计支持在线递推。

10.9.2 线性 MDP

线性函数逼近把奖励或转移写成已知特征与未知参数的线性组合。每个阶段的乐观 value iteration 都会调用类似的 ridge 估计、置信椭圆和椭圆势函数。因此线性 Bandit 是理解带函数逼近 RL 理论的局部模块，而不是完整 MDP。

10.9.3 One-pass

“单遍”不等于完全不保留历史信息。线性 Bandit 保留 V_t 与 b_t 这类可递推统计量，只是不保存全部原始样本。真正的研究张力是：

- 统计上需要足够精确的置信集；
- 计算上只能有限次访问数据；
- 内存上不能随 T 线性增长；
- 遗憾仍要接近离线或多遍方法。

GLB、重尾线性 Bandit 与 one-pass RLHF 的具体算法进入研究接口附录，不在本章提前复刻报告。

10.10 使用检查

典型误用

- 把自适应选择的 X_t 当作独立固定设计，直接套普通向量 Hoeffding。
- 只写 Euclidean 参数误差，却用它解释方向相关的探索；正确对象是 V_t 范数置信椭圆。
- 忘记正则偏差项 $\sqrt{\lambda S}$ 。
- 把 $\tilde{O}(d\sqrt{T})$ 理解为每轮计算只需 $O(d)$ 。
- 把线性 Bandit 结论直接当成线性 MDP 的完整遗憾证明。

至此，主线从全信息 OCO 经过自适应几何与 optimism，进入了部分反馈、统计置信和函数逼近。后续研究接口都应明确自己相对于这条基线新增了哪一种困难。

A 概率、范数与集中工具

本附录只保存正文反复调用的概率与几何工具，不重复《概率论与数理统计工具箱》中的完整理论。

A.1 对偶范数与 Hölder 不等式

对偶范数定义为

$$\|y\|_* = \sup_{\|x\| \leq 1} \langle x, y \rangle,$$

并满足

$$|\langle x, y \rangle| \leq \|x\| \|y\|_*.$$

常见配对为 ℓ_2/ℓ_2 、 ℓ_1/ℓ_∞ ，以及矩阵范数 $\|x\|_A/\|y\|_{A^{-1}}$ 。正文出现“梯度有界”时，应确认使用的是当前原范数对应的对偶范数。

A.2 条件期望与 filtration

$\mathcal{F}_{t-1}$ 表示第 t 轮决策前的全部历史；合法在线决策 x_t 应当对 $\mathcal{F}_{t-1}$ 可测。记

$$\mathbb{E}_t[Z] = \mathbb{E}[Z \mid \mathcal{F}_{t-1}].$$

若 $\mathbb{E}_t[X_t] = 0$ ，则 (X_t) 为鞅差序列。随机梯度的正确无偏性通常写成

$$\mathbb{E}_t[g_t] \in \partial F(x_t),$$

而不是忽略自适应历史的无条件等式。

A.3 次 Gaussian 随机变量

若对所有 $\lambda \in \mathbb{R}$,

$$\mathbb{E}_t[e^{\lambda X_t}] \leq e^{\lambda^2 \sigma^2 / 2},$$

则称 X_t 给定历史是 σ -次 Gaussian。它蕴含条件均值为零及尾界

$$\Pr(|X_t| \geq u \mid \mathcal{F}_{t-1}) \leq 2e^{-u^2/(2\sigma^2)}.$$

A.4 Hoeffding、Azuma 与 Freedman

工具	典型条件	控制对象	何时使用
Hoeffding	独立有界变量	固定样本均值	ETC、逐臂 UCB
Azuma–Hoeffding	有界鞅差	自适应和	粗粒度高概率在线界
Freedman	有界鞅差 + 条件方差	方差自适应的和	online-to-batch、高概率遗憾

设 $(\mathcal{F}_t)_{t \geq 0}$ 为 filtration, X_t 是适应于它的平方可积鞅差, 即 X_t 对 $\mathcal{F}_t$ 可测且 $\mathbb{E}[X_t \mid \mathcal{F}_{t-1}] = 0$ 。假设存在确定常数 $b > 0$, 使每步 $X_t \leq b$ 几乎处处成立。定义从零出发的鞅及其可预测二次变差

$$M_T = \sum_{t=1}^T X_t, \quad V_T = \sum_{t=1}^T \mathbb{E}[X_t^2 \mid \mathcal{F}_{t-1}].$$

对固定时刻 T 和**确定阈值** $x \geq 0$ 、 $v > 0$, Freedman 不等式给出联合事件界

$$\Pr(M_T \geq x, V_T \leq v) \leq \exp\left(-\frac{x^2}{2(v + bx/3)}\right). \quad (\text{A.1})$$

这是 Tropp 的 [Theorem 1.1](#) 的固定时刻推论; 原定理还控制存在某个时刻同时越过这两个确定阈值的事件。这里仅需增量的单侧上界; 若要双侧界, 还要对 $-X_t$ 检查相应条件。

若另有确定的 $v > 0$ 满足 $V_T \leq v$ 几乎处处成立, 令 $L = \log(1/\delta)$ 、 $0 < \delta < 1$, 则以至少 $1 - \delta$ 的概率,

$$M_T \leq \frac{bL}{3} + \sqrt{2vL + \frac{b^2 L^2}{9}} \leq \sqrt{2vL} + \frac{2bL}{3}.$$

第一项阈值来自解二次不等式 $x^2 \geq 2L(v + bx/3)$ 。 V_T 一般是随机量，不能在固定阈值尾界中直接把 v 换成观测到的 V_T ；若只以高概率控制 V_T ，还须计入该事件失败的概率。使用时必须同时检查单步上界、条件方差及阈值是否确定，不能只凭二阶矩有限就套用。

A.5 Union bound 与 anytime 置信事件

固定 t 的概率界不能直接宣称“对所有轮同时成立”。有限时域可将失败概率分配为 δ/T ；未知时域可取

$$\delta_t = \frac{6\delta}{\pi^2 t^2}, \quad \sum_{t=1}^{\infty} \delta_t = \delta,$$

再用 union bound 构造 anytime 事件。更紧的 time-uniform 结果需要 stitching 或置信序列工具。

A.6 矩阵集中接口

矩阵 Bernstein/Freedman 用于控制随机自伴矩阵和，例如经验协方差与 Hessian 近似。主线只需要知道：

- 标量方差被矩阵条件方差替代；
- 结论常包含维数对数项；
- 非交换矩阵乘积不能逐坐标直接套标量集中。

本书线性 Bandit 主证明使用更贴合自适应设计的自归一化向量鞅，而不是一般矩阵 Bernstein。

A.7 自归一化集中

设 X_t 对 $\mathcal{F}_{t-1}$ 可测， η_t 为条件 R -次 Gaussian 鞅差，

$$S_t = \sum_{s=1}^t \eta_s X_s, \quad V_t = V_0 + \sum_{s=1}^t X_s X_s^\top, \quad V_0 \succ 0.$$

则以至少 $1 - \delta$ 的概率，对所有 t 同时有

$$\|S_t\|_{V_t^{-1}} \leq R \sqrt{2 \log \frac{1}{\delta} + \log \frac{\det V_t}{\det V_0}}.$$

归一化矩阵 V_t 与动作序列一起增长，因此允许 X_t 依赖过去噪声。这是线性 Bandit 置信椭圆成立的核心，而不是普通独立样本集中。

A.8 使用条件速查

1. 随机量是独立、鞅差，还是仅不相关？
2. 条件均值是否相对于正确的 $\mathcal{F}_{t-1}$ 定义？
3. 结论针对固定时间，还是对所有时间同时成立？
4. 已知的是几乎处处有界、条件方差、次 Gaussian，还是只有有限高阶矩？
5. 使用 union bound 后是否同步修改了对数项？
6. 自适应设计下是否需要自归一化或矩阵型工具？

B 遗憾与收敛证明模板

本附录将正文中的高频证明方法压缩为可复用的检查表。

B.1 势函数下降

选择非负势函数 $\Phi_t(u)$ ，把单轮误差写成

$$\text{gap}_t \leq \Phi_t(u) - \Phi_{t+1}(u) + \text{stability}_t.$$

Euclidean 方法使用平方距离; Hedge 使用 log-partition; OMD 使用 Bregman 散度; ONS 与 LinUCB 使用 log-determinant。

B.2 望远镜求和

固定系数时直接消去中间项。时变学习率时先展开

$$\sum_{t=1}^T \frac{a_t - a_{t+1}}{\eta_t} = \frac{a_1}{\eta_1} + \sum_{t=2}^T a_t \left(\frac{1}{\eta_t} - \frac{1}{\eta_{t-1}} \right) - \frac{a_{T+1}}{\eta_T}.$$

必须检查 $1/\eta_t$ 的单调性，再用势函数上界控制新增项。

B.3 凸性线性化

$$f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle.$$

它把一般凸损失化为线性损失，但只给上界；后续算法实际处理的是 g_t 及其几何。

B.4 强凸负二次项

$$f_t(x_t) - f_t(u) \leq \langle g_t, x_t - u \rangle - \frac{\mu}{2} \|x_t - u\|^2.$$

选 $1/\eta_t$ 的增量与 μ 匹配，使负项抵消时变势函数系数。若强凸参数随轮次变化，应匹配累计强凸性。

B.5 指数权重与 log-partition

1. 定义 $W_t = \sum_i e^{-\eta L_{t,i}}$;
2. 用最佳专家下界 $\log W_T$;
3. 用指数函数二阶上界控制 $\log(W_t/W_{t-1})$;
4. 保留 $\sum_{t,i} p_{t,i} \ell_{t,i}^2$ ，需要自适应界时不要过早替换成 T 。

B.6 重要性加权估计

Bandit 降到全信息通常检查三件事：

$$\mathbb{E}_t[\hat{\ell}_t] = \ell_t, \quad \langle p_t, \hat{\ell}_t \rangle = \ell_{t,a_t}, \quad \mathbb{E}_t \|\hat{\ell}_t\|_{p_t}^2 \leq \text{variance budget}.$$

只有无偏性不够；遗憾通常由估计器二阶矩主导。

B.7 椭圆势函数

若

$$V_t = V_{t-1} + x_t x_t^\top,$$

矩阵行列式引理把局部不确定性转成 log-determinant：

$$\sum_{t=1}^T \min\{1, \|x_t\|_{V_{t-1}^{-1}}^2\} \leq 2 \log \frac{\det V_T}{\det V_0}.$$

再用 trace-determinant 关系把它上界为 $O(d \log T)$ 。

B.8 步长优化

面对

$$\frac{A}{\eta} + B\eta,$$

事后最优步长为 $\eta^* = \sqrt{A/B}$, 最优值为 $2\sqrt{AB}$ 。若 A, B 或 T 事前未知, 必须说明 doubling、self-confident tuning 或 parameter-free 机制, 不能直接使用未来量。

B.9 速率、假设与输出点对照

每个结论交付前填写:

检查项	需要写明
问题结构	凸、强凸、光滑、exp-concave
信息模型	全信息、一阶、Bandit、随机 oracle
环境	随机、oblivious、adaptive/non-anticipating
有界条件	域直径、梯度、损失、噪声尾部
输出	最后点、最佳点、均匀/加权平均
结论类型	逐路径、期望、高概率、anytime
参数依赖	$D, G, L, \mu, d, K, \delta$

若其中一项无法回答, 通常说明定理还没有被完整转录。

C 研究接口：通用性、one-pass 与鲁棒 Bandit

本附录面向后续研究阅读。每个专题只保留问题、关键困难、算法骨架、主结论和阅读入口，不复刻论文级证明。

⚠ 扩写边界

以下内容当前均为 P2。未经确认，不将技术细节大规模扩写进正文。

C.1 Universal gradient-variation online learning

基础 OOMD 需要预先知道曲率类型、光滑常数或合适学习率。Universal gradient-variation online learning 试图用一个算法同时竞争于多种曲率和变化尺度，并保持与相应专用算法接近的遗憾。

C.1.1 未知曲率与多层 ensemble

典型结构是两层或多层学习器：底层覆盖不同曲率、步长或正则配置，元学习器根据在线表现聚合。真正困难不是“多跑几个参数”，而是控制元遗憾、底层相关性和 gradient-variation 量，使聚合开销不吞掉自适应收益。

C.1.2 Hölder 光滑与通用离线加速

Hölder 光滑在 Lipschitz 与梯度 Lipschitz 之间插值。AOPT_Holder 通过 stabilized online-to-batch 把 universal gradient-variation 遗憾转成离线收敛率，使同一算法适应未知 Hölder 指数。主线只保留第 7 章的转换机制；完整多层 ensemble 与最优率证明暂不展开。

C.2 One-pass generalized linear bandits

C.2.1 非线性度带来的统计困难

GLB 的均值为 $\mu(x^\top \theta^*)$ 。链接函数曲率会进入置信集，若最小导数很小，局部可辨识性变差；直接线性化可能引入额外非线性度惩罚。

C.2.2 最大似然带来的计算与存储困难

线性 ridge 估计可由 (V_t, b_t) 精确递推；一般 GLB 的最大似然目标是非二次的，朴素更新需反复访问全部历史。one-pass 方法必须用在线二阶近似、OMD/FTRL 或可递推 surrogate 压缩历史。

C.2.3 联合统计——计算效率

目标不是只降低每轮时间，而是在近最优遗憾、 $O(1)$ 次数据访问、次线性/常数历史存储和稳定数值更新之间同时成立。AOPT_GLB 作为该问题的专题入口。

C.3 Heavy-tailed linear bandits

C.3.1 重尾噪声与鲁棒估计

只有有限 $(1 + \nu)$ 阶矩时，样本均值和平方损失容易被极端值主导，次高斯置信椭圆失效。需要重新设计估计误差界，而不是只把 R 换成更大的常数。

C.3.2 Huber 回归

Huber 损失在中心区域保持二次，在尾部转为线性，以降低异常值影响。阈值决定偏差—鲁棒性平衡，并通常随时间、矩尺度和置信水平变化。

C.3.3 OMD 作为 one-pass 估计器

AOPT_HvtLB 的关键接口是用在线镜像/梯度更新近似鲁棒回归解，使每个样本只处理一次；随后再把估计误差嵌入 OFUL 型乐观选择。完整重尾自归一化分析保留为 P2。

C.4 四份研究材料的定位

材料	基础模块	新困难	当前处理
AOPT_Universal	OOMD、gradient variation	未知曲率与多算法聚合	只记研究问题与架构
AOPT_Holder	stabilized O2B	未知 Hölder 光滑度	只记 universality 接口
AOPT_GLB	LinUCB/GLM-UCB	非线性估计的 one-pass 效率	只记统计—计算张力
AOPT_HvtLB	线性 Bandit	重尾噪声与鲁棒单遍估计	只记 Huber + OMD 骨架

C.5 待添加研究方向

- dynamic regret 与 non-stationarity;
- delayed feedback 与 memory;
- Bayesian optimization;
- 线性与广义线性 MDP;
- 在线博弈和均衡收敛。

这些方向只有在进入单独研究专题时再扩写假设、算法和完整定理，避免附录变成论文摘要合集。

D 统一记号与模型对照

本附录固定全书最重要的符号角色。局部章节若需要特殊记号，应在首次出现时定义，不静默复用已有字母。

D.1 决策、动作与损失

记号	含义
$t = 1, \dots, T$	在线轮次
x_t	连续决策或 OCO 动作
a_t	多臂 Bandit 中选择的臂
f_t	第 t 轮损失函数
g_t	真实梯度、次梯度或随机一阶 oracle 输出
M_t	在观察 g_t 前产生的 optimistic prediction
$\mathcal{X}$	决策集合

D.2 Regret

记号	含义
$\text{Reg}_T(u)$	相对固定比较点 u 的在线遗憾
Reg_T	相对最佳固定比较点的静态遗憾
$\bar{R}_T$	随机 Bandit 的伪遗憾
$\mathbb{E}[\text{Reg}_T]$	对算法或环境随机性取期望后的遗憾
$\tilde{O}(\cdot)$	隐去对数因子的量级

D.3 随机历史

记号	含义
$\mathcal{F}_{t-1}$	第 t 轮决策前的历史信息
$\mathbb{E}_t[\cdot]$	给定 $\mathcal{F}_{t-1}$ 的条件期望

记号	含义
$\hat{g}_t, \tilde{g}_t$	随机或 Bandit 梯度估计

D.4 几何

记号	含义
$\ \cdot\ $	原空间范数
$\ \cdot\ _*$	对偶范数
ψ	正则函数或镜像势函数
$D_\psi(x, y)$	由 ψ 生成的 Bregman 散度
$\ x\ _A$	$\sqrt{x^\top A x}$, 其中 $A \succeq 0$
$\Pi_{\mathcal{X}}$	Euclidean 投影; 其他几何投影会显式标注

D.5 Bandit

记号	含义
K	多臂 Bandit 的动作数
$N_T(a)$	前 T 轮动作 a 的选择次数
μ_a	随机 Bandit 中臂 a 的均值奖励
$\Delta_a = \mu^* - \mu_a$	次优差
X_t	线性 Bandit 中选择的特征向量
V_t	正则化设计/协方差矩阵
$\hat{\theta}_t$	未知线性参数的估计
$\beta_t(\delta)$	置信椭球半径

D.6 常数角色

记号	含义
D, R	域直径或到比较点的距离尺度; 以所在章节定义为准
G	梯度/次梯度范数上界
L	光滑常数; 在线性 Bandit 章节局部也用于动作范数上界
μ, σ	强凸参数; 同一推导内只使用其中一个
α	exp-concavity 参数或局部权重; 须在章节内重新声明
η_t	学习率/步长

记号	含义
d	连续参数空间维数
δ	失败概率或 BCO 扰动半径；须依上下文区分

D.7 Loss 与 reward 的约定

在线凸优化默认采用损失最小化语言；Bandit 课件若采用奖励最大化，将先转换为统一的损失或明确标注奖励形式，避免在同一推导中静默改变遗憾符号方向。

随机 MAB 与线性 Bandit 章节保留奖励最大化语言，并使用 $\bar{R}_T$ 表示伪遗憾；对抗 Bandit 采用损失最小化语言并使用 Reg_T 。