

经典统计学习笔记

Classical Statistical Learning Notes

目录

前言	1
阅读路线	1
记号约定	1
第一部分 几何与优化	2
第一章 线性模型统一视角	3
1.1 记号与偏置	3
1.2 线性回归的四种理解	3
1.3 感知机：用误分类推动更新	7
1.4 逻辑回归：从线性得分到概率	8
1.5 生成式与判别式：GDA	9
1.6 朴素贝叶斯：用条件独立减少参数	11
1.7 Fisher 线性判别：类内紧、类间远	11
1.8 本章对照	13
第二章 支持向量机与核方法	14
2.1 从几何间隔到硬间隔 SVM	14
2.2 拉格朗日函数、原问题与对偶问题	15
2.3 对偶的几何解释：读懂原稿中的图	16
2.4 Slater 条件：为什么“留有余地”有帮助	17
2.5 KKT 条件与硬间隔对偶的求解	20
2.6 软间隔：允许违反间隔	21
2.7 核技巧：只计算特征空间的内积	22
第三章 主成分分析	24
3.1 高维直觉与降维方法	24
3.2 中心化与协方差矩阵	24
3.3 最大方差视角	25
3.4 最小重构误差视角	26
3.5 SVD 与主坐标分析	27

3.6	概率 PCA: 保留原稿的概率视角	27
3.7	使用时的边界	28
第二部分 树模型与集成学习		29
第四章	决策树	30
4.1	一次划分解决什么问题	30
4.2	熵与信息增益	30
4.3	信息增益率: 处理多值偏好	31
4.4	Gini 指标与 CART	32
4.5	ID3、C4.5 与 CART	32
4.6	剪枝: 控制树的复杂度	32
第五章	提升方法与集成学习	34
5.1	为什么组合多个模型	34
5.2	AdaBoost 的迭代	34
5.3	从指数损失推导权重	35
5.4	训练误差为何可以下降	36
5.5	边界情况与理解范围	36
第三部分 概率建模与推断		38
第六章	指数族与最大熵	39
6.1	指数族的统一形式	39
6.2	两个例子	40
6.3	对数配分函数的导数	40
6.4	MLE 就是矩匹配	41
6.5	共轭先验与广义线性模型	41
6.6	最大熵: 只使用已知约束	42
6.7	配分函数与学习的共同结构	43
第七章	EM 算法与高斯混合模型	44
7.1	E 步与 M 步	44
7.2	单调性的第一种证明: $Q-H$ 分解	44
7.3	第二种理解: ELBO 与 KL	45
7.4	GMM: 用多个高斯解释多峰数据	46
7.5	GMM 的 E 步: 责任度	46
7.6	GMM 的 M 步: 加权估计	47
7.7	初始化、停止与局限	48
7.8	广义 EM 与近似后验: 少量衔接	48

第八章 概率图模型	49
8.1 表示、推断与学习	49
8.2 有向无环图：贝叶斯网络	49
8.3 无向图：马尔可夫随机场	51
8.4 从有向图到道德图，再到因子图	52
8.5 变量消除：调整求和顺序	52
8.6 树上的信念传播：sum-product	53
8.7 Max-product 与联合最优配置	54
8.8 高斯图模型	54
8.9 主线模型之间的联系	55
第九章 隐马尔可夫模型	56
9.1 模型、参数与假设	56
9.2 前向算法：把指数枚举变成递推	57
9.3 后向算法：从未来观测向前计算	58
9.4 滤波、平滑与预测	58
9.5 Baum-Welch: HMM 中的 EM	59
9.6 Viterbi: 最可能的完整路径	60
9.7 数值稳定性与连续状态的联系	60
第十章 条件随机场	61
10.1 从 HMM 到 MEMM: 局部归一化的限制	61
10.2 线性链 CRF 的条件分布	62
10.3 前向后向：计算配分函数与边缘	63
10.4 参数学习：经验特征减模型期望	64
10.5 译码：选择分数最高的路径	64
10.6 与 HMM 的对照	65
附录	66
附录 A MCMC	66
A.1 Monte Carlo 估计	66
A.2 马尔可夫链与平稳分布	67
A.3 转移矩阵的谱视角	68
A.4 Metropolis-Hastings: 修正提议使目标平稳	68
A.5 Gibbs 采样：每次更新一个条件分布	69
A.6 怎样看待 burn-in、相关性与诊断	70

前言

本笔记从几何、优化与概率推断三个视角，整理经典统计学习的模型、学习目标与核心推导。

全书分为三个部分。第一部分从线性模型出发，连接最大间隔、对偶与降维；第二部分讨论树的局部划分和弱学习器的组合；第三部分用概率分布、隐变量与图结构组织学习和推断。MCMC 作为附录，用来补充难以精确计算时的采样工具。

阅读路线

部分	章节	核心问题
几何与优化	1 线性模型；2 SVM 与核；3 PCA	表示、目标和几何结构如何相互联系
树与集成	4 决策树；5 AdaBoost	怎样划分数据，怎样组合简单模型
概率建模与推断	6 指数族；7 EM/GMM；8 图模型；9 HMM；10 CRF	怎样表达分布、处理隐变量并高效计算
附录 A	MCMC	怎样用相关样本近似目标期望

记号约定

N 通常表示样本数， p 表示输入维数； x_i 是列向量，数据矩阵 X 按行堆叠样本。 I 为单位矩阵， $\mathbf{1}$ 为全 1 向量。类别数或状态数用 K ，序列长度用 T 。均值、协方差与精度矩阵分别常记为 μ, Σ, Λ 。

非序列模型使用样本下标 i ；序列模型使用时间下标 t ，EM 的迭代次数用上标 (r) 。具体章节仍会说明局部记号。所有对数默认是自然对数，决策树的信息量例子使用底数 2。

第一部分

几何与优化

第一章 线性模型统一视角

许多经典模型从同一个线性得分 $w^\top x + b$ 出发，却赋予它不同含义：它可以是连续响应的预测值、决定类别的符号，也可以是对数几率。不同的损失函数、约束和概率假设，决定了我们怎样从数据中学习这个得分。

本章保留原稿的主线：先从四种视角理解线性回归，再比较感知机、逻辑回归、GDA、朴素贝叶斯和 Fisher 判别分析。

1.1 记号与偏置

训练集为 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ ，其中 $x_i \in \mathbb{R}^p$ 是列向量。设计矩阵把样本按行堆叠：

$$X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_N^\top \end{pmatrix} \in \mathbb{R}^{N \times p}, \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix} \in \mathbb{R}^N.$$

不显式写偏置时，可理解为数据已经中心化，或者已将常数特征 1 加入 x 。使用正则化时要另行说明是否惩罚偏置；通常偏置不受惩罚。回归中的 y_i 是实数；感知机采用 $\{-1, +1\}$ 标签；逻辑回归和 GDA 采用 $\{0, 1\}$ 标签。

1.2 线性回归的四种理解

1.2.1 矩阵视角：最小二乘与正规方程

模型预测为 $\hat{y}_i = x_i^\top w$ ，整体预测为 $\hat{Y} = Xw$ 。注意 Y 是观测值，通常不等于 Xw ；残差为

$$e = Y - Xw.$$

希望整体误差尽可能小，可最小化残差的欧氏范数。平方不会改变最优点，因此使用平方损失：

$$\begin{aligned}
L(w) &= \|Y - Xw\|_2^2 \\
&= (Y - Xw)^\top (Y - Xw) \\
&= Y^\top Y - 2w^\top X^\top Y + w^\top X^\top X w.
\end{aligned}$$

对 w 求导，并令梯度为零：

$$\nabla L(w) = 2X^\top Xw - 2X^\top Y = 0, \quad X^\top X\hat{w} = X^\top Y.$$

后一个式子称为**正规方程**。由于 Hessian 为 $2X^\top X \succeq 0$ ，损失是凸函数，满足正规方程的解就是全局最小点。

当 X 列满秩，即 $\text{rank}(X) = p$ 时，

$$\hat{w} = (X^\top X)^{-1} X^\top Y.$$

这里“半正定”并不足以保证可逆。利用 $\text{rank}(X^\top X) = \text{rank}(X)$ 可知：特征之间存在精确线性依赖，或 $p > N$ 时， $X^\top X$ 必然奇异；特征高度相关但并非精确相关时，则可能可逆却数值病态。

补充说明：秩不足时怎么办？最小二乘仍有解，预测向量仍唯一，参数可能不唯一。最小范数解为 $\hat{w} = X^+ Y$ 。若紧致 SVD 为 $X = U_r D_r V_r^\top$ ，则

$$X^+ = V_r D_r^{-1} U_r^\top.$$

只对非零奇异值取倒数。数值计算通常直接采用 QR 或 SVD，不必显式计算矩阵逆。

1.2.2 几何视角：到列空间的正交投影

所有可能的 Xw 都位于 $\text{Col}(X)$ 。最小二乘是在这个子空间中，寻找距离 Y 最近的点 $\hat{Y}$ 。

由正规方程：

$$X^\top (Y - X\hat{w}) = 0, \quad X^\top e = 0.$$

记 X 的第 j 列为 $X_{:j}$ ，则上式意味着 $X_{:j}^\top e = 0$ 对每一列成立。因此 e 垂直于整个列空间：

$$Y = \hat{Y} + e, \quad \hat{Y} \in \text{Col}(X), \quad e \in \text{Col}(X)^\perp.$$

列满秩时，投影矩阵为




图 1.1: 最小二乘的正交投影。图中用一维子空间表示列空间；残差连接预测点与观测点，并与子空间垂直。

$$P = X(X^\top X)^{-1}X^\top, \quad \hat{Y} = PY.$$

它满足 $P^\top = P$ 和 $P^2 = P$ 。第二个性质表示：已经投影到子空间里的点，再投影一次不会改变。秩不足时可统一写成 $P = XX^+$ 。

1.2.3 频率学派视角：最小二乘等价于高斯噪声下的 MLE

假设

$$y_i = x_i^\top w + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2), \quad \sigma^2 > 0.$$

于是条件密度为

$$p(y_i | x_i, w) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_i - x_i^\top w)^2}{2\sigma^2}\right].$$

给定 X ，样本条件独立，因此似然是各项密度的乘积。取对数，把连乘转为求和：

$$\begin{aligned} \ell(w) &= \log p(Y | X, w) \\ &= -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - x_i^\top w)^2. \end{aligned}$$

固定 σ^2 时，第一项与 w 无关，第二项前的系数为负，所以

$$\arg \max_w \ell(w) = \arg \min_w \|Y - Xw\|_2^2.$$

平方损失既有几何解释，也有概率解释。类似地，独立、同尺度的 Laplace 噪声对应绝对值损失。这说明许多损失可以解释为数据生成假设下的负对数似然，但并非所有人为设计的损失都必须来自概率模型。

1.2.4 贝叶斯视角：岭回归等价于高斯先验下的 MAP

当数据不足或特征相关性强时，参数估计可能很不稳定。岭回归在拟合误差之外惩罚参数大小：

$$J(w) = \|Y - Xw\|_2^2 + \lambda \|w\|_2^2, \quad \lambda > 0.$$

求导得

$$-2X^\top Y + 2X^\top Xw + 2\lambda w = 0,$$

所以

$$\hat{w} = (X^\top X + \lambda I)^{-1} X^\top Y.$$

对任意非零 v ， $v^\top (X^\top X + \lambda I)v = \|Xv\|^2 + \lambda \|v\|^2 > 0$ ，故该矩阵正定可逆。约束形式 $\min_w \|Y - Xw\|^2$ 、 $\|w\|^2 \leq c$ 与惩罚形式通过拉格朗日乘子联系；对应的 c 和 λ 需要匹配，不是任意取值都相同。

现在引入先验 $w \sim \mathcal{N}(0, \tau^2 I)$ 。贝叶斯公式给出

$$p(w \mid X, Y) \propto p(Y \mid X, w)p(w).$$

最大化后验等价于最大化对数后验：

$$\log p(w \mid X, Y) = C - \frac{1}{2\sigma^2} \|Y - Xw\|^2 - \frac{1}{2\tau^2} \|w\|^2.$$

乘以 $-2\sigma^2$ 后，得到岭回归目标，且

$$\lambda = \frac{\sigma^2}{\tau^2}.$$

先验越集中, τ^2 越小, 正则化越强。高斯先验对应 L_2 正则化; 独立 Laplace 先验对应 L_1 正则化, 二者在原 cheatsheet 中写反了。

补充说明: 点估计与完整后验。 MLE 和 MAP 都只输出一个参数值。若保留高斯后验, 并设一般先验协方差为 $\Sigma_p \succ 0$, 则配方可得

$$\begin{aligned}\Sigma_w &= (\sigma^{-2} X^\top X + \Sigma_p^{-1})^{-1}, \\ \mu_w &= \sigma^{-2} \Sigma_w X^\top Y, \\ p(y_* | x_*, X, Y) &= \mathcal{N}(x_*^\top \mu_w, x_*^\top \Sigma_w x_* + \sigma^2).\end{aligned}$$

预测方差包含参数不确定性与观测噪声两部分; 本书不另展开贝叶斯线性回归专题。

1.3 感知机: 用误分类推动更新

感知机以线性得分的符号进行二分类:

$$\hat{y} = \text{sign}(w^\top x + b), \quad y \in \{-1, +1\}.$$

正确分类且不落在边界上等价于 $y_i(w^\top x_i + b) > 0$ 。线性可分假设是: 存在一组参数, 使所有训练样本都满足这个条件。

最直观的目标是误分类数 $\sum_i \mathbf{1}\{y_i(w^\top x_i + b) \leq 0\}$, 但它不适合直接做梯度优化。感知机使用替代损失

$$L(w, b) = \sum_i \max\{0, -y_i(w^\top x_i + b)\}.$$

对于得分非正的样本, 选择次梯度 $(-y_i x_i, -y_i)$, 更新为

$$w \leftarrow w + \eta y_i x_i, \quad b \leftarrow b + \eta y_i.$$

这一步把参数推向能提高该样本正确类别得分的方向。边界处损失虽然为零, 算法仍可选择上述次梯度更新, 因此停止条件应检查是否还有 $y_i f_i \leq 0$ 的样本, 不能只检查损失是否为零。

在线性可分、有限训练集及标准固定正步长等条件下, 感知机在有限次错误更新后找到分离超平面。不可分数据则不保证终止。它找到的是一个分隔面, 不直接优化最大间隔。

1.4 逻辑回归：从线性得分到概率

1.4.1 从对数几率得到 sigmoid

令 $p = P(y = 1 | x)$, 则 $P(y = 0 | x) = 1 - p$ 。几率为 $p/(1 - p)$ 。逻辑回归假设对数几率是线性的：

$$\log \frac{p}{1 - p} = w^\top x + b = z.$$

依次指数化、移项： $p = e^z(1 - p)$, 所以

$$p = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}} = \sigma(z).$$

这不是给预测值随意套一个函数，而是对条件概率作出了具体假设。

1.4.2 Bernoulli 似然与交叉熵

采用 $y_i \in \{0, 1\}$, 令 $p_i = \sigma(w^\top x_i + b)$:

$$p(y_i | x_i, w, b) = p_i^{y_i} (1 - p_i)^{1 - y_i}.$$

对独立样本取负对数似然：

$$L(w, b) = - \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

这就是二元交叉熵。其符号与对数似然相反：最大化对数似然等价于最小化交叉熵。

1.4.3 梯度的逐步推导

因为 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$, 单个样本的梯度为

$$\begin{aligned} \frac{\partial L_i}{\partial z_i} &= \left(-\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i} \right) p_i(1 - p_i) \\ &= -y_i(1 - p_i) + (1 - y_i)p_i = p_i - y_i. \end{aligned}$$

再利用 $\partial z_i / \partial w = x_i$, 得到

$$\nabla_w L = \sum_i (p_i - y_i) x_i, \quad \frac{\partial L}{\partial b} = \sum_i (p_i - y_i).$$

可用梯度下降或随机梯度下降。阈值取 $1/2$ 时，决策边界仍为 $w^\top x + b = 0$ 。补充：完全可分的数据上，无正则化逻辑回归可能没有有限的 MLE；参数可以持续变大而使损失趋近零。

1.5 生成式与判别式：GDA

判别式概率模型直接学习 $p(y | x)$ ；生成式模型学习 $p(x, y) = p(x | y)p(y)$ ，再利用贝叶斯公式分类。直接学习决策函数的感知机、SVM 也属于判别式方法，但不必输出概率。

1.5.1 共享协方差的高斯假设

GDA 假设

$$y \sim \text{Bernoulli}(\phi), \quad x | y = k \sim \mathcal{N}(\mu_k, \Sigma), \quad k \in \{0, 1\}.$$

这里两个类别共享 $\Sigma \succ 0$ 。参数是 $\theta = (\phi, \mu_0, \mu_1, \Sigma)$ ，训练时最大化联合似然；没有参数先验时这是 MLE，不是 MAP。

$$\ell(\theta) = \sum_i \left[y_i \log \phi + (1 - y_i) \log(1 - \phi) + \log \mathcal{N}(x_i | \mu_{y_i}, \Sigma) \right].$$

1.5.2 类别比例与均值

对 ϕ 求导：

$$\sum_i \left(\frac{y_i}{\phi} - \frac{1 - y_i}{1 - \phi} \right) = 0 \quad \Rightarrow \quad \hat{\phi} = \frac{N_1}{N}.$$

对 μ_1 ，只需保留 $y_i = 1$ 的二次项：

$$\min_{\mu_1} \sum_i y_i (x_i - \mu_1)^\top \Sigma^{-1} (x_i - \mu_1).$$

梯度为 $-2\Sigma^{-1} \sum_i y_i (x_i - \mu_1)$ 。令其为零得到

$$\hat{\mu}_1 = \frac{\sum_i y_i x_i}{N_1}, \quad \hat{\mu}_0 = \frac{\sum_i (1 - y_i) x_i}{N_0}.$$

这里要求两类均有样本。

1.5.3 共享协方差

令 $R = \sum_i (x_i - \hat{\mu}_{y_i})(x_i - \hat{\mu}_{y_i})^\top$ ，与协方差有关的对数似然为

$$-\frac{N}{2} \log |\Sigma| - \frac{1}{2} \text{tr}(\Sigma^{-1} R).$$

为避免错误交换矩阵乘法次序，改用精度矩阵 $\Lambda = \Sigma^{-1}$ 求导：

$$\frac{\partial}{\partial \Lambda} \left[\frac{N}{2} \log |\Lambda| - \frac{1}{2} \text{tr}(\Lambda R) \right] = \frac{N}{2} \Lambda^{-1} - \frac{1}{2} R.$$

因此

$$\hat{\Sigma} = \frac{R}{N} = \frac{N_0 S_0 + N_1 S_1}{N}, \quad S_k = \frac{1}{N_k} \sum_{i: y_i = k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top.$$

S_k 是使用 N_k 分母类内经验协方差，不是无偏估计。若该矩阵奇异，实际使用时需要正则化等处理。

1.5.4 为什么得到线性边界

补充推导。 对后验几率取对数，归一化项抵消：

$$\log \frac{p(y=1|x)}{p(y=0|x)} = \log \frac{\phi}{1-\phi} - \frac{1}{2} (x - \mu_1)^\top \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_0)^\top \Sigma^{-1} (x - \mu_0).$$

共享协方差使 $x^\top \Sigma^{-1} x$ 抵消，结果为 $w^\top x + b$ ，其中

$$w = \Sigma^{-1} (\mu_1 - \mu_0),$$

$$b = \log \frac{\phi}{1-\phi} - \frac{1}{2} \mu_1^\top \Sigma^{-1} \mu_1 + \frac{1}{2} \mu_0^\top \Sigma^{-1} \mu_0.$$

因此后验也具有 sigmoid 形式，但参数由联合分布拟合得到。若两类协方差不同，二次项通常不抵消，得到二次判别边界。

1.6 朴素贝叶斯：用条件独立减少参数

直接估计高维 $p(x | y)$ 需要大量数据。朴素贝叶斯作出更强的结构假设：给定类别后，所有特征联合条件独立：

$$p(x | y = k) = \prod_{j=1}^p p(x_j | y = k).$$

于是

$$p(y = k | x) = \frac{p(y = k) \prod_j p(x_j | y = k)}{p(x)}.$$

分类时分母对各类别相同，可比较对数得分

$$\log p(y = k) + \sum_j \log p(x_j | y = k).$$

连续特征可假设 $x_j | y = k \sim \mathcal{N}(\mu_{kj}, \sigma_{kj}^2)$ ；离散特征可用类别分布 $P(x_j = a | y = k) = \theta_{kja}$ 。前者按类别估计各维均值和方差，后者按频数估计概率；必要时加入平滑，避免未出现事件使整个乘积为零。

这里的“朴素”不是不学习参数，而是减少维度之间的依赖建模。一个足够贴合问题的简单假设，可能比数据不足时的复杂模型更有效。

朴素贝叶斯并非总有线性边界。例如高斯朴素贝叶斯允许类间方差不同，得分差中会出现 x_j^2 。它放在本章，是为了比较生成式与判别式建模。

1.7 Fisher 线性判别：类内紧、类间远

1.7.1 投影后的类内方差

考虑两类 C_0, C_1 ，均值为 μ_0, μ_1 。沿 w 投影为标量 $z = w^\top x$ ，投影后均值是 $\bar{z}_k = w^\top \mu_k$ 。

沿用纸质稿的类内经验协方差 S_k ，投影方差为

$$\begin{aligned} \text{Var}(z | C_k) &= \frac{1}{N_k} \sum_{i \in C_k} [w^\top (x_i - \mu_k)]^2 \\ &= w^\top \left[\frac{1}{N_k} \sum_{i \in C_k} (x_i - \mu_k)(x_i - \mu_k)^\top \right] w \\ &= w^\top S_k w. \end{aligned}$$

1.7.2 Rayleigh 商与最优方向

两类投影均值的距离平方为

$$(\bar{z}_1 - \bar{z}_0)^2 = w^\top (\mu_1 - \mu_0)(\mu_1 - \mu_0)^\top w.$$

令 $S_b = (\mu_1 - \mu_0)(\mu_1 - \mu_0)^\top$ 、 $S_w = S_0 + S_1$ ，最大化

$$J(w) = \frac{w^\top S_b w}{w^\top S_w w}.$$

分子要求类间远，分母要求类内紧；同时缩放 w 不改变比值。对称矩阵的二次型梯度给出

$$\nabla J(w) = \frac{2S_b w(w^\top S_w w) - 2S_w w(w^\top S_b w)}{(w^\top S_w w)^2}.$$

令其为零，得到 $S_b w = J(w)S_w w$ 。若 $S_w \succ 0$ 且均值不同，因为 $S_b w = (\mu_1 - \mu_0)[(\mu_1 - \mu_0)^\top w]$ ，最优方向为

$$w \propto S_w^{-1}(\mu_1 - \mu_0).$$

也可令 $v = S_w^{1/2}w$ ，用 Cauchy-Schwarz 不等式证明该方向取得全局最大值。方向确定后还需选择阈值，才能形成分类器。




图 1.2: Fisher 投影的几何直觉：同一批数据沿不同方向投影，类别分离程度不同。

约定说明。许多教材用类内散度 $\sum_k N_k S_k$ 定义 S_w ，而原稿用 $S_0 + S_1$ 。样本数不等时，两者一般不是常数倍。共享协方差 GDA 与标准 Fisher 方向的对应，需要采用匹配的加权约定。

1.8 本章对照

方法	线性量的含义	学习原则
最小二乘	响应均值或预测值	平方损失；高斯噪声下的 MLE
岭回归	带收缩的预测值	平方损失加 L_2 ；高斯先验下的 MAP
感知机	分类得分	对误分类点更新
逻辑回归	条件对数几率	Bernoulli 条件似然
共享协方差 GDA	由联合模型导出的对数几率	联合似然
朴素贝叶斯	各特征条件对数概率之和	联合条件独立假设
Fisher 判别	一维投影坐标	最大化类间与类内离散程度之比

本章需要掌握的是：同样的线性表达可以来自不同的建模假设；相似的最终形式，并不意味着训练目标或适用条件相同。

第二章 支持向量机与核方法

SVM 的三条主线是**间隔**、**对偶**、**核技巧**。本章先把“分得更稳”写成优化问题，再解释为什么对偶能够求解它，最后推广到不可分数据和非线性边界。

2.1 从几何间隔到硬间隔 SVM

设 $y_i \in \{-1, +1\}$ ，分类超平面为 $w^\top x + b = 0$ ， $w \neq 0$ 。样本到超平面的距离为

$$\frac{|w^\top x_i + b|}{\|w\|_2}.$$

当所有点正确分类时，绝对值可写成 $y_i(w^\top x_i + b)$ 。训练集的几何间隔就是最近样本的距离：

$$\gamma(w, b) = \min_i \frac{y_i(w^\top x_i + b)}{\|w\|_2}.$$

这里对样本下标 i 取最小值；参数 w, b 在外层选择。线性可分时，目标是最大化这个最小距离。

2.1.1 为什么可以把最小函数间隔设为 1

同时将 (w, b) 乘以正数 c ，超平面与几何间隔都不改变。设某分离参数满足

$$r = \min_i y_i(w^\top x_i + b) > 0.$$

用 $(w/r, b/r)$ 表示同一超平面，就得到最小函数间隔为 1。于是最大化几何间隔等价于

$$\min_{w, b} \frac{1}{2} \|w\|_2^2 \quad \text{使得} \quad y_i(w^\top x_i + b) \geq 1 \quad (i = 1, \dots, N).$$

最优解处至少有一个约束取等号，否则还能共同缩小参数，降低目标。两条间隔边界分别为 $w^\top x + b = \pm 1$ ；单侧间隔为 $1/\|w\|$ ，总宽度为 $2/\|w\|$ 。




图 2.1: 硬间隔分类: 实线是决策边界, 虚线是两侧间隔边界, 圈出的点位于间隔边界上。

2.2 拉格朗日函数、原问题与对偶问题

将约束写成 $g_i(w, b) = 1 - y_i(w^\top x_i + b) \leq 0$, 引入 $\alpha_i \geq 0$:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2}w^\top w + \sum_i \alpha_i [1 - y_i(w^\top x_i + b)].$$

2.2.1 原问题为何是先对乘子取上确界

固定 w, b 。若它可行, 每项 $\alpha_i g_i \leq 0$, 选择 $\alpha = 0$ 使上确界等于原目标。若某个约束 $g_i > 0$, 令对应乘子趋于正无穷, 上确界就是 $+\infty$ 。因此

$$p^* = \inf_{w, b} \sup_{\alpha \geq 0} \mathcal{L}(w, b, \alpha).$$

定义对偶函数与对偶最优值:

$$q(\alpha) = \inf_{w, b} \mathcal{L}(w, b, \alpha), \quad d^* = \sup_{\alpha \geq 0} q(\alpha).$$

使用 $\inf, \sup$ 是为了允许最优值无法在有限参数处取得; 确认可取到时才写 $\min, \max$ 。

2.2.2 弱对偶：下界永远不超过原问题最优值

对任意原问题可行点 (w, b) 和任意 $\alpha \geq 0$:

$$q(\alpha) \leq \mathcal{L}(w, b, \alpha) \leq \frac{1}{2} \|w\|^2.$$

左边先对乘子取上确界，右边再对可行点取下确界，得到

$$d^* \leq p^*.$$

这不要原问题凸，也不要最优值达到。原稿用“先在各组中选小的，再从中选大的”帮助记忆极大极小关系；严格依据是上述对任意可行点成立的不等式。

2.3 对偶的几何解释：读懂原稿中的图

先考虑一个约束的通用问题

$$\inf_{x \in D} f(x) \quad \text{使得} \quad m(x) \leq 0.$$

引入约束值和目标值坐标

$$u = m(x), \quad t = f(x), \quad G = \{(m(x), f(x)) : x \in D\}.$$

图的横轴是**约束值**，纵轴是**目标值**，不是输入数据的两个特征。原问题最优值是 G 中位于 $u \leq 0$ 一侧的最低纵坐标：

$$p^* = \inf\{t : (u, t) \in G, u \leq 0\}.$$

固定乘子 $\lambda \geq 0$,

$$q(\lambda) = \inf_{(u, t) \in G} (t + \lambda u).$$

等值线 $t + \lambda u = c$ 是斜率为 $-\lambda$ 的直线。由下向上移动它，使整条直线仍不高于 G 的任一点，最大可达到的截距就是 $q(\lambda)$ 。对偶问题进一步选择斜率，尽量抬高这个截距。

对可行点 $u \leq 0$ ，有 $t \geq q(\lambda) - \lambda u \geq q(\lambda)$ ，因此截距是原问题的下界。

为使图意可以核算，取 $G = \{(-1, 2), (0, 2), (1, 0)\}$ 。这相当于一个有三个候选点的非凸问题：




图 2.2: 弱对偶与正对偶间隙的补充例子。可达集合只有三个点；可行点的最低值为 2，最高下支撑线的截距为 1。

$$p^* = 2, \quad q(\lambda) = \min\{2 - \lambda, 2, \lambda\}.$$

在 $\lambda = 1$ 时下界最大，为 $d^* = 1$ 。这里存在严格可行点 $u = -1$ ，却仍有间隙，说明**没有凸性**，仅有严格可行点不足以保证强对偶。

2.4 Slater 条件：为什么“留有余地”有帮助

2.4.1 条件的准确表述

考虑凸优化问题

$$\min_{x \in D} f_0(x) \quad \text{使得} \quad f_i(x) \leq 0 \quad (i = 1, \dots, m), \quad Ax = b,$$

其中 f_0, f_i 为凸函数，等式约束是仿射的。标准 Slater 条件要求存在

$$\bar{x} \in \text{relint}(D), \quad f_i(\bar{x}) < 0 \text{ 对所有 } i, \quad A\bar{x} = b.$$

D 是相关函数的公共定义域， relint 是相对内部：在定义域自身的仿射空间里考虑内部，而不要在整个环境空间中包含一个球。等式始终要精确满足，不改成严格不等式。

在上述凸性与 Slater 条件下, 强对偶成立; 若原问题最优值有限, 还能保证存在取得对偶最优值的乘子。该条件是充分条件, 并非强对偶的必要条件。

当部分 f_i 是仿射函数时, **放宽的 Slater 条件**只要求非仿射不等式严格满足, 仿射不等式可以非严格满足; 仍需公共定义域相对内部和等式约束条件。目标函数本身不要求严格凸。

2.4.2 几何上究竟排除了什么

原稿把严格可行点理解为“有一处真正进入了约束内部”。在单不等式图中, 它表现为存在 $u < 0$ 的可达点。

需要注意: 即使原问题是凸问题, 精确像集 $G = \{(m(x), f(x))\}$ 也不一定是凸集。用于分离论证的是其向上、向右扩展的集合

$$\mathcal{A} = \{(u, t) : \exists x \in D, m(x) \leq u, f(x) \leq t\}.$$

凸性保证这个扩展集合凸。严格可行性帮助排除只含约束方向、无法正规化为目标系数 1 的退化分离超平面。由此可以得到有限斜率的支持关系, 令对偶下界达到原最优值。图解服务于直觉, 不能把“有支撑线”本身当作未附条件的证明。

2.4.3 有 Slater 条件的具体例子

补充例子:

$$\min_x (x-1)^2 \quad \text{使得} \quad x \leq 0.$$

$\bar{x} = -1$ 严格可行; 最优点为 $x^* = 0$, $p^* = 1$ 。对偶函数通过配方得到:

$$\begin{aligned} q(\lambda) &= \inf_x [(x-1)^2 + \lambda x] \\ &= \inf_x [x - (1 - \lambda/2)]^2 + \lambda - \lambda^2/4 \\ &= \lambda - \lambda^2/4. \end{aligned}$$

在 $\lambda^* = 2$ 达到最大值 1。图中 $u = x, t = (u-1)^2$; 直线 $t = 1 - 2u$ 在 $(0, 1)$ 处支撑抛物线, 其截距恰好为 $p^* = d^* = 1$ 。

严格可行点不需要是最优点。将“最优解在边界上”误认为“不满足 Slater”, 是很容易产生的混淆。




图 2.3: Slater 条件成立的例子：左侧点提供严格可行性，最优点可以仍位于边界上。右图显示有限最优乘子。

2.4.4 不满足 Slater，不等于必有对偶间隙

补充反例：

$$\min_x \text{ 使得 } x^2 \leq 0.$$

唯一可行点为 $x = 0$ ，所以 $p^* = 0$ ，但不存在 $x^2 < 0$ 。对于 $\lambda > 0$ ，

$$q(\lambda) = \inf_x (x + \lambda x^2) = -\frac{1}{4\lambda}; \quad q(0) = -\infty.$$

于是 $d^* = \sup_{\lambda \geq 0} q(\lambda) = 0 = p^*$ ，但没有有限的最优乘子，只有 $\lambda \rightarrow \infty$ 时逼近。




图 2.4: 没有严格可行点但仍为零间隙：下支撑线截距趋于 0，斜率绝对值却趋于无穷，不能获得有限最优乘子。

这也解释了原稿边注中的“ $\lambda \rightarrow +\infty$ ”：它可以表示**对偶最优值不取到**，不必然表示正对偶间隙。

2.4.5 为什么硬间隔 SVM 满足条件

有限样本线性可分时，存在 (w_0, b_0) ，使 $r = \min_i y_i(w_0^\top x_i + b_0) > 0$ 。取 $c > 1/r$ ，则

$$y_i(cw_0^\top x_i + cb_0) > 1 \quad \text{对所有 } i.$$

因此每个不等式都严格满足。目标为凸二次函数，约束是仿射函数，定义域为整个参数空间，故强对偶成立。

2.5 KKT 条件与硬间隔对偶的求解

2.5.1 四组条件

对于可微的凸问题，一组原始变量与乘子满足 KKT 条件时，足以证明全局最优；Slater 等约束资格条件使 KKT 也成为最优解的必要条件。

在 SVM 中，KKT 写成：

$$\begin{aligned} y_i(w^\top x_i + b) &\geq 1 && \text{原始可行性,} \\ \alpha_i &\geq 0 && \text{对偶可行性,} \\ \alpha_i[1 - y_i(w^\top x_i + b)] &= 0 && \text{互补松弛,} \\ w - \sum_i \alpha_i y_i x_i = 0, \quad \sum_i \alpha_i y_i &= 0 && \text{驻点条件.} \end{aligned}$$

互补松弛可以从强对偶推导。对原始、对偶最优解：

$$d^* = \inf_{w, b} \mathcal{L}(w, b, \alpha^*) \leq \mathcal{L}(w^*, b^*, \alpha^*) \leq f_0(w^*, b^*) = p^*.$$

若 $p^* = d^*$ ，两处不等式必须取等号。由于每个 $\alpha_i^* g_i(w^*, b^*) \leq 0$ ，而它们之和为零，每一项都只能为零。第一处等号说明原始最优点同时最小化固定乘子下的拉格朗日函数，得到驻点条件。

2.5.2 消去 w, b

固定 α ，对 b 求导得到 $\sum_i \alpha_i y_i = 0$ ；若不满足，该线性项可使下确界为 $-\infty$ 。

对 w 求导得到 $w = \sum_i \alpha_i y_i x_i$ 。代入原式：

$$q(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j.$$

故对偶问题为

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j, \\ \text{使得} \quad & \alpha_i \geq 0, \quad \sum_i \alpha_i y_i = 0. \end{aligned}$$

等式约束不能省略。

2.5.3 支持向量与偏置

得到 α^* 后,

$$w^* = \sum_i \alpha_i^* y_i x_i.$$

若 $\alpha_k^* > 0$, 互补松弛给出 $y_k(w^{*\top} x_k + b^*) = 1$, 利用 $y_k^2 = 1$ 得到

$$b^* = y_k - w^{*\top} x_k.$$

可以对多个满足条件的支持向量计算偏置后取平均, 以减轻数值误差。 $\alpha_i > 0$ 蕴含点在间隔边界上; 反过来, 退化情况下边界点的乘子可能为零, 不应将这两句话无条件等同。

2.6 软间隔: 允许违反间隔

真实数据可能不可分。令 $z_i = y_i(w^\top x_i + b)$, hinge loss 为

$$\ell_{\text{hinge}}(z_i) = \max\{0, 1 - z_i\}.$$

它惩罚的不仅是误分类点, 还包括正确分类但离边界太近的点。原稿的 $\mathbf{1}\{z_i < 1\}$ 应称为间隔违约指示损失; 通常的分类 0-1 损失使用阈值 0。

软间隔的无约束目标为

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_i \max\{0, 1 - y_i(w^\top x_i + b)\}, \quad C > 0.$$

此处不能再附加硬间隔约束，否则所有 hinge 项都被强制为零。引入松弛变量得到等价形式：

$$\min_{w,b,\xi} \quad \frac{1}{2}\|w\|^2 + C \sum_i \xi_i,$$

$$\text{使得} \quad y_i(w^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

固定 w, b , 由于目标随 ξ_i 严格递增, 最优时 $\xi_i = \max\{0, 1 - z_i\}$, 而不是对所有样本写成 $\xi_i = 1 - z_i$ 。

2.6.1 软间隔对偶与乘子的含义（补充推导）

为 $1 - \xi_i - z_i \leq 0$ 引入 $\alpha_i \geq 0$, 为 $-\xi_i \leq 0$ 引入 $\mu_i \geq 0$ 。对 ξ_i 的驻点条件为

$$C - \alpha_i - \mu_i = 0 \implies 0 \leq \alpha_i \leq C.$$

其余驻点条件与硬间隔相同，因此对偶目标不变，约束变为

$$0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0.$$

乘子	KKT 推出的情况
$\alpha_i = 0$	$\xi_i = 0, z_i \geq 1$
$0 < \alpha_i < C$	$\xi_i = 0, z_i = 1$, 可用于直接计算 b
$\alpha_i = C$	$z_i = 1 - \xi_i \leq 1$, 可能在间隔内, 也可能误分类

如果没有 $0 < \alpha_i < C$ 的点，需根据 KKT 的不等式确定偏置区间，不能随意取一个 $\alpha_i = C$ 的点套用硬间隔公式。

2.7 核技巧：只计算特征空间的内积

补充整理：原稿仅给出核方法概述，本节补足本章主线。

设特征映射 $\varphi(x)$ 把输入送入某个内积空间。对偶目标和预测只依赖 $\langle \varphi(x_i), \varphi(x_j) \rangle$ ，因此定义

$$k(x, x') = \langle \varphi(x), \varphi(x') \rangle.$$

将对偶中的 $x_i^\top x_j$ 换成 $k(x_i, x_j)$ 即可。预测为

$$\hat{y}(x) = \text{sign} \left[\sum_i \alpha_i^* y_i k(x_i, x) + b^* \right].$$

核函数让我们隐式使用特征空间，不必显式构造所有坐标。

2.7.1 合法核的条件

对实值对称函数，标准正定核条件是：对任意有限点集，Gram 矩阵 $K_{ij} = k(x_i, x_j)$ 均半正定，即 $c^\top K c \geq 0$ 对任意 c 成立。仅仅“对称”或“函数值为正”都不够。

常见核为

$$\begin{aligned} k(x, x') &= x^\top x' && \text{线性核,} \\ k(x, x') &= (x^\top x' + c)^d, c \geq 0, d \in \mathbb{N}^+ && \text{多项式核,} \\ k(x, x') &= \exp[-\|x - x'\|^2 / (2s^2)], s > 0 && \text{高斯核.} \end{aligned}$$

例如二维二次齐次核对应

$$\varphi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)^\top, \text{quad} \varphi(x)^\top \varphi(x') = (x^\top x')^2.$$

必须掌握的关系是：**几何间隔给出原问题，强对偶支持对偶求解，KKT 解释支持向量，对偶中的内积结构使核化成为可能。**

第三章 主成分分析

降维希望用较少坐标保留数据中重要的变化。它可以降低存储和计算成本，也可能减轻估计困难；但若丢掉与任务相关的信息，预测反而会变差，因此不能把降维称为普遍“最好”的防过拟合方法。

3.1 高维直觉与降维方法

半径 R 的 p 维球体积为 $V_p R^p$ ，其中 $V_p = \pi^{p/2}/\Gamma(p/2 + 1)$ 。它与外接超立方体的体积之比为

$$\frac{V_p R^p}{(2R)^p} = \frac{\pi^{p/2}}{2^p \Gamma(p/2 + 1)} \rightarrow 0 \quad (p \rightarrow \infty).$$

原稿中的极限下标应为维度趋于无穷，常数 V_p 也依赖维度。这个例子说明高维几何与低维直觉不同；它本身不能证明任意真实数据都集中在立方体边界上。

降维可以是特征选择，也可以是构造新坐标。PCA 是线性降维；经典 MDS/PCoA 从距离或 Gram 矩阵构造坐标；Isomap、LLE 等流形方法处理更一般的非线性结构。本章重点是 PCA。

3.2 中心化与协方差矩阵

仍用 $X \in \mathbb{R}^{N \times p}$ 表示按行排列的数据。令 $\mathbf{1} \in \mathbb{R}^N$ 为全 1 向量：

$$H = I_N - \frac{1}{N} \mathbf{1} \mathbf{1}^\top, \quad X_c = HX, \quad \bar{x} = \frac{1}{N} \sum_i x_i.$$

X_c 的第 i 行是 $(x_i - \bar{x})^\top$ 。由 $\mathbf{1}^\top \mathbf{1} = N$ ：

$$H^\top = H, \quad H^2 = I_N - \frac{2}{N} \mathbf{1} \mathbf{1}^\top + \frac{1}{N^2} \mathbf{1} (\mathbf{1}^\top \mathbf{1}) \mathbf{1}^\top = H.$$

所以 H 是投影到 $\mathbf{1}^\perp$ 的正交投影矩阵。经验协方差为

$$S = \frac{1}{N} \sum_i (x_i - \bar{x})(x_i - \bar{x})^\top = \frac{1}{N} X_c^\top X_c = \frac{1}{N} X^\top H X.$$

使用 $1/(N-1)$ 会改变特征值尺度，不改变主成分方向。

3.3 最大方差视角

3.3.1 一个投影方向

对单位向量 u ，中心化后的投影坐标为 $z_i = u^\top(x_i - \bar{x})$ ，均值为零，方差为

$$\frac{1}{N} \sum_i z_i^2 = u^\top S u.$$

因此第一主成分求解

$$\max_{u^\top u=1} u^\top S u.$$

构造 $\mathcal{L}(u, \lambda) = u^\top S u - \lambda(u^\top u - 1)$ ，驻点条件为

$$2S u - 2\lambda u = 0 \implies S u = \lambda u.$$

若 S 的特征值按 $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ 排列，最大值是 λ_1 ，方向是其对应单位特征向量。

3.3.2 多个投影方向

令 $U_q = (u_1, \dots, u_q) \in \mathbb{R}^{p \times q}$ 。必须同时要求正交归一：

$$\max_{U_q^\top U_q = I_q} \text{tr}(U_q^\top S U_q) = \max \sum_{j=1}^q u_j^\top S u_j.$$

只要求每个向量长度为 1 或“线性无关”都不够；分别独立最大化会重复选同一最大特征方向。正交约束下选择前 q 个特征向量，最大值为 $\sum_{j=1}^q \lambda_j$ 。

3.4 最小重构误差视角

正交完备基允许将中心化样本展开为

$$x_i - \bar{x} = \sum_{j=1}^p [u_j^\top (x_i - \bar{x})] u_j.$$

保留前 q 项得到重构

$$\hat{x}_i = \bar{x} + U_q U_q^\top (x_i - \bar{x}).$$

利用正交性，残差平方为剩余坐标的平方和：

$$\begin{aligned} \frac{1}{N} \sum_i \|x_i - \hat{x}_i\|^2 &= \frac{1}{N} \sum_i \sum_{j=q+1}^p [u_j^\top (x_i - \bar{x})]^2 \\ &= \text{tr}(S) - \text{tr}(U_q^\top S U_q). \end{aligned}$$

总方差固定，所以最小重构误差与最大保留方差是同一问题。最小误差是 $\sum_{j=q+1}^p \lambda_j$ 。




图 3.1: PCA 保留最大方差方向；正交投影给出低维表示，垂直线段表示被舍弃的残差。

3.5 SVD 与主坐标分析

3.5.1 直接分解中心化数据

采用紧致 SVD: $X_c = UDV^\top$, D 的对角元为 $d_1 \geq \dots \geq d_r > 0$ 。则

$$S = \frac{1}{N}VD^2V^\top.$$

因此右奇异向量 V 给出特征方向, $\lambda_j = d_j^2/N$ 。降维坐标为

$$Z = X_c V_q = U_q D_q,$$

其中此式的 U_q 指左奇异向量的前 q 列, 区别于上一节通用的投影基记号。原数据的重构为 $\mathbf{1}\bar{x}^\top + ZV_q^\top$ 。

3.5.2 从样本 Gram 矩阵得到坐标

定义

$$T = X_c X_c^\top = HXX^\top H = UD^2U^\top.$$

若其前 q 个正特征值为 $\rho_j = d_j^2$, 对应向量构成 U_q , 则坐标为 $U_q \text{diag}(\sqrt{\rho_1}, \dots, \sqrt{\rho_q})$ 。

S 是 $p \times p$, T 是 $N \times N$ 。当 $N \ll p$ 时, 从后者求解可能更方便。补充: 经典 PCoA 常从平方距离矩阵 $D^{(2)}$ 出发, 双中心化得到 $T = -\frac{1}{2}HD^{(2)}H$; 对于欧氏距离, 这与中心化数据的 Gram 矩阵一致。

3.6 概率 PCA: 保留原稿的概率视角

设 $z \in \mathbb{R}^q$ 为低维隐变量:

$$z \sim \mathcal{N}(0, I_q), \quad x = Wz + \mu + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_p),$$

并假设 z, ε 独立。于是

$$\mathbb{E}[x] = \mu, \quad \text{Cov}(x) = WW^\top + \sigma^2 I_p = C.$$

$\text{Cov}(z, x) = W^\top$, 因此联合高斯的条件分布公式给出

$$p(z | x) = \mathcal{N}(W^\top C^{-1}(x - \mu), I_q - W^\top C^{-1}W).$$

学习 W, μ, σ^2 可以使用 EM, 见章节 4; 推断则用后验均值作为低维表示, 并可保留后验协方差描述不确定性。这一视角说明 PCA 与隐变量模型的联系, 本章不展开完整 PPCA 的 EM 更新。

3.7 使用时的边界

PCA 保留的是输入方差, 不保证保留对标签最有用的信息。特征量纲差异较大时, 需要决定是否标准化; 这是改变问题权重的建模选择。若特征值重复, 对应子空间可能唯一, 但子空间内的基不唯一。累计解释方差比为 $\sum_{j \leq q} \lambda_j / \sum_j \lambda_j$, 可辅助选择维数。

第二部分

树模型与集成学习

第四章 决策树

本章为**补充整理**：依据已确认的章节提纲补写，当前未收到对应的详细原稿。重点是“如何选择一次划分”，以及 ID3、C4.5、CART 与剪枝的关系。

4.1 一次划分解决什么问题

树从根节点开始，对特征提出问题，将样本送往不同子节点，直到叶节点输出预测。分类叶节点可输出多数类别或类别频率；回归叶节点可输出响应均值。

设当前样本集为 D ，用某个划分 A 将它拆成 $D_1, \dots, D_V$ 。若 $I(D)$ 表示节点不纯度，则比较

$$\Delta I = I(D) - \sum_{v=1}^V \frac{|D_v|}{|D|} I(D_v).$$

好的划分使子节点更纯，同时考虑每个子节点包含多少样本。连续特征常用阈值 $x_j \leq s$ 二分，并在候选特征与阈值中搜索。

4.2 熵与信息增益

若节点内类别比例为 $p_1, \dots, p_K$ ，信息熵为

$$H(Y) = - \sum_{k=1}^K p_k \log_2 p_k,$$

约定 $0 \log 0 = 0$ 。节点只有一类时熵为零；类别越均衡，标签越难预测。

以划分结果 A 为条件，剩余不确定性是

$$H(Y | A) = \sum_v P(A = v) H(Y | A = v).$$

信息增益为

$$\text{Gain}(A) = H(Y) - H(Y | A) = I(Y; A).$$

4.2.1 为什么等于互信息

从联合分布直接展开：

$$\begin{aligned} I(Y; A) &= \sum_{y,a} p(y, a) \log_2 \frac{p(y, a)}{p(y)p(a)} \\ &= \sum_{y,a} p(y, a) \log_2 p(y | a) - \sum_{y,a} p(y, a) \log_2 p(y) \\ &= -H(Y | A) + H(Y). \end{aligned}$$

因此选择信息增益大的划分，就是选择最能减少标签不确定性的划分。使用训练集频数代替真实概率时，得到的是经验信息增益，不自动保证泛化。

4.2.2 小例子

节点有 8 个样本，正负各 4 个，熵为 1 bit。某次划分得到两个同样大的子节点，类别分别为 (3, 1) 与 (1, 3)。划分后的熵是

$$-\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.811,$$

信息增益约为 0.189 bit。若能划成两个纯节点，增益就是 1 bit。

4.3 信息增益率：处理多值偏好

某个特征若给每个训练样本一个独有值，就能制造完全纯的叶节点，却可能没有预测价值。信息增益容易偏好这种多分支划分。

C4.5 使用划分本身的熵进行归一化：

$$\text{SplitInfo}(A) = - \sum_v p_v \log_2 p_v, \quad \text{GainRatio}(A) = \frac{\text{Gain}(A)}{\text{SplitInfo}(A)}.$$

分母为零时该比值不使用。实际选择还要防止分母极小而夸大比值；常见 C4.5 选择过程先筛选信息增益不低的候选，再比较增益率。

4.4 Gini 指标与 CART

分类 CART 常用

$$\text{Gini}(D) = 1 - \sum_k p_k^2 = \sum_k p_k(1 - p_k).$$

它可解释为从该类别分布独立抽两次、标签不同的概率。对二叉划分，选择加权子节点 Gini 最小的候选。上例根节点 Gini 为 $1/2$ ，子节点为 $3/8$ ，下降 $1/8$ 。

回归 CART 通常最小化叶内平方误差。固定叶节点 R ，对常数输出 c ：

$$\frac{\partial}{\partial c} \sum_{i \in R} (y_i - c)^2 = -2 \sum_{i \in R} (y_i - c) = 0,$$

故最优叶值是均值。划分时分别计算两个子节点的最小平方误差之和。

4.5 ID3、C4.5 与 CART

方法	典型划分指标	结构与任务
ID3	信息增益	经典形式主要处理离散特征分类，可多叉
C4.5	信息增益率	扩展连续特征、缺失值等处理，并进行剪枝
CART	分类用 Gini；回归用平方误差等	二叉树，可分类也可回归

三者共享递归划分思想，区别并不只在公式名称，还包括候选划分、缺失值处理、停止与剪枝策略。

4.6 剪枝：控制树的复杂度

持续分裂可以降低训练误差，却可能把噪声也记下来。预剪枝在生长过程中限制深度、叶样本数或最低改进量；后剪枝先生成较大树，再评估删除子树的效果。

CART 的代价复杂度目标可写为

$$R_\alpha(T) = R(T) + \alpha |\mathcal{L}(T)|,$$

其中 $R(T)$ 是拟合误差， $|\mathcal{L}(T)|$ 是叶节点数， $\alpha \geq 0$ 控制复杂度惩罚。可用验证集或交叉验证选择大小。测试集应保留给最终评估。

单次划分通常是贪心选择，不等于找到全局最优的整棵树。决策树的重要价值，是把复杂预测拆成一系列可执行的局部判断；下一章会通过组合多个弱模型提高表达能力。

第五章 提升方法与集成学习

本章为**补充整理**：依据最初提纲，重点补写二分类 AdaBoost 的加权误差、样本重加权，以及它与前向分步加法模型、指数损失的关系。

5.1 为什么组合多个模型

若多个模型犯错的方式不同，组合预测可能比单个模型更稳定。Bagging 对重采样数据训练多个模型，再平均或投票；随机森林还在树的划分中随机选择候选特征。Boosting 则顺序构造模型，让后续步骤关注当前尚未解决的错误。

这里不展开整个集成方法谱系，主线是二分类 AdaBoost。设标签 $y_i \in \{-1, +1\}$ ，弱分类器 $h_t(x) \in \{-1, +1\}$ 。

5.2 AdaBoost 的迭代

初始化样本权重 $D_1(i) = 1/N$ 。第 t 轮在当前权重下训练弱分类器，并计算加权错误率

$$\epsilon_t = \sum_i D_t(i) \mathbf{1}\{h_t(x_i) \neq y_i\}.$$

当 $0 < \epsilon_t < 1/2$ 时，设置

$$\alpha_t = \frac{1}{2} \log \frac{1 - \epsilon_t}{\epsilon_t}.$$

然后更新并归一化：

$$D_{t+1}(i) = \frac{D_t(i) \exp[-\alpha_t y_i h_t(x_i)]}{Z_t}, \quad Z_t = \sum_i D_t(i) \exp[-\alpha_t y_i h_t(x_i)].$$

正确分类点的未归一化权重乘以 $e^{-\alpha_t}$ ，错误点乘以 e^{α_t} ，从而增加后者的相对重要性。最终输出

$$F_T(x) = \sum_{t=1}^T \alpha_t h_t(x), \quad \hat{y}(x) = \text{sign } F_T(x).$$

弱学习条件针对每一轮的**当前加权分布**，不是只要求在初始数据上优于随机猜测。

5.3 从指数损失推导权重

5.3.1 前向分步加法建模

假设已有 F_{t-1} ，本轮只增加 αh ，不重新优化以前所有弱模型：

$$F_t(x) = F_{t-1}(x) + \alpha h(x).$$

最小化指数损失

$$\mathcal{E}(F_t) = \sum_i \exp[-y_i F_t(x_i)] = \sum_i e^{-y_i F_{t-1}(x_i)} e^{-\alpha y_i h(x_i)}.$$

将前一项归一化，就得到本轮权重

$$D_t(i) = \frac{e^{-y_i F_{t-1}(x_i)}}{\sum_j e^{-y_j F_{t-1}(x_j)}}.$$

因此“当前难分类的点更重”不是独立添加的规则，而是指数损失的直接结果。

5.3.2 固定弱分类器，求最优系数

正确点上 $y_i h(x_i) = 1$ ，错误点上等于 -1 ，所以需要最小化

$$Z(\alpha) = (1 - \epsilon)e^{-\alpha} + \epsilon e^{\alpha}.$$

求导并令其为零：

$$-(1 - \epsilon)e^{-\alpha} + \epsilon e^{\alpha} = 0 \quad \implies \quad e^{2\alpha} = \frac{1 - \epsilon}{\epsilon}.$$

于是得到 $\alpha = \frac{1}{2} \log[(1 - \epsilon)/\epsilon]$ 。代回可得

$$Z_t = 2\sqrt{\epsilon_t(1 - \epsilon_t)}.$$

固定 $\alpha > 0$ 时, $Z(\alpha) = e^{-\alpha} + \epsilon(e^{\alpha} - e^{-\alpha})$ 随 ϵ 递增, 因此选择加权错误率小的弱分类器与这个目标一致。

5.3.3 一个数值例子

若当前加权错误率为 $\epsilon_t = 1/4$, 则 $\alpha_t = \frac{1}{2} \log 3$ 。错误点相对正确点的权重倍率变为

$$\frac{e^{\alpha_t}}{e^{-\alpha_t}} = e^{2\alpha_t} = 3.$$

不是把所有权重简单加上一个常数, 而是通过乘法改变相对重心。

5.4 训练误差为何可以下降

若 $y_i F_T(x_i) \leq 0$, 指数损失至少为 1, 所以

$$\frac{1}{N} \sum_i \mathbf{1}\{y_i F_T(x_i) \leq 0\} \leq \frac{1}{N} \sum_i e^{-y_i F_T(x_i)}.$$

由每轮归一化递推及 $D_1(i) = 1/N$,

$$D_{T+1}(i) = \frac{e^{-y_i F_T(x_i)}}{N \prod_{t=1}^T Z_t}.$$

两边对 i 求和得到

$$\frac{1}{N} \sum_i e^{-y_i F_T(x_i)} = \prod_{t=1}^T Z_t.$$

若每轮 $\epsilon_t \leq 1/2 - \gamma$, $\gamma > 0$, 则

$$Z_t \leq \sqrt{1 - 4\gamma^2} \leq e^{-2\gamma^2}, \quad \text{训练错误率} \leq e^{-2T\gamma^2}.$$

这是训练集上的界, 不能直接当作测试误差保证。

5.5 边界情况与理解范围

$\epsilon_t = 0$ 时系数公式趋于无穷, 可结束迭代或做数值截断; $\epsilon_t = 1/2$ 时 $\alpha_t = 0$, 本轮没有改进; 若大于 $1/2$, 应重新寻找弱分类器, 二分类下也可检查翻转输出是否有效。

指数损失对持续误分类点施加很大权重，因此噪声标签和异常值可能带来问题。轮数、基学习器复杂度等仍需要验证。

本章的核心对应是：**弱分类器** → **加权误差** → **系数** → **样本重加权** → **加法模型**。AdaBoost 可以视为指数损失下的前向分步加法建模；梯度提升进一步推广这种“逐步添加函数”的思路，本书仅作联系说明。

第三部分

概率建模与推断

第六章 指数族与最大熵

高斯、Bernoulli、Poisson 等看似不同的分布，常能写成同一种结构。统一表示的价值在于：归一化、矩、似然估计和凸性都可由一个函数处理。

6.1 指数族的统一形式

写成

$$p(x | \eta) = h(x) \exp\{\eta^\top T(x) - A(\eta)\}.$$

η 是自然参数， $T(x)$ 是充分统计量， $h(x)$ 是基准因子， $A(\eta)$ 是对数配分函数。为避免与类别概率及特征映射混淆，本章用 T 代替原稿的 ϕ 。

归一化要求

$$A(\eta) = \log \int h(x) e^{\eta^\top T(x)} dx,$$

离散情形把积分换成求和。自然参数空间是使积分有限的参数集合；讨论导数时通常取其内部，并要求可交换积分与求导。

“充分”是相对于给定参数族而言：统计量保留了样本中用于推断该参数的全部信息，不代表保留了样本的所有细节。对独立同分布样本，联合似然中与参数相关的数据项只通过 $\sum_i T(x_i)$ 出现。

常见指数族包括高斯、Bernoulli、二项、Poisson、Beta、Dirichlet、Gamma 等；具体表示取决于哪些量被视为未知参数及支持集是否固定。

6.2 两个例子

6.2.1 Bernoulli: 自然参数就是对数几率

补充例子。对 $x \in \{0, 1\}$,

$$p(x | \pi) = \pi^x (1 - \pi)^{1-x} = \exp \left[x \log \frac{\pi}{1 - \pi} + \log(1 - \pi) \right].$$

因此 $T(x) = x$ 、 $h(x) = 1$ 、 $\eta = \log[\pi/(1 - \pi)]$ 、 $A(\eta) = \log(1 + e^\eta)$ 。让自然参数等于 $w^\top x + b$ ，就回到了逻辑回归的对数几率结构。

6.2.2 一维高斯: 均值和方差都未知

展开平方项:

$$\log p(x | \mu, \sigma^2) = \frac{\mu}{\sigma^2} x - \frac{1}{2\sigma^2} x^2 - \frac{\mu^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2).$$

取 $h(x) = 1$ 、 $T(x) = (x, x^2)^\top$ ，则

$$\eta_1 = \frac{\mu}{\sigma^2}, \quad \eta_2 = -\frac{1}{2\sigma^2} < 0,$$

$$A(\eta) = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2} \log \left(-\frac{\pi}{\eta_2} \right).$$

一个样本的充分统计量是 x, x^2 ；对样本集是 $\sum_i x_i, \sum_i x_i^2$ ，可据此计算经验均值和方差。

6.3 对数配分函数的导数

从 $e^{A(\eta)} = \int h(x) e^{\eta^\top T(x)} dx$ 出发，对 η 求导:

$$e^{A(\eta)} \nabla A(\eta) = \int h(x) e^{\eta^\top T(x)} T(x) dx.$$

两边除以 e^A :

$$\nabla A(\eta) = \int p(x | \eta) T(x) dx = \mathbb{E}_\eta[T(x)].$$

再求导，利用 $\nabla_\eta p = p(T - \nabla A)$:

$$\begin{aligned}
\nabla^2 A(\eta) &= \int p(x | \eta) T(x) [T(x) - \mathbb{E}T(x)]^\top dx \\
&= \mathbb{E}[TT^\top] - \mathbb{E}[T]\mathbb{E}[T]^\top \\
&= \text{Cov}_\eta(T).
\end{aligned}$$

对任意向量 v , $v^\top \nabla^2 A v = \text{Var}(v^\top T) \geq 0$, 所以 A 为凸函数。协方差是半正定, 不一定正定, 因此不能无条件宣称严格凸。

6.4 MLE 就是矩匹配

样本 $x_1, \dots, x_N$ 独立同分布, 对数似然为

$$\ell(\eta) = \eta^\top \sum_i T(x_i) - NA(\eta) + \sum_i \log h(x_i).$$

梯度和 Hessian 分别为

$$\nabla \ell = \sum_i T(x_i) - N\mathbb{E}_\eta T(x), \quad \nabla^2 \ell = -N \text{Cov}_\eta(T) \preceq 0.$$

若有限的内部最优解存在, 它满足

$$\mathbb{E}_{\hat{\eta}} T(x) = \frac{1}{N} \sum_i T(x_i).$$

也就是模型期望与经验统计量匹配。边界数据可能导致有限 MLE 不存在, 不能只凭驻点公式保证解的存在。

6.5 共轭先验与广义线性模型

原稿指出指数族便于寻找共轭先验。一个典型形式为

$$p(\eta | \chi, \nu) \propto \exp\{\eta^\top \chi - \nu A(\eta)\}.$$

在先验可归一化等条件下, 乘以 N 个样本的似然后, 参数更新为

$$\chi \leftarrow \chi + \sum_i T(x_i), \quad \nu \leftarrow \nu + N.$$

例如二项/Bernoulli 似然与 Beta 先验共轭。共轭性是选定似然和先验之间的关系，不表示任意先验都会保持同族。

广义线性模型让响应的条件分布属于指数族，并以链接函数连接条件均值和线性预测量： $g(\mathbb{E}[y | x]) = w^\top x + b$ 。采用典范链接时自然参数就是这个线性量。这样能统一线性回归、逻辑回归等模型。

6.6 最大熵：只使用已知约束

6.6.1 有限支持上，只有归一化约束

设随机变量有 K 个可能值，最大化

$$H(p) = - \sum_{k=1}^K p_k \log p_k, \quad p_k \geq 0, \quad \sum_k p_k = 1.$$

等价于最小化 $\sum_k p_k \log p_k$ 。构造

$$\mathcal{L} = \sum_k p_k \log p_k + \lambda_0 (1 - \sum_k p_k).$$

对每个 p_k 分别求偏导： $\log p_k + 1 - \lambda_0 = 0$ ，所以各 p_k 相等，再由归一化得到 $p_k = 1/K$ 。

“均匀时熵最大”需要限定支持集等条件；在无界连续空间，只有归一化约束通常不存在熵最大的分布。

6.6.2 加入经验矩约束

从经验分布 $\hat{p}$ 得到特征期望 $\Delta_j = \mathbb{E}_{\hat{p}}[f_j(x)]$ 。只要求模型满足这些已知信息：

$$\sum_x p(x) f(x) = \Delta, \quad \sum_x p(x) = 1.$$

支持集上的求和不是“对训练样本编号求和”；二者在原稿中需要区分。拉格朗日函数为

$$\mathcal{L}(p, \lambda_0, \lambda) = \sum_x p(x) \log p(x) + \lambda_0 (1 - \sum_x p(x)) + \lambda^\top \left[\Delta - \sum_x p(x) f(x) \right].$$

对一个具体的 $p(x)$ 求导，得到

$$\log p(x) + 1 - \lambda_0 - \lambda^\top f(x) = 0.$$

这里不需要、也不能用“总和为零所以每项为零”论证；每个概率分量本来就是独立求偏导的变量。解得

$$p(x) = e^{\lambda^\top f(x) + \lambda_0 - 1} = \frac{e^{\lambda^\top f(x)}}{\sum_{x'} e^{\lambda^\top f(x')}}.$$

于是自然得到指数族形式。若有一般基准测度 h ，可用相对熵版本得到 $p \propto h \exp(\lambda^\top f)$ 。最大熵是在指定支持和矩约束下保持其余部分尽量不偏向，不等于所有指数族都是“无信息先验”。

6.7 配分函数与学习的共同结构

对一般模型 $p(x | \theta) = \tilde{p}(x | \theta)/Z(\theta)$ ，在可交换求导与积分时，

$$\begin{aligned} \nabla_\theta \log Z(\theta) &= \frac{1}{Z} \int \nabla_\theta \tilde{p}(x | \theta) dx \\ &= \int p(x | \theta) \nabla_\theta \log \tilde{p}(x | \theta) dx. \end{aligned}$$

所以平均对数似然的梯度是

$$\frac{1}{N} \sum_i \nabla \log \tilde{p}(x_i | \theta) - \mathbb{E}_{p_\theta}[\nabla \log \tilde{p}(x | \theta)].$$

即“数据项减模型期望项”。CRF 中会再次出现这个结构；若模型期望难以精确计算，可考虑采样或其他近似。本书不在此展开 RBM 与对比散度。

第七章 EM 算法与高斯混合模型

隐变量模型的困难在于：看得见 X ，却不知道产生它的 Z 。观测似然 $p(X | \theta) = \int p(X, Z | \theta) dZ$ 把不同解释混在一起，取对数后往往难以直接优化。EM 通过“先估计隐变量分布，再更新参数”逐步提升观测似然。

7.1 E 步与 M 步

令第 r 轮参数为 $\theta^{(r)}$ ，定义

$$Q(\theta | \theta^{(r)}) = \mathbb{E}_{Z|X, \theta^{(r)}} [\log p(X, Z | \theta)].$$

E 步用旧参数计算后验，并由它构造关于新参数的函数 Q 。M 步为

$$\theta^{(r+1)} \in \arg \max_{\theta} Q(\theta | \theta^{(r)}).$$

期望中的后验在 M 步固定。 Q 是函数值， $\arg \max$ 是使它最大化的参数，两者不能直接写成等号。EM 不限于混合模型，只要完整数据结构使这两步可处理即可。

7.2 单调性的第一种证明： $Q - H$ 分解

用旧后验 $q_r(Z) = p(Z | X, \theta^{(r)})$ 对恒等式

$$\log p(X | \theta) = \log p(X, Z | \theta) - \log p(Z | X, \theta)$$

求期望，定义

$$H(\theta | \theta^{(r)}) = \mathbb{E}_{q_r} \log p(Z | X, \theta).$$

则 $\ell(\theta) = Q(\theta | \theta^{(r)}) - H(\theta | \theta^{(r)})$ 。这里 H 沿用原稿记号，并不是带负号的 Shannon 熵。

M 步保证 $Q(\theta^{(r+1)} | \theta^{(r)}) \geq Q(\theta^{(r)} | \theta^{(r)})$ 。另一方面,

$$\begin{aligned} & H(\theta^{(r+1)} | \theta^{(r)}) - H(\theta^{(r)} | \theta^{(r)}) \\ &= \int q_r(Z) \log \frac{p(Z | X, \theta^{(r+1)})}{q_r(Z)} dZ \\ &= -\text{KL}(q_r \| p(Z | X, \theta^{(r+1)})) \leq 0. \end{aligned}$$

两项相减, 所以

$$\ell(\theta^{(r+1)}) \geq \ell(\theta^{(r)}).$$

准确结论是似然不下降, 不保证每次严格上升, 更不保证到达全局最优。

7.3 第二种理解: ELBO 与 KL

对任意合适的分布 $q(Z)$, 定义证据下界

$$\mathcal{F}(q, \theta) = \mathbb{E}_q[\log p(X, Z | \theta)] + H(q), \quad H(q) = -\mathbb{E}_q \log q(Z).$$

代数分解得到

$$\log p(X | \theta) = \mathcal{F}(q, \theta) + \text{KL}(q \| p(Z | X, \theta)).$$

KL 非负, 因此 $\mathcal{F}$ 是下界; 当 q 等于真实后验时取等号。KL 的方向是近似分布在前、后验在后。

7.3.1 Jensen 推导保留原稿的另一条路线

$$\begin{aligned} \log p(X | \theta) &= \log \int q(Z) \frac{p(X, Z | \theta)}{q(Z)} dZ \\ &\geq \int q(Z) \log \frac{p(X, Z | \theta)}{q(Z)} dZ = \mathcal{F}(q, \theta). \end{aligned}$$

在适当支持条件下, 等号要求 $p(X, Z | \theta)/q(Z)$ 为常数。积分归一化可知该常数为 $p(X | \theta)$, 于是 $q(Z) = p(Z | X, \theta)$ 。

EM 的 E 步在旧参数处把下界拉紧; M 步固定这个 q_r , 抬高下界:

$$\ell(\theta^{(r+1)}) \geq \mathcal{F}(q_r, \theta^{(r+1)}) \geq \mathcal{F}(q_r, \theta^{(r)}) = \ell(\theta^{(r)}).$$

M 步完成后, 旧的 q_r 通常不再等于新参数的后验, 所以不能说每一步都联合求得了全局最大的 ELBO。

7.4 GMM: 用多个高斯解释多峰数据

高斯混合模型为

$$p(x | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1.$$

引入类别隐变量 $z_i \in \{1, \dots, K\}$: 先按 π 选择分量, 再从该分量的高斯分布生成 x_i 。联合分布为

$$p(x_i, z_i = k | \theta) = \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k).$$

参数是 $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ 。(X, Z) 称为完整数据, 不是“完整参数”。

观测对数似然

$$\ell(\theta) = \sum_i \log \left[\sum_k \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k) \right]$$

包含对数内部的求和, 参数相互耦合, 通常没有一次代入即可得到的闭式 MLE。EM 是一种常用优化方式, 并非唯一方式。

7.5 GMM 的 E 步: 责任度

根据贝叶斯公式,

$$r_{ik} = P(z_i = k | x_i, \theta^{(r)}) = \frac{\pi_k^{(r)} \mathcal{N}(x_i | \mu_k^{(r)}, \Sigma_k^{(r)})}{\sum_l \pi_l^{(r)} \mathcal{N}(x_i | \mu_l^{(r)}, \Sigma_l^{(r)})}.$$

每个样本对不同分量的责任度相加为 1。它表达的是软归属, 而不是把样本立即硬分给一个类别。

7.5.1 为什么对整个隐变量向量的求和可拆开

条件于数据和参数, $p(Z | X, \theta^{(r)}) = \prod_i p(z_i | x_i, \theta^{(r)})$ 。完整对数似然是样本项之和, 所以

$$Q = \sum_Z \left[\sum_i \log p(x_i, z_i | \theta) \right] \prod_j p(z_j | x_j, \theta^{(r)}).$$

固定第 i 项时, 其他隐变量的分布求和均等于 1, 留下

$$Q(\theta | \theta^{(r)}) = \sum_i \sum_k r_{ik} [\log \pi_k + \log \mathcal{N}(x_i | \mu_k, \Sigma_k)].$$

这是原稿长求和推导的关键, 不需要枚举全部 K^N 种隐变量配置。

7.6 GMM 的 M 步: 加权估计

定义有效样本数 $N_k = \sum_i r_{ik}$ 。

7.6.1 混合权重

最大化 $\sum_k N_k \log \pi_k$, 约束 $\sum_k \pi_k = 1$ 。拉格朗日函数为

$$\mathcal{L} = \sum_k N_k \log \pi_k + \lambda (\sum_k \pi_k - 1).$$

驻点条件为 $N_k/\pi_k + \lambda = 0$ 。先乘以 π_k , 再对 k 求和:

$$\sum_k N_k + \lambda \sum_k \pi_k = N + \lambda = 0.$$

因此 $\pi_k^{(r+1)} = N_k/N$ 。原稿中这一步漏写了乘以 π_k , 不能直接把带 $1/\pi_k$ 的式子相加得到结论。

7.6.2 均值与协方差 (补充原稿略去的求导)

固定责任度, 对均值相关的部分最大化, 等价于最小化

$$\sum_i r_{ik} (x_i - \mu_k)^\top \Sigma_k^{-1} (x_i - \mu_k).$$

其梯度为 $-2\Sigma_k^{-1} \sum_i r_{ik} (x_i - \mu_k)$, 所以

$$\mu_k^{(r+1)} = \frac{1}{N_k} \sum_i r_{ik} x_i.$$

令 $R_k = \sum_i r_{ik} (x_i - \mu_k^{(r+1)})(x_i - \mu_k^{(r+1)})^\top$, 协方差部分为

$$-\frac{N_k}{2} \log |\Sigma_k| - \frac{1}{2} \text{tr}(\Sigma_k^{-1} R_k).$$

像 GDA 一样对精度矩阵求导, 可得

$$\Sigma_k^{(r+1)} = \frac{R_k}{N_k}.$$

这些公式要求 $N_k > 0$, 并需处理数值退化与正定性。

7.7 初始化、停止与局限

选初始权重、均值和正定协方差, 重复 E/M 两步, 检查观测对数似然的变化。计算责任度时可在对数域用 log-sum-exp 避免下溢。

不同初始化可能收敛到不同驻点。无约束 GMM 的似然还可能因某分量协方差塌缩而无界, 因此“似然不下降”本身不保证得到有意义的模型。协方差下界、正则化、合理初始化等是必要的实际考虑。分量标签可以交换, 参数表示也因此不唯一。

7.8 广义 EM 与近似后验：少量衔接

原稿把几种推广放在“广义 EM”名下, 这里区分:

- **GEM (广义 EM)**: 仍使用精确 E 步, M 步只需增加 Q , 不必完全最大化, 仍可得到似然不下降。
- **变分 EM**: 把 q 限制在某分布族中, 交替优化 ELBO; 保证的是相应下界的改进, 不能照搬精确 EM 的似然单调性。
- **MCEM**: 用采样近似 E 步期望, 有限采样误差也会影响单调性。

平均场 $q(Z) = \prod_j q_j(Z_j)$ 的坐标更新可写为

$$q_j^*(Z_j) \propto \exp\{\mathbb{E}_{q_{-j}} \log p(X, Z | \theta)\}.$$

必须归一化后才能成为概率分布。VI、随机变分梯度与重参数化不在本书主线中展开; MCMC 见附录附录 A。

第八章 概率图模型

高维联合分布难以直接表示和计算。概率图模型用图表达分解结构与条件独立性，使局部计算成为可能。节点代表随机变量；边表达依赖结构，边本身一般不是一个“条件概率数值”。

8.1 表示、推断与学习

基本概率规则为

$$\begin{aligned}p(x_1) &= \int p(x_1, x_2) dx_2, \\p(x_1, x_2) &= p(x_1 | x_2) p(x_2), \\p(x_1, \dots, x_p) &= \prod_{i=1}^p p(x_i | x_1, \dots, x_{i-1}), \\p(x_1 | x_2) &= \frac{p(x_2 | x_1) p(x_1)}{p(x_2)}.\end{aligned}$$

链式法则总成立，图模型通过条件独立假设减少各因子所需条件变量。 $X_A \perp X_B | X_C$ 表示给定 X_C 后两组变量条件独立。

任务	主要问题
表示	联合分布怎样分解，哪些条件独立关系被编码
推断	求边缘、条件分布或最可能的变量配置
学习	估计参数，或从数据中学习结构；缺失数据可使用 EM

有向/无向是图结构分类，离散/连续是变量类型分类，二者可以组合；不能把有向图限定为离散变量。MAP 推断也不只针对参数，可以针对隐变量或结构化输出。

8.2 有向无环图：贝叶斯网络

给定一个 DAG，按父节点分解：

$$p(x_1, \dots, x_p) = \prod_i p(x_i | x_{\text{pa}(i)}).$$

拓扑排序保证父节点先于子节点。仅给定一个一般联合分布并不会唯一确定 DAG；图同时表达建模假设。

8.2.1 三种局部结构




图 8.1: 链、分叉、碰撞三种局部结构。前两种给定中间节点会阻断路径；碰撞结构在不观测中间节点及其后代时阻断路径。

链结构 $A \rightarrow B \rightarrow C$: $p(a, b, c) = p(a)p(b | a)p(c | b)$, 因此

$$p(a, c | b) = p(a | b)p(c | b), \quad A \perp C \mid B.$$

分叉结构 $A \leftarrow B \rightarrow C$: $p(a, b, c) = p(b)p(a | b)p(c | b)$, 同样有 $A \perp C \mid B$ 。

碰撞结构 $A \rightarrow B \leftarrow C$: $p(a, b, c) = p(a)p(c)p(b | a, c)$ 。对 b 求和得到 $p(a, c) = p(a)p(c)$, 故 $A \perp C$ ；但给定 B 后, A, C 通常会相关, 这就是 explaining away 的来源。这里并不是说 A 或 C 与 B 条件独立。

8.2.2 d-separation: 从局部规则到整条路径

忽略箭头方向观察一条路径。给定集合 S , 路径在以下任一种情形下被阻断:

1. 路径上有非碰撞节点属于 S ;
2. 路径上有碰撞节点, 而且它自身及其所有后代都不在 S 。

若 A 与 B 之间每条路径都被 S 阻断, 则图蕴含 $X_A \perp X_B \mid X_S$ 。碰撞节点的后代被观测也可能打开路径, 不能遗漏这个条件。

图没有蕴含某个独立关系, 不代表所有参数选择下变量必然相关; 特殊参数可能产生额外独立性。

8.2.3 Markov 毯

求一个变量在其他变量给定时的条件分布：

$$p(x_i | x_{-i}) \propto p(x_i | x_{\text{pa}(i)}) \prod_{j \in \text{ch}(i)} p(x_j | x_{\text{pa}(j)}).$$

因为联合分布里其他不含 x_i 的因子在归一化时消掉。相关变量包括父节点、子节点以及子节点的其他父节点；这三类合称 Markov 毯。原稿只写 $p(x_{\text{child}(i)} | x_i)$ ，省掉共同父节点后会误解依赖关系。

8.3 无向图：马尔可夫随机场

无向图直接用图分隔表达条件独立，不使用 DAG 的碰撞节点规则。常见性质为：

- 全局 Markov：若 S 分隔 A, B ，则 $X_A \perp X_B | X_S$ 。
- 局部 Markov：给定邻居后，一个节点独立于其他非邻居节点。
- 成对 Markov：两个不相邻节点在其余所有节点给定后独立。

全局性质蕴含局部与成对性质；在标准严格正分布等条件下三者等价。省去正性等条件而直接声称等价并不严谨。

8.3.1 团与因子分解

团是两两相连的节点集合；不能再加入节点的团称为**极大团** (maximal clique)，与“节点数最多的最大团”不同。

对严格正分布，Hammersley–Clifford 定理将图的 Markov 性质与团因子分解联系起来：

$$p(x) = \frac{1}{Z} \prod_C \psi_C(x_C), \quad Z = \sum_x \prod_C \psi_C(x_C).$$

连续情形用积分替代求和，并要求 Z 有限。正势函数可写成 $\psi_C = \exp[-E_C]$ ，因此

$$p(x) = \frac{1}{Z} \exp \left[- \sum_C E_C(x_C) \right].$$

这称为 Gibbs 形式。它与指数族相关；若要赋予最大熵解释，还须明确支持集和期望约束，而不只是观察到指数符号。

8.4 从有向图到道德图，再到因子图

把 DAG 转为道德图的步骤是：先将每个节点的父节点两两相连，再去掉所有箭头。链和分叉只需去箭头；碰撞结构需要把两位父节点相连，因为 $p(b | a, c)$ 同时涉及三个变量。

道德化可以保留该分布的某种无向因子表示，但不保证保留全部条件独立关系。碰撞结构中的 $A \perp C$ 在道德图中就不再由分隔表达。

因子图把变量节点与因子节点区分开。若

$$p(x) \propto \prod_s f_s(x_s),$$

则变量与包含它的因子相连。例如一个三变量因子 $f(a, b, c)$ 可以用一个因子节点连接三个变量，形成星形图。




图 8.2: 道德化与因子图：碰撞结构的父节点相连形成三角形；若联合因子是一个三变量因子，其因子图可表示为星形。

但将分布画成因子图**不保证无环**。若保留三个不同的两变量因子 $f_{ab}f_{bc}f_{ac}$ ，对应因子图仍有环；把它们合成一个大因子虽然改变图形，却可能把计算困难放入大因子表中。

8.5 变量消除：调整求和顺序

考虑链 $a \rightarrow b \rightarrow c \rightarrow d$ ：

$$\begin{aligned} p(d) &= \sum_{a,b,c} p(a)p(b|a)p(c|b)p(d|c) \\ &= \sum_c p(d|c) \sum_b p(c|b) \sum_a p(b|a)p(a). \end{aligned}$$

从内向外计算时，每一步只构造需要的中间因子，避免枚举全部联合配置。变量消除可以用于一般图，并不只适用于树；复杂度由消除次序产生的中间因子大小决定，最优次序的寻找通常很困难。

原稿所谓“计算步骤无法存储”应理解为：朴素地对每个查询重新做消除会重复计算；算法本身当然可以缓存中间结果。消息传递系统地组织了这种复用。

8.6 树上的信念传播：sum-product

考虑两两势函数构成的树：

$$p(x) = \frac{1}{Z} \prod_i \psi_i(x_i) \prod_{(i,j) \in E} \psi_{ij}(x_i, x_j).$$

从节点 j 发往相邻节点 i 的消息为

$$m_{j \rightarrow i}(x_i) = \sum_{x_j} \psi_j(x_j) \psi_{ij}(x_i, x_j) \prod_{k \in \mathcal{N}(j) \setminus \{i\}} m_{k \rightarrow j}(x_j).$$

发送时先收集除接收者之外的所有入消息，再将发送者变量求和消去。若 j 是叶节点，乘积为空，取 1。

8.6.1 原稿中的四节点例子

设边为 $(a, b), (b, c), (b, d)$ 。先从叶节点计算

$$m_{c \rightarrow b}(b) = \sum_c \psi_c(c) \psi_{bc}(b, c), \quad m_{d \rightarrow b}(b) = \sum_d \psi_d(d) \psi_{bd}(b, d).$$

再向 a 发消息：

$$m_{b \rightarrow a}(a) = \sum_b \psi_b(b) \psi_{ab}(a, b) m_{c \rightarrow b}(b) m_{d \rightarrow b}(b).$$

最后

$$p(a) = \frac{\psi_a(a) m_{b \rightarrow a}(a)}{\sum_{a'} \psi_a(a') m_{b \rightarrow a}(a')}.$$

一般边缘概率为 $p(x_i) \propto \psi_i(x_i) \prod_{j \in \mathcal{N}(i)} m_{j \rightarrow i}(x_i)$ ，最终需要归一化。

选一个根，先从叶到根收集，再从根向叶分发，即可得到全部单点边缘。在树上是精确计算；有环时迭代的 loopy BP 不保证收敛或精确。

对没有任何观测证据的有向链，从后代反向求和得到的因子可为 1；不能凭空再乘一个末端边缘概率 $p(e)$ 。有观测时，证据通过局部似然因子进入消息。

8.7 Max-product 与联合最优配置

如果需要最可能的联合状态，树上的消息可将求和替换成最大值：

$$m_{j \rightarrow i}(x_i) = \max_{x_j} \psi_j(x_j) \psi_{ij}(x_i, x_j) \prod_{k \in \mathcal{N}(j) \setminus \{i\}} m_{k \rightarrow j}(x_j).$$

还必须保存每一步取最大值的状态，在根节点决策后沿树回溯。分别最大化各节点边缘，不保证得到联合概率最大的配置。取对数可得到 max-sum；HMM 中的 Viterbi 是链结构上的对应算法。

Junction tree 将变量聚成团，在团树上传递消息来处理一般图；复杂度可能随树宽指数增长。近似方法包括 loopy BP、VI、Monte Carlo 等，附录介绍 MCMC。

8.8 高斯图模型

8.8.1 联合高斯是前提

设 $x \sim \mathcal{N}(\mu, \Sigma)$ 且 $\Sigma \succ 0$ 。不能仅从“每个节点边缘都是高斯”推出联合高斯；本节把联合高斯作为模型假设，或由线性高斯结构方程推导它。

记精度矩阵 $\Lambda = \Sigma^{-1}$ ：

$$\begin{aligned} x_i \perp x_j &\iff \Sigma_{ij} = 0, \\ x_i \perp x_j \mid x_{-\{i,j\}} &\iff \Lambda_{ij} = 0. \end{aligned}$$

第一条是边缘独立，不应称为图上的“全局 Markov 性”。

8.8.2 从精度矩阵得到条件分布

对联合密度指数保留与 x_i 有关的项，并配方：

$$x_i \mid x_{-i} \sim \mathcal{N} \left(\mu_i - \frac{1}{\Lambda_{ii}} \sum_{j \neq i} \Lambda_{ij} (x_j - \mu_j), \frac{1}{\Lambda_{ii}} \right).$$

原稿漏写了均值平移和负号。精度矩阵某项为零，就不会在这个条件均值中出现对应变量。

8.8.3 高斯贝叶斯网络：结构方程

用独立噪声 $\varepsilon_i \sim \mathcal{N}(0, 1)$ 表示

$$x_i - \mu_i = \sum_{j \in \text{pa}(i)} w_{ij}(x_j - \mu_j) + s_i \varepsilon_i.$$

矩阵形式为 $x - \mu = W(x - \mu) + S\varepsilon$ ，其中 $S = \text{diag}(s_i)$ 。DAG 按拓扑顺序排列后 W 严格下三角， $I - W$ 可逆，所以

$$\Sigma = (I - W)^{-1} S^2 (I - W)^{-\top}.$$

8.8.4 高斯马尔可夫网络：二次型与边

展开密度并令 $h = \Lambda\mu$ ：

$$p(x) \propto \exp \left[-\frac{1}{2} x^\top \Lambda x + h^\top x \right].$$

节点项为 $-\frac{1}{2} \Lambda_{ii} x_i^2 + h_i x_i$ ，每个无向变量对 $i < j$ 的项为 $-\Lambda_{ij} x_i x_j$ 。对称性使交叉项合并，不能再对有序对重复计数。由此再次看出精度矩阵的零元素对应缺失边。

8.9 主线模型之间的联系

朴素贝叶斯用给定类别后的特征独立性简化联合分布；GMM 用隐分量解释多峰；HMM 把隐状态沿时间串联；CRF 直接对给定输入后的标签分布建模。图不仅用于展示模型，也决定可以如何分解计算、传递消息和组织学习。

第九章 隐马尔可夫模型

GMM 用一个隐类别解释一个观测。若隐状态随着时间变化，并使相邻观测产生依赖，就进入状态空间模型。HMM 使用离散隐状态；观测可以是离散或连续的。本章先采用离散观测，便于写出完整递推。

9.1 模型、参数与假设

令隐状态 $z_t \in \{1, \dots, K\}$ ，观测 $o_t \in \{v_1, \dots, v_M\}$ ，序列长度为 T 。参数为 $\theta = (\pi, A, B)$ ：

$$\pi_j = P(z_1 = j), \quad a_{ij} = P(z_{t+1} = j \mid z_t = i), \quad b_j(v) = P(o_t = v \mid z_t = j).$$

π 、 A 的每一行、 B 的每一行都归一化。




图 9.1: HMM 的状态链与观测：隐状态连接相邻时刻，每个观测由对应时刻的隐状态产生。

一阶马尔可夫假设是未来状态在给定当前状态后与更早历史独立；齐次性另要求转移核不随时间变化。观测条件独立假设给出

$$p(o_{1:T} | z_{1:T}) = \prod_{t=1}^T p(o_t | z_t).$$

这不表示观测在边缘分布下独立：共享、相关的隐状态仍能使它们相关。

于是联合分布为

$$p(z_{1:T}, o_{1:T} | \theta) = \pi_{z_1} \prod_{t=2}^T a_{z_{t-1}, z_t} \prod_{t=1}^T b_{z_t}(o_t).$$

三个核心问题是：求证据概率 $p(o_{1:T} | \theta)$ ，学习参数 θ ，以及寻找最可能的联合状态路径。它们分别对应前向/后向算法、Baum–Welch、Viterbi。

9.2 前向算法：把指数枚举变成递推

直接计算

$$p(o_{1:T} | \theta) = \sum_{z_{1:T}} p(z_{1:T}, o_{1:T} | \theta)$$

要枚举 K^T 条隐状态序列。求和对象是隐状态路径，不是已观测到的序列。

定义前向量

$$\alpha_t(i) = p(o_{1:t}, z_t = i | \theta).$$

初始化 $\alpha_1(i) = \pi_i b_i(o_1)$ 。对下一时刻：

$$\begin{aligned} \alpha_{t+1}(j) &= \sum_i p(o_{1:t+1}, z_t = i, z_{t+1} = j | \theta) \\ &= \sum_i p(o_{t+1} | z_{t+1} = j) p(z_{t+1} = j | z_t = i) p(o_{1:t}, z_t = i | \theta) \\ &= b_j(o_{t+1}) \sum_i \alpha_t(i) a_{ij}. \end{aligned}$$

最后 $p(o_{1:T} | \theta) = \sum_j \alpha_T(j)$ 。共有 T 层、每层 K^2 次量级计算，复杂度降为 $O(TK^2)$ 。原稿递推末项的 o_t 应改为 o_{t+1} 。

9.3 后向算法：从未来观测向前计算

定义

$$\beta_t(i) = p(o_{t+1:T} \mid z_t = i, \theta).$$

末端没有未来观测，因此 $\beta_T(i) = 1$ 。对下一隐状态求和：

$$\begin{aligned} \beta_t(i) &= \sum_j p(o_{t+1:T}, z_{t+1} = j \mid z_t = i, \theta) \\ &= \sum_j a_{ij} b_j(o_{t+1}) \beta_{t+1}(j). \end{aligned}$$

证据概率也可写成

$$p(o_{1:T} \mid \theta) = \sum_i \pi_i b_i(o_1) \beta_1(i).$$

更一般地，对任意 t ， $p(o_{1:T} \mid \theta) = \sum_i \alpha_t(i) \beta_t(i)$ 。

9.4 滤波、平滑与预测

滤波只使用到当前时刻的观测：

$$p(z_t = i \mid o_{1:t}) = \frac{\alpha_t(i)}{\sum_j \alpha_t(j)}.$$

平滑使用整条观测序列，包括当前时刻之后的信息：

$$\gamma_t(i) = p(z_t = i \mid o_{1:T}) = \frac{\alpha_t(i) \beta_t(i)}{\sum_j \alpha_t(j) \beta_t(j)}.$$

一步状态预测和观测预测分别为

$$\begin{aligned} p(z_{t+1} = j \mid o_{1:t}) &= \sum_i a_{ij} p(z_t = i \mid o_{1:t}), \\ p(o_{t+1} = v \mid o_{1:t}) &= \sum_j b_j(v) p(z_{t+1} = j \mid o_{1:t}). \end{aligned}$$

滤波是在线问题，平滑通常在已有整段数据时进行。二者都不等于联合路径解码。

9.5 Baum–Welch: HMM 中的 EM

为区分时间下标 t 和迭代次数, 用 r 表示 EM 轮数:

$$Q(\theta \mid \theta^{(r)}) = \sum_{z_{1:T}} p(z_{1:T} \mid o_{1:T}, \theta^{(r)}) \log p(o_{1:T}, z_{1:T} \mid \theta).$$

旧参数下的证据概率与新参数无关, 所以在求 $\arg \max_{\theta}$ 时可整体乘去归一化常数, 但 E 步中使用归一化后验更清晰。

9.5.1 E 步需要哪些统计量

除了单状态后验 $\gamma_t(i)$, 还需要相邻状态对的后验:

$$\xi_t(i, j) = p(z_t = i, z_{t+1} = j \mid o_{1:T}, \theta^{(r)}) = \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{p(o_{1:T} \mid \theta^{(r)})}.$$

右边的参数和消息全部用旧参数计算。分子分解为过去、转移、下一个观测和未来四部分。

取完整对数似然的期望后,

$$\begin{aligned} Q &= \sum_i \gamma_1(i) \log \pi_i \\ &\quad + \sum_{t=1}^{T-1} \sum_{i,j} \xi_t(i, j) \log a_{ij} \\ &\quad + \sum_{t=1}^T \sum_j \gamma_t(j) \log b_j(o_t). \end{aligned}$$

9.5.2 M 步: 期望计数归一化

最大化第一项, 约束 $\sum_i \pi_i = 1$ 。拉格朗日驻点为 $\gamma_1(i)/\pi_i + \lambda = 0$, 相乘求和后 $\lambda = -1$, 所以

$$\pi_i^{\text{new}} = \gamma_1(i).$$

这保留了原稿对初始分布的推导。对每一行转移概率施加相同的归一化约束, 得到补充更新

$$a_{ij}^{\text{new}} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}.$$

分子是从 i 到 j 的期望转移次数, 分母是离开 i 的期望机会数。离散发射概率为

$$b_j^{\text{new}}(v_k) = \frac{\sum_{t=1}^T \gamma_t(j) \mathbf{1}\{o_t = v_k\}}{\sum_{t=1}^T \gamma_t(j)}.$$

多个独立序列时，把相应期望计数跨序列相加，初始分布对各序列起点平均；不能把序列首尾误连。分母为零的状态需要单独处理。

9.6 Viterbi: 最可能的完整路径

目标是

$$\hat{z}_{1:T} = \arg \max_{z_{1:T}} p(z_{1:T} \mid o_{1:T}, \theta).$$

分母与路径无关，因此最大化联合概率即可。定义

$$\delta_t(j) = \max_{z_{1:t-1}} p(o_{1:t}, z_{1:t-1}, z_t = j \mid \theta).$$

初始化 $\delta_1(j) = \pi_j b_j(o_1)$ 。递推与回溯指针为

$$\begin{aligned} \delta_{t+1}(j) &= b_j(o_{t+1}) \max_i [\delta_t(i) a_{ij}], \\ \psi_{t+1}(j) &= \arg \max_i [\delta_t(i) a_{ij}]. \end{aligned}$$

先取 $\hat{z}_T = \arg \max_j \delta_T(j)$ ，再从后向前令 $\hat{z}_t = \psi_{t+1}(\hat{z}_{t+1})$ 。仅记录最大值而不保存前驱，不能恢复完整路径。

前向算法把路径概率相加，Viterbi 选取最大路径；逐时刻最大化 γ_t 又是另一个目标，可能产生不符合高概率转移结构的路径。

9.7 数值稳定性与连续状态的联系

长序列的概率连乘会下溢。可使用逐步缩放并累计对数尺度，或全程在对数域用 $\log\text{-sum-exp}$ ；Viterbi 则用加法替换乘法。

本书只少量衔接架构外材料：线性高斯状态空间模型使用连续状态，Kalman 滤波给出精确的预测—更新递推；粒子滤波用带权样本近似更一般的状态后验。LDS 是模型，Kalman 滤波是算法；粒子滤波也是算法，不是“所有非线性模型”的别名。

第十章 条件随机场

逻辑回归直接建模一个标签的条件概率，HMM 则建模状态与观测的联合分布。序列标注希望综合整段输入并协调相邻标签，可以直接建模 $p(y_{1:T} | x_{1:T})$ 。线性链 CRF 是这一思路的经典实现。

10.1 从 HMM 到 MEMM：局部归一化的限制

HMM 的生成式分解为

$$p(x, y) = \pi_{y_1} b_{y_1}(x_1) \prod_{t=2}^T a_{y_{t-1}, y_t} b_{y_t}(x_t).$$

观测独立性是在给定状态序列后的条件独立，不是“所有单词本来彼此独立”。HMM 同时建模观测生成，可能限制可方便使用的输入特征。

MEMM 直接建模

$$p(y | x) = \prod_{t=1}^T p(y_t | y_{t-1}, x),$$

每个局部转移可以是对数线性分类器，并可使用整个输入的特征。它的每个局部条件分布都要对后继状态归一化。

10.1.1 Label bias 的直觉

如果一个状态只有一个允许的后继，那么局部归一化会把该转移概率强制设为 1，无论输入对这条路径提供多少支持。这种局部归一化限制了不同路径之间比较观测证据的方式，是标签偏置问题的典型直觉。

CRF 改为给整条标签路径打分，再在所有路径之间统一归一化。它保留标签链上的局部因子结构；不能简单说成“去掉箭头就破坏齐次 Markov 假设”。

10.2 线性链 CRF 的条件分布

令 y_0 为固定的开始状态, $\mathcal{S}$ 为标签集合。用局部得分 s_t 定义

$$p_{\theta}(y \mid x) = \frac{1}{Z(x, \theta)} \exp \left[\sum_{t=1}^T s_t(y_{t-1}, y_t, x) \right],$$

$$Z(x, \theta) = \sum_{y_{1:T} \in \mathcal{S}^T} \exp \left[\sum_{t=1}^T s_t(y_{t-1}, y_t, x) \right].$$

这是离散标签的条件概率质量函数, 正文使用“条件分布”, 避免误称连续 PDF。输入 x 被条件化, 不必再给它指定独立生成分布。




图 10.1: 给定整段输入后的标签链: 相邻标签通过局部势函数联系, 所有路径共享同一个全局配分函数。

10.2.1 转移特征与状态特征

一种常见参数化是

$$s_t(a, b, x) = \sum_{k=1}^{K_f} \lambda_k f_k(a, b, x, t) + \sum_{l=1}^{L_f} \eta_l g_l(b, x, t).$$

f_k 表达转移与输入关系, g_l 表达某标签与输入的关系。即使参数跨时刻共享, 特征仍可以依赖位置与上下文。

把参数拼成 θ , 把整条路径上累计的特征拼成 $F(y, x)$, 可统一写成

$$p_{\theta}(y \mid x) = \exp[\theta^{\top} F(y, x) - \log Z(x, \theta)].$$

对固定输入，这是指数族结构。特征可以设计很多个，数量不受 $|\mathcal{S}|$ 或 $|\mathcal{S}|^2$ 的一般上界约束；仅用状态/转移指示函数时才会出现对应计数。

10.3 前向后向：计算配分函数与边缘

令势函数 $\psi_t(a, b; x) = e^{s_t(a, b, x)}$ 。对固定输入省略参数。定义 $\alpha_t(j)$ 为所有以 $y_t = j$ 结束的前缀路径的未归一化权重和：

$$\alpha_1(j) = \psi_1(y_0, j; x), \quad \alpha_t(j) = \sum_{i \in \mathcal{S}} \alpha_{t-1}(i) \psi_t(i, j; x).$$

末端求和得到 $Z(x) = \sum_j \alpha_T(j)$ 。 y_0 是固定值，不对它枚举所有普通标签。

后向量是固定 $y_t = i$ 后，所有后缀权重之和：

$$\beta_T(i) = 1, \quad \beta_t(i) = \sum_j \psi_{t+1}(i, j; x) \beta_{t+1}(j).$$

10.3.1 单点边缘为什么是前后两部分的乘积

固定 $y_t = i$ 后，链分为左右两段。对左段所有标签求和得到 $\alpha_t(i)$ ，对右段所有标签求和得到 $\beta_t(i)$ ，所以

$$p(y_t = i \mid x) = \frac{\alpha_t(i) \beta_t(i)}{Z(x)}.$$

固定两个相邻标签，则

$$p(y_{t-1} = i, y_t = j \mid x) = \frac{\alpha_{t-1}(i) \psi_t(i, j; x) \beta_t(j)}{Z(x)}, \quad t \geq 2.$$

首位置使用固定开始状态单独处理。原稿中左右两段求和的长展开，实质上就是这两个消息的定义。动态规划将枚举所有路径的指数复杂度降为 $O(T|\mathcal{S}|^2)$ 。

10.4 参数学习：经验特征减模型期望

给定训练序列 $(x^{(n)}, y^{(n)})$ ，条件对数似然为

$$\ell(\theta) = \sum_{n=1}^N [\theta^\top F(y^{(n)}, x^{(n)}) - \log Z(x^{(n)}, \theta)].$$

利用指数族的对数配分函数导数：

$$\nabla_{\theta} \log Z(x, \theta) = \mathbb{E}_{p_{\theta}(y|x)} F(y, x).$$

因此

$$\nabla \ell(\theta) = \sum_n [F(y^{(n)}, x^{(n)}) - \mathbb{E}_{p_{\theta}(y|x^{(n)})} F(y, x^{(n)})].$$

第一项来自真实标签，第二项是当前模型的平均预测特征。学习推动二者匹配。

10.4.1 为什么不需要枚举所有路径求期望

对某个转移特征，

$$\begin{aligned} \mathbb{E} \sum_t f_k(y_{t-1}, y_t, x, t) &= \sum_t \sum_y p(y | x) f_k(y_{t-1}, y_t, x, t) \\ &= \sum_t \sum_{i,j} p(y_{t-1} = i, y_t = j | x) f_k(i, j, x, t). \end{aligned}$$

因为特征只依赖两个标签，其余标签求和形成状态对边缘。状态特征则用单点边缘。两者都可由前向后向计算。

固定特征且参数线性时，对数似然为凹函数；加入 $-\frac{\rho}{2} \|\theta\|^2$ 正则项后，梯度再减 $\rho\theta$ 。可用梯度或拟牛顿方法优化。完整训练循环是：计算消息、得到边缘与梯度、更新参数。

10.5 译码：选择分数最高的路径

$Z(x, \theta)$ 与待比较的标签路径无关，因此

$$\hat{y} = \arg \max_y \sum_t s_t(y_{t-1}, y_t, x).$$

定义最优前缀得分 $v_t(j)$ ：

$$v_1(j) = s_1(y_0, j, x), \quad v_t(j) = \max_i [v_{t-1}(i) + s_t(i, j, x)].$$

保存取得最大值的前驱，从末端最优标签向前回溯，即得到 Viterbi 路径。边缘推断用求和，联合译码用最大值；二者需要分清。

10.6 与 HMM 的对照

方面	HMM	线性链 CRF
建模对象	$p(x, y)$	$p(y \mid x)$
输入处理	需要观测生成分布	可使用丰富的输入特征
归一化	初始、转移、发射分布分别归一化	整条标签路径全局归一化
概率计算	前向后向	前向后向
联合译码	Viterbi	Viterbi
学习	常用 EM 处理未观测状态	有监督条件似然梯度

两种模型共享动态规划工具，但概率假设与学习目标不同。CRF 的优势来自条件建模和全局归一化，并非自动取消所有标签依赖结构。

附录 A MCMC

本附录保留原稿从普通 Monte Carlo 到 MCMC 的路线。采样既可用于生成样本，也可用于近似求和、积分和后验期望。困难在于目标分布可能只知道未归一化密度，或虽能求值却难以直接抽样。

A.1 Monte Carlo 估计

若 $z^{(1)}, \dots, z^{(N)}$ 独立同分布于 p ，则在可积条件下，

$$\mathbb{E}_p[f(z)] \approx \frac{1}{N} \sum_{i=1}^N f(z^{(i)}).$$

独立性使经典方差分析简单；MCMC 通常生成相关样本，在适当遍历条件下，时间平均仍能收敛到目标期望。因此不能把“样本必须独立”作为所有 Monte Carlo 方法的必要条件。

A.1.1 逆变换采样

对一维分布，取 $u \sim \text{Uniform}(0, 1)$ ，令 $z = F^{-1}(u)$ 。更一般地用广义逆。困难不一定是 CDF 不存在，而是 CDF 或其逆难以高效计算；高维分布也不能简单套用一个标量逆函数。

A.1.2 拒绝采样

选容易采样的提议分布 q ，并找到有限常数 M ，使 $p(z) \leq Mq(z)$ 。重复：先取 $z \sim q$ ，再取 $u \sim U(0, 1)$ ，若

$$u \leq \frac{p(z)}{Mq(z)}$$

则接受，否则重试。若只知道 $\tilde{p} = Zp$ ，可以使用 $\tilde{p}(z) \leq Cq(z)$ 的包络及接受率 $\tilde{p}/(Cq)$ ，不必预先知道 Z 。困难通常是找到紧的全局包络；包络太松会导致大量拒绝。

A.1.3 重要性采样与重采样

要求提议分布在目标积分有贡献处非零。利用

$$\mathbb{E}_p[f] = \int q(z) \frac{p(z)}{q(z)} f(z) dz,$$

从 q 抽样后估计

$$\hat{I} = \frac{1}{N} \sum_i \frac{p(z^{(i)})}{q(z^{(i)})} f(z^{(i)}).$$

若只有未归一化目标, 令 $\tilde{w}_i = \tilde{p}(z^{(i)})/q(z^{(i)})$, 得到自归一化估计

$$\hat{I}_{\text{SN}} = \sum_i \bar{w}_i f(z^{(i)}), \quad \bar{w}_i = \frac{\tilde{w}_i}{\sum_j \tilde{w}_j}.$$

自归一化估计有限样本通常有偏, 但在合适条件下相合。问题是权重过度集中, 而不是权重绝对值小; 所有未归一化权重乘同一个常数不改变估计。

SIR 在提议样本中按 $\bar{w}_i$ 再抽样, 输出等权样本。它可复制高权重点, 不能凭空增加原样本的信息或保证去除相关性。

A.2 马尔可夫链与平稳分布

MCMC 常用离散时间的马尔可夫链, 但状态空间可以离散, 也可以连续。一阶马尔可夫性为

$$p(z_{t+1} | z_0, \dots, z_t) = p(z_{t+1} | z_t).$$

转移核不随时间变化时称为齐次链。若核写为 $P(z' | z)$, 平稳分布满足

$$\pi(z') = \int \pi(z) P(z' | z) dz.$$

含拒绝和原地停留的核可能带点质量, 此时应将积分理解为对转移核积分。平稳的含义是: 若当前服从 π , 下一步仍服从 π ; 它不意味着从任意初始分布运行有限步后精确变成 π 。

A.2.1 细致平衡

若

$$\pi(z)P(z' | z) = \pi(z')P(z | z'),$$

则对 z 积分，利用转移核归一化得到平稳性。细致平衡是平稳性的充分条件，不是必要条件；满足它的链称为可逆链。

A.2.2 有平稳分布不等于从任意初值收敛

有限状态、不可约且非周期的链有唯一平稳分布，并从任意初始分布收敛到它。连续状态需要相应的不可约性、Harris 遍历性等条件，不能只说“满足细致平衡所以收敛”。

例如

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

有平稳分布 $(1/2, 1/2)$ ，但从单个状态开始会交替跳动，边缘分布不收敛。

A.3 转移矩阵的谱视角

按行概率向量约定， $P_{ij} = P(z_{t+1} = j | z_t = i)$ ，每行和为 1，分布更新为 $q_{t+1} = q_t P$ 。

随机矩阵的所有特征值满足 $|\lambda| \leq 1$ ，而不是只比较实数大小。原稿写 $P = A\Lambda A^{-1}$ 还隐含可对角化条件；一般矩阵不一定可以这样分解。

若可对角化、特征值 1 单重且其他特征值模严格小于 1，则其余模态随幂次渐近衰减， P^t 趋向平稳投影。有限状态不可约非周期链提供了相应收敛结论。衰减一般是趋近零，不是在“足够大但有限”的步数后全部精确为零。

A.4 Metropolis–Hastings：修正提议使目标平稳

希望目标分布 $\pi(z) \propto \tilde{\pi}(z)$ 为平稳分布。选择提议核 $q(z' | z)$ ，接受率为

$$\alpha(z, z') = \min \left\{ 1, \frac{\tilde{\pi}(z')q(z | z')}{\tilde{\pi}(z)q(z' | z)} \right\}.$$

归一化常数在比值中消掉。不同状态之间的转移概率密度为 $q(z' | z)\alpha(z, z')$ ，剩余概率用于原地停留。

A.4.1 细致平衡的验证

$$\begin{aligned}\pi(z)q(z' | z)\alpha(z, z') &= \min\{\pi(z)q(z' | z), \pi(z')q(z | z')\} \\ &= \pi(z')q(z | z')\alpha(z', z).\end{aligned}$$

因此完整转移核以 π 为平稳分布。若提议无法连通不同区域，仍可能不能遍历目标，所以提议核不能只满足形式上的接受率公式。

A.4.2 算法

从目标支持内的初值 $z^{(0)}$ 开始，每轮：

1. 取候选 $z' \sim q(\cdot | z^{(t)})$ 。
2. 计算 $\alpha(z^{(t)}, z')$ ，取 $u \sim U(0, 1)$ 。
3. 若 $u \leq \alpha$ ，令 $z^{(t+1)} = z'$ ；否则保留 $z^{(t+1)} = z^{(t)}$ 。
4. 无论接受与否，都记录新的链状态。

只记录被接受的点通常会改变采样分布。对称提议可消去两个 q ，得到基本 Metropolis 接受率。

A.5 Gibbs 采样：每次更新一个条件分布

将 $z = (z_1, \dots, z_d)$ 。依次取

$$z_j^{(t+1)} \sim \pi(z_j | z_1^{(t+1)}, \dots, z_{j-1}^{(t+1)}, z_{j+1}^{(t)}, \dots, z_d^{(t)}).$$

已更新的坐标用新值，尚未更新的用旧值。也可随机选择坐标，或按块更新。

A.5.1 为什么单坐标更新接受率为 1

某一步只有坐标 j 改变，因此 $z'_{-j} = z_{-j}$ 。提议正好是目标全条件分布：

$$\frac{\pi(z')q(z | z')}{\pi(z)q(z' | z)} = \frac{\pi(z'_j | z_{-j})\pi(z_{-j})\pi(z_j | z_{-j})}{\pi(z_j | z_{-j})\pi(z_{-j})\pi(z'_j | z_{-j})} = 1.$$

因此每个这样的 Gibbs 子步骤都是接受率为 1 的 MH 更新。固定顺序的一整轮组合仍保持目标平稳，但整体转移核不一定可逆。接受率为 1 也不表示混合快；高度相关变量可能移动非常缓慢。

A.6 怎样看待 burn-in、相关性与诊断

burn-in 是实践中舍弃初始部分样本的做法；混合时间是关于分布接近程度的概念，二者不能直接等同。有限轨迹上的诊断能够发现某些问题，不能仅凭一张平稳曲线证明已经收敛。

可检查多条链、轨迹、自相关和有效样本量。对平稳标量序列，在适用条件下，常见近似为

$$N_{\text{eff}} \approx \frac{N}{1 + 2 \sum_{k \geq 1} \rho_k},$$

其中 ρ_k 是滞后相关。间隔取样可能降低保留样本之间的相关性，但会丢弃数据，并不自动提高每单位计算量的信息效率。

多峰目标可能使链长期困在单个峰内。应关注提议尺度、参数化与链的混合；不能仅为采样方便就把原模型改成独立结构而不承认建模假设发生了变化。

本附录需要掌握三层区别：**目标平稳分布、从初值向它收敛、利用相关轨迹估计期望**。它们互相关联，但不是同一句话。