

凸优化工具箱

面向人工智能与机器学习的理论、几何与算法

Gary Chen

2026-09-19

目录

前言	10
阅读路径	10
I 基础语言与几何	11
1 优化问题与凸优化视角	12
1.1 优化问题的基本组成	12
1.2 最优值与最优解	13
1.2.1 局部最优与全局最优	13
1.3 问题类别与结构	14
1.3.1 最小二乘	14
1.3.2 线性规划	14
1.4 什么使一个问题成为凸优化问题	15
1.5 为什么凸性值得识别	15
1.6 从模型到算法	15
1.7 本章小结	16
2 凸集与几何工具	17
2.1 三类组合与三类集合	17
2.1.1 仿射集	17
2.1.2 凸集	18
2.1.3 凸锥	18
2.2 仿射包、凸包与锥包	19
2.3 相对内部	19
2.4 典型凸集	20
2.4.1 超平面与半空间	20
2.4.2 范数球与椭球	20
2.4.3 多面体	20
2.4.4 范数锥与半正定锥	21
2.5 保持凸性的集合运算	21
2.5.1 任意交	21
2.5.2 仿射像与原像	21
2.5.3 笛卡尔积与 Minkowski 和	22
2.5.4 线性分式映射	22

2.6	分离超平面	23
2.6.1	点与闭凸集的分离	24
2.7	支撑超平面	24
2.8	判断集合凸性的实用流程	25
2.9	典型误区	25
2.10	本章小结	25
3	凸函数、判定方法与保凸运算	26
3.1	凸函数的定义	26
3.1.1	基本定义	26
3.1.2	严格凸函数	27
3.1.3	扩展值表示	27
3.2	三类常用判定方法	27
3.2.1	零阶判定：限制在任意直线上	28
3.2.2	一阶判定：切平面是全局下界	28
3.2.3	二阶判定：Hessian 半正定	30
3.3	上境图、下水平集与 Jensen 不等式	31
3.3.1	上境图：把函数变成集合	31
3.3.2	下水平集与拟凸性	31
3.3.3	Jensen 不等式	32
3.4	常用凸函数原子	32
3.5	保持凸性的运算	33
3.5.1	非负加权和	33
3.5.2	与仿射映射复合	33
3.5.3	逐点最大值与上确界	34
3.5.4	一般复合：必须检查单调性	34
3.5.5	部分极小化	35
3.5.6	透视变换	36
3.6	普通凸、严格凸与强凸	37
3.7	凸性判断的实用流程	38
3.8	典型误区	38
3.9	本章小结	38
II	问题、对偶与最优性	39
4	凸优化问题的构造与等价变换	40
4.1	标准凸优化问题	40
4.2	局部最优为什么成为全局最优	41
4.3	一阶最优性条件	41
4.3.1	必要性	41
4.3.2	充分性	42
4.4	等价变换的基本原则	42

4.5	变量替换	42
4.6	消去仿射等式约束	43
4.7	引入松弛变量	43
4.8	上境图形式	44
4.9	显式约束与隐式约束	44
4.10	部分极小化	45
4.11	等价凸问题	45
4.11.1	单调变换目标	45
4.12	拟凸优化与二分法	46
4.13	建模检查清单	46
4.14	典型误区	47
4.15	本章小结	47
5	共轭函数、Lagrange 对偶与 KKT	48
5.1	共轭函数	48
5.1.1	基本性质	48
5.1.2	常用例子	49
5.2	Fenchel–Young 不等式	51
5.3	Lagrangian	52
5.4	原问题的极大表示	52
5.5	对偶函数与对偶问题	53
5.6	用共轭计算对偶函数	53
5.6.1	核心恒等式：消去带线性项的变量	54
5.6.2	仿射约束下的通用模板	54
5.6.3	例子：等式约束下的最小范数	55
5.6.4	变量分裂：为复合目标构造对偶	56
5.6.5	使用边界	57
5.7	弱对偶	57
5.8	对偶函数的一个推导例子	58
5.9	对偶间隙与强对偶	58
5.10	Slater 条件	59
5.11	互补松弛	60
5.12	KKT 条件	61
5.12.1	从 Fenchel–Young 等号看驻点条件	61
5.12.2	KKT 的充分性	62
5.12.3	KKT 的必要性	62
5.13	一个一维 KKT 例子	63
5.14	鞍点解释	63
5.15	Slater、强对偶与 KKT 的关系	63
5.16	典型误区	64
5.17	本章小结	64

III 算法工具箱	65
6 强凸性、光滑性与下降框架	66
6.1 强凸性	66
6.1.1 二阶判据	67
6.2 强凸性的直接推论	67
6.2.1 最优解唯一	67
6.2.2 函数误差控制距离误差	67
6.2.3 梯度控制函数误差	68
6.3 光滑性	68
6.3.1 二次上界	69
6.3.2 二阶判据	69
6.4 光滑性的下降保证	70
6.5 梯度余强制性	70
6.5.1 强凸光滑情形的加强	71
6.6 强凸与光滑的联合控制	71
6.7 条件数	72
6.8 一般下降方法	72
6.9 步长选择	73
6.9.1 固定步长	73
6.9.2 精确线搜索	73
6.9.3 回溯线搜索	73
6.9.4 Wolfe 与 Goldstein 条件	74
6.10 线搜索的收敛接口: Zoutendijk 定理	74
6.10.1 从可求和到梯度趋于零	76
6.11 典型误区	76
6.12 本章小结	76
7 梯度方法与无约束优化	77
7.1 梯度下降法	77
7.2 为什么负梯度是最速下降方向	78
7.2.1 最速下降依赖所选范数	78
7.3 步长的三种选择	79
7.3.1 固定步长	79
7.3.2 精确线搜索	79
7.3.3 回溯线搜索	79
7.4 如何阅读收敛速度	79
7.5 光滑凸函数的 $O(1/k)$ 收敛率	80
7.5.1 单步势函数下降	80
7.5.2 求和	81
7.6 强凸光滑函数的线性收敛	82
7.6.1 一般强凸光滑函数的距离收缩	83
7.7 二次函数中的谱视角	83

7.8	线搜索与固定步长如何选择	84
7.9	与进阶无约束方法的接口	84
7.10	典型误区	85
7.11	本章小结	85
8	约束优化与复合结构	86
8.1	Euclidean 投影	86
8.1.1	常见投影	86
8.2	投影的变分刻画	87
8.2.1	Pythagorean 不等式	88
8.2.2	非扩张性	88
8.3	投影梯度法	88
8.3.1	二次模型解释	89
8.4	光滑凸情形的 $O(1/k)$ 速率	89
8.5	仅有梯度界时的 $O(1/\sqrt{K})$ 速率	90
8.6	等式约束与 KKT 线性系统	91
8.7	三种约束处理路线	91
8.8	复合结构的边界	92
8.9	典型误区	92
8.10	本章小结	92
IV	模型与应用	93
9	典型凸模型与机器学习应用	94
9.1	线性规划	94
9.1.1	Chebyshev 逼近	95
9.2	二次规划与最小二乘	95
9.2.1	最小二乘	95
9.2.2	加权最小二乘	96
9.2.3	Ridge 回归	96
9.3	范数逼近	97
9.3.1	ℓ_1 逼近的线性规划形式	97
9.3.2	带约束的逼近	97
9.4	正则化与约束形式	98
9.4.1	ℓ_1 与 ℓ_2 正则化	98
9.5	最小范数问题	99
9.6	凸集投影	99
9.6.1	投影到超平面	100
9.7	线性分类与最大间隔	100
9.7.1	硬间隔 SVM	101
9.7.2	软间隔 SVM	102
9.8	Logistic 回归	102

9.9	模型识别速查	103
9.10	典型误区	103
9.11	本章小结	103
附录		104
A	数学预备工具箱	104
A.1	内积与 Cauchy–Schwarz 不等式	104
A.1.1	矩阵内积	105
A.2	向量范数	105
A.3	对偶范数与 Hölder 不等式	106
A.4	矩阵算子范数	106
A.4.1	输入与输出范数	106
A.4.2	谱范数: Euclidean 长度的最大放大倍数	107
A.4.3	常用公式与记号边界	107
A.4.4	应用: 最小二乘的光滑常数	108
A.5	谱范数与核范数的对偶	108
A.5.1	三种常用矩阵范数	108
A.5.2	矩阵空间中的对偶范数	109
A.5.3	关键证明: 用 SVD 找到达到上界的矩阵	110
A.5.4	为什么核范数用于低秩优化	111
A.5.5	与向量 Euclidean 范数的区别	111
A.6	向量、矩阵与张量求导	111
A.6.1	Jacobian、梯度与方向导数	111
A.6.2	矩阵变量与 Frobenius 配对	112
A.6.3	用微分计算矩阵梯度	113
A.6.4	高频向量梯度	114
A.6.5	高频矩阵梯度	114
A.6.6	链式法则与反向传播	115
A.6.7	向量、矩阵与张量输出	117
A.6.8	求导检查清单	118
A.7	Hessian 与二阶方向信息	118
A.8	正定与半正定矩阵	119
A.9	特征值分解、SVD 与伪逆	120
A.10	Schur 补	120
A.11	维度检查清单	121
A.12	本附录小结	121
B	广义不等式与锥规划	122
B.1	正常锥与广义不等式	122
B.1.1	三个基本例子	123

B.2	对偶锥	123
B.2.1	自对偶锥	124
B.2.2	广义不等式的对偶刻画	124
B.3	关于锥的凸映射	125
B.4	锥规划标准形式	125
B.5	锥规划对偶	126
B.6	锥 Slater 条件与 KKT	127
B.6.1	广义不等式约束的 KKT	128
B.7	线性规划作为锥规划	129
B.8	二阶锥规划	129
B.8.1	旋转二阶锥	130
B.9	半定规划	130
B.9.1	谱范数的 LMI 表示	131
B.10	三类锥规划的统一视角	132
B.11	建模检查清单	132
B.12	典型误区	132
B.13	本附录小结	132
C	进阶算法工具箱	133
C.1	次梯度与次微分	133
C.1.1	常用例子	133
C.1.2	最优性条件与运算法则	134
C.2	次梯度法	135
C.3	近端算子	136
C.3.1	三个高频近端映射	137
C.3.2	稳定性与 Moreau 包络	138
C.4	近端梯度法	138
C.5	加速梯度与 FISTA	140
C.6	坐标下降	141
C.7	Newton 法	142
C.7.1	局部二次收敛	143
C.8	信赖域: 限制模型可信的范围	144
C.9	拟 Newton 与 BFGS	145
C.10	增广 Lagrangian 方法	146
C.11	ADMM	147
C.11.1	原始残差与对偶残差	147
C.11.2	变量分裂例子	148
C.11.3	收敛边界	148
C.12	方法选择速查	148
C.13	典型误区	149
C.14	本附录小结	149

D	随机梯度、镜像下降与在线优化	150
D.1	四种信息模式	150
D.2	随机目标与随机一阶 oracle	150
D.3	随机梯度下降	152
D.3.1	一般凸情形的主界	152
D.3.2	强凸情形	153
D.4	光滑非凸目标中的 SGD	154
D.5	小批量、采样与步长	155
D.6	为什么需要镜像下降	156
D.7	Bregman 散度	156
D.8	镜像下降更新	157
D.8.1	单步核心不等式	157
D.9	两种核心几何	158
D.9.1	Euclidean 几何	158
D.9.2	概率单纯形上的负熵几何	158
D.10	随机镜像下降	159
D.11	在线凸优化	160
D.12	在线梯度下降	161
D.12.1	强凸在线损失	162
D.13	在线镜像下降	162
D.14	FTRL	163
D.15	Online-to-batch 转换	164
D.16	静态遗憾与非平稳环境	165
D.17	与自适应方法、optimism 和 Bandit 的接口	165
D.17.1	自适应几何	165
D.17.2	Optimism	166
D.17.3	Bandit feedback	166
D.18	方法选择速查	166
D.19	典型误区	167
D.20	本附录小结	167
E	记号表	168

前言

本笔记是笔者学习凸优化这门课程积累下来的工具箱，主要梳理思路为：

凸几何与凸函数 → 凸问题建模 → 对偶与最优性证书 → 算法与收敛 → 机器学习模型

目的在于组织凸优化课程中的核心概念、关键推导和常用算法，便于复习取用。

阅读路径

- 第 1-3 章建立凸优化的语言与几何基础；
- 第 4-5 章处理凸问题、对偶和 KKT 条件；
- 第 6-8 章组织强凸与光滑条件、一阶方法和约束优化算法；
- 第 9 章连接正则化、投影、分类等机器学习问题；
- 附录集中保存数学预备、锥规划、不可微与复合算法、二阶与分裂算法，以及随机梯度、镜像下降与在线优化。

公开来源与尚待补齐的材料身份见仓库的[参考资料](#)。

Part I

基础语言与几何

1 优化问题与凸优化视角

优化把“作出一个选择”写成数学问题：变量描述可以改变的量，约束排除不允许的选择，目标函数则比较剩余选择的优劣。凸优化关注其中结构最好的一类问题——它通常没有闭式解，但局部信息足以支持全局判断和可靠算法。

1.1 优化问题的基本组成

一般优化问题写为

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{1.1}$$

其中：

- $x \in \mathbb{R}^n$ 是优化变量；
- f_0 是目标函数；
- f_i 是不等式约束函数；
- h_j 是等式约束函数。

可行集为

$$\mathcal{X} = \{x \mid f_i(x) \leq 0, \quad i = 1, \dots, m; + h_j(x) = 0, \quad j = 1, \dots, p\}.$$

若 $\mathcal{X} = \emptyset$ ，问题不可行；否则，任意 $x \in \mathcal{X}$ 称为可行点。

建模视角

变量、约束和目标分别回答三个不同问题：可以决定什么、必须满足什么、希望优化什么。很多建模错误并非出在算法，而是把要求放错了位置，例如把必须满足的安全限制写成一个权重很小的惩罚项。

1.2 最优值与最优解

最优值定义为

$$p^* = \inf_{x \in \mathcal{X}} f_0(x).$$

使用 $\inf$ 而不是 $\min$ ，是因为最优值未必能被某个可行点取到。若存在 $x^* \in \mathcal{X}$ 使

$$f_0(x^*) = p^*,$$

则称 x^* 为最优解，并记最优解集合为

$$\mathcal{X}^* = \operatorname{argmin}_{x \in \mathcal{X}} f_0(x).$$

最优值和最优解必须区分：

- p^* 是一个数；
- $\mathcal{X}^*$ 是一个集合，可能为空、只含一点或包含多个点。

例如，

$$\inf_{x > 0} x = 0,$$

但没有 $x > 0$ 能取到 0，因此最优值有限而最优解不存在。

如果存在可行序列 x_k 使 $f_0(x_k) \rightarrow -\infty$ ，则问题向下无界，记 $p^* = -\infty$ 。不可行问题通常约定 $p^* = +\infty$ 。

1.2.1 局部最优与全局最优

若存在 $r > 0$ ，使得

$$f_0(x^*) \leq f_0(x), \quad \forall x \in \mathcal{X} \cap B(x^*, r),$$

则 x^* 是局部最优点。若不需要限制在邻域内，而对所有 $x \in \mathcal{X}$ 都成立，则它是全局最优点。

一般非凸问题可能存在许多质量不同的局部最优点；凸优化的核心优势之一，是任意局部最优点都是全局最优点。这个结论依赖可行集和目标函数共同具有凸性，而不是单独来自“目标函数看起来光滑”。

1.3 问题类别与结构

优化问题的难度主要由结构决定，而不只由变量个数决定。

问题类别	典型结构	全局求解特征
最小二乘	二次误差 $\ Ax - b\ _2^2$	常可由线性代数直接求解
线性规划	线性目标与线性约束	有成熟的全局算法
凸优化	凸目标、凸不等式约束、仿射等式约束	局部最优即全局最优
一般非线性优化	不保证凸性	通常只能寻求局部解或特殊结构

1.3.1 最小二乘

基本最小二乘问题为

$$\min_x \frac{1}{2} \|Ax - b\|_2^2.$$

其一阶最优性条件是正规方程

$$A^\top Ax = A^\top b.$$

若 A 列满秩，则解唯一：

$$x^* = (A^\top A)^{-1} A^\top b.$$

实际计算通常不显式形成逆矩阵，而使用 QR 分解或其他数值稳定方法。这里的闭式表达主要用于揭示结构。

1.3.2 线性规划

线性规划的一种形式是

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && Ax \leq b. \end{aligned}$$

它一般没有统一的闭式解，但具有成熟可靠的算法。最小二乘和线性规划都属于凸优化的特例。

1.4 什么使一个问题成为凸优化问题

标准凸优化问题要求：

1. 目标函数 f_0 为凸函数；
2. 每个不等式约束函数 f_i 为凸函数；
3. 每个等式约束函数 h_j 为仿射函数。

等式约束不能任意使用凸函数。例如集合

$$\{x \mid x^2 = 1\} = \{-1, 1\}$$

不是凸集。仿射等式的解集才会保持凸性。

凸优化之所以特殊，并不是因为它“没有非线性”。指数函数、对数函数、范数和许多二次函数都是非线性的，却仍可构成凸问题。真正的分界是凸性。

1.5 为什么凸性值得识别

凸结构带来四类可复用结论：

1. **局部与全局统一。**局部最优点就是全局最优点。
2. **一阶条件具有全局意义。**梯度为零或相应的变分不等式不再只是局部必要条件。
3. **对偶可以提供下界与最优性证书。**在适当条件下，原问题与对偶问题最优值相等。
4. **算法可以给出明确收敛保证。**速率能够用光滑性、强凸性和条件数刻画。

但识别凸结构往往比运行求解器更需要判断。一个问题可能以非标准形式出现，需要经过变量替换、消去等式约束、上境图变换或引入辅助变量才能显出凸性。



凸优化不等于轻松优化

凸性排除了坏的局部极小值，却不自动解决病态条件数、超大规模、不可微性或高精度计算成本。凸性保证的是结构可控，而不是所有实例都计算便宜。

1.6 从模型到算法

后续各章依次处理一条完整链路：

1. 用凸集描述可行域；
2. 用凸函数描述目标与约束；
3. 把问题变换为可识别的凸形式；

4. 用对偶与 KKT 刻画最优性;
5. 根据光滑性、强凸性和约束结构选择算法;
6. 将这些模板复用于回归、正则化、投影和分类模型。

1.7 本章小结

优化问题由变量、目标和约束组成。最优值使用 $\inf$ 描述，最优解则要求下确界实际取到。凸优化的关键不是“函数是否线性”，而是目标与可行域是否具有凸结构；一旦结构成立，局部信息、对偶下界和迭代算法都能获得全局意义。

2 凸集与几何工具

凸优化首先要求可行域是凸集。几何上，这意味着任意两个可行点之间的整条线段仍然可行；算法因此可以沿连续方向移动，而不会在两个可行点之间突然穿过不可行区域。

2.1 三类组合与三类集合

给定 $x_1, \dots, x_k \in \mathbb{R}^n$ ，考虑

$$x = \sum_{i=1}^k \theta_i x_i.$$

系数条件决定了组合的几何含义：

组合	系数条件	几何含义
线性组合	无额外限制	由原点出发的线性结构
仿射组合	$\sum_i \theta_i = 1$	与原点选择无关
凸组合	$\sum_i \theta_i = 1, \theta_i \geq 0$	点之间的加权平均
锥组合	$\theta_i \geq 0$	从原点沿给定方向张成

2.1.1 仿射集

若对任意 $x, y \in C$ 和 $\theta \in \mathbb{R}$,

$$\theta x + (1 - \theta)y \in C,$$

则 C 为仿射集。仿射集允许沿连接两点的整条直线延伸，而不只保留线段。

任意非空仿射集都可以写成

$$C = x_0 + V,$$

其中 V 是线性子空间。线性方程组的解集

$$C = \{x \mid Ax = b\}$$

就是典型仿射集；若它非空，取一个特解 x_0 ，则

$$C = x_0 + \text{null}(A).$$

2.1.2 凸集

若对任意 $x, y \in C$ 和 $\theta \in [0, 1]$,

$$\theta x + (1 - \theta)y \in C, \tag{2.1}$$

则 C 为凸集。由归纳法，式 2.1 等价于： C 包含其任意有限个点的所有凸组合。

2.1.3 凸锥

若 K 为凸集，并且

$$x \in K, \quad \alpha \geq 0 \quad \implies \quad \alpha x \in K,$$

则称 K 为凸锥。等价地， K 对任意锥组合封闭：

$$x, y \in K, \quad \alpha, \beta \geq 0 \quad \implies \quad \alpha x + \beta y \in K.$$

例如非负正交锥

$$\mathbb{R}_+^n = \{x \mid x_i \geq 0\}$$

和半正定锥

$$\mathbb{S}_+^n = \{X \in \mathbb{S}^n \mid z^\top X z \geq 0, \forall z \in \mathbb{R}^n\}$$

都是凸锥。

2.2 仿射包、凸包与锥包

一个集合通常不具备所需结构，可以通过取“最小包”补齐。

仿射包定义为

$$\text{aff } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \sum_{i=1}^k \theta_i = 1 \right\}.$$

凸包定义为

$$\text{conv } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0, \sum_{i=1}^k \theta_i = 1 \right\}.$$

锥包定义为

$$\text{cone } C = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in C, \theta_i \geq 0 \right\}.$$

它们分别是包含 C 的最小仿射集、最小凸集和最小凸锥。

💡 凸包的建模意义

离散候选集合往往难以直接优化。把它替换为凸包，相当于允许候选点之间进行随机化或连续混合。这会得到一个凸松弛；松弛解未必属于原离散集合，但能提供原问题的界和近似方向。

2.3 相对内部

低维凸集在环境空间中可能没有内部。例如， $\mathbb{R}^2$ 中的一条线段内部为空，但它在自身所在直线上有自然的内部。

集合 C 的相对内部定义为

$$\text{relint } C = \{x \in C \mid \exists r > 0, B(x, r) \cap \text{aff } C \subseteq C\}.$$

相对内部把邻域限制在 $\text{aff } C$ 中。后续 Slater 条件使用相对内部，正是为了允许定义域或可行域位于低维仿射空间。

2.4 典型凸集

2.4.1 超平面与半空间

对 $a \neq 0$, 集合

$$H = \{x \mid a^\top x = b\}$$

是超平面, 而

$$H_- = \{x \mid a^\top x \leq b\}$$

是闭半空间。超平面是仿射集, 半空间是凸集。

向量 a 是超平面的法向量。点 x_0 到超平面的 Euclidean 距离为

$$\text{dist}(x_0, H) = \frac{|a^\top x_0 - b|}{\|a\|_2}.$$

2.4.2 范数球与椭球

任意范数下的球

$$B = \{x \mid \|x - x_c\| \leq r\}$$

都是凸集, 因为范数满足三角不等式。

若 $P \succ 0$, 椭球可以写为

$$E = \{x \mid (x - x_c)^\top P^{-1}(x - x_c) \leq 1\}.$$

它是 Euclidean 单位球在仿射映射 $x = x_c + P^{1/2}u$ 下的像。

2.4.3 多面体

多面体是有限个半空间与超平面的交:

$$P = \{x \mid Ax \leq b, Cx = d\}.$$

有界多面体称为多胞体。线性规划的可行域就是多面体。

2.4.4 范数锥与半正定锥

对任意范数，集合

$$K = \{(x, t) \mid \|x\| \leq t\}$$

是凸锥。Euclidean 范数对应二阶锥。

半正定锥 $\mathbb{S}_+^n$ 的凸性来自

$$z^\top (\theta X + (1 - \theta)Y)z = \theta z^\top Xz + (1 - \theta)z^\top Yz \geq 0.$$

正常锥、对偶锥以及二阶锥和半正定锥所诱导的广义不等式在 附录 B 中统一整理。

2.5 保持凸性的集合运算

2.5.1 任意交

若每个 C_α 都是凸集，则

$$C = \bigcap_{\alpha \in \mathcal{A}} C_\alpha$$

仍为凸集。许多可行域的凸性都由此得到：每个凸不等式产生一个凸下水平集，每个仿射等式产生一个仿射集，它们的交仍然凸。

2.5.2 仿射像与原像

设 $T(x) = Ax + b$ 。若 C 为凸集，则仿射像

$$T(C) = \{Ax + b \mid x \in C\}$$

为凸集。

若 D 为凸集，则仿射原像

$$T^{-1}(D) = \{x \mid Ax + b \in D\}$$

也为凸集。原像规则经常用来证明由范数、线性矩阵不等式或概率约束定义的可行域是凸的。

2.5.3 笛卡尔积与 Minkowski 和

若 $C \subseteq \mathbb{R}^n$ 、 $D \subseteq \mathbb{R}^m$ 均凸, 则

$$C \times D = \{(x, y) \mid x \in C, y \in D\}$$

为凸集。

Minkowski 和

$$C + D = \{x + y \mid x \in C, y \in D\}$$

也保持凸性。

2.5.4 线性分式映射

考虑映射

$$T(x) = \frac{Ax + b}{c^\top x + d}, \quad \text{dom } T = \{x \in \mathbb{R}^n : c^\top x + d > 0\},$$

其中 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$ 、 $c \in \mathbb{R}^n$ 、 $d \in \mathbb{R}$ 。

若 $C \subseteq \text{dom } T$ 是凸集, 则其像

$$T(C) = \{T(x) : x \in C\}$$

也是凸集。

关键不在于 T 是线性映射——它一般不是——而在于: 像空间中两点的任意凸组合, 都能找到一个仍在 C 中的原像。

证明。

任取 $x_1, x_2 \in C$ 和 $\theta \in [0, 1]$ 。我们要找到 $x_\theta \in C$, 使得

$$T(x_\theta) = \theta T(x_1) + (1 - \theta)T(x_2).$$

引入透视坐标

$$t_i = \frac{1}{c^\top x_i + d} > 0, \quad y_i = t_i x_i, \quad i = 1, 2.$$

由定义可得

$$c^\top y_i + d t_i = 1, \quad T(x_i) = A y_i + b t_i.$$

因此, 在 (y, t) 坐标下, 原来的分式变成了线性表达式。

在这个坐标空间中取凸组合:

$$y_\theta = \theta y_1 + (1 - \theta)y_2, \quad t_\theta = \theta t_1 + (1 - \theta)t_2.$$

由于 $t_1, t_2 > 0$, 有 $t_\theta > 0$, 可以还原出

$$\begin{aligned} x_\theta &= \frac{y_\theta}{t_\theta} \\ &= \frac{\theta t_1}{t_\theta} x_1 + \frac{(1-\theta)t_2}{t_\theta} x_2. \end{aligned}$$

这里两个系数均非负, 且和为 1。所以 x_θ 是 x_1, x_2 的凸组合, 由 C 的凸性可知 $x_\theta \in C$ 。

另一方面, 线性约束在凸组合下保持:

$$\begin{aligned} c^\top y_\theta + dt_\theta &= \theta(c^\top y_1 + dt_1) + (1-\theta)(c^\top y_2 + dt_2) \\ &= 1. \end{aligned}$$

于是

$$c^\top x_\theta + d = \frac{c^\top y_\theta + dt_\theta}{t_\theta} = \frac{1}{t_\theta} > 0,$$

从而

$$\begin{aligned} T(x_\theta) &= \frac{A(y_\theta/t_\theta) + b}{1/t_\theta} \\ &= Ay_\theta + bt_\theta \\ &= \theta(Ay_1 + bt_1) + (1-\theta)(Ay_2 + bt_2) \\ &= \theta T(x_1) + (1-\theta)T(x_2). \end{aligned}$$

这说明像空间中的任意凸组合仍属于 $T(C)$, 故 $T(C)$ 为凸集。

几何理解。

线性分式映射保留线段, 但一般不保留线段上的分点比例: 像空间中的权重是 θ , 对应原空间中的权重却是 $\theta t_1/t_\theta$ 。

分母为正的条件保证 $t_1, t_2, t_\theta > 0$, 使还原过程中的系数确实构成凸组合。因此不能不加条件地把结论推广到跨越分母零点的集合。

这种“引入 (y, t) , 把分式还原为线性关系”的方法, 也是后续线性分式规划等价变换的几何基础。

2.6 分离超平面

分离定理把“两个凸集不相交”转化为一个线性不等式。

设 $C, D \subseteq \mathbb{R}^n$ 是非空、不相交的凸集。则存在 $a \neq 0$ 和 b , 使

$$a^\top x \leq b \leq a^\top y, \quad \forall x \in C, \forall y \in D. \quad (2.2)$$

超平面 $\{z \mid a^\top z = b\}$ 将两个集合放在不同侧。若 C, D 闭且至少一个紧, 则可以严格分离:

$$\sup_{x \in C} a^\top x < \inf_{y \in D} a^\top y.$$

2.6.1 点与闭凸集的分离

设 C 为非空闭凸集, $x_0 \notin C$, 令

$$p = \operatorname{argmin}_{x \in C} \|x - x_0\|_2.$$

取 $a = x_0 - p$ 。投影的最优性给出

$$a^\top (x - p) \leq 0, \quad \forall x \in C,$$

而

$$a^\top (x_0 - p) = \|x_0 - p\|_2^2 > 0.$$

因此, 经过 p 且法向量为 a 的超平面把 x_0 与 C 严格分开。这里的关键构造不是凭空寻找法向量, 而是使用“外部点减去其投影点”。

💡 为什么分离如此重要?

分离定理把集合关系变成线性函数关系。对偶变量、支撑函数、最优性证书和 Farkas 型结论, 本质上都在寻找一个能证明“某点不属于某凸集”或“某个界无法被突破”的超平面。

2.7 支撑超平面

设 C 为非空闭凸集, $x_0 \in \partial C$ 。若存在 $a \neq 0$ 使

$$a^\top x \leq a^\top x_0, \quad \forall x \in C, \tag{2.3}$$

则

$$H = \{x \mid a^\top x = a^\top x_0\}$$

称为 C 在 x_0 处的支撑超平面。闭凸集的每个边界点都至少存在一个支撑超平面, 但法向量未必唯一。

分离超平面处理两个不相交集；支撑超平面则“贴住”一个凸集而不穿过它。对可微凸函数，上图在 $(x, f(x))$ 处的支撑超平面正对应一阶下界

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

2.8 判断集合凸性的实用流程

1. 先看定义。能否直接验证线段封闭？
2. 识别标准集合。仿射集、半空间、范数球、多面体、二阶锥和半正定锥都是常用原子。
3. 识别构造。检查交、仿射像、仿射原像、笛卡尔积和 Minkowski 和。
4. 改写为下水平集。若 $C = \{x \mid f(x) \leq \alpha\}$ 且 f 凸，则 C 凸。
5. 寻找反例。若怀疑不凸，找两个可行点，使其中点或某个凸组合不可行。

2.9 典型误区

1. 集合的并保持凸性。一般错误；两个相交凸集的并也未必凸。
2. 凸集必须有内部。低维仿射集可以是凸集，但在环境空间中内部为空。
3. 锥就是凸锥。集合对非负缩放封闭并不自动保证对加法封闭。
4. 线性映射的逆像需要可逆。不需要；任意仿射映射下，凸集的原像都凸。
5. 边界光滑才有支撑超平面。多面体顶点同样存在支撑超平面，只是法向量可能不唯一。

2.10 本章小结

凸集的核心是对凸组合封闭。仿射包、凸包和锥包分别补齐三类组合结构；交、仿射像和原像则提供模块化构造。分离与支撑超平面进一步把几何关系转化为线性不等式，为后续凸函数的一阶条件、Lagrange 对偶和 KKT 条件提供统一几何语言。

3 凸函数、判定方法与保凸运算

凸集描述“允许在哪里取点”，凸函数则描述“目标函数具有怎样的形状”。凸性的核心价值是把局部信息升级为全局信息：对一般函数，某一点附近下降不代表全局趋势；对凸函数，切平面、梯度和 Hessian 都能给出全局结论。

本章集中回答三个问题：

1. 怎样准确地定义凸函数？
2. 怎样判断一个函数是否凸？
3. 怎样由已知凸函数构造新的凸函数？

3.1 凸函数的定义

3.1.1 基本定义

设

$$f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}.$$

记有效定义域为

$$\text{dom } f = \{x \in \mathbb{R}^n \mid f(x) < +\infty\}.$$

如果 $\text{dom } f$ 是凸集，并且对任意 $x, y \in \text{dom } f$ 与 $\theta \in [0, 1]$ ，都有

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y), \quad (3.1)$$

则称 f 为凸函数。

式 3.1 的几何含义是：函数图像上任意两点之间的弦，都位于函数图像的上方。

i 为什么定义域也必须是凸集？

只有当 x 与 y 之间的整条线段都在定义域内时，比较“线段中点的函数值”和“端点函数值的加权平均”才有意义。定义域的凸性不是附带条件，而是凸函数定义的一部分。

3.1.2 严格凸函数

如果对任意不同的 $x, y \in \text{dom } f$ 和 $\theta \in (0, 1)$, 都有

$$f(\theta x + (1 - \theta)y) < \theta f(x) + (1 - \theta)f(y),$$

则称 f 为严格凸函数。

严格凸性排除了函数图像上的非平凡线段, 因此一旦最优解存在, 它至多只有一个。不过, 严格凸性并不保证最优解一定存在。

3.1.3 扩展值表示

扩展值表示把约束直接编码进函数。设 f 只在集合 C 上定义, 可以将其扩展为

$$\tilde{f}(x) = \begin{cases} f(x), & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

于是

$$\min_{x \in C} f(x) \iff \min_{x \in \mathbb{R}^n} \tilde{f}(x).$$

特别地, 集合 C 的指示函数定义为

$$I_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

I_C 为凸函数, 当且仅当 C 为凸集。这个表示把“凸集”和“凸函数”统一在同一套语言中, 后续近端方法也会反复使用它。

3.2 三类常用判定方法

凸函数的定义是零阶条件, 只比较函数值。如果函数可微或二阶可微, 还可以使用梯度和 Hessian 判定凸性。

3.2.1 零阶判定：限制在任意直线上

对任意 $x \in \text{dom } f$ 和方向 $v \in \mathbb{R}^n$ ，定义一元函数

$$g(t) = f(x + tv),$$

其定义域为

$$\text{dom } g = \{t \in \mathbb{R} \mid x + tv \in \text{dom } f\}.$$

则

$$f \text{ 为凸函数} \iff g \text{ 在每条与 } \text{dom } f \text{ 相交的直线上均为凸函数}.$$

这个结论把高维凸性化为一维凸性。它本身未必是最方便的计算判据，却是许多证明的基础：沿着任意方向研究 f ，本质上只需研究一个一元函数。

3.2.2 一阶判定：切平面是全局下界

设 f 在开凸集 $\text{dom } f$ 上可微，则

$$f \text{ 为凸函数} \iff f(y) \geq f(x) + \nabla f(x)^\top (y - x), \quad \forall x, y \in \text{dom } f. \quad (3.2)$$

右侧是 f 在 x 处的一阶 Taylor 近似。式 3.2 表明：对凸函数，一阶近似不仅在 x 附近有效，而且是整个定义域上的全局下界。

💡 几何视角：局部信息为何能够控制全局？

$\nabla f(x)$ 决定函数图像在 $(x, f(x))$ 处的切平面。凸函数的图像始终位于这个切平面上方，因此梯度提供的不是局部猜测，而是全局有效的线性下界。这也是梯度法、对偶理论和 KKT 条件能够成立的共同几何基础。

3.2.2.1 必要性

假设 f 为凸函数。固定 $x, y \in \text{dom } f$, 对 $t \in (0, 1]$ 有

$$f(x + t(y - x)) \leq (1 - t)f(x) + tf(y).$$

移项并除以 t :

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x).$$

令 $t \downarrow 0$, 左侧趋于方向导数 $\nabla f(x)^\top(y - x)$, 于是

$$f(y) \geq f(x) + \nabla f(x)^\top(y - x).$$

关键步骤是从弦斜率取极限得到切线斜率。

3.2.2.2 充分性

反过来, 假设式 3.2 对所有 x, y 都成立。令

$$z = \theta x + (1 - \theta)y, \quad \theta \in [0, 1].$$

分别在 z 处对 x 和 y 使用一阶下界:

$$f(x) \geq f(z) + \nabla f(z)^\top(x - z),$$

$$f(y) \geq f(z) + \nabla f(z)^\top(y - z).$$

第一式乘以 θ , 第二式乘以 $1 - \theta$ 后相加。由于

$$\theta(x - z) + (1 - \theta)(y - z) = 0,$$

梯度项正好消失, 从而得到

$$\theta f(x) + (1 - \theta)f(y) \geq f(z).$$

这正是凸函数的定义。

3.2.3 二阶判定: Hessian 半正定

设 f 在开凸集 $\text{dom } f$ 上二阶可微, 则

$$f \text{ 为凸函数} \iff \nabla^2 f(x) \succeq 0, \quad \forall x \in \text{dom } f. \quad (3.3)$$

这里 $\nabla^2 f(x) \succeq 0$ 表示

$$v^\top \nabla^2 f(x) v \geq 0, \quad \forall v \in \mathbb{R}^n.$$

沿直线 $x + tv$ 定义 $g(t) = f(x + tv)$, 则

$$g''(t) = v^\top \nabla^2 f(x + tv) v.$$

因此, 高维 Hessian 半正定恰好等价于函数沿每个方向的二阶导数非负, 再结合直线限制判定即可得到式 3.3。

3.2.3.1 例: 凸二次函数

考虑

$$f(x) = \frac{1}{2} x^\top P x + q^\top x + r,$$

其中 $P = P^\top$ 。由于

$$\nabla^2 f(x) = P,$$

所以

$$f \text{ 为凸函数} \iff P \succeq 0.$$

如果 $P \succ 0$, 则 f 严格凸。但反方向不成立: 严格凸函数的 Hessian 不必处处正定。例如 $f(x) = x^4$ 严格凸, 而 $f''(0) = 0$ 。

3.3 上境图、下水平集与 Jensen 不等式

3.3.1 上境图：把函数变成集合

函数 f 的上境图定义为

$$\text{epi } f = \{(x, t) \mid x \in \text{dom } f, f(x) \leq t\}.$$

上境图是函数图像上方的全部点。凸函数可以用上境图完全刻画：

$$f \text{ 为凸函数} \iff \text{epi } f \text{ 为凸集.} \quad (3.4)$$

这个视角把“函数凸性”转化为“集合凸性”。许多保凸运算都可以通过集合的交、投影和线性映射来证明。

对于可微凸函数，式 3.2 给出的切平面也正是上境图在 $(x, f(x))$ 处的支撑超平面。

3.3.2 下水平集与拟凸性

对 $\alpha \in \mathbb{R}$ ，定义 α -下水平集

$$S_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\}.$$

如果 f 为凸函数，则每个 S_α 都是凸集。证明只需取 $x, y \in S_\alpha$ ：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) \leq \alpha.$$

但反方向一般不成立。所有下水平集均凸，只能推出 f 是拟凸函数。

拟凸函数等价地满足

$$f(\theta x + (1 - \theta)y) \leq \max\{f(x), f(y)\}.$$

例如 $f(x) = x^3$ 在 $\mathbb{R}$ 上单调递增，因此每个下水平集都是区间，故它拟凸；但 $f''(x) = 6x$ 会改变符号，所以它不是凸函数。

⚠ 凸函数与拟凸函数的关键差别

凸函数控制函数值如何随凸组合变化；拟凸函数只控制下水平集的形状。拟凸性足以排除“坏形状”的可行水平集，却不足以保证切平面是全局下界，也不能直接继承凸优化的全部一阶理论。

3.3.3 Jensen 不等式

凸函数定义可以推广到有限个点。若 $x_i \in \text{dom } f$, $\theta_i \geq 0$ 且 $\sum_{i=1}^k \theta_i = 1$, 则

$$f\left(\sum_{i=1}^k \theta_i x_i\right) \leq \sum_{i=1}^k \theta_i f(x_i). \quad (3.5)$$

在相应期望存在时, 它进一步写成

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]. \quad (3.6)$$

Jensen 不等式说明: 先平均再代入凸函数, 不会大于先代入再平均。它是概率论、统计学习和风险分析中连接“均值”与“非线性损失”的基本工具。

3.4 常用凸函数原子

实际判断复杂函数时, 通常不从定义重新证明, 而是先识别一组已知原子, 再使用保凸运算组合它们。

函数	定义域	性质
$a^\top x + b$	$\mathbb{R}^n$	仿射, 既凸又凹
x^p	$\mathbb{R}_+$	$p \geq 1$ 时凸
e^x	$\mathbb{R}$	严格凸且单调递增
$-\log x$	$\mathbb{R}_{++}$	严格凸且单调递减
$x \log x$	$\mathbb{R}_{++}$	严格凸
$\ x\ $	$\mathbb{R}^n$	任意范数均凸
$\max_i x_i$	$\mathbb{R}^n$	凸
$\log \sum_i e^{x_i}$	$\mathbb{R}^n$	凸, 即 log-sum-exp
x^2/t	$t > 0$	关于 (x, t) 联合凸

其中, 范数的凸性直接来自三角不等式和正齐次性:

$$\begin{aligned} \|\theta x + (1 - \theta)y\| &\leq \|\theta x\| + \|(1 - \theta)y\| \\ &= \theta\|x\| + (1 - \theta)\|y\|. \end{aligned}$$

3.5 保持凸性的运算

3.5.1 非负加权求和

若 $f_1, \dots, f_k$ 均为凸函数, $w_i \geq 0$, 则

$$f(x) = \sum_{i=1}^k w_i f_i(x)$$

仍为凸函数。

权重非负是必要条件之一；负权重会把凸函数变成凹函数。例如 x^2 凸, 但 $-x^2$ 凹。

常见的经验风险

$$\frac{1}{n} \sum_{i=1}^n \ell_i(x)$$

就是这一规则的直接应用：只要每个样本损失 ℓ_i 关于参数 x 凸, 平均损失仍然凸。

3.5.2 与仿射映射复合

若 f 为凸函数, 则

$$g(x) = f(Ax + b)$$

也是凸函数, 因为

$$A(\theta x + (1 - \theta)y) + b = \theta(Ax + b) + (1 - \theta)(Ay + b).$$

因此, 仿射映射复合不会破坏凸组合结构。

例如, 任意范数损失

$$\|Ax - b\|$$

关于 x 都是凸函数。

3.5.3 逐点最大值与上确界

若 $f_1, \dots, f_k$ 均为凸函数, 则

$$f(x) = \max_{1 \leq i \leq k} f_i(x)$$

仍为凸函数。更一般地, 若对每个 $\alpha \in \mathcal{A}$, f_α 都是凸函数, 则

$$f(x) = \sup_{\alpha \in \mathcal{A}} f_\alpha(x)$$

也是凸函数, 只要该上确界没有处处取 $+\infty$ 。

从上图看,

$$\text{epi } f = \bigcap_{\alpha \in \mathcal{A}} \text{epi } f_\alpha.$$

由于凸集之交仍为凸集, 结论立即成立。

分段线性凸函数

$$f(x) = \max_{1 \leq i \leq k} (a_i^\top x + b_i)$$

就是仿射函数逐点最大值的典型例子。

3.5.4 一般复合：必须检查单调性

考虑

$$f(x) = h(g(x)).$$

仅知道 h 和 g 都凸, 不能推出 $h \circ g$ 凸。常用的充分条件为:

外层函数 h	内层函数 g	$h \circ g$
凸且单调不减	凸	凸
凸且单调不增	凹	凸
凹且单调不减	凹	凹
凹且单调不增	凸	凹

这些单调性只需在 $g(\text{dom } g)$ 上成立。

典型例子包括：

- 若 g 凸, 则 $e^{g(x)}$ 凸;
- 若 g 凹且 $g(x) > 0$, 则 $-\log g(x)$ 凸;
- 若 g 凸且 $g(x) \geq 0$, 则 $g(x)^2$ 凸。

最后一条中的非负条件不能省略, 因为 $u \mapsto u^2$ 并非在整个实数轴上单调。

对于向量复合

$$f(x) = h(g_1(x), \dots, g_k(x)),$$

一个常用规则是: 若 h 为凸函数, 并且关于每个分量都单调不减, 而每个 g_i 都凸, 则 f 凸。例如, 若 g_i 均凸, 则

$$\log \sum_{i=1}^k e^{g_i(x)}$$

仍为凸函数。

3.5.5 部分极小化

设 $f(x, y)$ 关于 (x, y) 联合凸, C 为凸集, 定义

$$g(x) = \inf_{y \in C} f(x, y).$$

如果 g 不取 $-\infty$, 则 g 为凸函数。

这个结论可以直接由近似极小点证明。取 x_1, x_2 , 对任意 $\varepsilon > 0$, 选择 $y_1, y_2 \in C$ 使得

$$f(x_i, y_i) \leq g(x_i) + \varepsilon, \quad i = 1, 2.$$

令

$$x_\theta = \theta x_1 + (1 - \theta)x_2, \quad y_\theta = \theta y_1 + (1 - \theta)y_2.$$

由于 C 为凸集, $y_\theta \in C$; 再由 f 的联合凸性,

$$\begin{aligned}
g(x_\theta) &\leq f(x_\theta, y_\theta) \\
&\leq \theta f(x_1, y_1) + (1 - \theta) f(x_2, y_2) \\
&\leq \theta g(x_1) + (1 - \theta) g(x_2) + \varepsilon.
\end{aligned}$$

令 $\varepsilon \downarrow 0$ 即得凸性。这里使用近似极小点，是因为下确界未必能够取到。

例如，对非空凸集 C ，距离函数

$$\text{dist}(x, C) = \inf_{y \in C} \|x - y\|$$

是凸函数。

这里必须要求 f 关于 (x, y) 联合凸；分别对 x 和 y 凸通常不够。

3.5.6 透视变换

函数 f 的透视函数定义为

$$g(x, t) = tf\left(\frac{x}{t}\right), \quad t > 0.$$

如果 f 为凸函数，则 g 关于 (x, t) 联合凸。

证明这一结论的关键是重新构造凸组合。取 $t_1, t_2 > 0$ ，令

$$t_\theta = \theta t_1 + (1 - \theta) t_2,$$

并定义

$$\alpha = \frac{\theta t_1}{t_\theta}, \quad \beta = \frac{(1 - \theta) t_2}{t_\theta}.$$

于是 $\alpha, \beta \geq 0$ 、 $\alpha + \beta = 1$ ，且

$$\frac{\theta x_1 + (1 - \theta) x_2}{t_\theta} = \alpha \frac{x_1}{t_1} + \beta \frac{x_2}{t_2}.$$

由 f 的凸性，

$$\begin{aligned} g(\theta x_1 + (1 - \theta)x_2, t_\theta) &\leq t_\theta \left[\alpha f\left(\frac{x_1}{t_1}\right) + \beta f\left(\frac{x_2}{t_2}\right) \right] \\ &= \theta g(x_1, t_1) + (1 - \theta)g(x_2, t_2). \end{aligned}$$

以 $f(x) = x^2$ 为例，其透视函数为

$$g(x, t) = \frac{x^2}{t}, \quad t > 0,$$

即常用的 quadratic-over-linear 函数。

透视变换在分式问题、统计模型和锥规划中经常出现。它的价值不在于记住某个孤立公式，而在于看到 $tf(x/t)$ 时能够立即识别其凸性来源。

3.6 普通凸、严格凸与强凸

强凸性将在算法章节系统讨论。这里先明确三者的边界。

若存在 $\mu > 0$ ，使得对所有 x, y 都有

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|_2^2, \quad (3.7)$$

则称 f 为 μ -强凸函数。

性质	图像含义	对最优解的影响
凸	弦在图像上方	局部最优即全局最优
严格凸	非平凡弦严格位于图像上方	最优解若存在则唯一
强凸	切平面与图像之间至少有二次间隙	最优解唯一，并可导出定量误差界

三者满足

$$\text{强凸} \implies \text{严格凸} \implies \text{凸},$$

反方向一般不成立。例如 e^x 严格凸，但在整个 $\mathbb{R}$ 上不是强凸函数，因为其二阶导数 e^x 没有统一的正下界。

若 f 二阶可微，则

$$\nabla^2 f(x) \succeq \mu I, \quad \forall x,$$

是 μ -强凸的二阶判据。强凸性如何与光滑性、条件数和收敛速度相连，留到第 6 章讨论。

3.7 凸性判断的实用流程

面对一个新函数，可以按以下顺序判断：

1. **先写定义域。**定义域不凸时，函数不可能是凸函数。
2. **识别原子函数。**检查它是否由范数、指数、负对数、二次函数、最大值等已知原子构成。
3. **识别保凸运算。**检查非负加权和、仿射复合、逐点上确界、满足单调性的复合、部分极小化或透视变换。
4. **必要时降到一维。**沿任意直线研究 $g(t) = f(x + tv)$ 。
5. **可微时用一阶条件。**它同时给出凸性和几何解释。
6. **二阶可微时检查 Hessian。**尽量利用矩阵结构，而不是机械展开所有主子式。

3.8 典型误区

1. “两个凸函数复合仍然凸。” 错。复合时必须检查外层函数的单调性和内层函数的凹凸性。
2. “凸函数的逐点最小值仍然凸。” 一般错误；逐点最大值保凸，逐点最小值不保凸。
3. “所有下水平集凸，所以函数凸。” 只能推出拟凸。
4. “严格凸等价于 Hessian 处处正定。” Hessian 正定是严格凸的充分条件，但不是必要条件。
5. “分别关于每个变量凸，就联合凸。” 一般错误。部分极小化等结论需要联合凸性。
6. **忽略定义域。** $-\log x$ 、 x^2/t 等函数的凸性都与定义域密不可分。

3.9 本章小结

凸函数的核心不是“曲线向上弯”这一直觉，而是一组可以相互转换的结构：

- 定义式控制弦；
- 一阶条件控制支撑切平面；
- 二阶条件控制各方向曲率；
- 上境图把函数凸性转化为集合凸性；
- 保凸运算提供模块化的函数构造方法。

判断复杂目标函数时，优先采用“原子函数 + 保凸运算”的结构化证明；只有结构无法直接识别时，再回到梯度或 Hessian 计算。这种顺序既更简洁，也更接近实际建模和后续算法分析的使用方式。

Part II

问题、对偶与最优性

4 凸优化问题的构造与等价变换

知道哪些集合和函数是凸的，还不等于能一眼识别凸优化问题。同一个问题可以有多种表示：有的形式直接暴露凸性，有的形式则把它隐藏在变量、目标或约束中。本章处理从“数学表达”到“标准凸问题”的转换。

4.1 标准凸优化问题

标准形式为

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \tag{4.1}$$

其中：

- $f_0, f_1, \dots, f_m$ 为凸函数；
- $h_1, \dots, h_p$ 为仿射函数。

其可行集为

$$\mathcal{X} = \bigcap_{i=1}^m \{x \mid f_i(x) \leq 0\} \cap \bigcap_{j=1}^p \{x \mid h_j(x) = 0\}.$$

凸函数的下水平集是凸集，仿射等式的解集是仿射集，因此 $\mathcal{X}$ 为凸集。

 标准形式中的方向不能随意改变

凸函数适合写成 $f_i(x) \leq 0$ ，凹函数适合写成 $g_i(x) \geq 0$ 。把凸约束写成 $f_i(x) \geq 0$ 通常会得到非凸可行域。等式约束则必须仿射；一般凸函数的等值集未必凸。

4.2 局部最优为什么成为全局最优

设 x^* 是凸优化问题的局部最优点。若它不是全局最优点，则存在 $y \in \mathcal{X}$ 使

$$f_0(y) < f_0(x^*).$$

由于 $\mathcal{X}$ 凸，对任意 $\theta \in (0, 1)$,

$$x_\theta = (1 - \theta)x^* + \theta y \in \mathcal{X}.$$

又由 f_0 凸，

$$f_0(x_\theta) \leq (1 - \theta)f_0(x^*) + \theta f_0(y) < f_0(x^*).$$

当 θ 足够小时， x_θ 任意接近 x^* ，这与局部最优矛盾。因此任意局部最优点都是全局最优点。

证明的关键是：从 x^* 朝更优点 y 移动任意小的一步，既不会离开可行域，也会严格降低目标。

4.3 一阶最优性条件

考虑抽象形式

$$\min_{x \in \mathcal{X}} f(x),$$

其中 f 可微且凸， $\mathcal{X}$ 非空且凸。对 $x^* \in \mathcal{X}$,

$$x^* \text{ 最优} \iff \nabla f(x^*)^\top (y - x^*) \geq 0, \quad \forall y \in \mathcal{X}. \quad (4.2)$$

4.3.1 必要性

固定 $y \in \mathcal{X}$ ，定义

$$g(t) = f(x^* + t(y - x^*)), \quad t \in [0, 1].$$

由于 x^* 在可行线段的端点处最优，右导数满足

$$g'(0) = \nabla f(x^*)^\top (y - x^*) \geq 0.$$

4.3.2 充分性

凸函数的一阶下界给出

$$f(y) \geq f(x^*) + \nabla f(x^*)^\top (y - x^*) \geq f(x^*),$$

所以 x^* 全局最优。

几何视角

在无约束问题中，可以向任意方向移动，因此式 4.2 退化为 $\nabla f(x^*) = 0$ 。有约束时梯度未必为零；条件要求负梯度方向不能与任何可行方向形成锐角，也就是已经没有可行下降方向。

4.4 等价变换的基本原则

变换优化问题时，应先明确希望保留什么。

- **完全等价**：可行点与目标值一一对应；
- **最优值等价**：两个问题的最优值相同，但变量或最优解表示不同；
- **松弛**：扩大可行域或降低目标，得到原问题的下界；
- **限制**：缩小可行域，得到原问题的可行上界。

只有前两类可以直接替换原问题。松弛和限制也很有价值，但不能把它们误称为等价变换。

4.5 变量替换

设 $x = \phi(z)$ ，并且 ϕ 在所考虑区域上一一对应，则

$$\min_{x \in \mathcal{X}} f_0(x) \iff \min_{z: \phi(z) \in \mathcal{X}} f_0(\phi(z)).$$

变量替换是否保凸需要单独检查。仿射替换 $x = Az + b$ 最安全，因为凸函数与仿射映射复合仍凸。

若变换不是一一对应，最优值仍可能保持，但恢复原变量时需要检查是否丢失或重复解。

4.6 消去仿射等式约束

考虑

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & Ax = b.\end{array}$$

若等式可行, 取一个特解 x_0 , 再令矩阵 F 的列张成 $\text{null}(A)$ 。所有可行点都可写为

$$x = Fz + x_0.$$

原问题等价于无等式约束问题

$$\min_z f_0(Fz + x_0).$$

这一变换会自动保证可行性, 并将变量维数从 n 降到 $\dim \text{null}(A)$ 。代价是 F 可能变稠密, 从而破坏原问题的稀疏结构。

4.7 引入松弛变量

不等式

$$f_i(x) \leq 0$$

可以写成

$$f_i(x) + s_i = 0, \quad s_i \geq 0.$$

松弛变量把不等式转为等式加非负约束, 在线性规划与 KKT 条件中尤其常见。不过, 它不会自动让一个非凸约束变凸。

4.8 上境图形式

任意目标最小化问题

$$\min_x f_0(x)$$

可以改写为

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && f_0(x) \leq t. \end{aligned} \tag{4.3}$$

若 f_0 凸, 则约束集合正是 f_0 的上境图, 因此问题仍为凸问题。

上境图形式常用于拆解最大值目标。例如

$$\min_x \max_{1 \leq i \leq m} f_i(x)$$

等价于

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && f_i(x) \leq t, \quad i = 1, \dots, m. \end{aligned}$$

它把一个不光滑最大值目标变成线性目标与多个凸约束。

4.9 显式约束与隐式约束

集合约束 $x \in C$ 可以通过指示函数写入目标:

$$\min_{x \in C} f(x) \iff \min_x (f(x) + I_C(x)).$$

反过来, 若一个函数只在 C 上有限, 也可以把 C 从定义域中抽出, 写成显式约束。

两种形式在数学上等价, 但对算法选择影响很大:

- 显式约束适合投影和可行方向方法;
- 指示函数形式适合后续近端与复合优化框架。

4.10 部分极小化

若

$$g(x) = \inf_{y \in C} f(x, y),$$

其中 f 关于 (x, y) 联合凸且 C 凸, 则在不出现 $-\infty$ 的条件下, g 为凸函数。

因此, 原问题

$$\min_{x, y \in C} f(x, y)$$

可以先消去 y , 再求

$$\min_x g(x).$$

这是一种“通过内部优化定义新目标”的变换。第 3 章已给出其 ε -近似极小点证明。

4.11 等价凸问题

一个表面上非凸的表达式, 可能经过保持最优解的变换成为凸问题。常见路径包括:

1. 单调变换目标函数;
2. 仿射变量替换;
3. 上境图变换;
4. 引入辅助变量;
5. 消去线性等式;
6. 将范数或最大值改写成标准约束。

4.11.1 单调变换目标

若 ϕ 严格单调递增, 则

$$\operatorname{argmin}_{x \in \mathcal{X}} f(x) = \operatorname{argmin}_{x \in \mathcal{X}} \phi(f(x)).$$

但两者最优值不同, 而且 $\phi \circ f$ 是否凸仍需检查。该规则保留最优解, 不等于自动保留凸性。

4.12 拟凸优化与二分法

若目标函数 f 拟凸, 约束可行域 $\mathcal{X}$ 凸, 则问题

$$\min_{x \in \mathcal{X}} f(x)$$

称为拟凸优化问题。它不一定是凸优化问题, 但其下水平可行性问题

$$\text{寻找 } x \text{ 使得 } x \in \mathcal{X}, \quad f(x) \leq t \tag{4.4}$$

对固定 t 是凸可行性问题。

假设已知最优值位于区间 $[\ell, u]$ 。二分法重复:

1. 取 $t = (\ell + u)/2$;
2. 求解式 (4.4);
3. 若可行, 则令 $u = t$;
4. 若不可行, 则令 $\ell = t$ 。

当 $u - \ell \leq \varepsilon$ 时停止。所需可行性检验次数至多为

$$\left\lceil \log_2 \frac{u_0 - \ell_0}{\varepsilon} \right\rceil.$$

二分对象是目标值 t , 而不是直接对变量 x 二分。

4.13 建模检查清单

面对一个新问题, 可以依次检查:

1. 变量、目标和约束是否写清;
2. 每个函数的定义域是否纳入可行域;
3. 不等式是否统一为“凸函数 ≤ 0 ”;
4. 等式是否仿射;
5. 最大值、范数或分式能否引入辅助变量;
6. 线性等式是否值得消去;
7. 变换是等价、松弛还是限制;
8. 最优值是否可能不取到或向下无界。

4.14 典型误区

1. 目标凸就一定是凸优化问题。还必须检查可行域。
2. 任何等式约束都可以出现在凸问题中。只有仿射等式具有一般保凸保证。
3. 引入变量会改变问题。正确设计的辅助变量可以保持最优值和最优解对应关系。
4. 单调变换保持最优值。它通常只保持最优解次序，不保持数值。
5. 拟凸问题直接使用梯度为零判定。拟凸性不具备凸函数的全部一阶下界结构。

4.15 本章小结

凸问题的标准形式由凸目标、凸不等式和仿射等式组成。局部最优成为全局最优，是可行域线段封闭与目标凸性共同作用的结果。变量替换、消去等式、上境图、指示函数和部分极小化提供了常用等价变换；拟凸问题则可通过对目标值做二分，化为一系列凸可行性问题。

5 共轭函数、Lagrange 对偶与 KKT

对偶理论从原问题构造一个新的优化问题。对偶可行点给出原问题最优值的下界；当强对偶成立时，这个下界可以达到原问题最优值，并由此产生可检验的最优性证书。共轭函数、Lagrangian、Slater 条件和 KKT 条件是这套语言的核心部件。

5.1 共轭函数

设 $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ 。其 Fenchel 共轭定义为

$$f^*(y) = \sup_{x \in \text{dom } f} (y^\top x - f(x)). \quad (5.1)$$

对固定的 y ，共轭函数寻找斜率为 y 的仿射函数

$$x \mapsto y^\top x - f^*(y)$$

在不超过 f 的条件下能够达到的最大截距。



几何视角：从点值转向斜率

原函数用输入 x 索引函数值，共轭函数则用斜率 y 索引支撑超平面。它把“函数在什么位置取什么值”转换为“函数允许哪些线性下界”，因此天然适合对偶化。

5.1.1 基本性质

无论 f 本身是否凸， f^* 都是凸函数。原因是

$$f^*(y) = \sup_x (x^\top y - f(x))$$

是关于 y 的一族仿射函数的逐点上确界。

若 $f \leq g$ ，则共轭会反转不等式：

$$f^* \geq g^*.$$

若 f 是闭、正常的凸函数，则双共轭恢复原函数：

$$f^{**} = f.$$

这里“正常”表示 f 不恒为 $+\infty$ ，且从不取 $-\infty$ 。双共轭结论说明闭凸函数可以完全由其仿射下界重建。

5.1.2 常用例子

5.1.2.1 二次函数

若

$$f(x) = \frac{1}{2}\|x\|_2^2,$$

则

$$f^*(y) = \sup_x \left(y^\top x - \frac{1}{2}\|x\|_2^2 \right).$$

对 x 求一阶条件得到 $x = y$ ，因此

$$f^*(y) = \frac{1}{2}\|y\|_2^2.$$

5.1.2.2 仿射函数

若 $f(x) = a^\top x + b$ ，则

$$f^*(y) = \begin{cases} -b, & y = a, \\ +\infty, & y \neq a. \end{cases}$$

当 $y \neq a$ 时，线性项 $(y - a)^\top x$ 可以沿某个方向趋于 $+\infty$ 。

5.1.2.3 范数

设 $f(x) = \|x\|$ 。回顾其对偶范数定义：

$$\|y\|_* = \sup_{\|u\| \leq 1} y^\top u.$$

它衡量线性函数 $u \mapsto y^\top u$ 在原范数单位球上的最大值，并满足 Hölder 不等式

$$|y^\top x| \leq \|y\|_* \|x\|.$$

下面计算范数函数的共轭：

$$f^*(y) = \sup_x (y^\top x - \|x\|).$$

若 $\|y\|_* \leq 1$ ，则

$$y^\top x - \|x\| \leq (\|y\|_* - 1)\|x\| \leq 0.$$

取 $x = 0$ 可达到 0，故 $f^*(y) = 0$ 。

若 $\|y\|_* > 1$ ，由定义可取 $\|u\| \leq 1$ 使 $y^\top u > 1$ 。沿该方向取 $x = tu$ ，其中 $t > 0$ ，则

$$y^\top x - \|x\| = t(y^\top u - \|u\|) \geq t(y^\top u - 1) \rightarrow +\infty.$$

故 $f^*(y) = +\infty$ 。

因此

$$f^*(y) = \begin{cases} 0, & \|y\|_* \leq 1, \\ +\infty, & \|y\|_* > 1. \end{cases}$$

即：范数的共轭是对偶范数单位球的指示函数。这里的指示函数在集合内取 0、集合外取 $+\infty$ ，不是概率论中的 0-1 指示函数。

注意，对偶范数 $\|y\|_*$ 与共轭函数 $f^*(y)$ 不是同一个对象。

对偶范数的几何解释、Hölder 不等式的证明及常见对偶范数，见附录中的 小节 A.3。

矩阵例子：核范数的共轭。

范数共轭的结论同样适用于矩阵空间。采用 Frobenius 内积 $\langle X, Y \rangle = \text{tr}(X^\top Y)$ ，令

$$F(X) = \|X\|_{\text{nuc}}.$$

其共轭定义为

$$F^*(Y) = \sup_X (\langle X, Y \rangle - \|X\|_{\text{nuc}}).$$

核范数的对偶范数是谱范数，因此直接应用前面的范数共轭结论：

$$F^*(Y) = \begin{cases} 0, & \|Y\|_2 \leq 1, \\ +\infty, & \|Y\|_2 > 1. \end{cases}$$

即：核范数的共轭是谱范数单位球的指示函数。

在计算对偶函数时，这个结论可以直接用于消去矩阵变量：

$$\inf_X (\|X\|_{\text{nuc}} - \langle Y, X \rangle) = -F^*(Y) = \begin{cases} 0, & \|Y\|_2 \leq 1, \\ -\infty, & \|Y\|_2 > 1. \end{cases}$$

所以，Lagrangian 中若出现“核范数减去线性项”，对矩阵变量取下确界后，有限性条件就会产生对应系数矩阵的谱范数约束。

注意，核范数与谱范数是互为对偶范数，不是互为共轭函数。它们的定义、SVD 证明与低秩解释见附录 小节 A.5。

5.2 Fenchel–Young 不等式

由共轭函数定义，对任意 x, y ,

$$f^*(y) \geq y^\top x - f(x).$$

移项得到

$$f(x) + f^*(y) \geq x^\top y. \quad (5.2)$$

这就是 Fenchel–Young 不等式。

若 f 可微且凸，则等号成立当且仅当

$$y = \nabla f(x).$$

证明来自凸函数的一阶下界：

$$f(z) \geq f(x) + \nabla f(x)^\top (z - x).$$

令 $y = \nabla f(x)$ ，可得

$$y^\top z - f(z) \leq y^\top x - f(x),$$

所以共轭定义中的上确界在 $z = x$ 处取得。不可微情形的等号条件是 $y \in \partial f(x)$ ；次微分与共轭之间的完整等价关系见 附录 C。

5.3 Lagrangian

考虑原问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{5.3}$$

定义 Lagrangian

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x), \tag{5.4}$$

其中 $\lambda \succeq 0$, 而 $\nu \in \mathbb{R}^p$ 不受符号限制。

不等式乘子必须非负。若 x 可行, 则 $f_i(x) \leq 0$, 所以

$$L(x, \lambda, \nu) \leq f_0(x)$$

在等式约束满足时成立。这个方向正是对偶下界的来源。

5.4 原问题的极大表示

对固定的 x , 定义

$$\Theta_P(x) = \sup_{\lambda \succeq 0, \nu} L(x, \lambda, \nu).$$

若 x 可行, 则约束项的上确界为 0, 所以 $\Theta_P(x) = f_0(x)$ 。若某个约束违反:

- 当 $f_i(x) > 0$ 时, 可令 $\lambda_i \rightarrow +\infty$;
- 当 $h_j(x) \neq 0$ 时, 可选择 ν_j 的符号并令其绝对值趋于无穷。

因此

$$\Theta_P(x) = \begin{cases} f_0(x), & x \text{ 可行}, \\ +\infty, & x \text{ 不可行}. \end{cases}$$

原问题可以写为

$$p^* = \inf_x \sup_{\lambda \geq 0, \nu} L(x, \lambda, \nu). \quad (5.5)$$

5.5 对偶函数与对偶问题

对固定的 (λ, ν) , 定义对偶函数

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu). \quad (5.6)$$

即使原问题不是凸问题, g 关于 (λ, ν) 仍是凹函数。因为对每个固定的 x , $L(x, \lambda, \nu)$ 关于乘子是仿射函数, 而一族仿射函数的逐点下确界为凹函数。

Lagrange 对偶问题为

$$\begin{aligned} & \text{maximize} && g(\lambda, \nu) \\ & \text{subject to} && \lambda \succeq 0. \end{aligned} \quad (5.7)$$

其最优值记为

$$d^* = \sup_{\lambda \geq 0, \nu} g(\lambda, \nu).$$

如果某些乘子使 $g(\lambda, \nu) = -\infty$, 可以把

$$g(\lambda, \nu) > -\infty$$

显式写成对偶可行性约束。

5.6 用共轭计算对偶函数

共轭函数与 Lagrange 对偶不是同一个对象: 共轭是对函数进行变换, 对偶则是从优化问题构造新的优化问题。两者的联系在于, 共轭可以计算 Lagrangian 对原变量的下确界。

5.6.1 核心恒等式：消去带线性项的变量

对正常函数 f 和给定向量 s ,

$$\begin{aligned}\inf_x [f(x) + s^\top x] &= -\sup_x [(-s)^\top x - f(x)] \\ &= -f^*(-s).\end{aligned}$$

这里采用扩展值约定：定义域之外 $f(x) = +\infty$ ，因此对 x 的优化自动限制在 $\text{dom } f$ 内。该恒等式不要求下确界能够取到。

它给出一个可复用的操作：当 Lagrangian 中关于 x 的部分可以写成“原函数 + 线性项”时，就能用共轭消去 x 。

注意两个负号的位置：

$$\inf_x [f(x) + s^\top x] = -f^*(-s), \quad \inf_x [f(x) - s^\top x] = -f^*(s).$$

5.6.2 仿射约束下的通用模板

考虑

$$\begin{aligned}\text{minimize} \quad & f_0(x) \\ \text{subject to} \quad & Ax \leq b, \\ & Cx = d,\end{aligned}$$

其中 f_0 为正常凸函数， $A \in \mathbb{R}^{m \times n}$ 、 $C \in \mathbb{R}^{p \times n}$ ，不等式按分量理解。

令 $\lambda \in \mathbb{R}_+^m$ 、 $\nu \in \mathbb{R}^p$ 。Lagrangian 为

$$\begin{aligned}L(x, \lambda, \nu) &= f_0(x) + \lambda^\top (Ax - b) + \nu^\top (Cx - d) \\ &= f_0(x) + (A^\top \lambda + C^\top \nu)^\top x - b^\top \lambda - d^\top \nu.\end{aligned}$$

固定乘子，对 x 取下确界：

$$\begin{aligned}g(\lambda, \nu) &= -b^\top \lambda - d^\top \nu \\ &\quad + \inf_x [f_0(x) + (A^\top \lambda + C^\top \nu)^\top x] \\ &= -b^\top \lambda - d^\top \nu - f_0^*(-A^\top \lambda - C^\top \nu).\end{aligned}$$

因此对偶问题可以写成

$$\begin{aligned}\text{maximize}_{\lambda, \nu} \quad & -b^\top \lambda - d^\top \nu - f_0^*(-A^\top \lambda - C^\top \nu) \\ \text{subject to} \quad & \lambda \geq 0, \\ & -A^\top \lambda - C^\top \nu \in \text{dom } f_0^*.\end{aligned}$$

最后一个约束把对偶函数取有限值的条件显式写了出来。若共轭在该点取 $+\infty$ ，对偶函数就取 $-\infty$ ，不能提供有限的下界。

这也说明了共轭的两种作用：

- 共轭函数的值决定对偶目标；
- 共轭函数的定义域决定对偶变量受到的额外限制。

由于 f_0^* 为凸函数，上式中的负共轭项为凹函数，与对偶函数应当为凹函数的结论一致。

5.6.3 例子：等式约束下的最小范数

考虑

$$\begin{aligned} & \text{minimize} \quad \|x\| \\ & \text{subject to} \quad Ax = b. \end{aligned}$$

令 $f(x) = \|x\|$ 。由前面已经得到的范数共轭，

$$f^*(y) = \begin{cases} 0, & \|y\|_* \leq 1, \\ +\infty, & \|y\|_* > 1. \end{cases}$$

代入共轭计算模板：

$$\begin{aligned} g(\nu) &= -b^\top \nu - f^*(-A^\top \nu) \\ &= \begin{cases} -b^\top \nu, & \|A^\top \nu\|_* \leq 1, \\ -\infty, & \|A^\top \nu\|_* > 1. \end{cases} \end{aligned}$$

这里使用了范数的对称性： $\| -A^\top \nu \|_* = \|A^\top \nu\|_*$ 。所以对偶问题是

$$\begin{aligned} & \text{maximize}_\nu \quad -b^\top \nu \\ & \text{subject to} \quad \|A^\top \nu\|_* \leq 1. \end{aligned}$$

原问题中的范数目标，经过共轭变成了对偶问题中的对偶范数约束。例如，若原目标是 $\|x\|_1$ ，对偶约束就是 $\|A^\top \nu\|_\infty \leq 1$ 。

若把等式乘子替换为 $-\nu$ ，目标也可以写成 $b^\top \nu$ ；两种写法等价，但必须与所选 Lagrangian 的符号约定保持一致。

5.6.4 变量分裂：为复合目标构造对偶

考虑没有显式约束的复合问题

$$\inf_{x \in \mathbb{R}^n} f_0(Ax + b),$$

其中 $A \in \mathbb{R}^{m \times n}$, $f_0 : \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ 为正常凸函数。

直接对无约束形式构造 Lagrange 对偶，没有可优化的乘子，得到的只是原问题最优值本身，不能简化计算。

引入辅助变量 $z = Ax + b$ ，等价地写为

$$\begin{aligned} & \text{minimize}_{x,z} && f_0(z) \\ & \text{subject to} && Ax + b - z = 0. \end{aligned}$$

对应的 Lagrangian 是

$$\begin{aligned} L(x, z, \nu) &= f_0(z) + \nu^\top (Ax + b - z) \\ &= f_0(z) - \nu^\top z + (A^\top \nu)^\top x + b^\top \nu. \end{aligned}$$

分别消去两个变量。

首先，由于 x 可以在整个 $\mathbb{R}^n$ 中变化，

$$\inf_x (A^\top \nu)^\top x = \begin{cases} 0, & A^\top \nu = 0, \\ -\infty, & A^\top \nu \neq 0. \end{cases}$$

当系数非零时，沿其反方向放大 x ，线性项就能趋于 $-\infty$ 。

其次，由共轭定义，

$$\inf_z [f_0(z) - \nu^\top z] = -f_0^*(\nu).$$

因此对偶问题为

$$\begin{aligned} & \text{maximize}_\nu && b^\top \nu - f_0^*(\nu) \\ & \text{subject to} && A^\top \nu = 0, \\ & && \nu \in \text{dom } f_0^*. \end{aligned}$$

这个推导中，消去自由变量 x 产生线性约束，消去辅助变量 z 产生共轭项。这是复合优化中常见的变量分裂思路。

5.6.5 使用边界

上述仿射约束模板不能直接用于一般非线性约束：只有当关于原变量的附加项确实是线性的，才能直接识别为原目标的共轭。

若对原变量取下确界时还保留约束 $x \in S$ ，则应将它写入函数：

$$\tilde{f}(x) = f(x) + \delta_S(x),$$

再使用 $\tilde{f}^*$ ，不能忽略这个定义域限制。

最后，写出对偶问题不等于证明强对偶成立。共轭负责计算对偶函数；对偶下界能否达到原问题最优值，仍需检查后续的强对偶条件。

5.7 弱对偶

取任意原始可行点 x 和对偶可行点 (λ, ν) 。由对偶函数定义，

$$g(\lambda, \nu) \leq L(x, \lambda, \nu).$$

又因为 x 可行且 $\lambda \succeq 0$,

$$L(x, \lambda, \nu) \leq f_0(x).$$

所以

$$g(\lambda, \nu) \leq f_0(x). \quad (5.8)$$

对两侧分别取最优，得到

$$d^* \leq p^*. \quad (5.9)$$

弱对偶不要求原问题凸，也不要求最优解存在。



对偶可行点就是下界证书

只要找到一个 $\lambda \succeq 0$ 和 ν 使 $g(\lambda, \nu)$ 有限，就立刻得到 $p^* \geq g(\lambda, \nu)$ 。这个数不仅是估计，更附带一份可以检查的证明。

5.8 对偶函数的一个推导例子

考虑等式约束凸二次问题

$$\begin{aligned} & \text{minimize} && \frac{1}{2}x^\top Px + q^\top x \\ & \text{subject to} && Ax = b, \end{aligned}$$

其中 $P \succ 0$ 。Lagrangian 为

$$L(x, \nu) = \frac{1}{2}x^\top Px + q^\top x + \nu^\top (Ax - b).$$

固定 ν ，对 x 求极小。一阶条件为

$$Px + q + A^\top \nu = 0,$$

因此

$$x(\nu) = -P^{-1}(q + A^\top \nu).$$

代回得到

$$g(\nu) = -\frac{1}{2}(q + A^\top \nu)^\top P^{-1}(q + A^\top \nu) - b^\top \nu.$$

对偶问题就是最大化这个关于 ν 的凹二次函数。这个例子展示了构造对偶的基本动作：写出 Lagrangian，对原变量取下确界，再保留乘子优化。

5.9 对偶间隙与强对偶

对一组原始可行点 x 和对偶可行点 (λ, ν) ，定义可计算的对偶间隙

$$\eta(x, \lambda, \nu) = f_0(x) - g(\lambda, \nu) \geq 0.$$

它同时控制两侧误差：

$$f_0(x) - p^* \leq \eta, \quad p^* - g(\lambda, \nu) \leq \eta.$$

最优对偶间隙为

$$p^* - d^*.$$

若

$$p^* = d^*,$$

则称强对偶成立。强对偶不是弱对偶的自动加强；它需要问题结构和约束资格条件。

5.10 Slater 条件

考虑标准凸优化问题，并记所有函数的公共定义域为

$$\mathcal{D} = \bigcap_{i=1}^m \text{dom } f_i.$$

若存在

$$\tilde{x} \in \text{relint } \mathcal{D}$$

使

$$f_i(\tilde{x}) < 0, \quad i = 1, \dots, m,$$

且

$$A\tilde{x} = b,$$

则称 Slater 条件成立。

对凸问题，Slater 条件是保证强对偶成立的常用充分条件；在原问题最优值有限时，它通常还保证对偶最优乘子能够取到。

Slater 条件要求不等式严格可行，但等式只能精确满足。使用 $\text{relint } \mathcal{D}$ ，是为了允许定义域位于低维仿射空间。

⚠ Slater 条件不是所有强对偶问题的必要条件

不满足 Slater 条件并不等于强对偶必然失败。它是一条容易检查、适用广泛的充分条件，而不是强对偶的定义。

5.11 互补松弛

假设原始最优点 x^* 和对偶最优点 (λ^*, ν^*) 存在，且强对偶成立。由

$$g(\lambda^*, \nu^*) \leq L(x^*, \lambda^*, \nu^*) \leq f_0(x^*)$$

以及两端同为 p^* ，中间所有不等式必须取等号。因此

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0.$$

每一项都满足

$$\lambda_i^* \geq 0, \quad f_i(x^*) \leq 0,$$

所以每一项都必须为零：

$$\lambda_i^* f_i(x^*) = 0, \quad i = 1, \dots, m. \quad (5.10)$$

这意味着：

- 若约束严格松弛，即 $f_i(x^*) < 0$ ，则 $\lambda_i^* = 0$ ；
- 若 $\lambda_i^* > 0$ ，则对应约束必然活跃，即 $f_i(x^*) = 0$ 。

乘子只会给真正限制最优解的约束赋予正权重。

5.12 KKT 条件

假设目标与约束函数可微。候选点 (x^*, λ^*, ν^*) 的 KKT 条件包括:

1. 原始可行性

$$f_i(x^*) \leq 0, \quad h_j(x^*) = 0.$$

2. 对偶可行性

$$\lambda_i^* \geq 0.$$

3. 互补松弛

$$\lambda_i^* f_i(x^*) = 0.$$

4. 驻点条件

$$\nabla_x L(x^*, \lambda^*, \nu^*) = 0,$$

即

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(x^*) = 0. \quad (5.11)$$

5.12.1 从 Fenchel–Young 等号看驻点条件

对于前面讨论的仿射约束问题

$$\min_x f_0(x), \quad Ax \leq b, \quad Cx = d,$$

共轭与 KKT 之间还有一条直接联系。

设 f_0 为正常凸函数, $x \in \text{dom } f_0$, 并记

$$y = -A^\top \lambda - C^\top \nu.$$

Fenchel–Young 不等式及其等号条件为

$$\begin{aligned} f_0(x) + f_0^*(y) &\geq y^\top x, \\ f_0(x) + f_0^*(y) &= y^\top x \iff y \in \partial f_0(x). \end{aligned}$$

这里 $\partial f_0(x)$ 是次微分。等号意味着 x 实现了共轭定义中的上确界, 等价地, 也实现了 $f_0(x) + (A^\top \lambda + C^\top \nu)^\top x$ 的全局最小值。

代入 y , 等号条件变成

$$0 \in \partial f_0(x) + A^\top \lambda + C^\top \nu.$$

若 f_0 在 x 处可微, 则进一步化为

$$\nabla f_0(x) + A^\top \lambda + C^\top \nu = 0.$$

这正是该问题的 KKT 驻点条件。因此, 从共轭视角看, 驻点条件是在要求: 所选乘子对应的线性下界在 x 处恰好与目标函数接触。

但 Fenchel–Young 取等号只对应这里的驻点条件。要组成完整的 KKT 条件, 还必须检查 $Ax \leq b$, $Cx = d$, $\lambda \geq 0$, 以及互补松弛

$$\lambda_i((Ax)_i - b_i) = 0, \quad i = 1, \dots, m.$$

5.12.2 KKT 的充分性

对可微凸优化问题, 只要一组点满足 KKT 条件, 就能推出原始与对偶最优, 不需要额外使用 Slater 条件。

原因是: $L(\cdot, \lambda^*, \nu^*)$ 关于 x 凸, 而驻点条件说明 x^* 将其全局最小化。对任意原始可行点 x ,

$$\begin{aligned} f_0(x) &\geq L(x, \lambda^*, \nu^*) \\ &\geq L(x^*, \lambda^*, \nu^*) \\ &= f_0(x^*), \end{aligned}$$

最后一个等号使用了原始可行性和互补松弛。

5.12.3 KKT 的必要性

对一般非凸问题, 局部最优点只有在相应约束资格条件下才必须满足 KKT, 而且满足 KKT 也未必是全局最优。

对凸问题, 若 Slater 条件成立、原始最优解存在且最优值有限, 则存在对偶最优乘子, 使原始最优点与这些乘子共同满足 KKT。

因此, Slater 条件主要负责保证“最优解能够配上合适的乘子”; 凸性主要负责保证“满足 KKT 就是全局最优”。

5.13 一个一维 KKT 例子

考虑

$$\begin{aligned} & \text{minimize} && x^2 \\ & \text{subject to} && 1 - x \leq 0. \end{aligned}$$

Lagrangian 为

$$L(x, \lambda) = x^2 + \lambda(1 - x), \quad \lambda \geq 0.$$

KKT 条件是

$$x \geq 1, \quad \lambda \geq 0, \quad \lambda(1 - x) = 0, \quad 2x - \lambda = 0.$$

若约束不活跃, 则 $\lambda = 0$, 驻点条件给出 $x = 0$, 与可行性矛盾。因此约束活跃, $x^* = 1$, 再由驻点条件得到

$$\lambda^* = 2.$$

乘子 λ^* 可以解释为放松约束边界时最优值的一阶敏感度。

5.14 鞍点解释

若 (x^*, λ^*, ν^*) 为原始—对偶最优点且强对偶成立, 则

$$L(x^*, \lambda, \nu) \leq L(x^*, \lambda^*, \nu^*) \leq L(x, \lambda^*, \nu^*) \quad (5.12)$$

对所有 x 、 $\lambda \geq 0$ 和 ν 成立。

这说明:

- 固定最优乘子时, x^* 最小化 Lagrangian;
- 固定最优原变量时, (λ^*, ν^*) 最大化 Lagrangian。

原问题的“先对乘子取上确界, 再对 x 取下确界”与对偶问题的相反顺序, 在鞍点处交换而不改变结果。

5.15 Slater、强对偶与 KKT 的关系

条件	可以推出
任意原问题与其 Lagrange 对偶	弱对偶 $d^* \leq p^*$
凸问题 + Slater 条件	强对偶；在常用有限性条件下对偶最优可取
可微凸问题 + KKT	原始点与对偶点均最优
可微凸问题 + Slater + 原始最优解存在	最优当且仅当存在乘子使 KKT 成立
一般非凸问题 + KKT	通常只是一阶候选条件

i 使用顺序

实际分析时通常先写 Lagrangian 和对偶函数，再检查 Slater 条件，最后使用 KKT 求候选解并验证。不要先机械罗列 KKT，再倒推问题是否满足凸性和约束资格条件。

当标量不等式被二阶锥或半正定序等广义不等式替代时，乘子应属于对偶锥，互补松弛也改写为锥内积为零。该推广见 附录 B。

5.16 典型误区

1. 对偶函数只有在原问题凸时才凹。错；它始终是乘子的凹函数。
2. 弱对偶需要 Slater 条件。错；弱对偶几乎无条件成立。
3. 强对偶等于对偶最优解一定存在。最优值相等与上确界是否取到是两个问题。
4. KKT 对所有问题都是充要条件。非凸问题中通常不是。
5. 互补松弛表示 $\lambda_i^* = 0$ 或 $f_i(x^*) = 0$ 二者只能成立一个。两者可以同时为零。
6. 等式乘子也必须非负。等式乘子 ν 不受符号约束。
7. 驻点公式中的不等式乘子项带负号。符号由 Lagrangian 定义决定；本书采用 $L = f_0 + \sum_i \lambda_i f_i + \sum_j \nu_j h_j$ 。

5.17 本章小结

共轭函数把函数表示为仿射下界的集合，Fenchel–Young 不等式则连接原变量与斜率。Lagrange 对偶通过对原变量取下确界构造原问题的全局下界。弱对偶始终成立；凸性与 Slater 条件把它加强为强对偶；KKT 条件最终把原始可行性、对偶可行性、互补松弛和驻点条件组合成可检验的全局最优性证书。

Part III

算法工具箱

6 强凸性、光滑性与下降框架

普通凸性说明局部信息具有全局意义，却没有回答两个定量问题：函数离切平面至少多远，以及函数弯曲得最多有多快。强凸性给出统一的下曲率，光滑性给出统一的上曲率；二者共同决定一阶算法的收敛速度。

本章统一使用：

- $\mu > 0$ 表示强凸参数；
- $L > 0$ 表示梯度 Lipschitz 常数；
- $\kappa = L/\mu$ 表示条件数。

6.1 强凸性

设 f 在凸集 C 上可微。若存在 $\mu > 0$ ，使对任意 $x, y \in C$ ，

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|_2^2, \quad (6.1)$$

则称 f 在 C 上为 μ -强凸函数。

普通凸性只要求函数位于切平面上方；强凸性进一步要求函数与切平面之间至少存在一个二次间隙。

等价地，

$$x \mapsto f(x) - \frac{\mu}{2} \|x\|_2^2$$

是凸函数。

6.1.1 二阶判据

若 f 在开凸集 C 上二阶可微, 则

$$f \text{ 为 } \mu\text{-强凸} \iff \nabla^2 f(x) \succeq \mu I, \quad \forall x \in C.$$

对二次函数

$$f(x) = \frac{1}{2}x^\top P x + q^\top x + r, \quad P = P^\top,$$

最优的强凸参数是 P 的最小特征值:

$$\mu = \lambda_{\min}(P),$$

前提是 $P \succ 0$ 。

6.2 强凸性的直接推论

6.2.1 最优解唯一

强凸函数至多有一个最优解。若 $x_1 \neq x_2$ 都是最优点, 则强凸性在其中点给出

$$f\left(\frac{x_1 + x_2}{2}\right) \leq \frac{1}{2}f(x_1) + \frac{1}{2}f(x_2) - \frac{\mu}{8}\|x_1 - x_2\|_2^2 < p^*,$$

与 p^* 的定义矛盾。

6.2.2 函数误差控制距离误差

若 x^* 是无约束最优点, 则 $\nabla f(x^*) = 0$ 。在式 6.1 中令 $x = x^*$, 得到

$$f(x) - f(x^*) \geq \frac{\mu}{2}\|x - x^*\|_2^2. \quad (6.2)$$

因此

$$\|x - x^*\|_2 \leq \sqrt{\frac{2(f(x) - p^*)}{\mu}}.$$

目标值接近最优, 就能定量保证变量也接近唯一最优点。

6.2.3 梯度控制函数误差

本节及后续无约束梯度更新取 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ；若限制在一般凸集上，需另行检查更新可行性或使用投影。

从强凸下界出发，对右侧关于 y 求最小：

$$\inf_y \left[f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|_2^2 \right] = f(x) - \frac{1}{2\mu} \|\nabla f(x)\|_2^2.$$

由于 $f(y)$ 始终不小于该二次下界，

$$p^* \geq f(x) - \frac{1}{2\mu} \|\nabla f(x)\|_2^2,$$

所以

$$f(x) - p^* \leq \frac{1}{2\mu} \|\nabla f(x)\|_2^2. \quad (6.3)$$

这一步把“梯度小”转化为“函数值接近最优”，是线性收敛证明的关键接口。

6.3 光滑性

设 f 在凸集 C 上可微。若

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2, \quad \forall x, y \in C, \quad (6.4)$$

则称 f 为 L -光滑函数。

光滑性限制的是梯度变化速度，而不是函数值变化速度。函数 Lipschitz 连续与梯度 Lipschitz 连续是两个不同概念。

6.3.1 二次上界

若 f 为 L -光滑函数, 则

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|_2^2. \quad (6.5)$$

证明沿线段积分。令 $d = y - x$, 则

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \nabla f(x + td)^\top d \, dt \\ &= \nabla f(x)^\top d + \int_0^1 (\nabla f(x + td) - \nabla f(x))^\top d \, dt. \end{aligned}$$

由 Cauchy–Schwarz 不等式和梯度 Lipschitz 性,

$$(\nabla f(x + td) - \nabla f(x))^\top d \leq Lt \|d\|_2^2.$$

积分即得 式 6.5。



二次夹逼

若 f 同时 μ -强凸且 L -光滑, 那么它在任一点附近都被两个共享同一切平面的二次函数夹住。强凸下界防止函数过平, 光滑上界防止函数弯曲过快。

6.3.2 二阶判据

若 f 在开凸集 C 上二阶连续可微, 则 L -光滑等价于

$$\|\nabla^2 f(x)\|_{\text{op}} \leq L \iff -LI \preceq \nabla^2 f(x) \preceq LI, \quad x \in C.$$

必要性由梯度沿单位方向的差商得到; 充分性由沿线段积分 Hessian 得到。若 f 还凸, 则下界可加强为 $0 \preceq \nabla^2 f(x)$ 。

只有上界 $\nabla^2 f \preceq LI$, 不能排除负曲率过大, 因此在一般非凸情形下不足以刻画光滑性。

6.4 光滑性的下降保证

在式 6.5 中取

$$y = x - \frac{1}{L} \nabla f(x),$$

得到

$$\begin{aligned} f\left(x - \frac{1}{L} \nabla f(x)\right) &\leq f(x) - \frac{1}{L} \|\nabla f(x)\|_2^2 + \frac{1}{2L} \|\nabla f(x)\|_2^2 \\ &= f(x) - \frac{1}{2L} \|\nabla f(x)\|_2^2. \end{aligned} \tag{6.6}$$

因此，只要梯度非零，步长 $1/L$ 的负梯度更新一定降低目标。

如果 f 还是凸函数，并且最优解存在，则

$$f(x) - p^* \geq \frac{1}{2L} \|\nabla f(x)\|_2^2. \tag{6.7}$$

原因是 p^* 不大于式 6.6 左侧的函数值。

6.5 梯度余强制性

凸性给出梯度的单调性，光滑性限制梯度差的大小。二者结合，能进一步用内积控制梯度差的平方。

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 凸且 L -光滑，则 Baillon–Haddad 定理给出

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|_2^2. \tag{6.8}$$

这称为梯度的 $1/L$ -余强制性。它同时约束梯度差的长度和方向，强于单独使用 Cauchy–Schwarz 不等式。

关键证明。固定 y ，减去切平面的线性部分，令

$$h(z) = f(z) - \nabla f(y)^\top z.$$

h 仍凸且 L -光滑，并且 $\nabla h(y) = 0$ ，所以 y 是其全局最优点。对 h 从 x 做一步梯度下降，得到

$$h(y) \leq h\left(x - \frac{1}{L} \nabla h(x)\right) \leq h(x) - \frac{1}{2L} \|\nabla h(x)\|_2^2.$$

代回定义便有

$$f(x) - f(y) - \nabla f(y)^\top (x - y) \geq \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|_2^2.$$

交换 x, y 再相加，即得式 式 6.8。这里凸性用于把 $\nabla h(y) = 0$ 转成全局最优，光滑性用于单步下降。

6.5.1 强凸光滑情形的加强

若 f 还为 μ -强凸，记 $s = x - y$ 、 $v = \nabla f(x) - \nabla f(y)$ ，则

$$\langle v, s \rangle \geq \frac{\mu L}{\mu + L} \|s\|_2^2 + \frac{1}{\mu + L} \|v\|_2^2. \quad (6.9)$$

当 $\mu < L$ ，令 $\tilde{f}(z) = f(z) - \mu\|z\|_2^2/2$ 。它凸且 $(L - \mu)$ -光滑：从 f 的二次上界减去该二次项，得到常数 $L - \mu$ 的二次上界；对全空间可微凸函数，这与相同常数的梯度光滑性等价。

对 $\tilde{f}$ 使用余强制性，

$$(L - \mu) \langle v - \mu s, s \rangle \geq \|v - \mu s\|_2^2.$$

展开并移项，得到

$$(L + \mu) \langle v, s \rangle \geq \|v\|_2^2 + \mu L \|s\|_2^2.$$

当 $L = \mu$ ，强凸下界与光滑上界重合， $f(z) - \mu\|z\|_2^2/2$ 为仿射函数，故 $v = \mu s$ ，上述结论仍成立。下一章用它证明梯度更新的距离收缩。

6.6 强凸与光滑的联合控制

若 f 同时 μ -强凸且 L -光滑，并有无约束最优点 x^* ，则

$$\frac{\mu}{2} \|x - x^*\|_2^2 \leq f(x) - p^* \leq \frac{L}{2} \|x - x^*\|_2^2,$$

以及

$$2\mu(f(x) - p^*) \leq \|\nabla f(x)\|_2^2 \leq 2L(f(x) - p^*).$$

这些不等式把三种误差联系起来：

- 变量距离 $\|x - x^*\|$;
- 函数误差 $f(x) - p^*$;
- 梯度大小 $\|\nabla f(x)\|$ 。

分析算法时，可以根据最容易递推的量在三者之间转换。

6.7 条件数

定义条件数

$$\kappa = \frac{L}{\mu} \geq 1.$$

对正定二次函数，若 P 的特征值位于 $[\mu, L]$ ，则

$$\kappa = \frac{\lambda_{\max}(P)}{\lambda_{\min}(P)}.$$

κ 描述不同方向曲率的不均衡程度：

- κ 接近 1 时，等高线接近球形；
- κ 很大时，等高线狭长，负梯度方向容易在陡峭方向来回摆动，而在平坦方向推进缓慢。

因此，变量缩放和预条件的目标不是改变最优解，而是改善问题几何，使各方向曲率更均衡。

6.8 一般下降方法

迭代方法通常写为

$$x_{k+1} = x_k + t_k d_k, \tag{6.10}$$

其中 d_k 是搜索方向， $t_k > 0$ 是步长。

若

$$\nabla f(x_k)^\top d_k < 0, \tag{6.11}$$

则 d_k 为下降方向。因为

$$f(x_k + t d_k) = f(x_k) + t \nabla f(x_k)^\top d_k + o(t),$$

所以对充分小的 $t > 0$ ，目标必然下降。

负梯度方向 $d_k = -\nabla f(x_k)$ 是最常用下降方向，但不是唯一选择。不同方向相当于使用不同的局部几何或预条件。

6.9 步长选择

6.9.1 固定步长

若已知光滑常数 L ，常用

$$t_k = \frac{1}{L}.$$

它直接保证式 6.6。缺点是实际问题中的 L 通常未知，而且全局上界可能过于保守。

6.9.2 精确线搜索

给定下降方向 d_k ，精确线搜索求

$$t_k \in \operatorname{argmin}_{t \geq 0} f(x_k + td_k).$$

这里要求射线上的最小值能够取得；仅有下降方向并不能保证这一点。步长 $1/L$ 最小化的是下降引理给出的二次上界，一般不是原函数的精确线搜索解。

它在当前射线上选择最优步长，但求解一维问题也有成本。精确线搜索单步更优，不代表总运行时间一定更短。

6.9.3 回溯线搜索

给定参数

$$\alpha \in (0, 1/2), \quad \beta \in (0, 1),$$

从 $t = 1$ 开始，反复令 $t \leftarrow \beta t$ ，直到满足 Armijo 条件

$$f(x_k + td_k) \leq f(x_k) + \alpha t \nabla f(x_k)^\top d_k. \quad (6.12)$$

右侧要求实际下降量至少达到一阶预测下降量的一定比例。因为 d_k 是下降方向，充分小的步长总会满足该条件，所以回溯过程会在有限次缩减后终止。

i 线搜索检查的是充分下降，不是步长越小越好

过大的步长可能越过低谷并使目标上升，过小的步长则推进缓慢。回溯线搜索从较大胆的步长出发，只缩小到刚好满足充分下降。

6.9.4 Wolfe 与 Goldstein 条件

记 $g_k = \nabla f(x_k)$, $\phi(t) = f(x_k + td_k)$, 并设 $g_k^\top d_k < 0$ 。Wolfe 条件由两部分组成，参数满足 $0 < c_1 < c_2 < 1$:

$$\begin{aligned}\phi(t_k) &\leq \phi(0) + c_1 t_k \phi'(0), \\ \phi'(t_k) &\geq c_2 \phi'(0).\end{aligned}\tag{6.13}$$

第一条是 Armijo 充分下降；第二条要求方向导数不再过于负，防止在仍可明显下降时过早停下。由于 $\phi'(0) < 0$ ，第二条对足够小的步长通常不成立，因此单纯不断缩小步长不能实现一般的 Wolfe 搜索。

强 Wolfe 条件把第二条换成

$$|\phi'(t_k)| \leq c_2 |\phi'(0)|,$$

还限制了越过谷底后的正斜率。若 ϕ 连续可微、沿正射线下有界且 $\phi'(0) < 0$ ，则存在满足强 Wolfe 条件的正步长；具体括区间与缩放算法暂不展开。

Goldstein 条件用函数值的双边约束排除过小步长：

$$\phi(0) + (1 - c)t_k \phi'(0) \leq \phi(t_k) \leq \phi(0) + ct_k \phi'(0), \quad 0 < c < \frac{1}{2}.$$

本书以后主要使用 Armijo 和 Wolfe；Goldstein 保留作比较，不再单独展开证明。

6.10 线搜索的收敛接口：Zoutendijk 定理

逐步下降不等于最终到达最优点：若步长不断变小，总推进量仍可能有限。Zoutendijk 定理说明，Wolfe 条件如何保证下降量与梯度大小建立联系。

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 连续可微、下有界，且存在统一常数 $L > 0$ 使梯度全局 L -Lipschitz。每个未终止的迭代使用下降方向 d_k 和满足式 6.13 的步长，参数 c_1, c_2 固定。定义

$$\cos \theta_k = \frac{-g_k^\top d_k}{\|g_k\|_2 \|d_k\|_2} > 0.$$

则

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|g_k\|_2^2 < \infty. \quad (6.14)$$

若某一步梯度为零，算法可直接终止，无需再定义该步方向角。这里使用全局光滑假设使陈述简洁；局部版本可在包含相关迭代线段的区域内施加统一光滑界。

证明。 Wolfe 曲率条件与 Lipschitz 性依次给出

$$(1 - c_2)(-g_k^\top d_k) \leq (g_{k+1} - g_k)^\top d_k \leq L t_k \|d_k\|_2^2.$$

因此步长不能任意小：

$$t_k \geq \frac{(1 - c_2)(-g_k^\top d_k)}{L \|d_k\|_2^2}.$$

再由 Armijo 条件，

$$\begin{aligned} f(x_k) - f(x_{k+1}) &\geq c_1 t_k (-g_k^\top d_k) \\ &\geq \frac{c_1(1 - c_2)}{L} \cos^2 \theta_k \|g_k\|_2^2. \end{aligned}$$

设 f_{low} 为函数下界，对 $k = 0, \dots, N$ 求和得到

$$\sum_{k=0}^N \cos^2 \theta_k \|g_k\|_2^2 \leq \frac{L[f(x_0) - f_{\text{low}}]}{c_1(1 - c_2)}.$$

右侧与 N 无关，令 $N \rightarrow \infty$ 即得结论。

6.10.1 从可求和到梯度趋于零

如果方向始终与负梯度保持足够小的夹角，即存在统一 $\delta > 0$ 使 $\cos \theta_k \geq \delta$ ，则 $\sum_k \|g_k\|_2^2 < \infty$ ，从而 $\|g_k\|_2 \rightarrow 0$ 。负梯度方向的 $\cos \theta_k = 1$ ，直接满足这一条件。

定理本身不要求凸性，也不直接保证 x_k 收敛。若序列有聚点，梯度连续性保证聚点驻定；再加凸性，驻点才是全局最优点。不要把一般非凸算法中的“全局收敛”误读成“找到全局最优解”。

一般可微函数中， $g_k^\top d_k < 0$ 保证充分小的正步长下降；反过来，仅观察到目标下降，不能推出方向导数严格为负。例如 $f(t) = -t^3$ 在 0 处向右下降，但导数为零。

6.11 典型误区

1. 严格凸一定存在统一强凸参数。错； e^x 在 $\mathbb{R}$ 上严格凸但不强凸。
2. 光滑函数的函数值一定有界。光滑只限制梯度变化，不限制函数本身大小。
3. 函数 Lipschitz 与梯度 Lipschitz 是同一条件。前者常等价于梯度有界，后者控制 Hessian 或梯度差。
4. 条件数只由算法决定。条件数首先是目标函数几何性质，也会受变量尺度影响。
5. 精确线搜索一定更高效。它减少迭代次数的同时可能增加单步成本。

6.12 本章小结

强凸性提供二次下界，使最优解唯一并把梯度、函数误差和变量距离联系起来；光滑性提供二次上界，保证适当的负梯度步能够下降。条件数 $\kappa = L/\mu$ 描述上下曲率的比例，是一阶方法快慢的核心量。一般下降框架将算法拆为搜索方向和步长选择，为下一章的梯度方法提供统一接口。

7 梯度方法与无约束优化

梯度给出函数在当前位置增长最快的方向，因此负梯度是最直接的下降方向。梯度下降的价值不只在于算法简单，更在于它清楚展示了函数结构如何转化为收敛速率：光滑性给出 $O(1/k)$ ，再加入强凸性便得到线性收敛。

7.1 梯度下降法

考虑无约束问题

$$\min_{x \in \mathbb{R}^n} f(x),$$

其中 f 可微。梯度下降迭代为

$$x_{k+1} = x_k - \eta_k \nabla f(x_k), \quad (7.1)$$

其中 $\eta_k > 0$ 为步长。

算法模板为：

1. 选择初始点 x_0 ;
2. 计算梯度 $g_k = \nabla f(x_k)$;
3. 选择步长 η_k ;
4. 更新 $x_{k+1} = x_k - \eta_k g_k$;
5. 满足停止条件时退出。

常用停止条件包括

$$\|\nabla f(x_k)\|_2 \leq \varepsilon_g,$$

相邻函数值变化足够小，或达到预设迭代次数。只有在相应凸性与误差界条件下，梯度小才可直接解释为接近全局最优。

7.2 为什么负梯度是最速下降方向

在 Euclidean 单位球中，一阶近似下降最快的方向由

$$\min_{\|d\|_2 \leq 1} \nabla f(x)^\top d$$

给出。由 Cauchy-Schwarz 不等式，

$$\nabla f(x)^\top d \geq -\|\nabla f(x)\|_2 \|d\|_2 \geq -\|\nabla f(x)\|_2,$$

等号在

$$d = -\frac{\nabla f(x)}{\|\nabla f(x)\|_2}$$

处取得。因此负梯度是 Euclidean 几何下的最速下降方向。

7.2.1 最速下降依赖所选范数

若单位步长由一般范数 $\|\cdot\|$ 衡量，则方向变为

$$d^\star \in \operatorname{argmin}_{\|d\| \leq 1} \nabla f(x)^\top d.$$

最优值是

$$-\|\nabla f(x)\|_\star,$$

其中 $\|\cdot\|_\star$ 是对偶范数。由此可见，“最速”不是坐标无关的绝对概念，而是相对于度量定义的。

7.3 步长的三种选择

7.3.1 固定步长

若 f 为 L -光滑函数, 最常用的是

$$\eta_k = \frac{1}{L}.$$

更一般地, $0 < \eta_k < 2/L$ 可在正定二次问题中保证收敛; 统一理论通常采用不超过 $1/L$ 的步长, 以获得简洁下降界。

7.3.2 精确线搜索

精确线搜索选择

$$\eta_k \in \operatorname{argmin}_{\eta \geq 0} f(x_k - \eta \nabla f(x_k)).$$

在凸二次问题中, 它常可解析求出; 一般问题则需要额外的一维优化。

7.3.3 回溯线搜索

若 L 未知, 可以从 $\eta = 1$ 开始反复缩小, 直到

$$f(x_k - \eta \nabla f(x_k)) \leq f(x_k) - \alpha \eta \|\nabla f(x_k)\|_2^2$$

成立, 其中 $\alpha \in (0, 1/2)$ 。这是第 6 章 Armijo 条件在负梯度方向上的具体形式。

7.4 如何阅读收敛速度

先明确误差量, 再比较速率。函数误差 $f(x_k) - f(x^*)$ 、距离误差 $\|x_k - x^*\|_2$ 与梯度范数不是同一个序列; 它们之间的转换需要相应条件。

对趋于零的非负误差 e_k , 常用约定如下; 若有限步误差变为零, 直接视为已经求解。

类型	充分大的 k 上满足的关系	含义
Q-线性	$e_{k+1} \leq q e_k$, 固定 $0 < q < 1$	每轮按固定比例缩小
Q-超线性	$e_{k+1}/e_k \rightarrow 0$	缩小比例也趋于零

类型	充分大的 k 上满足的关系	含义
Q-二次	$e_{k+1} \leq C e_k^2$, 固定 $C > 0$	误差足够小时, 平方效应主导

“线性”指误差的递推关系；例如 q^k 在对数纵轴上近似直线。 $O(1/k)$ 、 $O(1/k^2)$ 则通常描述次线性的误差上界，不能据此断言实际相邻误差之比恰好趋于 1。

R-线性只要求 $e_k \leq C q^k$ ，允许实际误差在该几何上界内波动，不要求每一步都按比例下降。Q-线性蕴含 R-线性，反向一般不成立。读收敛定理时，还应区分“从任意初值出发的保证”与“初值足够接近解的局部保证”。

7.5 光滑凸函数的 $O(1/k)$ 收敛率

假设：

1. f 为凸函数；
2. f 为 L -光滑函数；
3. 最优解 x^* 存在；
4. 使用固定步长 $\eta = 1/L$ 。

则

$$f(x_k) - f(x^*) \leq \frac{L \|x_0 - x^*\|_2^2}{2k}. \quad (7.2)$$

7.5.1 单步势函数下降

记

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k).$$

光滑性给出

$$f(x_{k+1}) \leq f(x_k) + \nabla f(x_k)^\top (x_{k+1} - x_k) + \frac{L}{2} \|x_{k+1} - x_k\|_2^2.$$

凸性给出

$$f(x_k) - f(x^*) \leq \nabla f(x_k)^\top (x_k - x^*).$$

将两式相加并整理：

$$f(x_{k+1}) - f(x^*) \leq \nabla f(x_k)^\top (x_{k+1} - x^*) + \frac{L}{2} \|x_{k+1} - x_k\|_2^2.$$

由

$$\nabla f(x_k) = L(x_k - x_{k+1}),$$

右侧变为

$$\frac{L}{2} (\|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2). \quad (7.3)$$

7.5.2 求和

对 $i = 0, \dots, k-1$ 求和, 距离项望远镜消去:

$$\sum_{i=0}^{k-1} (f(x_{i+1}) - f(x^*)) \leq \frac{L}{2} \|x_0 - x^*\|_2^2.$$

梯度下降在步长 $1/L$ 下使函数值单调不增, 因此

$$k(f(x_k) - f(x^*)) \leq \sum_{i=0}^{k-1} (f(x_{i+1}) - f(x^*)).$$

两式结合即得式 7.2。

i 如何读懂 $O(1/k)$

若希望函数误差不超过 ε , 迭代次数满足

$$k \geq \frac{L\|x_0 - x^*\|_2^2}{2\varepsilon}.$$

因此精度要求缩小十倍, 理论迭代次数大约增加十倍。

7.6 强凸光滑函数的线性收敛

进一步假设 f 为 μ -强凸函数。第 6 章给出

$$\|\nabla f(x_k)\|_2^2 \geq 2\mu(f(x_k) - p^*).$$

光滑下降界给出

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|_2^2.$$

合并得到

$$f(x_{k+1}) - p^* \leq \left(1 - \frac{\mu}{L}\right) (f(x_k) - p^*).$$

递推可得

$$f(x_k) - p^* \leq \left(1 - \frac{1}{\kappa}\right)^k (f(x_0) - p^*), \quad (7.4)$$

其中 $\kappa = L/\mu$ 。

由于

$$\left(1 - \frac{1}{\kappa}\right)^k \leq e^{-k/\kappa},$$

达到误差 ε 所需迭代次数为

$$k = O\left(\kappa \log \frac{f(x_0) - p^*}{\varepsilon}\right).$$

这里“线性收敛”指误差按固定比例缩小，也称几何收敛；它并不是说误差随 k 线性下降。

7.6.1 一般强凸光滑函数的距离收缩

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为 μ -强凸、 L -光滑函数, x^* 为其唯一最优解。记 $e_k = x_k - x^*$ 、 $g_k = \nabla f(x_k)$ 。固定步长 $0 < t \leq 2/(L + \mu)$ 时, 由式 6.9 及 $\nabla f(x^*) = 0$,

$$\begin{aligned}\|e_{k+1}\|_2^2 &= \|e_k\|_2^2 - 2t\langle g_k, e_k \rangle + t^2\|g_k\|_2^2 \\ &\leq \left(1 - \frac{2t\mu L}{\mu + L}\right) \|e_k\|_2^2 + \left(t^2 - \frac{2t}{\mu + L}\right) \|g_k\|_2^2 \\ &\leq \left(1 - \frac{2t\mu L}{\mu + L}\right) \|e_k\|_2^2.\end{aligned}$$

最后一步正是步长上界被使用的位置。取 $t = 2/(L + \mu)$, 得到

$$\|x_{k+1} - x^*\|_2 \leq \frac{L - \mu}{L + \mu} \|x_k - x^*\|_2. \quad (7.5)$$

当 $L > \mu$, 这是距离误差的 Q-线性收敛; 当 $L = \mu$, 该步长一步到达最优解。这是上述距离上界中的最佳固定步长, 不是每个具体问题的精确线搜索步长, 也不保证同样的因子逐步控制函数误差。

7.7 二次函数中的谱视角

考虑

$$f(x) = \frac{1}{2}x^\top Px - q^\top x, \quad P \succ 0.$$

最优解满足 $Px^* = q$ 。固定步长梯度下降为

$$x_{k+1} = x_k - \eta(Px_k - q).$$

令误差 $e_k = x_k - x^*$, 则

$$e_{k+1} = (I - \eta P)e_k.$$

沿 P 的第 i 个特征向量方向, 误差乘以

$$1 - \eta\lambda_i(P).$$

因此收敛要求

$$|1 - \eta \lambda_i(P)| < 1$$

对所有特征值成立，也就是

$$0 < \eta < \frac{2}{L}.$$

选择

$$\eta = \frac{2}{L + \mu}$$

可以平衡最陡与最平方向，其距离收缩因子为

$$\frac{\kappa - 1}{\kappa + 1}.$$

这个谱分解清楚解释了病态问题中的“之”字形轨迹：同一个步长必须同时照顾大特征值方向的稳定性和小特征值方向的推进速度。

7.8 线搜索与固定步长如何选择

情形	常用选择	主要理由
已知可靠的 L	固定步长 $1/L$	理论清楚，单步成本低
L 未知但函数值可计算	回溯线搜索	自适应寻找充分下降步长
射线极小值易求	精确线搜索	可利用特殊结构
单步计算非常昂贵	固定或复用步长	避免重复函数评估

实践中还应关注梯度计算成本、稀疏结构、数值尺度与停止准则，而不只比较理论迭代次数。

7.9 与进阶无约束方法的接口

纸质笔记还列出：

- 坐标轮换法；
- Newton 法；
- 拟 Newton 法。

这些方法保留在主线之外，是因为它们分别依赖坐标可分性或二阶曲率，而不是梯度下降的统一一阶框架。附录 C 已按同一写作标准补入：坐标下降从坐标 Lipschitz 上界推导单步更新；Newton 法从二阶局部模型推导线性系统；BFGS 则用割线条件近似 Hessian，并说明正定性与线搜索条件。

当完整梯度被随机样本替代，或目标从固定函数变为在线损失序列时，步长、评价指标和证明条件都会改变。SGD、镜像下降与在线遗憾的统一入口见附录 D。

7.10 典型误区

1. 负梯度在任何度量下都是最速方向。它只在 Euclidean 范数下成立。
2. 步长越大下降越快。超过稳定范围会振荡甚至发散。
3. 函数值单调下降就一定收敛到最优点。还需要凸性、光滑性、解存在等条件。
4. 线性收敛表示误差每次减去固定常数。实际上是每次乘以固定比例。
5. 梯度很小总能证明接近最优。需要凸性及强凸性等误差界条件；非凸问题可能停在鞍点附近。

7.11 本章小结

梯度下降由下降方向和步长共同决定。对 L -光滑凸函数，步长 $1/L$ 给出 $O(1/k)$ 函数误差；再加入 μ -强凸性，速率提升为依赖条件数 $\kappa = L/\mu$ 的线性收敛。二次函数的谱分解进一步说明，不同方向曲率不均衡正是梯度法变慢的根源。

8 约束优化与复合结构

约束改变了无约束梯度法的基本动作：沿负梯度移动后，新点可能不再可行。最直接的修正就是把更新点投影回可行集。对结构简单的闭凸集，这一操作既保持可行性，又能延续无约束梯度法的收敛分析。

本章展开课件完整支撑的投影梯度、等式约束 KKT 系统和约束处理框架。近端梯度、增广 Lagrangian 与 ADMM 需要额外的次微分和变量分裂语言，集中整理在 附录 C。

8.1 Euclidean 投影

设 $C \subseteq \mathbb{R}^n$ 为非空闭凸集。点 x 到 C 的 Euclidean 投影定义为

$$\Pi_C(x) = \operatorname{argmin}_{z \in C} \frac{1}{2} \|z - x\|_2^2. \quad (8.1)$$

由于目标函数关于 z 强凸，且 C 非空闭，投影存在且唯一。

若集合不是凸的，最近点可能不唯一；若集合不闭，距离下确界可能无法取到。因此“非空、闭、凸”三个条件各有作用。

8.1.1 常见投影

8.1.1.1 区间盒

对

$$C = \{x \mid \ell_i \leq x_i \leq u_i\},$$

投影逐坐标截断：

$$[\Pi_C(x)]_i = \min\{u_i, \max\{\ell_i, x_i\}\}.$$

8.1.1.2 非负正交锥

对 $C = \mathbb{R}_+^n$,

$$[\Pi_C(x)]_i = \max\{x_i, 0\}.$$

8.1.1.3 Euclidean 球

对

$$C = \{x \mid \|x\|_2 \leq r\},$$

有

$$\Pi_C(x) = \begin{cases} x, & \|x\|_2 \leq r, \\ r \frac{x}{\|x\|_2}, & \|x\|_2 > r. \end{cases}$$

8.2 投影的变分刻画

令 $p = \Pi_C(x)$ 。则

$$(x - p)^\top (z - p) \leq 0, \quad \forall z \in C. \quad (8.2)$$

证明只需对投影问题使用一阶最优性条件。目标函数

$$\phi(z) = \frac{1}{2} \|z - x\|_2^2$$

的梯度为 $\nabla \phi(z) = z - x$, 所以

$$(p - x)^\top (z - p) \geq 0,$$

等价于式 8.2。

几何上, $x - p$ 与从 p 指向任意可行点 z 的方向形成钝角。若某个方向形成锐角, 沿该方向移动就能进一步靠近 x , 与 p 是最近点矛盾。

8.2.1 Pythagorean 不等式

展开平方距离：

$$\|x - z\|_2^2 = \|x - p\|_2^2 + \|p - z\|_2^2 + 2(x - p)^\top(p - z).$$

由式 式 8.2,

$$(x - p)^\top(p - z) \geq 0,$$

因此

$$\|x - z\|_2^2 \geq \|x - p\|_2^2 + \|p - z\|_2^2. \quad (8.3)$$

当 C 是仿射子空间时，相关方向正交，上式取等号；一般凸集只保证不等式。

8.2.2 非扩张性

对任意 x, y ,

$$\|\Pi_C(x) - \Pi_C(y)\|_2 \leq \|x - y\|_2. \quad (8.4)$$

投影不会放大两点之间的距离。收敛分析正是利用这一性质，保证“投影回去”不会破坏与最优点之间的距离递推。

8.3 投影梯度法

考虑

$$\min_{x \in C} f(x),$$

其中 C 非空闭凸， f 可微且凸。投影梯度更新为

$$x_{k+1} = \Pi_C(x_k - \eta_k \nabla f(x_k)). \quad (8.5)$$

初始点取 $x_0 \in C$ ，此后每次投影都保证 $x_k \in C$ 。

这个更新分成两步：

1. 忽略约束，沿负梯度移动；
2. 将结果投影回 C 。

若 $C = \mathbb{R}^n$ ，投影是恒等映射，算法退化为普通梯度下降。

8.3.1 二次模型解释

式 式 8.5 等价于

$$x_{k+1} = \operatorname{argmin}_{z \in C} \left\{ \nabla f(x_k)^\top (z - x_k) + \frac{1}{2\eta_k} \|z - x_k\|_2^2 \right\}. \quad (8.6)$$

第一项希望沿一阶近似降低目标，第二项限制更新不要离当前位置过远。投影梯度并非先随意走一步再“补救”，而是在可行域上直接最小化一个局部二次模型。

8.4 光滑凸情形的 $O(1/k)$ 速率

假设：

1. f 为凸且 L -光滑；
2. C 非空闭凸；
3. 最优解 $x^* \in C$ 存在；
4. 使用步长 $\eta = 1/L$ 。

则

$$f(x_k) - f(x^*) \leq \frac{L\|x_0 - x^*\|_2^2}{2k}. \quad (8.7)$$

记 $x^+ = x_{k+1}$ 、 $x = x_k$ 。由式 式 8.6 的最优性条件，对任意 $z \in C$ ，

$$(\nabla f(x) + L(x^+ - x))^\top (z - x^+) \geq 0.$$

结合光滑上界与凸性下界，可得

$$f(x^+) - f(z) \leq \frac{L}{2} (\|x - z\|_2^2 - \|x^+ - z\|_2^2). \quad (8.8)$$

令 $z = x^*$ 并对迭代求和，距离项望远镜消去；再利用函数值单调不减，即得式 式 8.7。

8.5 仅有梯度界时的 $O(1/\sqrt{K})$ 速率

若不使用光滑性，只假设

$$\|\nabla f(x)\|_2 \leq G, \quad \forall x \in C,$$

并记

$$D = \|x_0 - x^*\|_2,$$

则常步长投影梯度满足另一类速率。

由投影非扩张性,

$$\begin{aligned} \|x_{k+1} - x^*\|_2^2 &\leq \|x_k - \eta \nabla f(x_k) - x^*\|_2^2 \\ &= \|x_k - x^*\|_2^2 - 2\eta \nabla f(x_k)^\top (x_k - x^*) + \eta^2 \|\nabla f(x_k)\|_2^2. \end{aligned}$$

由凸性,

$$\nabla f(x_k)^\top (x_k - x^*) \geq f(x_k) - f(x^*).$$

因此

$$2\eta(f(x_k) - f(x^*)) \leq \|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2 + \eta^2 G^2.$$

对 $k = 0, \dots, K-1$ 求和, 并定义平均点

$$\bar{x}_K = \frac{1}{K} \sum_{k=0}^{K-1} x_k,$$

由 Jensen 不等式得到

$$f(\bar{x}_K) - f(x^*) \leq \frac{D^2}{2\eta K} + \frac{\eta G^2}{2}. \quad (8.9)$$

选择

$$\eta = \frac{D}{G\sqrt{K}},$$

可得

$$f(\bar{x}_K) - f(x^\star) \leq \frac{DG}{\sqrt{K}}.$$

这里输出平均点而不是最后一个迭代点，是因为证明控制的是各轮函数误差之和。若进一步允许不可微函数并用次梯度替代梯度，就得到投影次梯度法；其定义、步长条件与 $O(1/\sqrt{K})$ 结论见 附录 C。

8.6 等式约束与 KKT 线性系统

对等式约束二次问题

$$\begin{aligned} & \text{minimize} && \frac{1}{2}x^\top Px + q^\top x \\ & \text{subject to} && Ax = b, \end{aligned}$$

其中 $P \succ 0$, KKT 条件为

$$Px + q + A^\top \nu = 0, \quad Ax = b.$$

可以合并为线性系统

$$\begin{bmatrix} P & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} x^\star \\ \nu^\star \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}. \quad (8.10)$$

这体现了约束优化的另一条路线：不反复投影，而是直接联立原变量与乘子的一阶条件。对一般凸问题，KKT 系统通常是非线性的，需要专门算法求解。

8.7 三种约束处理路线

路线	适用结构	核心动作
消去约束	线性等式易参数化	在零空间坐标中优化
投影方法	Π_C 易计算	梯度更新后保持可行
对偶与 KKT	乘子结构清晰	联立或转到对偶问题

选择方法时，关键问题不是约束有多少，而是投影、参数化或对偶下确界哪一个最容易计算。

8.8 复合结构的边界

许多机器学习目标写为

$$F(x) = g(x) + h(x),$$

其中 g 光滑凸, 而 h 凸但可能不可微。集合约束是特殊情形:

$$h(x) = I_C(x).$$

投影梯度正是在处理这一特殊复合结构。若 h 是 ℓ_1 范数等一般正则项, 需要近端算子与近端梯度。附录 C 从近端子问题的一阶条件出发, 进一步给出基本近端梯度、FISTA、增广 Lagrangian 与两块 ADMM。

8.9 典型误区

1. 投影只要求集合非空。唯一投影需要闭凸结构。
2. 先梯度下降再投影一定等于约束问题的精确最优步。它只是局部二次模型的精确解。
3. 投影会增加到最优点的距离。对凸集的 Euclidean 投影具有非扩张性。
4. 有界梯度与光滑性相同。前者控制梯度大小, 后者控制梯度变化。
5. 任何约束都适合投影法。如果投影本身比原问题还难, 就应考虑消元、对偶或其他结构化方法。

8.10 本章小结

Euclidean 投影把不可行更新拉回非空闭凸集, 并通过变分刻画、Pythagorean 不等式和非扩张性支持收敛分析。光滑凸情形下, 投影梯度保持 $O(1/k)$ 速率; 只有梯度有界时, 平均迭代点获得 $O(1/\sqrt{K})$ 速率。等式约束 KKT 系统展示了乘子路线, 而指示函数则把投影方法连接到更一般的复合优化框架。

Part IV

模型与应用

9 典型凸模型与机器学习应用

凸优化工具真正发挥作用的地方，是把具体任务识别为少数可复用模型。本章不追求罗列应用，而是提炼六类高频结构：线性规划、二次与最小二乘、范数逼近、正则化、投影和线性分类。

9.1 线性规划

线性规划的一般形式是

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && Ax \leq b, \\ & && Cx = d. \end{aligned}$$

目标和所有约束都是仿射函数，因此线性规划是凸优化问题。

常见标准形式为

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && Ax = b, \\ & && x \succeq 0. \end{aligned} \tag{9.1}$$

一般线性规划可以通过以下操作转为标准形式：

- 对 $a_i^\top x \leq b_i$ 引入松弛变量 $s_i \geq 0$;
- 将自由变量写成 $x_j = x_j^+ - x_j^-$ ，其中 $x_j^+, x_j^- \geq 0$;
- 通过乘以 -1 调整不等式方向。

9.1.1 Chebyshev 逼近

最小化最大绝对误差:

$$\min_x \|Ax - b\|_\infty$$

表面上含有范数与最大值, 引入变量 t 后变为

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && -t\mathbf{1} \leq Ax - b \leq t\mathbf{1}. \end{aligned}$$

这就是线性规划。识别动作是把

$$\max_i |a_i^\top x - b_i|$$

改写为对所有分量同时成立的线性上下界。

9.2 二次规划与最小二乘

凸二次规划的一般形式为

$$\begin{aligned} & \text{minimize} && \frac{1}{2}x^\top Px + q^\top x + r \\ & \text{subject to} && Ax \leq b, \\ & && Cx = d, \end{aligned} \tag{9.2}$$

其中 $P \succeq 0$ 。若 $P \succ 0$ 且可行集非空, 则最优解唯一。

9.2.1 最小二乘

基本最小二乘问题为

$$\min_x \frac{1}{2} \|Ax - b\|_2^2.$$

展开后,

$$\frac{1}{2} \|Ax - b\|_2^2 = \frac{1}{2} x^\top A^\top A x - b^\top A x + \frac{1}{2} \|b\|_2^2,$$

其 Hessian 为

$$A^\top A \succeq 0.$$

正规方程为

$$A^\top Ax = A^\top b.$$

若 A 列满秩, 则目标强凸, 解唯一。

9.2.2 加权最小二乘

若不同观测具有不同可靠性, 可使用

$$\min_x \frac{1}{2} (Ax - b)^\top W (Ax - b), \quad W \succeq 0.$$

若 W 是对角矩阵, 其对角元素就是各观测残差的权重。

9.2.3 Ridge 回归

加入二次正则项:

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \frac{\lambda}{2} \|x\|_2^2, \quad \lambda > 0. \quad (9.3)$$

其一阶条件为

$$(A^\top A + \lambda I)x = A^\top b,$$

所以

$$x^* = (A^\top A + \lambda I)^{-1} A^\top b.$$

即使 A 不列满秩, $A^\top A + \lambda I \succ 0$, 解仍然唯一。正则化不仅限制参数大小, 也改善了线性系统的条件数。

9.3 范数逼近

统一模型为

$$\min_x \|Ax - b\|, \quad (9.4)$$

其中范数选择表达了对误差的不同偏好。

损失	几何与统计倾向	常见标准形式
ℓ_2	强调平方能量，解析结构好	二次规划
ℓ_1	对少量大残差更稳健	线性规划
ℓ_∞	控制最坏分量误差	线性规划

9.3.1 ℓ_1 逼近的线性规划形式

引入 $u \succeq 0$:

$$\begin{aligned} &\text{minimize} && \mathbf{1}^\top u \\ &\text{subject to} && -u \leq Ax - b \leq u. \end{aligned}$$

在最优点, $u_i = |(Ax - b)_i|$ 。

9.3.2 带约束的逼近

先验知识可以直接进入可行域:

$$\begin{aligned} &\text{minimize} && \|Ax - b\| \\ &\text{subject to} && Fx \leq g. \end{aligned}$$

只要使用凸范数且约束集凸, 问题仍然是凸的。约束表达必须满足的结构, 正则化则表达软偏好。

9.4 正则化与约束形式

正则化问题写为

$$\min_x \ell(x) + \lambda R(x), \quad \lambda \geq 0, \quad (9.5)$$

其中 ℓ 衡量数据拟合, R 衡量模型复杂度。

对应的约束形式是

$$\begin{aligned} & \text{minimize} && \ell(x) \\ & \text{subject to} && R(x) \leq \tau. \end{aligned} \quad (9.6)$$

在凸性、最优解存在和适当约束资格条件下, 约束形式的最优乘子可以作为某个正则化权重 λ , 使两种形式共享最优解。但 λ 与 τ 通常没有简单的一一解析关系。

 正则项不是装饰性的附加项

λ 改变的是拟合误差与结构偏好的权衡。它过小会使正则化几乎失效, 过大则可能让结构项主导目标。不同特征量纲还会改变同一个 λ 的实际含义, 因此常需先做尺度标准化。

9.4.1 ℓ_1 与 ℓ_2 正则化

Ridge 使用

$$R(x) = \frac{1}{2} \|x\|_2^2,$$

产生光滑、强凸的惩罚。

Lasso 使用

$$R(x) = \|x\|_1,$$

其单位球带有尖角, 最优解更容易落在坐标轴或低维面上, 从而产生稀疏性。Lasso 是凸问题, 但目标在坐标为零处不可微。软阈值近端映射、近端梯度和坐标下降的算法模板见 [附录 C](#)。

9.5 最小范数问题

当线性方程

$$Ax = b$$

存在多个解时，可以选择最小范数解：

$$\begin{array}{ll} \text{minimize} & \|x\| \\ \text{subject to} & Ax = b. \end{array}$$

在 Euclidean 范数下，若 A 行满秩，

$$x^* = A^\top (AA^\top)^{-1}b.$$

这个解属于 $\text{range}(A^\top)$ ，并与 $\text{null}(A)$ 正交。任何其他可行解都可写成

$$x = x^* + z, \quad z \in \text{null}(A),$$

从而

$$\|x\|_2^2 = \|x^*\|_2^2 + \|z\|_2^2.$$

这说明最小范数解是线性约束与投影几何的直接结合。

9.6 凸集投影

投影问题

$$\min_{z \in C} \frac{1}{2} \|z - x\|_2^2$$

既是一个独立模型，也是投影梯度的基本子问题。

9.6.1 投影到超平面

对

$$C = \{z \mid a^\top z = b\}, \quad a \neq 0,$$

KKT 条件给出

$$z - x + \nu a = 0, \quad a^\top z = b.$$

消去 ν 后得到

$$\Pi_C(x) = x - \frac{a^\top x - b}{\|a\|_2^2} a. \quad (9.7)$$

修正量沿超平面法向量方向，这与几何直觉一致。

若投影集合由大量线性不等式、范数约束或半正定约束定义，投影本身就是一个凸优化问题，未必有闭式解。

9.7 线性分类与最大间隔

给定样本

$$(x_i, y_i), \quad x_i \in \mathbb{R}^n, \quad y_i \in \{-1, +1\},$$

仿射分类器为

$$\text{sign}(w^\top x + b).$$

正确分类要求

$$y_i(w^\top x_i + b) > 0.$$

由于 (w, b) 可以同时缩放，单纯最大化函数间隔没有意义。规定最靠近超平面的样本满足函数间隔 1 后，几何间隔为 $1/\|w\|_2$ 。

9.7.1 硬间隔 SVM

线性可分时，最大间隔问题为

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \|w\|_2^2 \\ & \text{subject to} && 1 - y_i(w^\top x_i + b) \leq 0, \quad i = 1, \dots, N. \end{aligned} \tag{9.8}$$

这是凸二次规划。Lagrangian 为

$$L(w, b, \alpha) = \frac{1}{2} \|w\|_2^2 + \sum_{i=1}^N \alpha_i (1 - y_i(w^\top x_i + b)),$$

其中 $\alpha_i \geq 0$ 。

驻点条件给出

$$w = \sum_{i=1}^N \alpha_i y_i x_i, \tag{9.9}$$

以及

$$\sum_{i=1}^N \alpha_i y_i = 0.$$

互补松弛为

$$\alpha_i (1 - y_i(w^\top x_i + b)) = 0.$$

所以只有满足 $\alpha_i > 0$ 的样本会出现在式 式 9.9 中，而且它们位于间隔边界上。这些样本就是支持向量。

将 w 消去，得到对偶问题

$$\begin{aligned} & \text{maximize}_\alpha && \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^\top x_j \\ & \text{subject to} && \alpha_i \geq 0, \\ & && \sum_{i=1}^N \alpha_i y_i = 0. \end{aligned} \tag{9.10}$$

对偶目标只通过内积 $x_i^\top x_j$ 使用样本，这也是核方法能够替换内积的接口。

9.7.2 软间隔 SVM

数据不可完全线性分离时, 引入松弛变量 $\xi_i \geq 0$:

$$\begin{aligned} & \text{minimize} && \frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^N \xi_i \\ & \text{subject to} && y_i(w^\top x_i + b) \geq 1 - \xi_i, \\ & && \xi_i \geq 0. \end{aligned} \tag{9.11}$$

$C > 0$ 控制间隔宽度与违约惩罚之间的权衡。其对偶仍为式 9.10 的目标, 但增加盒约束

$$0 \leq \alpha_i \leq C.$$

这正是软间隔中每个样本乘子上界的来源。

💡 支持向量决定分隔超平面

由式 9.9, $\alpha_i = 0$ 的样本不直接参与 w 的表示。只要数据变化没有改变支持向量集合及其最优乘子, 分隔超平面就不会改变; 但移动非支持向量也可能让它们进入间隔, 从而改变支持向量集合。

9.8 Logistic 回归

二分类 Logistic 回归可写为

$$\min_w \frac{1}{N} \sum_{i=1}^N \log(1 + e^{-y_i w^\top x_i}) + \frac{\lambda}{2} \|w\|_2^2. \tag{9.12}$$

函数 $u \mapsto \log(1 + e^u)$ 凸且单调递增, 而 $-y_i w^\top x_i$ 关于 w 仿射, 因此每个样本损失凸; 非负加权和与二次正则化保持凸性。

当 $\lambda > 0$ 时, 正则项使目标强凸, 但若模型中存在未正则化的截距或特征矩阵退化, 仍需检查整体变量上的强凸性。

任务结构	常见凸模型	关键变换
------	-------	------

9.9 模型识别速查

任务结构	常见凸模型	关键变换
控制最坏误差	线性规划	ℓ_∞ 上境图
平方拟合	最小二乘 / QP	展开二次型
鲁棒绝对误差	线性规划	引入绝对值上界变量
参数收缩	Ridge	加 ℓ_2^2 正则
稀疏参数	Lasso	加 ℓ_1 正则
最近可行点	投影问题	二次目标 + 凸约束
最大间隔分类	SVM / QP	归一化函数间隔
概率分类	Logistic 回归	log-sum-exp 原子
Euclidean 范数约束	SOCP	仿射映射进入二阶锥
线性矩阵与谱约束	SDP	仿射映射进入半正定锥

LP、SOCP 与 SDP 的统一锥形式、对偶和 Slater 条件见 附录 B。

9.10 典型误区

1. 使用范数的模型一定是二次规划。 ℓ_1 、 ℓ_∞ 常转为线性规划， ℓ_2 范数约束常对应二阶锥结构。
2. 正则化形式与约束形式对任意 λ, τ 都等价。两者参数需要通过最优乘子或解路径对应。
3. Ridge 的闭式表达意味着应显式求逆。数值计算通常应解线性系统。
4. 所有训练样本都同等决定 SVM 超平面。KKT 表明只有正乘子的支持向量直接进入 w 。
5. 加上二次正则项必然让所有变量强凸。未正则化方向仍可能破坏强凸性。

9.11 本章小结

线性规划、二次规划和范数逼近是许多应用的标准骨架；辅助变量可以把最大值和绝对值转为线性约束；正则化与约束形式表达拟合和复杂度之间的权衡；投影把几何最近点问题变成强凸优化；SVM 的 KKT 与对偶则说明支持向量为何足以决定分隔超平面。实际建模时，优先识别这些结构，而不是从零开始设计新问题。

A 数学预备工具箱

本附录只收录正文反复使用的线性代数与微分工具。它的作用是统一记号和维度，而不是替代完整的线性代数或矩阵微积分课程。

A.1 内积与 Cauchy–Schwarz 不等式

Euclidean 内积定义为

$$\langle x, y \rangle = x^\top y.$$

对应范数为

$$\|x\|_2 = \sqrt{x^\top x}.$$

Cauchy–Schwarz 不等式为

$$|x^\top y| \leq \|x\|_2 \|y\|_2. \quad (\text{A.1})$$

等号成立当且仅当 x, y 线性相关。对非零向量,

$$\cos \theta = \frac{x^\top y}{\|x\|_2 \|y\|_2},$$

所以内积符号描述方向关系：

- $x^\top y > 0$: 夹角为锐角；
- $x^\top y = 0$: 两向量正交；
- $x^\top y < 0$: 夹角为钝角。

下降方向条件 $\nabla f(x)^\top d < 0$ 正是说搜索方向与梯度形成钝角。

A.1.1 矩阵内积

对同型矩阵 X, Y , Frobenius 内积为

$$\langle X, Y \rangle = \text{tr}(X^\top Y).$$

对应范数为

$$\|X\|_F = \sqrt{\text{tr}(X^\top X)} = \sqrt{\sum_{i,j} X_{ij}^2}.$$

这相当于把矩阵按元素展开成向量后使用 Euclidean 内积与范数。

A.2 向量范数

范数 $\|\cdot\|$ 满足:

1. 非负与正定: $\|x\| \geq 0$, 且等号仅当 $x = 0$;
2. 绝对齐次: $\|\alpha x\| = |\alpha| \|x\|$;
3. 三角不等式: $\|x + y\| \leq \|x\| + \|y\|$ 。

常用 ℓ_p 范数为

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad p \geq 1.$$

特别地,

$$\|x\|_1 = \sum_i |x_i|, \quad \|x\|_2 = \sqrt{\sum_i x_i^2}, \quad \|x\|_\infty = \max_i |x_i|.$$

有限维空间中的任意两个范数等价: 存在常数 $c, C > 0$ 使

$$c\|x\|_a \leq \|x\|_b \leq C\|x\|_a.$$

这里“等价”表示它们产生相同的收敛与连续性概念, 并不表示数值相同。

A.3 对偶范数与 Hölder 不等式

范数 $\|\cdot\|$ 的对偶范数定义为

$$\|y\|_{\star} = \sup_{\|x\| \leq 1} y^{\top} x.$$

由缩放可得广义 Hölder 不等式

$$|x^{\top} y| \leq \|x\| \|y\|_{\star}. \quad (\text{A.2})$$

ℓ_p 范数的对偶是 ℓ_q 范数，其中

$$\frac{1}{p} + \frac{1}{q} = 1.$$

因此：

$$(\ell_1)^{\star} = \ell_{\infty}, \quad (\ell_2)^{\star} = \ell_2, \quad (\ell_{\infty})^{\star} = \ell_1.$$

对偶范数在最速下降、鲁棒优化和范数共轭中反复出现。

A.4 矩阵算子范数

向量范数衡量向量的大小，算子范数则衡量线性映射最多能把向量放大多少倍。它是控制矩阵乘法、估计光滑常数和选择步长的常用工具。

A.4.1 输入与输出范数

设 $A \in \mathbb{R}^{m \times n}$ ，输入空间 $\mathbb{R}^n$ 使用范数 $\|\cdot\|_b$ ，输出空间 $\mathbb{R}^m$ 使用范数 $\|\cdot\|_a$ 。由这两个范数诱导的算子范数定义为

$$\|A\|_{b \rightarrow a} = \sup_{x \neq 0} \frac{\|Ax\|_a}{\|x\|_b} = \sup_{\|x\|_b \leq 1} \|Ax\|_a.$$

箭头表示“输入范数 $\rightarrow$ 输出范数”。两个表达式等价，因为任意非零 x 都可以归一化为 $x/\|x\|_b$ 。

由定义，对所有 x 都有

$$\|Ax\|_a \leq \|A\|_{b \rightarrow a} \|x\|_b.$$

若输入与输出都使用 ℓ_p 范数，通常简写为 $\|A\|_p = \|A\|_{p \rightarrow p}$ 。当上下文没有明确指定范数时，不能把不同的算子范数混用。

A.4.2 谱范数：Euclidean 长度的最大放大倍数

输入与输出都使用 ℓ_2 范数时，得到谱范数：

$$\|A\|_2 = \sup_{\|x\|_2=1} \|Ax\|_2.$$

将长度平方后，

$$\begin{aligned}\|A\|_2^2 &= \sup_{\|x\|_2=1} \|Ax\|_2^2 \\ &= \sup_{\|x\|_2=1} x^\top A^\top A x \\ &= \lambda_{\max}(A^\top A).\end{aligned}$$

最后一步使用对称矩阵的 Rayleigh 商结论：单位向量上的二次型最大值等于最大特征值，并在相应的单位特征向量处取到。

由于 A 的奇异值是 $A^\top A$ 特征值的非负平方根，

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^\top A)} = \sigma_{\max}(A).$$

因此，最大的右奇异向量给出被 A 放大最多的输入方向，最大奇异值给出这个方向上的放大倍数。

A.4.3 常用公式与记号边界

算子范数	计算公式
$\ A\ _1$	$\max_{1 \leq j \leq n} \sum_{i=1}^m A_{ij} $, 最大绝对列和
$\ A\ _2$	$\sigma_{\max}(A)$, 最大奇异值
$\ A\ _\infty$	$\max_{1 \leq i \leq m} \sum_{j=1}^n A_{ij} $, 最大绝对行和

这里的矩阵 ℓ_1 算子范数不是所有元素绝对值之和；谱范数也不是 Frobenius 范数：

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2} = \sqrt{\sum_k \sigma_k(A)^2}.$$

谱范数关注最大放大方向，Frobenius 范数则汇总所有奇异方向的平方大小。

算子范数与对偶范数也不是同一个概念：前者衡量线性映射的放大能力，后者衡量线性函数在单位球上的最大值。

A.4.4 应用：最小二乘的光滑常数

考虑

$$F(x) = \frac{1}{2} \|Ax - b\|_2^2.$$

其梯度与 Hessian 为

$$\nabla F(x) = A^\top (Ax - b), \quad \nabla^2 F(x) = A^\top A.$$

对任意 x, z ,

$$\begin{aligned} \|\nabla F(x) - \nabla F(z)\|_2 &= \|A^\top A(x - z)\|_2 \\ &\leq \|A^\top A\|_2 \|x - z\|_2 \\ &= \|A\|_2^2 \|x - z\|_2. \end{aligned}$$

因此可取梯度的 Lipschitz 常数

$$L = \|A\|_2^2 = \lambda_{\max}(A^\top A).$$

这解释了谱范数如何进入优化算法：它控制梯度变化的最快尺度。当 $A \neq 0$ 时，梯度下降常用固定步长

$$\eta = \frac{1}{\|A\|_2^2}.$$

若目标写成 $\|Ax - b\|_2^2$ ，没有前面的 $1/2$ ，则对应的光滑常数变为 $2\|A\|_2^2$ 。使用步长公式前，应先核对目标函数的系数。

A.5 谱范数与核范数的对偶

矩阵优化不仅关心线性映射的最大放大倍数，也关心矩阵在多少个方向上具有显著作用。谱范数与核范数分别从不同角度描述奇异值，并在矩阵内积下互为对偶。

A.5.1 三种常用矩阵范数

设 $X \in \mathbb{R}^{m \times n}$ ，其奇异值为 $\sigma_1(X) \geq \dots \geq \sigma_k(X) \geq 0$ ，其中 $k = \min\{m, n\}$ 。

范数	定义	含义
谱范数	$\ X\ _2 = \sigma_1(X)$	最大方向上的放大倍数
核范数	$\ X\ _{\text{nuc}} = \sum_{i=1}^k \sigma_i(X)$	所有奇异值的总量

范数	定义	含义
Frobenius 范数	$\ X\ _F = \sqrt{\sum_{i=1}^k \sigma_i(X)^2}$	所有奇异值的平方和开方

核范数也称迹范数。文献常将它记为 $\|X\|_*$ ；为避免与一般对偶范数的下标 $*$ 混淆，本书使用 $\|X\|_{\text{nuc}}$ 。

只有当 X 为对称半正定矩阵时，才可以直接写成

$$\|X\|_{\text{nuc}} = \text{tr}(X).$$

一般矩阵的核范数不能用主对角线元素之和计算。

A.5.2 矩阵空间中的对偶范数

矩阵空间采用 Frobenius 内积

$$\langle X, Y \rangle = \text{tr}(X^\top Y).$$

给定矩阵范数 N ，其对偶范数定义为

$$N_*(Y) = \sup_{N(X) \leq 1} \langle X, Y \rangle.$$

在这个内积下，谱范数与核范数互为对偶：

$$\sup_{\|X\|_2 \leq 1} \langle X, Y \rangle = \|Y\|_{\text{nuc}},$$

$$\sup_{\|X\|_{\text{nuc}} \leq 1} \langle X, Y \rangle = \|Y\|_2.$$

相应的 Hölder 不等式为

$$|\langle X, Y \rangle| \leq \|X\|_2 \|Y\|_{\text{nuc}}$$

以及交换两个矩阵后得到的

$$|\langle X, Y \rangle| \leq \|X\|_{\text{nuc}} \|Y\|_2.$$

A.5.3 关键证明：用 SVD 找到达到上界的矩阵

先证明谱范数的对偶是核范数。

设 $Y \neq 0$ ，秩为 r ，其紧致 SVD 写成

$$Y = \sum_{i=1}^r \sigma_i u_i v_i^\top,$$

其中 $\sigma_i > 0$ ， $\{u_i\}$ 与 $\{v_i\}$ 分别是正交归一向量组。

对任意 $\|X\|_2 \leq 1$ ，

$$\begin{aligned} |\langle X, Y \rangle| &= \left| \sum_{i=1}^r \sigma_i u_i^\top X v_i \right| \\ &\leq \sum_{i=1}^r \sigma_i |u_i^\top X v_i| \\ &\leq \sum_{i=1}^r \sigma_i \|u_i\|_2 \|X v_i\|_2 \\ &\leq \sum_{i=1}^r \sigma_i \|X\|_2 \\ &\leq \sum_{i=1}^r \sigma_i = \|Y\|_{\text{nuc}}. \end{aligned}$$

这里依次使用了三角不等式、Cauchy–Schwarz 不等式，以及谱范数控制长度放大的性质。

为了证明这个上界可以达到，取

$$X_0 = \sum_{i=1}^r u_i v_i^\top.$$

它把每个 v_i 映到对应的 u_i ，并把这些 v_i 张成空间的正交补映到零，所以 $\|X_0\|_2 = 1$ 。此时

$$\langle X_0, Y \rangle = \sum_{i=1}^r \sigma_i = \|Y\|_{\text{nuc}}.$$

因此谱范数单位球上的上确界恰好等于核范数。

再证明反方向。由上面得到的不等式交换 X, Y ，对于 $\|X\|_{\text{nuc}} \leq 1$ ，

$$\langle X, Y \rangle \leq \|X\|_{\text{nuc}} \|Y\|_2 \leq \|Y\|_2.$$

取对应最大奇异值的秩一矩阵

$$X_1 = u_1 v_1^\top.$$

它只有一个非零奇异值，且该奇异值为 1，所以

$$\|X_1\|_{\text{nuc}} = 1, \quad \langle X_1, Y \rangle = \sigma_1(Y) = \|Y\|_2.$$

上界再次取到，故核范数的对偶是谱范数。当 $Y = 0$ 时，两个结论均直接成立。

A.5.4 为什么核范数用于低秩优化

矩阵的秩统计非零奇异值的个数，而核范数累加奇异值的大小。因此，核范数惩罚相当于对奇异值向量施加 ℓ_1 惩罚，常被用作秩惩罚的凸替代，以鼓励低秩结构。

谱范数与核范数的对偶关系又说明：核范数目标在共轭与对偶推导中，会自然对应谱范数单位球约束。

不过，使用核范数并不自动保证指定的秩，也不自动保证恢复真实低秩矩阵；这些结论还需要观测模型与问题结构的额外条件。

A.5.5 与向量 Euclidean 范数的区别

向量的 ℓ_2 范数是自对偶的，但矩阵谱范数不是。矩阵空间中自对偶的是 Frobenius 范数：

$$\sup_{\|X\|_F \leq 1} \langle X, Y \rangle = \|Y\|_F.$$

原因是 Frobenius 内积与范数等价于把矩阵按元素展开后，使用向量的 Euclidean 内积与范数。不能仅因谱范数也记作 $\|\cdot\|_2$ ，就把向量 ℓ_2 范数的自对偶结论直接搬过来。

A.6 向量、矩阵与张量求导

优化问题最终通常以标量目标为中心，但中间计算可能在向量、矩阵甚至更高阶张量之间传递。本节统一三件事：导数表示什么线性映射，梯度为什么与变量同形，以及链式法则如何在不显式构造高阶导数张量的情况下完成反向传播。

A.6.1 Jacobian、梯度与方向导数

设

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

若存在矩阵 $Df(x) \in \mathbb{R}^{m \times n}$ 使

$$f(x+h) = f(x) + Df(x)h + o(\|h\|_2),$$

则 $Df(x)$ 是 f 在 x 处的导数，也称 Jacobian：

$$[Df(x)]_{ij} = \frac{\partial f_i(x)}{\partial x_j}. \tag{A.3}$$

本书固定采用“输出维度为行、输入维度为列”的约定，因此

$$Df(x) \in \mathbb{R}^{m \times n}.$$

不同资料可能使用转置约定，引用公式前必须先检查维度，不能只凭符号名称判断。

沿方向 $v \in \mathbb{R}^n$ 的方向导数为

$$Df(x)[v] = \lim_{t \rightarrow 0} \frac{f(x + tv) - f(x)}{t} = Df(x)v.$$

当 $m = 1$ 时， $Df(x)$ 是 $1 \times n$ 行向量。本书把梯度定义为列向量

$$\nabla f(x) = Df(x)^\top \in \mathbb{R}^n,$$

于是

$$Df(x)[v] = \nabla f(x)^\top v, \tag{A.4}$$

并且一阶展开写为

$$f(x + h) = f(x) + \nabla f(x)^\top h + o(\|h\|_2).$$

这里梯度不是抽象导数本身，而是借助 Euclidean 内积表示标量导数这个线性泛函后得到的向量。这一区分在换用非 Euclidean 几何时尤其重要。

A.6.2 矩阵变量与 Frobenius 配对

设

$$f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}.$$

矩阵梯度 $\nabla_X f(X) \in \mathbb{R}^{m \times n}$ 由下式定义：

$$f(X + H) = f(X) + \langle \nabla_X f(X), H \rangle_F + o(\|H\|_F), \tag{A.5}$$

其中

$$\langle A, B \rangle_F = \text{tr}(A^\top B).$$

在标准坐标下，这一定义等价于

$$[\nabla_X f(X)]_{ij} = \frac{\partial f(X)}{\partial X_{ij}}.$$

等价地，微分满足

$$df(X)[H] = \text{tr}([\nabla_X f(X)]^\top H). \quad (\text{A.6})$$

这解释了“梯度与参数同形”：导数 $df(X)$ 是作用在扰动 H 上的线性泛函，而 Frobenius 内积把这个线性泛函唯一表示为一个与 X 同型的矩阵。

A.6.3 用微分计算矩阵梯度

逐元素求偏导通常容易丢失转置。更稳健的方法是：

1. 先计算标量目标的微分 df ;
2. 利用迹的恒等式把它整理成 $\text{tr}(G^\top dX)$;
3. 由式 A.6 读出 $\nabla_X f = G$ 。

常用微分规则为

$$d(A + B) = dA + dB,$$

$$d(AB) = (dA)B + A(dB),$$

$$d(X^\top) = (dX)^\top,$$

$$d \text{tr}(X) = \text{tr}(dX).$$

若 X 可逆，则

$$d(X^{-1}) = -X^{-1}(dX)X^{-1}. \quad (\text{A.7})$$

该式可由 $XX^{-1} = I$ 直接推出：

$$0 = d(XX^{-1}) = (dX)X^{-1} + X d(X^{-1}).$$

迹的循环不变性

$$\text{tr}(ABC) = \text{tr}(BCA) = \text{tr}(CAB)$$

允许把 dX 移到便于识别梯度的位置，但只能循环换位，不能任意交换矩阵顺序。

A.6.4 高频向量梯度

设 $x \in \mathbb{R}^n$ 。以下公式应当能够从微分或一阶展开独立推出，而不只是背诵。

标量函数	梯度	条件或说明
$a^\top x$	a	$a \in \mathbb{R}^n$
$\frac{1}{2}\ x\ _2^2$	x	Euclidean 几何
$\frac{1}{2}x^\top Qx$	$\frac{1}{2}(Q + Q^\top)x$	若 Q 对称, 则为 Qx
$\frac{1}{2}\ Ax - b\ _2^2$	$A^\top(Ax - b)$	Hessian 为 $A^\top A$
$\log \sum_i e^{x_i}$	p	$p_i = e^{x_i} / \sum_j e^{x_j}$

以最小二乘为例，令 $r = Ax - b$ ，则

$$df = r^\top dr = r^\top A dx = [A^\top(Ax - b)]^\top dx,$$

所以

$$\nabla_x \frac{1}{2}\|Ax - b\|_2^2 = A^\top(Ax - b). \quad (\text{A.8})$$

A.6.5 高频矩阵梯度

设 $X \in \mathbb{R}^{m \times n}$ 。常用公式包括：

$$\nabla_X \langle C, X \rangle_F = C,$$

$$\nabla_X \frac{1}{2}\|X\|_F^2 = X,$$

$$\nabla_X \frac{1}{2}\|AX - B\|_F^2 = A^\top(AX - B), \quad (\text{A.9})$$

其中 $A \in \mathbb{R}^{p \times m}$ 、 $B \in \mathbb{R}^{p \times n}$ 。类似地, 若 $A \in \mathbb{R}^{n \times q}$ 、 $B \in \mathbb{R}^{m \times q}$, 则

$$\nabla_X \frac{1}{2} \|XA - B\|_F^2 = (XA - B)A^\top. \quad (\text{A.10})$$

例如, 对式 (A.9), 令 $R = AX - B$, 则

$$\begin{aligned} df &= \langle R, dR \rangle_F \\ &= \text{tr}(R^\top A dX) \\ &= \text{tr}([A^\top R]^\top dX), \end{aligned}$$

从而读出 $\nabla_X f = A^\top R$ 。

对 $X \in \mathbb{S}_{++}^n$, 还有

$$d \log \det X = \text{tr}(X^{-1} dX),$$

因此

$$\nabla_X \log \det X = X^{-1}. \quad (\text{A.11})$$

若不假设 X 对称, 则对应梯度写作 $X^{-\top}$ 。在凸优化中通常在正定锥 $\mathbb{S}_{++}^n$ 上使用 $-\log \det X$ 作为障碍函数。

A.6.6 链式法则与反向传播

若 $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $f: \mathbb{R}^m \rightarrow \mathbb{R}^p$, 则

$$D(f \circ g)(x) = Df(g(x))Dg(x). \quad (\text{A.12})$$

若最终输出为标量 $L(x) = \ell(g(x))$, 则

$$\nabla_x L(x) = Dg(x)^\top \nabla \ell(g(x)). \quad (\text{A.13})$$

这就是反向传播的基本形式: 从后续标量损失得到上游梯度, 再乘当前映射 Jacobian 的转置。

对矩阵仿射映射

$$Y = AXB + C,$$

令

$$A \in \mathbb{R}^{p \times m}, \quad X \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{n \times q}, \quad C, Y \in \mathbb{R}^{p \times q}.$$

设 $G = \nabla_Y L \in \mathbb{R}^{p \times q}$, 则

$$dL = \langle G, A(dX)B \rangle_F = \langle A^\top G B^\top, dX \rangle_F,$$

因此

$$\nabla_X L = A^\top G B^\top. \quad (\text{A.14})$$

这个公式比显式构造“矩阵对矩阵”的四阶导数更实用。

再看机器学习中的仿射层。设

$$y = W^\top x + b,$$

其中

$$W \in \mathbb{R}^{n \times m}, \quad x \in \mathbb{R}^n, \quad b, y \in \mathbb{R}^m.$$

若 $u = \nabla_y L \in \mathbb{R}^m$, 则

$$\nabla_x L = W u, \quad \nabla_W L = x u^\top, \quad \nabla_b L = u. \quad (\text{A.15})$$

严格来说, y 对 W 的导数是三阶张量; 但标量损失传回的 u 会与该张量缩并, 直接得到同形矩阵 $\nabla_W L$ 。实际计算通常只需要这个向量—Jacobian 乘积。

A.6.7 向量、矩阵与张量输出

若

$$F : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q},$$

逐元素记录导数需要四阶数组

$$[D_X F(X)]_{ij,kl} = \frac{\partial F_{ij}(X)}{\partial X_{kl}}. \quad (\text{A.16})$$

更一般地， k 阶张量输入到 l 阶张量输出的逐元素导数具有 $k + l$ 个指标。这里更适合称它为导数张量或 Jacobian 张量；“梯度与变量同形”只针对标量输出。

也可以先向量化：

$$\text{vec}(F(X)) \in \mathbb{R}^{pq}, \quad \text{vec}(X) \in \mathbb{R}^{mn},$$

于是普通 Jacobian 的尺寸为

$$\frac{\partial \text{vec}(F(X))}{\partial \text{vec}(X)} \in \mathbb{R}^{pq \times mn}.$$

向量化顺序必须预先约定，否则同一个导数会得到不同的矩阵排列。理论推导中，直接把 $DF(X)$ 看作从扰动 H 到输出扰动 $DF(X)[H]$ 的线性映射，通常更不容易混淆。

自动微分也很少显式生成完整 Jacobian，而是计算：

$$\underbrace{Df(x)v}_{\text{Jacobian-vector product, JVP}}, \quad \underbrace{Df(x)^\top u}_{\text{vector-Jacobian product, VJP}}.$$

前向模式自然计算 JVP，反向模式自然计算 VJP。标量损失对大量参数求梯度时，反向模式避免了存储巨大的高阶导数张量。

A.6.8 求导检查清单

1. 先写清输入、输出与每个矩阵的尺寸；
2. 标量对向量或矩阵求导才称为梯度，并与变量同形；
3. 向量输出对应 Jacobian，矩阵或张量输出对应线性映射或高阶导数张量；
4. 矩阵微分最终应整理成 $df = \text{tr}(G^\top dX)$ ；
5. 迹只能循环换位，矩阵乘积不能随意交换；
6. 链式法则中最常见的错误是漏掉转置；
7. 涉及逆矩阵、对数行列式时，必须同时写明可逆性或正定性条件。

A.7 Hessian 与二阶方向信息

对二阶可微标量函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，Hessian 定义为

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}.$$

在二阶连续可微条件下，Hessian 对称。二阶展开为

$$f(x+h) = f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h + o(\|h\|_2^2).$$

沿方向 v 的二阶方向导数为

$$D^2 f(x)[v, v] = v^\top \nabla^2 f(x) v.$$

许多二阶算法只需要 Hessian-vector product

$$\nabla^2 f(x) v = \left. \frac{d}{dt} \nabla f(x + tv) \right|_{t=0}, \quad (\text{A.17})$$

而不必显式存储整个 Hessian。

若 $h(x) = f(Ax + b)$ ，则

$$\nabla^2 h(x) = A^\top \nabla^2 f(Ax + b) A.$$

这个公式同时解释了为什么仿射复合保持 Hessian 半正定。

对 log-sum-exp 函数

$$f(x) = \log \sum_{i=1}^n e^{x_i},$$

记 $p = \nabla f(x)$, 即 p 为 softmax 向量, 则

$$\nabla^2 f(x) = \text{Diag}(p) - pp^\top \succeq 0. \quad (\text{A.18})$$

该矩阵可以解释为类别指标向量的协方差矩阵, 因此天然半正定。实际使用时应理解它的结构与半正定性, 不必背诵更高阶张量形式或 $\log \det$ 的完整 Hessian。

A.8 正定与半正定矩阵

对称矩阵 $P \in \mathbb{S}^n$:

$$P \succeq 0 \iff x^\top Px \geq 0, \quad \forall x,$$

$$P \succ 0 \iff x^\top Px > 0, \quad \forall x \neq 0.$$

等价地:

- $P \succeq 0$ 当且仅当所有特征值非负;
- $P \succ 0$ 当且仅当所有特征值为正。

若 $P \succeq 0$, 则存在平方根 $P^{1/2} \succeq 0$, 并且

$$x^\top Px = \|P^{1/2}x\|_2^2.$$

若

$$\mu I \preceq P \preceq LI,$$

则

$$\mu\|x\|_2^2 \leq x^\top Px \leq L\|x\|_2^2.$$

A.9 特征值分解、SVD 与伪逆

实对称矩阵可分解为

$$P = Q\Lambda Q^\top,$$

其中 Q 正交, Λ 为实对角矩阵。

任意矩阵 $A \in \mathbb{R}^{m \times n}$ 都有奇异值分解

$$A = U\Sigma V^\top.$$

若非零奇异值为 $\sigma_1, \dots, \sigma_r$, 则 Moore–Penrose 伪逆为

$$A^\dagger = V\Sigma^\dagger U^\top,$$

其中 $\Sigma^\dagger$ 将非零奇异值取倒数。

最小二乘的最小范数解可以统一写为

$$x^\star = A^\dagger b.$$

伪逆表达揭示了解的几何结构; 数值计算仍应使用稳定的分解算法。

A.10 Schur 补

考虑对称分块矩阵

$$M = \begin{bmatrix} A & B \\ B^\top & C \end{bmatrix}.$$

若 $A \succ 0$, 则

$$M \succeq 0 \iff C - B^\top A^{-1} B \succeq 0. \quad (\text{A.19})$$

$C - B^\top A^{-1} B$ 称为关于 A 的 Schur 补。

例如, 对 $t > 0$,

$$x^\top A^{-1} x \leq t$$

等价于线性矩阵不等式

$$\begin{bmatrix} A & x \\ x^\top & t \end{bmatrix} \succeq 0, \quad A \succ 0.$$

Schur 补常用于把含逆矩阵的约束改写为半正定约束。

A.11 维度检查清单

1. 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 则 $Df(x) \in \mathbb{R}^{m \times n}$;
2. 标量梯度 $\nabla f(x)$ 与变量 x 同维, 且按列向量记;
3. 矩阵梯度 $\nabla_X f(X)$ 与矩阵变量 X 同形;
4. 标量一阶项分别写成 $\nabla f(x)^\top (y - x)$ 或 $\langle \nabla_X f(X), Y - X \rangle_F$;
5. 若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 则 Hessian 是 $n \times n$ 矩阵;
6. 若 $A \in \mathbb{R}^{m \times n}$, 则 $Ax \in \mathbb{R}^m$, 反向链式法则会出现 $A^\top$;
7. 二次型 $x^\top P x$ 要求 P 的尺寸与 x 匹配, 且只需考虑其对称部分;
8. 任何包含逆矩阵或 $\log \det$ 的公式都必须同时检查定义域。

A.12 本附录小结

内积与对偶范数控制线性项, Jacobian、梯度和 Hessian 描述局部变化, 矩阵微分与 Frobenius 配对把高阶求导转化为可读的同形梯度, JVP、VJP 和 Hessian–vector product 则避免显式存储巨大的导数张量。正定矩阵与特征值描述二次曲率, SVD 和伪逆处理退化线性系统, Schur 补在二次形式与矩阵不等式之间转换。这些工具贯穿凸性判定、对偶推导、反向传播与算法收敛分析。

B 广义不等式与锥规划

标量不等式 $x_i \geq 0$ 、二阶锥约束 $\|u\|_2 \leq t$ 和矩阵不等式 $X \succeq 0$ 表面上属于不同模型，实际上都可以写成“某个向量属于一个凸锥”。锥语言把线性规划、二阶锥规划和半定规划放进同一套可行性、对偶与 KKT 框架。

本附录只展开课程主线需要的锥结构。向量优化、几何规划和内点法属于 P2，不在这里延伸。

B.1 正常锥与广义不等式

设 $K \subseteq \mathbb{R}^n$ 为凸锥。若 K 同时满足：

1. **闭性**： K 包含其所有极限点；
2. **实心性**： $\text{int } K \neq \emptyset$ ；
3. **尖性**： $K \cap (-K) = \{0\}$ ，即 K 不包含直线；

则称 K 为正常锥。凸性与闭性保证良好的几何和极限性质；实心性使严格不等式有意义；尖性则保证反对称性。

由正常锥 K 定义广义不等式

$$x \preceq_K y \iff y - x \in K, \quad (\text{B.1})$$

以及严格广义不等式

$$x \prec_K y \iff y - x \in \text{int } K.$$

$\preceq_K$ 是偏序而不一定是全序。两个向量可能无法比较；这在半正定序中很常见。

B.1.1 三个基本例子

对非负正交锥 $K = \mathbb{R}_+^n$,

$$x \preceq_K y \iff x_i \leq y_i, \quad i = 1, \dots, n.$$

对二阶锥

$$Q^{n+1} = \{(u, t) \in \mathbb{R}^n \times \mathbb{R} \mid \|u\|_2 \leq t\}, \quad (\text{B.2})$$

锥成员关系同时编码一个范数上界和右端非负性。

对半正定锥 $K = \mathbb{S}_+^n$,

$$X \preceq_K Y \iff Y - X \succeq 0.$$

这里的矩阵不等式按特征值或二次型判断，不是逐元素比较。

B.2 对偶锥

锥 K 的对偶锥定义为

$$K^\star = \{y \mid \langle y, x \rangle \geq 0, \forall x \in K\}. \quad (\text{B.3})$$

对偶锥收集所有在 K 上非负的线性函数。几何上， $y \in K^\star$ 当且仅当法向量为 y 的超平面在原点支撑 K ，并把 K 保留在非负一侧。

无论 K 是否凸， $K^\star$ 都是闭凸锥，因为它是半空间

$$\{y \mid y^\top x \geq 0\}$$

对所有 $x \in K$ 的交。

常用性质为

$$K_1 \subseteq K_2 \implies K_2^\star \subseteq K_1^\star,$$

以及

$$K^{\star\star} = \text{cl}(\text{cone } K).$$

特别地, 若 K 已是闭凸锥, 则

$$K^{**} = K.$$

正常锥的对偶锥仍为正常锥。

B.2.1 自对偶锥

若 $K^* = K$, 则称 K 自对偶。非负正交锥满足

$$(\mathbb{R}_+^n)^* = \mathbb{R}_+^n.$$

二阶锥也自对偶: 若 $(v, s) \in \mathcal{Q}^{n+1}$, 则对任意 $(u, t) \in \mathcal{Q}^{n+1}$,

$$v^\top u + st \geq -\|v\|_2 \|u\|_2 + st \geq 0.$$

反向包含可通过选择与 v 反向的边界向量得到。

在矩阵空间 $\mathbb{S}^n$ 中使用 Frobenius 内积

$$\langle X, Y \rangle = \text{tr}(XY).$$

半正定锥满足

$$(\mathbb{S}_+^n)^* = \mathbb{S}_+^n.$$

若 $X, Y \succeq 0$, 则

$$\text{tr}(XY) = \text{tr}(X^{1/2}YX^{1/2}) \geq 0.$$

反之, 若 Y 在方向 v 上有 $v^\top Y v < 0$, 取 $X = vv^\top \succeq 0$ 即违反对偶锥定义。

B.2.2 广义不等式的对偶刻画

对闭凸锥 K ,

$$x \preceq_K y \iff \lambda^\top x \leq \lambda^\top y, \quad \forall \lambda \in K^*. \quad (\text{B.4})$$

正向由对偶锥定义立即得到; 反向使用 $K^{**} = K$ 。这说明一个向量广义不等式等价于对所有对偶非负方向同时成立的一族标量不等式。

B.3 关于锥的凸映射

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的定义域为凸集, $K \subseteq \mathbb{R}^m$ 为正常锥。若对任意 $x, y \in \text{dom } f$ 和 $\theta \in [0, 1]$,

$$f(\theta x + (1 - \theta)y) \preceq_K \theta f(x) + (1 - \theta)f(y), \quad (\text{B.5})$$

则称 f 为 K -凸映射。

由式 式 B.4, f 为 K -凸当且仅当对每个

$$\lambda \in K^*,$$

标量函数

$$x \mapsto \lambda^\top f(x)$$

都是凸函数。这个标量化结论是把普通凸分析迁移到向量值约束的主要接口。

考虑问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m, \\ & && Ax = b. \end{aligned} \quad (\text{B.6})$$

若 f_0 凸、每个 f_i 为 K_i -凸映射且等式约束仿射, 则可行域为凸集。证明只需把两个可行点代入式 式 B.5, 并利用 $-K_i$ 的凸性。

B.4 锥规划标准形式

锥规划把线性规划中的逐分量非负约束替换为一般锥成员关系:

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && Ax = b, \\ & && x \succeq_K 0. \end{aligned} \quad (\text{B.7})$$

其中 K 为闭凸锥。目标与等式约束保持线性, 所有非线性几何都集中在 $x \in K$ 。

很多模型最初写成仿射锥约束

$$Fx + g \in K.$$

通过引入变量 $z = Fx + g$, 可以转为式 式 B.7 的标准形式。标准化的目的不是制造更多变量, 而是让对偶与算法只需识别锥 K 。

B.5 锥规划对偶

对式 式 B.7, 引入等式乘子 y , 并把 $x \in K$ 保留为取下确界时的定义域。Lagrangian 为

$$L(x, y) = c^\top x + y^\top (b - Ax) = b^\top y + (c - A^\top y)^\top x.$$

记

$$s = c - A^\top y.$$

若 $s \in K^*$, 则

$$\inf_{x \in K} s^\top x = 0,$$

并在 $x = 0$ 处取得。若 $s \notin K^*$, 则存在 $x \in K$ 使 $s^\top x < 0$; 利用锥的正比例封闭性可令下确界为 $-\infty$ 。

因此对偶问题为

$$\begin{aligned} & \text{maximize} && b^\top y \\ & \text{subject to} && c - A^\top y = s, \\ & && s \succeq_{K^*} 0. \end{aligned} \tag{B.8}$$

s 称为对偶松弛变量。

对任意原始可行 x 和对偶可行 (y, s) ,

$$\begin{aligned} c^\top x - b^\top y &= (A^\top y + s)^\top x - b^\top y \\ &= s^\top x \\ &\geq 0. \end{aligned} \tag{B.9}$$

这就是锥规划的弱对偶。对偶间隙恰好是两个互为对偶锥的变量之间的内积。

B.6 锥 Slater 条件与 KKT

若存在严格原始可行点

$$\tilde{x} \in \text{int } K, \quad A\tilde{x} = b, \quad (\text{B.10})$$

则称原问题满足锥形式的 Slater 条件。在原问题最优值有限等常用条件下，它保证强对偶，并保证对偶最优解能够取到。

若 (x^*, y^*, s^*) 为原始—对偶最优点且强对偶成立，则由式 式 B.9,

$$\langle s^*, x^* \rangle = 0. \quad (\text{B.11})$$

锥规划 KKT 条件为:

1. 原始可行性

$$Ax^* = b, \quad x^* \in K;$$

2. 对偶可行性

$$A^\top y^* + s^* = c, \quad s^* \in K^*;$$

3. 锥互补性

$$\langle s^*, x^* \rangle = 0.$$

对锥线性规划，任何满足这三组条件的点都是原始—对偶最优点；Slater 条件主要用于保证最优解能够配上这样的对偶变量。

B.6.1 广义不等式约束的 KKT

对式 式 B.6, 引入

$$\lambda_i \in K_i^*,$$

Lagrangian 为

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \langle \lambda_i, f_i(x) \rangle + \nu^\top (Ax - b). \quad (\text{B.12})$$

若 $f_i(x) \preceq_{K_i} 0$ 且 $\lambda_i \in K_i^*$, 则

$$\langle \lambda_i, f_i(x) \rangle \leq 0,$$

所以普通弱对偶推导保持不变。

若所有函数可微, KKT 条件中的互补性与驻点条件分别变为

$$\langle \lambda_i^*, f_i(x^*) \rangle = 0,$$

以及

$$\nabla f_0(x^*) + \sum_{i=1}^m Df_i(x^*)^\top \lambda_i^* + A^\top \nu^* = 0. \quad (\text{B.13})$$

这里

$$Df_i(x^*)^\top \in \mathbb{R}^{n \times k_i}, \quad \lambda_i^* \in \mathbb{R}^{k_i},$$

所以每一项都属于 $\mathbb{R}^n$ 。广义 Slater 条件要求存在 $\tilde{x}$ 使

$$f_i(\tilde{x}) \prec_{K_i} 0, \quad A\tilde{x} = b.$$

B.7 线性规划作为锥规划

在线性规划标准形式中取

$$K = \mathbb{R}_+^n.$$

原问题为

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && Ax = b, \\ & && x \geq 0, \end{aligned}$$

由于 $K^* = K$, 对偶为

$$\begin{aligned} & \text{maximize} && b^\top y \\ & \text{subject to} && A^\top y + s = c, \\ & && s \geq 0. \end{aligned}$$

消去 s 可写为

$$A^\top y \leq c.$$

逐坐标互补性

$$x_i^* s_i^* = 0$$

正是一般锥互补条件 $\langle x^*, s^* \rangle = 0$ 在非负正交锥中的展开。

B.8 二阶锥规划

二阶锥规划的典型形式为

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && \|A_i x + b_i\|_2 \leq d_i^\top x + e_i, \quad i = 1, \dots, m, \\ & && Fx = g. \end{aligned} \tag{B.14}$$

每个范数约束等价于

$$(A_i x + b_i, d_i^\top x + e_i) \in \mathcal{Q}.$$

因此它是仿射映射到二阶锥的成员约束。右端非负不需要另写，因为二阶锥成员关系已经蕴含

$$d_i^\top x + e_i \geq 0.$$

SOCP 能表示范数逼近、鲁棒线性约束、最小 Euclidean 范数和许多凸二次约束；其表达能力严格强于 LP，同时保留成熟的锥对偶结构。

B.8.1 旋转二阶锥

旋转二阶锥定义为

$$\mathcal{Q}_r^{n+2} = \{(u, v, w) \mid 2uv \geq \|w\|_2^2, u \geq 0, v \geq 0\}.$$

若 $P \succeq 0$ ，二次上境约束

$$x^\top P x \leq t$$

可以写为

$$\left(t, \frac{1}{2}, P^{1/2}x\right) \in \mathcal{Q}_r.$$

旋转二阶锥是把凸二次函数转为锥约束的常用接口。

B.9 半定规划

半定规划使用半正定锥。一个线性矩阵不等式形式为

$$\begin{aligned} & \text{minimize} && c^\top x \\ & \text{subject to} && F_0 + \sum_{i=1}^n x_i F_i \succeq 0, \\ & && Ax = b, \end{aligned} \tag{B.15}$$

其中 $F_i \in \mathbb{S}^m$ 。若所有 F_i 都是对角矩阵，矩阵不等式退化为一组线性不等式，因此 LP 是 SDP 的特殊情形。

以矩阵 $X \in \mathbb{S}^n$ 为变量的标准形式为

$$\begin{aligned} & \text{minimize} && \langle C, X \rangle \\ & \text{subject to} && \langle A_i, X \rangle = b_i, \quad i = 1, \dots, p, \\ & && X \succeq 0. \end{aligned} \tag{B.16}$$

由半正定锥自对偶，其对偶问题为

$$\begin{aligned} & \text{maximize} && b^\top y \\ & \text{subject to} && C - \sum_{i=1}^p y_i A_i = S, \\ & && S \succeq 0. \end{aligned} \tag{B.17}$$

互补性为

$$\langle X^*, S^* \rangle = 0.$$

由于 $X^*, S^* \succeq 0$ ，这进一步意味着

$$X^* S^* = 0.$$

两者的非零特征子空间彼此正交。

B.9.1 谱范数的 LMI 表示

对矩阵 M ，约束

$$\|M\|_2 \leq t$$

等价于

$$\begin{bmatrix} tI & M \\ M^\top & tI \end{bmatrix} \succeq 0. \tag{B.18}$$

这一等价关系可以由 Schur 补得到。若 $M = M(x)$ 关于变量仿射，则最小化谱范数可以写成 SDP。

B.10 三类锥规划的统一视角

模型	基本锥 K	典型约束	对偶锥
LP	$\mathbb{R}_+^n$	分量线性不等式	自对偶
SOCP	$\mathcal{Q}^n$ 或 $\mathcal{Q}_r^n$	Euclidean 范数与凸二次约束	自对偶
SDP	$\mathbb{S}_+^n$	线性矩阵不等式、谱约束	自对偶

从 LP 到 SOCP 再到 SDP，表达能力逐步增强，但单次求解成本和建模复杂度通常也会上升。应优先使用能准确表达问题的最小锥：线性约束足够时不必升到 SDP，范数结构可由 SOCP 表达时也不必引入矩阵变量。

B.11 建模检查清单

1. 先判断约束是逐分量不等式、范数上界，还是矩阵半正定约束。
2. 明确锥所在的向量空间及其内积；矩阵空间使用 $\text{tr}(XY)$ 。
3. 统一不等式方向，再确定乘子属于 K^* 还是 $-K^*$ 。
4. 检查严格可行点是否位于 $\text{int } K$ ，同时精确满足仿射等式。
5. 若要使用 KKT，分别写出原始可行、对偶可行与锥互补性，不要只写驻点式。
6. 若同一模型可用多个锥表示，优先选择维度更小、结构更直接的形式。

B.12 典型误区

1. 广义不等式可以比较任意两个向量。它通常只给出偏序，很多向量不可比。
2. $X \succeq 0$ 表示矩阵元素都非负。它表示所有特征值非负，或 $z^\top X z \geq 0$ 对所有 z 成立。
3. 原锥中的变量与乘子属于同一个锥。一般乘子属于对偶锥；只有自对偶锥时二者形式相同。
4. 锥互补性要求 $x^* = 0$ 或 $s^* = 0$ 。它只要求内积为零，允许两者分别位于互相正交的边界面。
5. Slater 条件允许近似满足等式。严格性只用于锥不等式，仿射等式必须精确满足。
6. 任何凸二次约束都是线性规划。它通常需要二阶锥或半定锥表示。

B.13 本附录小结

正常锥把非负、范数和半正定三类结构统一为广义不等式；对偶锥把向量序转成一族标量线性不等式。锥标准形式的对偶松弛变量自然属于 K^* ，其对偶间隙等于 $\langle s, x \rangle$ ；Slater 条件与锥 KKT 则延续了第 5 章的强对偶和最优化证书。LP、SOCP 与 SDP 的区别主要在所选锥，而不是另起一套对偶理论。

C 进阶算法工具箱

本附录承接第 6–8 章的一阶方法主线，处理三个在机器学习中反复出现的问题：目标不可微、变量具有可分结构，以及约束或损失适合分块求解。内容按“最优性语言 $\rightarrow$ 复合算法 $\rightarrow$ 二阶算法 $\rightarrow$ 分裂算法”组织。

C.1 次梯度与次微分

梯度通过切平面给出可微凸函数的全局下界。不可微时，支撑超平面的斜率通常不唯一，次梯度把这些斜率全部保留下来。

设 $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ 为凸函数，且 $x \in \text{dom } f$ 。若向量 $g \in \mathbb{R}^n$ 满足

$$f(y) \geq f(x) + g^\top(y - x), \quad \forall y \in \mathbb{R}^n, \quad (\text{C.1})$$

则称 g 是 f 在 x 处的一个次梯度。所有次梯度组成次微分

$$\partial f(x) = \{g \mid f(y) \geq f(x) + g^\top(y - x), \forall y\}.$$

若 f 在 x 处可微，则

$$\partial f(x) = \{\nabla f(x)\}.$$

次微分不是一个数值导数，而是一个凸集。它描述在 x 处能够支撑函数上境图的全部斜率。

C.1.1 常用例子

绝对值函数的次微分为

$$\partial|x| = \begin{cases} \{-1\}, & x < 0, \\ [-1, 1], & x = 0, \\ \{1\}, & x > 0. \end{cases}$$

因此

$$\partial\|x\|_1 = \{g \in \mathbb{R}^n \mid g_i = \text{sign}(x_i) \text{ 若 } x_i \neq 0, \quad g_i \in [-1, 1] \text{ 若 } x_i = 0\}.$$

若

$$f(x) = \max_{i=1, \dots, m} f_i(x),$$

其中每个 f_i 凸且可微，记活跃指标集

$$I(x) = \{i \mid f_i(x) = f(x)\},$$

则

$$\partial f(x) = \text{conv}\{\nabla f_i(x) \mid i \in I(x)\}. \quad (\text{C.2})$$

最大值的拐角正是由多个活跃函数的梯度共同形成。

对非空闭凸集 C 的指示函数 I_C ，有

$$\partial I_C(x) = N_C(x), \quad x \in C,$$

其中

$$N_C(x) = \{g \mid g^\top(y - x) \leq 0, \quad \forall y \in C\}$$

称为 C 在 x 处的法锥。于是集合约束也可以进入统一的次微分语言。

C.1.2 最优性条件与运算法则

对正常凸函数 f ,

$$x^* \in \text{argmin } f \iff 0 \in \partial f(x^*). \quad (\text{C.3})$$

充分性直接来自式 (C.1); 必要性则取 $g = 0$, 因为最优点处 $f(y) \geq f(x^*)$ 。

常用运算法则包括:

$$\partial(\alpha f)(x) = \alpha \partial f(x), \quad \alpha > 0,$$

以及在适当的相对内部条件, 例如

$$\text{relint}(\text{dom } f) \cap \text{relint}(\text{dom } g) \neq \emptyset,$$

成立时,

$$\partial(f+g)(x) = \partial f(x) + \partial g(x).$$

若 f 为闭正常凸函数, 则 Fenchel–Young 等号条件可以写为

$$y \in \partial f(x) \iff f(x) + f^*(y) = x^\top y \iff x \in \partial f^*(y). \quad (\text{C.4})$$

这补全了第 5 章中共轭函数与斜率之间的关系。

C.2 次梯度法

考虑最小化凸函数 f 。在 x_k 处任选

$$g_k \in \partial f(x_k),$$

次梯度法更新为

$$x_{k+1} = x_k - \eta_k g_k. \quad (\text{C.5})$$

若还有非空闭凸约束集 C , 则使用投影次梯度法

$$x_{k+1} = \Pi_C(x_k - \eta_k g_k). \quad (\text{C.6})$$

次梯度不一定是下降方向, 所以 $f(x_{k+1})$ 可能高于 $f(x_k)$ 。算法保证来自长期距离递推, 而不是每一步都下降。

假设:

1. f 凸, 最优解 $x^* \in C$ 存在;
2. C 非空、闭、凸; 无约束时取 $C = \mathbb{R}^n$;
3. 沿迭代点有 $\|g_k\|_2 \leq G$;
4. $R = \|x_0 - x^*\|_2$ 。

由投影非扩张性与次梯度不等式,

$$\|x_{k+1} - x^*\|_2^2 \leq \|x_k - x^*\|_2^2 - 2\eta_k(f(x_k) - f(x^*)) + \eta_k^2 G^2.$$

求和后得到

$$\min_{0 \leq k < K} (f(x_k) - f(x^*)) \leq \frac{R^2 + G^2 \sum_{k=0}^{K-1} \eta_k^2}{2 \sum_{k=0}^{K-1} \eta_k}. \quad (\text{C.7})$$

若预先知道迭代轮数并取

$$\eta_k = \frac{R}{G\sqrt{K}},$$

则

$$\min_{0 \leq k < K} f(x_k) - f(x^*) \leq \frac{RG}{\sqrt{K}}.$$

也可以输出加权平均点。若采用递减步长, 典型充分条件是

$$\sum_{k=0}^{\infty} \eta_k = +\infty, \quad \sum_{k=0}^{\infty} \eta_k^2 < +\infty.$$

第一条防止总移动距离过早耗尽, 第二条抑制长期振荡。

C.3 近端算子

次梯度法把所有不可微结构都压缩成一个次梯度, 因此速率通常只有 $O(1/\sqrt{K})$ 。如果不可微项本身可以被精确最小化, 近端算子能保留更多结构。

设 g 为闭正常凸函数, $\eta > 0$ 。其近端算子定义为

$$\text{prox}_{\eta g}(v) = \underset{x}{\operatorname{argmin}} \left\{ g(x) + \frac{1}{2\eta} \|x - v\|_2^2 \right\}. \quad (\text{C.8})$$

二次项是强凸的, 因此极小点存在且唯一。令

$$x^+ = \text{prox}_{\eta g}(v),$$

一阶最优性条件为

$$0 \in \partial g(x^+) + \frac{1}{\eta}(x^+ - v),$$

等价于

$$\frac{v - x^+}{\eta} \in \partial g(x^+). \quad (\text{C.9})$$

近端映射不是简单地在 v 处取一个次梯度，而是寻找一个新点，使“结构代价”和“偏离 v 的距离”达到平衡。

C.3.1 三个高频近端映射

若 $g = I_C$ ，其中 C 非空闭凸，则

$$\text{prox}_{\eta I_C}(v) = \Pi_C(v).$$

因此投影是近端算子的特殊情形。

若 $g(x) = \lambda \|x\|_1$ ，则近端映射逐坐标软阈值化：

$$[\text{prox}_{\eta \lambda \|\cdot\|_1}(v)]_i = \text{sign}(v_i) \max\{|v_i| - \eta \lambda, 0\}. \quad (\text{C.10})$$

这说明 ℓ_1 正则化产生精确零值，不只是让坐标“变小”。

若 $g(x) = \lambda \|x\|_2$ ，则

$$\text{prox}_{\eta g}(v) = \left(1 - \frac{\eta \lambda}{\|v\|_2}\right)_+ v,$$

其中 $(a)_+ = \max\{a, 0\}$ 。它对整个向量做成组收缩，是 group lasso 中的基本操作。

C.3.2 稳定性与 Moreau 包络

近端算子满足坚定非扩张性。若

$$p = \text{prox}_{\eta g}(v), \quad q = \text{prox}_{\eta g}(w),$$

则

$$\|p - q\|_2^2 \leq (p - q)^\top (v - w). \quad (\text{C.11})$$

由 Cauchy–Schwarz 不等式可进一步得到普通非扩张性。

Moreau 包络定义为

$$e_{\eta g}(v) = \min_x \left\{ g(x) + \frac{1}{2\eta} \|x - v\|_2^2 \right\}.$$

即使 g 不可微, $e_{\eta g}$ 仍可微, 并且

$$\nabla e_{\eta g}(v) = \frac{1}{\eta} (v - \text{prox}_{\eta g}(v)).$$

近端点可以理解为对不可微函数进行局部平滑后的一次梯度校正。

C.4 近端梯度法

考虑复合问题

$$\min_x F(x) = f(x) + g(x), \quad (\text{C.12})$$

其中:

- f 凸、可微且 L -光滑;
- g 闭、正常、凸, 但允许不可微;
- 最优解 x^* 存在。

在 x_k 处保留 f 的一阶近似，并加入二次稳定项：

$$Q_\eta(z; x_k) = f(x_k) + \nabla f(x_k)^\top (z - x_k) + \frac{1}{2\eta} \|z - x_k\|_2^2 + g(z).$$

当 $0 < \eta \leq 1/L$ 时，光滑上界保证

$$F(z) \leq Q_\eta(z; x_k),$$

所以最小化这个上界得到

$$\begin{aligned} x_{k+1} &= \underset{z}{\operatorname{argmin}} Q_\eta(z; x_k) \\ &= \operatorname{prox}_{\eta g}(x_k - \eta \nabla f(x_k)). \end{aligned} \tag{C.13}$$

这一式统一了多种算法：

- $g = 0$ 时退化为梯度下降；
- $g = I_C$ 时退化为投影梯度；
- $g = \lambda \|\cdot\|_1$ 时得到迭代软阈值算法。

定义近端梯度映射

$$G_\eta(x) = \frac{1}{\eta} \left[x - \operatorname{prox}_{\eta g}(x - \eta \nabla f(x)) \right]. \tag{C.14}$$

则更新为 $x_{k+1} = x_k - \eta G_\eta(x_k)$ ，并且

$$G_\eta(x) = 0 \iff 0 \in \nabla f(x) + \partial g(x).$$

因此 $\|G_\eta(x)\|_2$ 是复合问题中替代梯度范数的停止指标。

在上述条件和 $0 < \eta \leq 1/L$ 下，

$$F(x_k) - F(x^\star) \leq \frac{\|x_0 - x^\star\|_2^2}{2\eta k}. \tag{C.15}$$

证明与投影梯度相同：近端子问题的一阶最优性条件产生单步距离望远镜界。若 f 进一步为 μ -强凸函数，基本近端梯度在固定步长下获得依赖 μ/L 的线性收敛。

C.5 加速梯度与 FISTA

基本梯度法和近端梯度法在一般凸情形下都是 $O(1/k)$ 。Nesterov 加速通过在当前点之外构造一个带惯性的外推点，把速率提升为 $O(1/k^2)$ 。

对式 C.12，取 $\eta = 1/L$ ，初始化

$$x_0 = y_0, \quad t_0 = 1.$$

FISTA 迭代为

$$\begin{aligned} x_{k+1} &= \text{prox}_{\eta g}(y_k - \eta \nabla f(y_k)), \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\ y_{k+1} &= x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k). \end{aligned} \tag{C.16}$$

在 f 凸且 L -光滑、 g 闭正常凸、最优解存在的条件下，

$$F(x_k) - F(x^*) \leq \frac{2L\|x_0 - x^*\|_2^2}{(k+1)^2}. \tag{C.17}$$

达到函数误差 ε 所需迭代次数由 $O(1/\varepsilon)$ 降为 $O(1/\sqrt{\varepsilon})$ 。

 加速不保证函数值逐步下降

外推点 y_k 可能越过当前低值区域，所以 $F(x_{k+1})$ 可以短暂上升。加速结论控制的是整体势函数，而不是每轮单调性。实践中常在函数值恶化或动量方向失效时重启 t_k 。

若 $g = 0$ 且 f 同时为 μ -强凸、 L -光滑函数，可取固定动量

$$\beta = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}},$$

得到

$$f(x_k) - p^* = O\left(\left(1 - \sqrt{\frac{\mu}{L}}\right)^k\right).$$

它把梯度下降对条件数的 $O(\kappa)$ 依赖改善为 $O(\sqrt{\kappa})$ 。

C.6 坐标下降

当变量维数很高、单个偏导比完整梯度便宜，或目标对坐标可分时，可以每轮只更新一个坐标。

设 e_i 为第 i 个标准基向量。若 f 沿第 i 个坐标的偏导满足

$$|\nabla_i f(x + te_i) - \nabla_i f(x)| \leq L_i |t|,$$

则坐标方向有上界

$$f(x + te_i) \leq f(x) + t \nabla_i f(x) + \frac{L_i}{2} t^2.$$

最小化右侧得到更新

$$x_{k+1} = x_k - \frac{1}{L_{i_k}} \nabla_{i_k} f(x_k) e_{i_k}, \quad (\text{C.18})$$

并保证

$$f(x_{k+1}) \leq f(x_k) - \frac{[\nabla_{i_k} f(x_k)]^2}{2L_{i_k}}. \quad (\text{C.19})$$

坐标可以循环选择，也可以随机选择。随机选择便于给出整体速率；循环选择常有更好的缓存与实现性能，但理论分析更依赖问题结构。

若 i_k 在 $\{1, \dots, n\}$ 上均匀随机、 $L_i \leq L_{\max}$ ，则对凸光滑函数，在相应水平集有界时，

$$\mathbb{E}[f(x_k) - p^*] = O\left(\frac{nL_{\max}R^2}{k}\right).$$

若 f 进一步为 μ -强凸函数，则由式 式 C.19 与

$$\|\nabla f(x)\|_2^2 \geq 2\mu(f(x) - p^*)$$

可得

$$\mathbb{E}[f(x_k) - p^*] \leq \left(1 - \frac{\mu}{nL_{\max}}\right)^k (f(x_0) - p^*). \quad (\text{C.20})$$

对复合目标

$$F(x) = f(x) + \sum_{i=1}^n g_i(x_i),$$

可以使用坐标近端更新

$$x_{i_k}^{k+1} = \text{prox}_{g_{i_k}/L_{i_k}} \left(x_{i_k}^k - \frac{1}{L_{i_k}} \nabla_{i_k} f(x_k) \right),$$

其余坐标保持不变。Lasso 适合坐标下降, 正是因为 ℓ_1 正则项逐坐标可分, 单坐标子问题具有软阈值闭式解。

C.7 Newton 法

梯度法用统一的 Euclidean 二次项控制步长; Newton 法则直接使用函数在当前位置的曲率。

对二阶可微函数 f , 在 x_k 附近的二阶模型为

$$m_k(d) = f(x_k) + \nabla f(x_k)^\top d + \frac{1}{2} d^\top \nabla^2 f(x_k) d.$$

若

$$H_k = \nabla^2 f(x_k) \succ 0,$$

模型的唯一极小点满足

$$H_k d_k = -\nabla f(x_k). \quad (\text{C.21})$$

Newton 更新为

$$x_{k+1} = x_k + \alpha_k d_k, \quad (\text{C.22})$$

其中 $\alpha_k = 1$ 给出完整 Newton 步; 远离最优点时通常用回溯线搜索选择 $\alpha_k \in (0, 1]$ 。

因为

$$\nabla f(x_k)^\top d_k = -\nabla f(x_k)^\top H_k^{-1} \nabla f(x_k) < 0$$

在梯度非零时成立, 所以 d_k 是下降方向。若 Hessian 不正定或奇异, Newton 方程可能不给出下降方向。仅缩小正步长不能改变方向导数的符号; 可选足够大的 $\delta > 0$ 使 $H_k + \delta I \succ 0$, 重新求方向, 或使用信赖域方法。

C.7.1 局部二次收敛

设 x^* 满足

$$\nabla f(x^*) = 0, \quad \nabla^2 f(x^*) \succ 0,$$

并且 Hessian 在 x^* 邻域内 Lipschitz 连续。若 x_0 足够接近 x^* , 完整 Newton 步满足

$$\|x_{k+1} - x^*\|_2 \leq C \|x_k - x^*\|_2^2 \quad (\text{C.23})$$

对某个常数 $C > 0$ 成立。这意味着进入局部区域后, 有效精度位数大致每轮翻倍。

关键证明。 设 f 在该邻域内二阶连续可微, 记 $e_k = x_k - x^*$ 。由 $H(x^*) \succ 0$ 与连续性, 可选一个小球, 使其中

$$H(x) \succeq mI, \quad \|H(x)^{-1}\|_{\text{op}} \leq 1/m$$

对统一 $m > 0$ 成立。设该球内 Hessian 的 Lipschitz 常数为 $M > 0$ 。利用 $\nabla f(x^*) = 0$, 沿线段积分得到

$$\nabla f(x_k) = \int_0^1 H(x^* + se_k) e_k \, ds.$$

完整 Newton 步因而满足

$$e_{k+1} = H(x_k)^{-1} \int_0^1 [H(x_k) - H(x^* + se_k)] e_k \, ds.$$

两个 Hessian 的自变量相距 $(1-s)\|e_k\|_2$, 于是

$$\|e_{k+1}\|_2 \leq \frac{M}{m} \int_0^1 (1-s) \|e_k\|_2^2 \, ds = \frac{M}{2m} \|e_k\|_2^2.$$

最后取球内半径 $r > 0$, 使 $Mr/(2m) \leq 1/2$ 。若 $\|e_0\|_2 \leq r$, 上述递推保证 $\|e_{k+1}\|_2 \leq \|e_k\|_2/2 \leq r$, 归纳可知迭代始终留在该球内。这补上了“初值足够近”到“每一步都能使用局部条件”的连接。

控制逆矩阵范数用的是最小特征值: 对正定 H , $\|H^{-1}\|_{\text{op}} = 1/\lambda_{\min}(H)$, 一般不等于 $1/\|H\|_{\text{op}}$ 。

“局部二次”不等于从任意初值都快速收敛。远处通常先用正定修正与线搜索保证下降；在上述局部条件和常用 Armijo 参数小于 1/2 时，足够接近解后可接受完整步。仅有下降性仍不足以保证任意初值下的收敛。

C.8 信赖域：限制模型可信的范围

线搜索先选方向再选步长；信赖域直接在一个受限邻域内选择位移 p 。给定对称矩阵 B_k 与半径 $\Delta_k > 0$ ，建立模型

$$m_k(p) = f(x_k) + g_k^\top p + \frac{1}{2} p^\top B_k p, \quad g_k = \nabla f(x_k),$$

并近似求解

$$\min_{\|p\|_2 \leq \Delta_k} m_k(p).$$

即使 B_k 不正定，闭球上的连续模型仍能取得最小值。实际算法不必精确解子问题，但应保证足够的模型下降；具体子问题算法在此略去。

若预测下降 $m_k(0) - m_k(p_k) > 0$ ，定义

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}.$$

ρ_k 接近 1 表明模型预测可靠；为负则说明实际目标反而上升。一个基本更新模板取 $0 < \eta_a < \eta_s < \eta_e < 1$ ：

判断	操作
$\rho_k < \eta_a$	拒绝试探点，令 $x_{k+1} = x_k$
$\rho_k \geq \eta_a$	接受，令 $x_{k+1} = x_k + p_k$
$\rho_k < \eta_s$	缩小半径
$\rho_k > \eta_e$ 且步子达到边界	在预设上限内扩大半径
其余情形	保持半径

接受判据与半径更新分别执行；接受一步不意味着扩大半径。预测下降非正时不计算此比值，应重新求子问题或终止并检查驻定性。

信赖域适合局部二次模型在远处不可靠、Hessian 可能不正定的情况。以上是算法机制；完整收敛定理还需模型精度、子问题下降量等条件，不能仅由比值规则推出。

C.9 拟 Newton 与 BFGS

显式形成或分解 Hessian 的成本通常为 $O(n^2)$ 存储和 $O(n^3)$ 线性代数。拟 Newton 法用梯度差逐步学习曲率。

记

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

希望 Hessian 近似 B_{k+1} 满足割线条件

$$B_{k+1}s_k = y_k. \quad (\text{C.24})$$

BFGS 更新为

$$B_{k+1} = B_k - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k}. \quad (\text{C.25})$$

当

$$B_k \succ 0, \quad y_k^\top s_k > 0,$$

时, $B_{k+1} \succ 0$, 从而

$$B_k d_k = -\nabla f(x_k)$$

仍产生下降方向。Wolfe 线搜索保证上述曲率条件。事实上, 若 $s_k = t_k d_k$ 、 $t_k > 0$ 且 $g_k^\top d_k < 0$, 由 Wolfe 曲率条件,

$$y_k^\top s_k = t_k (g_{k+1} - g_k)^\top d_k \geq t_k (c_2 - 1) g_k^\top d_k > 0.$$

这一步不要求目标凸; 条件与收敛接口见 小节 6.10。

在目标二阶连续可微、最优点 Hessian 正定并配合适当线搜索等标准条件下, 完整 BFGS 可获得局部超线性收敛。L-BFGS 只保存最近若干组 (s_k, y_k) , 把存储降为 $O(mn)$, 适合高维稀疏机器学习问题, 但它不是严格的完整 Hessian 重建。

C.10 增广 Lagrangian 方法

考虑等式约束问题

$$\begin{aligned} & \text{minimize} && f(x) \\ & \text{subject to} && Ax = b. \end{aligned} \tag{C.26}$$

普通 Lagrangian 对违反约束只施加线性代价。增广 Lagrangian 加入二次惩罚：

$$L_\rho(x, \nu) = f(x) + \nu^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|_2^2, \quad \rho > 0. \tag{C.27}$$

算法迭代为

$$\begin{aligned} x_{k+1} & \in \operatorname{argmin}_x L_\rho(x, \nu_k), \\ \nu_{k+1} & = \nu_k + \rho(Ax_{k+1} - b). \end{aligned} \tag{C.28}$$

二次项改善了子问题对不可行方向的曲率，而乘子更新会累积约束残差。与单纯令惩罚参数趋于无穷不同，增广 Lagrangian 可以使用适中的 ρ ，减少病态性。

若 f 闭、正常、凸，原问题可行且存在鞍点，并且每个 x 子问题精确求解，则在标准条件下

$$Ax_k - b \rightarrow 0, \quad f(x_k) \rightarrow p^*.$$

更深一层的解释是：乘子更新等价于对凹对偶函数执行近端点法。若对偶最优解 ν^* 存在且 ρ 固定，则相应对偶目标误差具有 $O(1/k)$ 的近端点速率。实际采用非精确子问题时，通常要求求解误差可控，例如误差序列可求和。

不等式约束可以通过松弛变量转为等式，或使用带投影的乘子更新；但符号、锥结构和可行域会随具体模型变化，不应把等式形式机械照搬。

C.11 ADMM

若增广 Lagrangian 的联合 x 子问题仍然很难，但目标可以分成两块，交替方向乘子法会分别利用每一块的结构。

考虑

$$\begin{aligned} & \text{minimize} && f(x) + g(z) \\ & \text{subject to} && Ax + Bz = c, \end{aligned} \tag{C.29}$$

其中 f, g 为闭正常凸函数。令缩放乘子 $u = \nu/\rho$ ，两块 ADMM 为

$$\begin{aligned} x_{k+1} &\in \operatorname{argmin}_x \left\{ f(x) + \frac{\rho}{2} \|Ax + Bz_k - c + u_k\|_2^2 \right\}, \\ z_{k+1} &\in \operatorname{argmin}_z \left\{ g(z) + \frac{\rho}{2} \|Ax_{k+1} + Bz - c + u_k\|_2^2 \right\}, \\ u_{k+1} &= u_k + Ax_{k+1} + Bz_{k+1} - c. \end{aligned} \tag{C.30}$$

它不是同时最小化增广 Lagrangian，而是先固定 z 更新 x ，再使用新 x 更新 z ，最后做乘子更新。

C.11.1 原始残差与对偶残差

原始残差为

$$r_{k+1} = Ax_{k+1} + Bz_{k+1} - c.$$

对偶残差可以写为

$$s_{k+1} = \rho A^\top B(z_{k+1} - z_k).$$

r_k 衡量约束违反， s_k 衡量相邻分块更新引起的对偶驻点误差。常用停止条件同时要求

$$\|r_k\|_2 \leq \varepsilon_{\text{pri}}, \quad \|s_k\|_2 \leq \varepsilon_{\text{dual}}.$$

只观察目标值可能掩盖严重的不可行性。

C.11.2 变量分裂例子

对

$$\min_x \ell(x) + \lambda \|x\|_1,$$

引入 z 并约束 $x = z$:

$$\min_{x,z} \ell(x) + \lambda \|z\|_1 \quad \text{s.t.} \quad x - z = 0.$$

于是 x 更新只处理光滑损失与二次项, z 更新则是软阈值:

$$z_{k+1} = \text{prox}_{(\lambda/\rho)\|\cdot\|_1}(x_{k+1} + u_k).$$

变量分裂的目的不是增加变量, 而是把一个困难联合问题改造成两个结构清楚的子问题。

C.11.3 收敛边界

若 f, g 闭正常凸, 未增广 Lagrangian 存在鞍点, 两个子问题可解并被精确求解, 则标准两块 ADMM 满足

$$r_k \rightarrow 0, \quad f(x_k) + g(z_k) \rightarrow p^*,$$

并在常见有界性条件下对遍历平均量给出 $O(1/k)$ 的原始—对偶误差。若还具有强凸性、光滑性或满秩等附加结构, 可得到线性收敛, 但这些条件不能省略。

直接把两块 ADMM 逐项推广到三个或更多分块可能发散; 非凸 ADMM 也不能直接沿用上述结论。

C.12 方法选择速查

结构	首选入口	关键条件或代价
一般不可微凸目标	次梯度法	只需次梯度, 但速率通常为 $O(1/\sqrt{k})$
光滑项 + 简单不可微项	近端梯度	近端映射可高效计算, 基本速率 $O(1/k)$
同上且追求更快一阶速率 高维可分变量	FISTA 坐标下降	$O(1/k^2)$, 但函数值未必单调 单坐标更新便宜, 最好有坐标 Lipschitz 常数

结构	首选入口	关键条件或代价
中等维、高精度、Hessian 可用	Newton	线性系统成本高，局部二次收敛
高维光滑问题、Hessian 不便形成	L-BFGS	用梯度差学习曲率，需线搜索保护
等式约束、联合子问题可解	增广 Lagrangian	乘子更新 + 二次惩罚
可分目标 + 线性耦合约束	两块 ADMM	分块子问题简单，必须同时监控两类残差

C.13 典型误区

1. 任意次梯度都是下降方向。次梯度法允许函数值短暂上升，收敛来自累积距离界。
2. 近端算子只是投影的另一种写法。投影对应指示函数；一般近端算子还编码正则项或损失结构。
3. 加速法每轮都优于基本梯度法。加速改善最坏情形阶数，但可能振荡，且对误差与参数更敏感。
4. Newton 法天然全局收敛。二次收敛是局部结论，远离解时需要阻尼或线搜索。
5. BFGS 在任何更新下都保持正定。必须保证 $y_k^\top s_k > 0$ 。
6. 惩罚参数越大越好。过大的 ρ 会让子问题病态；它还改变 ADMM 两类残差的平衡。
7. 两块 ADMM 的结论可直接用于任意多块或非凸问题。这些推广需要额外算法修正与理论条件。

C.14 本附录小结

次微分把不可微凸优化的最优性条件统一为 $0 \in \partial f(x^*)$ ；近端算子进一步把可计算的不可微结构变成单步精确子问题。近端梯度与 FISTA 分别给出 $O(1/k)$ 与 $O(1/k^2)$ 的复合优化模板；坐标法利用可分性；Newton 与 BFGS 利用曲率；增广 Lagrangian 与 ADMM 则通过乘子和变量分裂处理约束耦合。选择算法时，应首先判断哪一个基本操作——完整梯度、单坐标、Hessian 线性系统、近端映射或分块子问题——最容易计算。

本附录默认一阶信息可被准确计算。带噪梯度、非 Euclidean 几何、在线遗憾与 one-pass 接口见附录 D。

D 随机梯度、镜像下降与在线优化

确定性梯度法假设每轮都能获得当前目标的完整梯度。但机器学习中的数据可能只能逐样本到达，环境也可能随时间改变。此时算法面对的不是一次性求解一个固定函数，而是持续利用带噪信息更新决策。

本附录沿着三条递进关系组织：

随机梯度 $\rightarrow$ 非 Euclidean 几何 $\rightarrow$ 在线决策与遗憾。

随机梯度解决“完整梯度太贵”的问题；镜像下降解决“Euclidean 几何不合适”的问题；在线优化则把评价标准从固定目标的函数误差改为一段决策序列的累积损失。

本附录复用 附录 C 中的次微分和投影工具，但把重点转向随机信息、范数几何与序列决策。

D.1 四种信息模式

先区分算法实际能够观察什么。

模式	每轮获得的信息	典型目标
确定性优化	完整函数或完整梯度	最小化固定 $F(x)$
随机优化	无偏或近似无偏的随机梯度	最小化期望风险
在线凸优化	决策后观察本轮损失或梯度	控制累积遗憾
Bandit 优化	通常只观察所选动作的标量反馈	在部分反馈下控制遗憾

这些模式可能使用相似的更新式，但假设和结论不同。特别是，随机梯度的期望收敛结论不能直接替代对任意损失序列的在线遗憾界。

D.2 随机目标与随机一阶 oracle

随机优化常写为

$$\min_{x \in C} F(x) = \mathbb{E}_{\xi} [f(x; \xi)], \quad (\text{D.1})$$

其中 C 为非空闭凸集, ξ 表示随机样本。有限数据集上的经验风险

$$F(x) = \frac{1}{N} \sum_{i=1}^N f_i(x)$$

是特殊情形：每轮随机抽取索引 i_t , 用单样本梯度代替完整平均梯度。

在第 t 轮, 随机一阶 oracle 返回 $\hat{g}_t$ 。最常用的条件是条件无偏性:

$$\mathbb{E}_t[\hat{g}_t] \in \partial F(x_t), \quad (\text{D.2})$$

其中 $\mathbb{E}_t[\cdot]$ 表示在给定历史

$$\mathcal{F}_{t-1} = \sigma(x_1, \hat{g}_1, \dots, \hat{g}_{t-1}, x_t)$$

后的条件期望。条件无偏比无条件无偏更强：它要求即使固定算法已经走过的随机轨迹, 当前梯度估计仍然指向正确的一阶信息。

常用噪声控制有两种写法:

$$\mathbb{E}_t \|\hat{g}_t\|_*^2 \leq G^2, \quad (\text{D.3})$$

或在可微情形下,

$$\mathbb{E}_t \|\hat{g}_t - \nabla F(x_t)\|_*^2 \leq \sigma^2. \quad (\text{D.4})$$

第一式控制随机梯度的二阶矩; 第二式只控制噪声方差。两者不能静默互换, 因为

$$\mathbb{E}_t \|\hat{g}_t\|_*^2 = \|\nabla F(x_t)\|_*^2 + \mathbb{E}_t \|\hat{g}_t - \nabla F(x_t)\|_*^2$$

在 Euclidean 几何下成立。

D.3 随机梯度下降

投影随机梯度下降更新为

$$x_{t+1} = \Pi_C(x_t - \eta_t \hat{g}_t). \quad (\text{D.5})$$

若 $C = \mathbb{R}^n$ ，投影消失。与确定性梯度下降相比，随机梯度下降每轮便宜，但更新方向含噪，因此函数值通常不单调下降。

本节使用 Euclidean 投影和 ℓ_2 范数，因此式 式 D.3 中的对偶范数仍为 ℓ_2 。

D.3.1 一般凸情形的主界

假设：

1. F 为凸函数，最优解 $x^* \in C$ 存在；
2. C 非空、闭、凸；
3. 式 式 D.2 与 式 D.3 成立；
4. $R = \|x_1 - x^*\|_2$ 。

由投影非扩张性，

$$\|x_{t+1} - x^*\|_2^2 \leq \|x_t - x^*\|_2^2 - 2\eta_t \hat{g}_t^\top (x_t - x^*) + \eta_t^2 \|\hat{g}_t\|_2^2.$$

对历史取条件期望，再使用凸函数的次梯度不等式，

$$\mathbb{E}_t[\hat{g}_t^\top (x_t - x^*)] \geq F(x_t) - F(x^*).$$

因此

$$2\eta_t \mathbb{E}[F(x_t) - F(x^*)] \leq \mathbb{E}[\|x_t - x^*\|_2^2 - \|x_{t+1} - x^*\|_2^2] + \eta_t^2 G^2.$$

定义加权平均点

$$\bar{x}_T = \frac{\sum_{t=1}^T \eta_t x_t}{\sum_{t=1}^T \eta_t}.$$

对上式求和并使用 Jensen 不等式，得到

$$\mathbb{E}[F(\bar{x}_T) - F(x^*)] \leq \frac{R^2 + G^2 \sum_{t=1}^T \eta_t^2}{2 \sum_{t=1}^T \eta_t}. \quad (\text{D.6})$$

若已知总轮数并取

$$\eta_t = \frac{R}{G\sqrt{T}},$$

则

$$\mathbb{E}[F(\bar{x}_T) - F(x^*)] \leq \frac{RG}{\sqrt{T}}. \quad (\text{D.7})$$

这里的 $O(1/\sqrt{T})$ 与确定性光滑梯度法的 $O(1/T)$ 并不矛盾。前者只使用带噪且二阶矩有界的一阶信息；若增加光滑性、方差结构或方差缩减机制，可以获得更精细的界。

D.3.2 强凸情形

若 F 进一步为 μ -强凸函数，则对任意 $g_t \in \partial F(x_t)$ ，次梯度不等式加强为

$$F(x_t) - F(x^*) \leq g_t^\top (x_t - x^*) - \frac{\mu}{2} \|x_t - x^*\|_2^2.$$

额外的二次项产生距离收缩。取

$$\eta_t = \frac{2}{\mu(t+1)}$$

并输出加权平均

$$\tilde{x}_T = \frac{2}{T(T+1)} \sum_{t=1}^T tx_t,$$

在式 式 D.2 与 式 D.3 成立时，有

$$\mathbb{E}[F(\tilde{x}_T) - F(x^*)] \leq \frac{2G^2}{\mu(T+1)}. \quad (\text{D.8})$$

强凸性把期望函数误差从 $O(1/\sqrt{T})$ 改善为 $O(1/T)$ ，但需要递减步长和适当平均；使用固定大步长通常只能收敛到由噪声决定的邻域。

D.4 光滑非凸目标中的 SGD

深度学习目标通常不凸。此时不能承诺到达全局最优，只能控制一阶驻点指标。

本节考虑无约束更新

$$x_{t+1} = x_t - \eta \hat{g}_t.$$

假设：

1. F 可微、下界有限，记 $F_{\inf} = \inf_x F(x)$;
2. F 为 L -光滑函数；
3. $\mathbb{E}_t[\hat{g}_t] = \nabla F(x_t)$;
4. 式 式 D.4 成立；
5. 使用固定步长 $0 < \eta \leq 1/L$ 。

由光滑上界，

$$F(x_{t+1}) \leq F(x_t) - \eta \nabla F(x_t)^\top \hat{g}_t + \frac{L\eta^2}{2} \|\hat{g}_t\|_2^2.$$

取条件期望并分解二阶矩，得到

$$\mathbb{E}_t[F(x_{t+1})] \leq F(x_t) - \frac{\eta}{2} \|\nabla F(x_t)\|_2^2 + \frac{L\eta^2\sigma^2}{2}.$$

求和后，

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E} \|\nabla F(x_t)\|_2^2 \leq \frac{2(F(x_1) - F_{\inf})}{\eta T} + L\eta\sigma^2. \quad (\text{D.9})$$

取 η 与 $1/\sqrt{T}$ 同阶，可使平均梯度平方范数达到 $O(1/\sqrt{T})$ 。这只是“随机选取一个迭代点时梯度通常较小”，不表示函数值已接近全局最优。

D.5 小批量、采样与步长

若同一轮独立抽取 B 个样本并平均,

$$\hat{g}_t = \frac{1}{B} \sum_{j=1}^B \hat{g}_{t,j},$$

则在条件独立且单样本方差不超过 σ^2 时,

$$\mathbb{E}_t \|\hat{g}_t - \nabla F(x_t)\|_2^2 \leq \frac{\sigma^2}{B}.$$

增大 batch size 会降低方差, 但单轮计算和通信成本上升。方差缩小 B 倍不等于总计算量自动缩小 B 倍, 评价时必须同时区分迭代复杂度和样本复杂度。

若样本不是均匀抽取, 必须用重要性权重修正, 否则随机梯度可能有偏。对

$$F(x) = \frac{1}{N} \sum_{i=1}^N f_i(x),$$

若以概率 $p_i > 0$ 抽取 i , 无偏估计可写为

$$\hat{g} = \frac{1}{Np_i} \nabla f_i(x).$$

步长有两类常见设计:

- 为得到有限轮数速率, 直接按 T 选择常步长或分段常步长;
- 为研究渐近收敛, 常要求 Robbins–Monro 条件

$$\sum_{t=1}^{\infty} \eta_t = +\infty, \quad \sum_{t=1}^{\infty} \eta_t^2 < +\infty.$$

第一项防止算法过早停止移动, 第二项使累计噪声能量有限。满足渐近条件不代表它在有限时间内就是最优步长。

D.6 为什么需要镜像下降

投影梯度隐含使用 Euclidean 距离

$$\frac{1}{2}\|x - x_t\|_2^2.$$

但变量可能位于概率单纯形、稀疏集合或具有非 Euclidean 范数约束。此时 Euclidean 投影既可能不自然，也可能给出依赖维数较差的界。

镜像下降的核心不是换一个“更复杂的梯度”，而是换一个衡量更新幅度的几何。

D.7 Bregman 散度

设 $\psi : C \rightarrow \mathbb{R}$ 可微，并且关于范数 $\|\cdot\|$ 为 1-强凸，即

$$\psi(y) \geq \psi(x) + \nabla\psi(x)^\top(y - x) + \frac{1}{2}\|y - x\|^2.$$

由 ψ 生成的 Bregman 散度为

$$D_\psi(y, x) = \psi(y) - \psi(x) - \nabla\psi(x)^\top(y - x). \quad (\text{D.10})$$

强凸性保证

$$D_\psi(y, x) \geq \frac{1}{2}\|y - x\|^2.$$

Bregman 散度一般不对称，也不满足三角不等式，所以它不是距离度量。它表示函数 ψ 在 x 处的一阶近似低估 $\psi(y)$ 的程度。

关键的三点恒等式为

$$\begin{aligned} & (\nabla\psi(y) - \nabla\psi(x))^\top(z - y) \\ &= D_\psi(z, x) - D_\psi(z, y) - D_\psi(y, x). \end{aligned} \quad (\text{D.11})$$

它在镜像下降中承担 Euclidean 平方距离展开的作用。

D.8 镜像下降更新

给定一阶信息 g_t ，镜像下降更新为

$$x_{t+1} = \operatorname{argmin}_{x \in C} \{ \eta_t g_t^\top x + D_\psi(x, x_t) \}. \quad (\text{D.12})$$

第一项希望降低当前线性化损失，第二项限制新点不要在 ψ 所定义的几何中离 x_t 太远。

若没有约束，且迭代位于 ψ 可微的内部、镜像映射 $\nabla\psi$ 可逆，则最优性条件可写为

$$\nabla\psi(x_{t+1}) = \nabla\psi(x_t) - \eta_t g_t. \quad (\text{D.13})$$

算法先在对偶坐标 $\nabla\psi(x)$ 中做加法更新，再通过镜像映射回原变量空间，这就是“镜像”的来源。

D.8.1 单步核心不等式

由式 (D.12) 的最优性条件，对任意 $u \in C$ ，

$$[\eta_t g_t + \nabla\psi(x_{t+1}) - \nabla\psi(x_t)]^\top (u - x_{t+1}) \geq 0.$$

结合式 (D.11)，并把

$$g_t^\top (x_t - u) = g_t^\top (x_t - x_{t+1}) + g_t^\top (x_{t+1} - u)$$

分开处理，可得

$$\begin{aligned} \eta_t g_t^\top (x_t - u) &\leq D_\psi(u, x_t) - D_\psi(u, x_{t+1}) \\ &\quad + \frac{\eta_t^2}{2} \|g_t\|_*^2. \end{aligned} \quad (\text{D.14})$$

最后一项使用了 Hölder 不等式与 ψ 的强凸性。这个单步界是随机镜像下降和在线镜像下降共同的证明模板。

D.9 两种核心几何

D.9.1 Euclidean 几何

取

$$\psi(x) = \frac{1}{2} \|x\|_2^2.$$

则

$$D_\psi(y, x) = \frac{1}{2} \|y - x\|_2^2,$$

式 式 D.12 退化为

$$x_{t+1} = \Pi_C(x_t - \eta_t g_t).$$

因此投影梯度、投影次梯度和 OGD 都是镜像下降的 Euclidean 特例。

D.9.2 概率单纯形上的负熵几何

在概率单纯形

$$\Delta_n = \left\{ x \in \mathbb{R}_+^n \mid \sum_{i=1}^n x_i = 1 \right\}$$

上取负熵

$$\psi(x) = \sum_{i=1}^n x_i \log x_i.$$

对应的 Bregman 散度为 Kullback–Leibler 散度

$$D_\psi(y, x) = \sum_{i=1}^n y_i \log \frac{y_i}{x_i}.$$

从内部点 $x_{1,i} > 0$ 出发，镜像下降得到指数权重更新

$$x_{t+1,i} = \frac{x_{t,i} \exp(-\eta_t g_{t,i})}{\sum_{j=1}^n x_{t,j} \exp(-\eta_t g_{t,j})}. \quad (\text{D.15})$$

它自动保持非负和归一化，不需要做 Euclidean 单纯形投影。若 x_1 为均匀分布，则对任意 $u \in \Delta_n$,

$$D_\psi(u, x_1) \leq \log n.$$

负熵关于 ℓ_1 范数强凸，对偶范数是 ℓ_∞ 。因此当

$$\|g_t\|_\infty \leq G_\infty$$

时，后续遗憾界只依赖 $\sqrt{\log n}$ ，而 Euclidean 分析往往产生更差的维数依赖。

D.10 随机镜像下降

在随机目标式 D.1 中，用随机梯度 $\hat{g}_t$ 代替 g_t ：

$$x_{t+1} = \operatorname{argmin}_{x \in C} \{ \eta_t \hat{g}_t^\top x + D_\psi(x, x_t) \}. \quad (\text{D.16})$$

假设：

1. F 凸, x^* 存在;
2. $\mathbb{E}_t[\hat{g}_t] \in \partial F(x_t)$;
3. $\mathbb{E}_t \|\hat{g}_t\|_*^2 \leq G^2$;
4. $D_\psi(x^*, x_1) \leq R_\psi^2$.

对式 D.14 求条件期望并望远镜求和，可得

$$\mathbb{E}[F(\bar{x}_T) - F(x^*)] \leq \frac{R_\psi^2 + \frac{G^2}{2} \sum_{t=1}^T \eta_t^2}{\sum_{t=1}^T \eta_t}, \quad (\text{D.17})$$

其中 $\bar{x}_T$ 是按 η_t 加权的平均点。

当 $\eta_t = \eta$ 时，

$$\mathbb{E}[F(\bar{x}_T) - F(x^*)] \leq \frac{R_\psi^2}{\eta T} + \frac{\eta G^2}{2}.$$

选择

$$\eta = \frac{\sqrt{2}R_\psi}{G\sqrt{T}}$$

得到

$$\mathbb{E}[F(\bar{x}_T) - F(x^*)] \leq \frac{\sqrt{2}R_\psi G}{\sqrt{T}}.$$

速率阶仍为 $O(1/\sqrt{T})$ ，但常数和维数依赖由所选几何决定。镜像下降的价值通常不是改变这个阶数，而是让界与问题结构匹配。

D.11 在线凸优化

在线凸优化在每一轮 $t = 1, \dots, T$ 按以下顺序运行：

1. 学习者选择 $x_t \in C$;
2. 环境给出凸损失函数 f_t ;
3. 学习者承担损失 $f_t(x_t)$;
4. 学习者获得 f_t 或其一阶信息，并更新到 x_{t+1} 。

环境不必从固定分布独立采样，也可以根据过去历史选择损失，但不能预见学习者本轮尚未公开的私有随机性。算法的目标不是求某个预先固定的最优点，而是让累计损失接近最佳固定比较点。

对任意 $u \in C$ ，静态遗憾定义为

$$R_T(u) = \sum_{t=1}^T [f_t(x_t) - f_t(u)]. \quad (\text{D.18})$$

最坏比较点遗憾为

$$R_T = \sum_{t=1}^T f_t(x_t) - \min_{u \in C} \sum_{t=1}^T f_t(u).$$

若

$$R_T = o(T),$$

则称算法无遗憾，因为平均每轮差距 R_T/T 趋于零。

i One-pass 不等于忘掉历史

在线算法可以不保存原始损失或全部样本，但会把历史压缩进当前参数、累计梯度、二阶矩或正则化状态。不能回放原始历史，与完全不保留历史信息，是两个不同要求。

D.12 在线梯度下降

取

$$g_t \in \partial f_t(x_t),$$

在线梯度下降更新为

$$x_{t+1} = \Pi_C(x_t - \eta g_t). \quad (\text{D.19})$$

假设集合在 Euclidean 范数下直径不超过 D :

$$\|x - y\|_2 \leq D, \quad \forall x, y \in C,$$

且

$$\|g_t\|_2 \leq G.$$

由投影距离递推,

$$g_t^\top(x_t - u) \leq \frac{\|x_t - u\|_2^2 - \|x_{t+1} - u\|_2^2}{2\eta} + \frac{\eta G^2}{2}.$$

凸性给出

$$f_t(x_t) - f_t(u) \leq g_t^\top(x_t - u).$$

对 t 求和,

$$R_T(u) \leq \frac{D^2}{2\eta} + \frac{\eta G^2 T}{2}. \quad (\text{D.20})$$

选择

$$\eta = \frac{D}{G\sqrt{T}},$$

得到

$$R_T(u) \leq DG\sqrt{T}. \quad (\text{D.21})$$

因此平均遗憾为 $O(1/\sqrt{T})$ 。这条证明与次梯度法非常相似，但结论适用于任意凸损失序列，不需要 f_t 来自同一个随机分布。

D.12.1 强凸在线损失

若每个 f_t 都为 μ -强凸函数，且次梯度范数不超过 G ，使用

$$\eta_t = \frac{1}{\mu t}$$

可得

$$R_T \leq \frac{G^2}{2\mu}(1 + \log T). \quad (\text{D.22})$$

强凸性把一般凸损失的 $O(\sqrt{T})$ 静态遗憾改善为 $O(\log T)$ 。

D.13 在线镜像下降

对一般范数几何，令

$$g_t \in \partial f_t(x_t)$$

并使用式 [D.12](#)。若 ψ 关于 $\|\cdot\|$ 为 1-强凸函数，则对任意 $u \in C$ ，

$$R_T(u) \leq \frac{D_\psi(u, x_1)}{\eta} + \frac{\eta}{2} \sum_{t=1}^T \|g_t\|_*^2. \quad (\text{D.23})$$

证明只需把凸性不等式

$$f_t(x_t) - f_t(u) \leq g_t^\top(x_t - u)$$

代入式 D.14, 再对 Bregman 项望远镜求和。

在单纯形上使用负熵, 若 x_1 均匀且 $\|g_t\|_\infty \leq G_\infty$, 取

$$\eta = \sqrt{\frac{2 \log n}{T G_\infty^2}},$$

可得指数权重算法的遗憾界

$$R_T(u) \leq G_\infty \sqrt{2T \log n}. \quad (\text{D.24})$$

这里的 $\log n$ 正是负熵几何相对于 Euclidean 几何的结构收益。

D.14 FTRL

Follow-the-Regularized-Leader 使用截至当前的累计线性化损失:

$$x_t = \operatorname{argmin}_{x \in C} \left\{ \sum_{s=1}^{t-1} g_s^\top x + \frac{1}{\eta} \psi(x) \right\}. \quad (\text{D.25})$$

若 ψ 关于所选范数为 1-强凸函数, 则线性化遗憾满足

$$\sum_{t=1}^T g_t^\top (x_t - u) \leq \frac{\psi(u) - \min_{x \in C} \psi(x)}{\eta} + \frac{\eta}{2} \sum_{t=1}^T \|g_t\|_\star^2. \quad (\text{D.26})$$

OMD 与 FTRL 都通过正则函数选择几何, 但记忆方式不同:

- OMD 从当前点出发, 用一个局部 Bregman 项更新;
- FTRL 对累计梯度重新求一个正则化领导者。

在许多可微、固定正则的设置中, 两者可以导出相同更新; 在时变正则、自适应步长和复合损失下, 它们的形式差异会变得重要。

FTRL 不必保存所有过去的 g_s , 只需维护累计量

$$G_{t-1} = \sum_{s=1}^{t-1} g_s.$$

因此它可以是严格的单遍算法, 同时仍保留过去信息的充分统计。

D.15 Online-to-batch 转换

随机优化和在线优化可以通过 online-to-batch 转换连接。

设

$$f_t(x) = f(x; \xi_t),$$

其中 ξ_t 独立同分布, 且

$$F(x) = \mathbb{E}_\xi[f(x; \xi)].$$

由于 x_t 只依赖过去样本, 它与当前新样本 ξ_t 条件独立, 因此

$$\mathbb{E}[f_t(x_t)] = \mathbb{E}[F(x_t)].$$

对平均点

$$\bar{x}_T = \frac{1}{T} \sum_{t=1}^T x_t,$$

由凸性和 Jensen 不等式,

$$\begin{aligned} \mathbb{E}[F(\bar{x}_T) - F(u)] &\leq \frac{1}{T} \sum_{t=1}^T \mathbb{E}[F(x_t) - F(u)] \\ &= \frac{\mathbb{E}[R_T(u)]}{T}. \end{aligned} \tag{D.27}$$

因此一个 $O(\sqrt{T})$ 的在线遗憾界会产生 $O(1/\sqrt{T})$ 的随机优化期望误差界。反过来并不自动成立: 只对 i.i.d. 数据有效的算法, 未必能抵抗任意在线损失序列。

D.16 静态遗憾与非平稳环境

静态遗憾只和一个固定比较点比较。如果环境变化，固定比较点本身可能已经不合适。

给定比较序列 $u_1, \dots, u_T$ ，动态遗憾定义为

$$R_T^{\text{dyn}}(u_{1:T}) = \sum_{t=1}^T [f_t(x_t) - f_t(u_t)]. \quad (\text{D.28})$$

若允许 u_t 任意变化，就不可能普遍获得次线性动态遗憾。因此必须限制比较序列或环境的变化，例如使用比较点路径长度

$$P_T = \sum_{t=2}^T \|u_t - u_{t-1}\|, \quad (\text{D.29})$$

函数变化量或变化次数预算。动态遗憾界通常依赖这些非平稳度量；重启、滑动窗口和折扣历史则是在算法层面控制“保留多少旧信息”。

💡 静态无遗憾不等于适应得快

算法可能相对最佳固定决策具有很小的静态遗憾，却在每次环境切换后恢复很慢。研究非平稳问题时，应明确比较对象和变化预算，而不能只报告静态遗憾。

D.17 与自适应方法、optimism 和 Bandit 的接口

以下内容对后续在线学习与 Bandit 很重要，但本附录只保留入口。

D.17.1 自适应几何

AdaGrad 根据历史梯度的坐标尺度或矩阵结构动态选择正则几何。它把统一的最坏界

$$G\sqrt{T}$$

替换为依赖实际累计梯度的量，使稀疏或各向异性序列获得更好的数据依赖界。其本质不是普通 SGD 外加一个技巧，而是时变正则下的 OMD 或 FTRL。

D.17.2 Optimism

若在第 t 轮决策前能够预测梯度 m_t ，乐观在线方法会让遗憾依赖预测误差

$$\sum_{t=1}^T \|g_t - m_t\|_*^2$$

而不是完整梯度能量。序列越可预测，收益越大；预测错误时仍需要保留最坏情形保护。该视角是可预测环境、博弈和许多序贯决策算法的重要入口。

D.17.3 Bandit feedback

标准 OCO 通常在决策后获得完整梯度或完整损失函数；Bandit 场景只观察

$$f_t(x_t)$$

或所选臂的奖励。为了使用梯度型更新，必须构造重要性加权或随机扰动梯度估计，由此引入额外方差、探索和维数代价。

因此从 OMD 进入 Bandit 时，真正新增的难点不是更新公式，而是：

1. 如何在部分反馈下构造可控的一阶估计；
2. 如何保证每个动作有足够探索概率；
3. 如何把估计方差纳入遗憾分析。

D.18 方法选择速查

问题结构	常用入口	主要保证
i.i.d. 数据、单样本梯度便宜	SGD	一般凸 $O(1/\sqrt{T})$
强凸随机目标	递减步长 SGD	加权平均 $O(1/T)$
光滑非凸随机目标	SGD	平均梯度平方范数界
非 Euclidean 约束或单纯形	随机镜像下降	几何匹配的 $O(1/\sqrt{T})$
任意凸损失序列	OGD	$O(\sqrt{T})$ 静态遗憾
强凸在线损失	递减步长 OGD	$O(\log T)$ 静态遗憾
单纯形上的专家权重	负熵 OMD / 指数权重	$O(\sqrt{T \log n})$
需要累计历史或时变正则	FTRL	正则化累计损失界
非平稳比较对象	动态遗憾方法	必须依赖变化预算
只观察所选动作反馈	Bandit 方法	需要探索和无偏估计

D.19 典型误区

1. 随机梯度只要无条件均值正确就足够。自适应迭代通常需要给定历史后的条件无偏性。
2. SGD 每轮都应降低目标函数。随机方向含噪，理论通常控制期望、平均点或随机输出点。
3. batch size 增大 B 倍就会让总训练时间缩短 B 倍。方差、迭代数和单轮成本必须共同计算。
4. 镜像下降只是把 Euclidean 投影换个记号。正则函数决定原空间与对偶空间的几何，并改变维数依赖。
5. Bregman 散度是一个距离。它通常不对称，也不满足三角不等式。
6. 在线无遗憾表示每一轮都接近当轮最优。静态遗憾只要求累计表现接近最佳固定比较点。
7. 随机优化的期望收敛率等同于任意序列上的遗憾界。i.i.d. 假设和对抗序列是不同问题。
8. 静态遗憾足以刻画非平稳适应。环境变化时还要考察动态遗憾、路径长度或变化预算。
9. Bandit 只是信息更少的 OGD。部分反馈会新增探索与估计方差这两个核心困难。

D.20 本附录小结

SGD 用带噪一阶信息换取低单轮成本：一般凸目标获得 $O(1/\sqrt{T})$ ，强凸目标在递减步长和加权平均下获得 $O(1/T)$ ，非凸情形则控制平均梯度平方范数。镜像下降用 Bregman 散度选择问题几何，其单步不等式同时支撑随机优化和在线遗憾分析。OCO 以累计遗憾评价决策序列，OGD、OMD 与 FTRL 分别提供 Euclidean、非 Euclidean 和累计正则化视角；online-to-batch 把在线遗憾重新连接到统计学习。动态遗憾、optimism 和 Bandit feedback 则说明，进入非平稳与部分反馈环境后，比较对象、可预测性和梯度估计会成为新的主角。

E 记号表

记号	含义
$\text{dom } f$	函数 f 的定义域
$\text{relint } C$	集合 C 的相对内部
$\text{aff } C$	集合 C 的仿射包
$\text{conv } C$	集合 C 的凸包
I_C	集合 C 的扩展值指示函数
$\Pi_C(x)$	点 x 到闭凸集 C 的 Euclidean 投影
$\langle x, y \rangle = x^\top y$	Euclidean 内积
$\ \cdot\ _\star$	给定范数的对偶范数
$Df(x)$ 或 $J_f(x)$	Jacobian; 行对应输出维度, 列对应输入维度
$\nabla f(x)$	标量函数的梯度, 按列向量记
$\nabla_X f(X)$	标量函数关于矩阵变量 X 的梯度, 与 X 同形
$df(X)[H]$	f 在 X 处沿矩阵方向 H 的一阶微分
$\nabla^2 f(x)$	函数的 Hessian 矩阵
$\text{vec}(X)$	按约定顺序把矩阵 X 展开为向量
$A \succeq 0$	对称矩阵 A 半正定
$x \succeq_K y$	$x - y \in K$ 所定义的广义不等式
$f^\star$	函数 f 的 Fenchel 共轭
$p^\star, d^\star$	原问题与对偶问题的最优值
λ, ν	不等式与等式约束的 Lagrange 乘子
μ	强凸参数
L	梯度 Lipschitz 常数
$\kappa = L/\mu$	强凸光滑问题的条件数
η_k	第 k 次迭代的步长
$\partial f(x)$	凸函数 f 在 x 处的次微分
$N_C(x)$	闭凸集 C 在 x 处的法锥
$\text{prox}_{\eta g}$	参数为 η 的近端算子
$G_\eta(x)$	近端梯度映射
L_i	第 i 个坐标方向的 Lipschitz 常数
$K^\star$	锥 K 的对偶锥
$\mathcal{Q}^n$	n 维二阶锥
$\mathbb{S}_+^n$	$n \times n$ 实对称半正定锥
ρ	增广 Lagrangian 或 ADMM 的惩罚参数
r_k, s_k	ADMM 的原始残差与对偶残差

记号	含义
$\hat{g}_t$	第 t 轮获得的随机梯度估计
$\mathbb{E}_t[\cdot]$	给定第 t 轮以前历史后的条件期望
ψ	镜像下降的强凸正则函数
$D_\psi(y, x)$	由 ψ 生成的 Bregman 散度
Δ_n	n 维概率单纯形
$R_T(u)$	相对固定比较点 u 的静态遗憾
R_T^{dyn}	相对时变比较序列的动态遗憾
P_T	比较点序列的路径长度

全书约定：向量使用小写字母，矩阵使用大写字母，梯度使用列向量；最优点写作 x^* ，最优值写作 p^* 。