

深度学习与进阶统计学习工具箱

目录

前言与阅读导航	1
0 使用约定与最小前置知识	2
第一部分 统计学习与泛化基础	4
第一章 风险、经验风险最小化与渐近分析	5
第二章 从集中不等式到一致收敛	8
第三章 Rademacher 复杂度：从随机符号到泛化界	11
第四章 间隔、核方法与函数空间	14
第五章 覆盖数、链式逼近与 Dudley 方法	16
第二部分 神经网络、正则化与训练	19
第六章 前馈网络、输出建模与反向传播	20
第七章 神经网络的泛化界：范数、深度与全层间隔	23
第八章 显式正则化、数据先验与模型组合	26
第九章 数值计算、初始化与训练算法	29
第三部分 非凸优化与可分析模型	32
第十章 非凸优化：到底收敛到什么	33
第十一章 可分析的非凸问题：PCA、因子化与矩阵补全	35
第十二章 NTK：从局部线性化到训练轨迹	38

第四部分 隐式偏置与优化噪声	41
第十三章 回归中的隐式偏置：优化器、初始化与参数化	42
第十四章 分类中的隐式偏置：参数发散，方向趋向最大间隔	53
第十五章 噪声的隐式正则化与曲率	56
第五部分 序列、表示学习与实验方法	58
第十六章 序列模型、长期依赖与显式记忆	59
第十七章 表示学习、高斯混合与矩方法	62
第十八章 谱聚类：期望结构、随机扰动与图切割	65
第十九章 实验设计、诊断与超参数选择	69
附录	72
Appendix A 常用计算、证明步骤与自检答案	72
Appendix B 材料覆盖与来源定位	76
Appendix C 校对记录、来源边界与补充说明	88
Appendix D 交付检查与使用说明	91

前言与阅读导航

本书参考了《深度学习》（花书）和 CS229M 课程进行了整理，作为深度学习的学习材料。

内容路线

部分	章节	主线
预备章	0	阅读约定、符号、范数与展开
第一部分	1-5	风险 $\rightarrow$ 集中 $\rightarrow$ 复杂度 $\rightarrow$ 间隔与核 $\rightarrow$ 覆盖数
第二部分	6-9	前馈网络 $\rightarrow$ 泛化界 $\rightarrow$ 显式正则化 $\rightarrow$ 数值训练
第三部分	10-12	非凸收敛 $\rightarrow$ 矩阵因子化 $\rightarrow$ NTK
第四部分	13-15	回归隐式偏置 $\rightarrow$ 分类最大间隔 $\rightarrow$ 噪声与曲率
第五部分	16-19	序列模型 $\rightarrow$ 表示与矩方法 $\rightarrow$ 谱聚类 $\rightarrow$ 实验诊断

如何阅读

首次学习从[预备章](#)开始，再按正文顺序阅读；第 16–19 章也可作为专题入口。复习时先查[数学速查与自检答案](#)，回到正文核对假设、归一化和证明步骤。

要从课程或教材定位正文，请查[材料覆盖与来源定位](#)；逐段时间戳保存在项目根目录的 `source-ledger.json`。校对与补充的边界见[附录 C](#)。

推导可以逐行验算；**引用结论**应连同条件使用；**启发式**用于理解机制；**校对说明**指出原材料中尚有不确定性的地方。

0 使用约定与最小前置知识

这份工具箱以你上传的 CS229M 第 1–20 讲转录和花书第 4、6、7、8、10、11、15 章为边界。正文按知识依赖重组；附录保留来源索引和校对记录。这里的“完整”指选定范围的主体内容都有实质讲解，并不意味着复制原书全部文字、复现每个课堂插话，或证明课程本身仅引用的全部研究定理。

阅读标记。“推导”可逐行验算；“引用结论”明确写出使用条件，但不冒充全文证明；“启发式”说明机制而非一般定理；“校对说明”指出原转录的不确定处。本书新增的标准推导用于补足逻辑，不能反向归为老师原话。

0.1 符号与随机性

符号	固定含义
$S = (Z_1, \dots, Z_n), Z_i = (X_i, Y_i)$	独立同分布训练样本，除非另有说明
P, P_n	总体分布与经验平均算子
$R(f) = P\ell_f, \widehat{R}_S(f) = P_n\ell_f$	总体风险与经验风险
d, p, m, k	输入维度、参数数目、隐藏层宽度、网络深度；聚类章局部重定义 k
$\delta \in (0, 1)$	失败概率；层扰动另记为 ξ_i
η, λ	学习率、正则化强度
β	光滑常数，避免与风险函数混淆
σ_i, ε_i	奇异值、Rademacher 随机符号，分别使用

先固定样本，再对随机符号取期望，得到的是**经验**复杂度；再对样本取期望，才得到总体复杂度。条件于历史的无偏随机梯度，与无条件平均为零不是同一个条件。

$O(\cdot)$ 隐藏常数， $\widetilde{O}(\cdot)$ 还隐藏对数项。隐藏哪个量的依赖必须说明；不能把 d^2/n^2 当成“与维度无关的高阶小量”。 $O_p(a_n)$ 表示除以 a_n 后依概率有界，并非确定性上界。

0.2 范数、投影与导数

向量对偶范数定义为 $\|z\|_* = \sup_{\|x\| \leq 1} z^\top x$, 于是 $|z^\top x| \leq \|z\|_* \|x\|$ 。最常用配对为 ℓ_2/ℓ_2 与 ℓ_1/ℓ_∞ 。

矩阵谱范数 $\|A\|_{\text{op}} = \sup_{\|x\|_2=1} \|Ax\|_2 = \sigma_{\max}(A)$; Frobenius 范数 $\|A\|_F^2 = \sum_{ij} A_{ij}^2 = \sum_j \sigma_j^2$ 。逐元素范数 $\|A\|_{1,1} = \sum_{ij} |A_{ij}|$ 与诱导算子范数不是同一概念。后文 $\|A^\top\|_{2,1}$ 明确定义为其列欧氏范数之和, 不能误读为 $2 \rightarrow 1$ 算子范数。

对 $f: \mathbb{R}^p \rightarrow \mathbb{R}$, $\nabla f \in \mathbb{R}^p$, $\nabla^2 f \in \mathbb{R}^{p \times p}$ 。对 $F: \mathbb{R}^p \rightarrow \mathbb{R}^n$, Jacobian $J \in \mathbb{R}^{n \times p}$, 链式法则为 $\nabla_\theta \ell(F(\theta)) = J^\top \nabla_F \ell$ 。检查维度通常可以发现遗漏的转置。

若 $X = U_r \Sigma_r V_r^\top$, 则 $X^\dagger = V_r \Sigma_r^{-1} U_r^\top$ 。 $XX^\dagger$ 投影到列空间, $X^\dagger X$ 投影到行空间。 $\mathbb{R}^d = \text{range}(X^\top) \oplus \ker X$ 是第 13 章的核心几何。

0.3 两条反复使用的展开

若梯度是 β -Lipschitz, 则

$$f(x+h) \leq f(x) + \nabla f(x)^\top h + \frac{\beta}{2} \|h\|^2.$$

若 Hessian 是 ρ -Lipschitz, 则

$$\left| f(x+h) - f(x) - \nabla f(x)^\top h - \frac{1}{2} h^\top \nabla^2 f(x) h \right| \leq \frac{\rho}{6} \|h\|^3.$$

前式来自沿线段积分梯度, 后式再积分 Hessian 的变化。这些是有条件的余项控制, 而不是“高阶项总能忽略”。

0.4 如何使用本书

第一次依次读第 1–5 章, 再读第 6–15 章。第 16–19 章保留独立入口。每章结尾的问题用于主动回忆, 不是考试题库。查公式时先查假设与归一化, 再把它代入自己的问题。尤其不要把总体风险、训练风险、参数误差和预测误差混为一个“误差”。

第一部分

统计学习与泛化基础

第一章 风险、经验风险最小化与渐近分析

来源：CS229M L1、L2 前半段；花书 §8.1。本章补全渐近展开中的条件与正负号。

1.1 为什么要最小化经验风险

总体目标是 $R(f) = \mathbb{E}[\ell(f(X), Y)]$ ，但分布未知，只能计算 $\widehat{R}(f) = n^{-1} \sum_i \ell(f(X_i), Y_i)$ 。经验风险最小化 (ERM) 选择 $\hat{f} \in \arg \min_{f \in \mathcal{H}} \widehat{R}(f)$ 。

定义 $f_{\mathcal{H}}^* \in \arg \min_{f \in \mathcal{H}} R(f)$ ， R^* 为所有可测预测规则的最优风险。实际算法返回 $\tilde{f}$ ，满足 $\widehat{R}(\tilde{f}) \leq \inf_{f \in \mathcal{H}} \widehat{R}(f) + \epsilon_{\text{opt}}$ 。令 $\Delta_S = \sup_{f \in \mathcal{H}} |R(f) - \widehat{R}(f)|$ ，插入并减去经验风险：

$$\begin{aligned} R(\tilde{f}) - R^* &= [R(\tilde{f}) - \widehat{R}(\tilde{f})] + [\widehat{R}(\tilde{f}) - \widehat{R}(f_{\mathcal{H}}^*)] \\ &\quad + [\widehat{R}(f_{\mathcal{H}}^*) - R(f_{\mathcal{H}}^*)] + [R(f_{\mathcal{H}}^*) - R^*] \\ &\leq 2\Delta_S + \epsilon_{\text{opt}} + \epsilon_{\text{app}}. \end{aligned}$$

近似误差由模型类限制产生；统计项来自有限数据；优化项来自没把训练目标充分优化。增大网络可能减小第一项，却改变统计复杂度和优化难度，所以“越大越好”不能由这条分解直接推出。

1.2 固定模型与训练后选择的模型

对一个提前固定的 f ，大数定律说明 $\widehat{R}(f) \rightarrow R(f)$ 。但 $\hat{f}$ 是看到样本后选择的，不能把固定 f 的结论直接代入随机的 $\hat{f}$ 。一致收敛要求同一个事件上所有候选模型都满足误差界；这样事后选任何一个仍在事件内。

训练算法的偏置也可能使它只访问模型类的特殊区域。因此对整个巨大模型类的一致收敛失败，并不等于算法一定不能泛化；它只说明这条证明路径不够细。

1.3 参数估计的渐近正态性

设 $\theta^* \in \mathbb{R}^p$ 是总体风险的內点极小值, p 固定。作如下标准条件: $\hat{\theta} \rightarrow_p \theta^*$; 局部二阶光滑; 经验 Hessian 在所需邻域一致收敛到连续的总体 Hessian; $H = \nabla^2 R(\theta^*)$ 正定; 单样本梯度二阶矩有限, 且允许交换微分与期望。近似 ERM 的一阶残差若存在, 要求为 $o_p(n^{-1/2})$ 。

令 $g_i = \nabla_{\theta} \ell(\theta^*; Z_i)$, $\mathbb{E}g_i = 0$, $V = \mathbb{E}[g_i g_i^\top]$ 。用积分形式展开经验梯度:

$$0 = \nabla \widehat{R}(\theta^*) + \left[\int_0^1 \nabla^2 \widehat{R}(\theta^* + s(\hat{\theta} - \theta^*)) ds \right] (\hat{\theta} - \theta^*).$$

括号内趋于 H , 因 H 可逆, 连续映射定理保证逆也趋于 H^{-1} 。因此

$$\sqrt{n}(\hat{\theta} - \theta^*) = -H^{-1} \frac{1}{\sqrt{n}} \sum_i g_i + o_p(1) \Rightarrow N(0, H^{-1} V H^{-1}).$$

负号来自把经验梯度移项。它虽不改变零均值高斯的协方差, 却不能在中间等式里省略。

对总体风险作二阶展开, 因 $\nabla R(\theta^*) = 0$, 一阶项消失:

$$n[R(\hat{\theta}) - R(\theta^*)] \Rightarrow \frac{1}{2} Z^\top H Z, \quad Z \sim N(0, H^{-1} V H^{-1}).$$

故参数误差典型尺度为 $n^{-1/2}$, 风险差为 n^{-1} 。**分布收敛不自动推出期望收敛**; 若另有一致可积性等条件, 才可写

$$\mathbb{E}[R(\hat{\theta}) - R(\theta^*)] = \frac{1}{2n} \text{tr}(V H^{-1}) + o(n^{-1}).$$

1.4 正确设定的似然模型与 Fisher 信息

若数据确来自 p_{θ^*} , 损失为 $-\log p_{\theta}(Z)$, 且支持集和微分积分交换条件适当, 由 $\int p_{\theta}(z) dz = 1$ 求导两次:

$$\mathbb{E}[s_{\theta}] = 0, \quad -\mathbb{E}[\nabla^2 \log p_{\theta}] = \mathbb{E}[s_{\theta} s_{\theta}^\top] = I(\theta),$$

其中 $s_{\theta} = \nabla \log p_{\theta}$ 。于是 $H = V = I(\theta^*)$, 渐近协方差为 I^{-1} ; n 倍风险差趋于 $\chi_p^2/2$, 在期望收敛条件下其均值主项为 $p/(2n)$ 。模型错设时一般仍是 sandwich 矩阵 $H^{-1} V H^{-1}$, 不能强行约掉。

这套结果以固定维度和局部可识别性为基础。过参数化网络常有对称性与奇异 Hessian, 不能直接套用。唯一极小点也不保证 Hessian 可逆: $f(x) = x^4$ 在零点唯一最小, 但二阶导为零。这是对课堂转录中相关口头表述的必要修正。

自检。为什么参数误差是一阶尺度、风险差是二阶尺度？若将 p 随 n 增大，上述证明哪一步需要重新检查？

第二章 从集中不等式到一致收敛

来源：CS229M L2 后半、L3、L4。附录记录 L4 单边有界差分版本的符号核对。

2.1 指数矩怎样变成尾概率

设中心化随机变量 X 满足 $\mathbb{E}e^{tX} \leq e^{t^2v/2}$ ，所有 $t \in \mathbb{R}$ 成立，称其为方差代理 v 的次高斯变量。对 $t > 0$ ，由 Markov 不等式，

$$\Pr(X \geq a) = \Pr(e^{tX} \geq e^{ta}) \leq e^{-ta} \mathbb{E}e^{tX} \leq e^{-ta+t^2v/2}.$$

右边对 t 求导，最优 $t = a/v$ ，得到 $e^{-a^2/(2v)}$ 。负尾对 $-X$ 应用同一结果，两尾相加： $\Pr(|X| \geq a) \leq 2e^{-a^2/(2v)}$ 。

若 X_i 独立、代理为 v_i ，则乘积分解给出

$$\mathbb{E}e^{t\sum_i X_i} = \prod_i \mathbb{E}e^{tX_i} \leq e^{t^2\sum_i v_i/2}.$$

独立性用在乘积等式；不能只看每个变量的边缘次高斯性就无条件相加代理。 $N(0, \sigma^2)$ 的代理为 σ^2 ；中心化有界变量的代理由下节给出。真实方差不大于一个有效代理，但它们不必相等。

2.2 Hoeffding 引理与不等式

若 $a \leq X \leq b$ ，令 $K(t) = \log \mathbb{E}e^{t(X-\mathbb{E}X)}$ 。指数倾斜后的分布仍支持于 $[a, b]$ ，因此 $K''(t)$ 是该分布的方差，至多 $(b-a)^2/4$ 。因 $K(0) = K'(0) = 0$ ，积分两次得

$$K(t) \leq \frac{t^2(b-a)^2}{8}.$$

将独立样本的中心化变量相加，并对平均数代入，得到

$$\Pr \left(\left| \frac{1}{n} \sum_i (X_i - \mathbb{E} X_i) \right| \geq \epsilon \right) \leq 2 \exp \left(- \frac{2n^2 \epsilon^2}{\sum_i (b_i - a_i)^2} \right).$$

若每个损失在 $[0, 1]$, 固定模型的尾界就是 $2e^{-2n\epsilon^2}$ 。

2.3 有限类：先控制一个，再控制所有

设固定假设类 $|\mathcal{H}| = M$ 。坏事件为“存在某个模型偏差大于 ϵ ”，由 union bound：

$$\Pr \left(\sup_{h \in \mathcal{H}} |R(h) - \widehat{R}(h)| > \epsilon \right) \leq \sum_{h \in \mathcal{H}} 2e^{-2n\epsilon^2} = 2Me^{-2n\epsilon^2}.$$

不要求不同模型的坏事件独立。令右侧为 δ ，得

$$\Delta_S \leq \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

第 1 章立刻推出 ERM 的超额风险至多 $2\Delta_S$ 。若要求超额风险 $\leq \epsilon$ ，充分样本数为 $n \geq 2\log(2M/\delta)/\epsilon^2$ 。

例如 $M = 1000, \delta = 0.05, n = 10000$ ，风险偏差界约 0.0230，ERM 超额风险界约 0.0460。它是保守保证，并非实际误差预测。

2.4 无限参数空间：网格如何补上空隙

设 $\Theta \subset B_2(0, B) \subset \mathbb{R}^p$ ，且单样本损失对参数一致 L -Lipschitz。取半径 a 的覆盖 C 。对任意 θ ，找 $\theta' \in C$ 使距离 $\leq a$ ，则

$$|R(\theta) - \widehat{R}(\theta)| \leq |R(\theta') - \widehat{R}(\theta')| + 2La.$$

一个 La 来自总体风险变化，另一个来自经验风险变化。

覆盖大小推导。取球内极大的 a -分离集合；极大性保证它也是 a -覆盖。其半径 $a/2$ 小球互不相交，均在半径 $B + a/2$ 大球内。比较体积，

$$|C| \leq (1 + 2B/a)^p.$$

因此同一高概率事件上

$$\Delta_S \leq 2La + \sqrt{\frac{p \log(1 + 2B/a) + \log(2/\delta)}{2n}}.$$

减小 a 降低离散化误差，却增加网格数量。选 a 为 $n^{-1/2}$ 量级（对齐单位后）给出约 $\tilde{O}(\sqrt{p/n})$ 的界。若网络参数化可任意缩放， B 与 L 也会改变，不能只摘出参数数目作解释。

2.5 McDiarmid：函数不是和，也能集中

若独立 $Z_1, \dots, Z_n$ 的函数 F 在只替换第 i 个坐标时最多变化 c_i ，则

$$\Pr(F - \mathbb{E}F \geq t) \leq \exp\left(-\frac{2t^2}{\sum_i c_i^2}\right).$$

证明设 $M_i = \mathbb{E}[F \mid Z_1, \dots, Z_i]$ 。则 $M_i - M_{i-1}$ 条件均值为零；固定过去后，它的取值区间长度至多 c_i 。条件版 Hoeffding 引理给出

$$\mathbb{E}[e^{s(M_i - M_{i-1})} \mid Z_{1:i-1}] \leq e^{s^2 c_i^2 / 8}.$$

用塔式法则逐个消掉条件期望，得 $\mathbb{E}e^{s(F - \mathbb{E}F)} \leq e^{s^2 \sum c_i^2 / 8}$ ，再优化 s 即结论。这里不是假定鞅差独立。

对 $F(S) = \sup_f (Pf - P_n f)$ 且 $f \in [0, 1]$ ，单样本替换最多改变 $1/n$ 。故一致偏差围绕其均值波动仅为 $O(\sqrt{\log(1/\delta)/n})$ ；第 3 章只需再控制这个均值。

2.6 课程中的进阶工具及边界

高斯 Poincaré (引用结论)。 $G \sim N(0, I_d)$ ，适当可微且平方可积的 F 满足 $\text{Var } F(G) \leq \mathbb{E} \|\nabla F(G)\|^2$ 。它给方差，不直接等于指数尾界。

高斯集中 (引用结论)。若 F 对欧氏距离是全局 L -Lipschitz，则 $\Pr(|F(G) - \mathbb{E}F(G)| \geq t) \leq 2e^{-t^2/(2L^2)}$ 。这里控制的是梯度的全局上界，不是其期望。

位置依赖的有界差分。定义 $d_i^- F(x) = F(x) - \inf_z F(x_{-i}, z)$ ， $d_i^+ F(x) = \sup_z F(x_{-i}, z) - F(x)$ 。令 $V_- = \|\sum_i (d_i^- F)^2\|_\infty$ ， $V_+ = \|\sum_i (d_i^+ F)^2\|_\infty$ 。独立坐标下一个有效版本为上尾 $e^{-t^2/(4V_-)}$ 、下尾 $e^{-t^2/(4V_+)}$ 。它把“各坐标先取最坏再相加”改成“同一位置相加后取最坏”，可更精细。此处引用熵方法结论，未假装由上一段鞅证明直接得到。

补充比较：Bernstein。独立中心化 X_i 、 $|X_i| \leq b$ ， $v = \sum_i \mathbb{E}X_i^2$ 时， $\Pr(\sum X_i \geq t) \leq e^{-t^2/[2(v+bt/3)]}$ 。小偏差由真实方差控制、大偏差由范围控制；这是辅助对照，不将它误标为 L4 的唯一主轴。

自检。为何 union bound 不要求事件独立？经验风险上确界替换一个样本时为什么仍至多变 $1/n$ ？

第三章 Rademacher 复杂度：从随机符号到泛化界

来源：CS229M L5、L6；本章展开对称化和收缩引理的关键步骤。

3.1 定义与直觉

固定 $S = (z_1, \dots, z_n)$ ，让独立符号 ε_i 等概率取 ± 1 ，定义

$$\widehat{\mathfrak{R}}_S(\mathcal{F}) = \mathbb{E}_\varepsilon \sup_{f \in \mathcal{F}} \frac{1}{n} \sum_i \varepsilon_i f(z_i), \quad \mathfrak{R}_n(\mathcal{F}) = \mathbb{E}_S \widehat{\mathfrak{R}}_S(\mathcal{F}).$$

先观察随机符号，再在类里选最能对齐它的函数。若类能任意拟合样本上的 ± 1 ，复杂度等于 1；只有一个固定函数的类，其复杂度等于 0。由此可见它不总是 $n^{-1/2}$ ，课程末尾的口头讨论不能当作无条件下界。

本书采用上式**不含绝对值**的约定。若换成 $\sup |\cdot|$ ，对非对称类可能不同；不能在证明中途偷偷交换定义。

3.2 对称化的每一步

令 S' 为独立同分布的 ghost sample。固定 S 时 $Pf = \mathbb{E}_{S'} P'_n f$ ，所以

$$\begin{aligned} \mathbb{E}_S \sup_f (Pf - P_n f) &= \mathbb{E}_S \sup_f \mathbb{E}_{S'} (P'_n f - P_n f) \\ &\leq \mathbb{E}_{S, S'} \sup_f (P'_n f - P_n f) \\ &= \mathbb{E}_{S, S', \varepsilon} \sup_f \frac{1}{n} \sum_i \varepsilon_i [f(z'_i) - f(z_i)] \\ &\leq \mathbb{E} \sup_f \frac{1}{n} \sum_i \varepsilon_i f(z'_i) + \mathbb{E} \sup_f \frac{1}{n} \sum_i (-\varepsilon_i) f(z_i) \\ &= 2\mathfrak{R}_n(\mathcal{F}). \end{aligned}$$

第二行是“先知道随机结果再取最好，至少不差于预先选一个”，即 $\sup \mathbb{E} \leq \mathbb{E} \sup$ 。第三行因为每一对 (z_i, z'_i) 可交换且各对独立：随机换位不改变联合分布。第四行允许两项分别选各自最好的函数，所以上界而非等式。

3.3 从期望界到可计算的高概率界

若 $f \in [0, 1]$ ，第 2 章说明 $A(S) = \sup_f (Pf - P_n f)$ 的坐标敏感度为 $1/n$ 。同样， $\widehat{\mathfrak{R}}_S$ 的敏感度至多 $1/n$ 。用两个单边 McDiarmid 事件，各失败概率 $\delta/2$ ，得对所有 f 同时成立：

$$Pf \leq P_n f + 2\widehat{\mathfrak{R}}_S(\mathcal{F}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}.$$

因 $A \leq \mathbb{E}A + a \leq 2\mathfrak{R}_n + a$ ，且 $\mathfrak{R}_n \leq \widehat{\mathfrak{R}}_S + a$ ，常数 3 来自一个 a 加两个 a 。这一版本是总体量的一侧上界；若要双侧保证，对 $-\mathcal{F}$ 或对应反向差异再作一次处理。

假设类必须在抽样前固定。若先用样本挑出“看起来泛化很好的模型类”，再对它无代价套这条界，就漏掉了选择的统计代价。

3.4 线性类： ℓ_2 约束

设 $f_w(x) = w^\top x$ ， $\|w\|_2 \leq B$ 。固定样本时

$$\widehat{\mathfrak{R}}_S = \frac{B}{n} \mathbb{E}_\varepsilon \left\| \sum_i \varepsilon_i x_i \right\|_2 \leq \frac{B}{n} \sqrt{\mathbb{E} \left\| \sum_i \varepsilon_i x_i \right\|_2^2} = \frac{B}{n} \sqrt{\sum_i \|x_i\|_2^2}.$$

第一步是对偶范数，第二步是 Cauchy-Schwarz/Jensen，最后展开平方后交叉项因 $\mathbb{E}\varepsilon_i \varepsilon_j = 0$ 消失。若 $\|x_i\|_2 \leq C$ ，上界为 $BC/\sqrt{n}$ 。无显式维度不等于不受维度影响：数据范数本身可能随维度增长。

3.5 ℓ_1 约束与有限类引理

$\|w\|_1 \leq B$ 、 $\|x_i\|_\infty \leq C$ 时，

$$\widehat{\mathfrak{R}}_S = \frac{B}{n} \mathbb{E} \max_{j \leq d} \left| \sum_i \varepsilon_i x_{ij} \right| \leq BC \sqrt{\frac{2 \log(2d)}{n}}.$$

证明最大值界：把正负坐标看成 $2d$ 个向量 q ，均满足 $\|q\|_2 \leq C\sqrt{n}$ 。对一般有限集合 Q ， $\|q\|_2 \leq M\sqrt{n}$ ，利用 $\cosh u \leq e^{u^2/2}$ ：

$$\mathbb{E} \max_{q \in Q} \varepsilon^\top q \leq \frac{1}{t} \log \sum_q \mathbb{E} e^{t \varepsilon^\top q} \leq \frac{\log |Q|}{t} + \frac{tnM^2}{2}.$$

取 $t = \sqrt{2 \log |Q| / (nM^2)}$ 再除以 n ，即 Massart 有限类界 $M \sqrt{2 \log |Q| / n}$ 。注意候选是 $\{\pm e_j\}$ ，数量 $2d$ ，不是 2^d ；转录在此有明确错误。

3.6 收缩引理不是把非线性直接搬出上确界

若每个 ϕ_i 为 L -Lipschitz，则不含绝对值的 Rademacher 约定下

$$\mathbb{E} \sup_{a \in A} \sum_i \varepsilon_i \phi_i(a_i) \leq L \mathbb{E} \sup_{a \in A} \sum_i \varepsilon_i a_i.$$

常数平移的符号均值为零，可先令 $\phi_i(0) = 0$ 。核心是一次只处理一个坐标。固定其他符号，记其贡献为 $c(a)$ ，最后一位符号取平均得到

$$\frac{1}{2} \sup_{a,b} \{c(a) + c(b) + \phi(a_n) - \phi(b_n)\} \leq \frac{1}{2} \sup_{a,b} \{c(a) + c(b) + L|a_n - b_n|\}.$$

对右侧的最大值可交换 a, b ，故等于把 ϕ 换为 L 倍恒等映射后的符号平均。逐坐标重复即得结论。使用 supremum 不一定取到时，以任意逼近最优的点完成同样论证。

自检。为什么这里需要同时对样本和符号取期望？为何只知道激活函数 Lipschitz，还不能直接控制任意深网络而不付出层间放大因子？

第四章 间隔、核方法与函数空间

来源：CS229M L6、L8，衔接 L13–L14。

4.1 把 0–1 损失换成可分析的上界

二分类 $y \in \{-1, 1\}$ ，实值打分 $f(x)$ ，有符号间隔 $m = yf(x)$ 。保守地将 $m \leq 0$ 视作错误。0–1 损失不连续，不能直接用 Lipschitz 收缩引理。对提前固定的 $\gamma > 0$ 定义 ramp loss：

$$\phi_\gamma(m) = \begin{cases} 1 & m \leq 0, \\ 1 - m/\gamma & 0 < m < \gamma, \\ 0 & m \geq \gamma. \end{cases}$$

它在 $[0, 1]$ 内、是 $1/\gamma$ -Lipschitz，且 $1\{m \leq 0\} \leq \phi_\gamma(m) \leq 1\{m < \gamma\}$ 。于是

$$R_{01}(f) \leq \frac{1}{n} \sum_i \phi_\gamma(y_i f(x_i)) + \frac{2}{\gamma} \widehat{\mathfrak{R}}_{S_X}(\mathcal{H}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}.$$

固定样本标签后 $\varepsilon_i y_i$ 仍是独立 Rademacher 符号，所以引入 y_i 不改变复杂度。经验 ramp loss 也可以进一步上界为小间隔样本比例。

若读完样本再挑 γ ，需用可数网格与 union bound 分配失败概率，或者引用同时对 γ 成立的版本。不能把“对任意固定 γ ”误读为“同一事件对所有 γ ”。

4.2 为什么必须归一化

把 f 乘以 $c > 0$ 不改变分类，间隔与复杂度同时乘以 c 。界中有用的是二者的比值。线性模型中 $yf(x)/\|w\|_2$ 是几何间隔，且在 $\|x\|_2 \leq C$ 时，复杂度项约为 $BC/(\gamma\sqrt{n})$ 。

硬间隔 SVM 的两种形式等价：

$$\max_{\|w\|_2=1} \min_i y_i w^\top x_i \iff \min_w \frac{1}{2} \|w\|_2^2 \text{ s.t. } y_i w^\top x_i \geq 1.$$

在线性可分时，若最优单位间隔为 $\gamma_* > 0$ ，第二个问题最优解的范数为 $1/\gamma_*$ 。证明只需把单位方向放大到最小约束刚好等于 1，并反向归一化。非可分时需软间隔或其他损失，不能继续套硬约束结论。

4.3 核是特征内积的计算入口

设 Hilbert 特征空间映射 $\varphi(x)$ ， $k(x, x') = \langle \varphi(x), \varphi(x') \rangle$ 。Gram 矩阵 $K_{ij} = k(x_i, x_j)$ 半正定，因为 $a^\top K a = \|\sum_i a_i \varphi(x_i)\|^2 \geq 0$ 。

如果目标仅通过训练点预测依赖 w ，并加上严格递增的范数惩罚，把 $w = w_\parallel + w_\perp$ 分解到训练特征张成空间及其正交补。 $w_\perp$ 不影响任一训练预测，却增大范数，因此可取最优解 $w = \sum_i \alpha_i \varphi(x_i)$ 。这就是表示定理的基本几何。

岭回归

$$\min_w \frac{1}{2n} \sum_i (\langle w, \varphi(x_i) \rangle - y_i)^2 + \frac{\lambda}{2} \|w\|^2$$

的一个系数表示是 $\alpha = (K + n\lambda I)^{-1} y$ ，预测为 $f(x) = k_x^\top \alpha$ 。 $\lambda > 0$ 保证矩阵可逆； $\lambda = 0$ 时要考虑伪逆及可插值性。

4.4 无限维为什么不自动导致无限复杂度

对 $\|w\| \leq B$ 的 RKHS 球，完全沿用第 3 章：

$$\widehat{\mathfrak{R}}_S \leq \frac{B}{n} \sqrt{\sum_i \|\varphi(x_i)\|^2} = \frac{B}{n} \sqrt{\text{tr } K}.$$

若 $k(x, x) \leq C^2$ ，仍是 $BC/\sqrt{n}$ 。控制的是函数在选定几何中的大小，不是坐标数。

核方法通常在训练中固定特征映射；神经网络可以改变特征。NTK 是用初始化时的参数梯度定义特征的局部模型，它与“网络全部训练行为”等价需要另外证明。

自检。把所有权重乘十为什么不会凭空改善归一化间隔界？核矩阵奇异时，训练预测唯一是否意味着参数表示唯一？

第五章 覆盖数、链式逼近与 Dudley 方法

来源：CS229M L8 末尾、L9、L10；下文统一使用经验 L_2 归一化。

5.1 覆盖的是样本上的输出，而不一定是参数

对固定样本 S ，令 $Q = \{(f(x_1), \dots, f(x_n)) : f \in \mathcal{F}\} \subset \mathbb{R}^n$ ，度量为 $d_n(q, q') = \|q - q'\|_2 / \sqrt{n}$ 。 $N(a, Q, d_n)$ 是半径 a 球覆盖 Q 所需的最少数量。

即使两套参数差很大，只要它们在样本上的输出相同，对经验复杂度就是同一点。参数空间覆盖可能花钱区分了很多函数上无意义的差异。

5.2 单尺度逼近

取覆盖中心 q' ，有

$$\frac{1}{n} \varepsilon^\top q \leq \frac{1}{n} \varepsilon^\top q' + \frac{1}{n} \|\varepsilon\|_2 \|q - q'\|_2 \leq \frac{1}{n} \varepsilon^\top q' + a.$$

若中心输出范数至多 $M\sqrt{n}$ ，Massart 引理给出 $\widehat{\mathfrak{R}}_S \leq a + M\sqrt{2 \log N(a)/n}$ 。这把所有中心都按大尺度 M 处理，没有利用“细网格中相邻中心差很小”。

5.3 Chaining：把大跳跃拆成越来越小的跳跃

设 $\mathcal{F}$ 含零函数，输出半径至多 M 。取 $a_j = 2^{-j}M$ 的覆盖，记 $\pi_j(q)$ 为最近中心， $\pi_0(q) = 0$ 。对有限层数 J ，恒等式

$$q = \sum_{j=1}^J [\pi_j(q) - \pi_{j-1}(q)] + [q - \pi_J(q)]$$

让每层只支付对应尺度的复杂度。第 j 层增量的经验范数至多 $a_j + a_{j-1} \leq 3a_{j-1}$ ；增量候选数至多 $N(a_j)N(a_{j-1})$ 。对每层用 Massart，再对余项用 Cauchy-Schwarz，得到

$$\widehat{\mathfrak{R}}_S \leq a_J + \frac{C}{\sqrt{n}} \sum_{j=1}^J a_{j-1} \sqrt{\log N(a_j)}.$$

将几何尺度和转成积分，得到一个常用的截断 Dudley 形式（常数可随覆盖中心约定略变）：

$$\widehat{\mathfrak{R}}_S \leq \inf_{0 < a \leq M} \left[4a + \frac{12}{\sqrt{n}} \int_a^M \sqrt{\log N(u, \mathcal{F}, d_n)} du \right].$$

若不含零函数，先围绕一个固定函数平移，并用相应半径/直径；Rademacher 期望中的固定平移贡献为零。有限截断 $a > 0$ 很重要：积分在零处可能发散，但不代表真实复杂度发散。

5.4 看熵增长就知道哪里困难

若 $\log N(u) \leq A/u^p$ ，则被积函数为 $\sqrt{A}u^{-p/2}$ 。

情形	积分特征	典型结果（省略尺度常数）
$p < 2$	零端可积	$\sqrt{A/n}$ 乘半径因子
$p = 2$	对数发散	选正截断，约 $\sqrt{A/n} \log n$
$p > 2$	小尺度主导	平衡截断，约 $(A/n)^{1/p}$

这解释为何课上反复追求 u^{-2} 熵界。不能把它代进从零开始的积分后直接丢掉发散问题。

5.5 Maurey 稀疏化：为何有些覆盖只付 u^{-2}

补充证明。假设 q 属于有限原子集 $\{a_1, \dots, a_M\}$ 的凸包，原子在 Hilbert 范数下不超过 R 。把 q 看成某个随机原子 A 的期望。取 s 次独立采样， $\bar{A} = s^{-1} \sum_j A_j$ ，则

$$\mathbb{E} \|\bar{A} - q\|^2 = \frac{1}{s} \mathbb{E} \|A - q\|^2 \leq \frac{R^2}{s}.$$

故至少有一个平均近似误差不超过 $R/\sqrt{s}$ 。所有平均的数量至多 M^s ，取 $s \geq R^2/u^2$ 得 $\log N(u) \lesssim (R^2/u^2) \log M$ 。负系数可加入正负原子；范数预算通过整体缩放进入 R 。这也是有限坐标线性类熵界的基本来源。

5.6 逐层误差怎样分配最省

第 i 层误差 u_i , 后续层 Lipschitz 常数乘积 a_i , 总输出误差至多 $\sum_i a_i u_i$ 。若各层熵代价为 b_i^2/u_i^2 , 则需解

$$\min_{u_i > 0} \sum_i \frac{b_i^2}{u_i^2} \quad \text{s.t.} \quad \sum_i a_i u_i \leq u.$$

Lagrange 一阶条件 $-2b_i^2/u_i^3 + \nu a_i = 0$, 故 $u_i = c(b_i^2/a_i)^{1/3}$ 。由约束解 c 并代回:

$$\min = \frac{(\sum_i (a_i b_i^2)^{2/3})^3}{u^2}.$$

课程里看似神秘的 $2/3$ 与 $3/2$ 次幂, 来自这个误差预算最优化, 而不是任意选择的参数。

自检。单尺度覆盖与 chaining 差在哪里? 若采用未归一化欧氏度量, 哪些 $\sqrt{n}$ 因子需要搬动?

第二部分

神经网络、正则化与训练

第六章 前馈网络、输出建模与反向传播

来源：花书 §6.1–6.6；CS229M L7 的表示能力讨论。

6.1 为什么非线性是必要的

多层纯仿射映射仍是仿射映射： $W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2)$ 。增加层数而不加非线性，不能突破线性决策边界。

XOR 对 $(0,0), (1,1)$ 输出 0，对 $(1,0), (0,1)$ 输出 1。若存在严格线性分隔 $w_1x_1 + w_2x_2 + b$ ，则需 $b < 0, w_1 + w_2 + b < 0, w_1 + b > 0, w_2 + b > 0$ ；后两式相加与前两式相加冲突。

一个精确实现是令 $s = x_1 + x_2$ ， $f(x) = \text{ReLU}(s) - 2\text{ReLU}(s - 1)$ 。在 $s = 0, 1, 2$ 时输出依次为 0, 1, 0。这个例子说明隐藏表示可以把原空间不可线性分隔的问题变成线性读出。

6.2 输出层来自你想建模的量

目标	分布或统计量	对应损失
实值条件均值	固定方差 Gaussian 的均值	平方误差
条件中位数	$\arg \min_a \mathbb{E} Y - a $	绝对误差
条件分位数 τ	非对称绝对损失最小化	pinball loss
二分类概率	Bernoulli, 参数 $\sigma(z)$	二元交叉熵
多类互斥概率	categorical, 参数 softmax	多类交叉熵
多峰实值分布	高斯混合等条件密度	混合分布负对数似然

平方损失为何对应均值？固定 x ，写 $Y - a = (Y - \mu) + (\mu - a)$ ，取平方期望，交叉项为零，得 $\mathbb{E}[(Y - a)^2 | x] = \text{Var}(Y | x) + (a - \mu)^2$ 。对绝对误差，次梯度平衡两侧条件概率，故中位数最优。

Bernoulli 的负对数似然 $\ell(z, y) = \log(1 + e^z) - yz$ ，所以 $\partial \ell / \partial z = \sigma(z) - y$ 。softmax 对 one-hot 标签同样有 $\nabla_z \ell = p - y$ 。若把 sigmoid 输出再接平方误差，额外乘 $p(1 - p)$ ，饱和区梯度更小；输出激活与损失应共同设计。

若还学习 Gaussian 方差, 需输出正值如 $\sigma^2 = \text{softplus}(a)$, 并保留 $\log \sigma^2$ 项: $\ell = (y - \mu)^2 / (2\sigma^2) + \frac{1}{2} \log \sigma^2 + \text{常数}$ 。遗漏对数项会鼓励无限放大方差。混合密度网络同时输出混合权重、均值和有效协方差, 处理多峰而不是只输出平均值。

6.3 激活、宽度与深度

ReLU 是分段线性的, 负半轴梯度为零; leaky/PreLU 在负半轴保留斜率。sigmoid 与 tanh 有饱和区, 导数分别为 $s(1-s)$ 与 $1 - \tanh^2 z$ 。maxout 取若干仿射输出的最大值, 增加分段表达能力但也增加参数。其他如径向基单元对应不同局部响应先验。

通用逼近定理说明在适当激活、紧致域等条件下, 足够宽的网络可逼近连续函数; 它不保证所需宽度多项式、不保证有限数据可学到, 也不保证梯度下降找到。深度可复用中间计算, 某些组合函数用深模型更紧凑; 这不是“任意函数越深越省”的定理。

架构设计同时决定表示、计算量、参数共享和梯度传播。跳连可让 Jacobian 含近似恒等部分; 稀疏连接可编码先验。参数规模不能单独代表函数复杂度。

6.4 反向传播的完整递推

单样本网络 $h_0 = x$, $z_l = W_l h_{l-1} + b_l$, $h_l = \phi_l(z_l)$ 。对标量损失 ℓ , 令 $\delta_l = \partial \ell / \partial z_l$ 。输出层先由损失求得 δ_k ; 随后

$$\delta_l = (W_{l+1}^\top \delta_{l+1}) \odot \phi'_l(z_l), \quad \frac{\partial \ell}{\partial W_l} = \delta_l h_{l-1}^\top, \quad \frac{\partial \ell}{\partial b_l} = \delta_l.$$

证明用微分 $dz_l = dW_l h_{l-1} + W_l dh_{l-1} + db_l$, 再配对 $d\ell = \delta_l^\top dz_l$; 从 dW_l 的系数读出外积。共享参数在图上多次出现时, 要把所有使用位置的贡献相加, 不是只取最后一次。

反向模式一次反传即可求标量损失对大量参数的梯度, 成本通常与前向同阶。前向模式传播方向导数, 适合输入维度小或只需少数方向。计算梯度的反向传播不是优化算法; 得到梯度后才由 SGD 等算法更新。

6.5 自动微分与高阶导数

符号微分生成表达式, 数值有限差分使用扰动近似, 自动微分沿实际计算图精确应用局部链式法则 (仍有浮点误差)。共享子表达式若不缓存, 符号表达式可能膨胀; 反传缓存中间激活, 代价是内存, 可用重计算交换。

Hessian-向量积可写为 $Hv = \nabla_{\theta}[(\nabla_{\theta}\ell)^{\top}v]$ ，把 v 视为常量；也可对梯度作方向导数，避免显式存储 $p \times p$ Hessian。分支、循环、不可微节点和原地覆盖需要尊重图的实际语义。ReLU 在零点用约定次梯度，其取值不构成经典二阶光滑性保证。

自检。共享参数的梯度为何是和？为什么“交叉熵 + softmax”的输出梯度比逐项链式展开更简单？

第七章 神经网络的泛化界：范数、深度与全层间隔

来源：CS229M L7–L11。全层间隔定义另与 Wei–Ma 的原论文核对；研究定理的适用范围不由转录中省略的词语推定。

7.1 为什么“所有训练零误差解都好”不成立

过参数化网络能拟合真实标签，也可能拟合随机标签；还可以构造训练集上相同、训练外不同的函数。因此需要约束函数类，或分析训练算法偏好哪些解。泛化界通常说明“小复杂度且有大间隔的解有保证”，并不证明训练一定返回这种解。

7.2 两层网络：粗界与更合适的复杂度

写 $f(x) = \sum_{j=1}^m a_j \sigma(w_j^\top x)$ ， σ 为 1-Lipschitz 且 $\sigma(0) = 0$ 。若逐个神经元粗略控制，可能出现 $\sqrt{m}$ 甚至 m ，并且函数等价的神经元复制也让参数计数变大。

对 ReLU 的正齐次性，把 w_j 归一化到单位向量，系数变成 $a_j \|w_j\|_2$ 。令

$$C(f; \theta) = \sum_j |a_j| \|w_j\|_2 \leq B.$$

整个类包含于单神经元原子 $\{\pm \sigma(v^\top x) : \|v\|_2 \leq 1\}$ 的绝对凸包的 B 倍。线性泛函在凸包上的上确界等于原子上的上确界，收缩引理再将 ReLU 换为线性打分；用保守的绝对值处理因子 2，得

$$\widehat{\mathfrak{R}}_S \leq \frac{2B}{n} \sqrt{\sum_i \|x_i\|_2^2}.$$

这个界不显含宽度。将一个神经元拆成多个系数之和相同的副本，不改变 B 。把同一神经元的 w_j 放大 $c > 0$ 、 a_j 除以 c ，也不改变 B 。

此外

$$\frac{a_j^2 + \|w_j\|^2}{2} \geq |a_j| \|w_j\|,$$

在重缩放到 $|a_j| = \|w_j\|$ 时取等。因此对这种两层齐次表示，平衡后的平方参数惩罚与路径式复杂度有直接关系；不能把这一等价泛化到所有架构。

7.3 深层网络：误差为什么带上后续层的乘积

设 $F = f_k \circ \dots \circ f_1$, f_i 的 Lipschitz 常数至多 s_i 。把真实与覆盖网络逐层比较，得到误差递推 $e_i \leq s_i e_{i-1} + u_i$ ，展开为

$$e_k \leq \sum_{i=1}^k u_i \prod_{j>i} s_j.$$

每个组合的中心数量相乘，取对数后代价相加。第 5 章的预算分配给出熵的 $2/3$ 指数结构。一个常见的谱归一化复杂度形状是

$$\mathcal{C} = \left(\prod_i \|W_i\|_{\text{op}} \right) \left[\sum_i \left(\frac{\|W_i^\top\|_{2,1}}{\|W_i\|_{\text{op}}} \right)^{2/3} \right]^{3/2}.$$

此处 $\|W_i^\top\|_{2,1}$ 是分组范数；讲义转录的“2-to-1”不能直接当成诱导算子范数。零矩阵层可直接令网络为常量零并单独处理，而不做零分母运算。在有界输入、1-Lipschitz 齐次激活、提前给定的范数预算等设定下，典型间隔项为 $\tilde{O}(C_x \mathcal{C} / (\gamma \sqrt{n}))$ ；这里展示结构，具体对数与参考矩阵版本依所引用定理而定。

乘积可能随深度增长，但也可能被归一化控制。不能把“形式中有乘积”直接读成“任何深网络都指数恶化”。

7.4 全层间隔的定义

令 $h_0 = x$ ，向每层输出加入相对扰动：

$$h_i = f_i(h_{i-1}) + \xi_i \|h_{i-1}\|_2.$$

全层间隔 $m_F(x, y)$ 是使输出误分类所需的最小联合扰动范数 $\inf\{(\sum_i \|\xi_i\|^2)^{1/2} : F(x, \xi) \text{ 误分类}\}$ 。已误分类时取 0；边界和并列输出用固定约定处理。乘以前层状态范数，使扰动相对尺度可比较。

它衡量中间表示共同受扰动时的稳定性；不是只扰动输入，也不是 Hessian 特征值。分类输出间隔大，但内部极度敏感时，全层间隔仍可能很小。

7.5 为什么它能避开逐层误差乘积：关键证明

假设两个同架构齐次层函数满足 $\|f_i(z) - g_i(z)\| \leq \epsilon_i \|z\|$ 。取一组使 F 误分类的扰动 ξ 。让 G 在每层跟随同一条状态轨迹，只需设置

$$\xi'_i = \xi_i + \frac{f_i(h_{i-1}) - g_i(h_{i-1})}{\|h_{i-1}\|}.$$

状态为零时，齐次性给两层输出均为零，新增项可定义为零。于是 $\|\xi' - \xi\|_{\oplus} \leq (\sum_i \epsilon_i^2)^{1/2}$ 。 G 也误分类，故 $m_G \leq m_F + \|\epsilon\|_2$ 。交换 F, G 得

$$|m_F(x, y) - m_G(x, y)| \leq \sqrt{\sum_i \epsilon_i^2}.$$

误差被吸收到同层扰动里，不再由后面的函数继续放大。这是定义本身带来的优势。

各层取算子距离的覆盖后，得到

$$\log N_{\infty} \left(\sqrt{\sum_i \epsilon_i^2}, \{m_F\} \right) \leq \sum_i \log N_{\text{op}}(\epsilon_i, \mathcal{F}_i).$$

若右侧各层至多 C_i^2/ϵ_i^2 ，在 $\sum \epsilon_i^2 = \epsilon^2$ 下选 $\epsilon_i^2 = \epsilon^2 C_i / (\sum_j C_j)$ ，得到 $\log N_{\infty}(\epsilon, \{m_F\}) \leq (\sum_i C_i)^2 / \epsilon^2$ 。

7.6 泛化结论与“不好的界”

把 m_F 当作广义间隔，再复用第 4-5 章，得到固定阈值 γ 的小间隔比例加 $\tilde{O}((\sum C_i)/(\gamma\sqrt{n}))$ 。这较基本的结果已经解释复杂度从层乘积转为层复杂度之和，但困难部分转移到实际间隔大小。

引用的加强结论。在论文给定的固定函数类及熵条件下，对训练错误为零的网络可用训练集逆间隔的均方根替代最差逆间隔：

$$R_{01}(F) \lesssim \frac{\sum_i C_i}{\sqrt{n}} \sqrt{\frac{1}{n} \sum_{j=1}^n \frac{1}{m_F(x_j, y_j)^2} \log^2 n} + O\left(\frac{\log(1/\delta) + \log n}{n}\right).$$

这一步依赖更精细的平滑损失分析，不是简单把最小值改成平均值。来源：[Wei-Ma, §2 与附录 A](#)。

界大于 1 只表示保证无信息，不表示模型测试错误真的大。小间隔可使界松；不能反向推断必然不泛化。数据依赖的 Jacobian 与隐藏状态条件也必须通过固定类或合法选择论证进入，不能用训练后的“好子集”替代证明。

自检。全层间隔为何要在每层都允许扰动？范数界与优化器的隐式偏置分别回答哪个问题？

第八章 显式正则化、数据先验与模型组合

来源：花书 §7.1–7.14。早停的线性精确计算见第 13 章，训练噪声动力学见第 15 章。

8.1 范数惩罚、约束与欠定问题

目标 $J(\theta) + \lambda\Omega(\theta)$ 中， $\lambda \geq 0$ 调整拟合与偏好。若 θ_λ 是全局最优，则它也是约束 $\Omega(\theta) \leq \Omega(\theta_\lambda)$ 下的最优，否则存在约束内更低 J 与全局最优矛盾。反向“每个约束最优都对应某个惩罚系数”需要凸性、强对偶等条件，非凸情况不能无条件宣称等价。

局部二次目标 $J(w) = \frac{1}{2}(w - w^*)^\top H(w - w^*)$ 加 $\lambda\|w\|^2/2$ ，得到 $w_\lambda = (H + \lambda I)^{-1}Hw^*$ 。在 H 特征值 h_j 方向缩为 $h_j/(h_j + \lambda)$ ：平坦方向更强收缩。

ℓ_1 惩罚的稀疏机制用标量问题看得最清楚：

$$\min_w \frac{1}{2}(w - z)^2 + \lambda|w|, \quad w^* = \text{sign}(z)(|z| - \lambda)_+.$$

对 $w > 0$ 和 $w < 0$ 分别令导数为零；在 $w = 0$ 用次梯度 $[-1, 1]$ ，恰在 $|z| \leq \lambda$ 可平衡。 ℓ_2 平滑收缩一般不制造精确零点。

欠定最小二乘 $X^\top X$ 奇异时， λI 使岭回归系统可逆；PCA 本身可通过 SVD 求解，不应读作“PCA 必须求这个逆”。

8.2 数据增强、噪声与标签平滑

增强变换 T 隐含标签保持先验：训练 $\mathbb{E}_T \ell(f(TX), Y)$ 鼓励对这些变化稳定。若变换会改变标签，这个先验就错误。增强样本共享原始样本，不应直接当成新增同数量独立观测来套样本复杂度。

对线性平方损失、输入加独立零均值噪声 ξ ， $\text{Cov } \xi = \Sigma$ ，有精确恒等式

$$\mathbb{E}_\xi \frac{1}{2}[w^\top(x + \xi) - y]^2 = \frac{1}{2}(w^\top x - y)^2 + \frac{1}{2}w^\top \Sigma w.$$

因为交叉项均值为零。一般非线性网络只在局部小噪声展开下近似对应 Jacobian/曲率惩罚，不能一概等同 weight decay。

标签平滑将 one-hot 目标换成 $(1 - \alpha)y + \alpha u$ ，交叉熵梯度相应变为 $p - [(1 - \alpha)y + \alpha u]$ ，避免对单一类别施加无限置信的目标。随机标签扰动与固定标签平滑的动力学不相同。

8.3 半监督、多任务与参数共享

半监督同时用 $P(X)$ 与少量联合样本，但 $P(X)$ 本身不决定 $P(Y | X)$ ；需要聚类、流形或一致性等关联假设。多任务共享表示 h_θ 、各有输出头，以 $\sum_t \alpha_t \widehat{R}_t$ 训练；相关任务提供互补约束，不相关任务可能负迁移。

软参数绑定用 $\|\theta_a - \theta_b\|^2$ 惩罚，硬共享直接令两者是同一个变量。卷积跨位置共享核，RNN 跨时间共享转移，减少自由度并引入对应结构假设。稀疏参数与稀疏激活表示要区分： $\|w\|_1$ 与 $\sum_i \|h(x_i)\|_1$ 不是同一目标。

8.4 早停与模型选择

训练损失继续下降但验证表现变差时，保存验证最优参数，并用 patience 避免单次波动触发停止。停止时间是超参数选择的一部分，因此验证集不能再当作未使用测试集。

早停既节约优化成本，又限制训练路径。第 13 章给出平方损失下的精确谱滤波，并说明它与岭回归仅有联系，通常不完全等价。

8.5 集成与 dropout

若 M 个预测误差方差均为 v ，两两协方差为 c ，平均误差方差为 $v/M + (M - 1)c/M$ 。集成收益来自不完全相关；复制同一个模型不降低方差。Bagging 用 bootstrap 重采样训练模型，深网络也可用初始化或数据顺序制造多样性。

Inverted dropout 用 $\tilde{h}_j = m_j h_j / p$, $m_j \sim \text{Bernoulli}(p)$ ，故 $\mathbb{E} \tilde{h}_j = h_j$, $\text{Var} \tilde{h}_j = (1 - p)h_j^2 / p$ 。训练在不同子网络上共享参数，测试常关闭 mask。均值缩放只保证这一层的期望；非线性后 $\mathbb{E} f(\tilde{h}) \neq f(\mathbb{E} \tilde{h})$ ，所以“精确平均全部子模型”通常不成立。

8.6 对抗训练与切向方法

对抗目标为 $\min_\theta \mathbb{E} \max_{\|r\| \leq \epsilon} \ell(f_\theta(x + r), y)$ 。线性化内层损失为 $r^\top \nabla_x \ell$ ，其最大值为 $\epsilon \|\nabla_x \ell\|_*$ ； ℓ_∞ 球的最大化方向是 $\epsilon \text{sign}(\nabla_x \ell)$ 。这是局部近似，不保证找到非线性最坏攻击。

若 $T_a(x)$ 表示已知标签保持变换, 切向量 $v = \partial_a T_a(x)|_{a=0}$, 希望 $f(T_a(x))$ 不变, 就惩罚 $\|J_f(x)v\|^2$ 。Tangent distance 在邻域的切平面之间比较距离, tangent prop 直接罚切向导数, manifold tangent classifier 用学习到的流形切向量提供这些方向。三者共享不变性动机, 但算法不同。

自检。为何给输入加噪声只在线性平方损失中有上述精确等价? 范数约束与正则化系数的双向等价需要什么条件?

第九章 数值计算、初始化与训练算法

来源：花书 §4、§8 全章；补充区分 weight decay 与自适应算法中的 ℓ_2 惩罚。

9.1 同一个数学函数，数值实现可能完全不同

对 logits z ，令 $m = \max_j z_j$ ，

$$\text{LSE}(z) = m + \log \sum_j e^{z_j - m}, \quad \log \text{softmax}(z)_i = z_i - \text{LSE}(z).$$

减去最大值避免指数溢出，并确保分母至少有一项为 1。不要先求 softmax 再取 log，小概率可能已下溢为零。二元交叉熵稳定式为 $\max(z, 0) - yz + \log(1 + e^{-|z|})$ 。

条件数描述输入扰动被问题自身放大的程度；对可逆矩阵欧氏条件数是 $\kappa_2(A) = \sigma_{\max}/\sigma_{\min}$ 。一般非正规矩阵不能只用特征值绝对值比；对对称正定矩阵才简化为最大最小特征值比。最小二乘直接构造正规方程会把条件数平方，数值求解通常优先考虑 QR/SVD，而不是显式求逆。

9.2 梯度、Hessian 与约束

β -光滑函数上，梯度方向是局部线性模型在欧氏单位球内下降最快的方向，不意味着有限步长必下降。Newton 解局部二次模型 $Hp = -g$ ，若 H 不定， p 未必是下降方向。阻尼 $H + \lambda I$ 和信赖域可控制不定性。

约束问题可写 $\min f(x) \text{ s.t. } g_i(x) \leq 0, h_j(x) = 0$ ，Lagrangian 为 $f + \sum \lambda_i g_i + \sum \nu_j h_j$ 。KKT 包括可行性、 $\lambda_i \geq 0$ 、互补松弛及驻点；非凸时满足 KKT 不自动全局最优。投影 GD 更新 $x^+ = \Pi_C(x - \eta g)$ ，与惩罚法、可行参数化是不同手段。

9.3 Mini-batch 与优化噪声

独立均匀抽样批次 B 的梯度 g_B 无偏，独立有放回时协方差为单样本协方差的 $1/b$ 。无放回有有限总体修正。增大 batch 降低每步噪声，但每步工作增加；固定更新次数、固定样本遍历次数与固定

算力是三种不同比较。

训练优化的代理损失与最终指标可能不同；测试数据不用于梯度。优化困难包括病态性、局部极小、鞍点、平坦平台、悬崖与梯度爆炸、长期依赖、梯度估计误差和局部模型失真；它们需要不同诊断，不能统称“学习率不好”。

9.4 基本更新式

方法	本书采用的约定	机制与限制
SGD	$\theta^+ = \theta - \eta g$	梯度方向更新，步长决定稳定性
Momentum	$v^+ = \mu v - \eta g(\theta), \theta^+ = \theta + v^+$	平滑同向梯度，可能过冲
Nesterov	$v^+ = \mu v - \eta g(\theta + \mu v)$	在前瞻位置求梯度；其他等价实现符号可能不同
AdaGrad	$s^+ = s + g^2, \theta^+ = \theta - \eta g / (\sqrt{s^+} + \epsilon)$	稀少活跃坐标相对大步长；累积量不减
RMSProp	$s^+ = \rho s + (1 - \rho)g^2$ ，同上归一化	指数窗口抑制无限累积

平方、开方和除法均逐元素。Adam 再维护 $m_t = \beta_1 m_{t-1} + (1 - \beta_1)g_t$ 与 $v_t = \beta_2 v_{t-1} + (1 - \beta_2)g_t^2$ ，用 $\hat{m}_t = m_t / (1 - \beta_1^t)$ 、 $\hat{v}_t = v_t / (1 - \beta_2^t)$ 更新。偏差校正针对零初始化移动平均的早期缩小，不能理解为“修正所有统计偏差”。

普通 SGD 对 $\lambda \|\theta\|^2/2$ 的梯度更新给 $(1 - \eta\lambda)\theta - \eta g$ 。若先对 $g + \lambda\theta$ 做自适应逐坐标缩放，就不等同独立执行 $(1 - \eta\lambda)\theta$ 。这是解耦 weight decay 的意义；本书不指定某软件版本默认行为。

9.5 初始化：方差传播与对称性

若 $z = \sum_{j=1}^{d_{\text{in}}} W_j h_j$ ，近似独立、零均值，则 $\text{Var } z = d_{\text{in}} \text{Var } W \text{Var } h$ 。线性或近线性区域保持方差要求 $\text{Var } W \approx 1/d_{\text{in}}$ ；ReLU 在对称输入下保留约一半二阶矩，常取 $2/d_{\text{in}}$ 。兼顾前后向可用 fan-in/fan-out 平衡。这是近似计算，不是任意相关网络的精确保证。

相同隐藏神经元若同参数初始化并收到相同梯度，会保持相同，随机初始化打破对称。偏置可统一并不意味着所有权重可为零。第 13 章的平方参数化在零点梯度恰为零，尤其说明初始化不能只按“数值小”理解。

9.6 二阶近似与训练策略

共轭梯度在线性正定系统上寻找共轭方向，精确算术下至多维度步解出，但大模型中通常截断并通过 Hessian-向量积迭代。BFGS 用梯度差 $y_k = g_{k+1} - g_k$ 与步差 s_k 建立割线条件 $B_{k+1}s_k = y_k$ ，满足曲率条件时可保持正定；L-BFGS 仅保留有限历史。随机梯度噪声会破坏理想曲率差分。

Batch normalization 对批内特征标准化后再仿射变换 $\gamma\hat{h} + \beta$ ；训练依赖批统计，推理常用累计统计。这改变参数化与梯度尺度，收益不能仅归因于一个口号。小批量或分布变化时应检查统计失配。

坐标下降每次优化参数子块；Polyak averaging 平均多个迭代降低波动；监督预训练与逐层初始化使用相关任务或更浅网络提供起点；残差、门控等架构让优化更容易。Continuation 先解平滑/简单目标再逐渐逼近难目标，curriculum 改变样本难度顺序。它们是设计策略，不是任意任务上保证更好的定理。

自检。条件数是算法误差还是问题敏感性？为什么较大的模型参数梯度可同时包含需要大步长和需要小步长的方向？

第三部分

非凸优化与可分析模型

第十章 非凸优化：到底收敛到什么

来源：CS229M L12；花书 §4.3、§8.2。GD/SGD 复杂度与负曲率步骤为补充展开。

10.1 四种不同结论

全局极小点与域内所有点比较；局部极小点只与邻域比较。一阶驻点满足 $\nabla f(x) = 0$ ；二阶驻点还满足 $\nabla^2 f(x) \succeq 0$ 。可微内点局部极小必须一阶驻点，二阶可微还需 Hessian 半正定，但反向均不成立： x^3 在零点一阶、二阶导均为零，却不是局部极小。

近似一阶驻点用 $\|\nabla f(x)\| \leq \epsilon$ ；近似二阶驻点再要求 $\lambda_{\min}(H) \geq -\tau$ 。若要说“距离最优点小”，还需增长条件或其他几何性质，不能仅从小梯度推出。

10.2 下降引理的完整证明与 GD 复杂度

令 $h = y - x$ ，沿线段积分：

$$f(y) - f(x) - \nabla f(x)^\top h = \int_0^1 [\nabla f(x + th) - \nabla f(x)]^\top h dt \leq \int_0^1 \beta t \|h\|^2 dt = \frac{\beta}{2} \|h\|^2.$$

代入 $h = -\eta \nabla f(x)$ ：

$$f(x^+) \leq f(x) - \eta(1 - \beta\eta/2) \|\nabla f(x)\|^2.$$

取 $\eta = 1/\beta$ ，假设 $f \geq f_{\inf}$ ，从 $t = 0$ 到 $T - 1$ 相加，函数值望远镜消去：

$$\frac{1}{T} \sum_{t < T} \|\nabla f(x_t)\|^2 \leq \frac{2\beta[f(x_0) - f_{\inf}]}{T}.$$

于是最小梯度平方不大于右边；求得某个梯度范数 $\leq \epsilon$ 的点需 $O(\beta\Delta/\epsilon^2)$ 步。或者均匀随机返回历史迭代，得到期望梯度平方保证。它不是最后一步的全局最优值保证，也不单凭此证明整个参数序列收敛到唯一点。

10.3 SGD：噪声如何进入保证

设 $\mathbb{E}[g_t | \mathcal{F}_t] = \nabla f(x_t)$ ，条件方差 $\mathbb{E}[\|g_t - \nabla f(x_t)\|^2 | \mathcal{F}_t] \leq \sigma^2$ 。用下降引理并条件取期望：

$$\mathbb{E}_t f(x_{t+1}) \leq f(x_t) - \eta \|\nabla f(x_t)\|^2 + \frac{\beta \eta^2}{2} (\|\nabla f(x_t)\|^2 + \sigma^2).$$

当 $\eta \leq 1/\beta$ ，相加后

$$\frac{1}{T} \sum_{t < T} \mathbb{E} \|\nabla f(x_t)\|^2 \leq \frac{2\Delta}{\eta T} + \beta \eta \sigma^2.$$

固定步长有噪声平台；平衡两项取 $\eta \asymp \sqrt{\Delta/(\beta \sigma^2 T)}$ （并截断到 $1/\beta$ ），得到平均梯度平方 $O(T^{-1/2})$ 。因此梯度范数容差 ϵ 通常对应 $O(\epsilon^{-4})$ 的这类基础随机一阶界，不要把平方梯度与梯度混淆。

10.4 负曲率能做什么

若单位向量 v 满足 $v^\top H v \leq -\gamma$ ，选符号使 $\nabla f(x)^\top v \leq 0$ ，Hessian 为 ρ -Lipschitz，则令 $h = (\gamma/\rho)v$ ：

$$f(x+h) - f(x) \leq -\frac{\gamma^3}{2\rho^2} + \frac{\gamma^3}{6\rho^2} = -\frac{\gamma^3}{3\rho^2}.$$

即使梯度很小，沿负曲率方向仍能下降。 $\rho = 0$ 的二次函数需单独选有界步长，不使用这个除法。

普通 GD 若恰从鞍点开始，可能完全不动。随机初始化“几乎必然避开某些严格鞍点”的渐近结论，不等于有限时间高效逃离；扰动 GD 或显式负曲率方法的复杂度还需光滑性、下界、步长及概率条件。

10.5 Strict saddle 与良性景观

课程用一种几何分类：每个点要么梯度足够大，要么有显著负曲率，要么已在真正局部极小附近。严格鞍点排除高阶平坦的病态非极小驻点。不同论文对第三类的局部强凸或距离条件有不同定义，使用时必须展开。

若还证明“所有局部极小都是全局极小”，就可把局部搜索结果连接到全局目标。但缺一不可：只有无坏局部极小，算法仍可能在平坦鞍点附近很慢；只有严格鞍点结构，也可能收敛到较差的局部极小。

神经网络有神经元交换、尺度重参数化等对称性，最优解可能是一整条流形而非孤立点。因此全空间强凸常不成立，但商空间、限制子空间或局部预测误差仍可能有好性质。

自检。小梯度为何不代表低损失？严格鞍点与“局部极小全局最优”分别排除什么问题？

第十一章 可分析的非凸问题：PCA、因子化与矩阵补全

来源：CS229M L12, L13 对前讲的回顾。下面完整证明秩一全观测情形；矩阵补全保留观测与一致性条件，不将课程略去的技术假设删掉。

11.1 PCA 的两个等价入口

中心化数据协方差 $M \succeq 0$ ，PCA 求 $\max_{\|v\|=1} v^\top M v$ ，最优方向是最大特征向量。若想同时学习方向和幅度，可考虑

$$f(x) = \frac{1}{4} \|xx^\top - M\|_F^2.$$

它对 x 是四次非凸函数。非凸来自把矩阵变量限制为 $xx^\top$ ；并不意味着每个局部极小都是坏的。

11.2 梯度和 Hessian：先展开标量

展开得

$$f(x) = \frac{1}{4} \|x\|^4 - \frac{1}{2} x^\top M x + \frac{1}{4} \|M\|_F^2,$$

因此

$$\nabla f(x) = \|x\|^2 x - Mx, \quad \nabla^2 f(x) = \|x\|^2 I + 2xx^\top - M.$$

不想写 Hessian 时，可令 $g(t) = f(x + tv)$ ，读出 $g''(0) = v^\top H v$ 。矩阵参数时这个方向导数技巧尤其有效，避免四阶索引。

11.3 所有驻点分类

设 M 特征值 $\lambda_1 \geq \dots \geq \lambda_d \geq 0$ ，先取 $\lambda_1 > \lambda_2$ 。驻点要么 $x = 0$ ，要么 $Mx = \|x\|^2 x$ ，故 x 位于某个正特征值空间且 $\|x\|^2 = \lambda_j$ 。

在 $x = 0$ ， $H = -M$ 有负特征值，是非极小驻点。若 $x = \sqrt{\lambda_j} v_j$ 且 $\lambda_j < \lambda_1$ ，沿 v_1 的曲率

$$v_1^\top H v_1 = \lambda_j - \lambda_1 < 0,$$

所以也是鞍点。若 $x = \pm \sqrt{\lambda_1} v_1$ ，沿 v_1 曲率为 $2\lambda_1$ ，沿其他特征方向为 $\lambda_1 - \lambda_i > 0$ ，是局部极小。

它也是全局极小：记 $r = \|x\|^2$ ， $x^\top M x \leq \lambda_1 r$ ，所以 $f(x) \geq r^2/4 - \lambda_1 r/2 + \|M\|_F^2/4$ ，右边在 $r = \lambda_1$ 达最小，且顶特征方向取等。

若顶特征值有重数，最优方向形成集合；仍无坏局部极小，但不再是孤立强凸点。若 $M = z z^\top$ 且 $z \neq 0$ ，全局解正好为 $\pm z$ ，展示了最简单的良性非凸恢复。

11.4 矩阵补全：只看到少量位置

对低秩目标 M ，只观察随机集合 Ω 中的元素，用 P_Ω 保留观测、其余置零。秩一版本目标为

$$f_\Omega(x) = \frac{1}{4p} \|P_\Omega(x x^\top - M)\|_F^2,$$

其中各独立位置采样概率为 p ；对称模型需把 $(i, j), (j, i)$ 联动处理。固定 x 时有 $\mathbb{E} f_\Omega(x) = \frac{1}{4} \|x x^\top - M\|_F^2$ ，但这不自动保证优化所得、依赖 Ω 的 x 具有相同几何。

还需控制整个允许区域内的梯度与 Hessian 误差，且防止 x 变得极度尖峰。常见做法是限制或惩罚范数/坐标大小，并要求真值不相干 (incoherent)：秩一归一化 $\|z\|_2 = 1$ 下 $\|z\|_\infty \leq \mu/\sqrt{d}$ 。

如果 $z = e_1$ ，唯一非零信息在一个角落，没观测到它就无法辨别真值。故不相干性是信息分散的条件，不只是证明技巧。

11.5 景观迁移的证明路线

令 $\Delta \in \mathbb{R}^d$ ，有

$$\left. \frac{d}{dt} (x + t\Delta)(x + t\Delta)^\top \right|_0 = x\Delta^\top + \Delta x^\top.$$

令 $E = x x^\top - M$ ，则采样目标方向二阶导为

$$\frac{1}{2p} \|P_{\Omega}(x\Delta^{\top} + \Delta x^{\top})\|_F^2 + \frac{1}{p} \langle P_{\Omega}(E), P_{\Omega}(\Delta\Delta^{\top}) \rangle.$$

把它与全观测版本比较，是研究驻点与负曲率的入口。需要的三步是：观测足够且独立；在低秩、非尖峰的结构集合上一致集中；把集中界代入一阶与二阶必要条件，推出任一局部极小靠近 $\pm z$ ，再单独证明算法可在所需区域内到达近似二阶点。

11.6 条件明确的近似景观迁移推导

令全观测 $g(x) = \frac{1}{4} \|xx^{\top} - zz^{\top}\|^2$ ， $\|z\| = 1$ ，记 $r = \|x\|^2$ 、 $a = \langle x, z \rangle$ 。在某个已控制的不相干区域，假设采样目标的局部极小点 x 满足以下由一致集中导出的三个标量近似条件：

$$|\langle x, \nabla g(x) \rangle| \leq \epsilon, \quad |\langle z, \nabla g(x) \rangle| \leq \epsilon, \quad z^{\top} \nabla^2 g(x) z \geq -\epsilon.$$

前文梯度/Hessian 公式给出

$$|r^2 - a^2| \leq \epsilon, \quad |a(r - 1)| \leq \epsilon, \quad r + 2a^2 - 1 \geq -\epsilon.$$

由 $a^2 \leq r$ ，第三式推出 $r \geq (1 - \epsilon)/3$ 。若 $\epsilon \leq 1/64$ ，第一式再推出 $a^2 \geq r^2 - \epsilon > 1/16$ ，故 $|a| \geq 1/4$ 。第二式现在允许安全除以 $|a|$ ，得到 $|r - 1| \leq 4\epsilon$ 。再回代第一式， $a^2 \geq (1 - 4\epsilon)^2 - \epsilon \geq 1 - 9\epsilon$ ，于是 $|a| \geq 1 - 9\epsilon$ 。

选 z 的符号使内积为正，则

$$\min_{s \in \{\pm 1\}} \|x - sz\|^2 = r + 1 - 2|a| \leq (1 + 4\epsilon) + 1 - 2(1 - 9\epsilon) = 22\epsilon.$$

这严格说明了 $O(\sqrt{\epsilon})$ 距离从哪里来。还没有被这段代数证明的部分是：对采样模型建立覆盖整个需要区域的三个近似条件，并证明局部极小确实属于该区域。

课程官网链接的往届笔记给出采样规模的示意形式 $p = \text{poly}(\mu, \log d)/(d\epsilon^2)$ ；但其证明在中途额外使用了候选 x 的不相干性，并省略了确保该性质的完整机制。本书因此将该规模标为**课程示意结果**，不将它升级成无需约束/正则的全局正式定理。来源：[往届矩阵补全讲义](#)。

自检。全观测目标的好几何为什么不能仅通过“采样目标期望等于它”自动继承？唯一特征向量与唯一参数解为何还差一个符号？

第十二章 NTK：从局部线性化到训练轨迹

来源：CS229M L13、L14；固定线性回归的详细推导见第 13 章。本章补充一套可核查的梯度流局部条件，作为“为何不会离开邻域”的闭环证明。

12.1 Taylor 展开针对参数，不是输入

对训练输出向量 $F(\theta) = (f_\theta(x_i))_{i=1}^n$ ，在 θ_0 附近

$$F(\theta_0 + u) = F_0 + J_0 u + \text{余项}, \quad J_0 \in \mathbb{R}^{n \times p}.$$

初始化预测不必为零；线性模型拟合的标签是 $\tilde{y} = y - F_0$ 。有些配对初始化令两份输出互相抵消，使 $F_0 = 0$ ，但参数本身不为零。

若 J_0 满行秩且最小奇异值为 $s > 0$ ，线性化模型存在插值位移 $u^* = J_0^\dagger \tilde{y}$ ，满足 $\|u^*\| \leq \|\tilde{y}\|/s$ 。若每个单样本 Hessian 算子范数不超过 b ，则各样本 Taylor 误差至多 $b\|u\|^2/2$ ，整体向量余项至多 $\sqrt{nb}\|u\|^2/2$ 。

因此要同时比较“达到线性插值需要移动多远”和“这个距离内线性近似误差多大”。只做一个形式展开不能证明可训练性。

12.2 固定核的残差动力学

线性化平方损失 $\|J_0 u - \tilde{y}\|^2/(2n)$ 下，GD 的残差满足

$$e_{t+1} = (I - \eta K_0) e_t, \quad K_0 = J_0 J_0^\top / n.$$

满行秩下选 $0 < \eta < 2/\lambda_{\max}(K_0)$ ，残差几何收敛。最慢方向由小特征值决定，条件数决定各方向速度差异。训练样本很多但核退化时，增加参数数目本身不能自动解决问题。

真实网络的梯度流 $\dot{\theta} = -J(\theta)^\top e/n$ 给出**精确**等式

$$\dot{e} = -K(\theta)e, \quad K(\theta) = J(\theta)J(\theta)^\top/n.$$

但真实离散 GD 有有限步 Taylor 余项, 不能原封不动写成固定核递推。

12.3 局部收敛的一个闭环条件与证明

假设 F 在闭球 $B(\theta_0, R)$ 附近连续可微, J 局部 Lipschitz; $\sigma_{\min}(J_0) = s > 0$; 球内

$$\|J(\theta) - J_0\|_{\text{op}} \leq s/2, \quad \|J(\theta)\|_{\text{op}} \leq M.$$

并要求 $4M\|e_0\|/s^2 < R$ 。在首次离开球以前, Weyl 奇异值扰动界给 $\sigma_{\min}J \geq s/2$ 。所以

$$\frac{d}{dt}\|e\|^2 = -\frac{2}{n}\|J^\top e\|^2 \leq -\frac{s^2}{2n}\|e\|^2,$$

从而 $\|e(t)\| \leq e^{-s^2 t/(4n)}\|e_0\|$ 。参数走过的路径长满足

$$\int_0^t \|\dot{\theta}\| ds \leq \frac{M}{n} \int_0^t \|e(s)\| ds \leq \frac{4M\|e_0\|}{s^2} < R.$$

若存在首次退出时刻, 距离必须达到 R , 却被严格更小的路径长控制, 矛盾。因此一直留在球中, 残差趋零, 且有限路径长给参数极限。这里所有局部估计都由不退出论证闭合, 而不是循环假设。

如果已知 $\|J(\theta) - J_0\| \leq B_J\|\theta - \theta_0\|$, 可用 $B_J R \leq s/2$ 检查条件。它是一个充分条件, 不是对所有宽网络的必要刻画。ReLU 的不可微点需要分段/广义分析, 本节光滑证明不能直接假装全程二阶光滑。

12.4 初始化尺度、宽度与特征学习

把输出尺度乘以 a 时, 在相应零输出初始化约定下, Jacobian 奇异值乘 a 、单输出 Hessian 范数也乘 a , 所以 b/s^2 约除以 a 。线性拟合所需位移变小, 可能更接近固定特征区域。改变宽度也可能使 Jacobian 更稳定, 但具体结论依参数化和归一化, 不是“宽度大就必然 NTK”。

NTK 的解释力: 给出某些非凸网络在初始化附近训练成功的机制, 把参数多的问题转化为核矩阵条件。局限: 固定特征模型不能描述远离初始化的特征形成, 也不直接解释不同优化噪声和初始化下的所有泛化差异。

课程举出的二元乘积例子可用

$$x_1 x_2 = \frac{1}{2}(|x_1 + x_2| - |x_1 - x_2|), \quad x_1, x_2 \in \{-1, 1\},$$

再以 $|t| = \text{ReLU}(t) + \text{ReLU}(-t)$ 用四个神经元实现。它展示可学习少数相关特征的紧凑表示；单凭这个恒等式并没有证明所有核方法的样本复杂度下界，相关比较仍需指定数据分布和核。

自检。线性化模型存在近距离插值解，为什么还不足以证明真实 GD 收敛？本章梯度流证明的哪一步负责保证不退出邻域？

第四部分

隐式偏置与优化噪声

第十三章 回归中的隐式偏置：优化器、初始化与参数化

位置：第 13 章，衔接第 12 章。

材料关系：对应 CS229M 第 14 讲的线性化训练分析和隐式正则化讨论，以及第 15 讲开头对零初始化线性回归的回顾。花书第 4.5、7.3、7.8 节提供最小二乘、欠定问题和早停的背景。本章的推导经过独立重写，使用统一的 $1/(2n)$ 损失归一化，不逐字沿用转录公式。

13.1 要解释的现象

假设我们只有一条训练约束：

$$w_1 + w_2 = 1.$$

$(1, 0)$ 、 $(0, 1)$ 、 $(1/2, 1/2)$ 都能把训练误差降到零。仅仅指定“最小化训练误差”，并没有指定最终选哪一个解。

但训练过程还指定了初始化和更新方法。这些额外选择会影响最后停在哪里。本章将严格证明：**在线性最小二乘问题中，用合适的固定步长从零初始化做普通梯度下降，最终得到所有最小二乘解中欧氏范数最小的那个。**

这里的损失本身是凸的。它的作用是提供一个可精确计算的基准，帮助理解后续非凸模型中的隐式偏置；不能把它当作一般非凸网络结论的证明。

13.2 设定、维度与目标

有 n 个样本，每个输入 $x_i \in \mathbb{R}^d$ ，标签 $y_i \in \mathbb{R}$ 。记

$$X = \begin{bmatrix} x_1^\top \\ \vdots \\ x_n^\top \end{bmatrix} \in \mathbb{R}^{n \times d}, \quad y \in \mathbb{R}^n, \quad w \in \mathbb{R}^d.$$

预测向量是 Xw ，损失为

$$L(w) = \frac{1}{2n} \|Xw - y\|_2^2.$$

记 $r = \text{rank}(X)$ ，先假设 $r \geq 1$ 。当 $d > n$ 时，参数多于样本，但这本身不保证任意标签都可拟合；若 X 满行秩，才能保证对任意 y 都有 $Xw = y$ 的解。

需要区分三个问题：

1. 训练损失是否到达最小值？
2. 在所有最小化解中，算法选择哪一个？
3. 所选解在新样本上表现如何？

前两个是本章能直接回答的问题，第三个还需要数据分布、目标函数和噪声等统计假设。

13.3 第一步：计算梯度，识别算法能移动的方向

把损失展开：

$$L(w) = \frac{1}{2n} (w^\top X^\top X w - 2y^\top X w + y^\top y).$$

因为 $X^\top X$ 是对称矩阵，

$$\nabla L(w) = \frac{1}{n} X^\top (Xw - y), \quad \nabla^2 L(w) = \frac{1}{n} X^\top X.$$

普通梯度下降为

$$w_{t+1} = w_t - \frac{\eta}{n} X^\top (Xw_t - y). \quad (1)$$

每次更新量都是 $X^\top$ 乘上某个向量，因此必定位于

$$\text{range}(X^\top),$$

也就是 X 的行空间。另一方面，线性代数给出正交分解

$$\mathbb{R}^d = \text{range}(X^\top) \oplus \ker(X).$$

如果 $z \in \ker(X)$, 则 $X(w+z) = Xw$ 。训练数据完全看不到这个方向的参数变化。

将 w_t 分解成行空间分量和零空间分量。由式 (1), 每次更新只改变前者, 故

$$P_{\ker(X)} w_t = P_{\ker(X)} w_0 \quad \text{对所有 } t \text{ 成立.} \quad (2)$$

这已经揭示选择机制的一半：算法不会主动清除初始化中训练数据不可见的分量。

13.4 第二步：用 SVD 把矩阵递推变成标量递推

取紧致奇异值分解

$$X = U_r \Sigma_r V_r^\top,$$

其中 $U_r \in \mathbb{R}^{n \times r}$ 、 $V_r \in \mathbb{R}^{d \times r}$ 的列正交,

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r), \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

行空间由 $v_1, \dots, v_r$ 张成。令

$$a_{j,t} = v_j^\top w_t, \quad b_j = u_j^\top y.$$

把式 (1) 左乘 $v_j^\top$, 并使用

$$v_j^\top X^\top X w_t = \sigma_j^2 a_{j,t}, \quad v_j^\top X^\top y = \sigma_j b_j,$$

得到

$$a_{j,t+1} = \left(1 - \frac{\eta \sigma_j^2}{n}\right) a_{j,t} + \frac{\eta \sigma_j}{n} b_j. \quad (3)$$

这一递推的固定点是 $a_j^* = b_j / \sigma_j$ 。从两边减去固定点:

$$a_{j,t+1} - a_j^* = \left(1 - \frac{\eta \sigma_j^2}{n}\right) (a_{j,t} - a_j^*).$$

所以

$$a_{j,t} - a_j^* = \left(1 - \frac{\eta\sigma_j^2}{n}\right)^t (a_{j,0} - a_j^*). \quad (4)$$

每个坐标都收敛，需要所有收缩因子的绝对值严格小于 1：

$$\left|1 - \frac{\eta\sigma_j^2}{n}\right| < 1.$$

整理即 $0 < \eta < 2n/\sigma_j^2$ 。同时满足所有方向的充分且精确的统一范围是

$$0 < \eta < \frac{2n}{\sigma_1^2}. \quad (5)$$

严格小于不可随意改为小于等于：在上端点，最大奇异值方向的因子为 -1 ，一般会持续振荡。

13.5 第三步：得到极限，证明最小范数性质

由式 (2) 和式 (4)，

$$w_\infty = \sum_{j=1}^r \frac{u_j^\top y}{\sigma_j} v_j + P_{\ker(X)} w_0 = X^\dagger y + P_{\ker(X)} w_0. \quad (6)$$

这里 $X^\dagger = V_r \Sigma_r^{-1} U_r^\top$ 是 Moore–Penrose 伪逆。

为什么 $X^\dagger y$ 是最小二乘解？观察

$$X X^\dagger y = U_r U_r^\top y = P_{\text{range}(X)} y.$$

Xw 只能落在 X 的列空间中。在这个空间内，距离 y 最近的点正是其正交投影。因而所有最小二乘解满足

$$w = X^\dagger y + z, \quad z \in \ker(X).$$

又因为 $X^\dagger y$ 位于行空间，与 z 正交，所以

$$\|w\|_2^2 = \|X^\dagger y\|_2^2 + \|z\|_2^2.$$

取 $z = 0$ 时范数唯一最小。若 $w_0 = 0$ ，式 (6) 恰好给出这一解：

$$w_\infty = X^\dagger y.$$

定理。对固定矩阵 X 、平方损失 $L(w) = \|Xw - y\|^2/(2n)$ ，若普通全批量梯度下降使用式 (5) 的固定步长，则任意初始化都收敛到式 (6)。零初始化收敛到最小欧氏范数的最小二乘解；若标签可插值，则它也是最小范数插值解。

如果 $X = 0$ ，所有梯度均为零，迭代停留在初始化；零初始化仍是最小范数最小二乘解，但不能使用包含 σ_1 的步长表达式。

一般初始化还有一个更精确的解释：式 (6) 是所有最小二乘解中距离 w_0 最近的那个，因为它保留了 w_0 的零空间分量。它通常不是距离原点最近的解。

13.6 两个初始化，两个训练误差同为零的答案

取 $X = [1 \ 1]$ 、 $y = 1$ 、 $n = 1$ 。此时 $\sigma_1^2 = 2$ ，允许 $0 < \eta < 1$ 。

从 $w_0 = (0, 0)$ 出发，两坐标每次获得相同更新，因此始终相等。最终满足两坐标之和为 1，故

$$w_\infty = (1/2, 1/2).$$

若从 $w_0 = (2, -2)$ 出发，它完全位于零空间。该分量被保留，最终

$$w_\infty = (1/2, 1/2) + (2, -2) = (5/2, -3/2).$$

两个解在训练输入 $(1, 1)$ 上输出均为 1，但在新输入 $(1, -1)$ 上，输出分别为 0 和 4。这说明：相同训练拟合并不决定相同预测函数。

这里并没有证明第一个解一定具有更好的泛化误差。若真实目标在训练数据不可见方向上恰有非零分量，最小范数解也可能漏掉它。

13.7 切换到输出空间：为何 NTK 分析会出现核矩阵

定义残差 $e_t = Xw_t - y \in \mathbb{R}^n$ 。由式 (1)，

$$\begin{aligned}
e_{t+1} &= Xw_{t+1} - y \\
&= X \left(w_t - \frac{\eta}{n} X^\top e_t \right) - y \\
&= e_t - \frac{\eta}{n} X X^\top e_t \\
&= (I - \eta K) e_t,
\end{aligned} \quad K = \frac{1}{n} X X^\top. \tag{7}$$

参数空间使用 $X^\top X$ ，输出空间使用 $X X^\top$ 。二者的非零特征值相同，均为 σ_j^2 ；这里 K 额外含 $1/n$ 。

若 X 满行秩，则 K 正定。在 $0 < \eta \leq 1/\lambda_{\max}(K)$ 下，

$$\|e_t\|_2 \leq (1 - \eta \lambda_{\min}(K))^t \|e_0\|_2. \tag{8}$$

因为将 e_0 展开到 K 的正交特征向量基，每个坐标每轮乘以 $1 - \eta \lambda_j$ ；在这个步长范围内，最慢的方向对应最小特征值。

若只要求更宽的稳定范围 $0 < \eta < 2/\lambda_{\max}(K)$ ，正确的统一收缩因子是

$$\rho = \max_j |1 - \eta \lambda_j| < 1,$$

不能直接沿用式 (8) 的无绝对值表达式。

若 X 不满行秩， K 存在零特征值。残差的零空间分量保持不变：只有可拟合部分收缩。因此，“ K 半正定，所以所有残差都收缩到零”是错误的。

13.8 从线性回归到神经网络的局部线性化

设标量输出网络为 $f_\theta(x)$ ，初始化为 $\theta_0 \in \mathbb{R}^p$ 。在初始化附近作一阶展开：

$$f_\theta(x) \approx f_{\theta_0}(x) + \nabla_\theta f_{\theta_0}(x)^\top \Delta\theta, \quad \Delta\theta = \theta - \theta_0.$$

把训练点的梯度按行堆叠：

$$\Phi = \begin{bmatrix} \nabla_\theta f_{\theta_0}(x_1)^\top \\ \vdots \\ \nabla_\theta f_{\theta_0}(x_n)^\top \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

再定义初始化输出 $f_0 = (f_{\theta_0}(x_i))_{i=1}^n$ ，以及需要拟合的剩余标签 $\tilde{y} = y - f_0$ 。线性化模型的训练问题就是

$$\min_{\Delta\theta} \frac{1}{2n} \|\Phi\Delta\theta - \tilde{y}\|_2^2.$$

现在把前面的 X 替换为 Φ ，把 y 替换为 $\tilde{y}$ 。由于初始位移 $\Delta\theta_0 = 0$ ，在适当步长下，

$$\Delta\theta_\infty = \Phi^\dagger \tilde{y},$$

而线性化输出残差满足

$$e_{t+1} = (I - \eta K_0) e_t, \quad K_0 = \frac{1}{n} \Phi \Phi^\top.$$

K_0 是本章归一化约定下的经验神经切线核矩阵。它衡量不同训练点在参数梯度特征中的相似程度。

这里得到的是**固定线性化模型**的结论。要把它用于真实非线性网络，还必须控制训练轨迹上的 Taylor 余项、Jacobian 变化与核矩阵变化，并证明参数确实留在所需区域。不能用“假设一直在附近”代替对训练轨迹的证明。

还要注意：最小的是位移 $\|\Delta\theta\|_2$ ，一般不是最终参数 $\|\theta\|_2$ 。初始化输出也不能未经说明就当作零。

13.9 早停：按奇异方向学习的速度不同

从零初始化时，式 (4) 给出

$$w_t = \sum_{j=1}^r \underbrace{\left[1 - \left(1 - \frac{\eta\sigma_j^2}{n} \right)^t \right]}_{g_t(\sigma_j^2)} \frac{u_j^\top y}{\sigma_j} v_j. \quad (9)$$

如果进一步取 $0 < \eta \leq n/\sigma_1^2$ ，则各方向没有振荡， $g_t \in [0, 1]$ 。大奇异值方向学得快，小奇异值方向学得慢。

在小量条件 $t\eta\sigma_j^2/n \ll 1$ 下，

$$g_t(\sigma_j^2) \approx \frac{t\eta\sigma_j^2}{n}.$$

最小二乘解中的 $1/\sigma_j$ 会放大小奇异值方向的标签扰动；有限时间的 g_t 抑制了这些尚未充分学习的方向。因此早停具有谱滤波的效果。

为比较显式正则化，考虑岭回归

$$\min_w \frac{1}{2n} \|Xw - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2, \quad \lambda > 0.$$

令梯度为零，得到

$$w_\lambda = (X^\top X + n\lambda I)^{-1} X^\top y = \sum_{j=1}^r \underbrace{\frac{\sigma_j^2}{\sigma_j^2 + n\lambda}}_{g_\lambda(\sigma_j^2)} \frac{u_j^\top y}{\sigma_j} v_j.$$

早停和岭回归都抑制小奇异值方向，但滤波函数不同。一般不存在一个 λ ，让所有方向上的有限步早停解与岭回归解完全相同。只能在明确条件下比较或近似联系二者。

13.10 本节结论如何使用

想判断什么	本章能提供什么	仍需什么
平方损失训练是否收敛	奇异值给出的稳定步长与收缩率	已知或控制最大奇异值
欠定问题选哪个解	行空间更新、初始化零空间分量与伪逆公式	优化器确为本章的普通 GD
为什么初始化重要	零空间分量被完整保留	非线性模型需另作分析
NTK 为何控制训练	固定 Jacobian 特征下的输出残差递推	非线性训练中核稳定性的证明
早停为何有正则化效应	各奇异方向的谱滤波	泛化收益仍需统计条件

本章不推出 Adam、动量、任意预条件更新都具有相同偏置；也不推出所有神经网络都处于 NTK 区域。后续必须针对算法、参数化和初始化分别分析。

13.10.1 自检与简答

1. 为什么梯度下降无法改变初始化中的零空间分量？

因为每一步更新都属于 $\text{range}(X^\top)$ ，它与 $\ker(X)$ 正交。

2. $d > n$ 是否保证训练误差可以为零？

不保证。还需 $y \in \text{range}(X)$ ；满行秩可保证任意标签均可插值。

3. 损失若写成 $\|Xw - y\|^2/2$ ，步长如何变？

梯度不再含 $1/n$ ，稳定范围变成 $0 < \eta < 2/\sigma_1^2$ 。比较不同材料前必须先对齐损失约定。

4. 同样训练误差为零的两个解，在新数据上一定预测相同吗？

不一定。本章的二维例子已给出反例。

5. NTK 线性化得到的最小范数，是原参数还是参数位移？

这里是从零位移出发得到的最小位移范数，不能未经说明改为最终参数范数。

13.11 非线性参数化：同一个函数类，不同训练几何

来源：CS229M L15。考虑 $f_\beta(x) = (\beta \odot \beta)^\top x$ ，它对输入是线性的，但对训练参数是二次的。假设总体输入协方差为 I ，目标系数 $\theta^* = \beta^* \odot \beta^*$ ，取损失归一化为 $R(\beta) = \frac{1}{4}\|\beta^2 - \theta^*\|^2$ ，则

$$\nabla R(\beta) = \beta \odot (\beta^2 - \theta^*).$$

各坐标独立。在目标坐标 $\theta_j^* = 1$ ，小正初值按 $\beta_j^+ = \beta_j[1 + \eta(1 - \beta_j^2)]$ 增长；在非目标坐标 $\theta_j^* = 0$ ，按 $\beta_j^+ = \beta_j(1 - \eta\beta_j^2)$ 缓慢减小。零初始化会完全卡住，所以“小”与“零”不同。

若初始量级为 $\alpha > 0$ ，目标坐标到常数量级需约 $\eta^{-1} \log(1/\alpha)$ 步；非目标坐标仍小，整个向量近似稀疏。经验情形需用受限等距性质控制稀疏方向：

$$(1 - \delta)\|v\|^2 \leq n^{-1}\|Xv\|^2 \leq (1 + \delta)\|v\|^2 \quad \text{对指定稀疏度的 } v.$$

$n < d$ 时 $X^\top X/n$ 不可能在所有方向接近 I ，但可以在稀疏向量上接近。证明仍需保证经验轨迹不离开近似稀疏区，并控制梯度误差累积；不能只画出总体轨迹就宣布样本恢复定理成立。L15 的精确有限样本时间窗在转录中损坏，本书保留定性机制及上述可核查的总体递推，不伪造其常数。

13.12 对角网络：初始化如何连续改变隐式正则化

来源：CS229M L16 前半。补充完整推导。取 $\theta = u^2 - v^2$ (逐坐标)，初始化 $u_j(0) = v_j(0) = \alpha > 0$ ，训练平方损失 $\mathcal{L}(\theta) = \|X\theta - y\|^2/(2n)$ 。记 $g = \nabla_\theta \mathcal{L}$ 。对 (u, v) 做梯度流：

$$\dot{u}_j = -2u_j g_j, \quad \dot{v}_j = 2v_j g_j.$$

因此 $d(u_j v_j)/dt = 0$ ，恒等 $u_j v_j = \alpha^2$ 。进而

$$\dot{\theta}_j = 2u_j \dot{u}_j - 2v_j \dot{v}_j = -4(u_j^2 + v_j^2)g_j = -4\sqrt{\theta_j^2 + 4\alpha^4} g_j.$$

定义严格凸势函数

$$Q_\alpha(\theta) = \frac{1}{4} \sum_j \left[\theta_j \operatorname{arsinh}\left(\frac{\theta_j}{2\alpha^2}\right) - \sqrt{\theta_j^2 + 4\alpha^4} + 2\alpha^2 \right].$$

直接求导, $\partial_j Q_\alpha = \frac{1}{4} \operatorname{arsinh}(\theta_j/(2\alpha^2))$, $\partial_{jj} Q_\alpha = 1/[4\sqrt{\theta_j^2 + 4\alpha^4}]$, 所以

$$\frac{d}{dt} \nabla Q_\alpha(\theta(t)) = -g(t) = -\frac{1}{n} X^\top (X\theta - y).$$

从 $\theta(0) = 0$ 、 $\nabla Q_\alpha(0) = 0$ 出发, 任意时刻 $\nabla Q_\alpha(\theta(t)) \in \operatorname{range}(X^\top)$ 。若轨迹收敛到插值解 θ_∞ , 则它满足 $X\theta_\infty = y$ 且 $\nabla Q_\alpha(\theta_\infty) = X^\top \nu$ 。这正是凸问题 $\min Q_\alpha(\theta)$ s.t. $X\theta = y$ 的 KKT 条件 (乘子的符号可吸收), 严格凸性保证唯一最优。

大 α 、固定 θ 时, Taylor 展开给 $Q_\alpha(\theta) \approx \|\theta\|^2/(16\alpha^2)$, 偏向 ℓ_2 几何; 小 α 时主要增长项与 $\log(1/\alpha)\|\theta\|_1$ 成比例, 体现稀疏偏好。把函数的点态极限进一步变成最优解收敛还需要紧性/极限交换条件; 这里不跳过该区别。

这给出非常具体的答案: 即使可表示的线性函数类相同, 参数化和初始化尺度也能改变算法隐式最小化的复杂度。该推导使用连续梯度流, 有限步长并不精确保留 $u_j v_j$ 不变量。

13.13 一个可验算的有限样本稀疏轨迹版本

补充推导, 不冒充 L15 缺损时间窗的逐字复原。 取输入各坐标独立 Rademacher、目标 $\theta^* = e_1$ 。设 $C = X^\top X/n$, 则 $C_{jj} = 1$; Hoeffding 加 union bound 给概率至少 $1 - \delta_0$ 时

$$\max_{i \neq j} |C_{ij}| \leq \delta, \quad n \geq \frac{2}{\delta^2} \log \frac{2d^2}{\delta_0}$$

是一个保守充分规模。经验损失 $\widehat{R}(\beta) = \frac{1}{4}(\beta^2 - e_1)^\top C(\beta^2 - e_1)$, 梯度为 $\beta \odot C(\beta^2 - e_1)$ 。

写 $\beta = (a, z)$, 初始化所有坐标为 $\alpha > 0$ 。信号递推为

$$a^+ = a \left[1 + \eta(1 - a^2) - \eta \sum_{j>1} C_{1j} z_j^2 \right],$$

与总体递推的差至多 $\eta \delta \|z\|^2 a$ 。第 $i > 1$ 个坐标的增长因子最多

$$1 + \eta \delta (|a^2 - 1| + \|z\|^2),$$

因为其自身的 $-\eta z_i^2$ 项只抑制增长。只要 $a^2 \leq 2$ 、 $\|z\|^2 \leq 1/2$ 且步长足够小保证因子非负, 就有 $z_i(t) \leq \alpha e^{1.5\eta \delta t}$ 。若 $t \leq \log 2/(1.5\eta \delta)$, 则 $z_i \leq 2\alpha$, 并在 $4d\alpha^2 \leq 1/2$ 时闭合背景范数假设。

当 $a \leq 1/2$ 、 $\delta \leq 1/4$ ，信号每步增长因子至少 $1 + 5\eta/8$ ，因此在 $O(\eta^{-1} \log(1/\alpha))$ 步内到常数量级。之后在小步长下，它接近 $a^2 = 1$ 的稳定区域；扰动大小为 $O(\delta)$ ，故足够长但仍在背景受控窗口内，可达 $|a^2 - 1| = O(\delta)$ 。

关键兼容条件是 $\delta \log(1/\alpha)$ 足够小，并为后续收敛到 $O(\delta)$ 误差预留 $O(\eta^{-1} \log(1/\delta))$ 步。背景预测系数平方误差满足 $\sum_{j>1} z_j^4 \leq 16d\alpha^4$ 。于是这一机制给出目标误差的两个来源：信号扰动 $O(\delta^2)$ 与背景残留 $O(d\alpha^4)$ 。

这里明确展示了样本集中、信号增长、背景稳定和有效时间窗如何衔接。最后稳定区的离散收缩只给出阶数分析，未列出所有最优常数；也不把该简化版本当成任意稀疏度或任意输入分布的定理。

第十四章 分类中的隐式偏置：参数发散，方向趋向最大间隔

来源：CS229M L16 后半与 L18 约 00:17–00:39 的补完证明。明确补回跨讲内容。

14.1 为什么不能等一个有限参数最优解

对线性可分数据，存在 w 使所有 $y_i w^\top x_i > 0$ 。将它放大为 cw ，指数损失 $\sum_i e^{-cy_i w^\top x_i}$ 趋零，logistic 损失也趋零，但任意有限 c 的损失仍大于零。因此无正则化目标的下确界可能不在有限参数处取得。

算法参数范数发散不是自动“训练坏掉”；应研究单位方向和归一化间隔。但不同损失、步长和模型需分别证明，不能由可分性直接推出所有优化器都有同一方向。

14.2 软最小值如何逼近最差间隔

记 $a_i = y_i x_i$ ， $\gamma(w) = \min_i a_i^\top w / \|w\|$ 。取总和形式指数损失 $L(w) = \sum_i e^{-a_i^\top w}$ ， $q(w) = -\log L(w)$ 。因为最大一项为 $e^{-\min_i a_i^\top w}$ ，

$$\min_i a_i^\top w - \log n \leq q(w) \leq \min_i a_i^\top w.$$

除以 $\|w\|$ ，软间隔与真实间隔差至多 $\log n / \|w\|$ 。若用平均损失，常数项位置改变但机制相同。不能把 $-\log \sum_i \exp(-a_i^\top w / \|w\|)$ 与 $-\log \sum_i \exp(-a_i^\top w)$ 混为一谈。

14.3 指数损失梯度流的完整最大间隔证明

假设有限数据严格线性可分， u_* 是欧氏单位球上的最优间隔方向， $\gamma_* = \min_i a_i^\top u_* > 0$ 。梯度流满足

$$\dot{w} = -\nabla L(w) = \sum_i e^{-a_i^\top w} a_i =: g(w).$$

与 u_* 取内积：

$$\|g\| \geq u_*^\top g = \sum_i e^{-a_i^\top w} u_*^\top a_i \geq \gamma_* L(w). \quad (1)$$

沿梯度流， $\dot{L} = -\|g\|^2 \leq -\gamma_*^2 L^2$ ，故

$$\frac{1}{L(t)} \geq \frac{1}{L(0)} + \gamma_*^2 t.$$

所以 $L(t) \rightarrow 0$ 、 $q(t) \rightarrow \infty$ ，每个训练点的未归一化间隔都趋于无穷，参数范数也趋于无穷。有限数据下损失单调给 $\|g\| \leq (\max_i \|a_i\|)L(0)$ ，没有有限时间参数爆炸的问题。

接着

$$\dot{q} = -\dot{L}/L = \|g\|^2/L \stackrel{(1)}{\geq} \gamma_* \|g\| = \gamma_* \|\dot{w}\|.$$

积分并利用路径长大于端点距离：

$$q(t) - q(0) \geq \gamma_* \int_0^t \|\dot{w}(s)\| ds \geq \gamma_* (\|w(t)\| - \|w(0)\|).$$

除以 $\|w(t)\|$ ，得 $\liminf q(t)/\|w(t)\| \geq \gamma_*$ 。另一方面由软最小值界与 γ_* 定义， $q(t)/\|w(t)\| \leq \gamma(w(t)) \leq \gamma_*$ 。夹逼得到

$$\boxed{\gamma(w(t)) \rightarrow \gamma_*}.$$

若最优单位方向唯一，单位球紧性与连续性再推出 $w(t)/\|w(t)\| \rightarrow u_*$ ；有多个最优方向时，只能先得至最优方向集合的距离趋零，不能凭空指定一个。

14.4 能推广到哪里，不能推广到哪里

logistic 损失在正大间隔区尾部近似指数，相关方向收敛定理还需单独的步长和尾部分析，本节未用“近似”冒充其完整证明。带显式 ℓ_2 正则时通常有有限解，逐渐令正则趋零与固定正则下训练到收敛又是不同极限。

深齐次模型满足 $f_{c\theta}(x) = c^q f_\theta(x)$ 时，也可研究归一化间隔；但非凸参数几何意味着常只能保证最大间隔约束问题的驻点/KKT 性质，而不是全局最大间隔。不可分数据中损失也未必趋零，必须重新分解可分与不可分部分。

自检。上面哪一步使用严格可分性？为什么把 $\dot{q}$ 与路径长度比较，就能得到归一化间隔，而不必显式解微分方程？

第十五章 噪声的隐式正则化与曲率

来源：CS229M L17 全讲、L18 前半。课程自身将部分长期漂移分析标为启发式，本章保留这一边界。

15.1 先分清三种协方差

随机梯度写 $g_t = \nabla L(\theta_t) + \xi_t$ 。噪声协方差 $C(\theta) = \mathbb{E}_t[\xi_t \xi_t^\top]$ ，参数在局部附近的稳态协方差 S ，以及数据协方差，是不同对象。把它们都写成“方差”会让后面的 Hessian 关系失去意义。

15.2 一维二次目标：可以精确计算

局部目标 $L(x) = hx^2/2$, $h > 0$ ，更新 $x_{t+1} = (1 - \eta h)x_t - \eta \xi_t$ ，噪声独立中心化、方差 c 。若 $0 < \eta h < 2$ ，均值趋零，稳态方差满足

$$s = (1 - \eta h)^2 s + \eta^2 c, \quad s = \frac{\eta c}{2h - \eta h^2} \approx \frac{\eta c}{2h}.$$

标准差是 $O(\sqrt{\eta})$ ，方差是 $O(\eta)$ ；转录中两者有混用。固定非零步长下一般是围绕极小点波动，并非参数精确收敛到极小点。

15.3 多维 Lyapunov 方程

局部二次目标 $\frac{1}{2}x^\top Hx$ 、对称 $H \succ 0$ ，更新矩阵 $A = I - \eta H$ 。稳定时

$$S = ASA^\top + \eta^2 C, \quad HS + SH = \eta(C + HSH).$$

在小步长一阶近似下 $HS + SH \approx \eta C$ 。若 H, C 可同时对角化， $s_j \approx \eta c_j / (2h_j)$ 。一般不能随便写成 $S = \eta H^{-1}C/2$ ，因为矩阵未必交换。

若 H 有零方向且该方向有持续噪声，则对应随机游走通常没有有界稳态协方差。若噪声也完全不作用于该方向，它才可能保持初始分量。课程在限制子空间上分析，正是为处理这个区别。

15.4 高阶项如何产生平均漂移

局部启发式，非一般长期定理。在参考点附近令三阶导张量为 T ，则

$$\nabla L(x) = Hx + \frac{1}{2}T[x, x] + O(\|x\|^3).$$

中心化局部涨落协方差为 S 时，平均更新多出 $-\eta T : S/2$ ，第 i 坐标为 $-\eta \sum_{jk} T_{ijk} S_{jk}/2$ 。若局部把 S 视作常量， $T : S = \nabla \text{tr}(HS)$ ，看起来像沿某种曲率惩罚下降。

但实际 S 随位置变化，平均位置也可能偏移，长期时间尺度上小余项会累积；若对 $\text{tr}(H(\theta)S(\theta))$ 求导，还会出现 ∇S 项。因此不能由这一行就宣布“SGD 精确等于优化 $L + \lambda \text{tr} H$ ”。

15.5 Hessian 分解与标签噪声

对单样本损失 $\ell(f_\theta(x), y)$ ，标量输出链式法则给

$$\nabla_\theta^2 \ell = \ell''(f, y) \nabla f \nabla f^\top + \ell'(f, y) \nabla^2 f.$$

平方损失时 $\ell'' = 1$ 、 $\ell' = f - y$ ，所以在插值点第二项消失，经验 Hessian 为 $n^{-1} \sum_i \nabla f_i \nabla f_i^\top$ 。这是 Gauss-Newton 型分解，转录的“Gaussian decomposition”不准确。

若每次额外给标签加入独立零均值噪声 ζ ，梯度噪声中出现 $-\zeta \nabla f$ ；在上述局部条件下其协方差可能与 Hessian 成比例。若 $C = cH$ 且限制在正特征子空间，局部小步长稳态 $S \approx \eta c I/2$ ，从而前节平均高阶漂移与 $\nabla \text{tr} H$ 联系起来。这解释课程为何特意提“某种标签噪声”，而不是声称任意 mini-batch SGD 都有该正则项。

15.6 平坦性不是参数化不变的绝对质量

改变参数坐标会改变 Hessian 的数值尺度。相同函数用不同尺度表示，曲率可以变大或变小。曲率还要与噪声协方差、允许扰动度量以及函数输出敏感性一起讨论。平坦性可能提供有用线索，但“平坦一定泛化好、尖锐一定泛化差”不是本章定理。

L18 中权重层梯度为反向信号与前向激活的外积， $\nabla_w \ell = \delta h^\top$ ，其 Frobenius 范数平方为 $\|\delta\|^2 \|h\|^2$ 。因此约束 Jacobian 范数会同时联系前向表示和反向敏感性，衔接第 6、7 章。

自检。零曲率方向有噪声时为何不能使用稳态公式？ $C \propto H$ 和 $C \propto I$ 会产生相同参数涨落吗？

第五部分

序列、表示学习与实验方法

第十六章 序列模型、长期依赖与显式记忆

来源：花书 §10.1–10.12。本章保留原书的 RNN、门控与早期记忆模型范围，不把它改写为另一套 Transformer 教程。

16.1 递推与展开是同一个计算

基础 RNN 为 $a_t = Wh_{t-1} + Ux_t + b$, $h_t = \phi(a_t)$, 输出 $o_t = Vh_t + c$ 。递推写法简洁，展开后则是长度 T 的有向无环计算图，所有时间步共享 W, U, V 。可每步输出、只在终点输出，或由一个固定向量生成整个序列。

作为概率模型，自回归分解为 $p(y_{1:T} | x) = \prod_t p(y_t | y_{<t}, x)$ 。Teacher forcing 在训练时输入真实历史 $y_{<t}$ ，推理则通常使用已生成历史，造成上下文分布差异；这不意味着最大似然目标本身写错了。

条件信息可只初始化隐藏态，也可每步输入；二者对长期依赖的负担不同。确定性隐藏态是历史的计算摘要，不等于为每个时间步引入独立随机潜变量。

16.2 BPTT 的完整梯度递推

总损失 $L = \sum_t \ell_t(o_t)$ ，定义 $e_t = \partial \ell_t / \partial o_t$ 、 $\delta_t = \partial L / \partial a_t$ 。从终点向前：

$$\delta_t = (V^\top e_t + W^\top \delta_{t+1}) \odot \phi'(a_t), \quad \delta_{T+1} = 0.$$

当前状态影响当前输出和下一时刻两条路径，所以括号中是两者之和。参数梯度为

$$\nabla_W L = \sum_t \delta_t h_{t-1}^\top, \quad \nabla_U L = \sum_t \delta_t x_t^\top, \quad \nabla_V L = \sum_t e_t h_t^\top.$$

截断 BPTT 只传播有限时间跨度，降低内存与计算，但忽略更早的梯度路径，一般产生偏差；不是“完整梯度更快的等价算法”。

16.3 梯度消失与爆炸：连乘的后果

$$\frac{\partial h_t}{\partial h_s} = J_t J_{t-1} \cdots J_{s+1}, \quad J_t = \text{diag}(\phi'(a_t))W.$$

若每个 $\|J_t\|_{\text{op}} \leq q < 1$ ，乘积范数至多 q^{t-s} ，梯度指数衰减。若某些方向持续扩张则可能爆炸；仅有某一步谱范数大于 1 不足以证明整个乘积必爆炸，方向对齐也重要。

梯度裁剪 $g \leftarrow g \min(1, c/\|g\|)$ 控制一次更新幅度，却不能恢复已消失的远期信号。正交初始化有助控制线性部分的尺度，但激活导数和动态轨迹仍会改变实际 Jacobian。

16.4 常见结构各自解决什么

结构	机制	使用边界
双向 RNN	同时编码左、右上下文	实时因果生成不能读取未来
Encoder-decoder	变长输入编码，再生成变长输出	固定向量可能成为信息瓶颈
深 RNN	加深输入、状态转移、输出或堆叠层	深度与时间展开深度是两种轴
Recursive network	沿树结构合并子结点	需要树或组合结构，不同于时间链
Echo state network	固定循环储备池，只训练读出	历史表征依赖储备池；不是训练全部递归权重

Echo state 的关键是初始状态影响随历史消退，谱半径启发式并非任意非线性系统的充分必要条件。一个更直接的充分条件是状态转移对隐藏状态全局收缩。

16.5 多时间尺度与门控

Leaky unit: $h_t = (1 - \alpha)h_{t-1} + \alpha \tilde{h}_t$ 。当 α 小，旧信息衰减慢，典型时间尺度约 $1/\alpha$ 。跨时间跳连、不同频率更新或移除部分连接也能制造慢通道，但固定时间尺度不一定适合所有样本。

一个标准 LSTM 约定为

$$\begin{aligned} i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), & f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), & \tilde{c}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c), \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, & h_t &= o_t \odot \tanh c_t. \end{aligned}$$

沿显式记忆通道，局部直接导数为 $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$ （固定门的这条路径）。遗忘门接近 1 时可保留梯度；完整总导数还包含门对先前状态的依赖，因此不是“LSTM 永不梯度消失”。

GRU 用更新门在旧态与候选态间插值，重置门决定构造候选时读取多少旧态。一种约定为 $h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$ ，其他文献会交换 z_t 的含义，应先核对公式。

16.6 长期优化与记忆读写

除裁剪外，原书还讨论二阶方法以及鼓励反传范数保持的正则项。例如对特定梯度方向约束 $\|J_t^\top v\| / \|v\|$ 接近 1，目标是保持有用方向，不等于要求所有方向都扩张。

显式记忆将存储槽与读写控制分开：由查询与槽的相似度计算 softmax 权重，再作加权读出；写入可用擦除门与增量。可微寻址允许梯度学习访问规则，但容量、干扰和外推仍需分析。它是花书这一章的延伸，不应将早期 memory networks/可微外部存储与所有现代注意力机制完全等同。

自检。为什么 BPTT 对共享参数要跨时间求和？门接近 1 究竟保护了哪条导数路径？

第十七章 表示学习、高斯混合与矩方法

来源：花书 §15.1–15.6；CS229M L18 后半、L19 前半。神经表示学习与统计矩恢复分节处理，二者共享“利用结构”的思想但不是同一算法。

17.1 表示学习的六个要点

逐层无监督预训练先学习第一层表示，再把它作为下一层输入，最后用标签联合微调。它既可提供优化起点，也可能改变可到达解的偏好；历史上帮助过深网络训练，但不能据此把它当作所有现代任务的必经步骤。

迁移学习把源任务学到的信息用于目标任务；领域适应侧重分布变化。若仅 covariate shift，即 $p_t(y | x) = p_s(y | x)$ ，且目标支持包含于源支持，则

$$R_t(f) = \mathbb{E}_s \left[\frac{p_t(x)}{p_s(x)} \ell(f(x), y) \right].$$

条件分布也改变时，这个公式不再解决全部问题；权重过大也会显著增大方差。

半监督的聚类/流形假设将输入分布结构与标签联系起来。解耦表示希望不同坐标对应不同变化因素，但仅观察数据往往存在可逆变换的不识别性；需先验、监督、时间连续性或干预信息帮助选择，不能将“坐标看起来有意义”当作因果识别证明。

分布式表示用多个可组合特征表达概念， n 个 k 值特征最多有 k^n 个组合，而 one-hot 需要分别列出。组合数量不等于可可靠学习的语义数量。深度通过组合与复用实现某些函数的指数表示节省，受函数类别、激活和精度条件限制。

原书用于发现潜在因素的线索包括平滑性、多个解释因素、层级结构、共享任务、时间/空间一致性、稀疏性和低维流形等。每一条都是归纳偏好：如果任务违反它，可能损害性能。

17.2 高斯混合：参数恢复和聚类不同

设潜在类别 $H \sim \text{Cat}(\pi_1, \dots, \pi_k)$ ， $X | H = j \sim N(\mu_j, \sigma^2 I)$ 。目标可能是恢复均值/权重，也可能是给每个样本分配类别。即使参数完全恢复，分布重叠仍造成类别不确定性。

参数至多在类别置换下可识别。矩方法先估计 $\mathbb{E}[X^{\otimes r}]$ ，再反解参数；区别于直接迭代最大化混合似然。最大似然/EM 可作为实践比较，但本课程本段重点是矩与谱/张量分解。

17.3 对称双高斯：二阶矩已经足够

令 $X = S\mu + Z$ ， S 等概率取 ± 1 ， $Z \sim N(0, I)$ 独立。则

$$\mathbb{E}X = 0, \quad \mathbb{E}[XX^\top] = \mu\mu^\top + I.$$

展开后交叉项为零。总体二阶矩最大特征值为 $1 + \|\mu\|^2$ ，特征向量为 $\pm\mu/\|\mu\|$ ，因此恢复 μ 至符号。有限样本用 $\widehat{M}_2 = n^{-1} \sum_i X_i X_i^\top$ ；必须控制 $\|\widehat{M}_2 - M_2\|_{\text{op}}$ 相对于特征间隙 $\|\mu\|^2$ ，不能只控制每个元素而忽略维度。

若 $\mu = 0$ ，方向本来就不可识别。带噪样本估计最大特征值可能低于 1，幅度估计使用 $\sqrt{(\hat{\lambda}_1 - 1)_+}$ 是数值/模型约束处理，不代表总体公式改变。

17.4 为什么多分量的一二阶矩常不够

等权时令 $U = [\mu_1, \dots, \mu_k]$ ，则均值 $U\mathbf{1}/k$ 、去噪二阶矩 $UU^\top/k$ 。任何正交 Q 满足 $Q\mathbf{1} = \mathbf{1}$ ， UQ 保持这两个矩。当 $k \geq 3$ ，通常可在 $\mathbf{1}$ 的正交补旋转，得到不只是列置换的不同均值集合。

所以失败不是样本太少：即使准确知道这两个总体矩，也不能区分。需要更高阶矩或更强结构。

17.5 去噪三阶矩：逐坐标算出来

记 $m = \mathbb{E}X = \sum_j \pi_j \mu_j$ ，

$$M_2 = \mathbb{E}[XX^\top] - \sigma^2 I = \sum_j \pi_j \mu_j \mu_j^\top.$$

对三阶矩，展开 $X = \mu_H + Z$ 。只有含零个或两个 Z 的项期望非零，因此

$$\mathbb{E}[X_a X_b X_c] = \sum_j \pi_j \mu_{ja} \mu_{jb} \mu_{jc} + \sigma^2 (m_a \delta_{bc} + m_b \delta_{ac} + m_c \delta_{ab}).$$

减去后半部分定义张量 T ，得到 $T = \sum_j \pi_j \mu_j^{\otimes 3}$ 。噪声协方差未知或分量间不同，需要另估参数并修改公式，不能继续减一个固定 $\sigma^2 I$ 。

17.6 张量分解的可计算例子：白化与同时对角化

假设 $k \leq d$ 、均值线性独立、 $\pi_j > 0$ ，令 $W \in \mathbb{R}^{d \times k}$ 满足 $W^\top M_2 W = I$ 。设 $a_j = \sqrt{\pi_j} W^\top \mu_j$ ，则 $\sum_j a_j a_j^\top = I$ ，这些 k 个向量构成正交基。

白化后

$$T(W, W, W) = \sum_j \pi_j^{-1/2} a_j^{\otimes 3}.$$

选向量 r ，沿一维收缩成矩阵 $B_r = T(W, W, W)(I, I, r) = \sum_j \pi_j^{-1/2} (a_j^\top r) a_j a_j^\top$ 。若对应特征值互异，矩阵特征分解给出 a_j ；再计算三重收缩 $T(W, W, W)(a_j, a_j, a_j)$ 得 $\pi_j^{-1/2}$ （符号按正系数调整），从而恢复权重和均值。白化逆映射为 $(W^\top)^\dagger$ 在均值张成空间上的作用。

这给出原理清楚的可计算特殊情形。一般 CP 张量分解不是矩阵 SVD 的直接替代；对称三阶正交张量的幂迭代可用 $v \leftarrow T(I, v, v)/\|T(I, v, v)\|$ ，但随机起点、退化与 deflation 误差仍需控制。

17.7 过完备与有限样本：保留课程的边界

$k > d$ 时上述白化成 k 维正交基的方法失效。课程讨论三条路线：用更高阶矩把 $\mu_j^{\otimes 2}$ 当作新特征，利用四阶张量的特殊代数算法，或对随机分量作更强分布假设。高阶提升增加可区分分量，也提高矩估计的样本和计算成本。

“generic 可识别”“多项式时间可算”“对扰动稳定”是三项不同要求；精确张量分解成功不保证近似张量下鲁棒。课程转录中的过完备阈值和算法名存在缺字，本书不把它们作为经过验证的精确定理，保留路线、条件差异和适用意义。

同样流程可用于 ICA、HMM、topic models：先用相应独立结构构造矩，再化成分解问题。每个模型需要自己的矩恒等式，不能把高斯混合公式直接复制过去。

自检。一二阶矩不可识别与估计误差太大有什么区别？为什么有限样本矩方法需要鲁棒分解而不只是无噪声唯一分解？

第十八章 谱聚类：期望结构、随机扰动与图切割

来源：CS229M L19 后半、L20。补充展开扰动界、网格集中和 Cheeger 证明的核心链条。

18.1 平衡随机块模型

n 个结点等分两组，用 $s \in \{\pm 1\}^n$ 表示组别， $\mathbf{1}^\top s = 0$ 。组内边概率 p 、组间 q ， $p > q$ ，无自环，无向独立边。令 $\alpha = (p + q)/2, \beta = (p - q)/2$ ，则

$$\mathbb{E}A = \alpha \mathbf{1}\mathbf{1}^\top + \beta ss^\top - pI.$$

$-pI$ 修正零对角；省略它会改变特征值，但不改变特征向量。背景方向 $\mathbf{1}$ 的特征值为 $n\alpha - p$ ；群落方向 s 为 $n\beta - p$ ；其余方向为 $-p$ 。因此第二个代数最大特征向量携带分组信息。

若减去已知背景并加回对角修正， $B = A - \alpha \mathbf{1}\mathbf{1}^\top + pI = \lambda uu^\top + E, u = s/\sqrt{n}, \lambda = n\beta, E = A - \mathbb{E}A$ 。实际未知 p, q 时需要估计或使用归一化图方法，不能把真值背景当作已知输入而不说明。

18.2 一个可直接证明的特征向量扰动界

设 $B = \lambda uu^\top + E, \|u\| = 1, \lambda > 0, \|E\| \leq \lambda/2$ 。 $\hat{u}$ 为最大特征向量， $\hat{\lambda} \geq u^\top Bu \geq \lambda - \|E\|$ 。将特征方程投影到 $u^\perp$ ：

$$\hat{\lambda} P_{u^\perp} \hat{u} = P_{u^\perp} E \hat{u},$$

所以 $\sin \angle(\hat{u}, u) \leq \|E\|/(\lambda - \|E\|) \leq 2\|E\|/\lambda$ 。选整体符号后， $\|\hat{u} - u\|^2 \leq 2 \sin^2 \angle$ 。

真实每个坐标幅度为 $1/\sqrt{n}$ ；若按符号分组错误，该坐标平方误差至少 $1/n$ 。故误分比例至多 $\|\hat{u} - u\|^2$ ，量级为 $O(\|E\|^2/\lambda^2)$ 。这给弱恢复，不自动给零误分或逐坐标精确恢复。

18.3 为什么控制谱范数又回到一致收敛

对称矩阵 E 有 $\|E\| = \sup_{\|v\|=1} |v^\top E v|$ 。固定 v ,

$$v^\top E v = 2 \sum_{i < j} v_i v_j (A_{ij} - \mathbb{E} A_{ij}).$$

各项独立、区间长度为 $2|v_i v_j|$ ，长度平方和 $4 \sum_{i < j} v_i^2 v_j^2 \leq 2$ 。Hoeffding 给固定方向尾部 $2e^{-t^2}$ 的有效保守界。

取单位球的 $1/4$ 网格 N ， $|N| \leq 9^n$ 。若 v 是最大化方向、 v' 为近邻，则

$$|v^\top E v - v'^\top E v'| \leq 2\|v - v'\| \|E\| \leq \frac{1}{2} \|E\|,$$

故 $\|E\| \leq 2 \max_{v' \in N} |v'^\top E v'|$ 。Union bound 得概率至少 $1 - \delta$ 时

$$\|E\| \leq 2\sqrt{n \log 9 + \log(2/\delta)}.$$

这个粗界为 $O(\sqrt{n})$ ，适合展示稠密图分析。稀疏图中更精细结果需利用方差、度数与可能的正则化，不能用此界宣称达到稀疏恢复最优阈值。

18.4 一般图：先统一矩阵定义

对非负对称权重 A ，度数 $d_i = \sum_j A_{ij} > 0$ ， $D = \text{diag}(d_i)$ ：

$$L = D - A, \quad \mathcal{L} = I - D^{-1/2} A D^{-1/2}, \quad P = D^{-1} A.$$

L 是未归一化 Laplacian， $\mathcal{L}$ 是对称归一化版本， P 是随机游走转移。它们不是同一矩阵。孤立点须单独处理，不能除以零。

$\mathcal{L} D^{1/2} \mathbf{1} = 0$ 。任意 v 的能量为

$$v^\top \mathcal{L} v = \sum_{i < j} A_{ij} \left(\frac{v_i}{\sqrt{d_i}} - \frac{v_j}{\sqrt{d_j}} \right)^2.$$

因此低特征值对应相邻结点取值相近的变化模式。连通分量数等于零特征值重数；连通图的第二小特征向量反映最容易分开方向。

18.5 Cheeger: 谱值如何控制切割

定义 $\text{vol}(S) = \sum_{i \in S} d_i$, $\text{cut}(S, \bar{S}) = \sum_{i \in S, j \notin S} A_{ij}$,

$$\phi(S) = \frac{\text{cut}(S, \bar{S})}{\min(\text{vol } S, \text{vol } \bar{S})}, \quad \phi(G) = \min_S \phi(S).$$

对连通图, 记 λ_2 为 $\mathcal{L}$ 第二小特征值, 则

$$\frac{\lambda_2}{2} \leq \phi(G) \leq \sqrt{2\lambda_2}.$$

下界。对某切割取 $f = 1_S - \text{vol}(S)/\text{vol}(V)$, 满足 $\sum_i d_i f_i = 0$ 。Rayleigh 商为 $\text{cut}(S, \bar{S}) \text{vol}(V)/(\text{vol } S \text{vol } \bar{S}) \leq 2\phi(S)$ 。由变分定义 $\lambda_2 \leq R(f)$, 再对切割最小化。

上界的核心推导。令广义特征函数 $f = D^{-1/2}v_2$, $Lf = \lambda_2 Df$ 。取其按度数加权的中位数 m 。若 $m \leq 0$, 取 $g = (f - m)_+$; 若 $m \geq 0$, 取 $g = (m - f)_+$ 。选择非零的一侧, 其支撑体积至多全图一半。

以 $m \leq 0$ 为例, 截断单调性给

$$\sum_{i < j} A_{ij}(g_i - g_j)^2 \leq g^\top Lf = \lambda_2 \sum_i d_i g_i f_i \leq \lambda_2 \sum_i d_i g_i^2.$$

最后用 $f_i = g_i + m$ 且 $m \leq 0$ 。另一侧对 $-f$ 同理。

对阈值集合 $S_t = \{i : g_i^2 > t\}$, 积分恒等式 (逐边、逐点计算) 给

$$\int_0^\infty \text{cut}(S_t, \bar{S}_t) dt = \sum_{i < j} A_{ij} |g_i^2 - g_j^2|, \quad \int_0^\infty \text{vol}(S_t) dt = \sum_i d_i g_i^2.$$

于是至少一个阈值的 conductance 不大于两个积分之比。分子用 Cauchy-Schwarz:

$$\sum_{i < j} A_{ij} |g_i - g_j| |g_i + g_j| \leq \sqrt{\left[\sum_{i < j} A_{ij} (g_i - g_j)^2 \right] \left[2 \sum_i d_i g_i^2 \right]}.$$

除以分母, 得至多 $\sqrt{2\lambda_2}$ 。因此实际算法按 $v_{2,i}/\sqrt{d_i}$ 排序, 扫描所有相邻阈值, 选 conductance 最小的切割; 不是固定在零处切一刀就有同样保证。

18.6 谱嵌入与参数化表示

多簇时取若干最小 Laplacian 特征向量，把每个结点对应的行作为表示，再做聚类。必须说明是否包括平凡零特征向量、是否行归一化和图如何构造。图相似度若不反映语义，特征分解不会自动创造正确语义。

L20 后段还把谱表示与参数化低秩近似联系起来。对对称归一化邻接矩阵 $\bar{A}$ ，目标 $\|FF^\top - \bar{A}\|_F^2$ 展开为 $\|FF^\top\|_F^2 - 2\text{tr}(F^\top \bar{A}F) + \text{常数}$ ：第二项鼓励相似点内积大，第一项防止全部表示无限放大或塌成同一种无区分相似性。最优 PSD 秩约束近似保留最大的正特征值并取平方根缩放；负特征值不能直接开实平方根。

用 $F_i = f_\theta(x_i)$ 限制表示后，得到可对新样本求值的参数化模型，但优化变成新的问题，不能直接宣称任意网络训练等价于精确谱分解。

自检。谱恢复为什么要把扰动与特征间隙比较？Cheeger 的扫描阈值为什么作用在度数归一化后的坐标？

第十九章 实验设计、诊断与超参数选择

来源：花书 §11.1–11.6，连接本书统计与优化部分。

19.1 先定义成功，再选择代理损失

准确率适合类别相对平衡且错误代价近似的任务；不平衡任务需看 precision、recall、PR 曲线等。概率预测还看负对数似然与校准；序列任务需明确 token 平均还是序列平均。目标指标与训练损失不同是常态，但要能说明两者关系。

训练、验证、测试承担不同角色。重复使用测试结果选择模型，会把测试集变成隐性验证集。存在用户、时间或群组相关时，应按独立单位划分，不能简单随机打散后套 i.i.d. 泛化解释。

19.2 基线应尽快跑通端到端

先建立简单、可复现、与任务匹配的基线，确认数据读取、预处理、训练和评估接口。基线不是故意做弱的对照；它提供识别改进来源的参照。花书列举的具体默认架构属于其出版时期背景，本书保留决策方法，不据此宣称某个旧模型是当下最佳选择。

记录数据版本、划分、随机种子、损失归一化、batch、优化器、学习率计划、停止规则和所选 checkpoint。它们会改变结果，也是解释隐式偏置所必需的实验信息。

19.3 用曲线定位问题，而不是盲目换模型

现象	优先检查	可做的下一项受控实验
小训练子集也拟合不了	标签、损失、梯度、学习率、模型表达	关正则，在极小数据上过拟合
训练好、验证差	泄漏、分布差异、容量与正则、样本量	学习曲线、增强或正则强度对照
训练和验证都差	优化未成、表达不足、指标不匹配	与简单基线比较，改变单一瓶颈

现象	优先检查	可做的下一项受控实验
梯度/损失突然非有限	数值不稳定、坏样本、梯度爆炸	定位首个异常算子，检查 logits/范数
训练评估切换后剧变	dropout、BN、数据变换模式	同一批数据逐项固定对照

更多数据主要改善统计项；如果当前模型连训练集都拟合不好，先查优化与表示。训练好而验证差也不总意味着“只缺数据”，可能是划分或目标分布发生变化。

19.4 搜索超参数时控制比较成本

学习率与正则强度常跨数量级变化，用对数尺度比线性网格更合适。随机搜索在只有少数超参数真正重要时，能更有效覆盖重要维度；网格容易浪费在不重要轴上。基于模型的优化使用已完成试验拟合性能代理，并据此选下个配置，需要计入自身成本和评估噪声。

先粗范围找稳定区域，再局部细化；比较固定算力与固定 epoch 的结论分别报告。测试集只在最终选定后评估。若报告最优种子结果，必须说明选择过程；更可靠的是给多个种子的均值、波动和完整选择规则。

19.5 梯度与程序诊断

对小模型、双精度、平滑点做中心差分方向检查：

$$\frac{L(\theta + hv) - L(\theta - hv)}{2h} \approx \nabla L(\theta)^\top v.$$

h 太大有截断误差，太小有消减误差；ReLU 折点附近不要求两者像光滑函数那样吻合。再检查梯度范数、激活分布、参数更新相对幅度，以及共享参数是否正确累加。

消融实验一次改变一个机制，或采用明确设计的多因素实验。训练差异需要与数据处理、参数量、算力及选择次数对齐，否则无法将提升归因于新算法。

19.6 多位数字识别案例的可迁移逻辑

花书的案例从端到端任务出发，分别预测序列长度与各位置数字，并用置信标准处理整串结果。这提醒我们：单字符准确率高，不代表整串准确率同样高；长度错误也会破坏整个输出。合理流程是先明确输出结构和业务指标，再决定联合/分头建模、收集失败样本和评估拒识策略。

在科研复现中可沿用这套方法：把最终结论拆成可检查环节，首先确认整条流程正确，再优化最影响整体指标的瓶颈。不能只看一条下降训练曲线就宣布理论机制得到验证。

自检。为什么选择了最佳验证 checkpoint 后，验证误差不再是完全未使用数据上的评价？为什么固定 epoch 不一定是公平算力比较？

Appendix A 常用计算、证明步骤与自检答案

A.1 矩阵微分速查

标量函数	梯度（相对所示变量）	条件/说明
$a^\top x$	a	列向量约定
$x^\top Ax$	$(A + A^\top)x$	对称时为 $2Ax$
$\frac{1}{2}\ Ax - b\ ^2$	$A^\top(Ax - b)$	先查残差维度
$\text{tr}(A^\top X)$	A	Frobenius 内积
$\frac{1}{2}\ AXB - C\ _F^2$	$A^\top(AXB - C)B^\top$	微分配对读系数
$\log \det X$	$X^{-\top}$	可逆正定域上最常用
$\frac{1}{4}\ XX^\top - M\ _F^2$	$(XX^\top - M)X$	M 对称

若变量是矩阵，不必构造四阶 Hessian。对任意方向 V ，令 $g(t) = f(X + tV)$ ，计算 $g'(0)$ 、 $g''(0)$ ；第二个数就是 Hessian 在 V 方向的二次型。第 11 章采用了这个办法。

A.2 五种易混操作

1. $\mathbb{E} \sup_f Z_f \geq \sup_f \mathbb{E} Z_f$ ：先看随机结果再选有优势。逆向交换一般错。
2. $\mathbb{E}\|X\| \leq \sqrt{\mathbb{E}\|X\|^2}$ ：不是 $\mathbb{E}\|X\| = \|\mathbb{E}X\|$ 。
3. $\Pr(\cup_i A_i) \leq \sum_i \Pr(A_i)$ 不要求独立； $\mathbb{E} \prod_i Z_i = \prod_i \mathbb{E} Z_i$ 通常要求相应独立。
4. 对随机点 $\hat{\theta}(S)$ 使用集中界，需要一致事件、条件化的合法论证或算法专门分析，不能把它当成提前固定参数。
5. $\text{tr}(AB) = \text{tr}(BA)$ 不意味着 $AB = BA$ ；尤其在协方差方程中不能自由约去矩阵。

A.3 归一化换算

若 $L_1 = \frac{1}{2}\|Xw - y\|^2$ 、 $L_2 = L_1/n$ ，同一实际 GD 更新需 $\eta_2 = n\eta_1$ 。梯度流时间也按比例变化。经验核可定义为 $XX^\top$ 或 $XX^\top/n$ ，对应速率必须成套换算。

分类指数损失的 sum 与 mean 相差 n ; $-\log$ 后只差 $\log n$, 在归一化方向极限中消失, 但有限时间不等式常数不同。比较图表或证明前, 应把损失、核、步长统一到同一约定。

A.4 证明覆盖清单

结论	本书位置	呈现层级
三项误差控制	1.1	完整代数推导
渐近 sandwich 协方差与风险	1.3–1.4	条件明确的推导, 引用
二次型		CLT/Slutsky
Hoeffding、有限类与参数覆盖	2.1–2.4	完整主要步骤
McDiarmid	2.5	条件指数矩证明
高斯集中、单边敏感度加强版	2.6	引用结论, 不展开熵方法全证明
对称化与经验 Rademacher 泛化界	3.2–3.3	完整主要步骤
线性范数界、Massart、收缩引理	3.4–3.6	完整主要步骤
间隔界与 RKHS 范数控制	4	推导
Dudley 链式逼近	5.3	有限尺度证明与积分转换说明
Maurey 稀疏化、误差预算	5.5–5.6	完整主要步骤
两层范数泛化、全层间隔分解	7	推导; 精细逆间隔均值界为引用
岭与稀疏惩罚、噪声等价	8	明确模型下的精确计算
非凸 GD/SGD 一阶复杂度	10.2–10.3	完整推导
负曲率下降	10.4	带 Hessian-Lipschitz 余项推导
PCA/秩一因子化无坏极小	11.2–11.3	完整驻点分类
采样矩阵补全恢复	11.4–11.5	模型与导数、证明路线; 精确采样率不伪造
NTK 局部梯度流闭环	12.3	明确充分条件的完整证明
最小范数 GD、一般初始化、早停	13.1–13.10	SVD 完整推导
稀疏平方参数化	13.11	总体递推完整; 经验耦合为路线
对角网络初始化势函数	13.12	条件于插值收敛的完整推导
指数损失最大间隔	14.3	线性可分梯度流完整证明
噪声局部稳态	15.2–15.3	二次模型精确计算; 高阶漂移启发式
BPTT、Jacobian 连乘	16	完整基本递推

结论	本书位置	呈现层级
高斯混合矩、白化分解	17	指定模型的推导
谱扰动与误分率、网格集中	18.2–18.3	完整主要步骤
Cheeger 上下界	18.5	变分、截断、积分与 Cauchy–Schwarz 主链

A.5 各章自检简答

章	核心答案
1	总体一阶导在最优点为零，风险首项为参数误差的二次型；维度变化时需重新控制 CLT、Hessian 与余项
2	Union bound 来自指示函数次可加；上确界之差不超过逐函数差的上确界
3	经验复杂度只平均符号，总体再平均样本；非线性后续层仍可放大前层误差
4	模型缩放同时放大复杂度和间隔；参数差可落在训练特征零空间
5	Chaining 对每层细化付更小的增量代价；换度量要把所有覆盖半径乘/除 $\sqrt{n}$
6	同一参数影响损失的多条链式路径需要相加；似然与输出激活导数可消去中间分母
7	扰动每层才能吸收每层逼近误差；泛化界评估解，优化偏置解释为何选中该解
8	一般非线性存在高阶项；约束到惩罚的反向关系需要强对偶等条件
9	条件数是问题敏感性；不同 Hessian 特征方向允许的稳定步长不同
10	平台、鞍点和差局部极小都可小梯度；两种景观条件分别处理逃离与最优性
11	优化解依赖采样，需一致集中； $xx^\top$ 对 x 的正负不敏感
12	还要保证真实动力学留在近似区；首次退出反证与路径长上界完成闭环
13	GD 不动零空间；平方参数化与对角参数化改变有效坐标的更新度量

章	核心答案
14	可分性给正的 γ_* 与梯度下界；积分把软间隔增长与范数增长联系起来
15	零曲率不能恢复随机游走； $C \propto I$ 时稳态偏向低曲率方向， $C \propto H$ 时局部可近似各向同性
16	时间共享同一参数故累加；遗忘门保护显式细胞状态的直接路径
17	不可识别即无限样本仍有歧义；有限样本只能给近似矩，算法必须容忍扰动
18	小扰动若大于信号间隙也能改换主方向；归一化特征函数才与 conductance 的体积定义一致
19	已据验证值选择就付出选择偏差；不同模型每个 epoch 的计算量不同

Appendix B 材料覆盖与来源定位

B.1 材料盘点

课程 20 讲已按 Lecture 1–20 去重登记。表中时间为对应检索词的首个正文命中,是回到原材料的定位入口,不等于主题正式开始或结束。跨讲续讲内容另列。原始段落台账见 `source-ledger.json`。

B.1.1 Lecture 1

Stanford CS229M - Lecture 1: Overview, supervised learning, empirical risk minimization

主题	定位段	本书章节
监督学习与风险	00:00:00–00:00:35	第 1 章
ERM	00:11:21–00:11:49	第 1 章
一致性与渐近分析	00:04:37–00:05:12	第 1 章
Hessian 与参数展开	00:32:44–00:33:04	第 1 章
中心极限定理	00:53:00–00:53:33	第 1 章

B.1.2 Lecture 2

Stanford CS229M - Lecture 2: Asymptotic analysis, uniform convergence, Hoeffding inequality

主题	定位段	本书章节
渐近分布与 Fisher 信息	00:17:00–00:17:36	第 1 章
有限样本与渐近限制	00:25:50–00:26:22	第 1 章
一致收敛	00:00:47–00:01:19	第 2 章
Hoeffding	00:46:37–00:47:07	第 2 章

B.1.3 Lecture 3

Stanford CS229M - Lecture 3: Finite hypothesis class, discretizing infinite hypothesis space

主题	定位段	本书章节
有限假设类	00:02:22–00:02:47	第 2 章
Union bound	00:00:36–00:01:46	第 2 章
Lipschitz 参数化	00:29:57–00:30:51	第 2 章
覆盖与离散化	00:25:58–00:26:21	第 2 章

B.1.4 Lecture 4

Stanford CS229M - Lecture 4: Advanced concentration inequalities

主题	定位段	本书章节
次高斯	00:18:19–00:18:41	第 2 章
指数矩	00:16:51–00:17:24	第 2 章
有界差分	00:49:27–00:49:56	第 2 章
位置依赖敏感度	01:01:14–01:02:20	第 2 章
高斯集中与 Poincaré	00:06:38–00:07:05	第 2 章

B.1.5 Lecture 5

Stanford CS229M - Lecture 5: Rademacher complexity, empirical Rademacher complexity

主题	定位段	本书章节
复杂度定义与随机性	00:10:56–00:11:13	第 3 章
Ghost sample	00:43:21–00:43:51	第 3 章
对称化	00:42:27–00:43:01	第 3 章
高概率界	00:09:51–00:10:21	第 3 章
函数类与损失类	00:11:13–00:11:49	第 3 章

B.1.6 Lecture 6

Stanford CS229M - Lecture 6: Margin theory and Rademacher complexity for linear models

主题	定位段	本书章节
0-1 损失与间隔	00:12:21–00:12:59	第 4 章
Ramp surrogate	00:16:03–00:16:25	第 4 章
收缩引理	00:26:40–00:26:57	第 3 章
线性范数界	00:00:12–00:00:43	第 3 章

主题	定位段	本书章节
不同范数几何	01:07:08–01:07:31	第 3 章

B.1.7 Lecture 7

Stanford CS229M - Lecture 7: Challenges in DL theory, generalization bounds for neural nets

主题	定位段	本书章节
表达、优化与泛化的挑战	00:00:00–00:00:22	第 7 章
通用逼近	00:20:08–00:21:08	第 6 章
隐式偏好	00:34:49–00:35:37	第 13 章
两层网络粗界	00:59:12–00:59:31	第 7 章

B.1.8 Lecture 8

Stanford CS229M - Lecture 8: Refined generalization bounds for neural nets, Kernel methods

主题	定位段	本书章节
精细两层复杂度	00:04:13–00:04:41	第 7 章
路径范数	00:15:24–00:15:52	第 7 章
核与固定特征	00:00:48–00:01:20	第 4 章
覆盖输出空间	00:00:00–00:00:19	第 5 章

B.1.9 Lecture 9

Stanford CS229M - Lecture 9: Covering number approach, Dudley Theorem

主题	定位段	本书章节
有限类 Massart 引理	00:01:23–00:01:46	第 3 章
覆盖数	00:05:12–00:05:54	第 5 章
链式逼近	00:11:40–00:12:34	第 5 章
线性模型熵界	01:09:38–01:10:18	第 5 章

B.1.10 Lecture 10

Stanford CS229M - Lecture 10: Generalization bounds for deep nets

主题	定位段	本书章节
层复合与覆盖	00:00:29–00:01:07	第 7 章
覆盖半径与后续放大	00:00:29–00:01:07	第 7 章
各层误差预算	00:20:03–00:20:27	第 5 章
深度与范数依赖	00:02:52–00:04:07	第 7 章

B.1.11 Lecture 11

Stanford CS229M - Lecture 11: All-layer margin

主题	定位段	本书章节
数据依赖类的陷阱	00:12:02–00:12:35	第 7 章
广义间隔	00:19:58–00:20:17	第 7 章
全层扰动定义	00:18:29–00:19:09	第 7 章
复杂度分解	00:52:59–00:53:51	第 7 章
平均逆间隔	00:54:41–00:55:44	第 7 章

B.1.12 Lecture 12

Stanford CS229M - Lecture 12: Non-convex optimization, Non-convex opt for PCA, matrix complexion

主题	定位段	本书章节
非凸驻点与优化难度	00:05:04–00:06:18	第 10 章
严格鞍点	00:23:51–00:24:11	第 10 章
PCA 因子化	00:40:50–00:41:45	第 11 章
方向 Hessian	00:50:52–00:51:18	第 11 章
矩阵补全及不相干性	00:40:50–00:41:45	第 11 章

B.1.13 Lecture 13

Stanford CS229M - Lecture 13: Neural Tangent Kernel

主题	定位段	本书章节
参数 Taylor 展开	00:08:43–00:09:09	第 12 章
Jacobian 特征与伪逆	00:33:48–00:34:14	第 12 章
局部近似误差	00:46:22–00:46:56	第 12 章

主题	定位段	本书章节
初始化尺度	00:28:08–00:28:24	第 12 章
宽度与核区间	00:28:08–00:28:24	第 12 章

B.1.14 Lecture 14

Stanford CS229M - Lecture 14: Neural Tangent Kernel, Implicit regularization of gradient descent

主题	定位段	本书章节
输出残差递推	00:10:35–00:11:02	第 12 章
参数移动范围	00:00:31–00:00:58	第 12 章
核与特征学习局限	00:00:00–00:00:31	第 12 章
最小范数隐式偏置	00:00:00–00:00:31	第 13 章

B.1.15 Lecture 15

Stanford CS229M - Lecture 15: Implicit regularization effect of initialization

主题	定位段	本书章节
平方参数化与稀疏真值	00:03:25–00:03:48	第 13 章
非零小初始化	00:00:00–00:00:49	第 13 章
受限等距与总体经验比较	00:07:30–00:08:19	第 13 章
信号和背景坐标	00:04:54–00:05:23	第 13 章
轨迹耦合误差	00:39:23–00:40:23	第 13 章

B.1.16 Lecture 16

Stanford CS229M - Lecture 16: Implicit regularization in classification problems

主题	定位段	本书章节
梯度流	00:02:10–00:02:34	第 13 章
对角网络正负平方	00:06:22–00:06:48	第 13 章
初始化势函数	00:16:08–00:16:43	第 13 章
分类损失与间隔	00:00:18–00:00:47	第 14 章

B.1.17 Lecture 17

Stanford CS229M - Lecture 17: Implicit regularization effect of the noise

主题	定位段	本书章节
优化噪声	00:00:00–00:00:08	第 15 章
二次局部模型	00:04:25–00:04:59	第 15 章
参数协方差	00:23:36–00:24:05	第 15 章
三阶漂移	00:44:41–00:45:06	第 15 章
标签噪声和 Hessian 迹	01:25:39–01:25:59	第 15 章

B.1.18 Lecture 18

Stanford CS229M - Lecture 18: Unsupervised learning, mixture of Gaussians, moment methods

主题	定位段	本书章节
Gauss–Newton Hessian 分解	00:03:26–00:03:59	第 15 章
层梯度外积	00:02:24–00:02:52	第 6 章
最大间隔证明续篇	00:16:40–00:17:31	第 14 章
高斯混合	00:06:56–00:07:27	第 17 章
一二阶矩不可识别	00:41:53–00:42:25	第 17 章

B.1.19 Lecture 19

Stanford CS229M - Lecture 19: Mixture of Gaussians, spectral clustering

主题	定位段	本书章节
三阶矩与噪声修正	00:00:20–00:00:43	第 17 章
CP 张量分解	00:02:16–00:02:43	第 17 章
过完备与鲁棒性	00:34:31–00:35:06	第 17 章
谱聚类与相似度图	00:00:20–00:00:43	第 18 章
SBM 期望谱	00:51:50–00:54:00	第 18 章
特征向量扰动	01:23:59–01:24:21	第 18 章

B.1.20 Lecture 20

Stanford CS229M - Lecture 20: Spectral clustering

主题	定位段	本书章节
随机矩阵谱集中	00:01:14–00:01:44	第 18 章
网格与一致控制	00:09:05–00:09:38	第 18 章
图归一化与 Laplacian	00:33:45–00:34:16	第 18 章
Conductance 与 Cheeger	00:16:55–00:18:11	第 18 章
扫描阈值切割	00:14:58–00:15:54	第 18 章
谱表示与低秩参数化	01:05:22–01:05:43	第 18 章

B.2 花书小节覆盖

下表列出指定章节中提取出的编号小节。条目落到现有正文主题；“覆盖”不表示所有历史例子逐字复制或所有引用定理全证明。

花书小节	原目录标题	本书落点
4.1	Overflow and Underflow	9、10、13、附录 A
4.2	Proor Conditioning	9、10、13、附录 A
4.3	Gradient-Based Optimization	9、10、13、附录 A
4.3.1	Beyond the Gradient: Jacobian and Hessian Matrices	9、10、13、附录 A
4.4	Constrained Optimization	9、10、13、附录 A
4.5	Example: Linear Least Squares	13.2–13.5
6.1	Example: Learning XOR	6
6.2	Gradient-Based Learning	6
6.2.1	Cost Functions	6
6.2.1.1	Learning Conditional Distributions with Maximum Likelihood	6
6.2.1.2	Learning Conditional Statistics	6
6.2.2	Output Units	6
6.2.2.1	Linear Units for Gaussian Output Distributions	6
6.2.2.2	Sigmoid Units for Bernoulli Output Distributions	6
6.2.2.3	Softmax Units for Multinoulli Output Distributions	6
6.2.2.4	Other Output Types	6

花书小节	原目录标题	本书落点
6.3	Hidden Units	6
6.3.1	Rectified Linear Units and Their Generalizations	6
6.3.2	Logistic Sigmoid and Hyperbolic Tangent	6
6.3.3	Other Hidden Units	6
6.4	Architecture Design	6
6.4.1	Universal Approximation Properties and Depth	6
6.4.2	Other Architectural Considerations	6
6.5	Back-Propagation and Other Differentiation	6.4–6.5、附录 A
6.5.1	Computational Graphs	6.4–6.5、附录 A
6.5.2	Chain Rule of Calculus	6.4–6.5、附录 A
6.5.3	Recursively Applying the Chain Rule to Obtain Backprop	6.4–6.5、附录 A
6.5.4	Back-Propagation Computation in Fully Connected MLP	6.4–6.5、附录 A
6.5.5	Symbol-to-Symbol Derivatives	6.4–6.5、附录 A
6.5.6	General Back-Propagation	6.4–6.5、附录 A
6.5.7	Example: Back-Propagation for MLP Training	6.4–6.5、附录 A
6.5.8	Complications	6.4–6.5、附录 A
6.5.9	Differentiation outside the Deep Learning Community	6.4–6.5、附录 A
6.5.10	Higher-Order Derivatives	6.4–6.5、附录 A
6.6	Historical Notes	6
7.1	Parameter Norm Penalties	8
7.1.1	L2 参数惩罚	8
7.1.2	L1 参数惩罚	8
7.2	Norm Penalties as Constrained Optimization	8
7.3	Regularization and Under-Constrained Problems	8

花书小节	原目录标题	本书落点
7.4	Dataset Augmentation	8
7.5	Noise Robustness	8
7.5.1	Injecting Noise at the Output Targets	8
7.6	Semi-Supervised Learning	8
7.7	Multitask Learning	8
7.8	Early Stopping	8.4、13.9
7.9	Parameter Tuning and Parameter Sharing	8
7.9.1	Convolutional Neural Networks	8
7.10	Sparse Representations	8
7.11	Bagging and Other Ensemble Methods	8
7.12	Drop out	8
7.13	Adversarial Training	8
7.14	Tangent Distance, Tangent Prop and Manifold	8
8.1	How Learning Differs from Pure Optimization	9、10、15
8.1.1	Empirical Risk Minimization	9、10、15
8.1.2	Surrogate Loss Functions and Early Stopping	9、10、15
8.1.3	Batch and Minibatch Algorithms	9、10、15
8.2	Challenges in Neural Network Optimization	9、10、15
8.2.1	Ill-Conditioning	9、10、15
8.2.2	Local Minima	9、10、15
8.2.3	Plateaus, Saddle Points and Other Flat Regions	9、10、15
8.2.4	Cliffs and Exploding Gradients	9、10、15
8.2.5	Long-Term Dependencies	9、10、15
8.2.6	Inexact Gradients	9、10、15
8.2.7	Pro or Correspondence between Local and Global Structure	9、10、15

花书小节	原目录标题	本书落点
8.2.8	Theoretical Limits of Optimization	9、10、15
8.3	Basic Algorithms	9、10、15
8.3.1	Stochastic Gradient Descent	9、10、15
8.3.2	Momentum	9、10、15
8.3.3	Nesterov Momentum	9、10、15
8.4	Parameter Initialization Strategies	9、10、15
8.5	Algorithms with Adaptive Learning Rates	9、10、15
8.5.1	AdaGrad	9、10、15
8.5.2	RMSProp	9、10、15
8.5.3	Adam	9、10、15
8.5.4	Choosing the Right Optimization Algorithm	9、10、15
8.6	Approximate Second-Order Methods	9.2、9.6
8.6.1	Newton's Method	9.2、9.6
8.6.2	Conjugate Gradients	9.2、9.6
8.6.3	BF-GS	9.2、9.6
8.7	Optimization Strategies and Meta-Algorithms	9、10、15
8.7.1	Batch Normalization	9、10、15
8.7.2	Coordinate Descent	9、10、15
8.7.3	Polyak Averaging	9、10、15
8.7.4	Supervised Pretraining	9、10、15
8.7.5	Designing Models to Aid Optimization	9、10、15
8.7.6	Continuation Methods and Curriculum Learning	9、10、15
10.1	Unfolding Computational Graphs	16
10.2	Recurrent Neural Networks	16
10.2.1	Teacher Forcing and Networks with Output Recurrence	16
10.2.2	Computing the Gradient in a Recurrent Neural Network	16

花书小节	原目录标题	本书落点
10.2.3	Recurrent Networks as Directed Graphical Models	16
10.2.4	Modeling Sequences Conditioned on Context with RNNs	16
10.3	Bidirectional RNNs	16
10.4	Encoder-Decoder Sequence-to-Sequence	16
10.5	Deep Recurrent Networks	16
10.6	Recursive Neural Networks	16
10.7	The Challenge of Long-Term Dependencies	16
10.8	Echo State Networks	16
10.9	Leaky Units and Other Strategies for Multiple	16
10.9.1	Adding Skip Connections through Time	16
10.9.2	Leaky Units and a Spectrum of Different Time Scales	16
10.9.3	Removing Connections	16
10.10	The Long Short-Term Memory and Other Gated	16
10.10.1	LSTM	16
10.10.2	Other Gated RNNs	16
10.11	Optimization for Long-Term Dependencies	16
10.11.1	Clipping Gradients	16
10.11.2	Regularizing to Encourage Information Flow	16
10.12	Explicit Memory	16
11.1	Performance Metrics	19
11.2	Default Baseline Models	19
11.3	Determining Whether to Gather More Data	19
11.4	Selecting Hyperparameters	19
11.4.1	Manual Hyperparameter Tuning	19

花书小节	原目录标题	本书落点
11.4.2	Automatic Hyperparameter Optimization Algorithms	19
11.4.3	Grid Search	19
11.4.4	Random Search	19
11.4.5	Model-Based Hyperparameter Optimization	19
11.5	Debugging Strategies	19
11.6	Example: Multi-Digit Number Recognition	19
15.1	Greedy Layer-Wise Unsupervised Pretraining	17
15.1.1	When and Why Does Unsupervised Pretraining Work?	17
15.2	Transfer Learning and Domain Adaptation	17
15.3	Semi-Supervised Disentanglement of Causal Factors	17
15.4	Distributed Representation	17
15.5	Exponential Gains from Depth	17
15.6	Providing Clues to Discover Underlying Causes	17

B.3 可核对的辅助来源

- [花书官方目录及完整在线版](#)：本书限定 7 章。
- [STATS214 / CS229M 官网](#)：确认双课程编号，链接往届 scribe notes。
- [课程作者维护的讲义仓库](#)：用于公式交叉核对；不同学期，不能按课号机械对齐。
- [全层间隔原论文](#)：核对定义、复杂度分解与逆间隔均值版本。
- [van Handel 的高维概率讲义](#)：L4 所引用的单边有界差分与高斯集中工具。

辅助材料只用于校对或明确标注的补充，不把课程官网 “if time permits” 的在线学习内容当作上传 20 讲已经讲过。

Appendix C 校对记录、来源边界与补充说明

C.1 如何处理原材料

上传的 20 个 HTML 中提取到 3342 段编辑正文。检索台账保留每段课次、时间戳、短摘录和关键词命中；重复 ASR 不作为第二份课程内容计数。花书指定范围提取到 128 个带编号目录层级条目，全部登记到覆盖表。

这些计数证明材料清单和索引的完整性，**不证明每一段转录都已逐词无误**。本书按理论条目重构，并对写入正文的核心等式独立推导。视频画面、音频和引用的相对图片未随 HTML 一同上传；台账中的图片缺失计数是引用次数，不是独立图片数量。

官网将 STATS214 与 CS229M 列为同一门课的两个编号。官网链接的 2021 往届讲义用于交叉核对，不能仅凭相似内容将上传视频年份或编号与其完全等同。往届源码含作者标明“可能有误、待修”的条目，因此仍需检查，不能因为叫讲义就直接照录。

C.2 已修正或明确化的主要问题

来源位置	问题	本书处理
L1 关于唯一极小与 Hessian 的口头讨论	唯一性不蕴含 Hessian 可逆	第 1 章补 x^4 反例，单列正定条件
L1-L2 渐近梯度展开	移项符号与求导点有混乱	用积分 Hessian 展开，保留负号
L2 的 $p/(2n)$	随机风险与期望主项混用	区分分布极限及一致可积条件
L4 次高斯/高斯工具	方差、代理、梯度上界与期望不能混用	第 2 章逐一定义，并区分引用结论
L5 复杂度随样本数的讨论	不存在无条件 $n^{-1/2}$ 统一下界	给单函数类与完全拟合类对照
L6 约 01:18-01:21	$\{\pm e_i\}$ 数量被转成 2^d	改为 $2d$ ，相应使用 $\log(2d)$
L6 的线性界	多余维度因子与根号位置疑点	从对偶范数独立计算两种范数界
L6 多处引理名	“Telegram/Taylor gradient”等转录	统一为 Rademacher 收缩引理，不臆造新定理

来源位置	问题	本书处理
L9 覆盖半径	经验度量归一化易漏 $\sqrt{n}$	全书使用 $\ q - q'\ /\sqrt{n}$
L10 分组范数	“2-to-1”与 2,1 混用	明确分组范数定义，不冒充诱导范数
L11 泛化解释	小间隔只让保证变松，不推出必泛化差	第 7 章明确上界不可反向推断
L12 标题	matrix complexion	正文证据确认改为 matrix completion
L12 与往届矩阵补全笔记	证明使用候选不相干性，简略定理未完整交代	第 11 章将景观迁移写成条件明确的推导
往届 NTK 源码	随机初始化必有好条件数的引理含作者待修注	不采用；第 12 章把最小奇异值作为显式条件
L14 约 00:09–00:15	残差递推符号、矩阵乘法和收缩因子损坏	第 12–13 章由平方损失重新推导
L14 约 00:54–00:56	ReLU 乘积例子省掉绝对值/系数	第 12 章给可逐点验证的四神经元恒等式
L15 有限样本定理	时间窗、初始化和误差幂次转录不完整	不声称精确复原；增加条件明确的秩一轨迹版本
L16 正负平方模型	Hadamard 被转成 antisymmetric product	统一逐坐标乘积 $\odot$ ，推导势函数
L17 局部噪声	稳态标准差与方差量级混用	方差 $O(\eta)$ 、标准差 $O(\sqrt{\eta})$
L17 高阶漂移	老师明确仅为启发式	标出协方差变化及高阶项，保留条件边界
L18 开头	“Gaussian decomposition”	改为 Gauss–Newton 型 Hessian 分解
L18 最大间隔续篇	容易按主题标题漏掉	完整并入第 14 章
L19–L20 图矩阵	自环对角与不同 Laplacian 容易混淆	第 18 章给全部定义和对角修正
L20 低秩近似	PSD 因子化不能开负特征值平方根	保留最大正特征值并明确条件
花书 §4.2	一般矩阵条件数不能用任意特征值比	第 9 章使用奇异值比，对称正定时再简化

C.3 没有伪装成完整证明的内容

高斯集中及熵方法加强界、精细均值逆间隔泛化界、带完整采样率和全局区域保证的矩阵补全定理、任意稀疏度的精确经验动力学、一般非线性 SGD 长期曲率漂移、过完备张量分解的最优阈值，均保留为引用/证明路线/来源限制。

这些内容已经有机制与条件讲解，部分还补了可完全验证的特殊情形；不能因此标成“每个研究定理均已证明”。其余主要基础推导的完成层级见附录 A。若之后取得同版本的正式板书或缺失媒体，可在这些明确位置继续精确校对，无需重写全书。

C.4 与原阶段清单的对应

原清单	本版结果
逐讲梳理并细化来源	完成 20 讲主题映射、3342 段检索台账，跨讲续篇单列；不是逐字转录认证
花书逐小节覆盖	7 章、128 个编号层级登记到正文，历史方法保留机制短节
统计与优化主体扩写	第 1–5、9–15 章均已成文；完整保留并扩展原样章
网络、序列、无监督、实践扩写	第 6–8、16–19 章均已成文，包含矩方法和 Cheeger 主证明
统一可导航版本	离线 HTML、合并 Markdown、分章文件与索引台账；具体文件检验见附录 D

Appendix D 交付检查与使用说明

版本说明。本附录以下内容保留自原版 v1, 属于**历史交付记录**。其中离线 HTML、KaTeX 解析数量及数值实验结果均指原版；本次没有重跑原版数学实验。本次 Quarto 迁移的检查结果见项目 `docs/migration.md`。

D.1 已完成的实际工作

- ☑ 阅读与组织 20 讲的 3342 段编辑正文，生成逐段来源台账。
- ☑ 对花书指定七章建立 128 个编号小节的覆盖索引。
- ☑ 写成预备章与第 1—19 章正文，补充主要理论推导、假设、反例边界与自测。
- ☑ 将来源覆盖、疑似转写问题、证明状态分开记录。
- ☑ 生成可离线阅读、带目录和整章关键词筛选的 HTML，以及合并 Markdown 和分章文件。

“完成”指上述交付项完成，不代表原始视频逐词校对或每篇引用论文的所有证明已经重写。原材料未附的媒体无法核验；精确研究定理中仅作引用的部分，正文和附录 A 已标明。

D.2 核心数学交叉检查

以下数值检查帮助发现符号和常数错误，不能替代理论证明。

检查	结果
秩一因子化梯度与 Hessian 的有限差分	最大误差约 1.04×10^{-8}
一般初始化梯度下降与闭式极限	误差约 3.6×10^{-15}
对角网络势函数链式法则与乘积不变量	误差约 2.22×10^{-16}
噪声协方差离散 Lyapunov 不动点	残差约 2.78×10^{-17}
12 个随机小型加权图穷举切割	Cheeger 上下界均通过

D.3 阅读顺序

首次学习依次阅读 0—10 章，再进入隐式偏置、核近似、无监督学习等专题。复习时从附录 B 找到某讲或花书小节，返回相应正文，先检查假设，再自行推导，最后核对答案。对只给条件式结论或证明概要的研究定理，应继续阅读其原始来源。

HTML 中的公式和字体均内嵌。外部来源链接需要联网访问；正文阅读与搜索不需要。Markdown 的公式显示取决于阅读器是否支持 LaTeX。

D.4 文件验收结果

- 24 个章节 / 附录文档已合并；1187 处数学表达式通过 KaTeX 严格语法解析，没有遗留占位符。
- 目录内部链接全部具有对应目标，未发现重复锚点；公式字体与样式内嵌。
- 当前环境缺少浏览器，浏览器下载失败，因此未完成截图级视觉验收与浏览器内搜索交互验证。页面采用响应式布局，但不同设备的实际排版仍可能有差异。