

深度强化学习笔记

从 Bellman 方程到离线 RL 与语言模型策略优化

目录

前言与阅读导航	1
第一部分 决策问题与经典基础	2
第一章 决策问题与算法地图	3
第二章 价值函数、Bellman 方程与动态规划	6
第三章 未知环境：MC、TD 与表格控制	9
第四章 多步估计、资格迹与重要性采样	12
第二部分 从表格到深度价值学习	15
第五章 函数近似与深度 RL 的不稳定性	16
第六章 DQN 与离散动作控制	18
第三部分 直接优化策略	20
第七章 策略梯度与 REINFORCE	21
第八章 Actor-Critic、优势估计与 GAE	24
第九章 稳定策略改进：自然梯度、TRPO 与 PPO	26
第四部分 正则化、推断与连续控制	29
第十章 最大熵 RL 与控制即推断	30
第十一章 连续动作：DDPG、TD3 与 SAC	33
第五部分 示范、模型与固定数据	36
第十二章 模仿学习：BC、分布偏移与 DAgger	37
第十三章 规划、模型式 RL 与世界模型	39

第十四章 离线 RL：覆盖、保守性与 IQL	42
第十五章 生成式策略、FQL 与离线到在线	45
第六部分 奖励学习与语言模型	47
第十六章 逆 RL、偏好学习与奖励模型	48
第十七章 语言生成的 RL 建模与后训练	51
第十八章 LLM 策略优化：PPO、GR-REINFORCE 与 GRPO	54
第七部分 探索、泛化、理论与实验	57
第十九章 探索、信息获取与无奖励技能学习	58
第二十章 多任务、目标条件、层次与 Meta-RL	60
第二十一章 强化学习理论：误差、采样与保证边界	63
第二十二章 实验方法、实现诊断与开放问题	67
参考文献	70
附录	72
附录 A 符号与数学工具	72
附录 B 算法速查与实现工具箱	74
附录 C 材料覆盖与来源定位	76
附录 D 校订记录与结论边界	79

前言与阅读导航

这份笔记以 CS285 Spring 2026 为现代深度强化学习主线，以 shuhuai008 的强化学习白板推导补足经典基础。正文按知识依赖重排为七篇、22 章，从决策建模和 Bellman 递推一直延伸到离线 RL、LLM 策略优化、技能发现和多任务学习。

每章从要解决的问题出发，给出条件与公式、关键推导、小例子、算法数据流及自测答案。

七篇主线

篇	章节	要回答的问题
决策与经典基础	1-4	如何描述目标、估计价值、复用轨迹
深度价值学习	5-6	表格变成网络后为什么不稳定
直接优化策略	7-9	如何估计梯度并控制更新幅度
正则化与连续控制	10-11	熵、推断和连续动作如何连接
示范、模型与固定数据	12-15	如何利用专家、模拟和离线数据
奖励与语言模型	16-18	评价从哪里来，怎样优化生成策略
探索、迁移与理论	19-22	如何获得新信息、迁移经验和验证结论

三条阅读路线

基础路线：1-9 → 10-11；先贯通价值估计与策略改进，再掌握 DQN、PPO、SAC。

数据与控制路线：基础 → 12-15 → 19-20；第 12 章 BC 可在第 1 章后提前读，以配合课程作业。

LLM 路线：1-4、7-9 → 第 10 章 KL 正则部分 → 16-18。第 21 章随证明回访，第 22 章从第一次实验开始使用。

第一部分

决策问题与经典基础

第一章 决策问题与算法地图

学习层级：A。必须能够把一个实际任务写成状态、动作、转移、奖励和目标；POMDP 的完整求解留到后文。材料入口：CS285 L1、L4；白板 MDP p1-p3。

1.1 为什么监督学习还不够

预测标签时，通常先给定数据，再优化预测误差。控制机器人时，今天向左还是向右会改变明天看见的数据；某个动作的好坏可能几步之后才显现。强化学习因此同时面对**决策影响数据分布**和**延迟信用分配**。奖励是评价信号，不是每一步应采取的动作标签。

设想小车从起点出发。可以立即退出拿 1 分，也可以花一步走到岔路，再选择拿 3 分或 0 分。只看即时奖励会退出；比较未来回报才可能选择继续。

1.2 MDP：哪些信息足以预测未来

离散时间 MDP 写为 $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma)$ 。状态 S_t 、动作 A_t 产生转移 (R_{t+1}, S_{t+1}) ， P 描述下一状态分布， $r(s, a)$ 是一步奖励条件均值。随机策略 $\pi(a | s)$ 给出动作分布。

马尔可夫性是充分性条件：给定当前状态和动作，更早历史不再改变下一步的条件分布。它不是说“现在不受过去影响”，而是说过去的预测信息已压缩在状态中。

观察 O_t 不一定就是状态。单张位置图像可能看不出速度；若未来依赖速度，仅用位置就不满足马尔可夫性。可以堆叠历史、学习记忆，或显式维护隐藏状态信念。POMDP 的策略应依赖观察历史或足够的记忆状态。

有限状态是额外假设，不能从“离散状态”直接推出。任务若有有限剩余时间，而最优动作依赖剩余时间，就应把时间纳入状态，或使用非平稳策略 π_t 。

1.3 回报、目标和时域

有限幕终止于 T 时，定义

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1}, \quad J(\pi) = \mathbb{E}_{S_0 \sim \rho_0, \pi}[G_0].$$

无限时域通常取 $0 \leq \gamma < 1$ 并假设奖励有界，使回报绝对可积。 γ 规定任务如何权衡时间，不只是训练技巧。若 $|R| \leq R_{\max}$ ，则 $|G_t| \leq R_{\max}/(1 - \gamma)$ 。

有限幕可以取 $\gamma = 1$ ；无限循环却可能产生无穷回报。平均奖励问题另有目标，不能直接套用本书折扣公式。

轨迹 $\tau = (s_0, a_0, r_1, s_1, \dots)$ 的概率由初始分布、策略和环境共同决定。假设环境转移不含策略参数，忽略奖励随机性记号，

$$p_{\theta}(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t | s_t) P(s_{t+1} | s_t, a_t).$$

这条分解是后续策略梯度的起点。

1.4 贯穿基础篇的小 MDP

状态	动作	奖励	下一状态
起点 s_0	退出	1	终止
起点 s_0	继续	0	岔路 s_1
岔路 s_1	好动作	3	终止
岔路 s_1	坏动作	0	终止

取 $\gamma = 0.9$ 。若在岔路均匀选择，两动作平均回报是 1.5，从起点继续的价值是 1.35，高于退出的 1。若岔路永远选好动作，继续价值为 2.7。同一个“继续”动作的价值依赖后续策略。

后文的 Bellman、MC、TD 和策略改进都可以在这个例子上手算。终止状态价值约定为 0。

1.5 算法分类是多个坐标

分类轴	两端的区别	例子
预测 / 控制	评估固定策略 / 寻找更好策略	TD 预测 / Q-learning
Model-free / model-based	直接学价值策略 / 使用环境模型	SAC / MPC
On-policy / off-policy	目标与采样策略是否一致	标准 REINFORCE / Q-learning
Online / offline	能否继续与环境交互	在线 SAC / IQL
价值 / 策略	主要学习对象不同	DQN / PPO

Off-policy 不等于 offline, Actor-Critic 也不必是 on-policy。回放缓冲区是一种数据组织方式,不能单靠“有没有回放”判断算法属于哪一类。

1.6 本章工具箱与自测

必须掌握:先写目标,再选算法;区分观察与状态、奖励与动作标签、折扣与学习率。只需有印象:POMDP 信念更新,后见章节 二十。

题: 小车在同一位置可能向左或向右高速运动,位置能否作为状态? **答:** 如果下一位置依赖速度,位置不足;加入速度或能推断速度的历史。**题:** 在线收集数据的 Q-learning 能否是 off-policy? **答:** 能,采样的探索策略可不同于目标中的贪心策略。

第二章 价值函数、Bellman 方程与动态规划

学习层级：A。 必须会从回报递推得到 Bellman 方程，并区分评估、改进与最优性。材料：白板 MDP p3–p5、DP p1–p5；CS285 L4、L7、L20。

2.1 价值是对未来策略的条件期望

定义 $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$, $Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$ 。 Q 固定当前动作，之后仍跟随 π 。优势

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s), \quad V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a).$$

所以 $\mathbb{E}_{a \sim \pi} A^\pi(s, a) = 0$ 。优势比较的是动作与“该状态下当前策略的平均水平”，不是与奖励零点比较。

2.2 从回报递推到期望方程

由 $G_t = R_{t+1} + \gamma G_{t+1}$ ，先对下一状态条件化，再用全期望公式：

$$\begin{aligned} Q^\pi(s, a) &= \mathbb{E}[R_{t+1} + \gamma G_{t+1} \mid s, a] \\ &= r(s, a) + \gamma \sum_{s'} P(s' \mid s, a) V^\pi(s'), \\ V^\pi(s) &= \sum_a \pi(a \mid s) \left[r(s, a) + \gamma \sum_{s'} P(s' \mid s, a) V^\pi(s') \right]. \end{aligned}$$

这是一组同时约束所有状态价值的方程，并不是“价值必须等到未来真实发生后才有定义”。随机变量的期望可以在观察结果前定义。

固定策略后，令 $P^\pi(s, s') = \sum_a \pi(a \mid s) P(s' \mid s, a)$ 、 $r^\pi(s) = \sum_a \pi(a \mid s) r(s, a)$ ，得到

$$V^\pi = r^\pi + \gamma P^\pi V^\pi, \quad V^\pi = (I - \gamma P^\pi)^{-1} r^\pi.$$

折扣条件下逆存在，因为 $\sum_{k \geq 0} \gamma^k (P^\pi)^k$ 收敛并等于该逆。计算时可以解线性方程组，不必显式求逆。

2.3 迭代评估与压缩

把右侧看作算子 $\mathcal{T}^\pi V = r^\pi + \gamma P^\pi V$ 。由于概率加权平均不会超过最大绝对值，

$$\|\mathcal{T}^\pi V - \mathcal{T}^\pi W\|_\infty \leq \gamma \|V - W\|_\infty.$$

因此每次用新估计更新 $V_{k+1} = \mathcal{T}^\pi V_k$ ，误差至多缩小为原来的 γ 倍。这里需要精确期望和全状态更新；样本/函数逼近版本另行分析。

2.4 为什么贪心改进有效

选择新策略 π' ，使每个状态满足

$$\mathcal{T}^{\pi'} V^\pi(s) = \mathbb{E}_{a \sim \pi'} Q^\pi(s, a) \geq V^\pi(s).$$

贪心选择 $\pi'(s) \in \arg \max_a Q^\pi(s, a)$ 满足此条件，因为最大值不小于原策略的加权平均。利用 Bellman 算子的单调性，

$$V^\pi \leq \mathcal{T}^{\pi'} V^\pi \leq (\mathcal{T}^{\pi'})^2 V^\pi \leq \dots \rightarrow V^{\pi'}.$$

所以 $V^{\pi'} \geq V^\pi$ 。注意 $\arg \max$ 给出动作， $\max$ 给出数值。该证明使用精确 Q^π ，并不保证用少量样本估出来的贪心策略每轮都进步。

2.5 策略迭代与价值迭代

策略迭代交替进行：评估 π_k 得到 V^{π_k} ；根据其 Q 值改进得到 π_{k+1} 。有限 MDP 中采用一致的平局处理，可在有限个策略之间到达最优策略。

最优 Bellman 算子直接把策略平均换成最大化：

$$V^*(s) = \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right].$$

价值迭代反复应用这个右侧算子。关键不等式 $|\max_i x_i - \max_i y_i| \leq \max_i |x_i - y_i|$ 仍给出 γ 压缩。策略迭代充分评估再改进；价值迭代每次只做一步最优 backup。广义策略迭代允许评估和改进交错，不要求每轮完全评估。

2.6 小例子：一轮评估与改进

在章节一的小 MDP, 设两状态都均匀选动作。 $V^\pi(s_1) = 1.5$; $Q^\pi(s_0, \text{继续}) = 1.35$, $Q^\pi(s_0, \text{退出}) = 1$, 故 $V^\pi(s_0) = 1.175$ 。新策略在起点继续、岔路选好动作, 实际价值成为 $V^{\pi'}(s_0) = 2.7$ 。

若从全零开始同步价值迭代, 第一轮 $V_1(s_1) = 3, V_1(s_0) = 1$; 第二轮 $V_2(s_0) = \max(1, 0.9 \times 3) = 2.7$ 。奖励信息需要沿转移向前驱传播。




图 2.1: 同步价值迭代将岔路奖励传播到起点。

2.7 工具箱与自测

固定策略用期望方程, 求最优用最优方程; 模型已知可做 DP, 模型未知转向采样。**题:** 初始 $V_0(s_0) = 0$, 能否只看第一轮价值迭代就认定退出最优? **答:** 不能, 远期奖励尚未传播到起点。**题:** 若神经网络拟合 Bellman 目标, 压缩证明是否自动保留? **答:** 不保留, 回归映射也参与更新, 见章节 五与章节 二十一。

第三章 未知环境：MC、TD 与表格控制

学习层级：A。必须能对同一条轨迹写出不同算法的目标。材料：白板 MC、TD、SARSA、Expected SARSA、Q-learning 系列。

3.1 没有转移模型，如何求期望

DP 需要知道转移概率。实际只能走一次、看到一个后继状态时，就用样本逼近期望。对某个状态的价值估计 $V(s)$ ，通用增量更新为

$$V(s) \leftarrow V(s) + \alpha[\text{目标} - V(s)].$$

目标来自完整真实回报时是 Monte Carlo；目标中含已有价值预测时是自举。 α 是学习率，与折扣 γ 的角色不同。

3.2 Monte Carlo：等结果回来

每幕结束后计算 G_t ，更新 $V(S_t) \leftarrow V(S_t) + \alpha(G_t - V(S_t))$ 。若按状态访问计数令 $\alpha = 1/N(s)$ ，就是样本平均。

First-visit MC 每幕只取状态第一次出现的回报；every-visit 使用每次出现。一次轨迹内的样本一般相关，不能将 every-visit 的所有回报当作独立样本套浓缩不等式。固定策略、适当可积性与重复访问条件下可以讨论一致性。

MC 不依赖下一状态价值，因此没有自举偏差；但漫长轨迹中的所有随机性都进入回报，方差可能很高。非终止任务还需要截断或其他处理。

3.3 TD(0)：先用一个预测补上未来

TD 误差定义为

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t), \quad V(S_t) \leftarrow V(S_t) + \alpha \delta_t.$$

真正终止时下一状态价值取零。这个目标只需要一步经验，能立刻更新；但当 V 不准确时，目标也有误差。不能把“通常较低方差”写成所有任务中严格方差更小的定理。

同轨迹计算。在小 MDP 走“继续、好动作”，奖励依次为 0、3， $\gamma = 0.9$ 。假设 $V(s_0) = 0, V(s_1) = 1, \alpha = 0.1$ 。起点 MC 目标为 2.7，更新至 0.27；TD 目标为 0.9，更新至 0.09。二者差别来自“未来用真实回报还是当前预测”。

3.4 从预测到控制

学习 Q 后，行为策略可以用 ϵ -greedy：大部分概率选贪心动作，小部分概率随机探索。下面都对当前 (S_t, A_t) 做 $Q \leftarrow Q + \alpha(y - Q)$ ，区别在目标 y 。

方法	非终止转移的目标	后续动作含义
SARSA	$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$	A_{t+1} 按行为/目标策略采样
Expected SARSA	$R_{t+1} + \gamma \sum_a \pi(a S_{t+1}) Q(S_{t+1}, a)$	对指定目标策略精确求和
Q-learning	$R_{t+1} + \gamma \max_a Q(S_{t+1}, a)$	目标为贪心后续行为

SARSA 学习当前探索策略的价值，所以会把将来的探索风险算进去。Q-learning 可以用探索策略采样，却以贪心后续行为为目标，因此是 off-policy；不需要先有回放缓冲区才成为 off-policy。

Expected SARSA 可以是 on-policy，也可以是 off-policy。仅当目标策略贪心时，其期望等于 max。例：Q 为 (1,3)，均匀目标策略的期望是 2，无论行为策略是否与它相同，都不能写成最大值 3。

3.5 MC 控制与探索条件

MC 控制也可交替进行：收集轨迹、用回报评估 Q 、令策略偏向高 Q 动作。Exploring Starts 假设每个状态动作都能以正概率成为初始对，现实中往往无法随意设置起点； ϵ -soft 策略是另一种保证持续探索的思路。

常见表格收敛讨论要求：每个相关状态动作被无限访问，逐对学习率满足 $\sum_n \alpha_n = \infty, \sum_n \alpha_n^2 < \infty$ ，奖励有界，并满足相应时域条件。SARSA 的最优控制结论还常使用 GLIE：无限探索、极限贪心。固定 $\epsilon > 0$ 的 SARSA 不应被描述为收敛到无探索的最优策略。

3.6 实现顺序与自测

SARSA 先在下一状态采样 A_{t+1} ，它同时参与目标并成为下一步实际动作；不要更新时采一个动作、执行时又独立采一个却仍声称严格复现同一算法。终止转移不再访问无意义的下一动作。

题：MC 为什么不能仅用一条没结束的轨迹得到完整回报？**答：**未来奖励尚未观察；但可以构造自举或截断估计。**题：**持续随机探索是不是越多越好？**答：**它有助覆盖，但牺牲当前回报；衰减速度又影响是否充分访问，需与任务目标区分。

第四章 多步估计、资格迹与重要性采样

学习层级：A/B。掌握 n-step、概率比及支持集条件；资格迹先掌握机制。材料：白板策略 MC；CS285 L6、L9、L21。一般数学衔接为本书补写。

4.1 把“一步预测”和“完整回报”连起来

当轨迹还剩至少 n 步，定义

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k R_{t+k+1} + \gamma^n V(S_{t+n}).$$

若先到终止，只累加到终止，省略尾部价值。一阶是 TD，延长 n 会增加真实奖励所占比例，减少对远期估计的依赖，同时暴露更多轨迹随机性。不存在对所有环境都最好的 n 。

取两步轨迹奖励 $(0, 3)$ 、 $\gamma = 0.9$ 、 $V(s_1) = 1$ ，则起点一步目标为 0.9，两步目标为 2.7。它们并不是同一个数据的两种等价写法，而是不同估计器。

4.2 λ -return 与后向资格迹

若剩余 $N = T - t$ 步，有限幕前向 λ -return 为

$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{N-1} \lambda^{n-1} G_t^{(n)} + \lambda^{N-1} G_t.$$

权重和为 1。 $\lambda = 0$ 选一步， $\lambda = 1$ 选完整回报，中间值混合不同预测长度。不要把最后一项也乘 $1 - \lambda$ ，否则有限幕权重丢失。

表格累积资格迹用

$$e_t(s) = \gamma \lambda e_{t-1}(s) + \mathbf{1}\{S_t = s\}, \quad V(s) \leftarrow V(s) + \alpha \delta_t e_t(s).$$

它让当前 TD 误差回传给近期访问过的状态。前向/后向严格等价需说明更新约定；固定参数或离线视角最清楚，朴素在线 TD(λ) 与参数不断变化的前向目标不能不加条件地说完全相等。

4.3 为什么异策略数据需要概率比

对目标分布 p 、采样分布 q ，只要 $p(x) > 0$ 的地方都有 $q(x) > 0$ ，

$$\mathbb{E}_p[f(X)] = \sum_x q(x) \frac{p(x)}{q(x)} f(x) = \mathbb{E}_q[w(X)f(X)].$$

比值纠正哪些事件被过多或过少采到。没有支持集覆盖时，不存在“给没采到过的事件乘一个很大权重”就恢复信息的方法。

策略评估中环境动力学相同，轨迹概率比的环境项相消。状态价值回报的权重为

$$\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k | S_k)}{b(A_k | S_k)}.$$

评估 $Q^\pi(s, a)$ 时，当前动作已条件固定，后续回报比值从 $t+1$ 开始；不要机械多乘一次当前动作比。

4.4 普通、加权与逐决策估计

普通 IS 估计 $N^{-1} \sum_i \rho_i G_i$ ；在合适条件下无偏，但长轨迹乘积可能产生巨大方差。自归一化估计为

$$\widehat{V}_{\text{WIS}} = \frac{\sum_i \rho_i G_i}{\sum_i \rho_i},$$

分母非零时定义。它一般有限样本有偏，但常更稳定；一致性仍需要覆盖和可积性等条件。有效样本量诊断 $N_{\text{eff}} = (\sum_i w_i)^2 / \sum_i w_i^2$ 只能提示权重集中，不是估计必然正确的证据。

逐决策 IS 用截至该奖励之前的比值：

$$\widehat{G}_t = \sum_{k=t}^{T-1} \gamma^{k-t} \rho_{t:k} R_{k+1}.$$

未来动作不会影响已获得奖励，所以无需给早期奖励乘上更晚的概率比。截断权重降低极端值影响，同时引入偏差，需明确采用什么修正方法。

4.5 动作修正不等于状态修正

目标联合占用写为 $d^\pi(s)\pi(a | s)$ 。从 $d^b(s)b(a | s)$ 转换时，精确比值包含

$$\frac{d^\pi(s) \pi(a | s)}{d^b(s) b(a | s)}.$$

只乘动作比，可以在固定的采样状态分布下纠正动作期望，却不能自动把状态分布换成目标策略的分布。PPO 的局部代理目标会利用“小步更新时状态分布变化较小”的思想，见章节九；它不是完整轨迹 IS 的恒等替代。

4.6 工具箱与自测

先写“从哪个分布采样、要估计哪个分布”，再写概率比。**题：**两动作目标均匀，行为概率 (0.9, 0.1)，动作奖励分别 (1, 3)，权重是多少？**答：** (5/9, 5)，加权期望 $0.9 \cdot (5/9) \cdot 1 + 0.1 \cdot 5 \cdot 3 = 2$ ，等于目标期望。第二个动作的稀少样本也会主导方差。

第二部分

从表格到深度价值学习

第五章 函数近似与深度 RL 的不稳定性

学习层级：A。先理解更新对象和梯度路径，再讨论稳定化技巧。材料：CS285 L7–8、L20；线性投影与双采样解释为补充。

5.1 为什么不能继续存一张表

图像状态和连续状态无法逐个枚举。用 $V_\theta(s)$ 或 $Q_\theta(s, a)$ 将经验共享给相似输入：一次更新能改变许多未见状态的预测。这既是泛化能力，也是误差扩散的来源。

线性表示 $V_\theta(s) = \phi(s)^\top \theta$ 便于分析；神经网络同时学习表示与数值。训练分布 μ 决定哪些误差被重视，回放上的低误差不代表所有可能状态上的低误差。

5.2 拟合价值不是普通固定标签回归

监督回归标签通常固定。TD 的目标 $y = r + \gamma V_\theta(s')$ 自己也依赖当前预测。若每一步都把目标当常数，更新为

$$\theta \leftarrow \theta + \alpha [r + \gamma V_\theta(s') - V_\theta(s)] \nabla_\theta V_\theta(s).$$

这是**半梯度**：只对被拟合的当前预测求导，不沿目标求导。若对样本平方 TD 残差完整求导，得到

$$\nabla_\theta \frac{1}{2} \delta_\theta^2 = \delta_\theta [\gamma \nabla_\theta V_\theta(s') - \nabla_\theta V_\theta(s)].$$

两者优化过程不同。完整梯度并不自动“更正确”：样本残差平方与期望 Bellman 残差平方也不是同一目标。

5.3 双采样问题从哪里来

设 $m_\theta(s) = \mathbb{E}[Y_\theta | s] - V_\theta(s)$ ，目标是 $m_\theta(s)^2$ 。其梯度含 $\mathbb{E}[Y_\theta | s] \mathbb{E}[\nabla Y_\theta | s]$ 。直接用同一个下一状态同时估计两项，会得到乘积的期望而非期望的乘积，通常多出协方差项。独立抽取两个下一状态可以消除这个问题，但真实环境未必允许从同一状态动作独立重采。

因此不能仅凭“把 detach 去掉”宣称实现了理想 Bellman 残差优化。

5.4 投影改变了算子

有限函数类只能近似目标。理想化 fitted iteration 写为

$$V_{k+1} = \Pi_{\mu} \mathcal{T}^{\pi} V_k,$$

其中 Π_{μ} 是按数据分布进行回归的投影。 $\mathcal{T}^{\pi}$ 在无穷范数中压缩，不代表 $\Pi_{\mu} \mathcal{T}^{\pi}$ 在相同范数中压缩。度量、数据分布和函数类必须一起分析。

“函数近似、自举、off-policy”并存称为 deadly triad：这是一组可能造成发散的因素，不是说三者同时出现就必然发散。深度 RL 常主动使用三者，再用稳定化设计控制问题，而不是消除所有风险。

5.5 一个直观失败情景

数据只覆盖状态左侧区域；网络在右侧未见状态外推出很高 Q。贪心策略偏向右侧动作，backup 又把这个高值传播回数据内状态。训练误差甚至可以下降，因为网络正越来越好地拟合自己的过高目标。离线 RL 将在章节 十四专门处理这种反馈。

三个常见技巧针对不同环节：回放减少短期样本相关并复用数据；目标网络减慢标签变化；双 Q 减轻 max 利用噪声的过估计。它们不是通用收敛证明。

5.6 实现检查与自测

每个损失都标出输入分布、被更新参数、冻结参数和目标。在 Critic 更新时通常冻结 bootstrap 目标；在 Actor 更新时可冻结 Critic 参数，但必须保留 Q 对动作输入的梯度，否则 Actor 学不到方向。

题：冻结 Critic 参数与把整个 $Q(s, \pi(s))$ 放进 no-grad 是否相同？**答：**不同。前者仍可把梯度沿动作传回 Actor，后者切断全部路径。**题：**DQN 的 target network 是否让问题变为永久固定标签回归？**答：**只在一段更新内相对固定，之后标签仍会变化。

第六章 DQN 与离散动作控制

学习层级：A。必须会写目标和训练循环；变体以机制比较为主。材料：CS285 L7-8、Section 4；白板 Q-learning。

6.1 从 Q-learning 到批量回归

离散动作网络输出每个动作的 Q 值。收集经验 (s, a, r, s', m) ， $m = 0$ 表示真正终止，其他可继续状态取 1。目标网络参数为 $\bar{\theta}$ ，DQN 目标与损失是

$$y = r + \gamma m \max_{a'} Q_{\bar{\theta}}(s', a'), \quad L_Q = \mathbb{E}_{\mathcal{D}} [\ell(Q_{\theta}(s, a) - \text{sg}(y))].$$

sg 表示停止梯度。 ℓ 可取平方或 Huber 损失；后者对大残差的梯度增长更温和。目标网络可每 C 步硬复制，或用 $\bar{\theta} \leftarrow (1 - \tau)\bar{\theta} + \tau\theta$ 慢速更新，二者不要混淆系数约定。

6.2 一轮数据流

用 `epsilon-greedy(Q)` 选择动作，与环境交互
把转移及真正的下一观察写入 `replay`
达到最小数据量后采样 `minibatch`
用 `target Q` 计算 `y`；切断 `y` 的梯度
只拟合被执行动作的 $Q(s, a)$ ，更新在线 Q
按预定频率更新 `target Q`
单独运行评估策略，记录环境交互数和回报

选择动作时用 online Q ，计算 backup 时用 target Q 。回放让样本可复用，但历史数据来自旧行为策略；Q-learning 的 off-policy 结构使这一点可行，不意味着任意算法都能无修正地使用 replay。

6.3 为什么最大化会过估计

若两个动作真实价值都为 0，各自估计存在零均值噪声，则 $\mathbb{E}[\max(\widehat{Q}_1, \widehat{Q}_2)] \geq 0$ 。最优动作选择倾向挑中误差向上的那个。Double DQN 把动作选择与估值分开：

$$a^* = \arg \max_a Q_\theta(s', a), \quad y_{\text{double}} = r + \gamma m Q_{\bar{\theta}}(s', a^*).$$

例如在线 Q 为 (2, 5)、目标 Q 为 (4, 3)，DQN 用目标最大值 4，Double DQN 先选第二动作，再用目标值 3。它减轻一种偏差，不保证估值总是无偏；两个网络也并非真正统计独立。

6.4 终止、时间截断与自动重置

若达到任务的吸收终点，未来回报确实为零，mask 为 0。若仅因采样器的最大步数截断，而原任务还可继续，一般仍需 bootstrap。有限时域任务若时间耗尽就是任务终止，则应为 0，并确保状态或价值含剩余时间。

自动重置环境可能返回下一幕的初始观察。应使用截断/终止前的 final observation 计算需要 bootstrap 的目标，不可跨幕连起来。该错误常使训练表面正常，却学到错误价值。

6.5 常见变体放在什么位置

Dueling 架构写 $Q(s, a) = V(s) + A(s, a) - |\mathcal{A}|^{-1} \sum_b A(s, b)$ ，用中心化固定 V/A 分解的不唯一性。优先回放偏向大 TD 误差样本，会改变采样分布，通常结合权重修正；权重实现和目标分布必须说明。Distributional RL 预测回报分布而非仅均值，不是分布式计算。

大动作空间中遍历 max 很贵，连续动作中通常无法直接枚举，转入章节 十一的 Actor-Critic 路线。

6.6 小例子与检查清单

取 $r = 1, \gamma = 0.9, m = 1$ ，前述 Double DQN 目标为 $1 + 0.9 \times 3 = 3.7$ ；若真正终止则为 1。一次 batch 应核对所取动作索引、目标形状、reward dtype、mask 方向和目标梯度。

题：为什么 Q 值突然上升而评估回报下降值得警惕？**答：**可能出现过估计反馈或数据外推，Q 预测不是独立绩效证据。先查目标、终止语义和评估，再考虑加大网络。

第三部分

直接优化策略

第七章 策略梯度与 REINFORCE

学习层级：A。必须能推导 likelihood-ratio 梯度并说明 baseline 条件。材料：CS285 L5、L9；白板策略近似、策略梯度定理、REINFORCE。

7.1 直接改变动作概率

Q-learning 先评价再贪心。策略梯度直接让获得较好结果的动作更可能发生，适合随机策略与连续动作。困难在于环境通常不可微，不能把最终回报沿整个真实世界反向传播。

先考虑固定有限时域、未折扣目标 $J(\theta) = \mathbb{E}_{\tau \sim p_\theta}[R(\tau)]$ 。在可交换微分与积分且支持条件合适时，

$$\begin{aligned}\nabla J &= \int R(\tau) \nabla p_\theta(\tau) d\tau \\ &= \mathbb{E}_{p_\theta}[R(\tau) \nabla \log p_\theta(\tau)] \\ &= \mathbb{E} \left[R(\tau) \sum_t \nabla \log \pi_\theta(A_t | S_t) \right].\end{aligned}$$

环境概率没有消失，它仍决定采样分布；只是它不依赖 θ ，因此对数导数为零。我们不需要显式知道该概率。

7.2 因果性：过去奖励不用给未来动作记功

给定到时刻 t 的历史，动作分布的 score 期望为

$$\mathbb{E}_{A_t \sim \pi_\theta}[\nabla \log \pi_\theta(A_t | S_t)] = \nabla \sum_a \pi_\theta(a | S_t) = 0.$$

所以将 $R(\tau)$ 中时刻 t 之前的奖励乘以这个 score，条件期望为零。可将完整轨迹回报换成 reward-to-go，减少无关噪声。

若目标是起点折扣回报 $J = \mathbb{E} \sum_t \gamma^t R_{t+1}$ ，且 G_t 从 t 重新计折扣，精确表达是

$$\nabla J = \mathbb{E} \sum_t \gamma^t \nabla \log \pi_\theta(A_t | S_t) G_t.$$

外部 γ^t 不能在严格推导中无声丢掉。许多实践实现按采样时间均匀平均，需要说明其采样/目标约定。

7.3 从回报到 Q：策略梯度定理

对 G_t 再条件于 (S_t, A_t) ，其条件均值是 $Q^\pi(S_t, A_t)$ 。定义归一化折扣状态占用

$$d_\gamma^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t P_\pi(S_t = s),$$

则无限时域折扣版本为

$$\nabla J = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_\gamma^\pi, a \sim \pi} [\nabla \log \pi_\theta(a | s) Q^\pi(s, a)].$$

状态分布虽依赖策略，定理已把该影响吸收到 Q 中，不是简单假设状态分布不变。归一化与未归一化占用的公式相差常数，必须保持一致。

7.4 Baseline 为什么不改变期望

只依赖状态的 $b(s)$ 满足

$$\mathbb{E}_{a \sim \pi} [\nabla \log \pi(a | s) b(s)] = b(s) \nabla \sum_a \pi(a | s) = 0.$$

于是可以用 $G_t - b(S_t)$ 。若 $b = V^\pi$ ，条件均值就是优势。baseline 需要在 score 梯度中视为常数；共享网络时不能让 Actor 损失经 baseline 分支偷偷更新价值参数。

准确 V 是常用选择，却不总是最小化梯度方差的唯一最优 baseline；最优形式还涉及 score 的平方范数。更重要的是，使用含当前样本回报的样本均值作为 baseline 会引入相关性，不能直接套用“与当前动作无关”的证明，组内基线见章节 十八。

7.5 手算两动作 bandit

设动作 1 概率 $p = \sigma(\theta)$ ，动作 0 概率 $1 - p$ ，奖励分别为 1、0。真实目标 $J = p$ ，故 $\nabla_\theta J = p(1 - p)$ 。score 为 $A - p$ ，REINFORCE 估计 $(A - p)R$ ：

$$\mathbb{E}[(A - p)R] = p(1 - p).$$

取 $p = 1/2$ ，真实梯度为 $1/4$ 。若 baseline 为 $1/2$ ，两个动作产生的估计都为 $1/4$ ，在这个特殊例子中方差恰好为零。一般任务不会如此理想。

7.6 从公式到训练

最小化 $L_\pi = -N^{-1} \sum \log \pi_\theta(a_t | s_t) \text{sg}(\hat{A}_t)$ ，注意与最大化回报的符号相反。连续动作常用对角高斯，离散动作 categorical；多维高斯 log-prob 要在动作维求和，不能保留向量再意外广播。

标准 REINFORCE 用当前策略采样并进行对应的 on-policy 更新。把同一批样本任意训练许多轮，策略已改变，就不再是原推导中的当前策略样本估计，需考虑章节 九的代理目标。

自测： baseline 为何不能随意用 $Q(s, a)$ ？因为它依赖当前动作，score 加权期望通常不为零；直接减去会改变梯度。必须另有补偿结构才可能成立。

第八章 Actor–Critic、优势估计与 GAE

学习层级：A。核心是估计器、数据和梯度路径；“Actor–Critic”是一类结构。材料：CS285 L6、L21；白板 baseline 与 Actor–Critic。

8.1 Critic 帮 Actor 判断动作相对好坏

REINFORCE 用真实回报，方差可能很大。Critic 学 V_ϕ 或 Q_ϕ ，Actor 用这些估计构造策略梯度。学习价值引入逼近误差，但允许更短反馈、更多样本复用。Actor 的目标是提高回报，Critic 的目标是改善价值估计，两者不是同一个损失。

若 $V = V^\pi$ ，一步 TD residual 条件期望为

$$\mathbb{E}[\delta_t \mid s_t, a_t] = r(s_t, a_t) + \gamma \mathbb{E}V^\pi(S_{t+1}) - V^\pi(s_t) = A^\pi(s_t, a_t).$$

当 V 不准确时，一步优势一般有偏；偏差依赖下一状态价值误差与当前基线误差的组合。

8.2 从 n-step 优势推到 GAE

先写

$$\widehat{A}_t^{(n)} = G_t^{(n)} - V(S_t).$$

把每个 $\delta_{t+l} = R_{t+l+1} + \gamma V(S_{t+l+1}) - V(S_{t+l})$ 乘以 γ^l 并相加，中间价值望远镜消去：

$$\widehat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}.$$

对 n-step 优势按 λ 权重混合，交换求和，得到

$$\widehat{A}_t^{\text{GAE}} = \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}.$$

有限 rollout 从后向前递推 $\widehat{A}_t = \delta_t + \gamma \lambda c_t \widehat{A}_{t+1}$ ， c_t 表示是否继续连接到同一轨迹的下一条 residual。 $\lambda = 0$ 只用一步 residual； $\lambda = 1$ 在正确边界处理下回到 MC/完整多步目标减 baseline。

8.3 两种 mask 不应混为一谈

计算 δ_t 时用 bootstrap mask m_t : 真正终止为 0, 允许延续的时间截断为 1。GAE 递推则不能穿过 reset 边界, 因此连接 mask c_t 在终止和截断重置处都为 0。

```
next_adv = 0
从 rollout 末尾向前:
    delta = reward + gamma * bootstrap_mask * V(final_next_obs) - V(obs)
    adv = delta + gamma * lambda * continuation_mask * next_adv
    return_target = adv + V(obs)
    next_adv = adv
```

若 rollout 在未终止处结束, 最后一个 residual 可以 bootstrap, 但不能凭空加入未采集的 residual。 $\widehat{R}_t = \widehat{A}_t + V_{\text{old}}(s_t)$ 可作为价值回归目标, 整个 target 应被冻结。

8.4 数值例子

仍用两步轨迹 $(0, 3)$, $\gamma = 0.9$, $V(s_0) = 1, V(s_1) = 2$ 。则 $\delta_0 = 0.8$, $\delta_1 = 1$ 。 $\lambda = 0$ 时优势为 0.8; $\lambda = 1$ 时为 1.7, 等于 $2.7 - 1$; $\lambda = 0.5$ 时为 1.25。不同 λ 在短期价值误差和长程奖励噪声之间取舍。

8.5 联合损失与实现角色

常见形式是 $L = L_\pi + c_V L_V - c_H \mathcal{H}$, 但应先分别理解: Actor 用停止梯度的优势; Critic 拟合停止梯度的回报目标; 熵项鼓励动作分布不过早塌缩。共享表示时三条梯度可能互相影响, 需检查尺度。

优势标准化在实践中常见, 会改变 batch 的尺度; 有限样本随机分母也会改变估计性质。不要把“标准化让训练稳定”升级为严格不改变梯度的定理。

Off-policy Actor-Critic 可以用 replay, 但通常换了评价/改进结构或引入概率修正; 不是把 on-policy GAE 随手放入旧数据缓冲区。SAC 见章节 十一。

8.6 自测

题: Critic 的 MSE 越小, Actor 一定越好吗? **答:** 未必; 关键是相关状态动作的优势是否正确, 价值尺度、覆盖与策略更新都影响结果。**题:** $\lambda = 1$ 能否保证任意截断下完全无偏? **答:** 不能, 未观察尾部若用不准确价值 bootstrap, 仍有偏差。

第九章 稳定策略改进：自然梯度、TRPO 与 PPO

学习层级：A/B。 PPO 目标与诊断必须掌握；自然梯度机制掌握，TRPO 数值求解细节可后补。
材料：CS285 L9–10、L21；原论文 [TRPO](#)、[PPO](#)。

9.1 为什么沿着好梯度也会变差

梯度描述当前位置附近的变化。大步更新后，状态分布改变，旧优势估计可能失效，少数动作概率可能暴涨。控制更新幅度的目的，是让旧数据提供的局部信息在新策略处仍有参考价值。

折扣目标满足性能差异恒等式：

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\pi'}, a \sim \pi'} [A^{\pi}(s, a)].$$

证明可把 $A^{\pi} = r + \gamma \mathbb{E} V^{\pi}(s') - V^{\pi}(s)$ 沿 π' 轨迹折扣求和，中间 V 项抵消，留下新策略回报减初始旧价值。这里使用的是**新策略状态占用**。

9.2 用旧状态分布构造代理目标

把难以采集的 $d^{\pi'}$ 近似为 d^{π} ，再只对动作做 IS，得到忽略常数的局部目标

$$L(\theta) = \mathbb{E}_{s, a \sim \pi_{\text{old}}} [\rho_{\theta}(s, a) \hat{A}(s, a)], \quad \rho_{\theta} = \exp(\log \pi_{\theta} - \log \pi_{\text{old}}).$$

在旧参数处，这个代理的梯度与相应策略梯度匹配；离开该点后的目标值不等于真实性能差异。重要性比不能自动修正被忽略的状态分布变化。

9.3 自然梯度与 TRPO 的几何

欧氏参数距离不等于策略分布距离。令 g 为目标梯度， F 为旧策略上的 Fisher 信息矩阵；局部 KL 约为 $\frac{1}{2} \Delta^{\top} F \Delta$ 。求解

$$\max_{\Delta} g^{\top} \Delta \quad \text{s.t.} \quad \frac{1}{2} \Delta^{\top} F \Delta \leq \delta$$

在 F 正定时，方向为 $F^{-1}g$ ，缩放后

$$\Delta = \sqrt{\frac{2\delta}{g^\top F^{-1}g}} F^{-1}g.$$

TRPO 用局部近似、共轭梯度与线搜索等实现受约束更新。理论界、近似 KL 约束和实际有限样本求解不是同一层面的保证；奇异 F 常需要阻尼。

9.4 PPO clipping 的分段含义

PPO 最大化

$$L_{\text{clip}} = \mathbb{E} \left[\min\{\rho \hat{A}, \text{clip}(\rho, 1 - \epsilon, 1 + \epsilon) \hat{A}\} \right].$$

优势符号	被截平的一侧	意义
$\hat{A} > 0$	$\rho > 1 + \epsilon$	已明显提高好动作概率后，不再给额外代理收益
$\hat{A} < 0$	$\rho < 1 - \epsilon$	已明显降低坏动作概率后，不再给额外代理收益

取 $\epsilon = 0.2$ 。若 $A = 2, \rho = 1.5$ ，贡献为 $\min(3, 2.4) = 2.4$ ；若 $A = -2, \rho = 0.5$ ，贡献为 $\min(-1, -1.6) = -1.6$ 。朝坏方向变化时仍受线性项惩罚。图中的横轴是固定样本的概率比，并非完整网络更新轨迹。




图 9.1: PPO 代理目标在两种优势符号下的形状。

Clipping 只改变目标，不把真实概率比强制限制在区间内，也不提供硬 KL 约束。参数共享可能让未主动更新的样本概率继续变化，因此仍需监测 KL。

9.5 一轮 PPO 更新应冻结什么

先用旧策略采 rollout，存储 old log-prob、old values、mask 和奖励；计算 GAE 与 return targets 后冻结。再进行有限轮 minibatch 更新：重新计算当前 log-prob，形成 ratio，更新 Actor 和 Critic。old log-prob 不能每个 epoch 重算为“当前值”，否则 ratio 被错误重置为 1。

监测平均回报、KL、clip fraction、熵、价值误差和梯度范数。近似 KL 的数值可能依估计式不同而不同，日志须写定义。KL 过大时可早停；clip fraction 高不自动等于训练失败，要结合回报和 KL 判断。

9.6 工具箱与自测

必须掌握：优势固定、旧概率固定、min 的符号、数据复用的范围。**题：**同一批数据训练越多轮是否总更高效？**答：**更多优化可能降低采样成本，也会扩大策略偏移并过拟合旧优势。**题：**PPO 是不是“不会降低回报”的算法？**答：**不是，有限样本、近似优势和无硬约束都允许性能退化。

第四部分

正则化、推断与连续控制

第十章 最大熵 RL 与控制即推断

学习层级：A/B。掌握熵正则和 soft Bellman；变分推断的角色达到能解释 ELBO。材料：CS285 L11-13；一般 VI 基础在附录补齐。

10.1 为什么不只追求单一最大值

当多个动作价值接近时，过早确定一个动作会失去多样性，也可能对价值误差敏感。最大熵 RL 优化奖励与策略熵的组合：

$$J_{\alpha}(\pi) = \mathbb{E}_{\pi} \sum_{t \geq 0} \gamma^t [R_{t+1} + \alpha \mathcal{H}(\pi(\cdot | S_t))].$$

$\alpha > 0$ 是温度，控制随机性的代价/收益；它不是环境奖励本身。连续动作使用微分熵，会受单位和坐标变换影响，因此动作缩放与密度修正必须一致。

10.2 一个状态上的最优随机策略

固定 Q ，在有限动作上求 $\max_{\pi} \sum_a \pi_a Q_a - \alpha \sum_a \pi_a \log \pi_a$ ，加上概率和为 1 的乘子。逐项求导：

$$Q_a - \alpha(\log \pi_a + 1) + \lambda = 0 \implies \pi^*(a) = \frac{\exp(Q_a/\alpha)}{\sum_b \exp(Q_b/\alpha)}.$$

代回得到最优值

$$V(s) = \alpha \log \sum_a \exp(Q(s, a)/\alpha).$$

另一种更有解释力的写法是

$$\mathbb{E}_{\pi} Q + \alpha \mathcal{H}(\pi) = \alpha \log Z - \alpha D_{\text{KL}}(\pi \| \pi^*).$$

最大化等价于逼近 softmax 分布。 $\alpha \rightarrow 0$ 时趋向 max；连续动作将和改积分，但需要可积性和明确基准测度。

10.3 Soft Bellman 方程

约定 Q 包含当前环境奖励与未来熵，不额外包含当前动作选择的熵项，则

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s'),$$

$$V^\pi(s) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a) - \alpha \log \pi(a | s)].$$

最优 V 由上面的 log-sum-exp 给出。不要把普通 Q 的 max backup 与带熵的 Actor 目标随意拼在一起而不说明目标已经改变。

例子。 $Q = (0, 1), \alpha = 1$ ，第二动作概率约 0.731，soft value 为 $\log(1 + e) \approx 1.313$ 。它高于最高环境动作值 1，是因为目标含熵奖励，不是凭空发现更多环境回报。

10.4 从隐变量推断理解优化

对潜变量模型 $p_\theta(x, z)$ ，引入近似后验 $q_\phi(z | x)$ ：

$$\log p_\theta(x) = \underbrace{\mathbb{E}_q[\log p_\theta(x, z) - \log q_\phi(z | x)]}_{\mathcal{L}, \text{ ELBO}} + D_{\text{KL}}(q_\phi(z | x) \| p_\theta(z | x)).$$

KL 非负，所以 ELBO 是下界。摊销推断让一个网络对不同 x 直接产生 q ，避免每个样本单独优化参数。高斯重参数化 $z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon$ 把采样随机性移到与参数无关的噪声，便于低方差路径梯度。VI 不是简单地“把真实后验替换成任意高斯而仍完全精确”。

控制即推断加入“最优性”观测，似然与 $\exp(r/\alpha)$ 成比例。严格作为概率需归一化或将奖励平移到满足概率范围；常也把它当非归一化势函数。对高奖励轨迹的后验偏好能够导出 soft 价值和随机策略。

10.5 随机动力学的关键限制

如果任意优化整个轨迹后验，推断可能偏向那些“环境碰巧更幸运”的转移，仿佛策略能控制环境噪声。实际只能选择动作，不能改真实动力学。受约束的变分分布要保留环境转移，只优化策略因子，才得到合理的最大熵控制目标。

相对参考策略正则则优化 $\mathbb{E}_\pi Q - \alpha D_{\text{KL}}(\pi \| \pi_{\text{ref}})$ ，最优解满足

$$\pi^*(a | s) \propto \pi_{\text{ref}}(a | s) \exp(Q(s, a)/\alpha).$$

这里奖励的是相对参考分布的变化，不等于单独最大化策略熵。该式连接 LLM 后训练中的 KL 约束。

10.6 自测

题：熵越大是否回报一定越好？**答：**不一定，熵改变优化目标，也可能降低原任务奖励。**题：**ELBO 变大是否保证真实似然每一步都变大？**答：**一般不保证，下界间隙也在变；须区分优化代理与原量。

第十一章 连续动作：DDPG、TD3 与 SAC

学习层级：A/B。 SAC 三组更新与数据流必须掌握；DDPG/TD3 作为比较。材料：CS285 L8、L13、Section 4；[SAC 原论文](#)、[TD3](#)。

11.1 连续动作中的 max 如何计算

DQN 可以遍历有限动作。连续动作的 $\max_a Q(s, a)$ 是一个新的优化问题，若每次 backup 都内层求解，代价很大。Actor 将状态映射到动作，用学习近似这一选择过程。

确定性策略 $a = \mu_\theta(s)$ 的 DDPG Critic 目标为 $y = r + \gamma m Q_{\bar{\phi}}(s', \mu_{\bar{\theta}}(s'))$ 。Actor 在 replay 状态上最大化 Q，路径梯度为

$$\mathbb{E}_{s \sim \mathcal{D}} \left[\nabla_a Q_\phi(s, a) \Big|_{a=\mu_\theta(s)} \nabla_\theta \mu_\theta(s) \right].$$

这是实际使用的 replay 分布代理更新；精确确定性策略梯度定理还需明确其占用分布，不能把任意 replay 均值直接等同于起点目标梯度。

11.2 TD3 的三个修改

TD3 用双 Critic 的最小值构造目标，给目标动作加入裁剪噪声进行平滑，并让 Actor/目标网络较低频率更新。目标可写为

$$\tilde{a}' = \text{clip}(\mu_{\bar{\theta}}(s') + \text{clip}(\epsilon, -c, c)), \quad y = r + \gamma m \min_i Q_{\bar{\phi}_i}(s', \tilde{a}').$$

动作外层 clip 对齐环境范围。平滑针对狭窄尖峰，双 Q 针对过估计，延迟更新减少 Actor 追逐瞬时不准 Critic。最小值也会带来低估，不能视为免费改进。

11.3 SAC：随机策略与 soft 价值

采样 $\epsilon \sim \mathcal{N}(0, I)$ ，令 $a = f_\theta(s, \epsilon)$ 。SAC 用两个 Critic 和可重参数化随机 Actor。冻结目标计算：

$$a' \sim \pi_\theta(\cdot | s'), \quad y = r + \gamma m \left[\min_i Q_{\bar{\phi}_i}(s', a') - \alpha \log \pi_\theta(a' | s') \right].$$

最小化 $L_{Q_i} = \mathbb{E}_{\mathcal{D}}(Q_{\phi_i}(s, a) - \text{sg}(y))^2$ 。Actor 最小化

$$L_{\pi} = \mathbb{E}_{s \sim \mathcal{D}, \epsilon} \left[\alpha \log \pi_{\theta}(f_{\theta}(s, \epsilon) \mid s) - \min_i Q_{\phi_i}(s, f_{\theta}(s, \epsilon)) \right].$$

更新 Actor 时冻结 Critic 参数，但保留 Q 对 a 的导数。更新 Critic 时则整个 y 停止梯度。SAC 的状态来自 replay，不是标准 on-policy score-function 更新。

11.4 有界动作的密度不能忘

若 $u \sim \mathcal{N}(\mu, \sigma^2)$ 、 $a = \tanh u$ ，变换公式给出

$$\log \pi(a \mid s) = \log \mathcal{N}(u; \mu, \sigma^2) - \sum_j \log(1 - \tanh^2 u_j).$$

若再乘动作尺度，还需减去尺度 Jacobian 的对数。临近边界直接计算 $\log(1 - a^2)$ 可能不稳定，可用基于 u 的稳定等价式；例如 $\log(1 - \tanh^2 u) = 2(\log 2 - u - \text{softplus}(-2u))$ 。

忽略密度修正会改变熵与 Actor 梯度。虽然采样动作仍落在合法范围，算法已不再优化写出的目标。

11.5 自动温度的方向

设期望目标熵为 H_* ，固定策略时对偶温度损失可写为

$$L_{\alpha} = \alpha \mathbb{E}[-\log \pi(a \mid s) - H_*], \quad \alpha > 0.$$

若当前熵低于目标，导数为负，梯度下降增大 α ，增强熵奖励；若熵过高则降低。通常参数化 $\alpha = e^{\eta}$ 保证正值，并冻结 log-prob。以 eta 直接写线性代理损失的实现，梯度尺度不同，应说明约定。连续分布的目标微分熵可以为负。

11.6 一轮 SAC 与数值核对

交互并存 replay $\rightarrow$ 抽 batch $\rightarrow$ 更新两个 Q $\rightarrow$ 更新 Actor $\rightarrow$ 可选更新温度 $\rightarrow$ Polyak 更新目标 Q。取 $r = 1, \gamma = 0.9, m = 1, \min Q' = 2, \alpha = 0.2, \log \pi' = -0.5$ ，则 $y = 1 + 0.9(2 + 0.1) = 2.89$ ；终止时仍为 1。

比较工具箱： PPO 依赖新 rollout 和受控复用；SAC 大量复用 replay，但要维护双 Q、目标网络 and 正确连续密度。不能脱离环境、数据预算和实现质量宣称某个方法总更好。

自测：若 Actor loss 的 Q 项全部 detach，会发生什么？答：策略只能受到熵项等剩余梯度推动，失去沿 Q 改善动作的主要信号。

第五部分

示范、模型与固定数据

第十二章 模仿学习：BC、分布偏移与 DAgger

学习层级：A。本章可在第 1 章后提前读。材料：CS285 L2-3、L21 与 HW1；[DAgger 原论文](#)。

12.1 有示范时，先把动作当标签

给定专家数据 $\mathcal{D}_E = \{(s_i, a_i)\}$ ，行为克隆最小化

$$L_{\text{BC}}(\theta) = -\mathbb{E}_{(s,a) \sim \mathcal{D}_E} \log \pi_\theta(a \mid s).$$

固定方差高斯的负对数似然等价于均方误差加常数。BC 不需要奖励，也不需要对环境反向传播；它可以成为 RL 前的初始化或强基线。

12.2 单步误差怎样改变后续输入

专家数据在 d^{π_E} 上，部署时输入来自 d^{π_θ} 。一旦偏离专家轨迹，后面可能遇见训练时没见过的状态，再产生更大错误。这是闭环分布偏移，不等于普通 IID 测试误差。

有限时域 H ，若沿专家轨迹每一步错误概率至多 ϵ ，union bound 使到 t 步前出错概率至多 $t\epsilon$ 。若错误后最坏每步额外损失有界，则累计额外成本可达 $O(H^2\epsilon)$ 。这是最坏情形量级，依赖错误/代价假设，不预言每个 BC 系统都按二次规律崩溃。

例子。自动驾驶在专家数据中几乎总位于车道中央。一次小偏移把车带到边缘，模型却没有见过“从边缘回正”的输入。增加相似中心轨迹未必补上恢复行为。

12.3 DAgger：在学习者真正访问的状态上询问专家

初始数据训练 BC；执行当前策略或混合策略；对访问状态询问专家动作；把新标签加入总数据；重新训练；重复。被保存的是“学习者到达的状态、专家建议的动作”，不是把学习者所有动作都当正确标签。

这个过程把训练分布推向部署会访问的状态。它需要专家能为这些状态提供合理标签，且交互成本可接受。相关 no-regret 分析还需有限时域、损失和策略类等条件；要得到线性时域任务成本界，通常需限制单次错误的后续成本，不能只凭数据聚合就宣布所有长程错误消失。

12.4 观察不充分和多峰动作是两种失败

同一图像下专家动作不同，可能是缺少速度、过去动作或目标信息；应补历史或任务上下文。也可能存在多条同样好的路线，即真实条件分布多峰；此时需要更强的策略表示。

两峰例子。动作 -1 和 $+1$ 各占一半，中间 0 会撞障碍。平方损失预测条件均值 0 ，却生成没有任何专家使用的危险动作。更低回归 MSE 不等于更好的行为。

可用混合密度、自回归动作离散化、diffusion/flow 策略表达多峰。自回归将动作维度分解为 $\prod_j p(a_j | s, a_{<j})$ ；动作分箱会引入量化误差与序列推理成本。Flow matching 的完整接口见章节十五。

12.5 目标条件与数据增强

目标条件 BC 学习 $\pi(a | s, g)$ ，让相同当前状态在不同目标下选择不同动作。对观察做增强时必须保持动作标签语义：图像左右翻转可能要求同步变换转向动作。无条件套用分类任务的增强可能制造错误示范。

部署评估用完整 rollout 的成功率、回报和失败状态分布；离线 log-likelihood 只能反映数据拟合。DAgger 应额外记录专家查询量，避免把大量昂贵专家标签当作免费优势。

12.6 工具箱与自测

先诊断四件事：输入是否充分、策略能否表示示范多峰、训练与部署分布是否不同、标签是否一致。**题：**增加参数一定能解决 BC 分布偏移吗？答：不能，容量无法替代缺失的恢复状态数据。**题：**BC 和 offline RL 是否相同？答：都可用固定数据，但 BC 拟合动作，offline RL 根据奖励学习改进，面临不同的外推风险。

第十三章 规划、模型式 RL 与世界模型

学习层级：B。掌握学习模型、用模型和控制误差三件事；复杂轨迹优化证明以后补。材料：CS285 L12、L15–16；白板 Dyna、算力聚焦、决策时规划与 MCTS。

13.1 模型给出了什么新能力

Model-free 从经验直接学习价值/策略；model-based 额外学习或使用环境模型，再在模型中比较行动后果。已知模型下的规划与从数据学习模型是两个不同任务，模型式 RL 将它们组合。

确定性动力学可拟合 $s' = f_\phi(s, a)$ ；预测增量 $s' - s$ 常更容易。概率模型用负对数似然训练 $p_\phi(s' | s, a)$ ，还可建模奖励和终止。训练数据的覆盖仍决定模型能否可靠外推。

13.2 开环优化与闭环 MPC

有限预测长度 H ，规划问题为

$$\max_{a_{0:H-1}} \sum_{t=0}^{H-1} \gamma^t r_\phi(s_t, a_t) + \gamma^H V_{\text{tail}}(s_H), \quad s_{t+1} = f_\phi(s_t, a_t).$$

开环一次决定全部动作；MPC 每次只执行第一个动作，观察真实下一状态后重新规划，减轻模型误差和扰动积累。短时规划仍可能近视，尾部价值可补偿但也引入估值误差。

随机射击采很多动作序列并选最高分；CEM 反复选精英序列、重新拟合采样分布。可微模型可以对动作梯度上升。局部线性化动力学、二次化成本后可用 LQR/iLQR 类方法；局部近似与全局最优不能混称。

例子。模型预测小车刹车需 2 米，真实需 3 米。长开环序列可能直接越线；MPC 利用真实减速反馈反复调整，但若模型一直严重错误且观测太晚，也不能保证补救。

13.3 Dyna 与短模型 rollout

Dyna 把每条真实经验用于两件事：直接更新价值；更新环境模型。随后从过去状态采样，用模型生成经验再更新价值。规划次数增加计算量，可能节省真实交互；模型错误时也会反复强化错误知识。

优先规划可关注大残差或其前驱，分配有限算力；决策时规划则在当前需要行动的状态临时搜索。两者都使用模型，但规划发生的时机和缓存对象不同。

现代短 rollout 方法从真实 replay 状态出发，只在模型中走少量步，把生成转移用于 model-free 学习。其动机是减少长程分布漂移，而不是断言一步模型必然准确。模型预测控制、模型生成数据、通过模型优化策略是三种不同用途。

13.4 不确定性与误差累积

偶然不确定性来自环境随机性；认知不确定性来自数据不足或模型不确定，可随数据增加下降。概率输出能表示前者，模型集成常用于近似后者，但集成差异并非校准置信区间。

若一步状态误差至多 ϵ ，动力学对状态 L -Lipschitz，则滚动误差满足 $e_{t+1} \leq L e_t + \epsilon$ 。 $L > 1$ 时可快速放大；即使 L 较小，策略也可能主动寻找模型高估的区域。应在真实环境评估、限制 rollout、约束策略或惩罚不确定性，而非只看模型训练误差。

13.5 隐状态世界模型

图像控制可学习隐状态 z ：编码历史为后验 $q(z_t | o_{\leq t}, a_{< t})$ ，动力学先验预测 $p(z_t | z_{t-1}, a_{t-1})$ ，解码器重建观察并预测奖励。简化序列 ELBO 含

$$\sum_t \mathbb{E}_q \log p(o_t | z_t) - \sum_t \mathbb{E}_{q(z_{t-1})} D_{\text{KL}}(q(z_t | \cdot) \| p(z_t | z_{t-1}, a_{t-1})).$$

初始项使用对应初始先验；奖励等额外观测可加入重建项。潜变量必须保留控制相关信息，图像重建好不代表反事实动作预测好。世界模型可用于规划或想象训练，具体大型系统作为扩展阅读。

13.6 MCTS 与连续规划的区别

树搜索依次选择、扩展、模拟/估值、回传。UCT 的一种选择准则是

$$\overline{Q}(s, a) + c \sqrt{\frac{\log N(s)}{N(s, a)}},$$

未访问动作需特殊处理。第一项利用价值，第二项探索访问较少的分支。叶子可用 rollout 回报或价值网络评估；回传沿搜索路径更新统计。树中探索动作不等于真实环境立即执行动作。MCTS 适合可模拟的分支决策，MPC 更常直接优化连续动作序列，二者不是互斥的哲学分类。

13.7 自测

题：更多模型规划步骤为什么可能更差？**答：**模型外推错误被优化器利用，规划越充分越可能找到“模型漏洞”。**题：**是否只需保存模型 loss？**答：**还需真实 rollout 表现、不同预测长度的误差、模型访问区域与训练数据覆盖。

第十四章 离线 RL：覆盖、保守性与 IQL

学习层级：A/B。必须掌握 offline 与 off-policy 的区别，以及 IQL 的三组更新。材料：CS285 L17-18、L22、HW5；IQL、CQL。

14.1 固定数据为何更困难

在线训练可以试验新策略并修正误判；离线训练只有固定数据 $\mathcal{D}$ ，不能通过新交互验证数据外动作。即使算法本来是 off-policy，直接在固定数据上跑也可能失败。

设某状态只见动作 A 的真实回报 1，网络对没见过的 B 预测 100。Actor/max 选择 B，bootstrap 又将 100 传播到已有数据。普通回归没有 B 的标签来纠正它。这是策略优化利用外推误差的反馈，不只是训练集拟合不好。

无覆盖的行为结果通常无法从数据唯一识别：两个环境可以在所有已有数据上相同，却在 B 上给出完全不同奖励。任何强保证都需要覆盖、结构或其他额外假设。

14.2 三类限制方式

策略约束让新策略接近行为；悲观价值让数据外动作不那么有吸引力；数据内回归避免在关键估值步骤查询未见动作。三者可组合，但各有取舍。

简单 BC 正则 Actor 的目标可写为 $-\mathbb{E}Q(s, \pi_\theta(s)) + \lambda \mathbb{E}\ell_{\text{BC}}(\theta; s, a)$ 。动作回归式 BC 与负 log-likelihood 式 BC 不同；具体 SAC+BC 实现应跟课程作业版本对齐，不能把所有变体视为同一损失。

14.3 CQL 的直觉与离散示意

在普通 TD 损失外，加一个抑制广泛动作价值、相对保留数据动作价值的项：

$$L_{\text{CQL}} = L_{\text{TD}} + \alpha \mathbb{E}_{s \sim \mathcal{D}} \left[\log \sum_a e^{Q(s,a)} - \mathbb{E}_{a \sim \mathcal{D}(\cdot|s)} Q(s,a) \right].$$

这是常见离散动作形式的机制示意。连续动作需要采样近似积分等处理；“保守”的理论结论带有分布、样本与优化条件，并非每个动作的神经网络预测都自动成为严格下界。

14.4 IQL: 隐式地偏向数据内较好动作

IQL 不直接在 V 回归中最大化任意动作, 而对数据动作 Q 做 expectile 回归。定义

$$\ell_\tau(u) = |\tau - \mathbf{1}\{u < 0\}|u^2, \quad L_V = \mathbb{E}_{(s,a) \sim \mathcal{D}} \ell_\tau(Q_\phi(s,a) - V_\psi(s)).$$

$\tau > 1/2$ 时, V 低于 Q 的正残差惩罚更重, V 倾向数据支持内较高 Q 。它是非对称平方损失得到的 expectile, 不是 quantile; 后者对应非对称绝对损失。

Critic 回归

$$L_Q = \mathbb{E}_{\mathcal{D}} [Q_\phi(s,a) - \text{sg}(r + \gamma m V_\psi(s'))]^2.$$

Actor 做优势加权行为克隆:

$$L_\pi = -\mathbb{E}_{\mathcal{D}} [\text{sg}(e^{\beta(Q_\phi(s,a) - V_\psi(s))}) \log \pi_\theta(a | s)].$$

β 在此是逆温度; 实践常裁剪指数权重。三组更新对应“数据内高值基线、价值传播、策略提取”。最终策略仍可能因函数泛化偏出数据区域, IQL 不是免除所有分布偏移问题。

14.5 Expectile 手算

某状态数据动作 Q 值为 0 与 2, 各一半。若 $0 < v < 2$, 一阶条件为 $(1-\tau)v = \tau(2-v)$, 故 $v = 2\tau$ 。 $\tau = 0.5$ 得 1, $\tau = 0.8$ 得 1.6。它偏向高值但未凭空取数据外最大值。




图 14.1: 同一双点分布的 expectile 随非对称权重变化。

14.6 离线策略评估与选择

IS 按目标/行为比修正回报，但依赖行为概率和覆盖，长轨迹方差可能很高。Fitted Q Evaluation 固定待评估策略，用其下一动作做 Bellman 回归；它仍依赖数据覆盖与函数类，不是独立真值。Doubly robust 类方法组合模型与权重校正，也需明确假设。

若有额外在线评估权限，应单独统计评估交互；不能反复用测试任务挑超参，再把它当未见测试集。训练中的 Q 高低不适合跨算法直接当真实回报排名。

14.7 自测

题：为什么保守越强不一定越好？答：过度限制会退化到模仿，失去组合数据中优良行为的能力。

题：IQL 的 V 是否就是 $\max_a Q(s, a)$ ？答：不是，它是按数据条件动作分布得到的上 expectile，只在额外极限与覆盖条件下接近最大值。

第十五章 生成式策略、FQL 与离线到在线

学习层级：B。掌握 flow 建模与价值优化各自的职责；复杂生成模型理论可后补。材料：CS285 L2-3、L18、L22、HW5；[Flow Q-Learning 原论文](#)。

15.1 为什么需要更强的动作分布

示范可能包含向障碍左侧或右侧绕行，平均动作却撞上障碍。策略不仅要有较高预期价值，还要能表达数据中的多峰行为。Flow/diffusion 提供从噪声生成动作的机制，但“生成模型会拟合数据”与“策略会最大化回报”是两件事。

15.2 Flow matching 的最小构造

给定状态 s 、数据动作 a_1 、噪声 $z \sim \mathcal{N}(0, I)$ ，取 $t \sim U[0, 1]$ 并构造 $a_t = (1 - t)z + ta_1$ 。这条条件路径的速度是 $a_1 - z$ ，训练

$$L_{\text{FM}} = \mathbb{E} \|v_\phi(s, a_t, t) - (a_1 - z)\|^2.$$

生成时从 $a_0 = z$ 出发解 $da_t/dt = v_\phi(s, a_t, t)$ ，终点为动作。这里的 t 是生成过程时间，不是环境时间。有限 Euler 步是数值近似，步数影响推理成本与分布精度。

Diffusion 的常见训练则给动作逐级加噪，学习预测噪声或 score，再逆向生成。两者有联系，但损失和采样器不是同一公式；正文不把 diffusion 与 flow 当成完全可互换名字。

15.3 直接把 Q 梯度穿过生成过程的问题

若最大化 $Q(s, \pi_\phi(s, z))$ ，而 π_ϕ 要迭代 F 次积分，反传会穿过所有步骤，增加计算、显存与梯度不稳定性。表达能力来自迭代生成，但价值优化不一定必须走同一条长反传链。

15.4 FQL 的四个对象

FQL 学行为 flow、一步策略和两个 Q。行为 flow 只学数据；一步策略 $\pi_\omega(s, z)$ 同时追求 Q 高、接近 flow 生成动作。共享同一噪声 z 的蒸馏保持模式对应，一步策略本身仍可表达多峰。

记 $\bar{Q} = (Q_1 + Q_2)/2$ 。与 2026 HW5 的均值双 Q 版本对齐，核心更新为

$$L_v = \mathbb{E} \frac{1}{d_a} \|v(s, a_t, t) - (a_1 - z)\|^2,$$

$$y = r + \gamma m \frac{1}{2} \sum_{i=1}^2 Q_{\bar{\phi}_i}(s', \pi_\omega(s', z')),$$

$$L_\omega = \mathbb{E} \left[-\bar{Q}(s, \pi_\omega(s, z)) + \frac{\alpha}{d_a} \|\pi_\omega(s, z) - \text{sg}(\pi_v(s, z))\|^2 \right].$$

Critic 拟合停止梯度的 y ；一步策略的 Q 梯度保留动作路径；行为 flow 不接收蒸馏项反传。该作业目标使用 Q 均值，不能不加说明地替换成 SAC 的 $\min$ 。CS285 HW5, FQL 部分

对象	输入到输出	更新信号
行为 flow	状态、噪声经积分到动作	数据 flow matching
一步 Actor	状态、噪声直接到动作	Q 最大化与行为蒸馏
双 Critic	状态、动作到价值	使用一步 Actor 的 Bellman 目标

例子。行为 flow 用 z 的符号选择左右绕行。若蒸馏给完全不含噪声的一步均值策略，它可能再次把两峰压成中间动作；一步不代表确定性，保留 z 是重要区别。

15.5 Offline-to-online 不是简单接着训练

在线交互后，新数据分布开始改变。过强行为约束可能妨碍新行为，突然移除约束又可能让策略冲向错误 Q 峰值；Critic 对新数据也可能暂时不准。

常见设计变量是离线/在线 batch 混合比例、约束权重、更新与交互之比、探索噪声、价值网络初始化和归一化统计是否冻结。每项都应通过控制变量实验比较，不把“离线预训练一定提高在线效果”当作结论。

评估横轴优先用新增真实环境交互数，同时报告预训练数据规模和计算预算。在线早期性能下降也应保留，不能只展示最终最好 checkpoint。

15.6 自测

题：FQL 是否通过 Q loss 直接训练行为 flow？答：本章版本不是， Q 优化主要进入一步 Actor，flow 通过 BC/FM 学数据。**题：**只用 state→action 的确定性一步网络能保留所有多峰吗？答：不能，需噪声等随机输入以及足够表示能力。

第六部分

奖励学习与语言模型

第十六章 逆 RL、偏好学习与奖励模型

学习层级：A/B。掌握“学行为”和“学评价”的区别；IRL/GAIL 理论达到机制层。材料：CS285 L13–14、Section 7；[GAIL](#)、[人类偏好学习](#)。

16.1 行为能否告诉我们目标

BC 回答“这种状态下专家做什么”；逆强化学习试图回答“怎样的奖励能解释专家为什么这样做”。奖励可能在新状态提供更灵活的行为指导，但学习奖励也会过拟合，且需要解决内部控制问题，并非天然优于 BC。

奖励通常不唯一。给定专家策略，很多奖励都可能使它最优；更一般地，势函数 shaping $r' = r + \gamma\Phi(s') - \Phi(s)$ 在适当边界条件下不改变最优策略。

沿无限折扣轨迹相加时 shaping 项望远镜消去，余下 $-\Phi(s_0)$ 与消失的尾项；对固定初始分布只是常数。有限幕需控制终止势函数，不能随意给不同终态不同残留奖励。

16.2 最大熵 IRL 与配分函数

在合适轨迹支持与基准动力学下，可写示意模型

$$p_\psi(\tau) = \frac{p_0(\tau) \exp(R_\psi(\tau))}{Z_\psi}.$$

最大化示范轨迹对数似然，梯度为

$$\nabla_\psi \mathbb{E}_{\tau \sim \mathcal{D}_E} \log p_\psi(\tau) = \mathbb{E}_E[\nabla R_\psi(\tau)] - \mathbb{E}_{p_\psi}[\nabla R_\psi(\tau)].$$

第一项提高专家轨迹奖励，第二项减去模型也认为可能的轨迹。若省略配分函数梯度，简单提高所有奖励就能虚假“进步”。难点是第二个期望依赖当前奖励诱导的行为分布，常需要内部 RL 或采样，计算昂贵。随机动力学的因果约束见章节十。

16.3 GAIL: 用判别器比较行为分布

让 $D(s, a)$ 表示样本来自专家的概率，训练它区分专家与当前策略；策略则试图让自己的行为被判为专家。以该标签约定，可用 $-\log(1 - D(s, a))$ 作为一种策略奖励，并结合熵正则。

若将 D 定义成“来自学习者”，奖励符号和公式要相应改变。不能从两个不同实现中抄判别器 loss 和策略 reward 拼在一起。理想化解释是匹配状态动作占用，而不只是单个状态动作对的分类准确率；实际还受样本、函数类和优化限制。

16.4 成对偏好与 Bradley-Terry

设完整回答或片段的评分为 $R_\psi(x, y)$ 。偏好模型

$$P_\psi(y^+ \succ y^- | x) = \sigma(R_\psi(x, y^+) - R_\psi(x, y^-))$$

对应 loss $-\log \sigma(R_\psi(x, y^+) - R_\psi(x, y^-))$ 。它学习相对比较，给同一 prompt 的所有回答加相同常数不改变预测。标注噪声、标注人偏好差异、长度捷径和覆盖范围会影响奖励的泛化。

例子。正负回答分差为 0，预测胜率 0.5；差为 $\log 3$ ，胜率 0.75。奖励值 10 本身没有跨模型可比较的绝对含义，差值才进入该概率模型。

16.5 从奖励学习到优化的风险

策略不断寻找能获得高预测奖励的回答，可能找到奖励模型的盲点。监督测试集上的偏好准确率高，不保证面对被优化出来的分布仍准确。应分开报告模型分数、独立任务成功率和人为抽查，并保存高分失败案例。

DPO 等直接偏好方法利用 KL 正则最优策略与奖励之间的关系消去显式奖励模型。一种标准形式为

$$-\log \sigma \left(\beta \left[\log \frac{\pi_\theta(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \log \frac{\pi_\theta(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right] \right).$$

它是特定偏好模型与正则化推导下的训练方式，不等价于对任意奖励做在线 PPO；本书作为扩展比较。[DPO 原论文](#)

16.6 自测

题：奖励不唯一是否意味着完全不能学？答：不意味着；可以学习足够用于决策的等价奖励，但解释性与跨任务迁移需要额外假设。**题：**只报告奖励模型分数增长够吗？答：不够，策略可能在利用模型误差。

第十七章 语言生成的 RL 建模与后训练

学习层级：A。必须能把 token、前缀、整条回答和三种策略对应起来。材料：CS285 L14、HW4。

17.1 一次生成也能是决策过程

给定 prompt x ，状态是当前前缀 $s_t = (x, y_{<t})$ ，动作是下一个 token $a_t = y_t$ 。在纯文本生成中，转移就是把 token 接到前缀后面；随机性主要来自策略采样。遇到工具调用、多轮用户输入时，环境还包含外部反馈，不再只是字符串拼接。

策略的序列概率分解为

$$\pi_{\theta}(y \mid x) = \prod_{t=1}^T \pi_{\theta}(y_t \mid x, y_{<t}), \quad \log \pi_{\theta}(y \mid x) = \sum_{t=1}^T \log \pi_{\theta}(y_t \mid x, y_{<t}).$$

也可以把完整回答当作 contextual bandit 的一个动作。两种视角在适当目标下相容，但动作空间、信用分配和估计方式不同。不能将 token 平均 log-prob 直接称为整条序列 log-prob。

17.2 SFT、RLHF 与可验证奖励

SFT 用示范回答最大化条件似然，类似行为克隆。RLHF 利用人类偏好训练奖励，再优化策略；可验证奖励直接使用判题器、格式规则或执行结果。结果奖励评价最终结果，过程奖励对中间步骤给信号，后者也可能错误或被利用。

对终局奖励 $R(x, y)$ 、 $\gamma = 1$ 的有限生成，未加其他逐步奖励时每个 token 的 reward-to-go 都是同一个最终分数。它不意味着每个 token 的真实贡献相同，而是这种估计器尚未精细分配信用。

17.3 三种策略必须分开

记号	职责	是否变化
π_{θ}	正在训练、计算梯度	每次优化变化
π_{old}	生成当前 rollout 的行为策略	当前复用周期固定
π_{ref}	定义参考偏离成本	通常整个阶段固定

PPO ratio 的分母是 old, KL 正则的参照是 ref. old 与 ref 在第一轮可能相同, 之后不必相同。把两者混成一个 frozen model 会改变算法。

17.4 KL 正则与序列分解

一种序列目标为

$$\mathbb{E}_{x,y \sim \pi_\theta}[R(x,y)] - \beta \mathbb{E}_x D_{\text{KL}}(\pi_\theta(\cdot | x) \| \pi_{\text{ref}}(\cdot | x)).$$

当两策略在完整序列空间上有合适支持和终止定义时, 链式法则将序列 KL 写成当前策略前缀分布上的 token KL 之和。给每个采样 token 加 $-\beta \log(\pi_\theta/\pi_{\text{ref}})$ 的奖励塑形、以及在 surrogate loss 外直接加入采样 KL 项, 是需要分别定义的实现, 不能重复加罚却仍按单项公式解释。

17.5 Mask、移位和长度

语言模型在位置 t 的 logits 预测下一个 token。teacher forcing 计算 log-prob 时, 应对 logits 与目标 token 做正确 shift。只对 completion 位置计算 RL 损失; prompt 与 padding 的 mask 为 0, EOS 若作为实际采样动作则通常包含在 completion 内。

变长 batch 至少有两种 reduction: 先每条回答取 token 平均再对回答平均; 或将所有有效 token 总和除以 token 总数。后者给长回答更大样本权重。序列 log-prob 的求和又是另一种量。哪一种合适取决于目标与实现, 不能互换而声称只差固定常数。

截断达到 max length 时应记录是否生成 EOS。判题器可能把未完成回答判错, 训练也可能受长度规则影响; 不要默默将截断当作自然结束。温度、top-p 等采样设置会改变实际行为分布, 概率比计算必须考虑是否与记录的采样概率一致。

17.6 一个最小检查

两条回答长度为 2 和 4, 所有 token log-prob 均为 -1 。序列 log-prob 分别为 $-2, -4$; 各自 token 平均均为 -1 。如果把后者放入普通序列 REINFORCE, 它对不同长度使用了不同缩放, 已改变估计器。

17.7 自测

题: 用生成时的 logits 直接保存 log-prob 足够吗? 答: 要确认采样温度、截断词表及模型模式与概率定义一致, 并保存对应 token/mask。**题:** 奖励为正确答案时是否就没有 reward hacking? 答:

仍可能利用解析器、格式漏洞或测试覆盖缺口；奖励函数正确性也是实验的一部分。

第十八章 LLM 策略优化：PPO、GR-REINFORCE 与 GRPO

学习层级：A。 必须掌握组内优势、采样策略与参考策略的区别。材料：CS285 L14；具体 reduction 和命名按 2026 HW4 对齐。

18.1 为什么同一 prompt 要采多条回答

难 prompt 和易 prompt 的奖励水平不同。把所有回答混在一起减总均值，会把题目难度与回答相对质量混淆。同一 prompt 采 G 个回答，奖励为 $r_1, \dots, r_G$ ，定义

$$\bar{r} = \frac{1}{G} \sum_j r_j, \quad \sigma_r = \sqrt{\frac{1}{G} \sum_j (r_j - \bar{r})^2}, \quad A_j = \frac{r_j - \bar{r}}{\sigma_r + \varepsilon}.$$

A_j 是回答级标量，再广播到该回答的 completion tokens。这里是总体型组内标准差，代码库的默认无偏样本标准差不一定等同。 $G=1$ 或全组奖励相同会给出零中心化优势，不能期待它提供质量区分。

例子。 奖励 $(0, 0, 1, 1)$ ，均值 0.5、标准差 0.5，忽略稳定项时优势为 $(-1, -1, 1, 1)$ 。换成 $(0, 0, 0, 0)$ 后优势全零，增加优化轮数也不会凭空产生成功信号。

18.2 组内 baseline 的统计细节

含当前样本的均值与当前动作相关。对独立同分布的 G 条轨迹、暂不做标准差归一化，令 $g_i = \nabla \log \pi(y_i)$ ，可推得

$$\mathbb{E}[g_i(r_i - \bar{r})] = (1 - 1/G)\mathbb{E}[g_i r_i].$$

因为交叉样本项中 $\mathbb{E}g_i = 0$ 。用不含自己的 leave-one-out baseline 可移除这一缩放；加入随机标准差后又不只是固定缩放。因此组相对优势是实用估计设计，不应直接宣称与原始 REINFORCE 完全无偏等价。

18.3 课程的 GR-REINFORCE

它使用组归一化优势、参考 KL 和每回答 token 平均。对 N 条 completion，

$$L_{\text{GRR}} = -\frac{1}{N} \sum_i A_i \frac{1}{T_i} \sum_{t=1}^{T_i} \log \pi_{\theta}(y_{i,t} | s_{i,t}) + \beta \widehat{\text{KL}}.$$

按作业约定，rollout batch 用一次 optimizer step 后重新采样。这是课程指定的训练版本，不是所有文献中 REINFORCE 的唯一标准定义；组标准化与变长 token 平均会改变原始序列期望奖励估计的性质。

18.4 GRPO 的 token 级代理

保存 old log-prob，令 $\rho_{i,t} = \exp(\ell_{\theta,i,t} - \ell_{\text{old},i,t})$ ，则

$$L_{\text{GRPO}} = -\frac{1}{N} \sum_i \frac{1}{T_i} \sum_t \min\{\rho_{i,t} A_i, \text{clip}(\rho_{i,t}, 1 - \epsilon, 1 + \epsilon) A_i\} + \beta \widehat{\text{KL}}.$$

优势和 old 概率在多轮更新中保持固定。GRPO 省去显式价值 baseline，但仍有估计偏差、长度效应和分布偏移；“不训练 Critic”不意味着不需要任何统计估计。PPO 可用 token value + GAE，适合更细的逐步信用；二者谁好需看任务和预算。

18.5 非负采样 KL：值的无偏不等于梯度自动正确

在固定上下文令 $\Delta = \log \pi_{\text{ref}}(a) - \log \pi_{\theta}(a)$ ，构造

$$\hat{k} = e^{\Delta} - \Delta - 1 \geq 0.$$

若 $a \sim \pi_{\theta}$ 且支持一致， $\mathbb{E} e^{\Delta} = 1$ ，所以 $\mathbb{E} \hat{k} = D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}})$ 。非负性来自 $x - \log x - 1 \geq 0$ 。

但若样本来自旧策略，该无偏等式一般不成立；即便样本在采样时来自当前策略，把离散样本冻结后只对 $\hat{k}$ 反传，也不自动得到完整 KL 目标梯度，因为目标采样分布本身依赖参数。正式笔记区分 **KL 数值估计**、**固定 rollout 上的正则 surrogate**、**精确 KL 梯度**。小步更新可有用，但不是恒等式。

18.6 从 batch 到 loss 的检查

按 `prompt` 分组生成 `G` 条 `completion`

解析并计算每条奖励；核对奖励失败的原因

只在同 `prompt` 内计算 `mean/std` 和 `advantage`

存储 `old log-prob`；用冻结 `reference` 计算 `ref log-prob`

正确 `shift token`；构建 `completion mask`（排除 `padding/prompt`）
按规定顺序先做回答内 `token reduction`，再做 `batch reduction`
更新；记录 `KL`、`clip fraction`、熵、长度和全零优势组比例

监测任务正确率与训练 `reward` 是否同步；序列长度是否漂移；有效 `token` 数、优势标准差、组内成功率分布是否异常。只看平均 `reward` 会遮住“全易题成功、难题完全无信号”的情况。

18.7 自测

题： `ref log-prob` 能用作 PPO `ratio` 分母吗？答：除非 `ref` 恰好是当前 `rollout` 的采样策略，否则不能。**题：** 非负 $\hat{k}$ 是否保证实际 `KL` 永远小？答：不保证，它只是每个采样 `token` 的正则量，仍需监测分布变化。

第七部分

探索、泛化、理论与实验

第十九章 探索、信息获取与无奖励技能学习

学习层级：A/B。掌握不确定性与随机性的区别；技能发现掌握机制。材料：CS285 L19、L23；后者使用官方讲义补足。

19.1 为什么随机动作不是完整答案

不知道某个动作好不好时，需要试；已知某动作有随机噪声时，不一定值得一直试。探索要获得影响未来决策的信息。长程任务还要求多步一致行为：每一步独立小概率探索，连续 H 次才能到达的区域可能几乎永远看不到。

在 K 臂 bandit 中，动作不改变后续可选状态。UCB 可用 $\hat{\mu}_a + c\sqrt{\log t / N_a}$ ，把均值与不确定性奖励相加；其保证依赖有界/次高斯、平稳等假设。Thompson sampling 从奖励模型后验采样，再选该模型下最优动作。二者都不是简单按固定概率随机选。

19.2 从 bandit 到深度探索

MDP 中有些动作当前回报低，却通往有价值的新区域；局部动作熵无法直接衡量这种长程价值。按 episode 采一个价值模型并保持一致行动，可以产生比逐步独立噪声更连贯的探索，这也是 posterior sampling 思想的直觉。

例子。走廊尽头有未知宝箱，只有连续向右十步才能到达。每步有一半概率掉头，完整走到的概率只有约 2^{-10} ；先选择“本幕探索右端”再持续执行更容易获得信息。

19.3 内在奖励的不同含义

计数奖励常随 $1/\sqrt{N(s)}$ 衰减，鼓励访问少见状态；高维状态需要抽象或伪计数。预测误差奖励鼓励模型暂时解释不了的转移，但可能被不可预测噪声吸引。RND 用固定随机目标网络与可训练预测网络的差衡量新颖性；它没有直接预测随机动力学，却仍可能受高熵观察和表示选择影响。

信息增益可写为对模型参数的后验 KL： $D_{\text{KL}}(p(\theta | \mathcal{D}, \text{新数据}) \| p(\theta | \mathcal{D}))$ 。它关心新数据使信念改变多少，而非原始预测误差有多大。近似推断和可计算性是难点。

量	衡量什么	常见误读
动作熵	给定状态的动作随机性	不等于覆盖更多状态

量	衡量什么	常见误读
状态熵	访问结果的分散程度	噪声也可带来高熵
模型信息增益	对未知机制减少多少不确定性	不等于误差大就有信息
技能—状态互信息	不同技能的结果可否区分	不保证技能对任务有用

19.4 没有任务奖励时学技能

采技能 $Z \sim p(z)$, 执行 $\pi(a | s, z)$, 用判别器 $q_\phi(z | s)$ 判断产生某状态的是哪个技能。由条件 KL 非负,

$$I(Z; S) = \mathbb{E}[\log p(z | s) - \log p(z)] \geq \mathbb{E}[\log q_\phi(z | s) - \log p(z)].$$

因此可用 $r_{\text{skill}} = \log q_\phi(z | s) - \log p(z)$ 训练策略, 并用技能标签训练判别器。DIAYN 固定技能先验、结合最大熵策略, 促进不同技能可区分而各技能内部保留多样性。实际奖励可在下一状态计算, 索引须一致。DIAYN

不同技能稳定访问左右两区时互信息高; 若所有技能访问同一分布, 再怎么随机动作也不能从状态识别技能。反过来, 凭无关视觉细节区分技能, 未必形成有用控制。无奖励意味着无外部任务奖励, 不意味着没有学习目标或环境交互。

19.5 Empowerment、目标覆盖与 Skew-Fit

Empowerment 描述动作选择能可靠影响多少未来结果, 常涉及给定初始状态时动作序列与未来状态的互信息。它与技能互信息有关, 但不同随机变量定义不应混为一谈。

目标条件任务可看 $I(G; S_T) = H(S_T) - H(S_T | G)$: 整体覆盖多种结果, 给定目标又能可靠控制结果。Skew-Fit 把目标分布学习与目标条件策略结合, 偏向更少访问的目标以扩大覆盖; 不代表任意采样的视觉目标都能达到。Go-Explore、HOMER 可作为进一步理解返回机制与状态抽象的入口。L23 讲义

19.6 自测

题: 看随机电视画面会一直有预测误差, 这算有益探索吗? 答: 未必, 若不可控且不减少任务相关不确定性, 只会吸引无效交互。**题:** 技能发现能替代所有目标条件学习吗? 答: 不能, 技能可以表达动作风格, 目标强调达到的结果, 二者可组合。

第二十章 多任务、目标条件、层次与 Meta-RL

学习层级: B/C。多任务与目标条件、后继特征与 options 必须能解释机制; C-learning 与 Meta-RL 的完整理论留作扩展。材料: CS285 L24 官方讲义, 覆盖 pp.5–53; 以下补充解释与例子用于连接前文。

技能发现回答“可以学哪些行为”, 本章回答“如何让已有经验服务于新目标”。迁移对象可以是共享参数、未来占用、低层控制器, 也可以是从交互中推断任务的能力。每次讨论迁移先说明奖励、动力学、观察或目标中什么改变了。

20.1 多任务与目标条件化

任务 c 可改变奖励、目标或动力学。若任务上下文已知, 学习 $\pi(a | s, c)$; 若任务未知, 必须从历史中推断相关信息。共享参数可能提高数据效率, 也可能因任务干扰、难度不均或奖励尺度不同而失衡。

目标条件化常写为 $\pi(a | s, g)$ 、 $Q(s, a, g)$ 。HER 的要点是利用真实达到的结果重新解释轨迹: 原目标失败的轨迹, 对另一目标可能成功。重标记后须根据新目标重算奖励, 并按任务定义处理成功终止; 若目标改变了物理动力学, 就不能随意复用原转移。

自编小例子。小车原本要去 A, 却到了 B。它没有完成去 A 的任务, 但这条经验能帮助学习去 B。不能把它直接当成“去 A 获得正奖励”的数据。

20.2 后继表示: 把“将访问哪里”与“那里值多少”分开

对固定策略定义未归一化后继表示:

$$M^\pi(s, s') = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t \mathbf{1}\{S_t = s'\} \mid S_0 = s \right].$$

当奖励只依赖当前状态时,

$$V^\pi(s) = \sum_{s'} M^\pi(s, s') r(s').$$

若用归一化版本 $\mu^\pi = (1 - \gamma)M^\pi$, 它在继续型 MDP 中是未来状态概率分布; 此时计算价值要除以 $1 - \gamma$ 。课堂使用归一化占用的地方, 必须显式换算, 不能与未归一化定义直接拼接。

更一般地，设一步奖励具有特征线性形式 $r_w(s, a, s') = \phi(s, a, s')^\top w$ ，定义

$$\psi^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t \phi(S_t, A_t, S_{t+1}) \mid S_0 = s, A_0 = a \right], \quad Q_w^\pi(s, a) = \psi^\pi(s, a)^\top w.$$

ψ^π 的 TD 目标为 $\phi(s, a, s') + \gamma \mathbb{E}_{a' \sim \pi}[\psi^\pi(s', a')]$ 。动力学、特征与策略固定而奖励权重改变时，能快速重估策略价值；所得是 Q_w^π ，不是新任务的 Q_w^* 。若保留多套已有策略的后继特征，可以按其 Q 值做广义策略改进；估计不精确时还需误差条件。

自编小例子。特征记录未来红色、蓝色区域的折扣访问次数， w 为两种颜色的奖励。更换颜色奖励无需重新预测访问次数；若墙的位置改变，未来访问规律也改变，原后继特征就可能失效。

20.3 C-learning：用分类恢复未来状态的密度比

连续状态中，精确命中某个点的概率通常为零，但对该位置的概率密度可以非零。用“未来状态样本”为正例、参考分布 $p_{\text{ref}}(g)$ 的样本为负例。若两类先验相等，最优分类器满足

$$C^*(s, a, g) = \frac{p_+^\pi(g \mid s, a)}{p_+^\pi(g \mid s, a) + p_{\text{ref}}(g)}, \quad \frac{C^*}{1 - C^*} = \frac{p_+^\pi(g \mid s, a)}{p_{\text{ref}}(g)}.$$

这只是 Bayes 公式给出的分类—密度比桥梁，不是完整 C-learning 更新。课程 p.33 先展示 on-policy 采样版本；原论文还推导 off-policy 递归分类，不能混写为“任意回放样本直接做上述分类就完成了全部算法”。[C-learning 原论文](#)

20.4 层次结构与时间抽象

Option 可记为 $o = (J_o, \pi_o, \beta_o)$ ：启动集合、内部策略、终止概率。高层选择 option，低层可能连续执行 τ 步。高层学习目标应包含这段累计折扣奖励，并用 γ^τ bootstrap：

$$y_{\text{high}} = \sum_{j=0}^{\tau-1} \gamma^j R_{t+j+1} + \gamma^\tau V_{\text{high}}(S_{t+\tau}),$$

环境真正终止时省略最后一项。不能把持续多步的 option 当成持续一步的动作来折扣。

结构带来的主要困难是联合学习：尚未学好的低层可能不被高层选择，从而拿不到训练数据；低层持续变化也使高层面临非平稳问题。先训练目标条件低层、再训练高层选择子目标，是值得比较的一条路径。

20.5 Meta-RL：学会利用试探获得的任务信息

多任务策略可以直接得到任务标签；Meta-RL 常要求根据少量交互适应未见任务。若任务是隐藏变量 c ，历史 h_t 可以形成信念 $b_t(c) = P(c | h_t)$ 。

在“同任务多 episode 适应”的循环网络设定中，环境 episode 结束不一定清空 RNN 记忆；同任务的线索需要留给后续 episode。更换独立任务时通常需要重置。该规则依赖评估协议，不能泛化为所有 RL 都不重置隐藏状态。

自编小例子。两扇门只有一扇有奖励，每个任务内奖励门固定。同任务第一幕试门的信息应帮助第二幕决策；新任务重新随机奖励门时，不能把旧门的结论当作已知事实。

20.6 五类设定的边界

设定	主要条件变量或结构	要解决的问题
多任务 RL	已知任务上下文 c	共享经验与参数
目标条件 RL	目标 g	用一个策略完成多个目标
技能发现	自采样技能 z	没有任务奖励时学可区分行为
层次 RL	高层选择低层技能/目标	时间抽象与组合
Meta-RL	历史/任务信念	利用交互快速适应

这些设定能够组合，并非五个互斥算法类别。

20.7 广义策略改进的具体接口

设已有策略 $\pi_1, \dots, \pi_K$ 的后继特征。新任务权重 w 给出每套 $Q_w^{\pi_i}(s, a)$ 。选择 $\pi_{\text{GPI}}(s) \in \arg \max_a \max_i Q_w^{\pi_i}(s, a)$ ，可在每个状态利用已有策略的最佳动作价值。在精确评估、相同动力学和折扣设定下，其价值至少不差于这些基策略；近似 Q 时保证会带误差项。不是简单把“整条轨迹最好的一个旧策略”全局选一次，也不是保证达到新任务的绝对最优。

20.8 工具箱与自测

自测与简答。只换奖励权重时，固定策略与动力学的未来特征可复用；换动力学通常不行。同任务跨幕适应可保留记忆，切换任务按协议重置。持续五步的技能累加五步折扣奖励，再以 γ^5 bootstrap。

来源：[L24 官方讲义](#)。

第二十一章 强化学习理论：误差、采样与保证边界

学习层级：A/B/C。 Bellman 压缩必须掌握；误差递推和浓缩要会使用；高阶样本复杂度证明以后补。材料：CS285 L20 官方讲义与 L22 复习。它们补足无转录的理论部分。

理论先限定什么被观测、哪些对象精确，再问误差怎样变化。这个顺序能防止把“理想算子收敛”当成“某个深度实现必然收敛”。

21.1 先固定问题，再陈述保证

这里先采用有限状态/动作、无限时域折扣 MDP, $0 \leq \gamma < 1$, 且 $|r(s, a)| \leq R_{\max}$ 。令 $r(s, a)$ 表示一步奖励的条件均值, $P(\cdot | s, a)$ 为转移分布, $\|\cdot\|_{\infty}$ 表示对所有状态动作取最大绝对值。

“价值迭代收敛”“用样本估计模型的误差小”“深度 Q 网络训练稳定”是三个不同命题，不能相互替代。样本复杂度还必须说明样本如何获得；给定每个状态动作的采样能力，并未解决如何探索到这些状态。

21.2 Bellman 压缩：为什么精确价值迭代能收敛

定义最优 Bellman 算子：

$$(\mathcal{T}Q)(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim P(\cdot | s, a)} \left[\max_{a'} Q(s', a') \right].$$

利用 $|\max_i x_i - \max_i y_i| \leq \max_i |x_i - y_i|$, 得到

$$\|\mathcal{T}Q - \mathcal{T}\tilde{Q}\|_{\infty} \leq \gamma \|Q - \tilde{Q}\|_{\infty}.$$

所以 $Q_{k+1} = \mathcal{T}Q_k$ 满足

$$\|Q_k - Q^*\|_{\infty} \leq \gamma^k \|Q_0 - Q^*\|_{\infty}.$$

这里证明的是精确算子的压缩。若更新中加入回归投影、采样或非凸优化，就需要额外分析，不能把同一结论直接贴到 DQN 上。

21.3 近似更新：把两类误差接起来

设一次学习后的 Q_{k+1} 与精确 backup 的差满足

$$\|Q_{k+1} - \mathcal{T}Q_k\|_\infty \leq \epsilon_k.$$

记 $e_k = \|Q_k - Q^*\|_\infty$ ，三角不等式给出

$$e_{k+1} \leq \gamma e_k + \epsilon_k.$$

若每一步 $\epsilon_k \leq \epsilon$ ，展开递推可得

$$e_K \leq \gamma^K e_0 + \epsilon \frac{1 - \gamma^K}{1 - \gamma}.$$

因此 $\limsup_K e_K \leq \epsilon/(1 - \gamma)$ 。用 $\limsup$ 而非直接断言序列收敛，因为持续的近似误差可能导致振荡。

若 $\widehat{\mathcal{T}}$ 是采样得到的 backup，再拆开：

$$\|Q_{k+1} - \mathcal{T}Q_k\|_\infty \leq \underbrace{\|Q_{k+1} - \widehat{\mathcal{T}}Q_k\|_\infty}_{\text{拟合/逼近与优化误差}} + \underbrace{\|\widehat{\mathcal{T}}Q_k - \mathcal{T}Q_k\|_\infty}_{\text{采样误差}}.$$

低训练 MSE 不自动给出全状态动作的无穷范数误差界；没覆盖到的区域尤其如此。

自编小例子。一状态、一动作、自环环境，真实奖励为 0。若每次 backup 固定多加 0.01，最终误差为 $0.01/(1 - \gamma)$ ： $\gamma = 0.9$ 时为 0.1， $\gamma = 0.99$ 时为 1。微小的局部偏差能通过长程自举放大。

21.4 模型误差与有效时域

固定策略 π ，令 P^π 为状态转移矩阵。若真实模型和估计模型的奖励相同，且 $\widehat{P}^\pi$ 也是随机矩阵，则

$$V^\pi - \widehat{V}^\pi = \gamma(I - \gamma P^\pi)^{-1}(P^\pi - \widehat{P}^\pi)\widehat{V}^\pi.$$

因为 $\|(I - \gamma P^\pi)^{-1}\|_\infty \leq (1 - \gamma)^{-1}$ ，且 $\|\widehat{V}^\pi\|_\infty \leq R_{\max}/(1 - \gamma)$ ，若每行转移概率的 L1 误差至多 ϵ_P ，则

$$\|V^\pi - \widehat{V}^\pi\|_\infty \leq \frac{\gamma R_{\max} \epsilon_P}{(1 - \gamma)^2}.$$

这是一个便于理解的固定策略界，不是最紧样本复杂度定理。奖励也有误差时要增加相应项；策略由同一数据选出来时，要额外处理统一保证。正式推导可继续参照讲义引用的 [RL Theory 教材](#)。

本节自测。为什么 γ 接近 1 时误差界恶化？为什么经验回放上的低损失不足以保证策略好？请分别回答“误差传播”与“数据覆盖”，不要混成一个原因。

21.5 一条带条件的采样界

固定有界 V ，令 $X_j = R_j + \gamma V(S'_j)$ 为同一 (s, a) 下独立样本，假设每个 X 落在长度 B 的区间。Hoeffding 给出

$$P\left(\left|N^{-1}\sum_j X_j - \mathbb{E}X\right| > \epsilon\right) \leq 2\exp(-2N\epsilon^2/B^2).$$

若有限 MDP 的每个状态动作都有 N 个这样的样本，union bound 得到同时误差不超过 ϵ 的充分样本量

$$N \geq \frac{B^2}{2\epsilon^2} \log \frac{2|\mathcal{S}||\mathcal{A}|}{\delta}.$$

这是每对 N 个样本，总量还要乘状态动作数；它没有说明如何走到所有状态。这里 V 预先固定或独立于这些评估样本。若 V 也由同一批数据自适应选择，要用独立样本、统一浓缩或合适的依赖分析，不能直接套这条固定函数界。

21.6 从价值误差到策略损失

若估计 Q 满足 $\|\widehat{Q} - Q^*\|_\infty \leq \epsilon$ ，令 $\hat{\pi}$ 对它贪心。设 a^* 为真最优动作，则

$$Q^*(s, a^*) \leq \widehat{Q}(s, a^*) + \epsilon \leq \widehat{Q}(s, \hat{\pi}(s)) + \epsilon \leq Q^*(s, \hat{\pi}(s)) + 2\epsilon.$$

每个状态的局部最优性差距至多 2ϵ ，再沿执行策略传播，得到 $\|V^* - V^{\hat{\pi}}\|_\infty \leq 2\epsilon/(1 - \gamma)$ 。这是基于全域误差保证的一个简单界；只有训练集误差小并不足以使用它。

21.7 Regret、PAC 与预测误差是不同问题

Regret 统计学习过程中相对基准策略累计损失多少；PAC 通常问多少样本后能以高概率得到近优策略；固定策略价值误差问估值是否准确。它们需要不同的采样和交互设定。L20 的入门分析不能替代所有探索或神经网络理论。




图 21.1: 相同局部 backup 误差在不同折扣下的长期放大。

一张可复用的定理记录卡应写：问题设定、采样方式、函数类、奖励/时域、概率水平、误差范数、保证对象、未覆盖情形。形式复杂但条件空白的公式，不应进入速查表。

21.8 自测

题：每个状态动作都有 N 个独立样本的界，是不是在线探索算法？**答：**不是，它假定了采样覆盖，探索困难尚未解决。

题：为什么使用 $\limsup$ 描述有持续噪声的误差？**答：**误差可以在界内振荡，并不一定收敛到某个数值。

第二十二章 实验方法、实现诊断与开放问题

学习层级：A/B。从第一个小实验就使用本章。课程对应 HW1-5、L25；下列实验协议是整理建议，不是已完成的课程实验。

22.1 用什么证据判断学会了

训练损失、价值估计、环境回报和任务成功率回答不同问题。Q 变大可能只是过估计；奖励模型分数提高可能来自漏洞；平均训练回报提高也可能依赖更容易的训练分布。先定义目标指标和测试任务，再运行训练。

横轴至少区分环境交互数、更新步数、处理 token 数和墙钟时间。SAC 同样环境步数可能做更多梯度更新；离线预训练并非没有数据成本；LLM 更长回答也会消耗更多 token。

22.2 一个最小可复现实验协议

固定任务版本、动作/观察变换、终止规则、评估采样方式与预算。训练与评估随机性分开记录，多种子报告每个种子及汇总量。均值之外保留离散程度、失败比例和样本量；少数种子不能支撑过强的显著性结论。

超参数在验证任务或预先规定预算内选择，不反复利用测试集找最好配置。比较新方法时保留最简单合理基线和关键消融，例如 BC、普通 Q、去掉正则、固定温度。不要同时改网络、奖励缩放和算法，再把全部收益归给新损失。

22.3 按数据流定位错误

现象	先查哪里	能排除什么
Q 暴涨，回报不涨	target、终止 mask、数据外动作	目标偏差/外推反馈
Actor 几乎不变	log-prob、detach、动作梯度	梯度路径被切断
PPO KL 突增	old log-prob、epoch、学习率	概率比定义/过度复用
SAC 动作贴边	tanh 密度、温度、reward scale	熵与价值尺度失衡
GRPO 优势全零	组内奖励分布、解析器、G	没有相对学习信号
训练好评估差	预处理、随机策略、环境版本	评估协议不一致

先在极小环境手算一轮目标，再增加模型。看见 NaN 应定位第一个非有限张量，而不是只在最终 loss 上加 clamp；clamp 可能掩盖密度或 mask 错误。

22.4 本工程附带的可运行核对

experiments/toy_mdp.py 用标准 Python 验证前文小 MDP 的精确价值、价值迭代、MC/TD 目标、GAE、IS、bandit 梯度和 PPO 分段值。它们验证公式与例子的一致性；不是 DQN/PPO/SAC 的训练复现，也不构成课程作业完成证据。

```
python3 experiments/toy_mdp.py
```

experiments/experiment-template.md 提供记录表。先写假设和预期失败现象，再跑实验；失败结果也保留条件与诊断。图片脚本生成数学示意，不把示意曲线冒充实际训练曲线。

22.5 五次作业的实践落点

作业	正文入口	值得留下的证据
HW1	模仿学习	示范拟合与完整 rollout 差异
HW2	PG、AC	baseline、reward-to-go、方差对比
HW3	DQN、连续控制	target、replay、Actor/Critic 数据流
HW4	LLM RL	组内优势、KL、长度与样本复用
HW5	离线、FQL	约束强度、覆盖、生成策略与蒸馏

使用官方作业当前要求核对提交，不把本书建议当作官方评分细则。[CS285 课程目录](#)

22.6 开放问题怎样进入笔记

L25 分别从工程控制、真实世界学习、利用既有数据学习决策来回顾 RL。工程场景关注仿真、反馈和迁移；真实世界关注奖励指定、恢复与持续适应；既有数据视角关注监督来源和如何将知识转成行动。[L25 官方讲义](#)

把愿景转成有约束的问题：固定真实交互预算时，模型能省多少数据？没有人工 reset 能否恢复？新目标与新动力学分别如何适应？奖励上升是否伴随独立成功率上升？同一数据用于模仿、价值学习和建模分别带来什么？

这些问题没有一个缩写能统一解决。阅读新论文时先定位它修改了哪种设定、使用了哪些额外数据、通过哪条证据支持改进，再决定放入哪章。

22.7 最终自测

拿到一个新算法，能否填写：数据从哪里来、估计什么值、怎样更新策略、哪些路径停止梯度、与哪个基线比较、什么条件下可能失败？如果能完整填写，通常比只背住 loss 公式更接近理解。

参考文献

课程目录、逐讲 PDF、白板视频与上传稿的精确映射见附录 C: 材料覆盖与来源定位。下列文献用于追溯核心方法和进一步阅读; 预印本链接可能早于会议发表年。正文的自编例子与数学衔接不冒充原课程逐字内容。

Agarwal, Alekh, Nan Jiang, Sham M. Kakade, 和 Wen Sun. 不详. *Reinforcement Learning: Theory and Algorithms*. <https://rltheorybook.github.io/>.

Christiano, Paul F., Jan Leike, Tom Brown, Miljan Martic, Shane Legg, 和 Dario Amodei. 2017 年. *Deep Reinforcement Learning from Human Preferences*. <https://arxiv.org/abs/1706.03741>.

Eysenbach, Benjamin, Abhishek Gupta, Julian Ibarz, 和 Sergey Levine. 2019 年. *Diversity is All You Need: Learning Skills without a Reward Function*. <https://arxiv.org/abs/1802.06070>.

Eysenbach, Benjamin, Ruslan Salakhutdinov, 和 Sergey Levine. 2021 年. *C-Learning: Learning to Achieve Goals via Recursive Classification*. <https://arxiv.org/abs/2011.08909>.

Fujimoto, Scott, Herke van Hoof, 和 David Meger. 2018 年. *Addressing Function Approximation Error in Actor-Critic Methods*. <https://arxiv.org/abs/1802.09477>.

Haarnoja, Tuomas, Aurick Zhou, Pieter Abbeel, 和 Sergey Levine. 2018 年. *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*. <https://arxiv.org/abs/1801.01290>.

Ho, Jonathan, 和 Stefano Ermon. 2016 年. *Generative Adversarial Imitation Learning*. <https://arxiv.org/abs/1606.03476>.

Kostrikov, Ilya, Ashvin Nair, 和 Sergey Levine. 2022 年. *Offline Reinforcement Learning with Implicit Q-Learning*. <https://arxiv.org/abs/2110.06169>.

Kumar, Aviral, Aurick Zhou, George Tucker, 和 Sergey Levine. 2020 年. *Conservative Q-Learning for Offline Reinforcement Learning*. <https://arxiv.org/abs/2006.04779>.

Levine, Sergey. 2026 年. *CS 185/285: Deep Reinforcement Learning, Spring 2026*. <https://rail.eecs.berkeley.edu/deeprlcourse/>.

- Mnih, Volodymyr 等. 2015 年. 《Human-level control through deep reinforcement learning》. *Nature* 518: 529 ~ 33. <https://doi.org/10.1038/nature14236>.
- Park, Seohong, Qiyang Li, 和 Sergey Levine. 2025 年. 《Flow Q-Learning》. *Proceedings of ICML*. <https://proceedings.mlr.press/v267/park25f.html>.
- Rafailov, Rafael, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, 和 Chelsea Finn. 2023 年. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*. <https://arxiv.org/abs/2305.18290>.
- Ross, Stephane, Geoffrey Gordon, 和 Drew Bagnell. 2011 年. 《A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning》. *Proceedings of AISTATS*. <https://proceedings.mlr.press/v15/ross11a.html>.
- Schulman, John, Sergey Levine, Philipp Moritz, Michael I. Jordan, 和 Pieter Abbeel. 2015 年. *Trust Region Policy Optimization*. <https://arxiv.org/abs/1502.05477>.
- Schulman, John, Philipp Moritz, Sergey Levine, Michael I. Jordan, 和 Pieter Abbeel. 2016 年. *High-Dimensional Continuous Control Using Generalized Advantage Estimation*. <https://arxiv.org/abs/1506.02438>.
- Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford, 和 Oleg Klimov. 2017 年. *Proximal Policy Optimization Algorithms*. <https://arxiv.org/abs/1707.06347>.
- Sutton, Richard S., 和 Andrew G. Barto. 2018 年. *Reinforcement Learning: An Introduction*. 2 版. MIT Press. <http://incompleteideas.net/book/the-book-2nd.html>.

附录 A 符号与数学工具

本附录作为全书共同约定。局部章节若改变时域、归一化或采样分布，会显式说明。

A.1 符号表

记号	含义	易混点
S_t, A_t, R_{t+1}	当前状态、动作、下一步收到的奖励	奖励索引在动作之后
G_t	从 t 起重新计折扣的回报	与从起点计的 $\gamma^t G_t$ 不同
P, r, ρ_0	转移、奖励均值、初始分布	环境模型不含策略参数时才可直接消去其 score
π, b	目标策略、行为策略	与 online/offline 分类不同
V^π, Q^π, A^π	真值、动作真值、优势	与参数网络估计不同
θ, ϕ, ψ	网络参数，具体角色逐章定义	同字母跨章不一定同一网络
$\bar{\theta}$	慢速目标网络参数	不等于数据采样的 old policy
sg	停止梯度	冻结参数不总等于切断输入梯度
m_t, c_t	bootstrap mask、轨迹连接 mask	时间截断可能分别取 1、0
d_γ^π	归一化折扣占用	总质量为 1；价值公式有额外系数
α, λ, β	步长/温度/正则等局部参数	先看本章定义，不凭字母猜角色

A.2 条件期望与全期望

$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X | Y]]$ 是 Bellman 分解与策略梯度换回报为 Q 的共同工具。给定状态动作后，未来回报仍是随机变量；它的条件期望在结果出现前就有意义。

线性性允许交换有限求和和期望。无限求和、梯度与积分交换需支配可积性或其他正则条件；有界奖励与折扣常用于保证相关量有限。

A.3 Score-function 与重参数化

Score-function 恒等式为 $\nabla_{\theta} \mathbb{E}_{p_{\theta}} f = \mathbb{E}[f \nabla \log p_{\theta}]$, 假设 f 本身不显式依赖 θ ; 若依赖, 还需加 $\mathbb{E}[\nabla f]$ 。它可处理离散样本, 但可能高方差。

重参数化写 $X = g_{\theta}(\epsilon)$, $\epsilon \sim p(\epsilon)$, 得到 $\nabla \mathbb{E} f(X) = \mathbb{E}[\nabla_x f \nabla_{\theta} g]$, 要求可微等条件。环境不可微不妨碍 score-function; SAC 对动作和 Critic 可微, 因此可用重参数化。

A.4 KL、熵与互信息

离散熵 $H(p) = -\sum_x p(x) \log p(x)$; KL 为 $D_{\text{KL}}(p \| q) = \sum_x p(x) \log[p(x)/q(x)]$, 要求 q 覆盖 p 的支持, 否则可为无穷。KL 不对称, 不是距离度量。

互信息 $I(X; Y) = D_{\text{KL}}(p(x, y) \| p(x)p(y)) = H(X) - H(X | Y)$ 。它度量统计依赖, 不自动意味着因果可控; 技能/动作由策略干预时还需明确生成过程。

连续分布使用密度, 微分熵可为负; 在可逆坐标变化下会改变。KL 在一致可逆变换下不变, 这也是动作变换要同时修正两侧密度的原因。

A.5 ELBO 的一行展开

将 $p(x, z) = p(z | x)p(x)$ 代入, 得到

$$\mathbb{E}_q \log \frac{p(x, z)}{q(z)} = \log p(x) - D_{\text{KL}}(q(z) \| p(z | x)).$$

若 q 的支持与模型不匹配或积分不存在, 这种形式也需要额外条件。VAE 常把第一项拆成重建与先验 KL; 世界模型则将先验扩为随动作演化的序列结构。

A.6 几何级数与误差递推

$\sum_{k=0}^{K-1} \gamma^k = (1 - \gamma^K)/(1 - \gamma)$ 。若 $e_{k+1} \leq \gamma e_k + \epsilon_k$, 逐次代入得到

$$e_K \leq \gamma^K e_0 + \sum_{j=0}^{K-1} \gamma^{K-1-j} \epsilon_j.$$

这是表格迭代误差、模型误差和近似动态规划的常用骨架, 使用前要检查收缩系数、范数与单步误差假设。

附录 B 算法速查与实现工具箱

每个公式都要与正文条件一起使用。这里的 r 表示已采集的一步奖励， m 是 bootstrap mask，目标 y 在 Critic 更新中停止梯度。

B.1 目标值对照

方法	一步目标 y	使用条件
TD(0)	$r + \gamma m V(s')$	固定策略预测
SARSA	$r + \gamma m Q(s', a')$	a' 按目标策略采样
Expected SARSA	$r + \gamma m \mathbb{E}_{a' \sim \pi} Q(s', a')$	目标策略明确
Q-learning	$r + \gamma m \max_{a'} Q(s', a')$	表格或近似控制
DQN	$r + \gamma m \max_{a'} Q_{\bar{\theta}}(s', a')$	冻结目标网络
Double DQN	$r + \gamma m Q_{\bar{\theta}}(s', a^*)$	选择/估值分开
SAC	$r + \gamma m [\min Q_{\text{target}}(s', a') - \alpha \log \pi(a' s')]$	随机动作与密度一致
IQL	$r + \gamma m V(s')$	数据内 expectile V

Double DQN 行中 $a^* = \arg \max_a Q_{\theta}(s', a)$ 。

FQL 的 2026 HW5 版本使用双 Q 均值与一步 Actor，不套用本表 SAC 目标。

B.2 策略改进的对象

家族	主要策略目标	数据复用要点
REINFORCE	$\log \pi \times$ 回报/优势	标准版本使用当前策略样本
PPO	clipped ratio $\times$ 优势	old log-prob 与优势固定
DDPG/TD3	连续 Actor 最大化 Q	replay 状态上的代理目标
SAC	最大化 Q 与动作熵	Q 对动作的梯度必须保留
BC	最大化示范动作似然	仅拟合数据，不直接优化奖励
IQL Actor	优势加权动作似然	权重冻结，注意指数溢出
FQL Actor	最大化 Q 与行为蒸馏	teacher flow 不经蒸馏反传
GRPO	token clipped ratio $\times$ 组优势	区分 old 与 reference

B.3 六个必须会解释的式子

1. Bellman: $Q^\pi = r + \gamma PV^\pi$, 当前奖励加后续价值。
2. TD residual: $\delta_t = R_{t+1} + \gamma m_t V_{t+1} - V_t$, 一步预测误差。
3. GAE: $\hat{A}_t = \delta_t + \gamma \lambda c_t \hat{A}_{t+1}$, 多步 residual 混合。
4. 动作比: $\rho = \exp(\ell_\theta - \ell_{\text{old}})$, 不自动修正状态占用。
5. Soft value: $V = \alpha \log \sum_a \exp(Q_a/\alpha)$, 有限动作的熵正则最大值。
6. 误差递推: $e_{k+1} \leq \gamma e_k + \epsilon_k$, 单步误差会随有效时域放大。

B.4 通用 tensor 与梯度检查

对象	期望形状示例	检查
离散动作 Q	$B \times A$	gather 后为 B, 不和 $B \times 1$ 意外广播
连续动作 log-prob	B	已对动作维求和并加 Jacobian 修正
Token log-prob	$B \times T$	logits/token 已 shift
Completion mask	$B \times T$	prompt/padding 排除, EOS 约定一致
Advantage	B 或 $B \times T$	在 Actor loss 中冻结
Return target	B 或 $B \times T$	不随本轮 Critic 更新反向变化

B.5 三种不要混淆的“停止”

真正终止意味着任务未来价值为零；rollout 截断意味着暂时没有后续样本；停止梯度意味着当前优化不沿某个计算路径传播。这三件事没有一一对应关系。

B.6 学习层级

A: 问题建模、Bellman、MC/TD、PG、GAE、PPO、SAC 数据流、offline 风险、LLM mask/ratio。

B: TRPO 几何、控制即推断、IQL/CQL、模型规划、FQL、技能与后继表示。

C: 完整复杂度最优界、复杂生成模型证明、完整 Meta-RL 理论、未纳入主线的大型世界模型和多智能体系统。C 级不代表不重要，只表示本轮先保留可继续阅读的接口。

附录 C 材料覆盖与来源定位

本书不是把转录稿逐句拼接，而是按 22 章重新编写。下表保留每份上传稿的独立入口；完整文件名与 SHA-256 在项目根目录的 source-ledger 文件中。哈希只证明本轮使用了哪份文件，不证明原稿无误。

C.1 白板材料：28 份

视频/分 P	主题	正文章节
BV1RA411q7wt / 1	马尔可夫链、回报与问题入口	1–2
BV1RA411q7wt / 2	MDP 与环境动态	1–2
BV1RA411q7wt / 3	策略与价值函数	2
BV1RA411q7wt / 4	Bellman 期望方程	2
BV1RA411q7wt / 5	Bellman 最优方程	2
BV1nV411k7ve / 1	动态规划概览、矩阵策略评估	2
BV1nV411k7ve / 2	迭代策略评估	2
BV1nV411k7ve / 3	策略改进定理	2
BV1nV411k7ve / 4	贪心改进与策略迭代	2
BV1nV411k7ve / 5	价值迭代与广义策略迭代	2
BV1rF411J7Mw / 1	MC 前情回顾	2–3
BV1vm4y1Z7Ce / 1	MC 策略评估	3
BV1N5411o7QD / 1	Exploring Starts MC 控制	3
BV1bS4y1C75M / 1	On-policy 与 off-policy	3–4
BV1EZ4y1R7r4 / 1	异策略 MC 评估	4
BV1sS4y1C7tR / 1	异策略 MC 评估与控制	3–4
BV1wS4y1F7zn / 1	TD 策略评估	3
BV1BS4y1r7cm / 1	SARSA	3
BV1cZ4y1C7Ma / 1	Q-learning	3、6
BV15L411T7LM / 1	Expected SARSA	3
BV1MS4y1r7ta / 1	策略近似	7
BV18u411Q76q / 1	策略梯度定理	7
BV1xb4y1W7Ye / 1	REINFORCE	7
BV1RF411x7oS / 1	REINFORCE baseline 与 Actor–Critic	7–8
BV1yT4y1U78Z / 1	Dyna Architecture	13

视频/分 P	主题	正文章节
BV1ar4y1p7ES / 1	规划算力聚焦	13
BV1cY4yli785 / 1	决策时规划	13
BV1s5411D7JT / 1	MCTS	13

C.2 CS285 转录: L1–19

官网的简写题名与视频标题可能不同，依据讲次和 Spring 2026 标识对齐。L9 视频题名强调 Off-Policy Policy Gradient，官网归为 Advanced Policy Gradients Part 1。

讲次	主题	正文章节
L1	课程概览	1
L2	行为克隆	12
L3	行为克隆续、策略表示	12、15
L4	RL 基础	1–2
L5	策略梯度	7
L6	Actor–Critic	8
L7	基于价值的 RL	5–6
L8	Q-learning 实践	6、11
L9	异策略策略梯度 / 高级 PG (一)	4、9
L10	高级 PG (二)	9
L11	变分推断	10、数学附录
L12	RL 中的变分推断	10、13
L13	控制即推断	10–11、16
L14	序列与 LLM RL	16–18
L15	模型式 RL 基础	13
L16	模型式 RL 算法	13
L17	离线 RL 基础	14
L18	离线 RL 算法	14–15
L19	探索	19

C.3 官方补充: L20–25

讲次	补充主题	正文章节
L20	RL Theory	21
L21	Midterm Review 1	跨章复习
L22	Midterm Review 2	跨章复习
L23	Exploration and Skill Learning	19
L24	Multi-Task and Hierarchical RL	20
L25	Challenges and Open Problems	22

C.4 复习讲义的回访入口

L21 的 BC、PG、AC 对照第 12、7–9 章；L22 的价值、推断、模型、离线、探索与理论对照第 5–6、10–11、13–15、19、21 章。复习课用于检查章节之间的关系，不重复生成两章正文。

C.5 自行补充的桥梁

n-step/ λ -return 的统一记法、IS 支持条件、半梯度/双采样说明、误差递推小证明、手算例子和实验脚本属于补充解释。DDPG/TD3、DPO 与复杂理论的深度按 A/B/C 边界处理。原提纲和上一轮补读稿保存在 docs 中，以便追溯本轮结构变化。

C.6 可核验程度

上传稿引用的原始截图没有随附。本书重新排写数学公式并绘制示意图；没有把画面描述当作已经亲见的板书。正文按数学定义修正明显矛盾，涉及课堂具体措辞的判断仍以原音视频复核为准。未收录原始转录全文和课程 PDF，避免把含失效图片路径的中间材料混入阅读版本。

附录 D 校订记录与结论边界

以下记录的是所上传文字的表达问题；没有核对原始音视频的位置，不将错误归因于讲师。原稿保留，规范笔记使用修正表述。时间均为稿件时间戳。

位置	核心修正
Expected SARSA 稿, 11:42 起	退化为 Q-learning 还需目标策略贪心
异策略 MC 稿, 开头	off-policy 不译为 offline
CS285 L8, 01:49 起	无 replay 的 Q-learning 仍可为 off-policy
CS285 L17, 04:49 起	标准 REINFORCE 的 on-policy 描述不能颠倒
MC 控制稿, 04:50 起	精确策略改进与有限样本估计分开
MC 控制稿, 05:24 起	max 返回值, argmax 返回动作
MDP p2, 开头	离散不必有限
CS285 L9, 29:38 起	联合占用与条件动作概率分开记
全部材料	术语识别错误、重复画面与编辑提示不进入正文

完整文件标识和时间段保存在 docs/material-audit.md；本表为阅读速查。

D.1 一个可立即使用的更正例子

Expected SARSA 的目标为

$$y = r + \gamma \sum_{a'} \pi(a' | s') Q(s', a').$$

若下一状态的 Q 值是 (1, 3)，目标策略为 (1/2, 1/2)，期望项为 2；即使行为策略不同，它也不是 Q-learning 的最大值 3。只有目标策略把质量放在最大值动作上，才退化为 Q-learning 目标。原文前面讲到贪心条件，笔记中不能在总结时把它省略。

D.2 全书统一的符号约定

- 转移写作 $(S_t, A_t, R_{t+1}, S_{t+1})$ ；回报 $G_t = \sum_{k \geq 0} \gamma^k R_{t+k+1}$ 。CS285 若用 r_t ，转换时明确一步索引。
- 行为策略 b 负责采样，目标策略 π 是正在评估/改进的对象；旧策略与 reference policy 另设符号。

- 折扣占用若归一化，写 $d_{\gamma}^{\pi}(s) = (1 - \gamma) \sum_t \gamma^t P_{\pi}(S_t = s)$ ；策略梯度系数、后继表示与价值公式随之换算。
- 神经网络输出用 Q_{θ}, V_{ϕ} ，数学真值用 Q^{π}, V^{π} ；不要把有限样本估计直接写成真值。
- $\gamma=1$ 的有限幕推导与 $\gamma<1$ 的无限时域推导分开记录；终止与截断也依任务语义分别处理。

D.3 本轮新增的统一约定

起点折扣目标的策略梯度保留外部 γ 的时间权重；GAE 的 bootstrap mask 与跨 reset 连接 mask 分开；FQL 的作业双 Q 均值不与 SAC min 混用；GRPO 中组标准化与长度 reduction 明确列出；采样 KL 的数值无偏不等于冻结样本反传得到精确 KL 梯度。

本书完成的是既定范围的完整初稿和针对性公式审校，不声称逐字复核所有视频。C 级内容明确标注扩展；实验结果只有附带小例子脚本实际输出，不包含未运行的课程训练。