

随机过程工具箱

P0 + P1 完整稿 · v0.4

目录

阅读说明	5
阅读路线	5
写作与使用约定	5
1 随机过程与条件信息	6
1.1 过程、路径与有限维分布	6
1.2 条件期望是对信息的投影	6
1.3 滤过与几种不同的结构	7
1.4 收敛方式与极限交换	7
2 联合高斯与高斯过程	8
2.1 从一维正态到联合高斯	8
2.2 特征函数为何封闭了线性计算	8
2.3 不相关何时足以推出独立	9
2.4 高斯过程由哪些量确定	9
2.5 高阶矩：把乘积拆成协方差配对	10
2.6 低维 Price 定理：对相关参数求导	10
3 条件高斯与估计	12
3.1 先分清：未知量、观测量与条件	12
3.2 条件分布：均值修正，协方差扣减	13
3.3 关键推导：保留观测块，消掉交叉块	13
3.4 残差解释：观测到底解释了什么	14
3.5 为什么条件均值就是最优估计	15
3.6 应用：从带噪观测推断状态	16
3.7 条件下求函数期望：先求分布，再求矩	17
3.8 查阅时先检查这几件事	17
4 泊松过程与到达时间	18
4.1 定义中每个条件的作用	18
4.2 用概率生成函数推出计数分布	18
4.3 到达时刻与指数间隔	19
4.4 反过来：由独立间隔构造计数	19
4.5 第 n 次到达的分布	20
4.6 叠加与独立稀疏化	20
4.7 非齐次泊松：强度随时间变化	21
4.8 复合泊松：次数之外还有每次的贡献	21
5 条件到达时刻与等待问题	23
5.1 给定总数后的联合密度	23
5.2 三个直接可用的推论	23
5.3 固定观察时刻的前向等待与年龄	24
5.4 为什么这不违背指数间隔的结论	25
5.5 一个等待成本计算	25
5.6 非齐次情形：位置按强度加权	25

6	Markov 链与分布演化	27
6.1	从条件分布定义 Markov 性	27
6.2	多步转移与 Chapman–Kolmogorov 方程	27
6.3	一个二状态模型	28
6.4	首次进入与一步分析	28
6.5	随机时刻的 Markov 性	29
7	状态分类与空间分解	30
7.1	可达、互达与闭类	30
7.2	首次返回与常返	30
7.3	更新方程与生成函数	31
7.4	平均返回时间与类性质	31
7.5	周期与循环分解	32
7.6	对称随机游走：常返不代表返回快	32
8	平稳分布与长期行为	33
8.1	平稳分布是不变概率	33
8.2	从返回周期构造平稳分布	33
8.3	访问频率：无需非周期条件	34
8.4	正常返与平稳概率的等价性	34
8.5	远期分布：周期条件在这里出现	35
8.6	有限可约链的边界	35
9	鞅与停止	37
9.1	定义与基本计算	37
9.2	可预测下注与乘积鞅	37
9.3	凸变换与下鞅	38
9.4	可预测漂移：把平均趋势单独记账	38
9.5	停时与停止过程	39
9.6	可选停止：先有限，再交换极限	39
9.7	赌徒破产：停止方法怎样正确使用	39
9.8	Wald 恒等式：随机项数怎样进入期望	40
10	鞅的收敛	42
10.1	非负下鞅的最大不等式	42
10.2	从最大不等式到强大数定律	42
10.3	L1 有界鞅的路径收敛	43
10.4	路径极限为何可以损失期望	43
10.5	一致可积：补足期望极限交换	43
10.6	L2 有界鞅：用正交性证明更强收敛	44
10.7	分枝过程：先消去平均增长率	44
	附录	46
A	共用概率与矩阵工具	46
A.1	非负求和、尾概率与极限交换	46
A.2	Borel–Cantelli 与可积变量的尾部	46
A.3	条件 Jensen、全方差与全协方差	47
A.4	半正定序与 Schur 补	47
B	关键结论的补充证明	48
B.1	泊松过程在到达时刻重新开始	48

B.2	有限不可约非周期链的分布收敛	48
B.3	上穿次数与鞅收敛	49
B.4	一致可积为何允许 L^1 取极限	49
C	序贯概率比检验	50
C.1	先固定似然比方向	50
C.2	用非负鞅得到严格错误界	50
C.3	常用 Wald 阈值为什么带有近似	51
C.4	平均样本数: Wald 等式与越界修正	51
C.5	一个 Bernoulli 方向检查	52

阅读说明

这是一份用于理解、复习和查阅的随机过程工具箱。保留核心定义、准确条件、关键推导、必要直觉和使用边界。目前，包含一个短预备章，高斯、泊松、Markov 链和鞅四个主体单元，共十章，另有三个附录。

阅读路线

单元	要解决的问题	主要前置
短预备章	怎样描述过程、路径和条件信息	概率分布与期望
高斯：联合结构、条件估计	怎样利用均值和协方差做条件推断	多元分布与线性代数
泊松：计数、到达与等待	怎样连接到达次数、间隔与条件位置	独立性、条件概率与积分
Markov 链：演化、分类与长期行为	怎样由局部转移得到长期规律	条件信息、矩阵与级数
鞅：停止、最大不等式与收敛	怎样控制随机时间上的平均关系和路径波动	条件期望与收敛方式

首次阅读可按目录顺序进行。查阅时可从所需结论进入，但应同时阅读紧邻的条件；停时与无限状态的结论尤其如此。附录收纳反复使用的规则和容易打断正文的证明。

写作与使用约定

全书默认实值变量，随机向量为列向量；Markov 链的状态分布专用行向量。等式涉及条件期望时，默认在几乎处处意义下理解。时间、状态空间与矩条件在各章注明。

章节编号与交叉引用由 Quarto 管理。必要基础在本书简短回顾；概率基础可配合《概率论与数理统计工具箱》阅读。

公开来源和章节映射见仓库的[参考资料](#)。不收录原始转录和课程截图；正式开放许可待确定，见本项目 LICENSE。

1 随机过程与条件信息

随机过程把“一个随机量的分布”扩展为“一族随机量如何共同变化”。后面的计算始终围绕三个问题：观察到了什么、下一步如何依赖过去、什么意义下存在长期规律。

1.1 过程、路径与有限维分布

在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上，一族取值于状态空间 E 的随机变量

$$X = (X_t)_{t \in T}$$

称为随机过程。 T 是时间指标集， E 是状态空间，两者分别决定时间与状态的类型。例如 $T = \mathbb{N}_0, E = \mathbb{R}$ 是离散时间、连续状态过程；泊松计数过程的 $T = [0, \infty), E = \mathbb{N}_0$ 。

固定 t ， $X_t : \Omega \rightarrow E$ 是随机变量；固定样本点 ω ， $t \mapsto X_t(\omega)$ 是一条**样本路径**。单个数 $X_t(\omega)$ 既不是整个过程，也不是整条路径。

任取有限个时刻 $t_1, \dots, t_m$ ，向量 $(X_{t_1}, \dots, X_{t_m})$ 的联合分布称为有限维分布。各时刻的边缘分布通常不够：若 Z, W 独立且都服从标准正态分布， (Z, Z) 与 (Z, W) 的两个边缘相同，时间间的依赖却不同。

有限维分布描述过程的分布结构；连续性、右连续性等路径性质仍需单独说明。正文不从有限维分布自动推断路径连续。

全书以 $\mathbb{P}, \mathbb{E}, \text{Var}, \text{Cov}$ 表示概率、期望、方差与协方差， $\mathbf{1}_A$ 表示事件 A 的指标函数。随机向量默认为列向量；Markov 链的状态分布专门采用**行向量**，转移矩阵每行和为 1。

1.2 条件期望是对信息的投影

对于可积随机变量 X 和子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$ ， $\mathbb{E}[X | \mathcal{G}]$ 是一个 $\mathcal{G}$ -可测随机变量，满足

$$\mathbb{E}[\mathbf{1}_A \mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[\mathbf{1}_A X], \quad A \in \mathcal{G}.$$

它在几乎处处意义下唯一。 $\mathcal{G}$ 表示已经获得的信息，条件期望把 X 中无法由该信息确定的部分平均掉。记号 $\mathbb{E}[X | Y]$ 是 $\mathbb{E}[X | \sigma(Y)]$ 的简写；它是 Y 的函数，未必是常数。

本书反复使用下列规则，使用时必须核对可积性：

- **取出已知量：** H 为 $\mathcal{G}$ -可测，且有关乘积可积时， $\mathbb{E}[HX | \mathcal{G}] = H\mathbb{E}[X | \mathcal{G}]$ 。有界 H 是常用的充分条件。
- **塔式法则：**若 $\mathcal{H} \subseteq \mathcal{G}$ ，则 $\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$ 。信息集之间的包含关系不能省略。
- **独立性：**若 X 与 $\mathcal{G}$ 独立，则 $\mathbb{E}[X | \mathcal{G}] = \mathbb{E}X$ 。反过来，单凭条件均值不变不能推出独立。

若 $X \in L^2$ ，令 $m = \mathbb{E}[X | \mathcal{G}]$ 。对任意平方可积的 $\mathcal{G}$ -可测变量 H ，

$$\mathbb{E}[(X - m)H] = \mathbb{E}[H\mathbb{E}[X - m | \mathcal{G}]] = 0.$$

这就是条件期望的正交性。展开平方可得

$$\mathbb{E}(X - H)^2 = \mathbb{E}(X - m)^2 + \mathbb{E}(m - H)^2.$$

因此条件期望在所有利用当前信息的平方可积估计中最小化均方误差。章节 3 将把这个一般结论化成高斯情形的矩阵公式。

对连续型 Y ，事件 $\{Y = y\}$ 往往概率为零，不能直接用事件条件概率的比值定义条件分布。后文使用条件密度或其连续版本给出 $X | Y = y$ 的表达。

1.3 滤过与几种不同的结构

滤过 $(\mathcal{F}_t)_{t \in T}$ 是随时间增加的信息族： $s \leq t$ 时 $\mathcal{F}_s \subseteq \mathcal{F}_t$ 。若 X_t 对 $\mathcal{F}_t$ 可测，就称 X 适应于该滤过。自然滤过为

$$\mathcal{F}_t^X = \sigma(X_s : s \leq t).$$

适应性只表示当前值已经可知，并不包含独立性或预测关系。鞅与停时都必须相对于指定的滤过定义；扩大信息后，原来的鞅性质可能失效。

结构	准确含义	不能由此推出
独立增量	互不重叠时间区间上的增量相互独立	增量分布只依赖区间长度
平稳增量	$X_{t+h} - X_t$ 的分布只依赖 h	各时刻 X_t 的分布相同
严格平稳	任意有限维分布在共同时间平移下不变	不同时间独立
Markov 性	给定当前状态后，下一步的条件分布不再依赖更早历史	下一步与当前状态独立

例如泊松过程具有独立、平稳增量，但 $N(t) \sim \text{Pois}(\lambda t)$ 随 t 变化，因此过程本身不平稳。对可数状态链，Markov 性可以理解为“未来与过去在给定现在后条件独立”；这里的“给定现在”是不可删除的条件。

1.4 收敛方式与极限交换

对于定义在同一概率空间上的实随机变量，常用收敛为

$$\begin{aligned} X_n &\rightarrow X \text{ a.s.} : \quad \mathbb{P}\{\omega : X_n(\omega) \rightarrow X(\omega)\} = 1, \\ X_n &\xrightarrow{\mathbb{P}} X : \quad \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0 \quad (\varepsilon > 0), \\ X_n &\xrightarrow{L^p} X : \quad \mathbb{E}|X_n - X|^p \rightarrow 0 \quad (p \geq 1). \end{aligned}$$

依分布收敛 $X_n \Rightarrow X$ 表示分布函数在极限分布的连续点处收敛，不要求这些变量定义在同一概率空间。基本蕴含为：几乎处处收敛蕴含依概率收敛， L^p 收敛也蕴含依概率收敛，而依概率收敛蕴含依分布收敛；这些逆命题一般不成立。

L^1 收敛允许交换期望与极限，因为

$$|\mathbb{E}X_n - \mathbb{E}X| \leq \mathbb{E}|X_n - X| \rightarrow 0.$$

仅有几乎处处收敛不够。取 $U \sim \text{Unif}(0, 1)$ ， $X_n = n\mathbf{1}_{\{U \leq 1/n\}}$ ，则 $X_n \rightarrow 0$ a.s.，但 $\mathbb{E}X_n = 1$ 。后面的非负鞅会出现同一种现象：越来越少的路径承担了不可忽略的期望。

非负求和可用 Tonelli 或单调收敛交换；有可积控制函数时可用控制收敛；一般有符号求和、积分需要绝对可积等依据。集中版本见 附录 A。

材料依据。本章是各组课程从中段开始所需的必要桥接，限定在高斯、Markov 链与鞅正文实际使用的对象和规则，不另开测度论专题。

2 联合高斯与高斯过程

高斯模型的优势在于：有限维联合分布由均值和协方差确定，线性运算后仍留在同一个分布族内。使用这一优势前，首先要确认的是**联合高斯**，而不只是每个分量分别正态。

2.1 从一维正态到联合高斯

随机向量 $X \in \mathbb{R}^d$ 称为联合高斯，如果对每个确定向量 $a \in \mathbb{R}^d$ ， $a^\top X$ 都服从一维正态分布；允许方差为零，此时该变量几乎处处等于一个常数。

记均值 $\mu = \mathbb{E}X$ 、协方差 $\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^\top]$ ，写作

$$X \sim \mathcal{N}_d(\mu, \Sigma), \quad \Sigma \succeq 0.$$

半正定性来自 $a^\top \Sigma a = \text{Var}(a^\top X) \geq 0$ 。若 $\Sigma \succ 0$ ，才有相对于 d 维 Lebesgue 测度的密度

$$p_X(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right].$$

若 Σ 奇异， X 集中在较低维仿射子空间上，联合高斯定义仍成立，上面的普通密度公式却不能直接使用。

边缘正态不够。令 $Z \sim \mathcal{N}(0, 1)$ ， ε 与 Z 独立且以相同概率取 ± 1 。 $X = Z, Y = \varepsilon Z$ 都是标准正态，而且 $\text{Cov}(X, Y) = 0$ 。但 $|X| = |Y|$ a.s.，二者不独立； $X + Y$ 有概率 $1/2$ 等于零，又并非恒为零，因此不是正态。这个反例同时说明了“任意线性组合”不能换成“每个分量”。

2.2 特征函数为何封闭了线性计算

对任意随机向量，特征函数定义为 $\varphi_X(u) = \mathbb{E}e^{iu^\top X}$ ；它对离散、连续和混合分布都适用。

先计算 $Z \sim \mathcal{N}(0, 1)$ 。由 $\mathbb{E}|Z| < \infty$ 可以在期望内求导，再对实变量积分分部，得到

$$\varphi'_Z(u) = i\mathbb{E}[Ze^{iuZ}] = -u\varphi_Z(u), \quad \varphi_Z(0) = 1.$$

边界项因高斯密度的衰减而为零。解得 $\varphi_Z(u) = e^{-u^2/2}$ 。这一推导避免把复数平移后的积分未经说明地当成概率密度积分。

对联合高斯 X ，因为 $u^\top X \sim \mathcal{N}(u^\top \mu, u^\top \Sigma u)$ ，

$$\varphi_X(u) = \exp(iu^\top \mu - \frac{1}{2}u^\top \Sigma u).$$

特征函数唯一确定分布，所以 μ, Σ 唯一确定联合高斯分布。反过来，对任意 $\Sigma \succeq 0$ ，取谱分解构造 A 使 $AA^\top = \Sigma$ ，令 Z 的分量独立标准正态，则 $\mu + AZ$ 的特征函数恰为上式。这也给出了退化情形的构造。

若 B 为确定矩阵、 b 为确定向量，则

$$BX + b \sim \mathcal{N}(B\mu + b, B\Sigma B^\top).$$

理由是 $a^\top (BX + b) = (B^\top a)^\top X + a^\top b$ 仍为一维正态。这里允许 B 不可逆或降维；不必每次重新作密度变量替换。

对**相互独立**的高斯向量求和，特征函数相乘，从而均值、协方差分别相加。若它们相关，则必须先确认合起来联合高斯，并保留交叉协方差。

2.3 不相关何时足以推出独立

设 $(X^\top, Y^\top)^\top$ 联合高斯，交叉协方差为 Σ_{XY} 。若 $\Sigma_{XY} = 0$ ，联合特征函数分解为

$$\varphi_{X,Y}(u, v) = \exp(iu^\top \mu_X - \frac{1}{2}u^\top \Sigma_{XX}u) \exp(iv^\top \mu_Y - \frac{1}{2}v^\top \Sigma_{YY}v) = \varphi_X(u)\varphi_Y(v).$$

由特征函数的唯一性， X, Y 独立。反向在二阶矩存在时对一般分布也成立。因此

$$\text{联合高斯时: } X \perp Y \iff \Sigma_{XY} = 0.$$

样章中把“线性估计残差与观测不相关”升级为“残差与观测独立”，正是在这里使用了联合高斯性。

一个课程中的典型应用是正态样本的均值与样本方差独立。若 $X_1, \dots, X_n$ 独立同分布于 $\mathcal{N}(\mu, \sigma^2)$ ， $n \geq 2$ ，取第一行为 $n^{-1/2}(1, \dots, 1)$ 的正交矩阵 Q 。令

$$Z = Q(X - \mu \mathbf{1}).$$

则 $Z \sim \mathcal{N}_n(0, \sigma^2 I)$ ，各分量独立，且

$$Z_1 = \sqrt{n}(\bar{X} - \mu), \quad \sum_{k=2}^n Z_k^2 = \sum_{k=1}^n (X_k - \bar{X})^2.$$

均值只依赖第一坐标，样本方差只依赖其余坐标，因而独立。证明的结构是“正交分解—协方差对角化—联合高斯下的独立”，不是“两个统计量看起来使用了不同信息”。

2.4 高斯过程由哪些量确定

过程 $(X_t)_{t \in T}$ 称为高斯过程，如果每个有限维向量 $(X_{t_1}, \dots, X_{t_m})$ 都联合高斯。 T 可以离散，也可以连续。它的有限维分布由

$$m(t) = \mathbb{E}X_t, \quad K(s, t) = \text{Cov}(X_s, X_t)$$

确定。合法协方差核必须对称，并对任意有限个时刻和实数 $a_1, \dots, a_m$ 满足

$$\sum_{i,j=1}^m a_i a_j K(t_i, t_j) = \text{Var} \left(\sum_{i=1}^m a_i X_{t_i} \right) \geq 0.$$

因此随意给出一个对称函数并不足够；必须核对所有有限 Gram 矩阵半正定。正文只在已有过程或显式构造下使用这项条件，不展开一般过程存在性定理。

对具有有限二阶矩的实过程，**宽平稳**要求 $m(t)$ 为常数，且 $K(s, t)$ 只依赖时间差 $t - s$ 。严格平稳要求所有有限维分布共同平移不变。严格平稳加有限二阶矩蕴含宽平稳；对高斯过程，宽平稳也蕴含严格平稳，因为平移前后均值向量、协方差矩阵相同，因而有限维联合分布相同。

例如令 Z, W 独立标准正态，

$$X_t = Z \cos t + W \sin t, \quad t \in \mathbb{R}.$$

每个有限维向量都是 (Z, W) 的线性变换，所以这是高斯过程； $m(t) = 0$ ， $K(s, t) = \cos(t - s)$ ，故严格平稳。路径很光滑，但跨时间通常高度相关；平稳性没有给出独立性。

给定若干观测时刻，把目标值和观测值拼成一个联合高斯向量，即可使用 章节 3 的分块公式。高斯过程的条件预测在这里首先是有限维线性代数问题，并不需要提前引入随机微积分。

2.5 高阶矩：把乘积拆成协方差配对

非线性变换后，均值与协方差的计算往往需要原变量的高阶矩。例如平方过程的协方差包含 $\mathbb{E}[X_s^2 X_t^2]$ ，不能在相关的两个时刻之间直接拆成期望的乘积。

设 $X = (X_1, \dots, X_d)^\top \sim \mathcal{N}_d(0, \Sigma)$ ，允许 Σ 奇异。由于 $X \stackrel{d}{=} -X$ ，任意奇数总次数的单项式期望都为零。对四个分量，允许下标重复，有

$$\mathbb{E}[X_a X_b X_c X_d] = \Sigma_{ab} \Sigma_{cd} + \Sigma_{ac} \Sigma_{bd} + \Sigma_{ad} \Sigma_{bc}.$$

三个加项分别对应四个位置的三种两两配对。这里要求零均值；非零均值时先写 $X = \mu + Z$ 再展开，不能把原始四阶矩直接替换成协方差配对。

沿课程的特征函数路线证明。高斯变量所有绝对矩有限，求导带下来的多项式因子可积，因此可以在期望内反复求导：

$$\varphi(u) = \mathbb{E}e^{iu^\top X} = e^{-u^\top \Sigma u/2}, \quad \partial_a \varphi(u) = -\sum_j \Sigma_{aj} u_j \varphi(u).$$

再对 b, c, d 求导并令 $u = 0$ 。若没有导数作用到 u_j ，该项在零处消失；有一个导数作用到它时，留下其余两个导数。因此

$$\begin{aligned} \partial_{abcd} \varphi(0) &= -\Sigma_{ab} \partial_{cd} \varphi(0) - \Sigma_{ac} \partial_{bd} \varphi(0) - \Sigma_{ad} \partial_{bc} \varphi(0) \\ &= \Sigma_{ab} \Sigma_{cd} + \Sigma_{ac} \Sigma_{bd} + \Sigma_{ad} \Sigma_{bc}. \end{aligned}$$

又 $\partial_{abcd} \varphi(0) = i^4 \mathbb{E}[X_a X_b X_c X_d]$ ，即得公式。证明没有求逆，因此也覆盖退化联合高斯。

同样的求导递推给出一般偶数阶公式：对 $2m$ 个位置，遍历所有两两配对，把每一对的协方差相乘，再对配对求和。配对数为 $(2m-1)!!$ ；它计数的是位置，即使变量下标相同也不能少算重数。特别地， $Z \sim \mathcal{N}(0, \sigma^2)$ 时

$$\mathbb{E}Z^{2m} = (2m-1)!! \sigma^{2m}.$$

查阅时最常用的两个特例是

$$\mathbb{E}X^4 = 3\sigma_X^4, \quad \mathbb{E}[X^2 Y^2] = \sigma_X^2 \sigma_Y^2 + 2 \text{Cov}(X, Y)^2,$$

其中 (X, Y) 联合高斯且均值为零。于是对零均值高斯过程，令 $Y_t = X_t^2$ ，

$$\mathbb{E}Y_t = K(t, t), \quad \text{Cov}(Y_s, Y_t) = 2K(s, t)^2.$$

平方后的过程一般不再高斯，但它的前两阶矩仍能由原协方差核算出。这里展示的是矩计算的封闭性，不是非线性变换后分布族的封闭性。

2.6 低维 Price 定理：对相关参数求导

如果非线性函数不是低次多项式，逐项展开高阶矩未必方便。Price 定理提供另一条路线：先研究期望怎样随相关系数变化，再从容易计算的独立情形积分回来。

设

$$(X, Y) \sim \mathcal{N}_2\left(0, \begin{pmatrix} \sigma_X^2 & \rho \sigma_X \sigma_Y \\ \rho \sigma_X \sigma_Y & \sigma_Y^2 \end{pmatrix}\right), \quad \sigma_X, \sigma_Y > 0, \quad |\rho| < 1.$$

固定两边的方差，只让 ρ 变化。取 $g \in C^2(\mathbb{R}^2)$ ，并假设 g 及各阶数不超过二的偏导数至多按多项式增长。这是一组方便检验的充分条件，而非最弱条件。令 $H(\rho) = \mathbb{E}_\rho g(X, Y)$ ，则

$$H'(\rho) = \sigma_X \sigma_Y \mathbb{E}_\rho \left[\frac{\partial^2 g}{\partial x \partial y}(X, Y) \right].$$

若 $g(x, y) = f(x)h(y)$ ，右侧变成 $\sigma_X \sigma_Y \mathbb{E}_\rho[f'(X)h'(Y)]$ ，往往比原期望容易算。

2.6.1 特征函数为什么让求导变简单

记联合密度为 p_ρ ，其特征函数为

$$\varphi_\rho(u, v) = \exp\left[-\frac{1}{2}(\sigma_X^2 u^2 + 2\rho\sigma_X\sigma_Y uv + \sigma_Y^2 v^2)\right].$$

它对 ρ 求导只产生因子 $-\sigma_X\sigma_Y uv$ 。反过来，对密度的 Fourier 逆变换先求 x 导数、再求 y 导数，产生的因子是 $(-iu)(-iv) = -uv$ 。所以

$$\frac{\partial p_\rho}{\partial \rho} = \sigma_X\sigma_Y \frac{\partial^2 p_\rho}{\partial x \partial y}.$$

在任意紧区间 $|\rho| \leq r < 1$ 上，协方差一致正定，相关的特征函数及导数可由可积的高斯衰减控制，因而上述求导与 Fourier 积分可以交换。得到密度恒等式后，再对 g 积分：

$$\begin{aligned} H'(\rho) &= \sigma_X\sigma_Y \iint g(x, y) \partial_{xy} p_\rho(x, y) dx dy \\ &= \sigma_X\sigma_Y \iint \partial_{xy} g(x, y) p_\rho(x, y) dx dy. \end{aligned}$$

第二步对两个坐标各分部积分一次，两个负号抵消。多项式增长加高斯衰减保证边界项为零，也保证求导与期望的交换。这是课程中“增长不要太快”的一个明确版本。

2.6.2 先求导，再补初值

取 $g(x, y) = x^2 y^2$ ，则 $g_{xy} = 4xy$ ，所以

$$H'(\rho) = 4\sigma_X\sigma_Y \mathbb{E}_\rho[XY] = 4\rho\sigma_X^2\sigma_Y^2.$$

在 $\rho = 0$ 时，联合高斯且不相关推出独立， $H(0) = \sigma_X^2\sigma_Y^2$ 。积分得到

$$H(\rho) = \sigma_X^2\sigma_Y^2(1 + 2\rho^2),$$

与四阶矩配对公式相互核对。独立情形给出的初值不可漏掉；仅求导并不能确定原期望。

若改用协方差 $c = \rho\sigma_X\sigma_Y$ 作参数，公式变为 $d\mathbb{E}_c g/dc = \mathbb{E}_c g_{xy}$ ，没有额外的 $1/2$ 。作为对照，一维方差参数 $v > 0$ 满足

$$\frac{d}{dv} \mathbb{E}f(\sqrt{v}Z) = \frac{1}{2} \mathbb{E}f''(\sqrt{v}Z), \quad Z \sim \mathcal{N}(0, 1),$$

在相同的光滑、多项式增长条件下成立；密度对应的是 $\partial_v p_v = \frac{1}{2} \partial_{xx} p_v$ 。不要混淆“对方差求导”和“同时改变两个对称交叉协方差元素”。

本节只证明光滑低维版本。 $|\rho| = 1$ 的退化端点需要另取极限；ReLU 等非光滑函数需要平滑逼近或弱导数论证，不能直接宣称满足本节的 C^2 条件。更一般版本的条件核验见 [Voigtlaender 的 Price 定理论文](#)，本书不展开其分布导数框架。

材料依据。张颢 P6–P8 的联合高斯、特征函数与线性变换；P9 约 00:09–00:35 的高阶矩、约 01:45–02:15 的低维 Price 定理。保留特征函数证明路线，补明可积性、参数固定方式和分部积分条件；非光滑推广与扩散方程不展开。

3 条件高斯与估计

我们常常只能看到系统的一部分：观测到了 $Y = y$ ，却想知道没有直接观测到的 X 。问题不只是“猜一个 X ”，还包括：猜测之后，剩下多少不确定性？

联合高斯模型把这两件事放在一起回答：**条件均值给出均方误差最小的估计，条件协方差描述估计后剩余的不确定性**。本章沿着“分块消元与配方 $\rightarrow$ 估计解释 $\rightarrow$ 线性观测”的顺序展开。

前置知识只需多元高斯、协方差和分块矩阵乘法。条件期望的最优性会在使用处证明。

3.1 先分清：未知量、观测量与条件

全章随机向量均为列向量。设 $X \in \mathbb{R}^p$ 、 $Y \in \mathbb{R}^q$ ，并且它们**联合高斯**：

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \underbrace{\begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}}_{\Sigma} \right).$$

这里

$$\Sigma_{XY} = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)^\top] \in \mathbb{R}^{p \times q}, \quad \Sigma_{YX} = \Sigma_{XY}^\top.$$

“ X 和 Y 各自高斯”还不够；需要拼起来的向量联合高斯。后面从不相关推出独立，正是用到了这个条件。

还要区分两个对象： $\mathbb{E}[X | Y = y]$ 是观测值 y 对应的向量； $\mathbb{E}[X | Y]$ 则是 Y 的函数，在观测发生之前仍是随机向量。我们先求前者，再把 y 换回 Y 得到后者。

连续型的 Y 通常满足 $\mathbb{P}(Y = y) = 0$ ，因此不能用事件概率之比解释这里的条件。非退化情形下，用条件密度

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

来计算即可。这里固定 y ，积分与配方的变量都是 x 。

3.2 条件分布：均值修正，协方差扣减

假设 $\Sigma_{YY} \succ 0$ ，定义

$$B = \Sigma_{XY} \Sigma_{YY}^{-1}, \quad S = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}.$$

则条件分布为

$$X | Y = y \sim \mathcal{N}(\mu_X + B(y - \mu_Y), S).$$

三个位置分别有明确作用：

- $y - \mu_Y$ ：观测相对于原先预期的偏差；
- B ：把观测偏差换算成对 X 的修正；
- S ：利用观测后，尚未解释的协方差。

条件协方差不依赖具体的 y ，这是联合高斯模型的特殊结构。不同观测值移动条件分布的中心，但不改变它的形状。

下面先在 $\Sigma \succ 0$ 时用密度证明；此时 $S \succ 0$ 。仅要求 $\Sigma_{YY} \succ 0$ 时， S 可以奇异，公式仍可用退化高斯分布来理解，后面的残差解释会说明原因。

3.3 关键推导：保留观测块，消掉交叉块

3.3.1 分块消元为什么恰好给出配方

记中心化后的取值为 $u = x - \mu_X$ 、 $v = y - \mu_Y$ 。联合密度的核心是二次型

$$\begin{pmatrix} u \\ v \end{pmatrix}^\top \Sigma^{-1} \begin{pmatrix} u \\ v \end{pmatrix}.$$

条件密度要除以 Y 的边缘密度。于是我们希望把这个二次型拆成两块：一块只含 v ，与分母抵消；另一块保留 u ，直接读出条件分布。

构造可逆矩阵

$$L = \begin{pmatrix} I_p & -B \\ 0 & I_q \end{pmatrix}.$$

左乘时，利用 $B\Sigma_{YY} = \Sigma_{XY}$ ，有

$$L\Sigma = \begin{pmatrix} \Sigma_{XX} - B\Sigma_{YX} & \Sigma_{XY} - B\Sigma_{YY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} = \begin{pmatrix} S & 0 \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}.$$

再右乘 $L^\top$ ，因为 $\Sigma_{YY}B^\top = \Sigma_{YX}$ ，得到

$$L\Sigma L^\top = \begin{pmatrix} S & 0 \\ 0 & \Sigma_{YY} \end{pmatrix} = D.$$

这一步保留了观测协方差 Σ_{YY} ，消掉了两个交叉块。又因为 $\Sigma \succ 0$ 且 L 可逆， $D \succ 0$ ，所以 $S \succ 0$ ，后续求逆有依据。

由 $L\Sigma L^\top = D$ 可得 $\Sigma^{-1} = L^\top D^{-1}L$ 。因此

$$\begin{aligned} \begin{pmatrix} u \\ v \end{pmatrix}^\top \Sigma^{-1} \begin{pmatrix} u \\ v \end{pmatrix} &= \left(L \begin{pmatrix} u \\ v \end{pmatrix} \right)^\top D^{-1} \left(L \begin{pmatrix} u \\ v \end{pmatrix} \right) \\ &= (u - Bv)^\top S^{-1} (u - Bv) + v^\top \Sigma_{YY}^{-1} v. \end{aligned}$$

这就是多元配方。关键不是背诵分块逆矩阵，而是找到变换 $u \mapsto u - Bv$ ，让交叉项消失。

3.3.2 抵消边缘密度，并补齐归一化因子

联合密度与边缘密度相除后，指数中的 $v^\top \Sigma_{YY}^{-1} v$ 正好抵消。归一化因子也能直接确定：由于 $\det L = 1$ ，

$$\det \Sigma = \det D = \det S \det \Sigma_{YY}.$$

于是

$$f_{X|Y}(x | y) = \frac{\exp[-\frac{1}{2}(u - Bv)^\top S^{-1}(u - Bv)]}{(2\pi)^{p/2}(\det S)^{1/2}}.$$

把 $u - Bv$ 写成 $x - [\mu_X + B(y - \mu_Y)]$ ，便得到上一节的条件均值与协方差。

3.4 残差解释：观测到底解释了什么

把刚才的消元作用到随机向量上，令

$$R = X - \mu_X - B(Y - \mu_Y).$$

直接计算可得

$$\mathbb{E}[R] = 0, \quad \text{Cov}(R, Y) = \Sigma_{XY} - B\Sigma_{YY} = 0, \quad \text{Cov}(R) = S.$$

由于 (R, Y) 是 (X, Y) 的线性变换，它们仍联合高斯；联合高斯加上零交叉协方差，才推出 R 与 Y 独立。于是

$$X = \underbrace{\mu_X + B(Y - \mu_Y)}_{\text{由观测确定的部分}} + \underbrace{R}_{\text{与观测独立的残差}}.$$

给定 $Y = y$ ，前一项成为确定向量，残差的分布不变。这既解释了条件均值的形式，也解释了条件协方差为什么不随 y 改变。

这一论证只需 $\Sigma_{YY} \succ 0$ ，不需要联合密度存在，因此也覆盖 S 奇异的情形：某些方向的残差可能恒为零。

3.4.1 “不确定性减少”是怎样的大小关系

协方差的大小用半正定序比较： $S \preceq \Sigma_{XX}$ 表示对所有 $a \in \mathbb{R}^p$,

$$a^\top S a \leq a^\top \Sigma_{XX} a.$$

也就是任意线性方向 $a^\top X$ 的条件方差都不超过原方差。这里

$$a^\top (\Sigma_{XX} - S) a = (\Sigma_{YX} a)^\top \Sigma_{YY}^{-1} (\Sigma_{YX} a) \geq 0,$$

所以 $0 \preceq S \preceq \Sigma_{XX}$ 。这不表示每个矩阵元素都变小，也不表示每个方向都严格减小：若 $\Sigma_{YX} a = 0$ ，该方向没有方差缩减。

对于一般分布，只能由全协方差公式得到

$$\text{Cov}(X) = \mathbb{E}[\text{Cov}(X | Y)] + \text{Cov}(\mathbb{E}[X | Y]).$$

它保证的是平均条件协方差不过原协方差，不能据此断言每一个观测值下的条件方差都更小。联合高斯中条件协方差恒为 S ，才得到这里逐个观测值成立的结论。

3.5 为什么条件均值就是最优估计

这里的“最优”专指平方损失。给定 $\mathbb{E}\|X\|^2 < \infty$ ，在所有满足 $\mathbb{E}\|g(Y)\|^2 < \infty$ 的可测估计中，求

$$\min_g \mathbb{E}\|X - g(Y)\|^2.$$

令 $m(Y) = \mathbb{E}[X | Y]$ 。把误差分成

$$X - g(Y) = [X - m(Y)] + [m(Y) - g(Y)].$$

交叉项的期望为零，因为第二项是 Y 的函数，而

$$\mathbb{E}[X - m(Y) | Y] = 0.$$

具体地，利用条件期望与塔式法则，

$$\begin{aligned} & \mathbb{E}[(X - m(Y))^\top (m(Y) - g(Y))] \\ &= \mathbb{E}[\mathbb{E}[X - m(Y) | Y]^\top (m(Y) - g(Y))] = 0. \end{aligned}$$

平方可积保证交叉项可积。因此

$$\boxed{\mathbb{E}\|X - g(Y)\|^2 = \mathbb{E}\|X - m(Y)\|^2 + \mathbb{E}\|m(Y) - g(Y)\|^2.}$$

第二项非负，且等号成立当且仅当 $g(Y) = m(Y)$ 几乎处处。这就证明了最优性与几乎处处意义下的唯一性，不需要高斯假设。

高斯假设额外保证了什么？它让本来可以是非线性的 $m(Y)$ 恰好成为仿射函数：

$$m(Y) = \mu_X + \Sigma_{XY} \Sigma_{YY}^{-1} (Y - \mu_Y).$$

仅有二阶矩且 $\Sigma_{YY} \succ 0$ 时，上式仍是最佳仿射估计。原因是其残差与 $Y - \mu_Y$ 不相关，因而与任意仿射估计之差正交；同样展开平方即可证明。但没有联合高斯性，它未必在所有非线性估计中最优。

本章把常说的“最优线性估计”准确写为“最优仿射估计”；中心化后，两者的系数公式相同。联合高斯是二者与条件均值重合的充分条件，不是必要条件。

3.6 应用：从带噪观测推断状态

考虑课程中的线性高斯模型

$$Y = AX + \varepsilon, \quad X \sim \mathcal{N}(\mu, P), \quad \varepsilon \sim \mathcal{N}(0, V), \quad X \perp \varepsilon.$$

这里 $A \in \mathbb{R}^{q \times p}$, $P \succeq 0$, 假设 $V \succ 0$ 。因此 $APA^\top + V \succ 0$, 观测协方差可逆。

先检查联合高斯性，不能只检查两个边缘：独立的高斯向量 (X, ε) 联合高斯，而

$$\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} I_p & 0 \\ A & I_q \end{pmatrix} \begin{pmatrix} X \\ \varepsilon \end{pmatrix},$$

所以 (X, Y) 联合高斯。再计算公式需要的三个量：

$$\begin{aligned} \mathbb{E}[Y] &= A\mu, \\ \text{Cov}(X, Y) &= \mathbb{E}[(X - \mu)(A(X - \mu) + \varepsilon)^\top] = PA^\top, \\ \text{Cov}(Y) &= APA^\top + V. \end{aligned}$$

后两行的交叉项因为独立且噪声零均值而消失，噪声自己的协方差 V 不会消失。

代入条件高斯公式，得到

$$\begin{aligned} K &= PA^\top (APA^\top + V)^{-1}, \\ \mathbb{E}[X | Y = y] &= \mu + K(y - A\mu), \\ \text{Cov}(X | Y = y) &= P - PA^\top (APA^\top + V)^{-1} AP. \end{aligned}$$

$y - A\mu$ 是实际观测与预测观测之差， K 决定用多大幅度修正原估计。本节只做一次观测更新，不延伸到完整的动态滤波算法。

一维例子。若 $Y = X + \varepsilon$, $X \sim \mathcal{N}(\mu, \tau^2)$, 独立噪声 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, 且 $\tau^2, \sigma^2 > 0$, 则

$$\mathbb{E}[X | Y = y] = \frac{\sigma^2}{\tau^2 + \sigma^2} \mu + \frac{\tau^2}{\tau^2 + \sigma^2} y, \quad \text{Var}(X | Y = y) = \frac{\tau^2 \sigma^2}{\tau^2 + \sigma^2}.$$

观测噪声越小，越信任 y ；观测噪声越大，越保留原均值 μ 。例如 $\mu = 0$, $\tau^2 = 4$, $\sigma^2 = 1$, $y = 3$, 条件均值是 2.4，条件方差是 0.8。估计向观测靠近，但仍保留噪声带来的不确定性。

3.7 条件下求函数期望：先求分布，再求矩

沿用讲稿中的例子。设 U, V 独立且都服从 $\mathcal{N}(0, 1)$ ，令

$$X = U + 2V, \quad Y = U - V.$$

它们联合高斯，且

$$\mathbb{E}[X] = \mathbb{E}[Y] = 0, \quad \text{Cov} \begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 5 & -1 \\ -1 & 2 \end{pmatrix}.$$

于是

$$X | Y = y \sim \mathcal{N} \left(-\frac{y}{2}, \frac{9}{2} \right).$$

要求 $\mathbb{E}[X^2 | Y = y]$ ，就在这个条件分布下求二阶矩：

$$\mathbb{E}[X^2 | Y = y] = \text{Var}(X | Y = y) + (\mathbb{E}[X | Y = y])^2 = \frac{9}{2} + \frac{y^2}{4}.$$

特别地， $y = 2$ 时结果为 $11/2$ 。若条件写为随机变量 Y ，则

$$\mathbb{E}[X^2 | Y] = \frac{9}{2} + \frac{Y^2}{4} \quad \text{几乎处处成立}.$$

一般地，在相应积分存在时，

$$\mathbb{E}[h(X) | Y = y] = \int h(x) f_{X|Y}(x | y) dx.$$

无需另造一个含义不清的“条件随机变量”；固定观测值，按条件分布计算即可。也不能把 $\mathbb{E}[h(X) | Y]$ 直接换成 $h(\mathbb{E}[X | Y])$ ，上面的平方例子就差了条件方差。

3.8 查阅时先检查这几件事

- **联合性**：边缘各自高斯不足以套条件高斯公式。
- **求逆对象**：逆的是观测协方差 Σ_{YY} ；公式不是对矩阵做普通除法，乘法次序不能交换。
- **退化情况**： Σ_{YY} 奇异时，本章的普通逆公式不适用；需先处理冗余观测或另行讨论支持集上的退化条件分布。
- **最优性的范围**：本章最优性针对平方损失；条件均值不必是其他损失下的最优解。
- **条件协方差**：联合高斯下它不随观测值变化，且按半正定序不减；不要把这句话推广成一般分布的逐点结论。

4 泊松过程与到达时间

同一串随机到达可以从两个角度描述：到时刻 t 共发生多少次，或相邻两次相隔多久。泊松模型把这两种描述连接起来：计数服从泊松分布，间隔独立且服从指数分布。

4.1 定义中每个条件的作用

设 $\lambda > 0$ 。齐次泊松过程 $(N(t))_{t \geq 0}$ 是从 $N(0) = 0$ 开始、路径右连续的计数过程，具有独立增量，且

$$N(t+h) - N(t) \sim \text{Pois}(\lambda h), \quad t, h \geq 0.$$

这里计数路径非减、取非负整数值，几乎处处只有大小为 1 的跳跃。参数 λ 是单位时间的期望到达次数，量纲为时间的倒数。

独立增量表示对 $0 \leq t_0 < t_1 < \dots < t_m$ ，各 $N(t_k) - N(t_{k-1})$ 相互独立；分布只依赖 h 是平稳增量。独立性还使 $N(t+h) - N(t)$ 与自然滤过 $\mathcal{F}_t^N$ 独立：先对有限多个过去计数成立，再由它们生成的信息集推广。

课程从局部条件出发：对具有独立、平稳增量的右连续计数过程，要求

$$\begin{aligned} \mathbb{P}(N(h) = 1) &= \lambda h + o(h), \\ \mathbb{P}(N(h) \geq 2) &= o(h), \quad h \downarrow 0. \end{aligned}$$

因此 $\mathbb{P}(N(h) = 0) = 1 - \lambda h + o(h)$ 。第二项排除了单位时间内以一阶概率成批到达；仅有独立、平稳增量并不足以推出普通泊松过程。

4.2 用概率生成函数推出计数分布

定义概率生成函数

$$G_t(z) = \mathbb{E}[z^{N(t)}], \quad 0 \leq z \leq 1,$$

其中 $z = 0$ 时按 $0^0 = 1$ 理解。它与矩母函数 $\mathbb{E}e^{\theta N(t)}$ 是不同记号。选择 $0 \leq z \leq 1$ 的好处是 $z^k \leq 1$ ，多次到达项可以直接由其概率控制：

$$G_h(z) = 1 + \lambda(z-1)h + o(h).$$

独立、平稳增量分别用于乘法分解和识别第二个因子：

$$G_{t+h}(z) = G_t(z)G_h(z).$$

将 $[0, t]$ 等分为 m 段，避免额外假设可微性，直接得到

$$G_t(z) = G_{t/m}(z)^m = \left(1 + \frac{\lambda(z-1)t}{m} + o(m^{-1})\right)^m = e^{\lambda t(z-1)}.$$

展开幂级数并由生成函数系数的唯一性，

$$\mathbb{P}(N(t) = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}, \quad n \in \mathbb{N}_0.$$

因此

$$\mathbb{E}N(t) = \text{Var}(N(t)) = \lambda t.$$

若 $s \leq t$, 把 $N(t) = N(s) + [N(t) - N(s)]$ 分开, 独立性给出

$$\text{Cov}(N(s), N(t)) = \lambda s, \quad K(s, t) = \lambda \min(s, t).$$

该协方差不是时间差的函数, 均值也不是常数; 过程具有平稳增量, 却不是平稳过程。

4.3 到达时刻与指数间隔

令

$$S_n = \inf\{t \geq 0 : N(t) \geq n\}, \quad S_0 = 0, \quad T_n = S_n - S_{n-1}.$$

S_n 是第 n 次到达时刻, T_n 是第 n 个间隔。因为 $\{T_1 > t\} = \{N(t) = 0\}$,

$$\mathbb{P}(T_1 > t) = e^{-\lambda t}, \quad t \geq 0,$$

所以 $T_1 \sim \text{Exp}(\lambda)$, 均值为 $1/\lambda$ 。

要把这个结论推广到随机时刻 S_n , 不能只说“独立增量”。独立增量首先是在确定时刻定义的。对右连续泊松过程, 可以把有限停时 S 用从右逼近的离散时刻近似, 从确定时刻的独立性推出

$$(N(S+u) - N(S))_{u \geq 0} \text{ 与 } \mathcal{F}_S^N \text{ 独立, 且与原过程同分布。}$$

这是此处需要的强 Markov 性, 具体逼近论证见 小节 B.1。每个 S_n 几乎处处有限, 因为

$$\mathbb{P}(S_n > t) = \mathbb{P}(N(t) < n) = e^{-\lambda t} \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!} \rightarrow 0.$$

于是逐次在 S_{n-1} 使用上述性质, 得到

$$T_1, T_2, \dots \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda).$$

这里的独立性来自随机到达时刻之后的“重新开始”, 而非把随机下标未经处理地代入确定时刻的公式。

指数分布的无记忆性也有准确表达:

$$\mathbb{P}(T > s+t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}.$$

它描述的是一个间隔在已知尚未结束后的剩余分布, 不表示任意选择出的间隔都服从同一个指数分布。下一章将讨论观察时刻所落入的间隔。

4.4 反过来: 由独立间隔构造计数

从独立同分布的 $T_n \sim \text{Exp}(\lambda)$ 出发, 置 $S_n = \sum_{k=1}^n T_k$, 再定义

$$N(t) = \max\{n : S_n \leq t\}.$$

这一定义需要 $S_n \rightarrow \infty$ a.s., 以排除有限时间内无限多次到达。取任意 $c > 0$, 事件 $\{T_n \geq c\}$ 独立且概率为 $e^{-\lambda c} > 0$, 几乎必然出现无穷多次, 因而总和发散。

对 $0 < s_1 < \dots < s_n < t$, 前 n 个间隔的密度乘上第 $n+1$ 次尚未到达的概率, 得

$$\lambda^n e^{-\lambda s_n} e^{-\lambda(t-s_n)} ds_1 \dots ds_n = \lambda^n e^{-\lambda t} ds_1 \dots ds_n.$$

有序单纯形体积为 $t^n/n!$, 积分即得泊松计数公式。若把 $[0, t]$ 划为长度 $h_1, \dots, h_m$ 的区间, 并规定各区间分别有 $n_1, \dots, n_m$ 个点, 同样积分得到

$$e^{-\lambda \sum_j h_j} \lambda^{\sum_j n_j} \prod_{j=1}^m \frac{h_j^{n_j}}{n_j!} = \prod_{j=1}^m e^{-\lambda h_j} \frac{(\lambda h_j)^{n_j}}{n_j!}.$$

乘积形式同时证明独立增量和增量的泊松分布。于是两种建模方式确实等价。

4.5 第 n 次到达的分布

由 $S_n \leq t \iff N(t) \geq n$,

$$\mathbb{P}(S_n \leq t) = 1 - e^{-\lambda t} \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!}.$$

对 $t > 0$ 求导,

$$f_{S_n}(t) = \frac{\lambda^n t^{n-1} e^{-\lambda t}}{(n-1)!}, \quad \mathbb{E}S_n = \frac{n}{\lambda}, \quad \text{Var}(S_n) = \frac{n}{\lambda^2}.$$

这称为 Erlang 分布, 亦即形状参数 n 、速率参数 λ 的 Gamma 分布。使用软件或教材的 Gamma 记号时, 应区分速率 λ 与尺度 $1/\lambda$ 。

计数问题通常转成 $N(t)$; “第几次发生前要等多久” 通常转成 S_n 。二者的事件等价式往往比直接积分更有用。

4.6 叠加与独立稀疏化

复杂的到达流可以合并, 也可以按事件类别拆分; 但能保留泊松结构的关键是独立性, 而不只是平均速率的加減。

4.6.1 独立流的叠加

设 N_1, N_2 是相互独立的齐次泊松过程, 速率分别为 $\lambda_1, \lambda_2 > 0$ 。定义 $N = N_1 + N_2$ 。对长度为 h 的任意时间区间, 两个增量独立, 概率生成函数相乘:

$$\mathbb{E}_z \Delta N = e^{\lambda_1 h(z-1)} e^{\lambda_2 h(z-1)} = e^{(\lambda_1 + \lambda_2)h(z-1)}.$$

因此增量为 $\text{Pois}((\lambda_1 + \lambda_2)h)$ 。对互不重叠的时间区间, 把两个过程的增量一起分组, 它们仍相互独立, 故 N 是速率 $\lambda_1 + \lambda_2$ 的泊松过程。这里核对了整族增量, 不只是某个时刻的边缘分布。

独立性不能删除: 若 $N_2 = N_1$, 叠加过程 $2N_1$ 每次跳 2, 即使均值也是两倍, 也不是普通泊松过程。独立指数等待时间的一个直接推论是

$$\min(T_1, T_2) \sim \text{Exp}(\lambda_1 + \lambda_2), \quad T_i \sim \text{Exp}(\lambda_i), T_1 \perp T_2.$$

它对应两条独立到达流中最先发生的事件, 亦可由生存概率相乘直接证明。

4.6.2 每个点独立保留

设 N 速率为 λ 。为第 k 个到达点附上标记 $B_k \sim \text{Bernoulli}(p)$, 各标记独立, 且标记序列与整个到达过程独立。令

$$N_1(t) = \sum_{k=1}^{N(t)} B_k, \quad N_0(t) = N(t) - N_1(t).$$

对 $0 \leq u, v \leq 1$, 先条件于 $N(t) = n$, 得到 $(pu + (1-p)v)^n$, 再对泊松总数平均:

$$\begin{aligned} \mathbb{E}[u^{N_1(t)} v^{N_0(t)}] &= \exp\{\lambda t[pu + (1-p)v - 1]\} \\ &= e^{\lambda p t(u-1)} e^{\lambda(1-p)t(v-1)}. \end{aligned}$$

生成函数分解为两个泊松生成函数, 证明两个计数独立。对任意有限时间划分重复这个计算, 独立标记与原独立增量保证各区间分组相互独立, 因而 N_1, N_0 是相互独立的泊松过程, 速率为 $\lambda p, \lambda(1-p)$ 。端点 $p = 0, 1$ 对应其中一个过程恒为零。

给定总数以后，两个子计数的和固定，通常不独立：

$$\text{Cov}(N_1(t), N_0(t) \mid N(t) = n) = -np(1-p).$$

无条件时，总数的随机性恰好改变了这种依赖；上述联合生成函数才是独立性的完整依据。

隔一个保留一个不适用。如果只保留第 2, 4, 6, ... 个点，新闻隔是两个独立指数间隔之和，服从 $\text{Gamma}(2, \text{速率}\lambda)$ ，并非指数分布。因此保留下来的过程不是泊松过程。仅有“保留一半”或“进行了随机选择”都不够，必须核对标记之间及其与到达流的独立关系。

4.7 非齐次泊松：强度随时间变化

现在把常数速率换成确定函数 $\lambda(t) \geq 0$ ，要求它在每个有限区间可积。定义累计强度

$$\Lambda(t) = \int_0^t \lambda(u) du.$$

非齐次泊松过程从零开始，具有独立增量，并满足

$$N(t) - N(s) \sim \text{Pois}(\Lambda(t) - \Lambda(s)), \quad 0 \leq s \leq t.$$

局部可积性保证有限时段计数几乎处处有限。只放松平稳增量，还不能唯一确定这一模型；上面的泊松增量分布同样是定义的一部分。

用一个单位速率泊松过程 $\bar{N}$ 作确定时间变换，

$$N(t) = \bar{N}(\Lambda(t)),$$

便给出构造：不交时间区间映射到不交的累计强度区间，故独立增量保留，参数变为累计强度差。 Λ 可以有平坦段，不必严格递增；该段强度为零，过程没有到达。

相应地，

$$\mathbb{E}N(t) = \text{Var}(N(t)) = \Lambda(t), \quad \text{Cov}(N(s), N(t)) = \Lambda(\min(s, t)).$$

$\lambda(t)$ 是速率， $\Lambda(t)$ 才是到时刻 t 的期望次数；不能把前者直接当作泊松分布参数。

从确定时刻 t 等到下一次到达的时间 R_t 满足

$$\mathbb{P}(R_t > h \mid \mathcal{F}_t^N) = e^{-[\Lambda(t+h) - \Lambda(t)]}, \quad h \geq 0.$$

这个条件生存函数不依赖已观测路径，但一般依赖起始时刻 t ，也通常不是关于 h 的指数函数。因此不能继续使用“所有间隔独立同分布于同一个指数分布”的齐次结论。

特别地，首次到达 S_1 的生存函数为 $e^{-\Lambda(t)}$ ，在几乎所有 t 处的密度为 $\lambda(t)e^{-\Lambda(t)}$ 。若 $\Lambda(\infty) < \infty$ ，还存在

$$\mathbb{P}(S_1 = \infty) = e^{-\Lambda(\infty)} > 0;$$

密度积分不足 1 并非算错，而是存在永不发生第一次到达的概率。下一章会说明给定总数后的均匀位置结论怎样随强度改变。

4.8 复合泊松：次数之外还有每次的贡献

若每次到达带来随机大小的贡献，就需要在计数外再加一层随机性。设 N 为速率 $\lambda > 0$ 的齐次泊松过程， $J_1, J_2, \dots$ 为独立同分布的实值标记，且与整个 N 独立，定义

$$C(t) = \sum_{k=1}^{N(t)} J_k, \quad \text{空和为0.}$$

这称为复合泊松过程。标记可以为正、负或零；因此 C 未必单调，也未必是计数过程。 λ 是底层事件率，若 $\mathbb{P}(J_1 = 0) > 0$ ，它不等于可见非零跳跃的发生率。

4.8.1 先固定次数，再取平均

假设 $\mathbb{E}|J_1| < \infty$ ，记 $m_J = \mathbb{E}J_1$ 。给定 $N(t) = n$ 后，各标记的原分布不变，因此

$$\mathbb{E}[C(t) | N(t)] = N(t)m_J, \quad \mathbb{E}C(t) = \lambda t m_J.$$

绝对可积性的依据也可同时核对： $\mathbb{E} \sum_{k=1}^{N(t)} |J_k| = \lambda t \mathbb{E}|J_1| < \infty$ 。

若再有 $\mathbb{E}J_1^2 < \infty$ ，记方差为 v_J 。全方差公式把两层波动分开：

$$\begin{aligned} \text{Var}(C(t)) &= \mathbb{E}[N(t)v_J] + \text{Var}(N(t)m_J) \\ &= \lambda t(v_J + m_J^2) = \lambda t \mathbb{E}J_1^2. \end{aligned}$$

第一项来自每次贡献大小不同，第二项来自贡献次数不同。只保留 $\lambda t \text{Var}(J_1)$ 会遗漏第二层；例如 $J_1 \equiv c$ 时仍有计数波动 $c^2 \lambda t$ 。

4.8.2 特征函数的复合

不加矩条件也能使用特征函数。记 $\varphi_J(u) = \mathbb{E}e^{iuJ_1}$ ，则

$$\begin{aligned} \mathbb{E}e^{iuC(t)} &= \sum_{n \geq 0} e^{-\lambda t} \frac{(\lambda t)^n}{n!} \varphi_J(u)^n \\ &= \exp\{\lambda t[\varphi_J(u) - 1]\}. \end{aligned}$$

级数绝对收敛，因为 $|\varphi_J(u)| \leq 1$ 。这沿用了课程的“先对单次贡献求变换，再代入泊松计数变换”的路线。若标记是非负整数，也可以写概率生成函数；对一般实标记，不能无条件使用 $\mathbb{E}[z^{J_1}]$ 。

在不交时间区间条件于各自点数，分属各区间的标记独立，且标记与点数独立，故 C 仍有独立、平稳增量。二阶矩存在时，

$$\text{Cov}(C(s), C(t)) = \lambda \min(s, t) \mathbb{E}J_1^2.$$

课程中的一个短例子是独立泊松过程之差 $N_1 - N_2$ 。把速率 $\lambda_1 + \lambda_2$ 的事件分别赋值 $+1, -1$ ，概率为 $\lambda_1/(\lambda_1 + \lambda_2)$ 与 $\lambda_2/(\lambda_1 + \lambda_2)$ ，独立稀疏化便得到同分布的过程。它不是普通泊松过程，却是复合泊松过程，均值与方差分别为 $(\lambda_1 - \lambda_2)t$ 和 $(\lambda_1 + \lambda_2)t$ 。

材料依据。张颢 P11 的泊松基础及 P12 约 00:29–00:55 的非齐次过程、00:55–01:18 的复合模型、01:18–01:30 的稀疏化、01:40–02:00 的叠加与差。随机时刻与间隔等价证明沿用 P0；P1 补齐生成函数适用对象、独立性和矩条件。

5 条件到达时刻与等待问题

知道一段时间内恰好发生了 n 次事件，事件的位置还有怎样的随机性？在某个时刻加入观察，等到的间隔是否仍是普通指数间隔？两个问题都要求先说清楚条件和抽样方式。

除最后一节的非齐次推广外，本章使用速率 $\lambda > 0$ 、从零时刻开始的齐次泊松过程。

5.1 给定总数后的联合密度

固定 $t > 0$ ，条件于 $N(t) = n$ ，其中 $n \geq 1$ 。上一章已得到

$$\mathbb{P}(S_1 \in ds_1, \dots, S_n \in ds_n, N(t) = n) = \lambda^n e^{-\lambda t} ds_1 \cdots ds_n$$

在 $0 < s_1 < \cdots < s_n < t$ 上成立。除以 $\mathbb{P}(N(t) = n) = e^{-\lambda t} (\lambda t)^n / n!$ ，得到

$$f_{S_1, \dots, S_n | N(t)=n}(s_1, \dots, s_n) = \frac{n!}{t^n}, \quad 0 < s_1 < \cdots < s_n < t.$$

参数 λ 消失：已知总数后，区间内位置的条件分布不再依赖到达率。

取 $U_1, \dots, U_n$ 独立同分布于 $\text{Unif}(0, t)$ ，将其排序为 $U_{(1)} < \cdots < U_{(n)}$ 。无并列的每个有序配置对应 $n!$ 种原始排列，因此顺序统计量的密度恰好也是 $n!/t^n$ 。所以

$$(S_1, \dots, S_n) | \{N(t) = n\} \stackrel{d}{=} (U_{(1)}, \dots, U_{(n)}).$$

有序到达时刻不独立。 独立均匀的是排序前的辅助变量。特别地，不能把 $S_1 | N(t) = n$ 当成均匀变量，除非 $n = 1$ 。

5.2 三个直接可用的推论

首先，第 k 次到达在 s 附近，意味着有 $k-1$ 个均匀点在其左、 $n-k$ 个在其右。因此

$$f_{S_k | N(t)=n}(s) = \frac{n!}{(k-1)!(n-k)!} \frac{s^{k-1}(t-s)^{n-k}}{t^n}, \quad 0 < s < t.$$

等价地， $S_k/t | N(t) = n \sim \text{Beta}(k, n+1-k)$ ，从而

$$\mathbb{E}[S_k | N(t) = n] = \frac{k}{n+1}t.$$

各有序位置的均值等间隔，不意味着实际点也等间隔。

其次，固定 $0 \leq s \leq t$ ，排序不改变落入 $[0, s]$ 的点数，所以

$$N(s) | N(t) = n \sim \text{Bin}\left(n, \frac{s}{t}\right).$$

这也可由独立泊松增量直接核对： $N(s)$ 和 $N(t) - N(s)$ 独立，条件于二者之和得到二项分布。

最后, 对可积函数 g , 排序不改变函数值之和, 故

$$\mathbb{E} \left[\sum_{k=1}^{N(t)} g(S_k) \middle| N(t) = n \right] = \frac{n}{t} \int_0^t g(s) ds.$$

对 $g \geq 0$, 先条件化再用 Tonelli; 对 $\int_0^t |g(s)| ds < \infty$, 用绝对可积性, 均可得到

$$\mathbb{E} \sum_{k=1}^{N(t)} g(S_k) = \lambda \int_0^t g(s) ds.$$

这是本章最常用的简化: 先固定随机点数, 把点的位置换成均匀样本, 再对点数取期望。

更一般地, 只有被积函数对各坐标**对称**时, 才可以把有序单纯形积分乘 $n!$ 换成整个立方体积分。涉及“第一个”“最后一个”的表达通常不对称, 不能直接消掉排序。

5.3 固定观察时刻的前向等待与年龄

固定确定时刻 $t \geq 0$, 令

$$A_t = t - S_{N(t)}, \quad R_t = S_{N(t)+1} - t.$$

A_t 是距最近到达的时间, 若尚未到达则从 $S_0 = 0$ 起算; R_t 是到下一次到达的剩余时间。

对 $r \geq 0$,

$$\{R_t > r\} = \{N(t+r) - N(t) = 0\}.$$

由确定时刻之后的独立、平稳增量,

$$R_t \sim \text{Exp}(\lambda), \quad R_t \perp \mathcal{F}_t^N.$$

因此 R_t 与 A_t 独立。

对 $0 \leq a < t$, $A_t > a$ 等价于最近长度为 a 的区间内没有到达, 故

$$\mathbb{P}(A_t > a) = e^{-\lambda a}, \quad 0 \leq a < t.$$

又有 $0 \leq A_t \leq t$, 且 $\mathbb{P}(A_t = t) = \mathbb{P}(N(t) = 0) = e^{-\lambda t}$. 所以 A_t 的分布等于 $\min(E, t)$, 其中 $E \sim \text{Exp}(\lambda)$; 这里的 E 是分布表示, 不是另一个已给定的实际间隔。

利用非负变量的尾积分公式,

$$\mathbb{E}A_t = \int_0^t e^{-\lambda a} da = \frac{1 - e^{-\lambda t}}{\lambda}, \quad \mathbb{E}R_t = \frac{1}{\lambda}.$$

包含观察时刻的完整间隔长度为

$$L_t = S_{N(t)+1} - S_{N(t)} = A_t + R_t,$$

于是

$$\mathbb{E}L_t = \frac{2 - e^{-\lambda t}}{\lambda} \rightarrow \frac{2}{\lambda}.$$

对于从零开始的过程, 有限 t 时不能直接把年龄当作完整指数变量, 也不能把均值写成恰好 $2/\lambda$; 边界 $S_0 = 0$ 的影响由 $e^{-\lambda t}$ 项体现。

5.4 为什么不违背指数间隔的结论

固定下标的 T_n 满足 $\mathbb{E}T_n = 1/\lambda$ ；但 $L_t = T_{N(t)+1}$ 的下标由整个到达配置选出，并不是独立抽签选出的下标。较长间隔更容易覆盖观察时刻，这改变了被选间隔的分布。

尤其不能写

$$\mathbb{E}[T_{n+1} \mid N(t) = n] = \mathbb{E}T_{n+1}.$$

条件 $N(t) = n$ 包含 $S_n \leq t < S_{n+1}$ ，已经对 T_{n+1} 施加了约束。P12 末尾的问题需要连同 P13 的解答理解，不能保留中途用于提出矛盾的式子作为结论。

同时，无记忆性只保证已知过去后的**前向剩余**仍为指数分布。它没有说已经过去的长度为零，因此“剩余均值为 $1/\lambda$ ”与“被观察间隔更长”并不矛盾。

5.5 一个等待成本计算

设在时刻 $h > 0$ 统一处理 $[0, h]$ 内到达的所有请求，单个请求的等待时间为 $h - S_k$ ，总等待量

$$W_h = \sum_{k=1}^{N(h)} (h - S_k).$$

条件于 $N(h) = n$ 后用均匀位置，或直接使用本章求和公式，得

$$\mathbb{E}W_h = \lambda \int_0^h (h - s) ds = \frac{\lambda h^2}{2}.$$

若在总时长 T 内安排固定的 m 次清空，间隔 $h_1, \dots, h_m \geq 0$ ， $\sum_j h_j = T$ ，且每次都处理完此前到达，则期望总等待量为

$$\frac{\lambda}{2} \sum_{j=1}^m h_j^2 \geq \frac{\lambda T^2}{2m},$$

其中 Cauchy–Schwarz 不等式的等号在 $h_j = T/m$ 时成立。这里固定了次数、到达率与处理规则；若引入容量、处理耗时或调整次数的成本，优化问题就变了。

5.6 非齐次情形：位置按强度加权

本节改用 小节 4.7 的非齐次模型。固定 $t > 0$ ，要求 $0 < \Lambda(t) < \infty$ ，条件于 $N(t) = n \geq 1$ 。与齐次情形一样，前 n 个到达位置的密度乘上其后直到 t 没有到达的概率，得到有序区域上的联合密度

$$f_{S_1, \dots, S_n \mid N(t)=n}(s_1, \dots, s_n) = \frac{n!}{\Lambda(t)^n} \prod_{k=1}^n \lambda(s_k), \quad 0 < s_1 < \dots < s_n < t.$$

也可用累计强度时间变换推导。它等于 n 个独立变量按大小排序后的密度，其中每个变量在 $[0, t]$ 上的密度为

$$f_t(s) = \frac{\lambda(s)}{\Lambda(t)}.$$

只有 λ 在该区间几乎处处为常数时，才恢复均匀分布。高强度时段在给定总数后仍更容易出现点。

因此对于 $0 \leq s \leq t$,

$$N(s) \mid N(t) = n \sim \text{Bin}\left(n, \frac{\Lambda(s)}{\Lambda(t)}\right).$$

对非负可测 g , 或满足 $\int_0^t |g(s)|\lambda(s)ds < \infty$ 的 g , 先固定总数再取平均, 得到

$$\mathbb{E} \sum_{k=1}^{N(t)} g(S_k) = \int_0^t g(s)\lambda(s) ds.$$

相应地, 在时刻 t 统一处理请求的期望总等待量为

$$\int_0^t (t-s)\lambda(s) ds.$$

齐次情况下它退化为 $\lambda t^2/2$; 强度随时间变化后, 各处理间隔的成本不再是同一个常系数二次函数, 因此上一节“固定次数下等间隔最优”的推导不能原样照搬。

材料依据。张颢 P12 末尾与 P13 的等待悖论、P13 的条件位置与对称积分, P14 的等待成本。末节把 P12 非齐次模型与 P13 条件位置连接, 是本轮增强桥接; 不另开一般点过程专题。

6 Markov 链与分布演化

如果当前状态已经包含预测下一步所需的历史信息，就可以用一步转移规则逐步构造整个过程的分布。本章限定为离散时间、有限或可数状态空间 E 的齐次 Markov 链。

6.1 从条件分布定义 Markov 性

令 $\mathcal{F}_n^X = \sigma(X_0, \dots, X_n)$ 。Markov 性要求对每个 $j \in E$,

$$\mathbb{P}(X_{n+1} = j \mid \mathcal{F}_n^X) = \mathbb{P}(X_{n+1} = j \mid X_n) \quad \text{a.s.}$$

若右侧在 $X_n = i$ 时不依赖 n ，称为时间齐次，记

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i), \quad P = (p_{ij})_{i,j \in E}.$$

矩阵满足 $p_{ij} \geq 0, \sum_j p_{ij} = 1$ 。对于在某个初始分布下不会被访问的状态， p_{ij} 仍作为模型给定的转移规则，而不是从一个零概率条件事件中反推。

给定初始分布 $\alpha_i = \mathbb{P}(X_0 = i)$ ，对有限路径有

$$\mathbb{P}(X_0 = i_0, \dots, X_n = i_n) = \alpha_{i_0} p_{i_0 i_1} \cdots p_{i_{n-1} i_n}.$$

这是条件概率链式法则加上 Markov 性：每次条件化时，全部历史都被当前状态替代。初始分布与转移矩阵缺一不可。

例如 $X_{n+1} = X_n + \xi_{n+1}$ ，其中增量独立同分布且与 X_0 独立，则

$$\mathbb{P}(X_{n+1} = j \mid \mathcal{F}_n^X) = \mathbb{P}(\xi_{n+1} = j - X_n).$$

独立增量给出了 Markov 性。一般 Markov 链则未必具有独立增量：下一步的变化可以随当前状态改变。

6.2 多步转移与 Chapman–Kolmogorov 方程

记从 i 出发的概率与期望为 $\mathbb{P}_i, \mathbb{E}_i$ ，并定义

$$p_{ij}^{(n)} = \mathbb{P}_i(X_n = j), \quad P^{(0)} = I.$$

在中间时刻 m 对状态 k 分解，

$$\begin{aligned} p_{ij}^{(m+n)} &= \sum_{k \in E} \mathbb{P}_i(X_m = k) \mathbb{P}_i(X_{m+n} = j \mid X_m = k) \\ &= \sum_{k \in E} p_{ik}^{(m)} p_{kj}^{(n)}. \end{aligned}$$

第二步同时用了 Markov 性和齐次性；零概率分支贡献为零。可数求和各项非负，不存在条件收敛问题。因此

$$P^{(m+n)} = P^{(m)} P^{(n)}, \quad P^{(n)} = P^n.$$

这就是 Chapman–Kolmogorov 方程。若转移规则随时间改变，需要保留起止时刻并按顺序乘不同矩阵，不能写成单个 P 的幂。

采用行向量分布约定，

$$\alpha_n = \alpha_0 P^n.$$

不要把分布行向量与随机状态向量混淆。对于函数 $f: E \rightarrow \mathbb{R}$ ，则把函数值排列为列向量，定义转移算子

$$(Pf)(i) = \sum_j p_{ij} f(j) = \mathbb{E}_i f(X_1).$$

对有界 f ，或有关项绝对可积时，

$$\mathbb{E}[f(X_{n+m}) \mid \mathcal{F}_n^X] = (P^m f)(X_n).$$

同一个矩阵向前推进状态分布、把未来函数拉回当前状态，左右乘法分别对应这两个用途。

6.3 一个二状态模型

令 $E = \{0, 1\}$,

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \quad 0 \leq a, b \leq 1.$$

设 $q_n = \mathbb{P}(X_n = 1)$ ，则

$$q_{n+1} = a(1 - q_n) + (1 - b)q_n = a + (1 - a - b)q_n.$$

若 $a + b > 0$ ，固定点为 $q_* = a/(a + b)$ ，故

$$q_n - q_* = (1 - a - b)^n (q_0 - q_*).$$

当 $0 < a + b < 2$ 时，分布趋向固定点；当 $a = b = 1$ 时，状态确定交替，分布一般振荡。即使后者存在不变分布 $(1/2, 1/2)$ ，从单个状态出发也不收敛到它。这个例子预告了“平稳”和“极限”的区别。

6.4 首次进入与一步分析

对集合 $A \subseteq E$ ，定义首次进入时间

$$T_A = \inf\{n \geq 0 : X_n \in A\}, \quad \inf \emptyset = \infty.$$

进入概率 $h_i = \mathbb{P}_i(T_A < \infty)$ 满足

$$h_i = 1 \ (i \in A), \quad h_i = \sum_j p_{ij} h_j \ (i \notin A).$$

后一个等式来自按第一步分解。对 $u_i = \mathbb{E}_i T_A$ ，允许值为无穷大，同理得到

$$u_i = 0 \ (i \in A), \quad u_i = 1 + \sum_j p_{ij} u_j \ (i \notin A).$$

方程给出了计算入口，但无限状态时仅解方程未必唯一。真实的 h 是第一组边界方程的最小非负解，真实的 u 是第二组的最小非负解。证明方法是先考虑有限步内进入的概率或截断的累计等待，再迭代一步关系，最后单调取极限；任意非负解都在每轮迭代中控制这些有限时量。边界条件、非负性与最小性不能省略。

6.5 随机时刻的 Markov 性

对自然滤过, 若 T 满足 $\{T \leq n\} \in \mathcal{F}_n^X$, 就称为停时。首次进入时间是停时, 因为是否已经进入只需检查到当前为止的状态。停时的信息记为

$$\mathcal{F}_T^X = \{A \in \mathcal{F} : A \cap \{T = n\} \in \mathcal{F}_n^X \text{ 对所有有限 } n\}.$$

对几乎处处有限的停时 T 和有界 f ,

$$\mathbb{E}[f(X_{T+m}) \mid \mathcal{F}_T^X] = (P^m f)(X_T).$$

离散时间下可以直接证明。任取 $A \in \mathcal{F}_T^X$, 按 $\{T = n\}$ 分解:

$$\begin{aligned} \mathbb{E}[\mathbf{1}_A f(X_{T+m})] &= \sum_{n \geq 0} \mathbb{E}[\mathbf{1}_{A \cap \{T=n\}} f(X_{n+m})] \\ &= \sum_{n \geq 0} \mathbb{E}[\mathbf{1}_{A \cap \{T=n\}} (P^m f)(X_n)] \\ &= \mathbb{E}[\mathbf{1}_A (P^m f)(X_T)]. \end{aligned}$$

中间一步用了确定时刻的 Markov 性, 因为分支事件属于 $\mathcal{F}_n^X$; 有界性使求和绝对可积。对有限多个未来状态的函数重复这一论证, 就得到停时之后的整段转移规则。若 T 可能无穷大, 结论只在 $\{T < \infty\}$ 上使用。

这项强 Markov 性支持后面“每次返回某状态后重新开始”的论证。它不能推广到任意依赖未来的随机时刻, 例如“最后一次访问某状态”的时刻一般不是停时。

材料依据。“随机过程—2024 年版”视频组 (讲者待补, 公开链接见仓库参考资料) P23–P24 的 Markov 性、齐次转移、多步分布与随机游走; 张颢 P14 的引入。一步分析和离散停时分解是状态分类与长期行为所需的桥接。

7 状态分类与空间分解

转移矩阵告诉我们怎样移动，状态分类则回答：能否到达、是否返回、平均多久返回、返回是否受固定节奏限制。这四个问题分别对应可达性、常返性、正常返性和周期性。

7.1 可达、互达与闭类

若存在 $n \geq 0$ 使 $p_{ij}^{(n)} > 0$ ，称 i 可达 j ，记为 $i \rightarrow j$ 。规定允许 $n = 0$ ，因此每个状态可达自身。若 $i \rightarrow j$ 且 $j \rightarrow i$ ，记 $i \leftrightarrow j$ ，称为互达。

由 Chapman–Kolmogorov 方程，两条正概率路径可以拼接，因此可达性传递。互达关系于是具有自反、对称、传递性，把状态空间划分成互达类。

若 C 满足

$$\sum_{j \in C} p_{ij} = 1, \quad i \in C,$$

称 C 为闭集；闭互达类称为闭类。闭性意味着进入后不能离开，互达性意味着类内任意两状态之间存在双向路径，二者是不同条件。整个状态空间只有一个互达类时，链称为不可约。

单状态闭类满足 $p_{ii} = 1$ ，称为吸收态。无限状态的闭不可约链未必常返：闭性排除了离开集合，却未排除在集合内部不断走远。

7.2 首次返回与常返

从 i 出发，定义首次正时刻返回

$$T_i^+ = \inf\{n \geq 1 : X_n = i\}, \quad f_{ii}^{(n)} = \mathbb{P}_i(T_i^+ = n), \quad f_i = \mathbb{P}_i(T_i^+ < \infty) = \sum_{n \geq 1} f_{ii}^{(n)}.$$

若 $f_i = 1$ ，状态 i 常返；若 $f_i < 1$ ，状态 i 暂留。首次返回概率 $f_{ii}^{(n)}$ 与普通转移概率 $p_{ii}^{(n)}$ 不同：后者允许在时刻 n 之前已经返回多次。

令 $V_i = \sum_{n \geq 0} \mathbf{1}_{\{X_n = i\}}$ ，包含初始访问。在每次返回后用强 Markov 性重新开始，可得

$$\mathbb{P}_i(V_i \geq k) = f_i^{k-1}, \quad k \geq 1.$$

若 $f_i < 1$ ，则 V_i 是取值于 $\{1, 2, \dots\}$ 的几何型变量，

$$\mathbb{E}_i V_i = \frac{1}{1 - f_i}.$$

若 $f_i = 1$ ，每一次后续返回都几乎必然发生，对可数次事件取交得 $V_i = \infty$ a.s.。另一方面由 Tonelli,

$$\mathbb{E}_i V_i = \sum_{n \geq 0} p_{ii}^{(n)}.$$

因此得到常返判据

$$i \text{ 常返} \iff \sum_{n \geq 0} p_{ii}^{(n)} = \infty.$$

这个结论依赖链返回后的再生结构；对一般非负随机变量，“期望无穷”本身不意味着变量几乎处处无穷。

7.3 更新方程与生成函数

在时刻 $n \geq 1$ 位于 i , 可以按第一次返回时刻 k 分解。强 Markov 性给出

$$p_{ii}^{(n)} = \sum_{k=1}^n f_{ii}^{(k)} p_{ii}^{(n-k)}, \quad p_{ii}^{(0)} = 1.$$

这是课程中从首次返回连接到重复返回的关键卷积式。令 $0 \leq z < 1$,

$$U_i(z) = \sum_{n \geq 0} p_{ii}^{(n)} z^n, \quad F_i(z) = \sum_{n \geq 1} f_{ii}^{(n)} z^n.$$

非负项可交换求和; 又 $U_i(z) \leq (1-z)^{-1}$ 、 $F_i(z) \leq z < 1$, 所以

$$U_i(z) = 1 + F_i(z)U_i(z), \quad U_i(z) = \frac{1}{1 - F_i(z)}.$$

令 $z \uparrow 1$, 用单调收敛得 $F_i(z) \uparrow f_i$, 再次得到常返判据与暂留时的平均访问次数。不能直接在可能发散的级数里做未经控制的 $z = 1$ 代数消去。

7.4 平均返回时间与类性质

对常返状态定义

$$\mu_i = \mathbb{E}_i T_i^+ = \sum_{n \geq 1} n f_{ii}^{(n)}.$$

若 $\mu_i < \infty$, 称为正常返 (正再生、positive recurrent); 若 $\mu_i = \infty$, 称为零常返 (null recurrent)。这两类都满足返回概率为 1。

若状态暂留, 则 $T_i^+ = \infty$ 有正概率, 扩展期望为无穷。此时仅计算 $\sum_n n f_{ii}^{(n)}$ 会遗漏无穷处的质量, 不能据它把暂留状态判为正常返。

常返性是互达类性质。若 $i \leftrightarrow j$, 取 r, s 使 $p_{ij}^{(r)} > 0, p_{ji}^{(s)} > 0$, 则

$$p_{ii}^{(r+n+s)} \geq p_{ij}^{(r)} p_{jj}^{(n)} p_{ji}^{(s)}.$$

若 j 常返, 右侧对 n 求和发散, 故 i 常返; 反向对称。

常返类必为闭类。否则可从某个类内状态沿正概率路径走到无法返回该类的状态, 取路径上最后一个类内状态, 从它出发就有正概率永不返回, 与常返矛盾。

正常返与零常返也是类性质。其依据是: 常返类中从一个状态到另一个状态的往返可以用返回周期组织; 若一个状态的周期均值有限, 就能构造该类的平稳概率, 再由下一章的返回时间公式得到每个状态的有限平均返回时间。

有限闭互达类一定正常返。固定目标状态 j , 类内每个状态都有一条有限路径到 j ; 有限性允许选出共同的步数上界 m 和成功概率下界 $\delta > 0$ 。于是

$$\mathbb{P}_i(T_j > km) \leq (1 - \delta)^k$$

(从 j 出发的正时刻返回可先走一步再用同一界)。尾和有限, 平均进入与返回时间都有限。无限类不能取这样的统一下界, 这正是有限结论不能直接照搬的地方。

7.5 周期与循环分解

对存在返回路径的状态 i ，定义

$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

$d(i) = 1$ 称为非周期。若返回集合为空，本书不为其定义周期，也不据此判为非周期。

周期是互达类性质。若 $i \rightarrow j$ 有长度 r 的路径、 $j \rightarrow i$ 有长度 s 的路径，则 $r+s$ 与 $r+n+s$ 都是 i 的返回长度，其中 n 是任一 j 的返回长度。因此 $d(i)$ 整除 n ，再反向论证得 $d(i) = d(j)$ 。

周期是返回长度的最大公约数，并不保证恰好 d 步就能返回；例如存在长度 4, 6 的返回路径时公约数为 2，仍可能没有两步返回。

对周期为 d 的不可约链，选参考状态 o ，把从 o 可达的路径长度模 d 等于 r 的状态放入 C_r 。这一归类不依赖所选路径：若到同一状态的两条路径长为 m, n ，再拼接一条返回 o 的路径，所得返回长度之差 $m-n$ 必为 d 的倍数。于是

$$P(x, C_{r+1 \bmod d}) = 1, \quad x \in C_r.$$

每一步按类循环；每隔 d 步观察， P^d 限制在每个 C_r 上都是不可约、非周期链。类内连通来自原链可达路径长度必须为 d 的倍数；新周期为原返回长度除以 d 后的公约数 1。这项分解不能用随意划分矩阵块代替。

例如整数线上每步 ± 1 的随机游走每次翻转奇偶性，且可两步返回，故周期为 2；给每个状态增加正概率自环后，返回集合包含 1，周期变为 1。

7.6 对称随机游走：常返不代表返回快

令 $X_0 = 0$ ，每步独立以概率 $1/2$ 向左右移动。在奇数时刻不能回到零，而

$$p_{00}^{(2n)} = \binom{2n}{n} 2^{-2n} \sim \frac{1}{\sqrt{\pi n}}.$$

由 Stirling 公式得到的级数发散，所以原点常返，进而所有状态常返。

它们却不是正常返。若存在平稳概率 π ，平衡方程要求

$$\pi_j = \frac{1}{2}\pi_{j-1} + \frac{1}{2}\pi_{j+1}, \quad j \in \mathbb{Z}.$$

于是 $\pi_{j+1} - \pi_j$ 为常数， π_j 是 j 的仿射函数。全整数上非负只能使斜率为零；常数序列又不能归一化为概率。由下一章的正常返与平稳概率等价定理，该链零常返。这个例子分开了“必然回来”与“平均返回时间有限”。

材料依据。“随机过程—2024 年版”视频组（讲者待补，公开链接见仓库参考资料）P25–P30 的首次返回、生成函数、互达与周期分解，连同 P31 对前一讲例子的澄清。正文保留能迁移的判据与证明，不复刻依赖缺失板书的矩阵数值例子。

8 平稳分布与长期行为

长期行为至少有三种不同含义：初始分布能否保持不变，某个远期时刻的分布是否收敛，一条路径的平均访问频率是否收敛。它们有关联，但需要的条件不同。

8.1 平稳分布是不变概率

概率行向量 π 若满足

$$\pi P = \pi, \quad \pi_j \geq 0, \quad \sum_j \pi_j = 1,$$

就称为平稳分布或不变分布。于是 $\pi P^n = \pi$ 。若 $X_0 \sim \pi$ ，则所有 $X_n \sim \pi$ ；进一步结合齐次路径概率，任意有限维联合分布共同平移不变，过程严格平稳。

平稳不意味着各时刻独立。确定交替的二状态链

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

具有平稳分布 $(1/2, 1/2)$ ，却满足 $X_{n+1} = 1 - X_n$ 。从 $X_0 = 0$ 出发，状态分布还会在两个点质量之间振荡。

有限链可以解线性方程 $\pi P = \pi$ 加归一化条件。不可约时平稳分布唯一；可约时需先识别闭类，不能从某个线性方程求解器给出的一个解就推断唯一性。

8.2 从返回周期构造平稳分布

设链不可约，某个状态 i 正常返， $\mu_i = \mathbb{E}_i T_i^+ < \infty$ 。定义一次返回周期内访问状态 j 的期望次数

$$\nu_j = \mathbb{E}_i \sum_{n=0}^{T_i^+-1} \mathbf{1}_{\{X_n=j\}}.$$

初始点计入，周期终点不计入，所以 $\nu_i = 1$ ，且由 Tonelli

$$\sum_j \nu_j = \mathbb{E}_i T_i^+ = \mu_i.$$

计算不变性时，事件 $\{n < T_i^+\}$ 在时刻 n 已知，故

$$\begin{aligned} (\nu P)_j &= \sum_{n \geq 0} \mathbb{E}_i [\mathbf{1}_{\{n < T_i^+\}} p_{X_n j}] \\ &= \mathbb{E}_i \sum_{n=0}^{T_i^+-1} \mathbf{1}_{\{X_{n+1}=j\}} \\ &= \mathbb{E}_i \sum_{n=0}^{T_i^+-1} \mathbf{1}_{\{X_n=j\}} = \nu_j. \end{aligned}$$

最后一步把求和指标从 $0, \dots, T_i^+ - 1$ 移到 $1, \dots, T_i^+$; 因为 $X_0 = X_{T_i^+} = i$, 两端增减恰好抵消。所有求和项非负, 可以交换期望与求和。

于是 $\pi_j = \nu_j / \mu_i$ 是平稳概率, 且

$$\pi_i = \frac{1}{\mu_i}.$$

构造揭示了含义: 在状态 j 花费的长期比例, 是一个完整返回周期内在 j 的平均次数, 除以平均周期长度。

8.3 访问频率: 无需非周期条件

先从状态 j 出发。历次返回 j 之间的时长 $Y_1, Y_2, \dots$ 由强 Markov 性独立同分布。若 $\mu_j < \infty$, 强大数定律给出

$$\frac{Y_1 + \dots + Y_k}{k} \rightarrow \mu_j \quad \text{a.s.}$$

设 $R(n)$ 为时刻 n 前完成的返回次数。由

$$Y_1 + \dots + Y_{R(n)} \leq n < Y_1 + \dots + Y_{R(n)+1}$$

夹逼得到 $R(n)/n \rightarrow 1/\mu_j$ 。初始访问只多贡献一次, 不影响极限。若 $\mu_j = \infty$, 对每个 K 将 Y_k 截断为 $Y_k \wedge K$ 后用强大数定律, 再令 $K \rightarrow \infty$, 得平均周期长度趋向无穷, 因而访问频率趋于零。暂留状态总访问次数几乎处处有限, 也有零频率。

在不可约常返链中, 从任意状态出发都几乎必然到达 j : 每次返回出发状态时都有固定正概率沿一条路径到 j , 不断失败的概率趋零。首次到达前的有限段不影响频率。因此对不可约链, 以 $1/\infty = 0$ 约定,

$$\frac{1}{n} \sum_{k=0}^{n-1} \mathbf{1}_{\{X_k=j\}} \rightarrow \begin{cases} 1/\mu_j, & j \text{ 常返}, \\ 0, & j \text{ 暂留} \end{cases} \quad \text{a.s.}$$

暂留情形即便起点不同, 首次进入 j 后也只会有限次返回, 结论仍成立。

这里使用的是独立同分布、绝对一阶矩有限的强大数定律; 下一单元从鞅最大不等式另证其有限方差版本。本章把前者作为已有概率基础工具, 不把有限方差证明误当成无限方差情形的证明。

8.4 正常返与平稳概率的等价性

现在可以核清完整条件: 有限或可数状态的不可约链存在平稳概率, 当且仅当链正常返; 此时平稳概率唯一, 并且 $\pi_j = 1/\mu_j$ 。不要求非周期。

正向构造已给出。反过来, 若存在平稳概率 π , 不可约性使每个 $\pi_j > 0$: 选 $\pi_i > 0$ 的状态, 再用 $\pi_j = (\pi P^m)_j \geq \pi_i p_{ij}^{(m)}$ 。从 π 出发, 访问频率的期望恒为 π_j ; 上一节给出的路径极限与初始状态无关, 且频率介于 $0, 1$, 控制收敛给出

$$\pi_j = \lim_{n \rightarrow \infty} \mathbb{E}_\pi \left[\frac{1}{n} \sum_{k=0}^{n-1} \mathbf{1}_{\{X_k=j\}} \right] = \frac{1}{\mu_j} > 0.$$

暂留或零常返都会使右侧为零, 矛盾。所有状态因此正常返, 公式也表明任意平稳概率必须相同。这同时补全了上一章的正常返类性质。

更一般地, 若 $\sum_j \pi_j |g(j)| < \infty$, 一个返回周期的总绝对奖励期望为 $\mu_i \sum_j \pi_j |g(j)| < \infty$, 周期强大数定律给出遍历平均

$$\frac{1}{n} \sum_{k=0}^{n-1} g(X_k) \rightarrow \sum_j \pi_j g(j) \quad \text{a.s.}$$

关键是把完整周期的奖励与长度分别求平均。最后一个未完成周期的绝对奖励, 被该周期的总绝对奖励控制; 独立同分布可积变量 Z_k 满足 $Z_k/k \rightarrow 0$ a.s., 所以余段除以 n 消失。有限状态时任意实函数 g 自动可积。

8.5 远期分布：周期条件在这里出现

若链不可约、正常返且非周期，则对任意 i, j ,

$$p_{ij}^{(n)} \longrightarrow \pi_j.$$

对任意初始分布 α 也有 $\alpha P^n \rightarrow \pi$ ；在可数离散空间中，这里的概率质量逐点收敛到概率分布还蕴含总变差收敛，即 $\sum_j |(\alpha P^n)_j - \pi_j| \rightarrow 0$ 。

课程的返回时间路线可以这样连接到结论。离散更新定理指出：若返回时长分布 f_k 的总质量为 1，支撑的最大公约数为 1，且均值 $\mu < \infty$ ，则更新序列

$$u_0 = 1, \quad u_n = \sum_{k=1}^n f_k u_{n-k}$$

满足 $u_n \rightarrow 1/\mu$ 。应用于状态 j 的返回方程，得到 $p_{jj}^{(n)} \rightarrow 1/\mu_j = \pi_j$ 。这一步使用了非周期条件；此处把更新定理作为必要桥接结论，其一般证明不纳入短正文。

再令 $H_j = \inf\{n \geq 0 : X_n = j\}$ ，按首次到达分解，

$$p_{ij}^{(n)} = \sum_{k=0}^n \mathbb{P}_i(H_j = k) p_{jj}^{(n-k)}.$$

不可约常返保证 $\sum_k \mathbb{P}_i(H_j = k) = 1$ 。固定有限 K 时逐项取极限， $k > K$ 的尾项由 $\mathbb{P}_i(H_j > K)$ 控制，再令 $K \rightarrow \infty$ ，得到极限 π_j 。这是从“回到自身”到“任意起点”的连接。

有限状态下还可完全绕开一般更新定理，用正矩阵幂给出收缩证明，见小节 B.2。它也直接给出一个几何收敛界。

若周期为 $d > 1$ ，点态极限一般不存在，但访问频率仍收敛。相应的平均转移概率满足

$$\frac{1}{n} \sum_{k=0}^{n-1} p_{ij}^{(k)} \longrightarrow \pi_j,$$

这是对有界访问频率应用控制收敛，故不要求非周期。

不可约的零常返或暂留链在每个固定状态上的 $p_{ij}^{(n)}$ 都趋零；零常返情形可由无限均值的更新定理及周期子序列版本得到，暂留情形由 $\sum_n p_{jj}^{(n)} < \infty$ 和首次进入分解得到。逐点为零不是“极限概率分布为零”：对无限状态，不能把极限交换到无穷状态求和里，概率质量可以移向越来越远的状态。

8.6 有限可约链的边界

有限链的每个闭互达类都有自己的唯一平稳分布；所有平稳分布都是这些分布的凸组合，对类外的暂留状态赋质量零。从任意起点出发，链最终几乎必然进入某个闭类。

若每个可能进入的闭类都非周期，则远期分布是各闭类平稳分布的混合，权重为进入相应闭类的概率，因而可能依赖初始分布。路径上的长期频率却由实际进入的那个闭类决定，通常是随机选择的结果，不能把路径极限一律写成上述确定混合。

问题	不可约链的常用充分条件	结论
存在唯一平稳概率	正常返	$\pi P = \pi, \pi_j = 1/\mu_j$
远期状态分布收敛到 π	正常返且非周期	$p_{ij}^{(n)} \rightarrow \pi_j$
访问频率收敛到 π_j	正常返	时间平均几乎处处收敛
任意可积状态函数的时间平均	正常返, $\pi(g) < \infty$	极限为 $\pi(g)$

材料依据。“随机过程—2024 年版”视频组（讲者待补，公开链接见仓库参考资料）P28–P32、MIT 第 25 讲。修正课程转录中把非周期性列为平稳分布必要条件的表述。可数状态极限定理的条件与返回周期论证另以 Durrett 《Probability: Theory and Examples》第五版第 5 章核验；外部材料只用于必要条件和连接步骤，未引入新专题。

9 鞅与停止

Markov 性约束未来的条件分布，鞅性质只约束未来的条件均值。鞅允许依赖全部历史，但要求在已经掌握的信息下，下一步没有可预测的平均增量。

9.1 定义与基本计算

固定滤过 $(\mathcal{F}_n)_{n \geq 0}$ 。实值过程 (M_n) 是关于该滤过的鞅，如果对每个 n ：

- M_n 对 $\mathcal{F}_n$ 可测，即过程适应；
- $\mathbb{E}|M_n| < \infty$ ；
- $\mathbb{E}[M_{n+1} | \mathcal{F}_n] = M_n$ a.s.。

若最后的等号换成 $\geq$ ，称为下鞅 (submartingale)；换成 $\leq$ ，称为上鞅 (supermartingale)。名称容易混淆，使用时以条件不等式方向为准。

反复用塔式法则， $m \geq n$ 时

$$\mathbb{E}[M_m | \mathcal{F}_n] = M_n, \quad \mathbb{E}M_m = \mathbb{E}M_0.$$

每一步的可积性确保条件期望存在；滤过的包含关系确保可以逐步消去较晚信息。仅有无条件均值恒定不够。例如 $M_0 = Z, M_1 = -Z$ ， Z 为均值零的非退化可积变量，取 $\mathcal{F}_0 = \mathcal{F}_1 = \sigma(Z)$ ，二者均值相同，但条件鞅等式不成立。

若 ξ_k 独立、可积且均值零， $S_n = \sum_{k=1}^n \xi_k$ ，则对自然滤过

$$\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + \mathbb{E}[\xi_{n+1} | \mathcal{F}_n] = S_n.$$

独立性在最后把条件均值化成零。更一般地，只需增量满足 $\mathbb{E}[\xi_{n+1} | \mathcal{F}_n] = 0$ ；这样的序列称为鞅差序列，不求增量独立。

反过来，任意鞅的增量 $D_k = M_k - M_{k-1}$ 都是鞅差。若平方可积，则 $j < k$ 时

$$\mathbb{E}[D_j D_k] = \mathbb{E}[D_j \mathbb{E}(D_k | \mathcal{F}_{k-1})] = 0.$$

因此不同时刻的鞅差正交，但一般不独立。

9.2 可预测下注与乘积鞅

设 H_k 对 $\mathcal{F}_{k-1}$ 可测，表示第 k 次结果揭晓前决定的系数。若每个 H_k 有界，则

$$Y_n = Y_0 + \sum_{k=1}^n H_k (M_k - M_{k-1})$$

在 Y_0 可积且 $\mathcal{F}_0$ -可测时仍是鞅，因为

$$\mathbb{E}[Y_n - Y_{n-1} | \mathcal{F}_{n-1}] = H_n \mathbb{E}[M_n - M_{n-1} | \mathcal{F}_{n-1}] = 0.$$

这里“下注先于结果”表现为可测性，“平均增量为零”来自原鞅；有界性是保证乘积可积的方便充分条件，并非要求所有时间共享同一个界。

另一个课程例子是独立可积变量 Z_k ，满足 $\mathbb{E}Z_k = 1$ 。置 $M_0 = 1, M_n = \prod_{k=1}^n Z_k$ ，则独立性保证有限乘积绝对可积，且

$$\mathbb{E}[M_{n+1} \mid \sigma(Z_1, \dots, Z_n)] = M_n.$$

如果 $Z_k = 2\mathbf{1}_{\{\text{第 } k \text{ 次公平硬币为正面}\}}$ ，则

$$M_n = 2^n \mathbf{1}_{\{\text{前 } n \text{ 次全为正面}\}}.$$

它是均值恒为 1 的非负鞅，几乎每条路径最终却变成零。章节 10 将解释为何这里不能交换极限与期望。

9.3 凸变换与下鞅

若 M 是鞅， φ 为凸函数且 $\varphi(M_n)$ 可积，由条件 Jensen 不等式，

$$\mathbb{E}[\varphi(M_{n+1}) \mid \mathcal{F}_n] \geq \varphi(\mathbb{E}[M_{n+1} \mid \mathcal{F}_n]) = \varphi(M_n).$$

因此 $|M_n|$ 是下鞅；若 M_n 平方可积， M_n^2 也是下鞅。对下鞅作同样变换，还需要 φ 单调不减，才能把条件均值的不等式传入 φ 。平方函数在全实轴上不单调，不能据此断言任意下鞅的平方仍是下鞅。

若 S_n 是独立同分布、均值零、方差 $\sigma^2 < \infty$ 的增量和，则展开平方，

$$\mathbb{E}[S_{n+1}^2 \mid \mathcal{F}_n] = S_n^2 + \sigma^2,$$

所以 $S_n^2 - n\sigma^2$ 是鞅。减去可预测的方差累积，把平方过程重新中心化，是后面计算停止时间的关键构造。

9.4 可预测漂移：把平均趋势单独记账

对于一般可积适应过程 Y_n ，条件平均增量不一定为零，但在增量发生前就能由当前信息计算。令

$$d_k = \mathbb{E}[Y_k - Y_{k-1} \mid \mathcal{F}_{k-1}], \quad A_0 = 0, \quad A_n = \sum_{k=1}^n d_k, \quad M_n = Y_n - A_n.$$

每个 d_k 都可积且对 $\mathcal{F}_{k-1}$ 可测， A_n 在时刻 $n-1$ 已知，称为可预测过程。注意“可预测”是相对于信息的可测性，并不表示它是确定性函数。

从定义直接得到

$$\mathbb{E}[M_n - M_{n-1} \mid \mathcal{F}_{n-1}] = \mathbb{E}[Y_n - Y_{n-1} \mid \mathcal{F}_{n-1}] - d_n = 0.$$

所以

$$Y_n = M_n + A_n, \quad M \text{ 是鞅, } A \text{ 可预测且 } A_0 = 0.$$

这就是离散时间的 Doob 分解。构造只涉及有限次可积变量求和，不需要二阶矩。它把可预测的平均漂移放进 A ，留下条件均值为零的波动。

在 $A_0 = 0$ 的约定下，分解唯一：若另一组 $Y = \tilde{M} + \tilde{A}$ 满足同样条件，令 $D = A - \tilde{A} = \tilde{M} - M$ 。它既是鞅又可预测，故

$$D_n = \mathbb{E}[D_n \mid \mathcal{F}_{n-1}] = D_{n-1}, \quad D_0 = 0.$$

因此 $D_n = 0$ a.s.。若 Y 是下鞅，则 $d_k \geq 0$ ， A_n 非减；上鞅对应非增的 A 。

两个已见构造现在具有同一个解释：独立均值零、方差 σ^2 的增量和满足 $Y_n = S_n^2$ 、 $A_n = n\sigma^2$ ；在整数时刻观察非齐次泊松过程时， $Y_n = N(n)$ 的平均漂移为 $\Lambda(n) - \Lambda(n-1)$ ，因此 $N(n) - \Lambda(n)$ 是关于该离散滤过的鞅。

这是对课程鞅差与条件均值构造的增强桥接。本节只处理离散时间，不把该有限和公式当作连续时间 Doob–Meyer 分解的证明。

9.5 停时与停止过程

取值于 $\mathbb{N}_0 \cup \{\infty\}$ 的随机变量 T 称为关于 $(\mathcal{F}_n)$ 的停时, 若

$$\{T \leq n\} \in \mathcal{F}_n \quad (n \geq 0).$$

例如首次达到阈值 $T = \inf\{n : M_n \geq a\}$ 是停时; 判断当前是否已经触发不需要未来信息。某个区间内“最后一次达到阈值”一般不是停时, 因为当前无法知道以后是否还会达到。

对鞅 M 和任意停时 T , 定义 $M_n^T = M_{n \wedge T}$ 。固定 n 时它适应且可积, 因为

$$|M_{n \wedge T}| \leq \sum_{k=0}^n |M_k|.$$

关键增量公式是

$$M_{(n+1) \wedge T} - M_{n \wedge T} = \mathbf{1}_{\{T > n\}}(M_{n+1} - M_n).$$

由于 $\{T > n\} \in \mathcal{F}_n$, 取条件期望为零, 所以停止过程仍是鞅; 对下鞅、上鞅亦保留相应不等式。固定 n 的停止过程合法, 不等于已经允许令 $n \rightarrow \infty$ 。

9.6 可选停止: 先有限, 再交换极限

若 $T \leq N$ a.s., 由停止过程在确定时刻 N 的期望, 立即得到

$$\mathbb{E}M_T = \mathbb{E}M_0.$$

若仅有 $T < \infty$ a.s., 只能先写

$$\mathbb{E}M_{T \wedge n} = \mathbb{E}M_0.$$

此时 $M_{T \wedge n} \rightarrow M_T$ a.s.; 要得到终端期望等式, 还需要保证 L^1 收敛。以下是两组方便检查的充分条件:

1. 存在可积随机变量 Y , 使所有 n 都有 $|M_{T \wedge n}| \leq Y$ 。控制收敛直接适用。
2. 鞅增量一致有界 $|M_{k+1} - M_k| \leq C$, 且 $\mathbb{E}T < \infty$ 。此时 $|M_{T \wedge n}| \leq |M_0| + CT$, 归入第一种情况。

更一般地, 一致可积的停止变量族也足够, 见下一章。这些是充分条件清单, 不是唯一可能的版本。

加倍下注反例。公平硬币每轮押正面, 第一次押 1, 每输一次翻倍, 首次赢时停止。第 k 次下注额 2^{k-1} 由过去决定, 每个有限时刻的净收益过程 G_n 是鞅, $G_0 = 0$ 。若 T 为首次正面, 则 $T < \infty$ a.s., 甚至 $\mathbb{E}T = 2$, 但

$$G_T = 1 \quad \text{a.s.}, \quad G_{T \wedge n} = \begin{cases} 1, & T \leq n, \\ -(2^n - 1), & T > n. \end{cases}$$

其期望仍为零: 概率 2^{-n} 的巨大损失恰好抵消其他路径的收益。下注增量不一致有界, 停止变量也不一致可积, 因此终端等式不成立。“公平”与“停时平均有限”各自都不足以替代适用条件。

9.7 赌徒破产: 停止方法怎样正确使用

令 $S_0 = i \in \{1, \dots, b-1\}$, 每步独立以相同概率加减 1, $b \geq 2$, 并令

$$T = \inf\{n : S_n \in \{0, b\}\}.$$

从任一内部状态, 接下来 b 步连续向同一方向走就会触边, 成功概率至少 2^{-b} 。按长度 b 的时间块条件化, 得到几何尾界, 故 $\mathbb{E}T < \infty$ 。

S_n 是鞅，且停止过程在 $[0, b]$ 内有界。因此

$$\mathbb{E}S_T = i, \quad \mathbb{P}_i(S_T = b) = \frac{i}{b}.$$

再对 $S_n^2 - n$ 使用有界停时 $T \wedge n$,

$$\mathbb{E}S_{T \wedge n}^2 - \mathbb{E}(T \wedge n) = i^2.$$

平方项由 b^2 控制，时间项单调增加到 T ，分别用控制收敛和单调收敛，得

$$\mathbb{E}T = \mathbb{E}S_T^2 - i^2 = bi - i^2 = i(b - i).$$

推导没有直接把无界停时塞进平方鞅：先截断，再逐项说明极限依据，才得到所需公式。

9.8 Wald 恒等式：随机项数怎样进入期望

设 $\xi_1, \xi_2, \dots$ 独立同分布， $\mathbb{E}|\xi_1| < \infty$ ，均值为 μ ，令 $S_n = \sum_{k=1}^n \xi_k$ 。相对于自然滤过 $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$ ，若停时 $T \in \mathbb{N}_0 \cup \{\infty\}$ 满足 $\mathbb{E}T < \infty$ ，则

$$\mathbb{E}S_T = \mu \mathbb{E}T.$$

T 一般依赖观测到的增量，并不与它们独立。真正起作用的是：是否需要第 k 项，即 $\{T \geq k\}$ ，在看到第 k 项之前已经确定。

9.8.1 从中心化鞅到可交换的级数

$M_n = S_n - n\mu$ 是鞅，对每个有界截断 $T \wedge n$ 有 $\mathbb{E}M_{T \wedge n} = 0$ 。这里增量未必一致有界，不能仅凭前面的“有界增量加可积停时”版本结束证明。

展开随机和更直接。由于 $\{T \geq k\} \in \mathcal{F}_{k-1}$ ，它与 ξ_k 独立。先用 Tonelli 检查绝对可积：

$$\begin{aligned} \mathbb{E} \sum_{k \geq 1} |\xi_k| \mathbf{1}_{\{T \geq k\}} &= \sum_{k \geq 1} \mathbb{E}|\xi_k| \mathbb{P}(T \geq k) \\ &= \mathbb{E}|\xi_1| \mathbb{E}T < \infty. \end{aligned}$$

于是 $S_T = \sum_{k \geq 1} \xi_k \mathbf{1}_{\{T \geq k\}}$ 可积，Fubini 允许交换有符号求和与期望：

$$\mathbb{E}S_T = \sum_{k \geq 1} \mu \mathbb{P}(T \geq k) = \mu \mathbb{E}T.$$

同一估计也控制截断尾部：

$$\mathbb{E}|S_T - S_{T \wedge n}| \leq \mathbb{E}|\xi_1| \sum_{k > n} \mathbb{P}(T \geq k) \rightarrow 0.$$

再加上 $T \wedge n \rightarrow T$ 于 L^1 ，就补齐了中心化鞅可选停止的极限步骤。这个证明说明：可积性可以由随机和结构提供，不必机械要求每步有统一界。

9.8.2 一个停时例子与一个非停时反例

令 $\xi_k \sim \text{Bernoulli}(p)$ 独立， $0 < p \leq 1$ ， T 是首次出现 1 的时刻。此时 $S_T = 1$ ，且 $\mathbb{E}T = 1/p$ ，故 $\mathbb{E}S_T = p\mathbb{E}T = 1$ 。终止与增量明显相关，但公式成立。

反过来，令 ξ_1, ξ_2 独立以相同概率取 ± 1 ，并按尚未观察的第二项定义：若 $\xi_2 = 1$ 就取 $T = 2$ ，否则取 $T = 1$ 。它有界，却不是自然滤过的停时，因为 $\{T \leq 1\} = \{\xi_2 = -1\}$ 在时刻 1 不可知。此时

$$S_T = \xi_1 + \xi_2 \mathbf{1}_{\{\xi_2 = 1\}}, \quad \mathbb{E}S_T = \frac{1}{2} \neq 0 = \mu \mathbb{E}T.$$

所以“项数有限”不能替代“终止规则是停时”。即使是停时，若 $\mathbb{E}T = \infty$ ，也不能照搬本节的有限期望等式。

9.8.3 与课程中的指数型 Wald 公式衔接

如果 $m(\theta) = \mathbb{E}e^{\theta\xi_1} < \infty$, 记 $\psi(\theta) = \log m(\theta)$, 则

$$L_n(\theta) = \exp\{\theta S_n - n\psi(\theta)\}$$

是非负乘积鞅。停止后若有适当的一致可积性, 才能把 $\mathbb{E}L_{T \wedge n}(\theta) = 1$ 推进到 $\mathbb{E}L_T(\theta) = 1$ 。课程还由指数表达对参数求导讨论随机和; 那需要额外核对求导与期望交换。本节用绝对可积级数单独证明一阶等式, 避免暗中附加矩母函数存在的假设。

序贯概率比检验使用的正是对数似然增量构成的随机游走, 见附录 C。其平均样本数计算使用本节等式; 其错误概率控制则使用非负似然比鞅, 两者用途不同。

材料依据。 MIT 第 23–24 讲的鞅差、可预测下注、乘积、停止及 Wald 讨论。可预测漂移分解是对课程构造的增强桥接; 一阶 Wald 等式另用绝对可积级数补齐证明, 不依赖未经检查的参数求导。序贯检验移入独立附录。

10 鞅的收敛

鞅的当前条件均值不变，并不意味着路径不波动。最大不等式控制一段时间内的大偏离，收敛定理控制无限时间内的振荡；要再把路径极限放进期望，还需额外的可积性控制。

10.1 非负下鞅的最大不等式

设 $(X_k, \mathcal{F}_k)$ 为非负下鞅，固定 $n \geq 0, a > 0$ 。令

$$T = \min(\inf\{k \geq 0 : X_k \geq a\}, n), \quad A = \{\max_{0 \leq k \leq n} X_k \geq a\}.$$

这是有界停时。更精确地按首次越界时刻分解 A ，事件 $A \cap \{T = k\}$ 属于 $\mathcal{F}_k$ ；多步下鞅关系给出

$$\begin{aligned} a\mathbb{P}(A) &\leq \sum_{k=0}^n \mathbb{E}[X_k \mathbf{1}_{A \cap \{T=k\}}] \\ &\leq \sum_{k=0}^n \mathbb{E}[X_n \mathbf{1}_{A \cap \{T=k\}}] = \mathbb{E}[X_n \mathbf{1}_A] \leq \mathbb{E}X_n. \end{aligned}$$

最后一步需要非负性。因此

$$\mathbb{P}\left(\max_{0 \leq k \leq n} X_k \geq a\right) \leq \frac{\mathbb{E}X_n}{a}.$$

它把“任一时刻曾经越界”的概率，归结为一个终端期望，并不需要对每个时间点分别用概率界再相加。

若 M 是平方可积鞅， M_k^2 为非负下鞅，故

$$\mathbb{P}\left(\max_{0 \leq k \leq n} |M_k| \geq a\right) \leq \frac{\mathbb{E}M_n^2}{a^2}.$$

特别地，对独立均值零、方差有限的增量和 S_k ，右侧为 $\sum_{j=1}^n \text{Var}(\xi_j)/a^2$ ，这给出 Kolmogorov 最大不等式的鞅证明。

10.2 从最大不等式到强大数定律

设 $\xi_1, \xi_2, \dots$ 独立同分布， $\mathbb{E}\xi_1 = 0$ ， $\text{Var}(\xi_1) = \sigma^2 < \infty$ ， $S_n = \sum_{j=1}^n \xi_j$ 。目标是证明 $S_n/n \rightarrow 0$ a.s.。

只对单个 n 用 Chebyshev 得到 $\sigma^2/(\varepsilon^2 n)$ ，概率上界不可求和，不能直接用第一 Borel–Cantelli 引理。课程的关键做法是改用二进制时间块。最大不等式给出

$$\mathbb{P}\left(\max_{1 \leq j \leq 2^k} |S_j| > \varepsilon 2^k\right) \leq \frac{\sigma^2}{\varepsilon^2 2^k}.$$

右侧对 k 可求和，因此几乎必然存在随机的 k_0 ，使 $k \geq k_0$ 时 $\max_{j \leq 2^k} |S_j| \leq \varepsilon 2^k$ 。若 $2^{k-1} < n \leq 2^k$ ，则

$$\frac{|S_n|}{n} \leq \frac{\varepsilon 2^k}{2^{k-1}} = 2\varepsilon.$$

先对可数个 $\varepsilon = 1, 1/2, 1/3, \dots$ 取概率一事件的交，再令 $\varepsilon \downarrow 0$ ，就得到所有整数时刻上的几乎处处收敛。

对均值 μ 的变量先中心化，得 $n^{-1} \sum_{j=1}^n \xi_j \rightarrow \mu$ a.s.。这里证明的是有限方差版本；一般只要求 $\mathbb{E}|\xi_1| < \infty$ 的独立同分布强大数定律需要额外截断论证，不由上述方差计算直接得到。

10.3 L1 有界鞅的路径收敛

若 (M_n) 是鞅, 且

$$\sup_{n \geq 0} \mathbb{E}|M_n| < \infty,$$

则存在可积随机变量 M_∞ , 使 $M_n \rightarrow M_\infty$ a.s., 并有

$$\mathbb{E}|M_\infty| \leq \liminf_n \mathbb{E}|M_n|.$$

条件中的绝对值不能丢。任何鞅都有 $\mathbb{E}M_n = \mathbb{E}M_0$, 所以 “ $\sup_n \mathbb{E}M_n < \infty$ ” 对一般鞅没有提供所需的控制。

证明的结构是控制上穿次数: 若路径不断从 a 以下涨到 b 以上, 按 “低位持有、高位退出” 构造的可预测策略每完成一次上穿就取得至少 $b - a$ 的收益。鞅策略的期望收益为零, 而最后一段未完成持仓的损失受 $\mathbb{E}|M_n|$ 控制, 因此上穿次数的期望一致有界。对所有有理数 $a < b$ 使用这一结论, 排除持续振荡; 再由 Fatou 排除无穷极限。完整短证明见 小节 B.3。

非负鞅自动满足 $\sup_n \mathbb{E}|M_n| = \mathbb{E}M_0$, 因而几乎处处收敛。结论尚未包含 L^1 收敛或期望保持。

10.4 路径极限为何可以损失期望

回到乘积鞅

$$M_n = 2^n \mathbf{1}_{\{\text{前 } n \text{ 次公平硬币全为正面}\}}.$$

全正面无限持续的概率为 $\lim_n 2^{-n} = 0$, 所以 $M_n \rightarrow 0$ a.s., 但

$$\mathbb{E}M_n = 1, \quad \mathbb{E}|M_n - 0| = 1.$$

它满足 L^1 有界条件, 却不在 L^1 中收敛。期望被越来越稀少、数值越来越大的路径维持, 几乎处处极限看不到这部分尾部贡献。

这也解释了上一章加倍下注的问题: 每个截断时刻的期望等式正确, 错误发生在缺乏尾部控制却令截断趋于无穷。

10.5 一致可积: 补足期望极限交换

随机变量族 (Y_n) 称为一致可积, 如果

$$\lim_{K \rightarrow \infty} \sup_n \mathbb{E}[|Y_n| \mathbf{1}_{\{|Y_n| > K\}}] = 0.$$

这控制的是所有变量的大值部分对期望的贡献。它比 $\sup_n \mathbb{E}|Y_n| < \infty$ 强; 上面的乘积鞅对任意固定 K 都能选 $2^n > K$, 使尾部期望仍为 1。

若 $Y_n \rightarrow Y$ a.s. 且 (Y_n) 一致可积, 则 $Y_n \rightarrow Y$ 于 L^1 。证明可以截断在 $[-K, K]$: 截断部分用控制收敛, 未截断尾部用一致可积性, 极限变量的尾部用其可积性; 先令 $n \rightarrow \infty$, 再令 $K \rightarrow \infty$ 。细节见 小节 B.4。

两个实用充分条件是: 存在可积 Z 使 $|Y_n| \leq Z$; 或存在 $p > 1$ 使 $\sup_n \mathbb{E}|Y_n|^p < \infty$ 。后者来自

$$\mathbb{E}[|Y_n| \mathbf{1}_{\{|Y_n| > K\}}] \leq K^{1-p} \mathbb{E}|Y_n|^p.$$

因此一致可积鞅不仅几乎处处收敛, 也在 L^1 中收敛, 并保持 $\mathbb{E}M_\infty = \mathbb{E}M_0$ 。对固定 n 还有

$$M_n = \mathbb{E}[M_\infty | \mathcal{F}_n].$$

因为 $m \geq n$ 时 $\mathbb{E}[M_m | \mathcal{F}_n] = M_n$, 而条件期望是 L^1 压缩: $\mathbb{E}|\mathbb{E}[M_m - M_\infty | \mathcal{F}_n]| \leq \mathbb{E}|M_m - M_\infty| \rightarrow 0$ 。

可选停止也由同一机制获得: 若 $T < \infty$ a.s. 且 $\{M_{T \wedge n} : n \geq 0\}$ 一致可积, 则其路径极限 M_T 同时为 L^1 极限, 因此 $\mathbb{E}M_T = \mathbb{E}M_0$ 。要核对的是停止变量族的可积性控制。

10.6 L^2 有界鞅：用正交性证明更强收敛

若 $\sup_n \mathbb{E}M_n^2 < \infty$ ，对 $m \geq n$ ，鞅性质给出

$$\mathbb{E}[M_m M_n] = \mathbb{E}[M_n \mathbb{E}(M_m | \mathcal{F}_n)] = \mathbb{E}M_n^2.$$

因此

$$\mathbb{E}(M_m - M_n)^2 = \mathbb{E}M_m^2 - \mathbb{E}M_n^2.$$

二阶矩序列非减且有界，故收敛，右侧随 $m, n \rightarrow \infty$ 趋零。由 L^2 空间的完备性， M_n 有 L^2 极限；同时它是 L^1 有界鞅，有几乎处处极限，两者由依概率极限的唯一性相同。于是

$$M_n \rightarrow M_\infty \quad \text{a.s.、于 } L^2, \text{ 也于 } L^1.$$

这个证明展示了鞅差正交性的用途：后续增量的二阶能量等于二阶矩增长量，二阶矩总量有界就使剩余能量消失。

可检查条件	保证的结论	仍需注意
鞅, $\sup_n \mathbb{E} M_n < \infty$	几乎处处收敛，极限可积	不能自动交换期望
非负鞅	满足上一行	极限期望可能变小
一致可积鞅	几乎处处与 L^1 收敛	期望保持
鞅, $\sup_n \mathbb{E}M_n^2 < \infty$	另有 L^2 收敛	用二阶矩正交恒等式验证

10.7 分枝过程：先消去平均增长率

课程用分枝过程说明：一个不断增长的过程未必直接是鞅，但除去平均增长率后可能得到鞅。

设初代 $Z_0 = 1$ 。每个个体独立产生非负整数个后代，所有代、所有个体的后代数 $\xi_{n,k}$ 独立同分布，满足

$$0 < m = \mathbb{E}\xi_{n,k} < \infty, \quad Z_{n+1} = \sum_{k=1}^{Z_n} \xi_{n,k}.$$

空和为零，故灭绝后始终保持零。令 $\mathcal{F}_n$ 包含产生到第 n 代所用的后代变量，下一代的后代数数组与它独立。给定 $\mathcal{F}_n$ ，求和项数 Z_n 已知，所以

$$\mathbb{E}[Z_{n+1} | \mathcal{F}_n] = mZ_n, \quad \mathbb{E}Z_n = m^n.$$

一般 Z_n 不是鞅，归一化后

$$W_n = \frac{Z_n}{m^n}, \quad \mathbb{E}[W_{n+1} | \mathcal{F}_n] = W_n, \quad \mathbb{E}W_n = 1.$$

W_n 是非负鞅，故存在有限可积的 W_∞ ，满足

$$W_n \rightarrow W_\infty \quad \text{a.s.}, \quad \mathbb{E}W_\infty \leq 1.$$

这控制的是相对于平均尺度 m^n 的比例，不是相邻两代的比值，也没有自动给出 L^1 收敛。在 $W_\infty > 0$ 的路径上才可写 $Z_n \sim W_\infty m^n$ ；若极限为零，结论只说明 $Z_n = o(m^n)$ ，不能单凭这一点断定已在有限时刻灭绝。

10.7.1 灭绝与极限期望是两件事

若 $m < 1$, 由 Z_n 取非负整数值,

$$\mathbb{P}(Z_n > 0) \leq \mathbb{E}Z_n = m^n \rightarrow 0.$$

事件 $\{Z_n > 0\}$ 随 n 递减, 所以永不灭绝的概率为零。于是 W_n 最终为零, $W_\infty = 0$ a.s., 但每个 $\mathbb{E}W_n = 1$; 这里出现了具体模型中的期望损失。

临界情形 $m = 1$ 也要区分退化与非退化。若 $\xi \equiv 1$, 则 $Z_n \equiv 1$, 永不灭绝。若后代分布非退化, 设生成函数 $f(s) = \mathbb{E}s^\xi$, $q_n = \mathbb{P}(Z_n = 0)$ 。由各子树独立且同分布,

$$q_0 = 0, \quad q_{n+1} = f(q_n).$$

它单调增加到灭绝概率 q , 连续性给出 $q = f(q)$ 。对 $0 < s < 1$, 严格 Jensen 给出 $f(s) > s^{\mathbb{E}\xi} = s$, 且非退化、均值为 1 的整数分布必有 $f(0) > 0$ 。因此唯一可能的固定点是 $q = 1$, 仍几乎必然灭绝。这里仅证明用来区分边界的临界结论, 不展开完整灭绝概率理论。

10.7.2 超临界时怎样保证 L2 收敛

进一步假设 $m > 1$, 且后代方差 $\sigma^2 < \infty$ 。给定 $\mathcal{F}_n$ 后, 独立求和给出

$$\text{Var}(Z_{n+1} \mid \mathcal{F}_n) = \sigma^2 Z_n, \quad \mathbb{E}[Z_{n+1}^2 \mid \mathcal{F}_n] = m^2 Z_n^2 + \sigma^2 Z_n.$$

除以 m^{2n+2} 再取期望, 得到

$$\mathbb{E}W_{n+1}^2 - \mathbb{E}W_n^2 = \frac{\sigma^2}{m^{n+2}}.$$

因 $W_0 = 1$, 几何求和给出

$$\mathbb{E}W_n^2 = 1 + \frac{\sigma^2}{m(m-1)}(1 - m^{-n}) \leq 1 + \frac{\sigma^2}{m(m-1)}.$$

由本章 L^2 有界鞅结论, $W_n \rightarrow W_\infty$ 于 L^2 、 L^1 且几乎处处, 因而

$$\mathbb{E}W_\infty = 1, \quad \text{Var}(W_\infty) = \frac{\sigma^2}{m(m-1)}.$$

这个例子给出清楚的条件链: 有限一阶矩负责构造归一化鞅, 非负性负责路径收敛, 超临界加有限方差负责二阶有界与期望保持。更弱矩条件下的非退化极限判据不在本轮展开。

材料依据。 MIT 第 24–25 讲的最大不等式、分块强大数律与鞅收敛; 第 24 讲约 01:14–01:20 的分枝过程归一化。上穿、一致可积与 L^2 基础沿用 P0; 分枝部分补明增长参数、退化情形和有限方差条件, 不把极限为零直接等同于灭绝。

A 共用概率与矩阵工具

本附录集中放置正文反复使用的规则，重点记录何时能用。它不替代原有概率统计工具箱，也不假定读者能访问旧项目。

A.1 非负求和、尾概率与极限交换

若 $Y_n \geq 0$ ，Tonelli 与单调收敛给出

$$\mathbb{E} \sum_{n \geq 0} Y_n = \sum_{n \geq 0} \mathbb{E} Y_n,$$

两边允许为无穷。若变量有正有负，一个方便的充分条件是 $\sum_n \mathbb{E}|Y_n| < \infty$ ，此时可以用 Fubini 交换。矩阵概率乘法、访问次数和周期占用量大多属于非负情形。

对非负实变量 Y ，逐点有 $Y = \int_0^\infty \mathbf{1}_{\{Y > t\}} dt$ ，故

$$\mathbb{E} Y = \int_0^\infty \mathbb{P}(Y > t) dt.$$

对取值于 $\mathbb{N}_0 \cup \{\infty\}$ 的 T ，同理

$$\mathbb{E} T = \sum_{n \geq 0} \mathbb{P}(T > n).$$

泊松年龄均值、几何尾停时的可积性都可直接用这两个式子。

常用极限定理的分工如下：

规则	条件	结论
单调收敛	$0 \leq Y_n \uparrow Y$ a.s.	$\mathbb{E} Y_n \uparrow \mathbb{E} Y$ ，允许无穷
Fatou	$Y_n \geq 0$	$\mathbb{E} \liminf Y_n \leq \liminf \mathbb{E} Y_n$
控制收敛	$Y_n \rightarrow Y$ a.s., $ Y_n \leq Z$, $\mathbb{E} Z < \infty$	$Y_n \rightarrow Y$ 于 L^1 ，期望收敛

Fatou 只有一个方向的不等式，不能用它宣称期望保持。有限个项可以逐项取极限；无穷个状态或时刻的求和仍需上述控制。

A.2 Borel–Cantelli 与可积变量的尾部

第一 Borel–Cantelli 引理：若 $\sum_n \mathbb{P}(A_n) < \infty$ ，则事件 A_n 只发生有限次 a.s.。不要求事件独立。证明是

$$\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n) \rightarrow 0,$$

再利用尾部并集递减到“发生无穷多次”的事件。鞅单元的分块证明只使用这一方向。

若事件独立且 $\sum_n \mathbb{P}(A_n) = \infty$ ，第二 Borel–Cantelli 引理保证无穷多次发生。对于正文中同概率独立事件，只需观察连续失败概率 $(1-p)^k \rightarrow 0$ 即可。

若 Z_n 同分布、 $\mathbb{E}|Z_1| < \infty$ ，不要求独立，则对每个 $\varepsilon > 0$ ，由尾积分比较

$$\sum_{n \geq 1} \mathbb{P}(|Z_n| > \varepsilon n) = \sum_{n \geq 1} \mathbb{P}(|Z_1| > \varepsilon n) \leq \frac{\mathbb{E}|Z_1|}{\varepsilon} < \infty.$$

因此 $Z_n/n \rightarrow 0$ a.s.。它用于返回周期论证中控制最后一个未完成周期，而不是把未完成周期直接删去。

独立同分布且 $\mathbb{E}|Z_1| < \infty$ 时，强大数定律给出平均值趋于 $\mathbb{E}Z_1$ a.s.。此处将其作为前置概率定理；正文给出了有限方差版本的可迁移证明。

A.3 条件 Jensen、全方差与全协方差

凸函数 φ 满足有关变量可积时，条件 Jensen 为

$$\varphi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\varphi(X) | \mathcal{G}].$$

特别地， $|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}[|X| | \mathcal{G}]$ ，所以条件期望在 L^1 中是压缩；对平方函数得到 L^2 压缩。这解释了条件期望正交分解中的可积性。

对二阶矩有限的列向量 X ，记 $m = \mathbb{E}[X | \mathcal{G}]$ ，

$$\text{Cov}(X | \mathcal{G}) = \mathbb{E}[(X - m)(X - m)^\top | \mathcal{G}].$$

由 $X - \mathbb{E}X = (X - m) + (m - \mathbb{E}X)$ 展开，交叉项的条件期望为零，故

$$\text{Cov}(X) = \mathbb{E}[\text{Cov}(X | \mathcal{G})] + \text{Cov}(\mathbb{E}[X | \mathcal{G}]).$$

标量版本就是全方差公式。一般只能推出平均条件协方差不超过原协方差；不能推出每个观测值对应的条件方差都减小。高斯样章中条件协方差不依赖观测值，才获得更强的逐值结论。

A.4 半正定序与 Schur 补

对实对称矩阵， $A \succeq 0$ 表示 $v^\top A v \geq 0$ 对任意 v 成立； $A \preceq B$ 表示 $B - A \succeq 0$ 。这比较所有线性方向上的二次型，不是逐元素比较。

若 $D \succ 0$ ，则

$$\Sigma = \begin{pmatrix} A & C \\ C^\top & D \end{pmatrix} \succeq 0 \iff S = A - CD^{-1}C^\top \succeq 0.$$

正定版本同样成立。分块消元把 Σ 合同变换为 $\text{diag}(S, D)$ ，且 $CD^{-1}C^\top \succeq 0$ ，所以 $S \preceq A$ 。这给出了条件高斯的剩余协方差及其大小关系；完整消元与密度证明见 小节 3.3。

B 关键结论的补充证明

本附录只收录正文主线已经使用、但完整展开会打断阅读的论证。

B.1 泊松过程在到达时刻重新开始

设 N 是右连续齐次泊松过程, $\mathcal{F}_t = \sigma(N(u) : u \leq t)$, S 是几乎处处有限的停时。连续时间停时信息定义为

$$\mathcal{F}_S = \{A \in \mathcal{F} : A \cap \{S \leq t\} \in \mathcal{F}_t \text{ 对每个 } t \geq 0\}.$$

置 $S_m = 2^{-m} \lceil 2^m S \rceil$, 则 $S_m \downarrow S$, 且对网格时刻 r , $A \cap \{S_m = r\} \in \mathcal{F}_r$ 。这一点使确定时刻的独立增量可以逐分支使用。

固定 $u_1, \dots, u_k \geq 0$ 及有界连续函数 g 。记

$$Z_m = g(N(S_m + u_1) - N(S_m), \dots, N(S_m + u_k) - N(S_m)),$$

并令 $c = \mathbb{E}g(N(u_1), \dots, N(u_k))$ 。对 $A \in \mathcal{F}_S$, 在各网格分支上, 未来增量与 $\mathcal{F}_r$ 独立且其分布不依赖 r , 因此

$$\mathbb{E}[\mathbf{1}_A Z_m] = \sum_r \mathbb{E}[\mathbf{1}_{A \cap \{S_m = r\}} Z_m] = \sum_r \mathbb{P}(A \cap \{S_m = r\}) c = \mathbb{P}(A) c.$$

有界性与分支事件互斥保证级数绝对可积。路径右连续使 Z_m a.s. 收敛到把 S_m 换为 S 的 Z ; 控制收敛得 $\mathbb{E}[\mathbf{1}_A Z] = \mathbb{P}(A) c$ 。有界连续测试函数确定有限维分布, 再推广到这些坐标生成的信息, 得到停时之后的计数过程与过去独立, 且与原过程同分布。

这段证明只用了确定时刻的独立、平稳增量, 加上停时可测性与右连续性。若随机时刻依赖尚未观察的未来, 分支事件不一定属于对应信息集, 证明就失效。

B.2 有限不可约非周期链的分布收敛

设状态数为 $d < \infty$, P 不可约且非周期。先说明存在某个 m 使 $Q = P^m$ 的所有元素都严格为正。

选参考状态 o 。其正概率返回长度集合在加法下封闭, 最大公约数为 1, 所以能选有限个返回长度 $r_1, \dots, r_k$, 公约数已经为 1。这些长度的非负整数和包含所有充分大的整数: 模 r_1 考察生成的剩余类, 有限加法半群实际构成子群, 而公约数为 1 使其覆盖全部剩余类; 每个剩余类选一个可表示的非负长度, 再不断加 r_1 即可。

从任意 i 先走到 o , 在 o 返回若干次, 再走到 j , 可得所有充分大长度的 $i \rightarrow j$ 路径。状态对只有有限个, 取共同足够大的 m , 便有 $Q_{ij} > 0$ 。

令 $\eta = \min_{i,j} Q_{ij} > 0$, $\epsilon = d\eta \leq 1$, u 为均匀概率行向量。若 $\epsilon < 1$, 每行可以分解为

$$Q(i, \cdot) = \epsilon u + (1 - \epsilon) R(i, \cdot),$$

其中 R 仍是随机矩阵。对概率行向量 α, β , 公共部分抵消, 且随机矩阵对 ℓ^1 距离不扩张, 故

$$\|\alpha Q - \beta Q\|_1 \leq (1 - \epsilon) \|\alpha - \beta\|_1.$$

不扩张性直接来自三角不等式和行和为 1: $\sum_j |\sum_i v_i R_{ij}| \leq \sum_i |v_i|$ 。若 $\epsilon = 1$, Q 的各行已全为 u , 一次即可消除初始分布影响。

有限不可约链由正文已知存在平稳概率 π 。写 $n = km + r, 0 \leq r < m$, 则

$$\|\alpha P^n - \pi\|_1 \leq (1 - \epsilon)^k \|\alpha - \pi\|_1 \rightarrow 0.$$

非周期性用于得到全正矩阵幂; 有限性用于把各状态对的路径长度与正概率统一控制。这个几何界不能直接推广到任意可数无限状态链。

B.3 上穿次数与鞅收敛

设 M 是鞅, $C = \sup_n \mathbb{E}|M_n| < \infty$ 。固定实数 $a < b$, 观察到 $M_k \leq a$ 时开始持有一单位, 直到观察到 $M_k \geq b$ 时退出, 再重复。每一步是否持有只由此前观测决定, 记为 $H_k \in \{0, 1\}$, 故

$$G_N = \sum_{k=1}^N H_k (M_k - M_{k-1}), \quad \mathbb{E}G_N = 0.$$

若在时刻零已满足买入条件, 就从第一段增量开始持有。令 $U_N[a, b]$ 为到时刻 N 完成的上穿次数, 每个完整段贡献至少 $b - a$; 最后一个未完成段若存在, 买入价不超过 a , 其损益至少 $-(M_N - a)^-$ 。所以逐路径有

$$G_N \geq (b - a)U_N[a, b] - (M_N - a)^-, \quad x^- = \max(-x, 0).$$

取期望,

$$(b - a)\mathbb{E}U_N[a, b] \leq \mathbb{E}(M_N - a)^- \leq C + |a|.$$

U_N 非减, 单调收敛使无穷时间的上穿次数仍有有限期望, 因而几乎处处有限。

对所有有理数 $a < b$ 取可数交。若某条路径 $\liminf M_n < \limsup M_n$, 就能在两者之间选有理数 $a < b$, 并产生无穷次上穿, 矛盾。因此 M_n 有扩展实数极限。再由 Fatou,

$$\mathbb{E} \liminf_n |M_n| \leq C,$$

排除正负无穷极限, 并证明极限可积。这里没有得到 $\mathbb{E}|M_n - M_\infty| \rightarrow 0$, 所以也没有自动得到期望保持。

B.4 一致可积为何允许 L1 取极限

设 $Y_n \rightarrow Y$ a.s., 且 (Y_n) 一致可积。先选一个足够大的 K 使尾期望统一有界, 便有

$$\sup_n \mathbb{E}|Y_n| \leq K + \sup_n \mathbb{E}[|Y_n| \mathbf{1}_{\{|Y_n| > K\}}] < \infty.$$

Fatou 给出 $\mathbb{E}|Y| < \infty$ 。定义连续截断函数 $\phi_K(x) = \max(-K, \min(x, K))$, 则

$$\begin{aligned} \mathbb{E}|Y_n - Y| &\leq \mathbb{E}|\phi_K(Y_n) - \phi_K(Y)| \\ &\quad + \mathbb{E}[|Y_n| \mathbf{1}_{\{|Y_n| > K\}}] + \mathbb{E}[|Y| \mathbf{1}_{\{|Y| > K\}}]. \end{aligned}$$

固定 K , 第一项由控制收敛趋零; 第二项对 n 的上确界随 $K \rightarrow \infty$ 趋零; 第三项由 Y 的可积性趋零。按这个顺序取极限得到 L^1 收敛。

核验来源。上穿与一致可积结论核对了 [Durrett 第五版作者公开稿](#) 中 Theorems 4.2.11、4.6.3 与 4.6.7; 本附录给出与正文所需鞅版本相适配的证明, 不转载教材原文。

C 序贯概率比检验

固定样本量检验先决定观察多少次，序贯检验则事先规定“何时证据足以停止”。随机停止并不自动破坏错误概率控制；关键是预先定义完整规则，并对这个规则证明概率界。

本附录沿 MIT 第 23 讲连接似然比、随机游走和 Wald 公式，只讨论两个简单假设之间的独立同分布检验，不展开一般最优性理论。

C.1 先固定似然比方向

在假设 H_i 下，观测 $Y_1, Y_2, \dots$ 独立同分布，密度或概率质量函数为 f_i ，概率与期望记作 $\mathbb{P}_i, \mathbb{E}_i$ 。假设 f_0, f_1 相对于同一基准测度定义，在共同支持集上均严格为正，且两分布不同。这样似然比在两种假设下都有限、正值。

沿讲稿采用 f_0/f_1 的方向，定义

$$L_0 = 1, \quad L_n = \prod_{k=1}^n \frac{f_0(Y_k)}{f_1(Y_k)}, \quad S_n = \log L_n = \sum_{k=1}^n \ell(Y_k), \quad \ell(y) = \log \frac{f_0(y)}{f_1(y)}.$$

L_n 大支持 H_0 ，小支持 H_1 。这是似然之比，不是后验概率之比；有正的先验概率时，后验比还要乘先验比。

取 $0 < B < 1 < A$ ，在观察前固定规则

$$T = \inf\{n \geq 1 : L_n \notin (B, A)\}.$$

当 $L_T \geq A$ 时判 H_0 ，当 $L_T \leq B$ 时判 H_1 ，未触边时继续。 T 是自然滤过 $\mathcal{F}_n = \sigma(Y_1, \dots, Y_n)$ 的停时。记判决事件为 D_0, D_1 ，并定义实际错误概率

$$\alpha = \mathbb{P}_0(D_1), \quad \beta = \mathbb{P}_1(D_0).$$

不要把阈值 A, B 、目标错误率和实际错误率混用。若某教材使用 f_1/f_0 ，它的上下边界及判决方向也必须一起转换。

C.2 用非负鞅得到严格错误界

在 H_1 下，每个似然比因子的均值为

$$\mathbb{E}_1 \frac{f_0(Y_k)}{f_1(Y_k)} = \int f_0(y) dy = 1,$$

所以 L_n 是关于 $\mathbb{P}_1$ 的非负鞅。同理， L_n^{-1} 是关于 $\mathbb{P}_0$ 的非负鞅。二者的“公平性”分别属于不同概率模型，不能省略下标。

对有限时间最大不等式令时限递增，事件单调收敛给出

$$\begin{aligned} \beta &\leq \mathbb{P}_1(\exists n : L_n \geq A) \leq \frac{1}{A}, \\ \alpha &\leq \mathbb{P}_0(\exists n : L_n^{-1} \geq B^{-1}) \leq B. \end{aligned}$$

这里不需要贸然写 $\mathbb{E}_1 L_T = 1$ ，也不需要忽略越界量。若目标为 $\alpha \leq \alpha_*, \beta \leq \beta_*$ ，其中 $0 < \alpha_*, \beta_* < 1$ ，一组保守且严格有效的选择是

$$B = \alpha_*, \quad A = \frac{1}{\beta_*}.$$

这些界控制按照预先规定规则作出的错误判决，不能据此随意更换假设、追加筛选规则后仍沿用同一个证明。

在本附录的模型下， T 在两种假设下都有有限期望。简要理由是：两分布不同且互相等价，故存在 $\varepsilon > 0$ ，使 $\mathbb{P}_i(\ell(Y) \geq \varepsilon) = q_i > 0$ ， $i = 0, 1$ 。选整数 r 使 $r\varepsilon > \log A - \log B$ ；只要尚未停止，接下来 r 个增量都至少为 ε 就必触上界，其条件概率为 q_i^r 。因此

$$\mathbb{P}_i(T > kr) \leq (1 - q_i^r)^k, \quad \mathbb{E}_i T < \infty.$$

这只用于证明有限性，通常是很粗的平均样本数上界。

C.3 常用 Wald 阈值为什么带有近似

对停止时可判定的事件 D ，按 $\{T = n\}$ 分解，固定时刻的密度比公式给出

$$\mathbb{P}_0(D) = \sum_{n \geq 1} \mathbb{E}_1[L_n \mathbf{1}_{D \cap \{T=n\}}] = \mathbb{E}_1[L_T \mathbf{1}_D].$$

T 在两种模型下都有限，各项非负，故分解与求和有依据。这是停止样本的换测度恒等式，不是无条件调用可选停止。

分别取 D_0, D_1 ，得到精确关系

$$1 - \alpha = \mathbb{E}_1[L_T \mathbf{1}_{D_0}] \geq A\beta, \quad \alpha = \mathbb{E}_1[L_T \mathbf{1}_{D_1}] \leq B(1 - \beta).$$

若忽略越界，把 L_T 在两个判决事件上近似为 A, B ，便得到

$$A \approx \frac{1 - \alpha}{\beta}, \quad B \approx \frac{\alpha}{1 - \beta}.$$

于是常见的设计是以目标错误率代入

$$A_W = \frac{1 - \alpha_*}{\beta_*}, \quad B_W = \frac{\alpha_*}{1 - \beta_*}, \quad \alpha_* + \beta_* < 1.$$

这不是上一节保守界的同一个选择，也不能单凭“忽略越界”的等式保证实际两项错误率恰好等于目标。对离散观测，似然比尤其可能跳过边界；需要准确保证时，可使用前述保守阈值，或另外核算该具体模型的实际错误概率。

C.4 平均样本数：Wald 等式与越界修正

再假设 $\mathbb{E}_i|\ell(Y)| < \infty$ ， $i = 0, 1$ 。定义

$$D(f\|g) = \int f(y) \log \frac{f(y)}{g(y)} dy.$$

在当前共同正支持且分布不同的条件下，

$$\mu_0 = \mathbb{E}_0 \ell(Y) = D(f_0\|f_1) > 0, \quad \mu_1 = \mathbb{E}_1 \ell(Y) = -D(f_1\|f_0) < 0.$$

每步平均对数证据朝正确假设的边界漂移。由 小节 9.8 及已证明的 $\mathbb{E}_i T < \infty$ ，精确等式为

$$\mathbb{E}_i S_T = \mu_i \mathbb{E}_i T.$$

令 $a = \log A > 0, b = \log B < 0$ 。若忽略对数越界量,

$$\begin{aligned}\mathbb{E}_0 T &\approx \frac{(1 - \alpha)a + \alpha b}{D(f_0 \| f_1)}, \\ \mathbb{E}_1 T &\approx \frac{\beta a + (1 - \beta)b}{-D(f_1 \| f_0)}.\end{aligned}$$

这里 α, β 是实际错误率；若再用目标错误率替代，又增加了一层近似。公式的用途是解释证据积累速度与观察成本的关系，不是无误差的样本数预算。

越界的含义可以写得很具体：在 D_0 上 $S_T = a + O_+$ ，在 D_1 上 $S_T = b - O_-$ ，其中 $O_+, O_- \geq 0$ 。若 $|\ell(Y)| \leq c$ ，则两种越界量至多为 c 。用实际错误率作权重时，忽略越界造成的 $\mathbb{E}_i S_T$ 误差至多 c ，平均样本数误差至多 $c/|\mu_i|$ 。当单步证据相对于阈值不小，越界就不应忽略。

C.5 一个 Bernoulli 方向检查

检验 $H_0 : p = 0.4$ 与 $H_1 : p = 0.6$ ，则

$$\ell(Y) = \begin{cases} \log(2/3), & Y = 1, \\ \log(3/2), & Y = 0. \end{cases}$$

观察到 1 支持成功率较高的 H_1 ，因此对数似然比下降，与 f_0/f_1 的约定一致。

若两个目标错误率均为 0.05，保守阈值为 $B = 0.05, A = 20$ 。因为每步对数证据为 $\pm \log(3/2)$ ，而 $7 \log(3/2) < \log 20 < 8 \log(3/2)$ ，实际停止发生在“零的累计个数减去一的累计个数”首次达到 ± 8 时。终端似然比不是恰好 20 或 $1/20$ ，这正是离散越界的可见例子。

材料依据。上传的 MIT 第 23 讲约 00:00–00:51，尤其是似然比方向、双阈值、平均试验次数与 overshoot 的讨论；衔接第 24 讲对停止极限交换的提醒。一般复合假设、自适应采样和序贯检验最优性定理不在本附录展开。